

Beschreibende Statistik

1. Einführung

1.1. Deskriptive und induktive Statistik

Deskriptiven Statistik oder beschreibende Statistik

Alle Aussagen und Schlussfolgerungen beziehen sich auf das zu Grunde liegende Datenmaterial.

Induktiven Statistik oder schließende Statistik

Man schließt mithilfe der Wahrscheinlichkeitsrechnung aus den Verhältnissen einer Stichprobe auf die Gesamtheit.

1.2. Statistische Einheiten, statistische Gesamtheit und Merkmale

- **Statistische Einheit, statistisches Element:** einzelnes, elementares Objekt.
- **Statistische Gesamtheit, statistische Masse:**
Menge von statistischen Einheiten mit denselben Identifikationsmerkmalen.
- Jede statistische Einheit besitzt ein oder mehrere **Merkmale** (charakteristische Eigenschaft, Identifikationsmerkmal).
- Jedes Merkmal hat zwei oder mehr **Merkmalsausprägungen**.
- Als **Merkmalswert** bezeichnet man die bei einer statistischen Einheit festgestellte Merkmalsausprägung.

Beispiel: Wi24 SEA

Untersuchung der Studierenden des Kurses ...

Statistische Masse: alle Studierende aus dem Kurs

Statistische Einheit: Frau ... Herr...

Merkmale: Noten in Mathe vom 1. Sem, Anwesenheit

Merkmalsausprägungen der Merkmale: 1,0; 1,1;...; 4,9; 5,0

Merkmalswert: Frau X...: $a_3 = 1,4$

1.3. Skalen

Merkmalsart	Skala	Interpretation	Beispiele
Rein qualitativ	Nominalskala	Verschiedenartigkeit	Geschlecht
qualitativ / komparativ	Ordinalskala	Verschiedenartigkeit Ordnung	Sportabzeichen
quantitativ	Intervallskala oder Verhältnisskala mit natürlichem Ursprung	Verschiedenartigkeit Ordnung Differenzen Verhältnissen mit natürlichem Ursprung	Alter Einkommen

Intervall- und Verhältnisskalen werden auch als **metrische** Skalen bezeichnet.

- **Diskrete Merkmale**

Ein Merkmal wird als diskret bezeichnet, wenn es auf einer metrischen Skala nur bestimmte Werte annehmen kann.

Beispiele: Anzahl der Mathebücher

- **Stetige Merkmale**

Ein Merkmal wird als stetig bezeichnet, wenn es zumindest in einem bestimmten Intervall jeden beliebigen Wert annehmen kann.

Beispiele: Körpergröße

Auch stetige Merkmale lassen in der Praxis wegen der Grenzen der Messgenauigkeit nur diskret erfassen.

1.4. Beispiel

Nr.	Alter	Ge- schlecht	Körper- größe	Auto	Netto- einkommen	Abitur- note	Sportab- zeichen
1	22	m	179	j	1050	2,7	Bronze
2	19	m	185	n	2000	1,8	Bronze
3	24	w	165	j	1585	2,2	Gold
4	20	m	175	j	1200	2,3	-
5	18	w	159	n	950	1,4	Silber
6	20	w	172	j	800	2,0	Bronze
7	22	w	164	j	950	2,5	-
8	28	w	175	j	1900	2,3	-
9	21	w	174	n	855	2,0	Gold
10	20	m	182	j	950	2,0	Bronze
11	25	m	180	n	790	1,7	Silber
12	19	w	163	n	825	3,0	Silber
13	26	m	176	n	1000	2,1	Gold
14	21	w	160	j	750	2,4	Bronze

2. Univariate Verteilungen

2.1. Darstellungsformen

2.1.1. Tabellarische Darstellung


Begriffe	Symbole
Statistische Masse Grundgesamtheit bestehend aus statistischen Einheiten mit denselben Identifikationsmerkmalen	Umfang: n
Urliste enthält Merkmalswerte	$a_1, \dots, a_n$
Merkmalsausprägungen	$x_1, \dots, x_m; m \leq n$ $m=5$
absolute Häufigkeit der Ausprägung x_i	$h_i = h(x_i)$ $h_1 + h_2 + \dots + h_m = \sum_{i=1}^m h_i = n$ $0 \leq h_i \leq n; i = 1, \dots, m.$
relativen Häufigkeiten	$f_i = \frac{h_i}{n}; i = 1, \dots, m$ $0 \leq f_i \leq 1; i = 1, \dots, m$ $f_1 + f_2 + \dots + f_m = \sum_{i=1}^m f_i = 1$
Kumulierte absolute Häufigkeit absolute Summenhäufigkeit H_i : Anzahl der statistischen Einheiten, deren Merkmalswert höchstens x_i beträgt.	$H_i = h_1 + h_2 + \dots + h_i = \sum_{j=1}^i h_j; i = 1, \dots, m$ $H_m = n$

Kumulierte relative Häufigkeit relativen Summenhäufigkeiten F_i: Anteil der statistischen Einheiten, deren Merkmalswert höchstens x_i beträgt.	$F_i = f_1 + f_2 + \dots + f_i = \sum_{j=1}^i f_j ;$ $i = 1, \dots, m$ $F_i = \frac{H_i}{n} ; \quad i = 1, \dots, m.$
Empirische Verteilungsfunktion = Relative Summenhäufigkeitsfunktion $F(x)$ gibt den Anteil der statistischen Einheiten mit einem Merkmalswert kleiner oder gleich x an. Die Summenhäufigkeitsfunktion ist eine Treppenfunktion.	$F(x) = \begin{cases} 0 & \text{für } x < x_1 \\ F_i & \text{für } x_i \leq x < x_{i+1}; \quad i = 1, \dots, m-1 \\ 1 & \text{für } x \geq x_m \end{cases}$
Häufigkeitsverteilung	Darstellung der Merkmalsausprägungen x_i mit h_i bzw. f_i in tabellarischer oder graphischer Form

2.1.2. Graphische Darstellungen


- Stabdiagramm (Säulendiagramm)

Die **Höhe** der i -ten Säule entspricht der absoluten bzw. der relativen Häufigkeit.




- Rechteckdiagramm

Die Häufigkeiten werden mittels **Teilflächen** dargestellt.



- Kreisdiagramm


Aufteilung der Kreisfläche: Winkel α : $\alpha_i = f_i \cdot 360^\circ$.



$$\alpha_1 = 20^\circ, \alpha_2 = 40^\circ, \alpha_3 = 120^\circ, \alpha_4 = 180^\circ$$

- Piktogramm

Die Häufigkeiten werden durch Bildsymbole (z.B. „Männchen“) dargestellt.



(Ein „♂“ entspricht 5,56%.)

✓ Aufgabe

Bei einer Untersuchung über die Mietpreise einer Kleinstadt erhebt man bzgl. 40 ausgewählter Wohnungen folgende Urliste:

Nr. i der statistischen Einheit	Merkmalswert a_i (in €/qm)	Nr. i der statistischen Einheit	Merkmalswert a_i (in €/qm)
1	12	21	12
2	8	22	10
3	14	23	8
4	10	24	14
5	12	25	12
6	16	26	14
7	14	27	8
8	16	28	16
9	8	29	10
10	10	30	12
11	12	31	14
12	12	32	10
13	14	33	16
14	12	34	12
15	16	35	10
16	14	36	8
17	12	37	12
18	10	38	14
19	8	39	12
20	10	40	10

- Erstellen Sie die Häufigkeitstabelle mit den absoluten und relativen Häufigkeiten sowie den absoluten und relativen Summenhäufigkeiten.
- Zeichnen Sie die empirische Verteilungsfunktion.

Lösung:

$$f_i = h_i / n$$

Merkmalsausprägung x_i	absolute Häufigkeit h_i	relative Häufigkeit f_i	absolute Summenhäufigkeit H_i	relative Summenhäufigkeit F_i
8	6	0,15	6	0,15
10	9	0,225	6+9=15	0,15 + 0,225 = 0,375
12	12	0,3	27	0,675
14	8	0,2	35	0,875
16	5	0,125	40	1

2.2. Darstellungsformen klassierter Daten

Klassen werden verwendet für

- diskrete Merkmale mit sehr vielen Merkmalsausprägungen,
- stetige Merkmale.

Beispiel

Klausurnoten an der DHBW _____

2.2.1. Tabellarische Darstellung

Die tabellarische Darstellung ähnelt der Darstellung unklassierter Daten.

Sie wird ergänzt um die absolute bzw. relative Dichte einer Klasse. Desweiteren ist die empirische Verteilungsfunktion stetig.

Begriffe	Symbole
absolute und relative Dichte	$d_i^a = \frac{h_i}{w_i}$ bzw. $d_i^r = \frac{f_i}{w_i}$
Klassierte Verteilungsfunktion Empirische Verteilungsfunktion	$F(x) = \begin{cases} 0 & x < x_1^u \\ F_{i-1} + d_i^r(x - x_i^u) & x \in [x_i^u, x_i^o[, \text{ alle } i \\ 1 & x \geq x_k^o \end{cases}$

2.2.2. Graphische Darstellung

Histogramm

Über den jeweiligen Klassen werden Rechtecke mit der Höhe d_i und der Klassenbreite w_i gebildet.

Die **Fläche** jedes Rechtecks ist **proportional** zur relativen Klassenhäufigkeit f_i .

$$d_i = \frac{f_i \cdot a}{w_i}; \quad a \text{ ist ein Proportionalitätsfaktor.}$$

Aufgabe

Bei einer Untersuchung über die Lebensdauer (in Stunden) von 100 Glühbirnen erhielt man folgende Häufigkeitsverteilung:

Klasse Nr i	Klassenbreite (in Stunden)	Anzahl h_i^* der Glühbirnen	f_i	F_i
1	$0 \leq x \leq 100$	1	0,01	0,01
2	$100 < x \leq 500$	24	0,24	0,25
3	$500 < x \leq 1000$	45	0,45	0,7
4	$1000 < x < 2000$	30	0,3	1

- Ergänzen Sie die Häufigkeitstabelle um die relativen Klassenhäufigkeiten, den absoluten und den relativen Summenhäufigkeiten.
- Zeichnen Sie das Histogramm.
- Zeichnen Sie die Summenhäufigkeitsfunktion und ermitteln Sie graphisch den Anteil der Glühbirnen mit einer Lebensdauer von höchstens 600 Stunden, von mindestens 400 Stunden und einer Lebensdauer zwischen 300 und 700 Stunden.

2.3. Verteilungsformen




Abb. 1: eingipflige Verteilung




Abb. 2: U-förmige Verteilung




Abb. 3: mehrgipflige Verteilung




Abb. 4: eingipflige Verteilung, linksschief (rechtssteil)




Abb. 5: eingipflige Verteilung, rechtsschief (linkssteil)




Abb. 6: symmetrische, eingipflige Verteilung

3. Statistische Maßzahlen univariater Verteilungen

3.1. Lageparameter

3.1.1. Modus $\tilde{x}_D$ und modale Klasse

Skalenniveau: beliebig.

Modus

Der **Modus** oder auch **Modalwert** $\tilde{x}_D$ ist die Merkmalsausprägung einer Häufigkeitsverteilung, die am **häufigsten** vorkommt.

Wenn es mehrere Merkmalsausprägungen mit höchster Häufigkeit gibt, gibt es mehrere Modalwerte.

Für nominal skalierte Merkmale ist der Modus der einzig mögliche Lageparameter.

Modale Klasse

Für klassierte Daten gibt man die am dichtesten besetzte Klasse an:

$\max\left(\frac{f_i}{w_i}\right)$ bzw. $\max\left(\frac{h_i}{w_i}\right)$. Man erkennt die modale Klasse am steilsten Anstieg der Verteilungsfunktion.

3.1.2. Median ($\tilde{x}$) und α -Quantil ($\tilde{x}_\alpha$)

Skalenniveau: Ordinal oder metrisch

3.1.2.1 Median $\tilde{x}$

Der Median $\tilde{x}$ entspricht dem 0.5 – Quantil ($\tilde{x}_{0.5}$) und wird auch als das zweite Quartil oder mit Zentralwert bezeichnet.

Liegt die Urliste in geordneter Reihenfolge vor, so ist der Median (Zentralwert) $\tilde{x}$ die Merkmalsausprägung die in der Mitte der Beobachtungsreihe steht.

Median für metrische Merkmale:

$$\tilde{x} = \begin{cases} a_{\left(\frac{n+1}{2}\right)} & \text{falls } n \text{ ungerade} \\ \frac{1}{2} \left(a_{\left(\frac{n}{2}\right)} + a_{\left(\frac{n}{2}+1\right)} \right) & \text{falls } n \text{ gerade} \end{cases}$$

Median für ordinal skalierte Merkmale:

$$\tilde{x} = a_{(k)} \text{ mit } k = \frac{n+1}{2} \text{ für } n \text{ ungerade und } k = \frac{n}{2} \text{ für } n \text{ gerade.}$$

Eigenschaften des Medians

- Mindestens 50% der Daten sind kleiner oder gleich dem Median $\tilde{x}$ und höchstens 50% der Daten größer als der Median $\tilde{x}$.
- Der Median ist unempfindlich gegenüber Ausreißern.

Median für klassierte Daten

Seien $K_1, K_2, \dots, K_k$ Klassen mit den relativen Häufigkeiten $f_1, f_2, \dots, f_k$.

Bestimme die Klasse K_i , die den Median enthält:

Für diese Klasse K_i gilt: $F_{i-1} < 0,5$ und $F_i \geq 0,5$.

Sei $F_0 = 0$.

Berechnung des Medians:

Bsp. (Seite 9) $i = 3$
3. Klasse

$$\tilde{x} = x_i^u + \frac{0,5 - F_{i-1}}{f_i} \cdot w_i \text{ mit } x_i^u = \text{Untergrenze des Intervalls und } w_i = \text{Klassenbreite des Intervalls}$$


Der Median einer klassierten Verteilung lässt sich leicht am Graphen der empirischen Verteilungsfunktion ablesen.

Aufgabe: Berechnen Sie den Median für die Lebensdauer der Glühbirnen.

3.1.2.2. α -Quantil

Als α - Quantil $\tilde{x}_\alpha$ (mit $0 < \alpha < 1$), bezeichnet man den Wert der geordneten Urliste mit folgender Eigenschaft:

Mindestens $\alpha \cdot 100\%$ der Merkmalswerte sind kleiner oder gleich dem α - Quantil $\tilde{x}_\alpha$, und höchstens $(1-\alpha) \cdot 100\%$ der Daten sind größer als das α - Quantil.



Spezielle α -Quantile

Der Median ist das 0,5-Quantil. Für $\alpha = 0,25$ spricht man vom unteren Quartil, für $\alpha = 0,75$ vom oberen Quartil. Das $(1-\alpha)$ -Quantil bezeichnet man als α - Fraktile.

3.1.3. Arithmetisches Mittel $\bar{x}$

Skalenniveau: metrisch

Das arithmetische Mittel $\bar{x}$ ist der am häufigsten verwendete Lageparameter.

Das arithmetische Mittel für unklassierte Verteilungen

(1) Berechnung aus der Urliste

$$\bar{x} = \frac{1}{n} (a_1 + a_2 + \dots + a_n) = \frac{1}{n} \sum_{i=1}^n a_i$$

(2) Berechnung aus der Häufigkeitstabelle

$$\bar{x} = \frac{1}{n} (h_1 x_1 + h_2 x_2 + \dots + h_m x_m) = \frac{1}{n} \sum_{i=1}^m h_i x_i \quad \text{oder}$$
$$\bar{x} = (f_1 x_1 + f_2 x_2 + \dots + f_m x_m) = \sum_{i=1}^m f_i x_i$$

Diesen Wert bezeichnet man auch als **gewogenes arithmetisches Mittel**.

Das arithmetische Mittel für klassierte Verteilungen:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k h_i \tilde{x}_i = \sum_{i=1}^k f_i \tilde{x}_i$$

Mit $\tilde{x}_i$ ist das arithmetische Mittel der i-ten Klasse oder als Ersatz deren Klassenmitte.

Aufgaben

Berechnen Sie das arithmetische Mittel

- für den Mietpreis. $\bar{x} = 11,85$
- für die Lebensdauer der Glühbirnen. $\bar{x} = 860$

Eigenschaften des arithmetischen Mittels $\bar{x}$

1. Das arithmetische Mittel ist empfindlich gegenüber Ausreißern.
2. Je stärker eine Verteilung von den Eigenschaften Eingipfligkeit und Symmetrie abweicht, desto weniger ist das arithmetische Mittel zur Beschreibung der „durchschnittlichen“ Lage der Verteilung geeignet.


3.1.4. Verteilungsformen und Lageparameter

Für metrisch skalierte Merkmale können der **Modus $\bar{x}_D$** , der **Median $\tilde{x}$** und das **arithmetische Mittel $\bar{x}$** zur Beurteilung der Symmetrie oder Schiefe einer Verteilung herangezogen werden.

Für eine **symmetrische** Verteilung gilt: $\bar{x}_D \approx \tilde{x} \approx \bar{x}$.


Für eine **linkssteile** Verteilung gilt: $\bar{x}_D < \tilde{x} < \bar{x}$

Für eine **rechtssteile** Verteilung gilt: $\bar{x}_D > \tilde{x} > \bar{x}$



3.2. Streuungsparameter

Beispiel



Die in der Graphik dargestellten Häufigkeitsverteilungen A, B und C haben alle das gleiche arithmetische Mittel. Die Beschreibung der Verteilung erfolgt zusätzlich über ein Streuungsmaß.

3.2.1. Spannweite (Range)

$$w = \max_i a_i - \min_i a_i$$

Beispiel

Im Monat August wurden folgende Temperaturen gemessen: 17, 19, 21, 29, 31. Als Spannweite ergibt sich $w = 31 - 17 = 14$

Eigenschaften

- Der **Streubereich** einer Häufigkeitsverteilung ist der Bereich, in dem alle Merkmalswerte liegen. Die Spannweite gibt die **Breite des Streubereichs** an.
- Die Spannweite ist für eine erste, schnelle Abschätzung der Streuung geeignet.
- Die Spannweite ist empfindlich gegenüber Extremwerten bzw. Ausreißern.
- Eine Spannweite kann schon für ordinalskalierte Merkmale angegeben werden.

3.2.2. Varianz und Standardabweichung

Varianz

Die **Varianz** ist das am häufigsten verwendete Streuungsmaß. Sie misst die Streuung um das arithmetische Mittel $\bar{x}$.

Berechnung der Varianz aus der Urliste:

$$s^2 = \frac{1}{n} \sum_{i=1}^n (a_i - \bar{x})^2.$$

Beispiel

Berechnen Sie die Varianz der Messwerte (Schraubenlängen in cm) 18, 17, 20, 18, 19 mit den beiden angegebenen Formeln.

Aufgabe

Zeigen Sie, dass folgende Gleichung gilt:

$$s^2 = \frac{1}{n} \sum_{i=1}^n (a_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n a_i^2 - \bar{x}^2$$

Berechnung der Varianz aus der Häufigkeitstabelle:

$$s^2 = \frac{1}{n} \sum_{i=1}^m h_i (x_i - \bar{x})^2$$

Aufgabe

Zeigen Sie, dass folgende Gleichung gilt:

$$s^2 = \frac{1}{n} \sum_{i=1}^m h_i (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^m h_i x_i^2 - \bar{x}^2$$

Varianz für klassierte Daten

$$s^2 = \sum_{i=1}^k f_i (\tilde{x}_i - \bar{x})^2 + \sum_{i=1}^k f_i \frac{w_i^2}{12}$$

mit $\tilde{x}_i$ ist arithmetische Mittel der i-ten Klasse oder deren Klassenmitte.

Standardabweichung

$$s = \sqrt{s^2}$$

Die Standardabweichung besitzt die **gleiche Dimension** wie die Beobachtungswerte.

Beispiel

Berechnen Sie die Varianz für die Mietpreise.

Anmerkungen

- 1) Zur Berechnung der Varianz sollte man die Formel $s^2 = \frac{1}{n} \sum_{i=1}^n a_i^2 - \bar{x}^2$ nur verwenden, wenn man die Berechnungen „von Hand“ durchführt. Es kann hierbei das Problem der Auslöschung auftreten.
- 2) z-Transformation: $a_i \rightarrow z_i = \frac{a_i - \bar{x}}{s} \Rightarrow \bar{z} = 0$ und $s_z^2 = 1$ (Rechnen Sie nach!)
- 3) Die Varianz kann nur für metrisch skalierte Merkmale berechnet werden.

3.2.3. Variationskoeffizient

Der Variationskoeffizient ist ein relatives Streuungsmaß und somit dimensionslos.

$$V = \frac{s}{\bar{x}} \quad \text{für } \bar{x} > 0.$$

Beispiel: Berechnen Sie V:

Gehaltsklassen	1	2
Durchschnittsgehälter in € pro h	7	80
Standardabweichung in €	2	8

4. Bivariate Verteilungen (Verteilungen von zwei Merkmalen)

4.1. Zweidimensionale Häufigkeitstabelle

Sei X ein Merkmal mit den Ausprägungen $x_i, i = 1, \dots, m$ und

Y ein Merkmal mit den Ausprägungen $y_j, j = 1, \dots, r$.

Es gibt demnach $m \cdot r$ mögliche Kombinationen der Merkmalsausprägungen: (x_i, y_j) .

Beispiel

Von 28 Studienanfängern wurden die Abiturnoten in Mathematik und Englisch aufgelistet (Mathematiknote, Englischnote):

(4;2); (3;1); (3;3); (2;3); (4;4); (3;4); (3;3); (1;3); (3;2); (5;3); (3;3); (3;4); (3;3); (3;4); (2;3); (2;1); (2;2); (3;4); (3;3); (3;3); (1;1); (4;5); (5;4); (2;5); (2;2); (2;3); (2;3); (3;4)

Bezeichnungen:

Mit h_{ij} bezeichnet man die **absoluten Häufigkeiten** der Kombinationen (x_i, y_j) , mit

f_{ij} die dazu gehörenden **relativen Häufigkeiten**.

Zusammengefasst werden die Merkmalsausprägungen x_i und y_j mit den dazugehörenden Häufigkeiten (absolut oder relativ) in einer **Häufigkeitstabelle**:

$X \backslash Y$	y_1	y_2	...	y_r
x_1	h_{11}	h_{12}	...	h_{1r}
x_2	h_{21}	h_{22}	...	h_{2r}
...	...	...	...	...
x_m	h_{m1}	h_{m2}	...	h_{mr}

Beispiel

Für die Abiturnoten der 28 Studenten ergibt sich folgende Häufigkeitstabelle:

$X \backslash Y$	1	2	3	4	5	
1	1		1			2
2	1	2	4		1	8
3	1	1	6	5		13
4		1		1	1	3
5			1	1		2
	3	4	12	7	2	28

Merkmal X: Mathematiknoten, Merkmal Y: Englischnoten.

4.2. Randverteilungen und bedingte Verteilungen

Die Verteilung nur eines Merkmals einer zweidimensionalen Häufigkeitsverteilung nennt man die **Randverteilung**. Hierzu ergänzt man die Häufigkeitstabelle durch die Zeilen- bzw. Spaltensummen (Randhäufigkeiten).

Aufgabe:

Ergänzen Sie die Häufigkeitstabelle der Abiturnoten um die Zeilen- bzw. Spaltensummen.

Bedingte Verteilung

Die bedingte Verteilung des Merkmals X unter der Bedingung $Y = y_j$ wird mit den Werten

$$f(x_i | Y = y_j) = \frac{h_{ij}}{h_{\bullet j}}, \quad i = 1, \dots, m \text{ angegeben.}$$

Die bedingte Verteilung des Merkmals Y unter der Bedingung $X = x_i$ wird mit den Werten

$$f(y_j | X = x_i) = \frac{h_{ij}}{h_{i\bullet}}, \quad j = 1, \dots, r \text{ angegeben.}$$

Für obiges **Beispiel** ergeben sich beispielsweise folgende bedingte Verteilungen:

$$f(x_i | y = 1) = \frac{h_{ij}}{h_{\bullet 1}}, \quad i = 1, \dots, 5$$

x_i	1	2	3	4	5
$f(x_i y = 1)$	1/3	1/3	1/3	0	0

$$f(y_j | x = 3) = \frac{h_{ij}}{h_{3\bullet}}, \quad j = 1, \dots, 5$$

y_i	1	2	3	4	5
$f(y_j x = 3)$	1/13	1/13	6/13	5/13	0

Statistische Unabhängigkeit

Beispiel: Klausurnoten im Kurs WWI ...

Noten	1	2	3	4	n.B	
Frauen	2	5	2	1	2	12
Männer	4	10	4	2	4	24
	6	15	6	3	6	36

Ergänzen Sie die Tabelle um die Zeilen-, bzw. Spaltensummen.

Ist die Verteilung der Noten abhängig vom Geschlecht der Studierenden?

Bei statistischer Unabhängigkeit gilt:

$$h_{ij} = h_{ij}^u = \frac{h_{\cdot j} \cdot h_{i \cdot}}{n}, \forall h_{ij}$$

4.3. Parameter zweidimensionaler Häufigkeits-Verteilungen

Alle in Kapitel 2 und Kapitel 3 behandelten statistischen Maßzahlen lassen sich auf die Randverteilungen und die bedingten Verteilungen anwenden, da sie eindimensionale Verteilungen sind.

Beispiel:

Berechnen Sie das arithmetische Mittel des Zeilenmerkmals X (Mathematiknote) und des Spaltenmerkmals Y (Englischnote).

Kovarianz

$$\begin{aligned} s_{xy} &= \frac{1}{n} \sum_{i=1}^m \sum_{j=1}^r h_{ij} (x_i - \bar{x})(y_j - \bar{y}) \\ &= \frac{1}{n} \sum_{i=1}^m \sum_{j=1}^r h_{ij} x_i y_j - \bar{x} \bar{y} \end{aligned}$$

Die Kovarianz ist ein Parameter für die gemeinsame Streuung beider Merkmale X und Y. Ist die Kovarianz positiv, spricht man von „**gleichläufiger Variation**“: die Veränderung eines Merkmals führt zu einer gleichgerichteten Veränderung des anderen Merkmals.

Ist die Kovarianz negativ, spricht man von „**gegenläufiger Variation**“: die Veränderung eines Merkmals führt zu einer gegen gerichteten Veränderung des anderen Merkmals.

Aufgabe

Berechnen Sie die Kovarianz der Abiturnoten und interpretieren Sie das Ergebnis.

5. Maßzahlen des rechnerischen Zusammenhangs

5.1. Chi-Quadrat-Koeffizient

Der Chi-Quadrat-Koeffizient kann für beliebiges Skalenniveau berechnet werden und gibt Auskunft über die Ausprägtheit eines Zusammenhangs.

$$\chi^2 = \sum_i \sum_j \frac{(h_{ij} - h_{ij}^u)^2}{h_{ij}^u}, \quad \chi^2 \in [0, \infty[$$

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}, \quad C \in [0, \min(k, m)]$$

$$C^* = \frac{C}{C_{\max}}, \quad C^* \in [0, 1]$$

$$C_{\max} = \sqrt{\frac{\min(k, m) - 1}{\min(k, m)}}$$

Liegt der C^* nahe bei Null, so sind die Merkmale eher unabhängig voneinander, liegt der Koeffizient nahe bei Eins, so liegt eher eine statistische Abhängigkeit vor.

Aufgabe:

Berechnen Sie C^* .

	Fach 1	Fach 2	Fach 3	
Gut	1	6	3	10
Befriedigend	4	3	3	10
Ausreichend	0	1	4	5
	5	10	10	25

5.2. Pearson'scher Korrelationskoeffizient r


Der Pearson'sche Korrelationskoeffizient r drückt den Grad der **Linearität** zwischen zwei **metrischen** Merkmalen X und Y aus. Er ist ein normiertes Maß: $-1 \leq r \leq 1$.

$$r = \frac{S_{xy}}{S_x S_y}$$

Interpretation des Korrelationskoeffizienten

- $r = 1$: Alle Beobachtungswerte liegen auf einer steigenden Geraden.
- $r = -1$: Alle Beobachtungswerte liegen auf einer fallenden Geraden.
- $r > 0$: Die Merkmale sind positiv korreliert, die Regressionsgerade ist steigend.
- $r < 0$: Die Merkmale sind negativ korreliert, die Regressionsgerade ist fallend.
- $r = 0$: Die Merkmale sind unkorreliert, es besteht kein linearer Zusammenhang.

Je näher der Korrelationskoeffizient bei $+1$ bzw. -1 liegt, desto enger scharen sich die Beobachtungswerte um die Regressionsgerade und desto stärker ist der lineare Zusammenhang.



Aufgabe

Von 10 Waschmittelfirmen wurden die Aufwendungen für die Werbung (X ; in 1000 €) und die Umsätze (Y ; in Mio. €) gegenübergestellt.

x_i	4	6	8	9	10	11	12	12	13	15
y_i	8	4	9	10	13	12	10	16	15	21

Zeichnen Sie ein Streuungsdiagramm und berechnen Sie den Korrelationskoeffizienten.

Kontrolle: $r = 0,855$

6. Lineare Regressionsanalyse

Regressionsfunktion

In der Regressionsanalyse wird die Tendenz des Zusammenhangs in einer mathematischen Funktion beschrieben.

Wir beschränken uns auf den **linearen** Zusammenhang und suchen eine Funktion der Form:

$$y^*(x) = a + b \cdot x$$

Beispiel:

Gegeben sind folgende Beobachtungswerte:

i	1	2	3	4
X _i	1	1	3	3
Y _i	1	3	2	4

Zeichnen Sie ein Streudiagramm.

Die Berechnung der Regressionsfunktion erfolgt mit Hilfe der **Methode der kleinsten Quadrate**:

Mithilfe zweier partieller Ableitungen ergibt sich für die **Steigung b**:

$$b = \frac{s_{xy}}{s_x^2}$$

Die arithmetischen Mittel beider Merkmale $\bar{x}$ und $\bar{y}$ liegen auf der Regressionsgeraden. Daraus ergibt sich für a:

$$a = \bar{y} - b \cdot \bar{x} \quad \textbf{Schwerpunkteigenschaft}$$

Aufgabe

Berechnen Sie die Regressionsfunktion für die „Waschmittelfirmen“. ($Y = 1,22x - 0,4$)

Bestimmtheitsmaß

Das Bestimmtheitsmaß gibt Auskunft über die **Güte der Regressionsfunktion**:

X_i	1	1	3	3
Y_i	1	3	2	4
$Y_i^* = 0,5x_i + 1,5$	2	2	3	3

Berechnen Sie: $\frac{s_{y^*}^2}{s_y^2} =$ $r^2 = \left(\frac{s_{xy}}{s_x \cdot s_y} \right)^2 =$

$B = r^2$ gibt den durch die Regressionsgerade erklärten Anteil an der Gesamtvarianz an.
($0 \leq B \leq 1$)

Im Beispiel werden 20 % der Gesamtvarianz durch die Regressionsgerade erklärt.

Je größer B, desto sinnvoller ist der lineare Ansatz der Regressionsfunktion.

Ist $B = 1$, so liegen alle Beobachtungswerte auf einer Gerade