

Management-Reihe Corporate Social Responsibility
René Schmidpeter *Hrsg.*

Reinhard Altenburger ·
René Schmidpeter *Hrsg.*

CSR und Künstliche Intelligenz



Springer Gabler

Management-Reihe Corporate Social Responsibility

Reihe herausgegeben von

René Schmidpeter, M3TRIX, Köln, Deutschland

Das Thema der gesellschaftlichen Verantwortung gewinnt in der Wirtschaft und Wissenschaft gleichermaßen an Bedeutung. Die Management-Reihe Corporate Social Responsibility geht davon aus, dass die Wettbewerbsfähigkeit eines jeden Unternehmens davon abhängen wird, wie es den gegenwärtigen ökonomischen, sozialen und ökologischen Herausforderungen in allen Geschäftsfeldern begegnet. Unternehmer und Manager sind im eigenen Interesse dazu aufgerufen, ihre Produkte und Märkte weiter zu entwickeln, die Wertschöpfung ihres Unternehmens den neuen Herausforderungen anzupassen sowie ihr Unternehmen strategisch in den neuen Themenfeldern CSR und Nachhaltigkeit zu positionieren. Dazu ist es notwendig, generelles Managementwissen zum Thema CSR mit einzelnen betriebswirtschaftlichen Spezialdisziplinen (z. B. Finanzen, HR, PR, Marketing etc.) zu verknüpfen. Die CSR-Reihe möchte genau hier ansetzen und Unternehmenslenker, Manager der verschiedenen Bereiche sowie zukünftige Fach- und Führungskräfte dabei unterstützen, ihr Wissen und ihre Kompetenz im immer wichtiger werdenden Themenfeld CSR zu erweitern. Denn nur, wenn Unternehmen in ihrem gesamten Handeln und allen Bereichen gesellschaftlichen Mehrwert generieren, können sie auch in Zukunft erfolgreich Geschäfte machen. Die Verknüpfung dieser aktuellen Managementdiskussion mit dem breiten Managementwissen der Betriebswirtschaftslehre ist Ziel dieser Reihe. Die Reihe hat somit den Anspruch, die bestehenden Managementansätze durch neue Ideen und Konzepte zu ergänzen, um so durch das Paradigma eines nachhaltigen Managements einen neuen Standard in der Managementliteratur zu setzen.

Weitere Bände in der Reihe <http://www.springer.com/series/11764>

Reinhard Altenburger · René Schmidpeter
(Hrsg.)

CSR und Künstliche Intelligenz

Hrsg.
Reinhard Altenburger
University of Applied Sciences Krems
IMC Fachhochschule Krems
Krems, Österreich

René Schmidpeter
M3TRIX, Köln, Deutschland

ISSN 2197-4322 ISSN 2197-4330 (electronic)
Management-Reihe Corporate Social Responsibility
ISBN 978-3-662-63222-2 ISBN 978-3-662-63223-9 (eBook)
<https://doi.org/10.1007/978-3-662-63223-9>

Die Deutsche Nationalbibliothek verzeichnet diese Publikation in der Deutschen Nationalbibliografie; detaillierte bibliografische Daten sind im Internet über <http://dnb.d-nb.de> abrufbar.

© Der/die Herausgeber bzw. der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

Das Kapitel „Künstliche Intelligenz und die Zukunft von Arbeit“ wird unter der Creative Commons Namensnennung 4.0 International Lizenz (<http://creativecommons.org/licenses/by/4.0/deed.de>) veröffentlicht.

Das Werk einschließlich aller seiner Teile ist urheberrechtlich geschützt. Jede Verwertung, die nicht ausdrücklich vom Urheberrechtsgesetz zugelassen ist, bedarf der vorherigen Zustimmung der Verlage. Das gilt insbesondere für Vervielfältigungen, Bearbeitungen, Übersetzungen, Mikroverfilmungen und die Einspeicherung und Verarbeitung in elektronischen Systemen.

Die Wiedergabe von allgemein beschreibenden Bezeichnungen, Marken, Unternehmensnamen etc. in diesem Werk bedeutet nicht, dass diese frei durch jedermann benutzt werden dürfen. Die Berechtigung zur Benutzung unterliegt, auch ohne gesonderten Hinweis hierzu, den Regeln des Markenrechts. Die Rechte des jeweiligen Zeicheninhabers sind zu beachten.

Der Verlag, die Autoren und die Herausgeber gehen davon aus, dass die Angaben und Informationen in diesem Werk zum Zeitpunkt der Veröffentlichung vollständig und korrekt sind. Weder der Verlag, noch die Autoren oder die Herausgeber übernehmen, ausdrücklich oder implizit, Gewähr für den Inhalt des Werkes, etwaige Fehler oder Äußerungen. Der Verlag bleibt im Hinblick auf geografische Zuordnungen und Gebietsbezeichnungen in veröffentlichten Karten und Institutionsadressen neutral.

Einbandabbildung: Michael Bursik

Planung/Lektorat: Christine Sheppard

Springer Gabler ist ein Imprint der eingetragenen Gesellschaft Springer-Verlag GmbH, DE und ist ein Teil von Springer Nature.

Die Anschrift der Gesellschaft ist: Heidelberger Platz 3, 14197 Berlin, Germany

Vorwort des Reihenherausgeber

Künstliche Intelligenz – Auf der Suche nach positiven Impact für die Gesellschaft durch neue technologische Lösungen!

Prof. Dr. René Schmidpeter



Nachhaltigkeit und Profit – sind kein Gegensatz, sondern eine untrennbare Basis erfolgreichen Unternehmertums! Dieses neue Mindset wirtschaftlichen Handelns vermittelt auch eine wichtige Grundlage für die weitere Entwicklung neuer Technologien. Insbesondere die künstliche Intelligenz (KI) hat das Potenzial, großen Nutzen für den Menschen zu stiften, aber birgt auch große Gefahren, wenn sie nicht den Menschen und seine Bedürfnisse in den Mittelpunkt ihres Denkens und Handelns stellt. Es gilt daher, die negativen Effekte der KI zu minimieren und das Potenzial des positiven Impacts neuer Technologien zu nutzen, mit dem Ziel neuen Nutzen und Mehrwert für die Gesellschaft zu stiften. Dazu ist es notwendig, die potenziellen Fehler, Verzerrungen und Risiken von Computeralgorithmen besser zu verstehen, die von IT-Entscheidungen betroffenen und beteiligten Stakeholder in die Technologieentwicklung und bei deren

Anwendungen einzubeziehen sowie eine IT-Kultur basierend auf Werten der Fairness, sozialen Gerechtigkeit und Inklusion zu schaffen.

Um Schaden durch IT-Programme zu vermeiden, gilt es, die Privatsphäre, Würde und Einzigartigkeit von Menschen bei der Datenerhebung und -verarbeitung zu respektieren. Dabei müssen Transparenz geschaffen und die Wirkungen von Big Data auch bei Entscheidungen ethisch reflektiert werden, insbesondere wenn verschiedene Datenquellen miteinander verbunden werden bzw. private Daten in die öffentliche Entscheidungsfindung einfließen. Dafür bedarf es klarer organisatorischer bzw. branchenweiter Governance-Strukturen und -Richtlinien, die die ethischen und juristischen Prinzipien der Datenverarbeitung regeln sowie technischer, wirtschaftlicher und juristischer Expertise. Damit ist eine enge Verknüpfung der Entwicklung von neuen technischen Anwendungen und wirtschaftlichen Geschäftsmodellen mit der Corporate Social Responsibility (CSR) von Unternehmen unbedingt notwendig.

Wie diese neuen wissenschaftlichen Erkenntnisse und Managementüberlegungen ganz konkret bei der Entwicklung von KI sowie in innovativen IT-Geschäftsmodellen umgesetzt werden können, zeigen die zahlreichen Unternehmensbeispiele, aber auch die kritischen Reflexionen in diesem Band. Mein Dank geht daher an alle Autorinnen und Autoren sowie an meinen Mitherausgeber Prof. Dr. Reinhard Altenburger, die gemeinsam diesen umfassenden Einblick über den gegenwärtigen Stand der KI aus einer wirtschaftlichen und ethischen Perspektive geben. Und auch Frau Christine Sheppard sowie Frau Madhipriya Kumaran sei an dieser Stelle mein Dank für die vertrauensvolle Zusammenarbeit ausgedrückt. Nun ist es an Ihnen, werte Leserin und werter Leser, die Fülle dieses Bands aufzunehmen und für ihr innovatives Engagement in Sachen nachhaltiges Wirtschaften fruchtbar zu machen. Auch dafür herzlichen Dank!

Zur Person

Prof. Dr. René Schmidpeter steht als innovativer Vordenker für einen Paradigmenwechsel in der BWL und in der Managementwissenschaft. Er ist ein internationaler anerkannter Experte für nachhaltiges Management, nachhaltige Unternehmenstransformation und globale Nachhaltigkeitsentwicklungen. Er ist Professor für Nachhaltiges Management an der IU – International University und hat in den letzten fünf Jahren mehr als 150 Publikationen zum Thema CSR, Sustainability, Governance und Ethik in seinen deutsch- und englischsprachigen Managementreihen im Springer Gabler Verlag veröffentlicht. Er ist Berater und Mitgestalter in zahlreichen nationalen und internationalen Nachhaltigkeitsinitiativen und Thinktanks (China, Australien, Großbritannien, Japan, Slowenien, USA) und Gründer der M3TRIX GmbH – Institut für Sustainable Business Transformation in Köln.

Weblink und Kontakt: www.m3trix.de

Köln
Oktober 2021

Prof. Dr. René Schmidpeter

Vorwort der Herausgeber

Neben dem Klimawandel und der Globalisierung ist unsere Welt vor allem von einer fortschreitenden Technologisierung gekennzeichnet. Diese tiefgreifenden Veränderungen betreffen nicht nur uns, sondern werden auch unsere Kinder und ihre Art des Wirtschaftens massiv betreffen. Brauchten technologische Fortschritte in der Vergangenheit mehrere Jahrzehnte, um sich zu etablieren (Telefon z. B. rund 70 Jahre, um 100 Mio. Nutzer zu verzeichnen), so bedarf es mittlerweile nur mehr Jahre und manchmal nur mehr Monate, um disruptive Innovationen weltweit zu verbreiten.

Dies stellt sowohl die Unternehmen als auch jeden Einzelnen von uns vor große Herausforderungen. Zum einen ergeben sich aus dem technologischen Fortschritt immense Chancen, zum anderen auch Gefahren, die es gilt, ethisch und wirtschaftlich zu adressieren. Eine Technologie, die hier besonders großes Potenzial hat, die Welt zu verändern, ist die KI. KI ist – anderes als viele annehmen – nicht ein Ersatz oder gar eine dem Menschen überlegene Intelligenz, sondern ist komplementär zur menschlichen Intelligenz zu entwickeln.

Nur wenn es gelingt, die menschliche Kreativität, Ethik und Ästhetik zu bewahren und die KI in deren Dienste zu stellen, kann ein positiver Nutzen aus den neuen Technologien entstehen. Jeglicher Versuch, die KI als der menschlichen Intelligenz gleichwertig zu beschreiben bzw. im Sinn einer Singularität zu erreichen oder gar zu überflügeln, wird an ethischen und realen Grenzen scheitern. Diese Herausforderungen stellen auch neue Anforderungen an die gesellschaftliche Verantwortung von Unternehmen. Die Komplexität, die mit KI-Entwicklung und dem Einsatz einhergeht, fordert einen umfassenden Dialog und die Einbindung von Stakeholdern aus Wirtschaft, Politik und Gesellschaft, um Vertrauen und Akzeptanz in KI-basierte Anwendungen zu schaffen.

Wie es dennoch gelingen kann, die immensen Potenziale der aktuellen KI-Anwendungen wirtschaftlich und für die Verbesserung unserer Lebensbedingungen zu nutzen, zeigen die Reflexionen und Beispiele in dieser Publikation. Wir möchten den Autorinnen und Autoren ganz besonders danken, dass sie sich aktiv mit dem Thema gesellschaftliche Verantwortung und KI beschäftigen und dabei helfen, die Zukunft aktiv positiv zu gestalten – und so einer Anything-goes-Mentalität Einhalt zu bieten. Dank gilt

auch dem Publikationsteam bei Springer Gabler, die diese vorliegende Veröffentlichung in der gewohnt professionellen Weise möglich gemacht haben. Und natürlich Ihnen, werte Leserin und Leser, die sie sich für das Thema interessieren und nunmehr viele neue Einsichten und Erkenntnisse bei der Lektüre erfahren.

Köln, Krems
Oktober 2021

René Schmidpeter
Reinhard Altenburger

Inhaltsverzeichnis

**Künstliche Intelligenz im Spannungsfeld Innovation, Effizienz
und gesellschaftliche Verantwortung 1**
Reinhard Altenburger

**Perspektiven auf KI: Governance, Autonomie, Vertrauen,
Ethik und Unvoreingenommenheit**

Digital Governance als CSR-Kompass für künstliche Intelligenz 17
Alexander Vocolka, Franziska Langensiepen und Stephan Beismann

Spannungsfeld automatisierte Entscheidungssysteme und Autonomie 61
Sabine Theresia Koeszegi

**Warum wir der künstlichen Intelligenz nicht blind vertrauen dürfen –
fünf Ansätze um künstliche Intelligenz zu beherrschen 77**
Helmut Leopold

**Vergessen wir mal die Roboter: So gelingt Künstliche-
Intelligenz-Ethik in der Praxis. 105**
Tobias Zwingmann und Tobias Gärtner

**Unvoreingenommenheit von Künstliche-Intelligenz-Systemen.
Die Rolle von Datenqualität und Bias für den verantwortungsvollen
Einsatz von künstlicher Intelligenz 121**
Katrin Strasser und Bernhard Niedermayer

Skizzierung einer vertrauensvollen künstlichen Intelligenz 137
Isabell Kunst

**Künstliche Intelligenz verantwortungsvoll entwickeln und einsetzen.
Zur Bedeutung ethischer Leitlinien für Unternehmen 159**
Johannes Winter

Environment-Social-Governance-Fingerprint – wie der Einsatz von Big Data und künstlicher Intelligenz Investoren, Unternehmen und Stakeholder unterstützen kann	171
Pajam Hassan und Frank Passing	
Anwendungen in der Unternehmenspraxis: Datenwert, Produktion, neue Instrumente, Mittelstand	
Datenwert und Datenminimalismus: Wege zu nachhaltiger künstlicher Intelligenz	189
Michaela Regneri	
Technik dient dem Menschen – Künstliche Intelligenz im BMW-Produktionssystem	209
Matthias Schindler und Frederik Schmieling	
Nüchtern gesehen: Künstliche Intelligenz als neues Werkzeug – mit neuen Regeln	235
Corina Apachite und Stefan Voget	
CSR und künstliche Intelligenz im Mittelstand – Chancen für innovativere und nachhaltigere kleine und mittlere Unternehmen?	251
Martin Lundborg, Lisa Schrade-Grytsenko und Christian Märkel	
CSR am Beispiel „Leftshift One“	261
Clemens Istel und Gerald Krammer	
Soziale Robotik, HR/Arbeitgeberattraktivität, Führung und Zukunft der Arbeit	
Mein neuer Teamkollege ist ein Roboter! Wie soziale Roboter die Zukunft der Arbeit verändern können	279
Sabine T. Koeszegi und Astrid Weiss	
Augmented Human-Centered Management – Personalentwicklung für hochautomatisierte Geschäftsfelder	305
Dirk Nicolas Wagner	
Künstliche Intelligenz – Kriegstreiber oder Friedensstifter im War for Talent?	327
Jakob Sidoruk und Harald Ritter	
Künstliche Intelligenz und Führung: Automatisierung und die Veränderung von Managementaufgaben und -arbeitsweisen	341
Isabell Claus und Matthias Szupories	

Künstliche Intelligenz und die Zukunft von Arbeit	353
Georg von Richthofen, Ali Aslan Gümüşay und Hendrik Send	
Künstliche Intelligenz: Wegbegleiter für ein neues menschliches „Maß“ – <i>Ein kurzer Ausblick</i>	367
René Schmidpeter	

Herausgeber- und Autorenverzeichnis

Über die Herausgeber

Prof. Dr. Reinhard Altenburger University of Applied Sciences Krems, IMC Fachhochschule Krems, Krems, Österreich

Prof. Dr. René Schmidpeter Köln, Deutschland

Autorenverzeichnis

Prof. Dr. Reinhard Altenburger IMC Fachhochschule Krems, Krems, Österreich

Dr. Corina Apachite Continental, Holistic Engineering & Technologies, Frankfurt, Deutschland

Stephan Beismann Horváth & Partner GmbH, München, Deutschland

Dr. Isabell Claus thinkers GmbH, Wien, Österreich

Tobias Gärtner Hannover, Deutschland

Dr. Ali Aslan Gümüşay Alexander von Humboldt Institut für Internet und Gesellschaft, Hochschule für Technik und Wirtschaft (HTW) Berlin, Berlin, Deutschland

Pajam Hassan intuitive.ai GmbH, Hamburg, Deutschland

Clemens Istel Leftshift One Software GmbH, Graz, Österreich

Univ. Prof. Dr. Sabine Theresia Koeszegi Institute of Management Science, TU Wien, Forschungsbereich Labor Science and Organization, Wien, Deutschland

Gerald Krammer Leftshift One Software GmbH, Graz, Österreich

Dr. Isabell Kunst Xephor Solutions GmbH, Purkersdorf, Österreich

Franziska Langensiepen Horváth & Partner GmbH, München, Deutschland

Dr. Helmut Leopold Head of Center for Digital Safety & Security, AIT Austrian Institute of Technology, Wien, Österreich

Martin Lundborg WIK Wissenschaftliches Institut für Infrastruktur und Kommunikationsdienste GmbH, Bad Honnef, Deutschland

Christian Märkel WIK Wissenschaftliches Institut für Infrastruktur und Kommunikationsdienste GmbH, Bad Honnef, Deutschland

Bernhard Niedermayer Cloudflight Austria GmbH, Linz, Österreich

Dr. Frank Passing intuitive.ai GmbH, Hamburg, Deutschland

Dr. Michaela Regneri OTTO (GmbH & Co. KG), Hamburg, Deutschland

Harald Ritter digital dynamite GmbH, Berlin, Deutschland

Dr. Matthias Schindler BMW Group – Innovationen, Digitalisierung, Data Analytics, München, Deutschland

Prof. Dr. René Schmidpeter Köln, Deutschland

Frederik Schmihing BMW Group – Innovationen, Digitalisierung, Data Analytics, München, Deutschland

Lisa Schrader-Grytsenko WIK Wissenschaftliches Institut für Infrastruktur und Kommunikationsdienste GmbH, Bad Honnef, Deutschland

Hendrik Send Alexander von Humboldt Institut für Internet und Gesellschaft, Hochschule für Technik und Wirtschaft (HTW) Berlin, Berlin, Deutschland

Jakob Sidoruk digital dynamite GmbH, Berlin, Deutschland

Katrin Strasser Cloudflight Austria GmbH, Linz, Österreich

Matthias Szupories DEUTZ AG, Köln, Deutschland

Alexander Vocolka Horváth & Partner GmbH, München, Deutschland

Stefan Voget Continental, Holistic Engineering & Technologies, Regensburg, Deutschland

Prof. Dr. Dirk Nicolas Wagner Karlsruhochschule International University, Karlsruhe, Deutschland

Astrid Weiss Institute of Visual Computing and Human-Centered Technology, TU Wien, Forschungsbereich Human Computer Interaction, Wien, Deutschland

Dr. Johannes Winter acatech – Deutsche Akademie der Technikwissenschaften e. V., München, Deutschland

Tobias Zwingmann Deutsche Messe AG, Hannover, Deutschland



Künstliche Intelligenz im Spannungsfeld Innovation, Effizienz und gesellschaftliche Verantwortung

Reinhard Altenburger

1 Herausforderungen und Potenziale der künstlichen Intelligenz

„Die KI wird bald wie Strom sein – allgegenwärtig und unentbehrlich. Daraus erwächst eine große Verantwortung, dafür zu sorgen, dass die KI ihrem Potenzial als positive Kraft zu wirken gerecht werden kann.“

Lee [2019](#)

Das Versprechen schneller, genauer, wiederholbarer und kostengünstiger Entscheidungen mit einer Qualität, die einer menschenähnlichen Intelligenz nahe kommt, war eine wichtige Triebkraft für die rasanten Entwicklungen der KI in den letzten Jahren. Während die rasche Einführung der KI die vielen messbaren Vorteile der Lern- und Vorhersagekraft der KI belegt, muss ihre Anwendung bei der Entscheidungsfindung in Organisationen auf einem angemessenen Verständnis ihrer Stärken und Schwächen beruhen. Dennoch zeigen jüngste Ereignisse und zunehmende Forschungsergebnisse, dass die Anwendung von KI-basierter Entscheidungsfindung eine Reihe schwerwiegender und oft versteckter Voreingenommenheit und Herausforderungen für die Aufrechterhaltung von Fairness, Rechenschaftspflicht, Transparenz und folglich für das Vertrauen in KI-basierte Entscheidungen einführen und verstärken kann (Shrestha et al. [2019](#)). Die Verbindung mit Entwicklungen in der Robotik, Internet of Things, Chatbots, additiver Fertigung aber auch zukünftig z. B. mit Quantencomputern wird zukünftig

R. Altenburger (✉)
IMC Fachhochschule Krems, Krems, Österreich
E-Mail: reinhard.altenburger@fh-krems.ac.at

© Der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

R. Altenburger und R. Schmidpeter (Hrsg.), *CSR und Künstliche Intelligenz*, Management-Reihe Corporate Social Responsibility,
https://doi.org/10.1007/978-3-662-63223-9_1

alle Branchen – von den Finanzdienstleistern bis zu den Gesundheitseinrichtungen – maßgeblich beeinflussen.

Der Einsatz von KI wird die Geschäftsmodelle und den Wettbewerb sowie den Umgang mit Daten und die Entscheidungsfindung in den Unternehmen radikal verändern (Iansiti und Lakhani 2020). Damit einher gehen auch die Fragen, wieweit die Verantwortung von Unternehmen, die KI einsetzen, reicht, welche neuen Themen auf Unternehmen damit zukommen und wie sich Führungskräfte auf diese Veränderungen vorbereiten. Das McKinsey Global Institute (2018) sieht folgenden Faktoren als Begrenzung der Anwendung der KI in Unternehmen:

- Verfügbarkeit bzw. etikettierte Trainingsdaten
- Beschaffung ausreichend großer Datensätze
- Schwierigkeit, Ergebnisse zu erklären: es ist oft schwierig, Ergebnisse aus großen Datenmengen zu erklären
- Komplexe, auf neuronalen Netzen basierende Systeme
- Schwierigkeit der Verallgemeinerung
- Risiko der Verzerrung bzw. des Bias (s. dazu auch den Beitrag von Leopold in diesem Band)

Als schwache KI (auch „weak/narrow AI“) werden Systeme bezeichnet, die nur sehr begrenzte Aufgaben bearbeiten können (z. B. Bild- oder Texterkennung,). Diese Form der KI steht im Mittelpunkt des vorliegenden Bands. Starke KI (auch als „strong/general AI“) bezeichnet ein System, das menschliche Fähigkeiten in einem breiten Spektrum erreicht oder übertrifft. Die Ausführungen in diesem Kapitel und auch in diesem Band beziehen sich auf die schwache KI und ihren Herausforderungen sowie Umsetzungsanforderungen.

Eine intensive Diskussion erfolgte 2020 im Zuge der Corona-Krise, in der enorme Datenmengen aus unterschiedlichen Datensätzen, Verlaufskurven und Studien unterschiedlichster Qualität generiert wurden, die kaum mehr von Menschen ohne Unterstützung überblickt oder analysiert werden konnten. KI sollte dabei unterstützen, eine optimale Strategie für das Pandemiemanagement aus den vorhandenen Informationspuzzlestücken zum SARS-CoV-2-Virus zu wählen, Risikogruppen zu identifizieren und zu schützen. Im Rahmen des Forschungsprojekts ML@WIBCE – ein Teil des Anti-Corona-Programms der Fraunhofer-Gesellschaft – wurden Daten aus einer repräsentativen Stichprobe mit Methoden des unüberwachten und überwachten maschinellen Lernens (ML) analysiert und dabei spezifische Verhaltensweisen und Charakteristiken identifiziert (Lingelbach 2020). Auch bei der Bewältigung der Herausforderungen, die mit den Sustainable Development Goals (SDG) fokussiert werden, wie beispielsweise Klimakrise, Armutsbekämpfung, Zugang zu und Optimierung der Bildung in Schwellen- und Entwicklungsländern oder Gesundheitsversorgung, hat die KI ein immenses Potenzial, durch die Analyse großer unstrukturierter Echtzeitdatensätze Lösungen zu finden bzw. bei der Lösungsentwicklung zu unterstützen (World Economic Forum 2018).

In der öffentlichen Diskussion zum Thema KI dominieren oftmals Bilder einer KI, die beispielsweise in Filmen wie *Matrix*, *Her*, *Ex Machina* oder *Minority Report* vermittelt werden. Hohe mediale Beachtung haben auch KI-Anwendungen gefunden, die im Schach, Go oder Jeopardy! überragende Erfolge erzielt haben, und werden nahezu in jeder KI-Diskussion zitiert. Auch Schattenseiten wie ein dramatischer Verlust an Arbeitsplätzen (hier hat die Studie von Frey und Osborne aus dem Jahr 2013 wesentlich zur Auseinandersetzung beigetragen), Überwachung, autonome Waffensysteme, Deep-Fake-Videos oder der Umgang mit privaten Datenbeständen und Diskriminierung wurden in den letzten Jahren intensiv diskutiert und prägten die Erwartungen was „die KI“ in Zukunft bedeuten wird. Auch in der Arbeitswelt können Algorithmen zu Benachteiligungen führen. Oftmals wird hier der Fall angeführt, bei dem Frauen bei Google-Suchen schlechter bezahlte Stellenanzeigen zu sehen bekamen als Männer. Als mögliche Erklärung wird hier das Training des Algorithmus mit Daten angeführt, aus denen hervorgeht, dass Frauen eher schlechter bezahlte Berufe ausüben. Daraus wird ein entsprechendes Muster erkannt und die Anzeigen werden entsprechend angepasst. Amazon hat einen Algorithmus zur Vorsortierung von Bewerbungsunterlagen abgeschafft, da dieser unbeabsichtigt Frauen diskriminierte – weil er auf Grundlage eines männlich dominierten Datensatzes gelernt hatte, dass Männer für den Job besser geeignet sind (BVWD 2019).

Aber auch die positiven Anwendungen der KI nehmen zu, beispielsweise bei der Krebsfrüherkennung, im Bereich der Cybersecurity, des autonomen Fahrens oder dabei, die soziale Inklusion voranzubringen und Menschen mit Behinderungen, Personen mit geringen Sprachkenntnissen oder mit eingeschränkter Mobilität eine möglichst gleichwertige Teilhabe an der Arbeitswelt und am gesellschaftlichen Leben zu eröffnen (Bitkom 2017).

In einer Studie von Grace et al. (2017) werden Experteneinschätzungen der University of Oxford aufgezeigt, wann KI (voraussichtlich) den Menschen übertrumpfen wird. Beim Übersetzen von Sprachen soll dies 2024, beim Schreiben von Schulaufsätzen 2026, beim Fahren eines Lkws 2027, beim Arbeiten im Einzelhandel 2031, beim Verfassen eines Bestsellers 2049 oder bei chirurgischen Operationen 2053 der Fall sein. In nur wenigen Generationen könnten Maschinen den größten Teil der uns heute vertrauten menschlichen Arbeiten nicht bloß übernehmen, sondern besser, schneller und billiger ausführen. Auch die Diskussion möglicher Szenarien einer Superintelligenz, die die menschliche Intelligenz auf so gut wie allen Gebieten übertrifft, und deren soziale, wirtschaftliche und auch politische Konsequenzen (Bostrom 2016) werden intensiv in in regelmäßigen Abständen diskutiert.

Für die Herausforderungen durch die KI ist es oftmals erforderlich, die „richtigen“ Fragen für die fokussierte Diskussion in den unterschiedlichen Organisationen und Systemen zu entwickeln. Der Rat für Forschung und Technologieentwicklung (2019) hat u. a. folgende Fragen im Umgang mit KI formuliert, die in der Wirtschaft, Politik und Gesellschaft mit den unterschiedlichen Stakeholdern diskutiert werden sollten (Rat für Forschung und Technologieentwicklung 2019):

„Was passiert, wenn zugrundeliegende Daten fehleranfällig oder verwendete Algorithmen nicht nachvollziehbar sind? Welche gesellschaftlichen Auswirkungen hätten die auf KI-Systeme übertragenen Vorurteile? Sollen auf KI basierende Roboter in ihrem Design und ihrer Funktionalität dem Menschen ähneln bzw. diesen sogar imitieren, z. B. in Form humanoider Roboter oder »Social-Bots«? Welche gesellschaftlichen und ethischen Herausforderungen ergeben sich dadurch? Inwiefern werden Werte (wie beispielsweise Menschenwürde, Autonomie, Freiheit, Solidarität, Gleichheit, Demokratie, Vertrauen, Rechtsstaatlichkeit) durch wissenschaftlich-technische Entwicklungen in der KI und Robotik neu definiert bzw. berührt?“

Eine wesentliche Herausforderung für Unternehmen ist die Gestaltung der Rahmenbedingungen für die KI-Entwicklung – „entscheidend ist dabei, sich von einem verbreiteten Technik-Determinismus zu lösen und die Gestaltbarkeit digitaler Technologien in den Mittelpunkt zu stellen“ (Vieth und Wagner 2017, S. 8). Über die Prinzipien, die bei der Konstruktion von intelligenten Systemen gelten sollen, sollte nach Ansicht der Hochrangigen Expertengruppe für KI ein interdisziplinärer und transparenter Konsens angestrebt werden. Alle Akteure in Wirtschaft, Politik und Gesellschaft müssen sich der ethischen und datenökologischen Verantwortung in Bezug auf nachhaltiges Datenwirtschaften bewusst werden. Gleichzeitig ist es notwendig, sich über ethische Standards bei der Algorithmisierung zu verständigen (High-Level Expert Group on Artificial Intelligence 2019).

Auch die Einführung von Zertifizierungsstandards und Leitlinien für die ethische Gestaltung von algorithmischen Systemen wird umfassend diskutiert. Zweig (2019, S. 25) hält dies nur dann für erforderlich, wenn diese Systeme „...über Menschen entscheiden oder über Ressourcen, die Menschen betreffen, oder die solche Entscheidungen treffen, die die gesellschaftlichen Teilhabemöglichkeiten von Personen ändern, die einer Regulierung und Kontrolle ihrer inneren Mechanik bedürfen.“

Wie schwierig es in kritischen Situationen ist, einen internationalen Konsens in Fragen der Entscheidungsfindung durch KI zu erzielen, zeigt beispielsweise das Moral Machine-Project des MIT. Wie sollte im Fall eines nicht mehr zu verhindernden Verkehrsunfalls entschieden werden, welche Personen(-gruppe) zu Schaden kommt. Im Herbst 2020 wurde auch die Frage der Zuteilung von Beatmungsgeräten in der Corona-Krise, wenn nicht ausreichend Geräte vorhanden sind, diskutiert. Die Ergebnisse zeigten dabei jeweils unterschiedliche Prioritäten in verschiedenen Ländern, sind jedoch ein wichtiger Beitrag zur weiteren Diskussion einer KI-Ethik (<https://www.moralmachine.net/>).

Welche Optimierungsziele gesellschaftlich sinnvoll sind, kann nicht allgemein für alle algorithmischen Systeme festgelegt werden. Dazu sind diese auch oftmals in verschiedenen Ländern unterschiedlich und verändern sich auch im Zeitablauf. Definition und Priorisierung gesellschaftlicher Ziele sind daher ein dynamischer Prozess. Die umfassende und in bestimmten Abständen immer wieder geführte Diskussion und das Aushandeln von Optimierungszielen sind notwendig, um gesellschaftlicher Dynamik Raum zu geben (Krüger und Lischka 2018).

Auch bei selbstlernenden algorithmischen Systemen geben Menschen Ziele algorithmischer Entscheidungsfindung, Datenbasis und grundlegende Modelle vor. Bei

der Implementierung in einen Algorithmic-decision-making(ADM)-Prozess (Prozesse algorithmischer Entscheidungsfindung) kommt die Gestaltung der organisatorischen Rahmenbedingungen hinzu sowie, für welchen Einsatzbereich dies erfolgt und welche Optimierungsziele verfolgt werden, z. B. optimaler Preis, kürzeste Lieferzeit usw. (Krüger und Lischka 2018). Nasehi (2019) merkt dazu an, dass in diesen Prozessen oftmals die Sinnstruktur der vergangenen Entscheidungen nur fortgesetzt wird.

Internationale Studien zeigen einerseits hohe Erwartungen an den Einsatz von KI, aber z. T. auch ein Zögern in der Umsetzung bzw. bei der Entwicklung von konkreten Anwendungen. So wird in einer Studie des McKinsey Global Institute (2018) von einem zusätzlichen Plus von 1,2 % Bruttoinlandsprodukt (BIP) weltweit pro Jahr (bis 2030) ausgegangen. Laut einer PWC-Studie (PWC 2019) sehen 49 % der deutschen Unternehmen KI als nicht relevant an. Auf die Frage, welche KI-Anwendungen bereits genutzt werden bzw. vorstellbar sind, sehen 70 % der Unternehmen die Datenanalyse für Entscheidungsprozesse, 63 % die Prozessautomatisierung und 44 % KI als einen wesentlichen Bestandteil neuer Geschäftsmodelle.

In einem Szenario bis 2035 hat Accenture errechnet, dass die Wachstumsrate der österreichischen Wirtschaft durch den Einsatz von KI auf 3 % pro Jahr ansteigen kann. Blicke es hingegen beim bisherigen technologischen Niveau, würde die Bruttowertschöpfung nur um 1,4 % pro Jahr wachsen. Nicht zuletzt wird die höhere wirtschaftliche Dynamik durch eine stark steigende Arbeitsproduktivität möglich. Das Szenario geht von einer 30 % höheren Produktivität der Beschäftigten in Österreich aus (Accenture 2019).

Eine Befragung von Ernst & Young LLP and Microsoft (2018) von 277 österreichischen Unternehmen ergab, dass 57 % der Unternehmen erwarten, dass die KI einen hohen oder sehr hohen Einfluss auf Geschäftsbereiche hat, die „vollständig dem Unternehmen heute unbekannt“ ist. Von 65 % der Unternehmen wird erwartet, dass die KI einen hohen oder sehr hohen Einfluss auf das Kerngeschäft haben wird. Aber nur 4 % der Unternehmen sind aktiv in der Verwendung von KI in vielen Prozessen und fortgeschrittenen Aufgabenfeldern.

Nach Ansicht von 58 % der Befragten einer IDG-Studie ist eine umfassende Diskussion über die ethischen Fragen im Zusammenhang mit KI und ML überfällig. Das gilt beispielsweise für Anwendungsfelder wie das Gesundheitswesen und autonomes Fahren. Dabei ist es für 52 % wichtig, dass Ethikfragen rasch beantwortet werden, damit Deutschland bei ML und KI nicht den Anschluss an internationale Vorreiter verliert (IDG Research Group 2019).

2 Anforderungen und Gestaltung von künstlicher Intelligenz durch das Management

KI stellt zahlreiche neue Anforderungen an das Management. Einerseits gilt es sich einen Überblick über die aktuellen Entwicklungen in technischer, ethischer und rechtlicher Hinsicht zu verschaffen und andererseits Verantwortung für die Entwicklung von

KI-basierten Lösungen zu übernehmen. Dies erfordert oftmals einen intensiven Dialog mit verschiedenen Stakeholdergruppen, um Ängste zu nehmen, Vertrauen in die neue Technologie aufzubauen und neue Geschäftsmöglichkeiten und Optimierungspotenziale zu erschließen.

2.1 Anforderungen an Managemententscheidungen

Für Entscheidungsträger stellen sich zahlreiche Herausforderungen, wenn es darum geht, die durch ML erstellten Vorhersagen anzuwenden. Dazu zählen rechtliche Fragen und Aspekte der Fairness, dem Umgang mit mangelnder Erklärbarkeit des Algorithmus und der Reaktion der Mitarbeiter auf algorithmische Entscheidungen. Im Fall beispielsweise des Human Resource Management stimmen das Streben nach Effizienz und die Bedenken hinsichtlich der Fairness nicht immer überein. Führungskräfte sollten daher die Phasen der Datengenerierung und des ML im Lebenszyklus der KI verstehen, wofür oftmals neue Kompetenzen erforderlich sind (Tambe et al. 2019). Bei Entscheidungen durch KI sollten folgende Problembereiche berücksichtigt werden (Shrestha et al. 2019):

- KI kann getäuscht werden, um Entscheidungsergebnisse zu verändern – beispielsweise durch die Manipulation der Daten, die sie als Input verwendet, oder durch ihr Design, z. B. durch Änderung der Gewichtung von Prädiktoren. Die Herausforderung besteht hier in passenden Regelungen und Verfahren zur Prüfung von KI-Algorithmen.
- Mittlerweile gibt es inzwischen eine Fülle von Beweisen dafür, dass auf KI basierende Entscheidungen menschliche Verzerrungen in den verfügbaren Daten verstärken. Voreingenommenheit und Ungerechtigkeit, die in KI-Entscheidungen eingebettet sind, sind besonders nachteilig für gefährdete Gruppen in unserer Gesellschaft.
- Drittens wird die Einführung KI-basierter Entscheidungen in Organisationen relativ effektiv, wenn ein gewisses Maß an Transparenz oder Interpretierbarkeit der Entscheidungen erreicht werden kann.

Manager sind gefordert, sich über die Entwicklungen im Bereich der interpretierbaren und erklärbaren KI auf dem aktuellen Stand halten. Bei der Einführung der KI in die Entscheidungsfindung von Organisationen müssen Manager interne Kompetenzen aufbauen, um über das Algorithmen-Design, die Interpretation der Ergebnisse und die Zusammenarbeit bei der Entscheidungsfindung zu entscheiden (Shrestha et al. 2019).

Für das Management ist es wichtig, die grundsätzlichen Phasen des Algorithmenentwicklungsprozesses zu kennen und dabei auch mögliche Fehlerquellen zu hinterfragen, sich als kritischer Sparingpartner in den Prozess einzubringen und letztendlich auch die Verantwortung für den Einsatz zu übernehmen. Folgende Phasen können in diesem Prozess unterschieden werden (Zweig et al. 2018):

- **Phase 1 – Algorithmen-Design und Implementierung:** Die Möglichkeit, handwerkliche Fehler aufzufinden, hängt davon ab, von wie vielen Personen der Algorithmus verwendet werden kann, wie gut das Verhalten des Algorithmus spezifiziert wurde und ob der Sourcecode öffentlich zugänglich ist.
- **Phase 2 – Operationalisierung sowie Daten- und Methodenauswahl:** Hier wird auch entschieden, wie eine gesellschaftlich relevante Frage so modelliert wird, dass sie vom Computer beantwortet werden kann.
- **Phase 3 – Konstruktion des Entscheidungssystems:** In dieser Phase werden Algorithmus und Trainingsdaten ausgewählt.
- **Phase 4 – Einbettung des Systems in den gesellschaftlichen Kontext:** In dieser Phase haben Algorithmen beim ML aus den Trainingsdaten beispielsweise gewisse Korrelationen von Verhalten und Erfolg gelernt. Dies kann zu Fehlinterpretationen führen, da möglicherweise in der Zukunft andere Kriterien erfolgsentscheidend sind oder sich gesellschaftliche Prioritäten und Wertvorstellungen verändert haben.
- **Phase 5 – Reevaluation des Entscheidungssystems:** Hier können beispielsweise in Empfehlungssystemen Algorithmen laufend Echtzeitfeedback erhalten und so optimiert werden. Es kann aber auch zu negativen Auswirkungen kommen, wie im Fall der Feedbackasymmetrie, in denen lernende Algorithmen eingesetzt werden, die Feedback nur in eine Richtung zulassen.

Bei der Gestaltung von KI sollte es zu einer intensiven Abstimmung von Management, Prozesseignern bzw. Prozessexperten und KI-Experten kommen, um sicherzustellen, dass sie KI-Lösungen effektiv, zielorientiert und verantwortungsbewusst anwenden. Unternehmen sind daher gefordert, verstärkt in KI-Experten und Prozessveränderungen zusätzlich zur KI-Technologie zu investieren (Massachusetts Institute of Technology 2019).

2.2 Neue Geschäftsmodelle und Gestaltung des Ökosystems

Unternehmen, die aus ihren KI-Aktivitäten Wert schöpfen, weisen eine Reihe unterschiedlicher organisatorischer Verhaltensweisen auf. Diese Unternehmen integrieren ihre KI-Strategien in ihre allgemeine Geschäftsstrategie und berücksichtigen diese in der Transformation des Unternehmens, womit eine ganzheitliche Herangehensweise statt Insellösungen sichergestellt werden soll (Massachusetts Institute of Technology 2019).

Umfassende und akzeptierte Rahmenbedingungen – sowohl in rechtlicher, technologischer als auch in betriebswirtschaftlicher Hinsicht – sind eine zentrale Voraussetzung, um datenbasierte Innovationen auf den Weg zu bringen. In Hinblick auf Produkt-, Maschinen- und Prozessdaten sind kartell-, eigentumschaftungs- und leistungsschutzrechtliche Fragestellungen sowie Unternehmensstrategien maßgeblich, um aus großen Datenmengen und flankierenden digitalen Geschäftsmodellen Wertschöpfung zu generieren (Riemensperger und Falk 2019).

Einsatzmöglichkeiten von KI werden auch im Innovationsbereich gesehen, beispielsweise bei der Bedürfnis- und Trendidentifikation, bei Konzepttests und im Technologie-Scouting. Dies eröffnet sowohl etablierten Unternehmen als auch Start-ups die Möglichkeit, neue disruptive Lösungen und Geschäftsmodelle mittels KI zu entwickeln und Märkte wie Mobilität, Medizin oder die Baubranche neu zu denken. Die Herausforderung für viele Unternehmen besteht darin, herauszufinden, für welche Aspekte welche Kooperationen am geeignetsten sind und wie die verschiedenen Akteure gemeinsam zielführend in die Arbeit integriert werden können (Hyve 2020).

Noch sehr in den Kinderschuhen steckt in vielen Branchen die Entwicklung von Use Cases. Datengetriebene Systeme und die darauf basierende KI können die Grundlage für neue und innovative Geschäftsmodelle sein. Es werden Netzwerke, Austauschplattformen und Kooperationen gebraucht, in denen verschiedene Akteure ihre Datenexpertisen teilen und gemeinsame Ziele erarbeitet werden können. Im Aufbau und der Entwicklung sogenannter Ökosysteme steckt großes Potenzial, erfordert aber auch innovative Formen der Zusammenarbeit. Ein Ökosystem ist ein dezentrales Netzwerk, in dem Beteiligte wechselseitige Beziehungen aufbauen. In einem Ökosystem können gemeinsame Geschäftsmodelle entwickelt, mit Prototypen experimentiert und neuartige, kreative Kooperationen eingegangen werden. Entscheidend für ein Ökosystem sind verschiedenartige Akteure, die durch ihre Beteiligung und Mitwirkung in unterschiedlichen Rollen zur Erreichung gemeinschaftlicher Wertschöpfungsprozesse und damit zum Mehrwert des Ökosystems beitragen (Abb. 1; Fraunhofer 2019).

Dieses Netzwerk ermöglicht den Akteuren einen fachlichen Austausch mit anderen Teilnehmern des Ökosystems. Wichtig ist es, in einem Ökosystem die rechtliche Rahmenbedingungen zu definieren, die die Akteure vor missbräuchlichem Umgang ihrer Daten schützen. Datenökosysteme zeichnen sich durch vielfältige Wechselbeziehungen in einem Netzwerk aus mehreren Akteuren wie z. B. Organisationen, Unternehmen, Individuen, Software, Hardware etc. aus, die durch ihre Interaktion in Form eines Datenaustauschs zum Leistungs- und Wertversprechen beitragen. Die miteinander interagierenden Akteure tragen dazu bei, Ressourcen in Form von Daten einzubringen. Dadurch kann ein Mehrwert für alle beteiligten Akteure im Ökosystem geschaffen werden. Alle Akteure sind je nach Rolle und Betrachtungswinkel auf das Szenario in irgendeiner Form beteiligt, z. B. durch das Einbringen von Daten oder Bereitstellung von Services am Ökosystem. Im Kern steht der Endkunde im Fokus, der vom Datenaustausch durch die Bereitstellung neuartiger und individualisierter datengetriebener Produkte und Dienstleistungen profitiert (Fraunhofer 2019).

Über den Aufbau interner Governance-Prozesse hinaus, sind Unternehmen daher herausgefordert, sich intensiv mit ihrem Ökosystem von Partnern und Kunden sowie mit den sie umgebenden Gemeinschaften zu befassen (Iansiti und Lakhani 2020). Die Auseinandersetzung mit den Interessen bzw. Ansprüchen der unterschiedlichen Stakeholdergruppen ist ein wichtiger Schritt, um akzeptierte und erfolgreiche Anwendungen der KI zu erreichen.




Abb. 1 Rollen und Akteure in einem Datenökosystem (Data Market Austria, o.J.)

3 Übersicht der Beiträge im Band

Im Mittelpunkt des ersten Teils dieses Bands stehen unterschiedliche Perspektiven auf KI: Fragen zu Governance, Autonomie, Vertrauen, Ethik und Unvoreingenommenheit. Der Beitrag von Alexander Vocolka, Franziska Langensiepen und Stephan Beismann setzt sich mit Digital Governance und den Auswirkungen von KI auf das CSR-Framework in Unternehmen sowie den Leitplanken für die Entwicklung und den Einsatz von KI auseinander. Die Auswirkungen werden anhand von mehreren Praxisbeispielen dargestellt. Im anschließenden Beitrag setzt sich Sabine Köszegi damit auseinander, wie sich automatisierte Entscheidungssysteme auf die Autonomie von Menschen auswirken und welche Anforderungen an automatisierte Entscheidungssysteme zu stellen sind, um Menschen und Gesellschaft zu schützen. Darauf aufbauend werden Anforderungen an automatisierte Entscheidungssysteme dargestellt, die sicherstellen können, dass wir auch in Zukunft ein selbstbestimmtes, autonomes Leben führen können. Im Beitrag von Helmut Leopold werden fünf prinzipielle Problembereiche/Herausforderungen der KI Technologie erörtert: *Modellierbarkeit*, *Verifizierbarkeit*, *Erklärbarkeit*, *Ethik* und *Verantwortlichkeit*. Darüber hinaus werden grundsätzliche gesellschaftliche Bedrohungspotenziale im Kontext der Informationsgesellschaft thematisiert und die Grenzen der KI-Technologie als klare Abgrenzung zu menschlicher Intelligenz aufgezeigt. Anhand

des CRISP-DM Framework stellen Tobias Zwingmann und Tobias Gärtner eine prozessorientierte KI-Ethik zur KI-Entwicklung und ein konkretes Anwendungsbeispiel für KI-Ethik in der Versicherungswirtschaft vor. Katrin Strasser und Bernhard Niedermayer zeigen daran anschließend in ihrem Beitrag Herausforderungen bei der Entwicklung von KI auf und schlagen Lösungsansätze für unvoreingenommene KI-Systeme vor, die von der grundsätzlichen Bewusstseinsschaffung über systematisches Qualitätsmanagement von Trainings- und Evaluierungsdaten bis hin zu erklärbarer KI, die auch den Menschen in den Prozess einbezieht, reicht. Isabell Kunst beschäftigt sich mit zahlreichen Einsatzbeispielen von KI in unterschiedlichen Branchen und der Implementierung einer vertrauenswürdigen KI basierend auf Europäischen Richtlinien für eine ethische KI. Der Beitrag von Johannes Winter skizziert die Potenziale von KI, setzt sich mit ethischen Prinzipien in der KI-Entwicklung und -Anwendung auseinander und verdeutlicht, wie ethische Aspekte bei der Entwicklung und dem Einsatz von KI zur Vertrauenswürdigkeit, aber auch zum Erreichen von CSR-Zielen beitragen können. Im abschließenden Beitrag des ersten Teils entwickeln Pajam Hassan und Frank Passing ein um Nachhaltigkeit erweitertes Risikomanagementmodell sowie ein Konzept zur Entwicklung einer Taxonomie zur Klassifizierung von Environment-Social-Governance(ESG)-relevanten Chancen und Risiken. Darauf aufbauend wird die Anwendung des Konzepts zur Entwicklung eines ESG-Fingerprints für KI-basierte Informationssysteme behandelt.

Im zweiten Teil dieses Bands werden Anwendungen in der Unternehmenspraxis mit dem Fokus Datenwert, KI in der Produktion und Mittelstand aufgezeigt. Im Mittelpunkt des Beitrags von Michaela Regneri steht der Datenminimalismus. Möglichst wenige Daten werden dabei so gezielt eingesetzt, dass keine Qualitätseinbußen zu erwarten sind. Wie dieser Datenwert bestimmt werden könnte und wie viele Daten dadurch eingespart werden könnten, wird anhand eines Experiments mit einem KI-System für Produktempfehlungen im E-Commerce aufgezeigt. Daran schließt sich der Beitrag von Matthias Schindler und Frederik Schmieling mit dem Fokus auf die Implikationen der Innovationen Data Analytics und KI auf die Qualitätsarbeit im BMW-Produktionssystem an. Es wird die gesellschaftliche Verantwortung des Unternehmens innerhalb dieser Systemgrenze beleuchtet sowie die Bedeutung von KI für die globale Wertschöpfung behandelt. Abschließend werden die Anforderungen an die Führungskräfte aller Ebenen in der Produktion anhand von konkreten Beispielen aufgezeigt. Im Beitrag von Corina Apachite und Stefan Voget werden Beispiele aus Produkten und Lösungen für Fahrzeuge sowie Anwendungsbeispiele für KI in internen Prozessen aufgezeigt und deutlich gemacht, warum das Technologieunternehmen Continental KI nutzt und in welcher Form dies erfolgt. Eine zentrale Rolle spielt dabei der Begriff Verantwortung, der für den internationalen Automobilsystemzulieferer traditionell Priorität besitzt. Den Kern der Verantwortungsethik für KI bildet ein nutzer- und mitarbeiterzentriertes Denken und Handeln auf allen Ebenen. Einen weiteren Schwerpunkt – Fragen der KI-Anwendungen zur Unterstützung von Nachhaltigkeitsmaßnahmen im Mittelstand und den Rahmenbedingungen zur Implementierung von KI im Mittelstand behandelt der Beitrag von Martin Lundborg, Lisa Schrade-Grytsenko und Christian Märkel. Im abschließenden

Beitrag dieses Teils beschäftigen sich Clemens Istel und Gerald Krammer mit Herausforderungen durch völlig unterschiedliche Zugänge zu Informationen verschiedener Teile der Bevölkerung und was dies für die KI-Entwicklung bedeutet. Neben Datenschutz liegt es auch an der „explainability“ und „trustworthiness“ von KI-Modellen, die Vorurteile über KI aufzubrechen und eine vertrauenswürdige, faire Technologie zu schaffen. Abschließend wird der Lösungsansatz von Leftshift One – symbiotische KI – vorgestellt.

Der dritte Teil dieses Bands setzt sich mit weiteren Anwendungsfeldern der KI, wie soziale Robotik, Human Resources bzw. Arbeitgeberattraktivität, Führung und Zukunft der Arbeit auseinander. Zu Beginn dieses Teils behandeln Sabine Köszegi und Astrid Weiss den Einsatz von autonomen KI- und Robotiksystemen in einer Vielzahl von Einsatzbereichen, von der industriellen Fertigung bis hin zur Pflege von Menschen. Aufbauend auf diese Analyse untersucht der Beitrag die Herausforderungen bei der Integration dieser Technologien in Arbeitsprozesse. Ein besonderer Fokus liegt im Aufzeigen, wie soziale Roboter die Arbeit in verschiedenen Anwendungsgebieten verändern können. Dirk Nicolas Wagner stellt in seinem Beitrag als möglichen Lösungsansatz in einer zunehmend digitalen Welt mit KI und den damit verbundenen neuen Strukturen, Prozessen und Systemen das Konzept eines Augmented Human-Centered Management mit entsprechenden Schritten für die Implementierung vor. Anschließend beschäftigen sich Jakob Sidoruk und Harald Ritter mit KI-Lösungen im Recruiting-Prozess, wie Chatbots, Sprachanalysesysteme oder KI im Active Sourcing sowie der Akzeptanz von KI-Lösungen bei Stellensuchenden. Isabell Claus und Matthias Szupories analysieren in ihrem Beitrag die Verbindung von künstlicher und menschlicher Intelligenz und die Konsequenzen für die Führung in Unternehmen. In einem Fallbeispiel wird aufgezeigt, wie KI in vielen Fällen entscheidende und oftmals sogar öffentlich zugängliche Informationen deutlich schneller und besser auswerten und aggregieren kann als herkömmliche Lösungen und Führungskräfte, wodurch bessere Entscheidungen im Wettbewerb getroffen werden können. Georg von Richthofen, Ali Aslan Gümüşay, Hendrik Send behandeln in ihrem Kapitel den Einsatz von KI und vier unterschiedliche Typen von Auswirkungen auf Arbeit, die als Ersatz, Entlastung, Einschränkung sowie als Entstehung neuer, maschinell ausgeführter Arbeit bezeichnet werden. Aufbauend auf einer eigenen empirischen Studie werden Implikationen und Erkenntnisse für menschliche Arbeit, Organisationen und Gesellschaft abgeleitet.

Im abschließenden Beitrag setzt sich René Schmidpeter mit Chancen der KI in einer nachhaltigen Transformation und der Weiterentwicklung der CSR auseinander.

Literatur

Accenture (Hrsg) (2019) Mission mit Vision. Wie Österreich seine Zukunft mit künstlicher Intelligenz gestaltet

- BVWD (Hrsg) (2019) Mensch, Moral, Maschine. Digitale Ethik, Algorithmen und künstliche Intelligenz. <https://www.bvdw.org/download/mensch-moral-maschine-digitale-ethik-algorithmen-und-kuenstliche-intelligenz/12339/>. Zugegriffen: 15. Okt. 2020
- Bitkom e. V., DFKI (2017) Künstliche Intelligenz. Wirtschaftliche Bedeutung, gesellschaftliche Herausforderungen, menschliche Verantwortung
- Bostrom N (2016) Superintelligenz: Szenarien einer kommenden Revolution. Suhrkamp
- Data Market Austria (o.J.) <https://datamarket.at/> (abgerufen am 2.6.2021)
- Ernst & Young LLP and Microsoft (Hrsg) (2018) Artificial Intelligence in Europe – Austria. Outlook for 2019 and beyond. How 277 Major Companies Benefit from AI
- Fraunhofer (2019) ÖKOSYSTEME FÜR DATEN UND KÜNSTLICHE INTELLIGENZ. Konzeption einer souveränen Dateninfrastruktur und Analyse von Potenzialen durch Ökosysteme in KI-Anwendungsfällen unterschiedlicher Domänen
- Frey C, Osborne MA (2013) The future of employment: how susceptible are jobs to computerization? University of Oxford
- Grace K, Salvatier J, Dafoe A, Zhang B, Evans O (2018) When will AI exceed human performance? Evidence from AI experts. *J Artif Intell Res* 62:729–754
- High-Level Expert Group on Artificial Intelligence (2019) Ethics Guidelines for Trustworthy AI. <https://ec.europa.eu/digital-single-market/en/news/ethics-guidelines-trustworthy-ai>. Zugegriffen: 8. Okt. 2020
- HYVE (Hrsg) (2020) Wie Künstliche Intelligenz und Algorithmen das Innovieren revolutionieren. Wissenschaftliche Studie zum Einfluss von KI auf das Innovationsmanagement
- Iansiti M, Lakhani KR (2020) Competing in the age of AI. Strategy and leadership when algorithms and networks run the world. Harvard Business Review Press
- IDG Research Services (Hrsg) (2019) Studie machine learning/deep learning
- Krüger J, Lischka K (2018) Damit Maschinen den Menschen dienen. Lösungsansätze, um algorithmische Prozesse in den Dienst der Gesellschaft zu stellen. Bertelsmann Stiftung. Impuls Algorithmenethik #2
- Lee K (2019) AI Superpowers. China, Silicon Valley und die Neue Weltordnung. Campus
- Lingelbach K (2020) Machine Learning für bessere Pandemiebekämpfung: unsere WIBCE-Studie für Entscheidungstragende. <https://blog.iao.fraunhofer.de/machine-learning-fuer-bessere-pandemiebekaeufung-unsere-wibce-studie-fuer-entscheidungsstragende/>. Zugegriffen: 22. Nov. 2020
- Massachusetts Institute of Technology (2019) Winning with AI. Findings from the 2019 artificial intelligence global executive study and research project
- McKinsey&Company (2018) McKinsey global institute. Notes from the frontier modeling the impact of AI on the world economy. Discussion Paper September 2018
- Nasehi A (2019) Muster. Theorie der digitalen Gesellschaft. Beck
- PWC (Hrsg) (2019) Künstliche Intelligenz in Unternehmen. Eine Befragung von 500 Entscheidern deutscher Unternehmen zum Status quo – Mit Bewertungen und Handlungsoptionen von PWC
- Rat für Forschung und Technologieentwicklung (2019) Digitaler Wandel und Ethik. Wissenschaftlich-technische Entwicklungen im Wechselspiel mit gesellschaftlicher Akzeptanz. Wien
- Riemensperger F, Falk S (2019) Titelverteidiger: Wie die deutsche Industrie ihre Spitzenposition auch im digitalen Zeitalter sichert. Redline
- Shrestha YR, Ben-Menahem SM, von Krogh G (2019) Organizational decision-making structures in the age of artificial intelligence. *Calif Manage Rev* 61(4):66–83
- Tambe P, Cappelli P, Yakubovich V (2019) Artificial intelligence in human resources management: challenges and a path forward. *Calif Manage Rev* 61(4):15–42
- Vieth K, Wagner B (2017) Teilhabe, ausgerechnet. Wie algorithmische Prozesse Teilhabechancen beeinflussen können. Bertelsmann Stiftung. Impuls Algorithmenethik #2

- World Economic Forum (2018) Harnessing artificial intelligence for the earth. In Collaboration with PwC and Stanford Woods Institute for the Environment
- Zweig KA, Fischer S, Lischka S (2018) Wo Maschinen irren können. Fehlerquellen und Verantwortlichkeiten in Prozessen algorithmischer Entscheidungsfindung. Bertelsmann Stiftung. Impuls Algorithmenethik #4
- Zweig K (2019) Ein Algorithmus hat kein Taktgefühl. Wo künstliche Intelligenz sich irrt, warum uns das betrifft und was wir dagegen tun können. Heyne

Prof. Dr. Reinhard Altenburger ist Professor für Strategisches Management, Nachhaltiges Management/CSR und Innovation im Department Business der IMC Fachhochschule Krems. Der Fokus seiner Forschung liegt in den Themenfeldern „CSR und Innovation“ sowie „Innovationen in Familienunternehmen“, „Start-up-Kooperationen mit Corporates und KMU“ und der Verbindung von gesellschaftlicher Verantwortung und Unternehmensstrategie. Studium der Betriebswirtschaft und Wirtschaftspädagogik sowie Doktoratstudium der Sozial- und Wirtschaftswissenschaften an der Wirtschaftsuniversität Wien; Dissertation über die Funktionen des Topmanagements in Strategieprozessen; langjährige Tätigkeit als Projektleiter und Fachexperte in den Bereichen Vertriebsstrategie, Unternehmensplanung, Controlling und Innovationsmanagement im Sparkassen- und Bankensektor und als Unternehmensberater; Fachbuchautor; umfassende Vortragstätigkeit bei internationalen Konferenzen. Mitglied im Scientific Panel und Gutachterboard mehrerer Organisationen. Bei Springer Gabler erschienen *CSR und Innovationsmanagement*, *CSR und Stakeholdermanagement*, *CSR und Familienunternehmen* sowie *Innovation Management and Corporate Social Responsibility*.

Perspektiven auf KI: Governance, Autonomie, Vertrauen, Ethik und Unvoreingenommenheit



Digital Governance als CSR-Kompass für künstliche Intelligenz

Alexander Vocolka, Franziska Langensiepen und Stephan Beismann

1 Einleitung

Die Entwicklung von Artificial Intelligence (AI), auf Deutsch künstliche Intelligenz (KI) genannt, ist die größte und transformativste Erfindung der Menschheit. Deswegen erfolgt sie auch, wie alle großen Erfindungen, nicht über Nacht, sondern erstreckt sich über Dekaden und wird alle Lebensbereiche unserer Zivilisation stark verändern.

KI ist wirtschaftlich gesehen die höchste Form der Produktivitätssteigerung. Investitionen in KI-Lösungen erzielen phänomenal hohe Renditen im Bereich von Hunderten und in etlichen Fällen sogar Tausenden von Prozenten Return on Investment (ROI). Für ein Unternehmen ist KI die beste Investition, die es tätigen kann. Jeder Prozess, jede Maschine, jedes Produkt, jeder Service und die ganze Infrastruktur werden von KI durchdrungen werden. Dadurch greift KI tief in die Wertschöpfungsdomäne der Menschen ein. Was bisher das geistige Privileg der Menschen war, wird nun nach und nach auch zur Fähigkeit der Maschinen.

Die rasche Verbreitung von KI in allen Lebensbereichen und allen Wirtschaftssektoren und die tiefgreifenden Änderungen in Aufgaben- und Verantwortungsbereichen des Menschen lassen ihr großes Disruptionspotenzial erahnen. Deshalb wird dieser

A. Vocolka (✉) · F. Langensiepen · S. Beismann
Horváth & Partner GmbH, München, Deutschland
E-Mail: AVocolka@horvath-partners.com

F. Langensiepen
E-Mail: flangensiepen@horvath-partners.com

S. Beismann
E-Mail: sbeismann@horvath-partners.com

Übergang von einer Welt mit „dummen“ Maschinen in eine mit intelligenten Maschinen auch die Vierte Industrielle Revolution genannt. Aktuelle Modelle schätzen, dass KI im Jahr 2050 etwa 20 % des menschlichen Wertschöpfungsanteils übernommen haben wird.

Langfristig ist KI nicht nur unvermeidlich, sondern auch eine natürliche, logische und förderliche Entwicklung für unsere Zivilisation. Die Möglichkeiten für ein besseres Leben, die sich dadurch eröffnen, sind phänomenal. Aber der Mensch ist immer auch bereit, jede Innovation zum Schaden anderer und sich selbst einzusetzen – das ist seine Natur. Jede Innovation, jedes Werkzeug ist dual, es kann immer sowohl als Werkzeug zur Produktivitätssteigerung als auch als Waffe zur Destruktion eingesetzt werden. Das ist aber primär das Problem des Menschen und wie wir später beleuchten werden, wird der Mensch auch für die Moral der KI initial noch einige Zeit die Verantwortung tragen müssen.

Und hier entstehen dann natürlich auch die Ängste vieler Menschen. Die Angst, dass das Werkzeug die menschliche Arbeitskraft überflüssig macht. Die Angst, dass das Werkzeug nicht mehr kontrolliert, ja nicht einmal mehr verstanden werden kann, dass es nicht nur zu Massenarbeitslosigkeit führt, sondern dass sich das Werkzeug sogar gegen seinen Schöpfer selbst richtet – absichtlich oder unabsichtlich.

Diese plakativen Aussagen, teilweise auch von Managern der IT-Industrie¹, sind natürlich eher vom Marketing getrieben und werden liebend gern von den Medien zur Schlagzeile erhoben. Sie schüren aber diffuse Ängste und verhindern, dass die Gesellschaft, die Regierungen aber auch die Wirtschaft den Themenkomplex analytisch-sachlich durchdringt und versteht. Die Folge einer übermäßig emotionalisierten und instinktgeführten Diskussion um KI resultiert im Minimum in einer starken Ausbremsung dieser wichtigen Innovation und im schlimmsten Fall führt es in einigen Ländern zu einer Art religiösen Verdammung dieser Technologie.

Global und langfristig gesehen, würde dies aber wenig ändern an der grundsätzlichen Entwicklung und dem Einsatz von KI als Wettbewerbsfaktor. Längst haben Länder wie China² und Russland³ KI als Sprung in die Zukunft verstanden und große Förderprogramme aufgesetzt. Da KI in seiner Endform viele philosophisch-moralische Fragen aufwirft, wird hier der kulturelle Kontext von Ländern eine entscheidende Rolle spielen, wenn es darum geht, welcher Stellenwert KI beigemessen und wie stark die Entwicklung reguliert wird.

Zwar bestehen Versuche einiger Interessengruppen⁴, KI weltweit nach einheitlichen Standards und Grundsätzen zu regulieren – das wird aber gerade wegen ihres wirtschaft-

¹ <https://www.bbc.com/news/31047780>

² <https://www.forbes.com/sites/cognitiveworld/2020/01/14/china-artificial-intelligence-superpower/>; <https://www.theatlantic.com/magazine/archive/2020/09/china-ai-surveillance/614197/>

³ <https://www.theverge.com/2017/9/4/16251226/russia-ai-putin-rule-the-world>

⁴ <https://www.fhi.ox.ac.uk/govai/>; https://www.g20-insights.org/policy_briefs/coordinating-committee-for-the-governance-of-artificial-intelligence/; <https://cyber.harvard.edu/topics/ethics-and-governance-ai>

lichen Potenzials nicht gelingen und ist aus Innovationssicht auch nicht wünschenswert. Selbst bei Genetic Engineering, einem ebenso bedeutungsvollen Thema wie KI, ist das nicht gelungen, obwohl hier gewichtigere ethische Fragen im Zentrum stehen.

KI sollte nicht vorverurteilt, vermieden, bekämpft oder gar verboten werden. Stattdessen gilt es, diese Revolution wie eine schnelle Evolution zu gestalten und zu durchlaufen, sodass der Übergang in die KI-geprägte Zeit nicht als schmerzhaft, sondern als bereichernd und lohnenswert wahrgenommen wird.

Der Quantensprung in der Leistungsfähigkeit, der durch den Einsatz von KI in allen Branchen erfolgt, zwingt alle Unternehmen dazu, diesen Themenkomplex in all seinen Facetten zu durchdringen und zu verstehen, damit sie heute die Investitionen darin tätigen können, die ihre Existenz morgen sichern wird.

Corporate Social Responsibility (CSR) kann diesen Übergang in das neue industrielle Zeitalter wesentlich erleichtern. Eine Voraussetzung dafür ist aber, dass CSR frühzeitig und umfassend die Entwicklung und den Einsatz von KI in allen Aspekten erfasst und berücksichtigt und dazu in ihrer Definition und ihrem Wirkbereich um diesen Themenkomplex erweitert und vertieft wird.

KI im CSR-Rahmen in Form von Prinzipien zu verankern, ist aber nur der erste Schritt. Ohne eine entsprechend wirkungsvolle Umsetzung der Prinzipien durch ein operatives Regelwerk bleiben Prinzipien Lippenbekenntnisse.

Ein dynamisches KI-Governance-Framework ist dieses verbindliche Regelwerk. Es konkretisiert die Prinzipien und übersetzt sie in Verhaltensregeln und Arbeitsvorschriften. Es ist dabei selbst wiederum Teil des Digital Governance Framework, in dem die benachbarten Themen wie Data Governance und Cybersecurity ebenfalls geregelt sind.

Die KI-Governance ist das Regelwerk, dass die KI-Prinzipien der CSR operationalisierbar macht. Dadurch wird die strukturierte und hinreichend verbindliche Umsetzung von CSR-Vorgaben in Bezug auf Entwicklung und Einsatz von KI in der Organisation, den Prozessen, den Maschinen, der Infrastruktur und den Produkten und Dienstleistungen und in der Interaktion mit Kunden und Geschäftspartnern eines Unternehmens erst ermöglicht.

CSR sollte dabei immer berücksichtigen, dass sie gerade bei KI eine duale Aufgabe als Facilitator hat: Fördern und sichern der Entwicklung und Nutzung von KI. Denn wenn wir die Vorteile von KI für die Menschheit verzögern oder ihr gar verwehren, handeln wir ebenfalls gegen das Wohl und eine progressive Entwicklung der Gesellschaft.

CSR als Intermediär zwischen dem freien und staatlich regulierten Markt kann die Entwicklung von KI sowohl beschleunigen als ihr auch ihren potenziell negativen Auswirkungen entgegenstehen. Wobei die Bewertung von positiven und negativen Effekten naturgemäß von Kulturkreis zu Kulturkreis anders erfolgt und sich die bisher im Westen vorherrschende amerikanische Sicht auf CSR in anderen Regionen der Welt gerade hinsichtlich KI anders entwickeln wird.

Dieser Beitrag liefert Ideen und konzeptionelle Ansätze für Unternehmensverantwortliche zur Erweiterung von CSR um den Aspekt KI und zur praktischen Umsetzung im Unternehmen durch ein strukturiertes, umfassendes KI-Governance-Framework.

2 Künstliche Intelligenz als Quintessenz der Vierten Industriellen Revolution

Um die Bedeutung der KI für Gesellschaft und Wirtschaft erfassen zu können, müssen wir Intelligenz allgemein verstehen und dazu einen Blick in unsere eigene, fernste Vergangenheit werfen.

Unsere heutige Zivilisation baut auf dem Wissen von 100.000 Generationen auf, einer seit 6 Mio. Jahren exponentiellen Wissensentwicklung. Schließlich ist das einzig wahre Gut, dass wir wirklich komplett ohne Abstriche vererben können und das den nachhaltigsten Nutzen erbringt, Wissen – Wissen vom Feuermachen und den Steinwerkzeugen des Homo erectus vor 2 Mio. Jahren bis zu den Quantencomputern in unserer Zeit.

Wissen wird durch Intelligenz erzeugt, die sich im Wesentlichen aus drei Komponenten zusammensetzt, die auch für das datengetriebene Unternehmen von großer Bedeutung sind: Sensorik, Informationsverarbeitung (inklusive Speicherung) und Motorik. Intelligenz steht dabei für die Fähigkeit, bestehendes Wissen aufzunehmen und durch abstrahierendes Denken neues Wissen zu entwickeln, zu kommunizieren und produktiv in Form von Prozessen und mithilfe technologischer Werkzeuge anwendbar, sprich produktiv einsetzbar, zu machen.

KI ist die Automatisierung oder Maschinisierung eben dieser natürlichen Intelligenz.

KI ist damit ein neuer Produktionsfaktor. Der vierte, nach natürlichen Ressourcen, inklusive Energie, dem Menschen (Arbeit) und seinen technologischen Hilfsmitteln, den Maschinen, der Infrastruktur und dem variablen Produktionsfaktor Geld (die ungenauerweise alle drei als Kapital zusammengefasst werden).

KI ist der Produktionsfaktor mit dem größten Wertschöpfungspotenzial. Treffenderweise ist sie damit die Quintessenz der Vierten Industriellen Revolution: der Automatisierung von Intelligenz und deren Verbreitung über alle Produkte, Dienstleistungen, Prozesse, Maschinen und unserer gesamten technologischen Infrastruktur. So wie zuvor die Dampfmaschine, dann die Elektrizität, dann der Computer und das Internet, so leitet die Verbreitung von KI ein neues industrielles, aber auch gesellschaftliches Zeitalter ein.

Um die zukünftige Arbeitsteilung zwischen Menschen und KI zu verstehen, müssen wir den zweiten Produktionsfaktor, den Menschen selbst, nach seinen beiden primären Komponenten analysieren: Der mechanischen und der rein mentalen Arbeitskraft.

Zwar ist die Motorik und damit die mechanische Produktivität des Menschen rückgekoppelt in seinem neuronalen Netz und die Fingerfertigkeit des Pianospielers ist natürlich eng gekoppelt mit Audio- und Videokortex und wiederum auch mit der Gesamtkörpermotorik, aber die Arbeitsleistung des Pianospielers ist weit weniger mechanischer als viel mehr informationsbasierter Natur. Der mentale koordinative Leistungsanteil ist viel höher als der rein körperliche.

Ein sehr schönes Beispiel, wie intelligent die Motorik tatsächlich sein kann, sind Passwörter. Der Autor erinnert sich an sein Firmenpasswort leichter durch seine Finger, wenn er sie von selbst über die Tasten gleiten lässt. Das Passwort ist also durch den Motorkortex besser abrufbar als durch den Neokortex!

Diese Differenzierung nach sensorischer, motorischer und abstrakter, semantischer Intelligenz kann weiter verfeinert werden. Sie hilft, die beiden Produktionsfaktoren Mensch und KI besser zu verstehen und damit im Verbund einzusetzen. Insbesondere hilft dieses Verständnis nicht nur, die Automatisierung der Intelligenz im Unternehmen systematisch und sehr effizient vorzunehmen, sondern auch die zukünftige Rolle der KI in der menschlichen Gesellschaft und am Arbeitsplatz besser zu bestimmen und die wirkungsvollsten Mensch-KI-Kollaborations- und -Hierarchiemodelle zu entwickeln.

So wie wir Intelligenz also als sensorische, modellierend-abstrahierende und motorische Intelligenz unterscheiden können, so müssen wir auch die Zunahme an Wissen differenziert betrachten, wenn es um KI und ihre Produktivität geht. Und dabei machen KIs derzeit die größten Fortschritte im Bereich der abstrakten Intelligenz, während die Fakultäten die starke sensorische oder motorische Unterstützung benötigen mit erheblichem Abstand folgen. Wenn man jedoch berücksichtigt, dass 80% der Neuronen im Cerebellum liegen, dort hochkompakt angeordnet sind und eine sehr hohe Schaltgeschwindigkeit haben, dann ist es nachvollziehbar, dass eine KI einen Forecast oder GO bereits meisterhaft beherrscht, aber noch nicht Fahrradfahren kann.

Semantische KIs „erlernen“ heute die ganze Wikipedia mit über 100 Mio. Artikeln je nach Qualität und Rechenleistung in Tagen oder nur Stunden.

Dies ist ebenfalls Wissensgenerierung, denn die Gesamtproduktivität der menschlichen Gesellschaft hängt entscheidend von der Wissensverteilung ab. Je mehr intelligente Subjekte und Objekte (Menschen und Maschinen) jeweils wissen, desto mehr potenzielle Produktivität (Wissen) kann in effektive Produktivität (Prozessaktivität) übersetzt werden. Man könnte dies auch als Copy-Produktivität bezeichnen. Denn es wird streng genommen kein neues Wissen generiert, sondern nur bestehendes Wissen verbreitet und in der Anwendung skaliert. Dies kann man als erste Produktivitätsebene der Intelligenz bezeichnen.

Wichtig ist also die Fähigkeit, bestehendes Wissen aufzunehmen, um es dann einzusetzen. Darin brillieren die KIs bereits heute.

Wenn eine heutige KI also Wiki „gelernt“ hat, findet ein limitierter Wissenübertrag auf die Maschine statt. Limitiert deshalb, weil diese KI das Gelernte noch nicht voll-assoziativ begreift und vor allem kann sie noch kaum neue oder nicht beschriebene Zusammenhänge daraus abstrahieren oder Schlussfolgerungen ziehen. Sie ist also noch nur sehr begrenzt in der Lage, daraus selbst wirklich neues Wissen zu generieren.

Sehr wohl aber kann sie menschliche Entscheidungen statistisch erlernen und sehr präzise und effizient in hinreichend ähnlichen Situationen einsetzen. Diese KI erreicht damit die erste Produktivitätsebene. Sie setzt bestehendes Wissen sehr effizient und präzise und konsequent in allen möglichen Prozessen ein.

Neues Wissen als zweite Produktivitätsebene zu generieren ist, wie wir alle wissen, ungleich schwieriger. Wobei gesagt werden muss, dass die effektive Produktivitätssteigerung und damit das Wirtschaftswachstum seit 30 Jahren vornehmlich durch die Verbreitung, sprich Globalisierung, des Wissens getrieben wurden, der ersten Produktivitätsebene von Wissen. Wir werden also derzeit nicht absolut sehr viel schlauer pro Zeiteinheit, sondern viele Menschen werden relativ schlauer und können dieses Zusatzwissen dann auch direkt in gesteigerte Produktivität und damit Wohlstand umsetzen.

Makroökonomisch ist genau dieser Prozess der Treiber für das Wirtschaftswunder von Japan und Südkorea in den 1970er- bis 1990er-Jahren und für den Wiederaufstieg Chinas in den letzten 30 Jahren zu einer modernen Technologienation.

Dabei trägt nicht nur neues Wissen per se zu mehr Gesamtproduktivität und Wohlstand bei, sondern eine optimale Wissensverteilung über die Gesellschaft. Länder mit einem hohen Bildungsstand sind die Länder mit hoher Gesamtproduktivität, da die gesamte Bevölkerung wertvolles Wissen zur Schaffung von zusätzlicher Produktivität besitzt. Das ist auch eine Erklärung, warum Menschen heute noch nicht zum Mars fliegen können: Die menschliche Gesellschaft musste erst eine bessere Wissensverteilung erreichen, bevor sie bereit war, substanziell neues Spitzenwissen in gewissen Gebieten zu erarbeiten.

Es ist anzunehmen, dass die Maschinen, wenn sie erst mal den Bogen raus haben, wie man lernt, sehr viel schneller und effizienter neues Wissen generieren werden als der Mensch. Erste Beispiele von Lab-KIs belegen dies bereits indikativ. Damit wird das Produktivitätspotenzial durch KI auf beiden Ebenen gewaltig steigen. Bestehendes Wissen wird sehr rasch für den globalen Einsatz kopiert und skaliert, während neues Wissen von KIs rascher generiert wird, als dies Menschen können, und eventuell sogar schneller als es die Menschen hinreichend absorbieren können. (Abb. 1).

Produktivität allein bestimmt aber noch nicht den Wert eines Arbeitsergebnisses. Ebenso bestimmt auch der Grad des Zusatz- oder Neuwissens nicht den Wert in einem Produkt oder einer Dienstleistung.

Der Wert wird durch Angebot und Nachfrage entschieden. Das Angebot muss eine hohe Nützlichkeit („utility“) haben für den Konsumenten und gleichzeitig sollte es knapp sein, erst dann entsteht ein hoher Wert. Die Nützlichkeit selbst aber bemisst sich




Abb. 1 Intelligenz als Quintessenz der Wertschöpfung (Vocolka 2017)

als empfundene Produktivitätssteigerung des Käufers, auch des Konsumenten von Vergnügung, denn dieses wirkt indirekt auf den Kunden produktiv. Alle gekaufte Nützlichkeit ist tatsächlich ein Produktivitätsgewinn durch gekauftes Wissen bzw. Fähigkeiten, sei es in Form von Produkten oder Dienstleistungen für den Käufer.

Wenn jetzt in all unseren noch recht „dummen“ Produkten und Dienstleistungen KI eingebettet wird, dann sind diese Produkte und Dienstleistungen nicht nur wesentlich nützlicher und produktiver für den Käufer, sondern sie gewinnen im Lauf ihrer Lebenszeit sogar noch an Nützlichkeit hinzu. Warum? Weil sie durch ihre Intelligenz lernen können und somit über die Zeit stetig steigendes Wissen und Fertigkeiten als Produkt und Dienstleistung zum Einsatz bringen können.

In dem Moment, da KI auch Maschinen und Applikationen steuert, also eine physische Ausprägung und Transaktionsfähigkeit erhält, macht sie den Schritt vom reinen Denken zum konkreten Handeln, und dann wird der Mensch in etlichen Bereichen aus der Wertschöpfung tatsächlich komplett verdrängt. Sie wird damit maximal produktiv, aber dann beginnt auch die Frage der Verantwortung noch wichtiger zu werden.

Die KI wird somit voll handlungsfähig. Etwas dass der Mensch selbst erst mit seiner Volljährigkeit erreicht. Und als implizite Voraussetzung dazu wird ihnen die volle Urteilsfähigkeit ebenfalls zugeschrieben. Etwas, das jungen Menschen in Europa erst ab dem Alter von etwa 16 Jahren zugeschrieben wird. Und die Kombination dieser beiden Aspekte, der Fähigkeit, den Menschen in ganzen Wertschöpfungsketten zu ersetzen, und urteils- und handlungsfähig zu wirken, ist, was die Emergenz und Verbreitung von KI so sehr disruptiv werden lassen kann.

Es gibt Modelle, die vorhersagen, dass KI im Jahr 2050 etwa 20 % der Arbeit der Menschen in den OECD-Ländern übernommen haben wird. Die effektive Pro-Kopf-Arbeitszeit ist in Deutschland zwischen 2000 und 2018 bereits um 17 % gesunken, ebenso in den meisten OECD-Ländern und sogar in den USA. So wie 80 Stunden Schwerstarbeit pro Woche vor 120 Jahren nicht unüblich waren, so ist auch eine 20-Stunden-Arbeitswoche in OECD-Ländern im Jahr 2050 eine durchaus mögliche Entwicklung (Abb. 2).

Wenn KI also den großen Produktivitätssprung darstellt, wer wird dann davon profitieren und wer verlieren? Oder kann es tatsächlich sein, dass es bei diesem Entwicklungsschritt, bei dieser Revolution keine Verlierer gibt, sondern nur Gewinner?

Es ist unwahrscheinlich, dass es keine Verlierer geben wird durch die Vierte Industrielle Revolution, aber es ist machbar, dass die überwältigende Mehrheit gewinnt und es nur wenige gibt, die Nachteile daraus erfahren. Das sollte der Anspruch von CSR sein, wenn es um KI geht.

Dazu bedarf es natürlich auch eines Überdenkens unseres Wirtschaftssystems. Wenn wir es schaffen, viele Grundsätze zu hinterfragen und fundamentale Änderungen an unserem Wirtschaftssystem und der Definition von Arbeit, Wohlstand und Menschenrechten vorzunehmen bereit sind, dann kann KI zum Win-Win werden. Wenn wir aber an alten Philosophien und Denkschemata festhalten, dann werden große gesellschaftliche Spannungen entstehen.




Abb. 2 Produktivitätssteigerungen durch intelligente Automatisierung und KI bis 2050 (OECD, IWF; Modelle: Vocolka 2017)

Nicht nur CSR muss diese Veränderungen antizipieren und berücksichtigen, sondern die Politik muss hier vorbereitet und informiert werden, damit die Weichen für den Übergang in eine positive Zukunft mit intelligenten Maschinen frühzeitig gestellt werden können, denn sowohl Utopia als auch Dystopia sind vorstellbar, wenn es um KI geht.

3 Utopia oder Dystopia – wo Licht, da auch Schatten

Würden alle Menschen sich einig sein, dass KI natürlich, sinnvoll und nützlich und auch unvermeidlicher Teil der Evolution ist, könnten wir den Beitrag jetzt abkürzen, indem wir feststellen, dass CSR sich damit nicht zu beschäftigen braucht, da ein überwältigender Konsens besteht, dass KI uns Utopia näher bringt und was immer die Wirtschaft in Sachen KI austüftelt, alles mit Freude von der Gesellschaft aufgenommen wird.

Dem ist aber, wie wir wissen, nicht so, weil KI ja dem Menschen an seine Kernsubstanz geht, um es salopp zu sagen. Wir erhalten wieder Konkurrenz in dieser Revolution, aber diesmal geht es nicht um Muskelkraft, sondern um Geisteskraft und da hört für viele der Spaß oder das Gaming auf.

Existenzielle Fragen entstehen: Wenn der Mensch dank KI komplett durch Maschinen ersetzt wird, wie kann der Mensch dann noch sein Brot verdienen? Gibt es dann noch Arbeiten, die nur er verrichten kann und für die er auch entlohnt wird? Hat er noch einen produktiven Wert, der zum Lebensunterhalt reicht?

Makroökonomische Fragen entstehen. Wer kauft noch Güter und Dienstleistungen, wenn keiner mehr ein Einkommen hat? Kann man das über eine KI-Steuer im weitesten Sinne lösen, sodass die KI unseren Lebensunterhalt verdient? Wie wird sich der Wirt-

schaftskreislauf verändern, wenn die Wertschöpfung durch die Maschinen 90 % oder mehr beträgt?

Psychologische Fragen entstehen: Welchen Wert hat der Mensch noch, wenn die Maschine alles besser kann? Welchen Sinn hat das menschliche Leben oder die menschliche Zivilisation dann? Benötigt der Mensch nicht die Arbeit, um überhaupt einen Lebenssinn zu haben?

Ethisch-moralische Fragen entstehen: Dürfen KI Soldaten, Polizisten oder Richter und Regierungen beraten? Dürfen sie En-lieu-Entscheidungen in diesen Funktionen selbst treffen? Darf eine KI eine Lizenz zum Töten haben? Ab wann hat eine KI ein Recht auf Existenz?

Juristische Fragen entstehen: Wer haftet, wenn eine KI Entscheidungen trifft, die Schaden anrichtet oder aus menschlicher Sicht falsch scheint? Kann eine KI sanktioniert werden?

Diese kritischen Fragen zeugen von Verunsicherung, Angst, Pessimismus oder sind teilweise sogar von Hoffnungslosigkeit geprägt und können nicht unbeantwortet bleiben, ohne dass die Menschen gegen eine KI-unterstützte Gesellschaft rebellieren.

Wiederum könnten wir das Thema CSR und KI ad acta legen, wenn sich die Menschen einig wären, dass KI Teufelszeug ist und es weltweit verboten wird.

Wir alle aber wissen, dass es sich mit KI nicht nur um den Gini handelt, der aus der Flasche entwichen ist, sondern um eine natürliche zivilisatorische Entwicklung.

Eine Entwicklung, die im Grundsatz auch von den Menschen begrüßt wird, wenn sie den Nutzen von KI innerhalb des nächsten Jahrhunderts reflektieren: Kaum noch Verkehrstote oder Verletzte, der Sieg über die meisten Krankheiten, eine signifikant höhere Lebenserwartung bei exzellenter Gesundheit, die Lösung unseres Energiebedarfs, eine regenerierte Umwelt und das alles ohne arbeiten zu müssen, sondern wertschöpfend tätig sein zu können, und das bei einer Wohlstandsverteilung basierend auf einer dynamisch definierbaren, gekappten Gauß-Verteilung.

Für dieses Licht lohnt es sich, sich mit den möglichen Schattenseiten zu beschäftigen, die alle erst mal durch den Menschen selbst induziert werden, nicht durch eine KI oder eine Gruppe von KIs. Das Entstehen von KI zwingt uns sehr viel mehr, über unsere eigenen Schattenseiten nachzudenken, denn es sind diese, die KIs von uns lernen könnten. Dystopische Effekte sind also primär die Reflexion unserer eigenen dunklen Seite. Vielleicht ist dies auch die Zeit, uns selbst zu verbessern, damit wir das Rollenmodell sind, an dem die KIs sich orientieren.

Also könnte man die Entwicklung und die Nutzung von KI von Staatswegen ganz eng regulieren. Aber jeder Staat würde das anders angehen, da jedes Land seine eigene Kultur hat und daraus die eigene Betrachtung zum Menschen und seiner Rolle in dieser Welt. Wir hätten Staaten, in denen alles erlaubt würde und die KI würde als 13. Geschworener im Gerichtssaal sitzen, und Staaten in denen würde KI bei Strafe verboten werden.

Zudem hinken die Regierungen meist hinter der Innovation her und müssen selbst erst den Charakter und die Auswirkungen von Neuerungen verstehen, bevor sie regulativ

aktiv werden können, zum Vorteil eines freien Innovationsraums. Nachteilig ist dieser Wissensabstand dann, wenn neue Technologien im Rahmen eines regulativen Rahmens eingesetzt werden müssen. Dann wird aus Innovationsfreiheit, Innovations- und vor allem Investitionsunsicherheit. Letztlich treten alle auf der Stelle und die Innovation steht still. Ein Effekt, den man jahrelang beim autonomen Fahren verfolgen konnte.

Diesen Zustand der Innovationslähmung kann und muss die Wirtschaft durch das Schaffen einer klaren CSR bezüglich KI und einem durchdachten KI-Governance-Framework aus eigener Kraft durchbrechen und die Regierungen und Regulatoren in einem proaktiven konstruktiv-gestalterischen Diskurs motivieren, wichtige Rahmen-voraussetzungen für den nützlichen und sicheren Einsatz von KI zu schaffen und auch zu garantieren.

Erfreulicherweise ist dies gerade im September 2020 beim Autogipfel in Berlin geschehen, nachdem die Unternehmen eben im Juni das autonome Fahren schon fast ad acta legen wollten.⁵ Zu wenig traute man sich, in diese fundamentale Technologie für die Mobilität von morgen zu investieren. Die Automobilindustrie konnte die Regierung dazu bewegen, endlich den gesetzlichen Rahmen für autonomes Fahren bis 2022 zu entwickeln und dabei gleichzeitig ein Signal für die Elektromobilität zu setzen.⁶ Die Automobilwirtschaft weiß jetzt, dass das autonome Fahren vom Gesetzgeber her erlaubt und ermöglicht wird und ab wann und unter welchen Bedingungen.

Hätte sich die Automobilindustrie ernsthafter und informierter mit dem Thema schon vor zehn Jahren beschäftigt, als die Technologie erstmals konkret zum Einsatz kam, dann hätten wir diese gesetzliche Regelung schon ein halbes Jahrzehnt früher gehabt. Die Automobilindustrie und die Regierung hätten sich nicht nur auf den minimalen Grenznutzen des CO₂-Ausstoßes fixiert, sondern erkannt, das KI-Autos als Nebeneffekt die größten CO₂-Reduktionen erbringen können. Dies hätte der Industrie jahrelange juristische Agonie und Strafzahlungen in Milliardenhöhe erspart. Milliarden, mit denen man bereits heute Level-5-KI-Autos entwickeln hätte können.

Jedes Jahr, da autonomes Fahren früher zum Einsatz kommt, rettet viele Menschenleben und vermeidet viel gesellschaftliches Leid, reduziert den Energieverbrauch und steigert die Lebensqualität. Das ist genau der Sinn von CSR!

Wenn also die Wirtschaft und damit auch die Gesellschaft keinen Rückschlag oder keinen Stillstand in dieser fundamental wichtigen technologischen Entwicklung erleiden will, müssen die Unternehmen selbst das Produktivpotenzial von KI verstehen, KI im Rahmen von CSR berücksichtigen und ein KI-Governance-Framework entwickeln und einsetzen, das die definierten Prinzipien von der Entwicklung bis zum Einsatz und dem Lebensende einer KI transparent und nachvollziehbar dokumentiert und sichert.

⁵ <https://www.manager-magazin.de/unternehmen/autoindustrie/autonomes-fahren-bmw-und-mercedes-beende-kooperation-a-1307833.html>

⁶ <https://www.automobil-industrie.vogel.de/autogipfel-keine-kaufzuschuesse-fuer-verbrenner-aber-anschub-fuers-autonome-fahren-a-962159/>

Es ist unwahrscheinlich, dass KI zu einem grenzenlosen Utopia innerhalb weniger Jahrhunderte führt, aber es ist ebenso unwahrscheinlich, dass die Maschinen sich in wenigen Dekaden aufschwingen werden, den Menschen zu beherrschen. Es ist wahrscheinlicher, dass es ein Mix aus positiven gesellschaftlichen Verbesserungen und negativen Nebeneffekten geben wird. Der Mix wird aber die Geschwindigkeit des Fortschritts bestimmen. Für Unternehmen gilt es, diese Geschwindigkeit hochzuhalten, indem CSR und ein KI-Governance-Framework den Anteil an unerwünschten Nebeneffekten möglichst klein hält, während der Nutzen beschleunigt der Gesellschaft zur Verfügung gestellt wird.

4 Künstliche Intelligenz ist nicht gleich künstliche Intelligenz – Differenzierung ist essenziell

Um KI im Rahmen von CSR richtig verorten zu können, müssen wir uns einen kurzen Überblick über das sehr dynamische Feld der Artificial Intelligence und den Gesamtkontext verschaffen.

Ohne Grundkenntnisse von natürlicher und künstlicher Intelligenz und ihrer Wechselwirkung können wir KI in ihrer Wirkung und ihrer Auswirkung in den CSR-Dimensionen nicht verstehen, nicht positionieren und natürlich auch nicht richtig moderieren. Auch können wir die Entwicklung von KI besser abschätzen, wenn wir die wesentlichen Ausprägungen von KI berücksichtigen.

Artificial Intelligence, auf Deutsch künstliche Intelligenz, beschreibt die Eigenschaft eines Systems, das nicht biologisch-natürlich entstanden ist, wie natürliche Intelligenz (NI), sondern vom Menschen geschaffen wurde, um von seiner Umgebung zu lernen und sich dieser anzupassen.

Aus dieser sehr grundsätzlichen Definition erkennen wir bereits, dass KI ebenso wie NI ein Kontinuum darstellt. Das heißt, dass es viele Schattierungen und, wenn man so will, Niveaus und Intelligenzen gibt. Entsprechend dieser Definition ist Fauna und Flora ebenso mit Intelligenz und sogar mit Bewusstsein ausgestattet, wie der Mensch, nur der Grad der Intelligenz und die Ausprägung des Bewusstseins als emergente Fähigkeit auf Basis komplexer dynamischer Informationsstrukturen sind unterschiedlich stark entwickelt. Während niedrige NI-Niveaus zu einem relativ langsamen Lern- und Anpassungs- bzw. Entwicklungsprozess führen, ermöglichen hohe Intelligenzgrade eine beschleunigte Evolution und die Entwicklung einer komplexen technologischen Zivilisation, wie der unseren.

Wie beim Menschen auch, können wir bei KI die Intelligenz oder Fähigkeit per Fakultät bewerten. Wie gut ist man beispielsweise bei der Vorhersage von Entwicklungen, wie gut kann man Dinge erkennen, wie gut ist man in Sprachen oder in der Mathematik oder – weiter aufgefächert – im Schachspielen oder in GO.


Bei KI kann man prinzipiell zwischen „narrow AI“ (NAI) und „general AI“ (GAI) unterscheiden. NAI haben sehr schmalbandige Aufgaben und Fähigkeiten. Sie sind

absolute „Fachidioten“. GAI haben mehrere Fakultäten (verschiedene Intelligenzen), die miteinander verbunden sind und können komplexere Aufgaben übernehmen. Je mehr Fakultäten eine GAI einsetzen kann, desto höherwertiger und komplexer die Denkstrukturen werden, desto varianter kann ihr Einsatz sein.

Während NAI klare Objektnatur haben, entwickeln sich die GAI in Richtung Subjekt.

In der Regel versteht der Laie unter KI eine GAI und dementsprechend schreibt er ihr unbewusst dem Menschen ebenbürtige bzw. kompetitive oder gar widersächliche Fähigkeiten und oft auch eine solche Natur zu. Über 95 % der heute eingesetzten KI sind aber überwiegend NAI und die aktuellen GAI sind noch weit davon entfernt, dem Menschen generell ebenbürtig zu sein.

Aber in ihren Fachdisziplinen, sei es nun Forecasting oder Go sind die NAI dem Menschen bereits jeweils klar überlegen. Ganz wie beim Schach versteht man inzwischen auch, dass der Mensch nicht das Maß für die KI ist, sondern dass er lediglich die wichtigste Benchmark ist auf einer nach oben offenen Skala der Intelligenz. Für Philosophen ist dies der vierte kopernikanische Moment nach Kopernikus, Darwin und Freud (Abb. 3).



*Degrees of sensoric and motoric freedom

Abb. 3 Die Freiheitsgrade der künstlichen Intelligenz sind eng mit ihrem Disruptionspotenzial verknüpft (nach Vöcelka 2017)

Nach allem was wir heute wissen im Bereich der KI-Forschung und der verwandten Neurowissenschaftsbereiche, werden KIs den Menschen nicht nur einholen, sondern in nicht allzu ferner Zukunft auch in vielen, vielleicht sogar in allen Denkdisziplinen übertreffen.

Die Entwicklung von genereller KI, also menschenähnlicher, allgemeiner Intelligenz und Denk- und Handlungsfähigkeit, steht erst am Anfang und wird noch Dekaden benötigen – aber sie ist heute schon absehbar.

Wenn KIs erst selbst neues Wissen generieren können, ist anzunehmen, dass auch diese Fähigkeit exponentiell zunimmt. Da Maschinen aber viel schneller arbeiten als Menschen, ist es wahrscheinlich, dass sie auch sehr viel schneller neues Wissen schaffen, als es die Menschen können, und sogar, als sie es von den Maschinen übernehmen können. Genau dies ist auch eine weitere Angst, die einige Menschen umtreibt, nämlich, dass die KIs uns nicht nur ebenbürtig sind, sondern weit mehr wissen und damit auch mehr können.

Die Idee KI dann eben einfach durch Programmklauseln zu vergattern und in ihrem Denken und Handeln eng zu kontrollieren, scheitert aber an einem wirtschaftlichen Paradoxon. Die Produktivität von KI steigt mit ihrer Intelligenz und Handlungsfähigkeit, die wiederum mit ihren sensorisch-motorischen Freiheitsgraden eng gekoppelt ist. Bereits in den 1990er-Jahren hat man verstanden, dass eine KI nicht regelbasiert konzipiert werden kann, der Aufwand wäre immens und unwirtschaftlich, diese Erkenntnis führte mit zum ersten KI-Winter.

Heute wissen wir, dass eine GAI dann die höchste Produktivität hat, wenn sie den höchsten Denk- und Handlungsspielraum hat – dann kann sie auf die unendlich variierenden Situationen der Realität am besten reagieren. Diese hohe Varianz ist der Grund, warum AIs nicht durch direkte menschliche Programme reguliert werden können. Die GAI muss im Prinzip wie der Mensch die Regeln ganzheitlich in einem sehr großen Kontext und mit variantem Spielraum erlernen. Das Lernen selbst kann sehr schnell erfolgen – programmieren kann der Mensch es aber nicht.

Aktuell wird überlegt, inwiefern eine GAI nicht auch eine Basismotivation benötigt, um produktiver und effektiver zu sein und um eine gewisse Verantwortlichkeit zu verankern. Mit einem sogenannten Need Personality Complex (NPC) ausgestattet, würde die GAI dann automatisch einen Subjektstatus einnehmen. Sie hätte eine kontinuierliche Grundmotivation, zu sein und mit der Umwelt selbst-verantwortlich zu interagieren.

Einfacher ausgedrückt: Die KI mit der höchsten Produktivität werden die mit den größten Freiheitsgraden und der höchsten intrinsischen Motivation sein und das heißt, auch sie werden sich initial so verhalten, wie sie es von uns lernen.

Dies ist eine zentrale Erkenntnis, wenn es um die Konzeption und Umsetzung von KI-Governance-Frameworks geht und die bereits heute intensiv diskutierten Themen des KI-Bias.

5 Die Rolle der künstlichen Intelligenz im Unternehmen

Das Unternehmen wird durch KI zu einem **komplexen intelligenten System**, wie jedes biologische System in der Natur auch.

Dieses Verständnis und diese Sicht auf das Unternehmen im 21. Jahrhundert ist von fundamentaler Bedeutung. Die Entwicklung von Geschäftsmodellen und -strategien hängt davon ab. Die Digitalisierungsstrategie des Unternehmens sollte daraus das Zielbild ableiten und die IT-Infrastruktur danach ausrichten und natürlich wird diese Sicht auch die Entwicklung von Produkten und Dienstleistungen verändern.

Wenn von intelligenter Automatisierung im Unternehmen gesprochen wird, wird dabei oft an eine Maschine gedacht. Korrekter ist es, dabei an einen Prozess zu denken. Alle Prozesse im Unternehmen werden durch KI intelligenter. Jeder Prozessschritt im Unternehmen wird systematisch durch intelligente KI-Komponenten in seiner Produktivität erhöht. KI wird auch immer mehr aktiv-steuernd in das Unternehmen eingreifen, nicht nur passiv-analysierend. Dabei haben KIs den Vorteil der Objektivierung der Steuerung. Das macht insbesondere Planung, Performancemanagement und Optimierung aller Ressourcen einfacher, schneller und effektiver. Politik und subjektive Einflüsse werden verstärkt herausgefiltert.

Die intelligente Automatisierung aller Prozesse bedeutet, dass die Mitarbeiter Aktivitäten an die KI abgeben und von der KI Ergebnisse übernehmen und nutzen. Dies verändert den Arbeitsmodus der Mitarbeiter und hat tiefgreifende Folgen für Verantwortlichkeiten und das Performancemanagement.

Aktuell zögern die Unternehmen noch, weil die Materie neu ist. Man lässt die KI analysieren und simulieren, aber entscheidet sehr oft nach Bauchgefühl. KI wird dabei mehr getestet, als aktiv eingesetzt. Davon zeugen auch zahllose Use Cases, die ein Prototypen-, Minimum-Viable-Product(MVP)- oder gar Schubladendasein fristen.

Reale Produktivität entsteht aber nur durch Entscheidung und Aktion, durch die physikalische Umsetzung der Denkprozesse einer Intelligenz, sei es eine Transaktion oder eine mechanische Aktion. Ohne Aktion oder Transaktion eines Unternehmens realisiert das Unternehmen kein Wissen, generiert kein neues Wissen und betreibt keine Wertschöpfung.

Womit wir bei dem überstrapazierten Begriff der Analyse sind. Alles ist aktuell Analytics im Sprachgebrauch der Unternehmen, sei es Business Analytics oder Advanced Analytics oder Data Analytics. Und unter dem Begriff Business Intelligence ordnet man wieder jedwede Analytics zu.

Das allein zeigt, wie wenig das Thema des vierten Produktionsfaktors bisher durchdrungen wurde. Obwohl der alte Spruch „paralysis by analysis“ bestens bekannt ist, beschränken sich die meisten Unternehmen aktuell immer noch auf die Datenanalyse. Aber dort liegt nur die potenzielle Produktivität.

Analyse allein generiert maximal potenzielles Wissen aber kein effektives Wissen und damit keine Wertschöpfung. Etwas zu wissen, hat keinen Wert, wenn das Wissen nicht in Aktion umgesetzt wird. Noch schlimmer als Geld in die Matratze zu nähen ist, Wissenspotenzial ungenutzt im Unternehmen zu horten und lediglich theoretisch-philosophisch zu betrachten.

Erst bei der Ausführung und nicht in der Simulation wird Wissen zu konkreter Wertschöpfung. Und genau da setzt KI an und genau da liegt die sensible Stelle. Die KI entwickelt nämlich nur dann Wertschöpfung, wenn sie Aktionen selbst auslöst bzw. Aktionen empfiehlt, die der Mensch dann auch so umsetzt. Solange sie auf Analyse beschränkt wird, ist die KI auf die NI, also den Menschen als „middleman“ zur Wertschöpfungsrealisierung angewiesen.

KI werden dann die höchste Produktivität erreichen, wenn sie an transaktionale oder motorische Systeme gekoppelt werden und den kompletten Wertschöpfungszyklus vom Monitoring über die Analyse und die Synthese bis zur Entscheidung und Umsetzung in einem Unternehmensprozess leisten können.

Intelligenz als zentraler Produktionsfaktor wird aber nicht nur vom Unternehmen zur Planung, Steuerung und Produktion und Logistik, also bei internen Prozessen und externer Kommunikation eingesetzt, sondern vom Unternehmen auch in seine Produkte und Dienstleistungen direkt eingebaut und verkauft. Ob Autos oder Rasenmäher, Pool-Roboter oder Kinderwagen, Kinderzimmer oder Sporthalle, sie alle werden richtig intelligent werden und erweiterte Aufgaben übernehmen können und damit die Funktionalität und ihren Nutzen steigern.

Der Kunde kauft also in Zukunft nicht einen Rasenmäher mit fixen Fähigkeiten aus einem Datenblatt, sondern einen intelligenten Rasenmäher mit dynamischen Fähigkeiten. Er kauft also nicht nur Produktivität, sondern Produktivitätspotenzial, dass von der Lern- und Aktionsfähigkeit des Rasenmähers abhängt. Daher ist es für das Unternehmen sinnvoll, den Rasenmäher schon heute mit dem Intelligenzpotenzial auszurüsten, sprich der Sensorik, dem Prozessor und der Motorik, die ihm in Folgejahren zusätzliche Fähigkeiten verleiht, wenn er diese erlernt hat. Tesla⁷ hat das schon vor Jahren verstanden und verfolgt eine Strategie des hochintelligenten Autos, das schon heute über alle Komponenten für eine sehr leistungsfähige KI verfügt.

Aus dieser Gesamtlogik heraus müsste ein Unternehmen jede Maschine, jeden Fahrstuhl, jede Fabrikhalle, jeden Prozess und natürlich jedes Produkt, von der Heckenschere bis zum Taschentuch, intelligent machen. Und genau das geschieht auch durch KI. Wobei man für marginale NAI auch „edge intelligence“ als Begriff eingeführt hat. Diese Produkte werden in steter Verbindung mit dem Mutterunternehmen sein und ihr erlerntes Wissen mit ihren Schwesterprodukten teilen, wenn die KI-Governance das richtig vorbereitet

⁷ <https://bernardmarr.com/default.asp?contentID=1251>; <https://hbr.org/2020/02/how-tesla-sets-itself-apart>

und ermöglicht und berücksichtigt, dass sich die Haftungsverhältnisse dadurch stark verschieben können.

Als Wirtschaftsfaktor stellt KI für jede Wirtschaftsbranche eine zutiefst transformative Herausforderung dar. Ihr Einsatz ermöglicht dem Unternehmen und seinen Kunden nie gekannte Produktivitäts- und Renditesprünge. Die meisten Unternehmen sind sich über dieses Wertschöpfungspotenzial jenseits von Data Analytics noch nicht wirklich bewusst.

Je höherwertig die KIs werden, desto mehr entscheiden sie von selbst und lösen auch Aktionen aus, ohne menschliches Zutun und dabei entwickelt sich die KI vom Berater zum Entscheider und damit vom Objekt zum handelnden Subjekt. Hier eröffnet sich das Problemfeld der Verantwortlichkeit im Unternehmen und auch der Leistungssteuerung. Nicht nur nimmt uns die KI die Arbeit ab, sie nimmt uns auch die Verantwortung ab. Wird sie zum Prokuristen? Kann sie das? Soll sie das? Darf sie das? Und was sind die möglichen Konsequenzen? Das sind Fragen, die die CSR betreffen und die im Rahmen eines KI-Governance-Frameworks rechtzeitig geregelt werden müssen.

Insbesondere in der Kundeninteraktion stellen sich viele dieser Fragen bereits heute dringlichst. Denn wenn der Mensch aufgrund von Kommunikation oder gar Empfehlungen der Maschine schädliche Aktivitäten ergreift – wer haftet dann? Insbesondere die junge Generation ist wesentlich anfälliger für Manipulation durch KI. Wo sind hier die Grenzen, die das Marketing nicht überschreiten sollte? In Frankreich ist Neuromarketing noch heute verboten, in den meisten anderen Ländern nicht.

Unternehmen haben in den letzten fünf Jahren nur sehr kleine Fortschritte bei der Digitalisierung gemacht.

Gründe dafür gibt es etliche. Der gewichtigste jedoch ist fehlendes Wissen zu dem Thema auf allen Ebenen, aber insbesondere auch auf der Leitungsebene der Unternehmen.

Man spielt mit zahllosen Use Cases, aber man möchte nicht wirklich „nass“ werden und diese produktiv schalten. Das Ganze mutet meist wie eine fröhliche Jagd nach Use Cases mit Platzpatronen an, aber nicht wie eine zielgerichtete Transformation. Spätestens wenn Use Cases aber produktiv gesetzt werden sollen, kommt es zum Schwur, und da zeigt sich, wie groß die instinktive Kluft von Managern und Mitarbeitern gegenüber KI noch ist.

Aufklärung und Leadership in den Unternehmen zum Thema KI und ihrem Einsatz tun not, gerade auch weil fehlendes Wissen an der Spitze zur Paralyse am Körper führt. Gleichzeitig ist man noch weit davon entfernt, die Auswirkungen von KI auf die eigenen Kunden und Mitarbeiter zu verstehen. Man stolpert langsam in die Vierte Industrielle Revolution.

CSR kann auch bei der eigenen digitalen Transformation der Unternehmen als Beschleuniger sehr wertvoll sein, indem das Management sich intensiv mit dem Thema Produktionsfaktor KI und dem konkreten Einsatz in allen Wertschöpfungsdimensionen aktiv, strategisch und konzeptionell beschäftigt. Die digitale und KI-Governance ermöglicht dabei nicht nur die Operationalisierung der CSR Richtlinien und Prinzipien, sondern sie bildet auch eine Säule der digitalen Transformation selbst.

6 An der Schnittstelle zwischen Menschen und Maschine – Welche Auswirkungen hat künstliche Intelligenz auf das bestehende CSR Framework?

6.1 Wirkung existierender CSR-Säulen (ökonomisch, sozial, ökologisch) im Kontext von künstlicher Intelligenz

Die zunehmende Wettbewerbsfähigkeit, die global vernetzten Wertschöpfungsketten und nicht zuletzt die Fortschritte in der Entwicklung innovativer Technologien beeinflussen die CSR-Aktivitäten. Dies erfordert eine Auseinandersetzung von Staaten sowie Unternehmen im Hinblick auf die Neuausrichtung der sozialen Handlungsfelder und die Bedeutung der ökologischen Verantwortung im Einklang mit den ökonomischen Belangen.

Im Rahmen dieses Kapitels werden die bekanntesten CSR-Modelle der Literatur kurz skizziert, um darauf aufbauend die Umsetzung von CSR-Aktivitäten im internationalen Kontext darzustellen und schließlich die Auswirkungen durch den Einsatz von KI auf das bestehende CSR Framework zu analysieren.

CSR kann als unternehmerische Philosophie oder Managementleitbild betrachtet werden. Dieser Ansatz umschließt ökonomische, ökologische sowie soziale Aspekte, deren Aktivitäten sich auf das unternehmerische Handeln, die Mikroumwelt sowie die Zivilisation auswirken. Dabei ist CSR nicht gesetzlich vorgeschrieben, sondern findet durch die Unternehmen auf freiwilliger Basis statt.

In der wissenschaftlichen Literatur existiert keine einheitliche Definition, vielmehr erscheint das CSR-Universum als sehr vielfältig. Das liegt insbesondere an der Tatsache, dass CSR eine Vielzahl von Akteuren einbindet und somit je nach Interessenslage, Perspektive sowie aktuellem Geschehen unterschiedlich ausgelegt und interpretiert wird.

Oftmals verwendet und referenziert wird die Pyramide nach Carroll, die sich in vier Stufen untergliedert: Ökonomische Verantwortung, gesetzliche Verantwortung, ethische Verantwortung sowie die philanthropische Verantwortung, die das Engagement von Unternehmen im Bereich des Sozialen, der Bildung und der Kultur umfasst (Carroll 1991). Die Ebenen der ökonomischen und gesetzlichen Verantwortung bilden das Fundament. Laut Carroll sind sie im Vergleich zu den ethischen und philanthropischen Aspekten zwingend für den wirtschaftlichen Erfolg des Unternehmens notwendig. Dieses Pyramidenmodell wurde einige Jahre später durch Carroll und Schwartz weiterentwickelt und in einem Venn-Diagramm neu aufgebaut. Die CSR-Kernbereiche werden nicht mehr hierarchisch strukturiert, sondern überlappend dargestellt, sodass insgesamt sieben mögliche Bereiche gesellschaftlicher Verantwortung entstehen (Schwartz und Carroll 2003). Der Nobelpreisträger Milton Friedman rückt die Säule der ökonomischen Verantwortung in den Mittelpunkt der CSR-Aktivitäten (Friedman 2007): „The Social Responsibility of Business is to Increase its Profits.“ Demnach folgt das Modell nach Friedman dem Leitgedanken, die gesellschaftliche Verantwortung von Unternehmen liegt ausschließlich in der Profitmaximierung und Unternehmenswertsteigerung.

Im Rahmen der Literaturrecherche wurden etliche CSR-Modelle identifiziert, die sich in ihrer inhaltlichen Ausprägung und Darstellung unterscheiden. Einzig die Begrifflichkeiten Ökonomie (nachhaltiges Wirtschaften), Ökologie (Umwelt und Nachhaltigkeit) sowie Soziales (gesellschaftliche, unternehmerische Verantwortung) wurden immer wieder aufgegriffen. Diese oftmals verwendeten und traditionell geltenden CSR-Säulen werden auch in diesem Beitrag für weitere Abgrenzungen herangezogen.

Nachdem die unterschiedlichen Definitionsansätze der wissenschaftlichen Literatur beleuchtet wurden, stellt sich die Frage, wie unterschiedlich CSR im internationalen Kontext behandelt wird und wie sich diese Unterschiede auf den Einsatz von KI auswirken.

Veränderte Rahmenbedingungen mit unterschiedlichen Interessenslagen und länderspezifischen Geschehen haben große Auswirkungen auf die jeweiligen CSR-Aktivitäten. Die kulturellen Ausprägungen, rechtlichen Regelungen, verschiedenen Wirtschaftssysteme sowie die daraus resultierenden Zielkonflikte erklären, warum die weltweite Vorgabe einheitlicher CSR-Standards und Grundsätze nicht umsetzbar ist.

Im europäischen Wirtschaftsraum hat sich die CSR-Definition der Europäischen Union (EU) durchgesetzt. Sie erklärt CSR in der neuen Definition als „[...] die Verantwortung von Unternehmen für ihre Auswirkungen auf die Gesellschaft“ (EUROPÄISCHE KOMMISSION 2011). Damit rückt, als Folge der wirtschaftlichen sowie gesellschaftlichen Entwicklungen der letzten Jahre, die soziale Verantwortung der Unternehmen in den Fokus. Zuvor definierte die EU in der Veröffentlichung aus dem Jahr 2001 CSR als „[...] ein Konzept, das den Unternehmen als Grundlage dient, auf freiwilliger Basis soziale Belange und Umweltbelange in ihre Unternehmenstätigkeit und in die Wechselbeziehungen mit den Stakeholdern zu integrieren“ (EUROPÄISCHE KOMMISSION 2011).

In Deutschland engagieren sich schon viele erfolgreiche Unternehmen für die gesellschaftlichen Interessen und vereinen CSR-Aktivitäten mit Unternehmenserfolg: Förderung der Aus- und Weiterbildung anderer Nationalitäten, Stärkung des Engagements in Umweltbelangen oder die Nutzung der KI zur Verstärkung der menschlichen Intelligenz mit dem Ziel der Profitsteigerung. Große Familienkonzerne wie Miele, Bosch und STIHL integrieren soziale sowie ökologische Gesichtspunkte in ihre Unternehmenstätigkeit, wobei das Prinzip der Gewinnmaximierung häufig in den Vordergrund gestellt wird. Doch im Vergleich zu den USA steckt die Entwicklung der konsequenten Umsetzung und kontinuierlichen Weiterentwicklung von CSR-Aktivitäten in den Kinderschuhen. Ein Grund dafür ist die Tatsache, dass die wissenschaftliche Debatte um CSR ihren Ursprung in den USA hat – CSR ist also traditionell im amerikanischen Raum verankert.

Laut dem Konzept von Hall und Soskice (2001) leitet sich die Begründung für die unterschiedlichen Ausprägungen von CSR-Aktivitäten aus den kapitalistischen Wirtschaftssystemen ab. In ihrem Buch *The Varieties of Capitalism* werden die zwei kapitalistischen Idealtypen „liberal market economies“ (LME), auf Deutsch liberale Marktwirtschaft, und „coordinated market economies“ (CME), auf Deutsch koordinierte

Marktwirtschaft, anhand von fünf Clustern aus der Wirtschafts-, Sozial- sowie Politikwissenschaft miteinander verglichen (Hall und Soskice 2011). Die liberalwirtschaftlichen (LME) Länder, zu denen neben den USA weitere angelsächsische Gebiete zählen, sind laut ihrer Theorie durch unter anderem privatisierte und individualisierte Ausbildungssysteme sowie dezentrale Gewerkschaftsstrukturen geprägt. Demgegenüber sind die kontinentaleuropäischen (CME) Länder durch staatlich geförderte Ausbildungssysteme sowie ausgeprägte, branchenweite Gewerkschaftsstrukturen gekennzeichnet (Hall und Soskice 2011). Während beispielsweise in den USA den Unternehmen mehr Freiraum und somit größere Anreize zur kreativen unternehmerischen Gestaltung gegeben wird, muss in europäischen Ländern das unternehmerische Handeln entsprechend der historisch gewachsenen Richtlinien erfolgen. Das europäische Rahmenwerk, das das Sozialsystem sowie die Finanz-, Bildungs- oder Arbeitsmarktbestimmungen einschließt, ist also im internationalen Vergleich deutlich ausgeprägter und lässt sich als stark reguliertes Wirtschaftssystem beschreiben.

Diese Einflussfaktoren sowie die volkswirtschaftlichen Entwicklungen in den Ländern prägen auch zukünftig die unterschiedliche Nutzung von KI. Für die Veranschaulichung werden zwei empirische Szenarien gegenübergestellt:

- Szenario 1:

Die Debatte um die **gesellschaftliche Verantwortung** von Unternehmen rückt insbesondere in Industrienationen in den Fokus. Zentrale Themen wie Arbeits- und Gesundheitsschutz, Vergütung, Arbeitszeitmodelle, Aus- und Weiterbildungen haben an Bedeutung gewonnen. Dadurch, dass in diesen Ländern kein niedergeschriebenes Wertegerüst existiert, sollten Unternehmen einen verbindlichen Kodex zur ethisch korrekten Nutzung von KI definieren, um eine gesellschaftliche Wahrnehmung im positiven Sinn zu fördern.

- Szenario 2:

Die Sicherstellung der **ökonomischen Belange** gilt als tragende Säule der CSR-Aktivitäten. In diesen Ländern, wie beispielsweise Russland und China, stehen die Interessen der langfristigen Wettbewerbsfähigkeit und die gewinnbringende Nutzung der globalen Entwicklung im Fokus. Der Einsatz von innovativen Technologien wird durch Subventionsprogramme gefördert. KI wird in diesen Ländern als sogenannter Quantensprung verstanden, durch das die Unternehmen in der Lage sind, die größten Herausforderungen der heutigen Welt zu bewältigen. Die Anwendung von KI wird staatlich gefördert, ist in vielen Unternehmungen dieser Volkswirtschaften als Produktivitätsfaktor nicht mehr wegzudenken und wird von der Bevölkerung als Bereicherung wahrgenommen.

Diese Szenarien beschreiben zwei Wirtschaftssysteme, die sich durch kulturelle Ausprägungen, staatliche Regelungen sowie die Wahrnehmung der Bevölkerung wesentlich unterscheiden.

Aus traditioneller Sicht wird CSR als Maßstab für Unternehmen und Staaten verstanden, um anhand der drei Säulen Ökologie, Wirtschaft und Soziales Leitlinien im Sinn der Nachhaltigkeit zu definieren. In der Theorie wird dieses Drei-Säulen-Modell als gleichrangig beschrieben, da eine nachhaltige Entwicklung nur zu erreichen ist, wenn die Umsetzung aller drei Zielbilder im Mittelpunkt liegt.

Jedoch zeigt die Auseinandersetzung entlang der oben beschriebenen Szenarien, dass die Aktivitäten der CSR-Säulen im internationalen Kontext unterschiedlich ausgeprägt sind. **CSR sollte daher um die Rolle des KI-Facilitators erweitert werden, um den Herausforderungen der verschiedenen Wirtschaftsräume gerecht zu werden und die gesellschaftlich wünschenswerte Nutzung von KI zu fördern.**

6.2 Erweiterung um die vierte Säule zur Beantwortung ethischer Fragestellungen

Durch die globale Vernetzung und die wachsenden Datenmengen erschließen sich neue Möglichkeiten, die zu einem Perspektivwechsel und Wertewandel auch bei den Konsumenten führen und von den Unternehmen berücksichtigt werden müssen.

Die weltweite Digitalisierung ist vorangeschritten, internationale Beziehungen haben sich zusammengeschlossen, Daten werden länderübergreifend ausgetauscht und durch intelligente Maschinen genutzt. Hier stellt sich die Frage, ob das Vertrauen in diese Technologien (darunter auch KI) in der Zivilbevölkerung schon vorhanden ist und welche ethischen sowie moralischen Handlungsfelder reflektiert werden sollten.

Der amerikanische Professor A.B. Carroll greift die ethische Verantwortung auf und stellt sie als eigenständigen Verantwortungsbereich in der vierstufigen CSR-Pyramide dar. Aufbauend auf dem Fundament der ökonomischen Verantwortung, mit dem Ziel der Profitabilität, und der juristischen Verantwortung, des gesetzeskonformen unternehmerischen Handelns, ergänzt Carroll als dritte Ebene die ethische Verantwortung (Carroll 1991). Er bekräftigt damit die These, dass Unternehmen über die existenziellen und gesetzlichen Mindestvorgaben hinaus, freiwillige Aktivitäten wahrnehmen müssen, um den Erwartungen der Gesellschaft gerecht zu werden.

Wir befinden uns in einer Zeit, in der sich die Art der Datenverarbeitung, die Nutzung von Technologien sowie sämtliche Verfahren der Automatisierung rapide schnell entwickeln. Diese Fortschritte zählen als große Potenzialträger, rücken aber auch die gesellschaftlichen Auswirkungen in den Fokus. Wie muss eine gesellschaftsverträgliche KI entwickelt werden und welche Fähigkeiten darf ein „gutes“ und „moralisch korrekt“ agierendes KI-System haben? Die Notwendigkeit zur Beantwortung dieser Fragestellungen wird immer größer, um die Kluft zwischen Technologie und Gesellschaft zu schließen und das Vertrauen in die intelligenten Systeme zu stärken.

Die Säule der ethischen Verantwortung fordert also ein Wertegerüst von Staaten und Unternehmen, dass das ethisch angemessene und korrekte sowie faire Handeln im Sinn aller Stakeholder sicherstellt. Der Gestaltungsrahmen wer, wie und wem gegenüber,

die Verantwortung durch den Einsatz von AI übertragen wird, kann länderspezifisch sowie unternehmensweit variieren. In jedem Fall sollten sich Unternehmen mit den ethischen Fragestellungen auseinandersetzen und Spielregeln zur Anwendung von KI oder dem Umgang von Daten in Verhaltenskodizes verschriftlichen, damit die Maschinenintelligenz im Sinn des Menschen handelt.

6.3 Erweiterung um die fünfte Säule zur Beantwortung psychischer Fragestellungen

Dass die Entwicklung der KI zu der transformativsten Erfindung unserer Zeit gehört, steht außer Frage. Jedoch bilden sich durch den Einsatz intelligenter Maschinen auch gesellschaftliche Ängste. Auch wenn uns die Formen der KI schon heute Dinge im Alltag erleichtern, z. B. die Sprachübersetzung oder die Smart-Home-Nutzung, regt sie bei der Gesellschaft zum Nachdenken an. Schließlich stellt sich folgende Fragestellung: Wie verändert die Vierte Industrielle Revolution unsere Bevölkerung und das Leben jeder einzelnen Person?

Der Weg in ein neues Zeitalter fordert die Gesellschaft seit jeher heraus. Damals galt die Erfindung der Dampfmaschine als Bedrohung, heute werden wir mit neuen technologischen Entwicklungen konfrontiert. Einigen bietet der Wandel neue Möglichkeiten und Chancen, andere gelten als Verlierer und entwickeln existenzielle Ängste. Diese Ängste resultieren unter anderem aus den folgenden Themen und Fragen:

- **Maschinen als zukünftige Arbeitskräfte?**
Intelligente Algorithmen, wie z. B. neuronale Netze, werden als menschenähnlich bezeichnet, können unsere Fähigkeiten erlangen und sind uns in einigen Spezialdisziplinen bereits überlegen. Maschinen werden nicht nur autonomer, sondern entwickeln eine eigene Identität. Übernehmen die Maschinen zukünftig unsere Jobs, wie verändert sich unsere Arbeitswelt und welchen Wert hat der Mensch, wenn die Maschine alles übernehmen kann?
- **Künstliche Intelligenz als autonomer Entscheider?**
Bislang lag die finale Entscheidungsmacht beim Menschen, der für sein Handeln die Verantwortung übernehmen muss. Wenn die KI unsere Denkfähigkeit erlangen kann, könnte sie auch einen eigenen, freien Willen entwickeln und Entscheidungen für oder gegen uns treffen, mit der Gefahr des Kontrollverlusts der Menschen. Zumindest beim einfachen Navigationssystem ist dies schon der Fall.
- **Diskriminierung durch Algorithmen?**
In China wird aktuell das sogenannte Social-Scoring-System zur Bewertung des menschlichen Verhaltens getestet. Dafür werden politische, moralische und soziale Daten jedes einzelnen Bürgers gesammelt und in einem Bonitätssystem für die Bewertung der finanziellen sowie gesellschaftlichen Kreditwürdigkeit dargestellt. Die Datensammlung erfolgt sowohl durch Informationen aus der Videoüberwachung

als auch durch Ratings intelligenter Algorithmen, die auf diverse Metadatenbanken zurückgreifen. Algorithmen liefern also die Grundlage, um das menschliche Verhalten zu beurteilen, wodurch Diskriminierungen oder die Benachteiligungen von Personen ausgelöst werden.

Diese Fragen sind in ihrer Natur alle sehr kritisch und erzeugen bei der betroffenen Gesellschaft Angst, Verunsicherung oder teilweise auch Hoffnungslosigkeit. Insbesondere die Auswirkungen des Einsatzes von KI auf die Arbeitswelt wird intensiv, emotional und dementsprechend subjektiv diskutiert. Angesichts der Tatsache, dass das Einkommen aus der Arbeitsleistung für die überwiegende Mehrheit die Basis menschlicher Existenz darstellt, ist es naheliegend, dass die revolutionäre Nutzung von Maschinen als Risikofaktor für sämtliche Arbeitsplätze gilt und zu der Entwicklung von Aversionen, einer Angststörung oder im schlimmsten Fall einer psychischen Erkrankung führen kann.

Die Säule zur Beantwortung psychischer Fragestellungen soll den Menschen, seine persönlichen Ängste und emotionale Befangenheiten in den Vordergrund stellen. Hierbei geht es um die Verantwortung von Staaten und Unternehmen, ein Wertegerüst zu etablieren, das die Befürchtungen der Gesellschaft aufgreift und Prinzipien sowie Normen definiert, die für den Umgang mit KI notwendig sind.

7 Zusammenspiel CSR und Digital Governance – Welche Leitplanken für die Entwicklung und den Einsatz von künstlicher Intelligenz sollten vorgegeben werden?

Die gewonnenen Erkenntnisse zur Weiterentwicklung des existierenden CSR-Modells können nun angewandt werden, um die Chancen durch den Einsatz von KI hervorzuheben und potenzielle Risiken kritisch zu beleuchten.

Die Entwicklungen der KI und die Fähigkeit des maschinellen Lernens sind als digitale Technologien maßgeblich dafür verantwortlich, dass wir uns heute in der Vierten Industriellen Revolution befinden. Die Nutzung von KI prägt das Leben der Menschheit, fördert als weiterer Produktivitätsfaktor die zukünftige Weltwirtschaft und ermöglicht uns einen gesellschaftlichen sowie wirtschaftlichen Strukturwandel.

Der Einsatz der intelligenten Systeme scheint ohne Grenzen zu sein. Wir nutzen die KI in unserem Alltag, passen unsere Lernmethoden an, kommunizieren über neue Wege und verändern unser Konsumverhalten. Die wissenschaftlichen Fortschritte der letzten Jahre führten dazu, KI auch im Mobilitätssektor voranzutreiben.

Die Anwendungsgebiete von KI sind sehr vielfältig. Bestehende Prozesse werden durch intelligente Algorithmen optimiert und neue, vorher undenkbare Anwendungsfelder geschaffen. Überall dort, wo komplexe Muster zu erkennen sind, wird KI beispielsweise für die Spracherkennung, Bilderkennung oder Prognose von Kennzahlen eingesetzt.

Doch die Entwicklung dieser innovativen Technologien steht erst am Anfang. Mit Blick in die Zukunft könnten sich die Schlagzeilen des Morning Briefing Podcast über das wirtschaftliche Weltgeschehen dann so anhören:

- **Statistisches Bundesamt: Zahl der Verkehrstoten auf Rekordtiefstand**

Noch nie seit Beginn der Statistik gab es in Deutschland so wenige Verkehrstote. Wegen der gesetzlich vorgeschriebenen Nutzung von autonomen Fahrzeugen wird das Tempolimit nicht mehr überschritten und Abstandsregelungen werden eingehalten. Das zeigt beträchtlich positive Auswirkungen.

- **Beschluss des Fachkräftegipfels: Die Wirtschaft braucht mehr Data Scientists**

Aus der Not heraus werden nun phasenweise sämtliche Produktionsmitarbeiter in dringend benötigte Datenexperten umgeschult. Arbeitsminister Fleissig bekräftigt diese Maßnahme und fordert eine klare Strategie zur Neuausrichtung der Arbeitswelt.

Allerdings entstehen mit dem Übergang in das Zeitalter der intelligenten Technologien neue Risiken und Herausforderungen, die neue Ausprägungen einer Digital Governance benötigen. Die traditionelle CSR-Philosophie ist im KI-Umfeld nicht ausreichend.

Beispielsweise erfolgt die Interpretation bestimmter Sachverhalte oder das Treffen von Entscheidungen durch den Menschen aufgrund des gesammelten Erfahrungsschatzes der letzten Jahrzehnte. Wir können nicht jede ausgelöste Situation oder getroffene Entscheidung erklären. Die für uns als selbstverständlich erwiesenen Handlungen können nicht vollständig in Worte ausgedrückt werden: „We know more than we can tell“ (Polanyi 1966). Doch unser spezifiziertes Wissen, unsere Gedanken und Selbstverständlichkeiten sind die Basis für die selbstlernende KI.

Auch das nachfolgende Beispiel verdeutlicht, dass wir mit der Entwicklung der KI vor einer Veränderung stehen und deren positive wie negative Auswirkungen nachlesen können. Daher ist es umso wichtiger, gewisse Rahmenbedingungen festzulegen und Leitlinien aufzuerlegen, die vorgeben, wie und in welchem Umfang KI angewandt werden sollte. Selbstverständlich muss die KI als eine der größten Potenzialträger unserer Revolution wahrgenommen werden, gleichzeitig darf diese Technologie aber nicht zu systemischer Diskriminierung, also gesellschaftlichen Nachteilen oder Risiken, führen.

Praxisbeispiel Autonomes Fahrzeug: Uber-Volvo

Automobilhersteller entwickeln für die autonomen Fahrzeuge künstliche neuronale Netze für die Umgebungserkennung, die Signale an Assistenzsysteme weiterleiten.

Aber was ist ein neuronales Netz und wie wird es entwickelt? Neuronale Netze können mit der Vernetzung des menschlichen Gehirns verglichen werden. Dieses komplexe Netzwerk nimmt Informationen in Form von Datensätzen auf und verändert seine interne Konfiguration um ein optimales Lernfeedback, sei es von einem Menschen, aus einer Situation oder durch einen Trainingsdaten-

satz zu erhalten. Das Netz kann dabei aber nicht darüber reflektieren, WARUM, seine Reaktion eine bestimmte ist. Es kann keine Logik ableiten aus seinem Verhalten, oder gar dem Verhalten anderer Menschen oder neuronaler Netze. Es kann auch fast nichts aus einem einmaligen Fehler lernen - es benötigt viele Fehler, um lernen zu können, und gerade das ist etwas, dass wir in vielen Situationen des menschlichen Lebens aus moralisch-ethischen Gründen natürlich niemals zulassen können. Gerade deshalb wird immer stärker nach Sicherheiten in Form von Nachvollziehbarkeit bei neuronalen Netzen verlangt. Nicht zuletzt sind Verantwortlichkeit an die Fähigkeit der Erklärbarkeit und der Nachvollziehbarkeit von Gedankengängen und damit auch Handlungssträngen gekoppelt. Dazu fehlen aber trotz neuerer „Explainable-AI“ Ansätze noch die richtigen Modelle.

Im Jahr 2018 kam es zu einem tödlichen Unfall mit einem selbstfahrenden Uber-Fahrzeug. Die Ursache des tödlichen Unfalls liegt in der fehlerhaften Software. Der speziell von Uber für autonomes Fahren ausgerüstete Volvo XC90 erkannte die Fußgängerin nicht als Hindernis, sodass das Fahrzeug mit gleicher, unverminderter Geschwindigkeit weiterfuhr. Würde man die KI des Fahrzeugs fragen, warum sie einfach weitergefahren ist, würde sie nicht einmal die Frage verstehen, geschweige denn eine Antwort geben können oder gar Reue zeigen können. Und genau das sind Fähigkeiten, die wir beim Menschen als Verantwortlichkeit beschreiben. Allerdings, wenn die KI tatsächlich durch korrektes aber unerklärliches Verhalten 3000 Menschenleben rettet und 10 Menschenleben nimmt, wie sollen wir dann entscheiden?

Quelle: <https://www.auto-motor-und-sport.de/verkehr/toedlicher-unfall-autonom-auto-uber-softwarefehler/>

Inwiefern ist es Unternehmen nun möglich, fair nach den ethischen Erwartungen der Gesellschaft zu handeln, verantwortungsvoll Daten für KI-Modelle zu nutzen, gleichzeitig die Profitabilitätskennzahlen zu erreichen und von den Konsumenten als zukunftsweisende und fortschrittliche Unternehmung akzeptiert und positiv wahrgenommen zu werden?

7.1 Einführung: Digital Governance als CSR-Kompass für die Nutzung künstlicher Intelligenz

Während CSR von Unternehmen als gesellschaftliche Verantwortung auf freiwilliger Basis angesehen wird, dient die Digital Governance als Rahmenwerk zur Definition von Leitplanken. Dabei geht es keinesfalls darum, möglichst hohe und unflexible Schutzwälle zu errichten. Vielmehr sollen durch die Digital Governance praxisnahe Wegweiser für den Einsatz von KI vorgegeben werden, um Unternehmen in die digitale Zukunft zu leiten.




Abb. 4 Digital Governance als CSR-Kompass für künstliche Intelligenz

Das Rahmenwerk der Digital Governance umfasst dabei die folgenden vier Eckpfeiler, die die Grundgedanken der CSR widerspiegeln (Abb. 4):

Ethik Maschinen benötigen eine gewisse Moral und sollten ethischen Grundsätzen befolgen, damit sie keine negativen oder beispielsweise diskriminierenden Entscheidungen treffen. Wir beschäftigen uns mit der Frage, was KI können darf und welche Ethikrichtlinien für den Einsatz von künstlicher Intelligenz vorgegeben werden sollten.

Recht Wenn der Gesetzgeber Innovation folgt, kann das CSR-Modell die Position einer Vorregulierung einnehmen und Leitplanken für die Gesetzgebung definieren. Wir beschäftigen uns mit der Frage, wer, Mensch oder Maschine, für den vielleicht ungewollten Schaden verantwortlich ist und wie die Haftungsfrage im Fall einer Fehlentscheidung beantwortet wird.

Organisation Mit Blick in die Zukunft werden mehr Aufgaben durch Maschinen und Roboter durchgeführt. Insbesondere die humanoiden Roboter, also ein der menschlichen Gestalt nachempfundenenes, hochentwickeltes Maschinenwesen, sind für verschiedenste Aufgaben einsetzbar. Wir beschäftigen uns mit der Frage, warum sollte

KI in jedem Unternehmen angewandt werden und welche Gründe für den Einsatz von Robotern sprechen. Es geht hierbei auch um die Frage: Kann eine Maschine wirklich den Menschen ersetzen und wie verändern sich die Arbeitsaufgaben der Mitarbeiter durch den Einsatz von Robotern?

Aufklärung Wir nutzen schon jetzt, teilweise unbewusst, die KI und kommen mit den innovativen Technologien in Berührung. Die selbstlernenden Algorithmen erleichtern durch digitale Assistenten wie Amazon Echo oder durch Vernetzung von Haushaltsgeräten unseren Alltag. Wir beschäftigen uns mit der Frage, warum weiterhin Ängste in Zusammenhang mit KI entstehen und wieso Unternehmen die Rolle der Aufklärung einnehmen müssen.

Mit diesem Rahmenwerk sollen der KI-Wegweiser vorgegeben werden, um das Entscheidungsmaß einzugrenzen und gleichermaßen die Entwicklungen weiter voranzutreiben. Die vier Eckpfeiler sowie unsere abgeleiteten Handlungsempfehlungen werden in den nachfolgenden Abschnitten detailliert beschrieben.

Die Digital Governance leitet sich aus der unternehmensweiten Corporate Governance ab. Sie hat drei verschiedene Ausprägungen, deren Ausprägung sich je nach Blickwinkel unterscheiden und mit den Eckpfeilern des Governance Framework zusammenspielen.

Die **Master Data Governance** stellt Anforderungen an die Datenbasis und umfasst sämtliche Vorgaben zur sicheren Datenverarbeitung. Sie umfasst bereits etablierte Aspekte, unter anderem datenbezogene Qualitäts- und Prozessstandards, als elementare Voraussetzung für die Nutzung von intelligenten Technologien.

Die **AI Decision Governance** liefert Antworten auf die Frage, was AI entscheiden darf und wo der Mensch die Entscheidungsmacht behalten muss, um künftig eine ethisch und moralisch einwandfreie Nutzung von KI sicherstellen zu können.

Die **AI Transformation Governance** bildet das Rahmenwerk, das für den digitalen Transformationsprozess von Relevanz ist. Sie hat dabei sowohl das organisatorische Zusammenspiel zwischen Mensch und Maschine im Blick als auch die Frage, wie die gesellschaftlichen Aspekte im Zeitalter von KI berücksichtigt werden können.

7.2 Künstliche Intelligenz als ethische Herausforderung – Welche Anforderungen an das Design und die Entwicklung müssen gestellt werden?

Die KI ist für unser Leben ein besonderes relevantes Thema, da sie das Potenzial hat, nahezu alle gesellschaftlichen Aspekte grundlegend zu verändern. Aus einer heutigen Betrachtung kann eine Narrow Artificial Intelligence spezifische Teilaufgaben (z. B. Schach spielen) bereits sehr gut lösen. Das langfristige Ziel von Forschern und Entwicklern wird es jedoch sein, starke KI (general artificial intelligence) zu entwickeln, die dem Menschen in nahezu jeder kognitiven Aufgabe überlegen sein werden.

Diese langfristig zu erwartende Entwicklung wirft jedoch auch grundsätzliche ethische Fragen auf, die im Zuge der Entwicklung und des Designs einer KI zu treffen sind. Angefangen bei dem Aspekt der zu nutzenden Daten, über Herausforderungen im Rahmen der KI-Programmierung bis zur abschließenden Frage der Entscheidungsbefugnisse einer KI.

7.2.1 Künftige Anforderungen an die Master Data Governance

Beim Einsatz von KI spielt die Datenbasis eine ganz zentrale Rolle, daher werden die Anforderungen an die Master Data Governance künftig weiter steigen. Neben elementaren Aspekten, wie definierten Qualitäts-, Sicherheits-, Datenerfassungs- und Prozessstandards, die bereits heute im Big-Data-Umfeld Anwendung finden, müssen künftig Daten noch stärker inhaltlich hinterfragt werden. Diese Gesichtspunkte werden deshalb so wichtig, da die Datenbasis den Input darstellt, auf dessen Basis die KI Muster erkennen, Verknüpfungen herstellen und Entscheidungen optimieren kann. Im Umkehrschluss bedeutet dies aber auch, wenn Fehler bzw. strukturelle Anomalien in der Datenbasis enthalten sind, wird sich dies auch zumindest anfänglich im normalen Einsatz der KI bemerkbar machen. Die Aufgabe an regulierende Behörden und ethische Initiativen wird es sein, einen Standard zu definieren, der sicherstellt, dass von einer KI verwendete Daten frei von Diskriminierungen und Fehlern sind und dass zudem juristische Anforderungen erfüllt werden.

- **Frei von Diskriminierung**

Das bedeutet ganz konkret, dass die Gesellschaft vor dem Einsatz von KI zunächst vor einer ethischen und technischen Herausforderung stehen wird, die Inputdaten so vorzubereiten, dass diese diskriminierungsfrei sind. Wenn wir uns beispielsweise vorstellen, dass eine KI bei Gerichtsentscheidungen den Richter unterstützen soll, wird es von enormer Bedeutung sein, dass die Datenbasis keine Merkmale enthält, die auf das Geschlecht oder die Hautfarbe des Angeklagten schließen lässt. Sollte die historische Datenbasis zeigen, dass überdurchschnittlich viele Gerichtsurteile zuungunsten von Personen mit einem Ausprägungsmerkmal „ethnischer Hintergrund – afroamerikanisch“ gefällt wurden, könnte dies eine KI dazu veranlassen, dass ein Afroamerikaner grundsätzlich eine höhere Verurteilungswahrscheinlichkeit hat als Bürger anderer ethnischer Gruppen. Um diesen Bias aus der Datenbasis zu entfernen, reicht es jedoch nicht, das Merkmal „ethnischer Hintergrund“ aus der Datenbasis zu entfernen, es müssen zudem auch alle Merkmale entfernt werden, die darauf schließen lassen könnten. Dies könnte z. B. die Postleitzahl sein, wenn ein Stadtteil dafür bekannt ist, dass dort besonders viele Afroamerikaner leben. Diese Reduktion könnte aber dazu führen, dass eine KI dann so wenig Datendimensionen erhält, dass sie gar keine Aussage mehr machen kann. Hier kann aus heutiger Sicht die Lösung nur in kausalen Modellen liegen, die auf neuronalen Modellen aufbauen.

- Frei von Fehlern der Vergangenheit

Darüber hinaus ist auch die Richtigkeit der Daten von enormer Bedeutung, im dargestellten Einsatzgebiet einer Gerichtsentscheidung bedeutet dies, dass es wichtig ist, dass Fehlurteile aus der Vergangenheit konsequent aus dem Inputdatensatz entfernt werden, damit vergangene Fehlentscheidungen nicht in die Zukunft fortgeführt werden. Denn nur dann kann eine KI eine tatsächliche Unterstützung sein, da die KI somit auch tatsächlich wertneutral auftritt. Dies kann im Idealfall sogar dazu führen, dass die KI ein besserer Richter als der Mensch ist.

- Rechtlich einwandfrei

Eine weitere Anforderung an die Datenbasis ergibt sich aus den rechtlichen Vorgaben: Unternehmen müssen zwingend sicherstellen, dass die verwendeten Daten auch im Einklang mit der gültigen Gesetzgebung sind, wie beispielsweise der Datenschutz-Grundverordnung (DSGVO). Da die DSGVO ein besonderes Augenmerk auf die Verarbeitung von personenbezogenen Daten legt, können sich hier unter Umständen auch Synergien mit der ersten Säule (Frei von Diskriminierung) ergeben. Darüber hinaus wird es auch wichtig sein, dass Unternehmen auch länderspezifische Datenschutzanforderungen erfüllen, um Rechtsrisiken ausschließen zu können.

Zusammenfassend bedeutet dies, dass eine wirksame Master Data Governance zwingend diese drei Säulen enthalten muss, damit der Einsatz von KI sowohl rechtlich als auch moralisch auf einer soliden Grundlage steht. Diese Aspekte sind wichtig, damit Fairness und Sicherheit gewährleistet sind. Darüber hinaus sollten aber auch weitere Standards (Qualitäts-, Sicherheits-, Datenerfassungs-, Prozessstandards) Anwendung finden.

7.2.2 Kann künstliche Intelligenz durch Programmierung kontrolliert werden?

Es ist jedoch auch wichtig, neben den initialen Input-Daten auch die neuen Daten zu validieren, mithilfe derer eine KI permanent optimiert und trainiert wird. Die besondere Bedeutung dieser Daten wird besonders schnell klar, wenn wir uns anhand der prominenten Beispiele wie Facebooks KI-Bots „Bob“ und „Alice“ (Nagels 2017) oder Microsofts „Tay“ (Vincent 2016) vergegenwärtigen, wie schnell eine KI in kürzester Zeit ein Eigenleben entwickeln kann, das so nie von den Entwicklern vorgesehen, geschweige denn vorhersehbar war. Im Fall von Facebook haben zwei Bots nach kurzer Zeit eine eigene Geheimsprache entwickelt. Im Fall von Microsofts „Tay“ hatte die KI zunächst die Aufgabe, Tweets zu schreiben, um mit den Menschen auf lockere Art und Weise ins Gespräch zu kommen. Jedoch hat sich „Tay“ innerhalb von weniger als 24 h in einen rassistischen und diskriminierenden Twitter-Nutzer verwandelt, der menschenverachtende Kurznachrichten veröffentlichte. Ein Grund hierfür war, dass „Tay“ im Rahmen der ersten Interaktionen besonders stark von politisch rechts orientierten Nutzern unter Beschuss genommen wurde und somit die Verhaltens- und Ausdrucksweise dieses Personenkreises trainierte. Ganz wie der Mensch auch, passt sich die KI ihrer Umgebung unweigerlich an.

Sowohl im Fall von Facebook als auch bei Microsoft war die Konsequenz, dass die KIs nach sehr kurzer Zeit abgeschaltet wurden.

Wenn wir diese Entwicklungen in größeren und komplexeren Szenarien durchdenken, stellen wir schnell fest, dass die Asimovschen Robotergesetze keine Anwendung mehr finden. So erkennt man bereits in diesem Fallbeispiel, dass zumindest im psychischen Sinn das erste Gesetz – Roboter darf keinem Menschen Schaden zufügen – verletzt wird. Wenn wir jedoch nun beispielsweise an den Einsatz von KI im militärischen Kontext denken, könnten die Konsequenzen denkbar ungünstig für die Menschheit sein, wenn diese jahrzehntealte Gesetzmäßigkeit nicht mehr erfüllt ist.

Ebenso ist es denkbar, dass eine starke KI auch nicht mehr der zweiten Gesetzmäßigkeit – Roboter muss menschlichen Befehlen gehorchen – folgt, da sie wie beispielsweise im Fall von Facebooks „Bob“ und „Alice“ eine bessere und effizientere Lösung für ein Problem entwickelt. Es kann also auch passieren, dass sich die KI gegen den Menschen wendet, wenn das aus welchen Gründen auch immer als effizient betrachtet wird. Den einzigen Befehl, den der Mensch in einer solchen Situation durchführen kann, ist die Abschaltung des Systems.

Obwohl die dargestellten Beispiele und Szenarien negative Folgen aufzeigen, verdeutlichen sie dennoch sehr klar, dass eine KI weitaus mehr als nur ein simpler Algorithmus ist, der eine mehr oder weniger wiederholende Prozedur durchführt. Eine KI verfügt über deutlich mehr Freiheitsgrade und entwickelt sich über den Zeitablauf in einem raschen Tempo weiter. Der gewonnene Vorteil der Freiheit und der gesteigerten Produktivität, geht allerdings auch gleichzeitig mit dem Verlust von Kontrolle einher. Denn in eine KI können keine allgemein gültigen Grenzen programmiert werden, es können lediglich explizite Verbote definiert werden. Am Beispiel von Microsoft hätte dies möglicherweise ein Verbot der Nutzung bestimmter Wörter sein können. Jedoch hätte sich dies möglicherweise dann in der Funktionalität niedergeschlagen, sodass die KI beispielsweise nicht in der Lage gewesen wären, bestimmte Tweets zu rezitieren, bzw. hätte die KI diese Einschränkung auch für sämtliche Sprachen der Welt erhalten müssen. Zudem ist auch unklar, wie sich das Szenario mit einer solchen Einschränkung möglicherweise weiterentwickelt hätte.

Es wird also klar, dass selbst bei einer „narrow“ KI die zu programmierenden Limitationen enorm wären, insbesondere wenn gleichzeitig die Funktionalität auch noch aufrecht erhalten bleiben soll. Man stelle sich nun vor, welche enormen Herausforderungen bei der Etablierung einer „general“ KI entstehen würden, wenn beispielsweise das Strafgesetzbuch in eine maschinenlesbare Form gebracht werden müsste und darüber hinaus auch noch ethische und moralische Anforderungen der Gesellschaft zu berücksichtigen wären – der Aufwand würde ins Unermessliche steigen und ist somit faktisch nicht erreichbar.




Abb. 5 Beispielhafte Klassifizierung von Entscheidungen entlang einer Risikomatrix (in Anlehnung an [Zweig 2019](#))




Abb. 6 Risikoklassen, auf deren Basis gesellschaftlich relevante Künstliche-Intelligenz-Entscheidungen eingruppiert werden können (in Anlehnung an [Zweig 2019](#))

7.2.3 Artificial Intelligence Decision Governance – Kontrolle statt Limitierung

Es wäre allerdings auch unsinnig für ein Unternehmen KI nicht einzusetzen, nur weil negative Konsequenzen entstehen können. Stattdessen muss eine AI Decision Governance die Frage, wie das Design des finalen Entscheidungsprozesses mit einer KI aufgebaut sein sollte, beantworten.

Hier scheint der Ansatz von Katharina Zweig (Zweig 2019) in Bezug auf algorithmische Entscheidungssysteme (ADM) ein guter Ausgangspunkt zu sein. Dieser Ansatz hat nicht notwendigerweise das Ziel, mittels Programmierung der KI Verbote aufzuzeigen. Die Idee hierbei ist, dass die Bedürfnisse der Menschen im Vordergrund stehen. Entscheidungen sollten entlang einer Risikomatrix klassifiziert werden, in welcher Höhe sie einen Schaden herbeiführen können und ob bei einer Fehlentscheidung das betroffene Individuum einen Anbieterwechsel durchführen kann bzw. eine weitere Chance erhält.

Je nachdem, wie gravierend die Entscheidung ausfallen kann, sollte dann wiederum die letzte Entscheidungsgewalt bei der KI oder beim Menschen liegen (Abb. 5 und 6).

Die Grafiken verdeutlichen klar, dass bei unproblematischen Entscheidungen die Entscheidungsgewalt vollständig bei der KI liegen kann, eine regelmäßige Analyse der Resultate jedoch dennoch durchgeführt werden sollte. Wenn aber schwerwiegende Entscheidungen mit massivem Schadenspotenzial getroffen werden, wie beispielsweise der Abschuss eines potenziellen Terroristen, ist es nötig, dass die letzte Entscheidung beim Menschen verbleibt. Hier muss es weiterhin im Interesse der Menschheit sein, dass eine KI nicht anstelle eines Menschen agiert. Auch wenn es denkbar ist, dass der Mensch diese Entscheidung in einigen Jahren abgeben könnte, muss auch klar sein, dass dadurch ein ganz zentraler Baustein unseres Wertesystems sich in einer Form verschieben würde, die sich nicht mit unserem heutigen Moralverständnis vereinbaren lässt.

Dennoch darf man nicht die Augen vor der Realität verschließen und erwarten, dass es deswegen keine KI-Entwicklung in bestimmten Sektoren, wie beispielsweise dem Rüstungssektor, geben wird. Hier wird es wichtig sein, dass eine KI lediglich unterstützend wirkt, indem sie eine Entscheidungsvorbereitung durchführt, sodass der Mensch nur noch zwischen Ja oder Nein entscheiden muss.

Der sich daraus ergebende Vorteil für Wirtschaft und Gesellschaft wird dadurch recht klar, indem die Vorteile der KI genutzt werden können, ohne dabei gänzlich die Kontrolle zu verlieren. Des Weiteren kann die Qualität der Entscheidungen auch durch das menschliche Feedback verbessert werden, da die KI lernt, welche Entscheidungen angenommen wurden und welche zu einer Ablehnung führen.

Gleichwohl ist auch klar, dass dieser Ansatz zur Entscheidungskontrolle im Kontext einer „narrow“ KI noch vergleichsweise einfach umsetzbar ist, da sich die KI nur auf einen bestimmten Output fokussiert. Bei einer „general“ KI sind die Anforderungen ungleich höher; hier kann ein CSR-Framework möglicherweise als ethischer Kompass herangezogen werden, um die Entscheidungsfreiheiten der KI klassifizieren zu können.

Zusammenfassend lässt sich sagen, dass eine AI Decision Governance folgende Aspekte immer im Blick haben muss:

- Der Einsatz von KI im Rahmen verschiedenster Entscheidungsprozesse ist wünschenswert, jedoch darf eine KI keine Stellvertreterrollen bei schwerwiegenden Entscheidungen einnehmen, sie darf nur beratend aktiv werden.

- In Abhängigkeit der Entscheidungsbedeutung muss eine KI mal mehr, mal weniger stark vor der finalen Entscheidungsumsetzung kontrolliert werden.
- Die technologischen Möglichkeiten von KI müssen vollkommen ausgeschöpft werden, jedoch darf darunter unser bestehender Wertekompass nicht leiden.

7.3 Künstliche Intelligenz im juristischen Kontext – Welche relevanten Fragestellungen müssen beleuchtet werden?

7.3.1 Wer trägt die ultimative Verantwortung

Neben den ethischen Herausforderungen muss beim Einsatz von KI auch immer die juristische Sichtweise bedacht werden, denn in der Konsequenz nimmt die KI dem Menschen Entscheidungen ab. Dieser Schritt führt unweigerlich auch zur Frage, wer ultimativ in der Verantwortung für getätigte Entscheidungen steht, im positiven wie im negativen Sinn.

Grundsätzlich könnte die Frage nach der Verantwortung auf unterschiedliche Art und Weise beantwortet werden. So könnte man zunächst sagen, dass der jeweilige Entwickler hinter der KI bei Fehlentscheidungen zur Rechenschaft gezogen werden muss, denn dieser hat das Programm erschaffen und hätte von allen Beteiligten am ehesten vorhersehen können, zu welchen Taten die KI in der Lage ist. Da jedoch insbesondere starke KI häufig in Gruppen entwickelt werden, stößt man hier bereits schnell an die Grenzen der Nachvollziehbarkeit. Da der Auslöser für eine bestimmte Handlung zudem auch noch durch die Verknüpfung mehrerer Programmierungsmodule zustande kommt, ist eine tatsächliche Nachvollziehbarkeit der verantwortlichen Person ein Ding der Unmöglichkeit.

Das Rechtssystem sieht bekanntermaßen vor, dass Eigentum verpflichtet, daher erscheint es also logisch, den jeweiligen Eigentümer der KI in die Pflicht zu nehmen, also eine juristische oder natürliche Person. Jedoch stößt man auch bei diesem Ansatz schnell an gewisse Grenzen, denn auch hier stellt sich die Frage, ob es angemessen wäre, jemanden für eine nicht beabsichtigte Handlung zu verurteilen, die sich aus der Nutzung der Technologie ergeben hat. Denn ein KFZ-Eigentümer wird typischerweise auch nicht nach einem Unfall verurteilt, wenn er diesen nicht fahrlässig oder nicht beabsichtigt verursacht hat. Ganz ähnlich könnte also auch gegebenenfalls die künftige Rechtsprechung zu Haftungsfragen aussehen, wenn eine KI beteiligt war. Somit erscheint es also auch nicht praktikabel, den Eigentümer der KI in die Haftung zu nehmen, wenn dieser keine grob fahrlässigen Fehler zu verantworten hat.

Wenn also weder der Entwickler noch der Eigentümer zur Rechenschaft gezogen werden kann, steht die Gesellschaft vor dem Problem eines Straffreihheitsvakuum. Also muss die Konsequenz sein, dass die KI die Verantwortung für getroffene Entscheidungen trägt. Der Gedanke erscheint zunächst absurd, bei genauerer Betrachtung der Umstände und einem weiten Blick in die Zukunft ergibt er jedoch Sinn.

Zunächst ist es vollkommen klar, dass es in unserem heutigen Rechtssystem unvorstellbar ist, ein Computersystem zu verurteilen, denn eine KI ist zunächst nicht

sanktionsfähig. Vor dem Hintergrund der rasanten Entwicklung von KI ist es jedoch zu überlegen, welche juristischen Rahmenbedingung geschaffen werden müssen, damit eine KI adäquat in unserem Rechtssystem abgebildet werden kann. Die folgerichtige Konsequenz muss also sein, dass in unserem Rechtssystem eine elektronischen Persönlichkeit analog einer juristischen Persönlichkeit geschaffen wird, damit die Verantwortung für getroffene Entscheidungen auch beim Verursacher verortet werden kann und damit das eingangs erwähnte Straffreiheitsvakuum möglichst verhindert wird.

Praxisbeispiel: DABUS AI

Das Unternehmen Imagination Engines hat eine KI entwickelt, die in der Lage ist, nur auf Basis eines Dateninputs eigenständig neue, patentfähige Erfindungen zu erschaffen.

Als Imagination Engines zwei von Device for the Autonomous Bootstrapping of Unified Sentience (DABUS) erschaffene Erfindungen (Warnleuchte und Lebensmittelbehälter) patentieren lassen wollte, wurde dies vom Patentamt zurückgewiesen. Die Erfindung selbst war tatsächlich neu und somit auch patentierbar. Der Grund für die Zurückweisung war jedoch die Argumentation der Behörde, dass ein Patent nur von einer natürlichen Person angemeldet werden kann. Auf der anderen Seite konnte Imagination Engines darstellen, dass es dem Unternehmen an Erfahrung im Bau von Lichtern und Lebensmittelbehältern mangelt, man habe lediglich Inputdaten einer Software zur Verfügung gestellt. Die Erfindung ist bis heute nicht patentiert, da es unmöglich ist, einen menschlichen Entwickler zu nennen. Allerdings verdeutlicht das Beispiel, dass eine starke KI in der Lage sein kann, etwas Neues zu erschaffen und dass somit auch die Verwertungsrechte der KI zustehen sollten. Hierfür wäre es aber notwendig, dass man der KI auch einen ähnlichen rechtlichen Status einräumt, wie man es bei einer juristischen Person macht.

Quelle: https://imagination-engines.com/iei_dabus.php;

<https://www.handelsblatt.com/technik/digitale-revolution/ada-das-recht-des-roboters/25583740.html?ticket=ST-3290894-XnceVVFPSGIHyoBwN3tS-ap5>

7.3.2 Einführung einer elektronischen Persönlichkeit als Chance

Der Bedarf zur Einführung einer neuen Rechtspersönlichkeit, der elektronischen Persönlichkeit, besteht darin, dass, wie im aufgezeigten Fallbeispiel der DABUS, KI-Systeme und Roboter mittlerweile in der Lage sind, Tätigkeiten auszuüben, die bis vor wenigen Jahren dem Menschen vorbehalten waren. Hierzu zählt z. B. die Fähigkeit zu lernen, autonome Entscheidungen zu treffen und mit der Umwelt zu agieren (Europäisches Parlament 2017).

Auch wenn die EU-Vorstöße zur Einführung einer elektronischen Persönlichkeit derzeit noch viele Kritiker aufschreiben lässt, erscheint die Einführung letztlich nur folgerichtig und konsequent, wenn das Thema KI zu Ende gedacht wird. Es mag durchaus

sein, dass zum heutigen Tage eine solche Gesetzgebung etwas befremdlich und weit hergeholt wirkt, jedoch wird sie in einigen Jahren notwendig sein, um einen rechtssicheren Rahmen beim Einsatz von KI zu schaffen. Zu diesem Schluss kommt man letztlich, wenn man sich vom heutigen Entwicklungsstand von schwachen KI löst, sich vergegenwärtigt, welche Handlungsmöglichkeiten eine „general“ KI in einigen Jahrzehnten haben kann, und gleichzeitig bei der Entwicklung einer elektronischen Persönlichkeit auch die Parallele zur juristischen Person zieht.

Denn ähnlich wie eine juristische Person müsste man künftig eine elektronische Persönlichkeit mit Rechten und Pflichten ausstatten, damit diese eine entsprechende Rechtsfähigkeit erlangt. Der Schritt ist deshalb notwendig, weil eine KI bereits heute in der Lage ist, innerhalb eines eng definierten Rahmens Entscheidungen zu tätigen. Das heißt, die KI kann faktisch mehr als eine juristische Person, denn diese wird immer nur von Menschen vertreten, während die KI autark handelt. Gleichwohl ist aber auch zu beachten, dass ähnlich wie bei einer juristischen Person auch die elektronische Person immer einen Eigentümer haben muss, entweder eine natürliche oder eine juristische Person.

Zumindest im Kontext einer „general“ KI kann man auch davon ausgehen, dass diese auch urteilsfähig ist, da sie in der Lage ist, gesamtheitliche und komplexe Zusammenhänge zu durchdringen und aller Wahrscheinlichkeit nach dies sogar besser macht als eine natürliche Person. Sie kann also abwägen, welche Konsequenzen eine Handlung nach sich zieht. Hier liegt es letztlich am Menschen, den Rahmen so zu setzen, dass die Urteilsfähigkeit der KI mit unserem Wertesystem im Einklang steht.

Damit die KI und damit die verbundene elektronische Persönlichkeit auch stets im Interesse des Menschen handelt, wird es auch wichtig sein, die Rechte und Pflichten genauestens zu definieren. So wird es auf der einen Seite wichtig sein, dass sie künftig handlungsfähig ist, jedoch müssen gegebenenfalls auch bestimmte Pflichten erfüllt werden, wie beispielsweise die Einhaltung der vorhandenen Gesetze. Wie bereits an anderer Stelle beschrieben, ist eine solche Limitierung sicherlich nicht einfach umzusetzen. Daher wird man möglicherweise an einigen Stellen die Rechte der elektronischen Persönlichkeit einschränken müssen, dass nicht alle Handlungen von ihr durchgeführt werden dürfen. Diesen Umstand könnte man mit der beschränkten Geschäftsfähigkeit von Kindern und Jugendlichen vergleichen.

Die wohl spannendste Fragestellung einer elektronischen Persönlichkeit wird es wohl sein, zu klären, wie diese zur Verantwortung gezogen werden kann. Ein praktikabler Ansatz könnte sein, dass eine elektronische Persönlichkeit mit einem bestimmten Kapital ausgestattet werden muss, ähnlich wie es auch bei Kapitalgesellschaften ein Mindeststammkapital gibt. Da die potenzielle Schadenshöhe jedoch beim Einsatz von KI unter Umständen sehr hoch sein kann, könnte man die elektronische Persönlichkeit auch stattdessen mit einer verpflichtenden Versicherungspolice oder einem Haftungsfonds ausstatten, worauf im Schadensfall zurückgegriffen werden kann. Auch hier lässt sich eine Parallele zu multinationalen Konzernen ziehen, denn auch hier wird typischerweise von der juristischen Person eine Police (Directors-and-Officers-Vermögenshaftpflichtversch

erung) für leitende Angestellte abgeschlossen. Darüber hinaus könnte die elektronische Persönlichkeit selbst Finanzmittel generieren, wenn sie beispielsweise selbst Verwertungsrechte aus einem Patent besitzt, wie es wohl beim Beispiel der DABUS-KI der Fall wäre, wenn diese KI eine Rechtspersönlichkeit hätte. Schlussendlich gäbe es noch eine weitere Sanktionsmöglichkeit, die wohl am ehesten mit der Todesstrafe zu vergleichen ist. Ein Gericht könnte theoretisch die Abschaltung einer KI anordnen, um künftigen Schaden abzuwenden.

Als letzter Aspekt ist die Frage der Besteuerung zu betrachten. Grundsätzlich könnte man hier das Argument anführen, dass KI entsprechend besteuert werden sollten, wenn sie eine ähnliche oder sogar höhere Arbeitsleistung als der Mensch erbringen. Allerdings muss man beachten, dass eine KI einen Teil des gesellschaftlichen Kapitalstocks ausmacht, sodass die Besteuerung letztlich eine Kapitalertragsbesteuerung darstellt. Aus den Erkenntnissen der Publikationen zur Optimalsteuertheorie ist bekannt, dass Kapitalerträge möglichst gering besteuert werden sollten (Julian 2019), da dies die Innovations- und Produktivitätsentwicklung beeinträchtigen könnte. Darüber hinaus würde eine solche Steuer einen negativen Effekt auf die Digitalisierung der Wirtschaft haben.

Abschließend lässt sich feststellen, dass es insbesondere vor dem Hintergrund starker „general“ KI sinnvoll ist, eine neue Rechtspersönlichkeit, die elektronische Persönlichkeit, einzuführen. Ein kurzer Überblick legt die Vorteile dar:

- Je nach Betrachtungswinkel lässt sich eine gewisse Nähe zur juristischen Persönlichkeit und mal zur natürlichen Persönlichkeit finden, diese hybride Rolle sollte daher separat geregelt werden.
- Eine Neuordnung kann die Chance schaffen, die Thematik sinnvoll und maßvoll zu regeln, statt den Versuch zu unternehmen, eine hochkomplexe Infrastruktur in einem ähnlich komplexen Rechtssystem notgedrungen unterzubringen.
- Die Einführung der elektronischen Persönlichkeit verhindert ein Straffreiheitsvakuum und stellt sicher, dass Haftungsfragen besser geregelt werden können. Im Sinn eines verantwortungsbewussten Gesellschaftssystems ist es zwingend notwendig, dass hier Klarheit herrscht.
- So wichtig eine CSR-Guideline bei ethischen Fragen ist, so unbedeutend ist sie im juristischen Kontext, da hier letztlich eine gewisse Verlässlichkeit, insbesondere bei Haftungsfragen, notwendig ist. Eine CSR-Guideline kann jedoch zumindest den ethisch-moralischen Kompass im Rahmen einer Übergangsphase bieten.

7.4 Künstliche Intelligenz in der Organisation – Welche Leitplanken müssen zur Neuausrichtung der Arbeitswelt gesetzt werden?

Der Einsatz von KI ist sehr vielfältig, sie beeinflusst und verändert einige unserer Lebensbereiche, doch die Auswirkungen auf das Arbeitsumfeld zählen zu den am meist

diskutierten und befürchteten Themen. Dabei geht es häufig nicht um die Veränderung von Qualität oder Quantität der Produkte, sondern vielmehr um die Verschiebung der Entscheidungsmacht vom Menschen auf die Maschine. Angesichts der großen Automatisierungspotenziale und der zukünftigen Entwicklung, dass intelligente Maschinen unsere didaktischen sowie methodischen Fähigkeiten erlangen, liegt die Fragestellung nahe, ob die Maschine wirklich den Menschen ersetzen und all seine Arbeitsaufgaben ausführen kann.

Die Gegenwart zeigt, dass wir uns im Alltag wie selbstverständlich von der Technik helfen lassen. Auch in der Berufswelt werden schon heute Aufgaben durch intelligente Maschinen oder Roboter ausgeführt. Mithilfe der KI werden beispielsweise automatisch die kennzahlenbasierten Trendprognosen mit tagesaktuellen Daten aufbereitet, was eine effektivere und effizientere Unternehmenssteuerung ermöglicht. Dabei kann KI sowohl in der Finanzbranche zur Datenanalyse als auch im Automobilsektor zur Qualitätsverbesserung und Zeitersparnis oder in der Gesundheitsindustrie zur Früherkennung von Krankheiten eingesetzt werden.

In jedem Fall scheint die Nutzung der Maschinenintelligenz in der Weltwirtschaft schon in wenigen Jahren nicht mehr wegzudenken. Damit nicht im schlechtesten Fall Millionen von Menschen ihre Arbeitsplätze verlieren oder die KI die volle Entscheidungsmacht übernimmt und Tätigkeiten ausführt, die aus ethischer Sicht bedenklich sind, müssen rechtzeitig Leitplanken aufgestellt werden. Diese Leitplanken werden durch die Digital Governance im Einklang mit den Säulen der CSR-Philosophie vorgegeben, um das volle Potenzial der KI auszuschöpfen, ohne einhergehende Nachteile befürchten zu müssen.

Im Folgenden wird aufgezeigt, welche Tätigkeiten potenziell von Maschinen übernommen werden können und wie die Rollenverteilung zwischen Mensch und Maschine erfolgt. Daran schließt sich die Beantwortung der Frage an, welche Leitplanken zukünftig im Arbeitsumfeld notwendig sind.

KI ist eine Technologieanwendung, die menschenähnliche, intelligente Verhaltensweisen zeigt. Die KI-Systeme werden mit bestehenden Datensätzen trainiert, erkennen in Lernprozessen die Zusammenhänge, um darauf aufbauend Vorhersagen zu treffen oder Ereignisse auszulösen. Damit bietet der Einsatz von KI den Unternehmen unter anderem folgende Vorteile:

- KI kann jederzeit kontinuierlich und ohne Pause eingesetzt werden.
- Algorithmen entscheiden objektiver als Menschen, die eine stark subjektive Wahrnehmung haben und teilweise unbewusst diskriminierend oder vorurteilsbehaftet entscheiden.
- Die Programmierung der KI kann für repetitive Aufgaben angepasst werden, um die Ausführung zu optimieren oder individuelle Anforderungen einzubauen – der Mensch kann nicht einfach „umprogrammiert“ werden.
- Der Einsatz von Maschinenintelligenz ist nicht nur deutlich effizienter, sondern schafft auch neue Chancen, identifiziert neue Entwicklungsfelder und entdeckt gleichermaßen Handlungsfelder sowie potenzielle Risiken im Unternehmensfeld.




Abb. 7 Nutzung von künstlicher Intelligenz auf allen Unternehmensebenen

Jedoch erfordert der Einsatz von KI immer eine menschliche Anleitung. Algorithmen können ausschließlich Tätigkeiten ausüben, die der vordefinierten Programmierung entsprechen und sind für unerwartete Situationen nutzlos. Für die Entscheidungsfindung fehlen ihnen sowohl die Fähigkeit des lateralen Denkens (umgangssprachlich auch Querdenken genannt) als auch Empathie, Gewissen und ein Sinn für Emotionen. Auch wenn die KI im Arbeitsumfeld nicht mehr verleugnet werden kann, gilt der Mensch in einigen Aufgabenbereichen als weitaus effizienter (Abb. 7).

Die Pyramide verdeutlicht, dass KI über alle Unternehmensebenen hinweg angewandt werden kann, jedoch variiert der prozentuale Anteil der Nutzung. Während sich der Algorithmus einer KI für Routineaufgaben auf der sogenannten Feldebene, die einer strikten Regel folgen oder nach einem festen Muster ausgeführt werden, sehr leicht programmieren lässt, dienen sie auf Ebene der Unternehmensführung als Assistenzwerkzeug. Strategische Entscheidungen, für die keine Ja-oder-Nein- oder Richtig-oder-Falsch-Antworten vorhersehbar sind, können nicht durch intelligente Maschinen getroffen werden. Auf der oberen Managementebene sind der menschliche Kontakt, die individuelle Expertise und situationsgerechte Flexibilität sehr wichtig, jedoch von der KI nur deutlich schwer oder unmöglich zu erfassen. Die KI wird zukünftig auch kognitive oder Nichtroutineaufgaben übernehmen, doch die endgültige Entscheidungsmacht und die daraus resultierende Verantwortung liegen beim Menschen.

Praxisbeispiel: Nutzung von künstlicher Intelligenz in der Vermögensverwaltung

Der Investmentprozess von der Anlageauswahl bis zur Entscheidungsfindung ist geprägt von Emotionen. Die Kurse sinken, der Mensch reagiert panisch und verfällt schließlich in den Verkauf seiner Anteile. Während Anleger häufig aus Angst oder Gier vorschnell und unüberlegt handeln, spüren Algorithmen

keine Emotionen, sondern führen ihre Aktionen ausschließlich auf Basis der programmierten Szenarien oder gelernten Datenmuster aus. Aktuell können KI-Lösungen auch für die Effizienzsteigerung der Geschäftsprozesse eingesetzt werden.

Die Estably Vermögensverwaltung AG erkannte KI als vielversprechende Innovation, wohlwissend, dass die Überwachung und finale Entscheidungsmacht beim Menschen liegen sollte. Daher nutzt Estably die Technologie für die digitale „Depoteröffnung, Ein- und Auszahlungen und Performanceüberwachung“, um „die Investment-Erfahrung unserer Kunden so angenehm wie möglich zu gestalten“. Für das Value Investing hat die KI jedoch noch nicht die ausreichende Denkfähigkeit des Menschen erlangen können. Hier zählen langjährige Erfahrungswerte einzelner Mitarbeiter, deren Expertise heutzutage nicht technologisch abbildbar sind – in Zukunft aber vielleicht schon.

Quelle: <https://estably.com/kuenstliche-intelligenz-in-der-vermoegensverwaltung-darauf-habe-ich-leider-keine-antwort-alexa/>

In Zukunft werden mehr Aufgaben von Maschinen oder Robotern übernommen. Jedoch führt der Algorithmus die Tätigkeiten aus, die ihm vom Menschen vorprogrammiert und durch Daten antrainiert wurden. Es stellt sich die Frage, ob die KI eben doch nur so intelligent ist wie der Mensch, der sie programmiert.

Die AI Transformation Governance muss Leitlinien vorgeben, die das Zusammenspiel zwischen Mensch und Maschine in der Arbeitswelt definieren und so eine verantwortungsvolle Steuerung einer vertrauenswürdigen KI sicherstellen. Nachfolgend sind drei Grundsätze skizziert, die im Einklang mit den CSR-Aktivitäten von Staaten und Unternehmen befolgt werden sollten:

- Die KI führt die vorprogrammierten Dinge aus. Der Mensch entscheidet über die Programmierfunktion, also welche Entscheidungen oder Tätigkeiten durch die Maschine oder die Arbeitskraft umgesetzt werden. Es muss daher sichergestellt werden, dass die KI nach angemessenen Kriterien der Ethik und Verantwortlichkeit konzipiert und das Ziel einer fairen und gerechten Gesellschaft verfolgt wird.
- Die Maschine konkurriert nicht mit dem Menschen. Vielmehr sollten Mensch und Maschine komplementär eingesetzt werden, um die Arbeitsleistung effizienter und kreativer zu gestalten. Für diese Interaktion muss sichergestellt werden, dass der Gesellschaft ausreichend Weiterbildungsmaßnahmen geboten werden und schließlich der Mitarbeiter über die erforderlichen Kompetenzen verfügt.
- KI-Systeme sind in der Lage, große Datenmengen innerhalb kurzer Zeit zu analysieren, ein Muster zu erkennen, nach bestimmten Parametern relevante Informationen zu filtern und schlussendlich grafisch darzustellen. Sie liefern damit die ideale Grundlage für beispielsweise Management-Reporting und strategische

Entscheidungsfindung. Jedoch muss sichergestellt werden, dass einerseits die dafür genutzten Datenquellen nachvollziehbar und transparent sind und andererseits der Mensch die technologiebasierten Ergebnisse versteht, um eine fundierte Entscheidung gewährleisten zu können.

7.5 Aufklärung über künstliche Intelligenz – Wie gelingt gesellschaftliche Akzeptanz und Vertrauen?

7.5.1 Wie kann der Gesellschaft die Angst genommen werden

Der Einsatz von KI auf breiter Basis wird für einen enormen Umbruch in der Gesellschaft sorgen. Wie bei vielen Neuerungen wird es auch in diesem Einsatzgebiet zunächst viele Skeptiker geben, die der Technologie kritisch oder sogar ängstlich gegenüberstehen. Es wird also unerlässlich sein, dass sich der Staat sowie Unternehmen dieser Ängste annehmen, um den Sorgen und Bedürfnissen der Gesellschaft gerecht zu werden. Die Tatsache, dass Menschen Angst verspüren, ist grundsätzlich positiv, denn die Funktion der Angst besteht darin, das Leben zu erhalten. Somit ist Angst zunächst nichts anderes als ein Alarmsystem, das den Menschen auch in der Vergangenheit das Leben gesichert hat. Jedoch ist es gerade im Kontext der KI wichtig, dass der Gesellschaft die Angst genommen wird, denn die Entwicklung hin zu immer weiter ausgereiften und menschenähnlicheren Systemen wird weiter unaufhaltbar fortschreiten.

Die AI Transformation Governance gibt zwei Strategieansätze vor, um den Menschen die Angst zu nehmen und Vertrauen in die KI zu schaffen:

1. Konfrontation und Transparenz:

Von anderen menschlichen Sorgen der Menschen ist bekannt, dass je öfter sie eine bestimmte Situation bzw. Konfrontation vermeiden, desto bedrohlicher wirkt die Angst mit der Zeit. Daher wird es wichtig sein, dass sich Menschen mit KI auseinandersetzen. Da es sich hierbei um eine gesellschaftliche Aufgabe handelt, die nicht von heute auf morgen umgesetzt werden kann, wird es wichtig sein, dass sich die betroffenen von morgen auch bereits im Schulunterricht mit der Thematik beschäftigen. Diese Form der Konfrontation wird wichtig sein, um der Bevölkerung transparent zu machen, welche Chancen und Risiken hinter der Technologie stehen.

Darüber hinaus wird es auch wichtig sein, dass von staatlicher Stelle eine Aufklärungskampagne erfolgt. Hier wäre es denkbar, dass dies in einem ähnlichen Stil erfolgt wie in der derzeitigen Corona-Krise. Das bedeutet, dass eine enge Zusammenarbeit zwischen staatlichen Einrichtungen und der Wissenschaft etabliert wird, sodass die Ängste der Bevölkerung ganz offensiv adressiert und diskutiert werden.

Ebenso sollten auch Unternehmen diese Aufgabe der Konfrontation wahrnehmen und öffentlich darlegen, für welche Zwecke KI genutzt wird. Darüber hinaus sollten Unternehmen in ihren Leitbildern und Unternehmenswerten gezielt darstellen, welche ethischen und moralischen Standards bei der Anwendung von KI berücksichtigt werden.

2. Veränderung der Interpretation:

Eine weitere gesellschaftliche Aufgabe wird es sein, die Interpretation der Angst vor KI auf das tatsächliche Problem zu fokussieren und dahingehend zu verändern. Denn die Menschen haben wohl in den wenigsten Fällen Angst vor dem komplexen Gebilde KI; sie fürchten eher die Angst um ihre Arbeitsplätze oder den Verlust von Kontrolle. In Bezug auf den Arbeitsmarkt müssen den Menschen Alternativen aufgezeigt werden. So werden gerade hochqualifizierte Personen wohl auch weiterhin zur Ausführung vieler strategisch getriebener Aufgaben benötigt werden, ebenso wird es wichtig sein, dass Menschen die Technologie hinter einer KI im Detail verstehen, um diese auch weiterhin zum Wohl der Menschheit einsetzen zu können. Bei gering Qualifizierten ist die Herausforderung sicherlich größer, da diese weniger flexibel eingesetzt werden können und da viele Jobs von einer KI erledigt werden können. Daher wird es von Bedeutung sein, dass gering Qualifizierte einen Branchenwechsel vollziehen, hin zu Berufen, die stärker von sozialen Fähigkeiten getrieben sind, da KI auf diese Berufsstände tendenziell eine geringere Auswirkung haben wird. Darüber hinaus muss die Thematik des Kontrollverlusts insbesondere von Unternehmen aufgegriffen werden; auch hier gilt es, den Menschen die Entscheidungsprozesse und Leitlinien der KI transparent zu machen. So könnte ein Unternehmen beispielsweise eine Entscheidungsmatrix wie in Abschn. 7.1.3 dargestellt, publik machen, um darzustellen, dass eine KI im jeweiligen Unternehmen nicht ohne Leitplanken handelt und dass die Kontrolle auch nicht vollständig aus der menschlichen Hand gegeben wird. Dadurch gelingt es, dass der Gesellschaft eine klare Perspektive aufgezeigt und verdeutlicht wird, was KI darf und was nicht.

7.5.2 Wie kann die Gesellschaft gut an künstliche Intelligenz herangeführt werden

Neben der zuvor beschriebenen Aufklärung der Gesellschaft muss diese auch gezielt an KI durch Bildung, staatliche Kampagnen und verstärkte Transparenz herangeführt werden. Damit dies gelingt, müssen verschiedene Phasen im Sinne der AI Transformational Governance durchlaufen werden; dies kann nur langsam und Schritt für Schritt erfolgen:

1. Schritt – Begreifen:

In dieser Phase wird es wichtig sein, dass die Menschen verstehen, welche Bedeutung die KI ganz konkret auf ihr Leben hat bzw. haben wird. Dies gelingt einerseits durch gesellschaftliche Aufklärung. Andererseits muss klar werden, inwiefern KI bereits heute schon eine Rolle in unserem Leben spielt. So nutzen bereits heute viele eine Gesichtserkennung zur Entsperrung des Smartphones oder nutzen intelligente Assistenten wie Alexa, die auf KI beruhen. Die Nutzer müssen also verstärkt ein Gefühl dafür entwickeln, dass sie nicht nur mit ihrem Smartphone oder einem Lautsprecher interagieren, sondern mit einem intelligenten System, das weit mehr als eine simple Datenbank ist. Das kann dann gelingen, wenn Hersteller solcher Geräte den Endkunden gezielt darauf hinweisen, dass KI-Komponenten eingesetzt werden.

Zudem wird es in dieser Phase auch wichtig sein, dass das Sicherheitsbedürfnis der Menschen adressiert wird und klar gemacht wird, welche technologischen Mechanismen berücksichtigt wurden, um den Einsatz von KI auch sicher zum Wohl der Menschen zu gestalten.

2. Schritt – Annehmen:

In der nächsten Phase der Heranführung an KI muss die Menschheit die positiven Aspekte erkennen und nach und nach in einer Hybridform bei immer komplexeren Anwendungsbereichen (KI handelt – Mensch bestätigt bzw. ist als Back-up da) mit KI interagieren. Ganz konkret wäre es beispielsweise denkbar, dass bei einem Arztbesuch die KI eine Diagnose und eine Behandlungsoption stellt, die aber noch von einem menschlichen Arzt verifiziert und bestätigt wird, um den Menschen gut an die Technologie heranzuführen. Zu einem späteren Zeitpunkt ist es denkbar, dass diese menschliche Komponente sogar ganz wegfällt, da der Mensch sich nach und nach daran gewöhnt, dass die KI richtig handelt. Ein solches Hybridvorgehen muss auf breiter gesellschaftlicher Basis erfolgen, um die Akzeptanz von KI nach und nach sicherzustellen.

Damit eine Akzeptanz auf breiter Linie gelingt, wird es zudem wichtig sein, dass die Vorteile der Technologie im Vordergrund stehen. In der öffentlichen Debatte ist zu beachten, dass beispielsweise wirtschaftliche Aspekte eher weniger im Vordergrund stehen, da viele besorgte Bürgerinnen und Bürger damit automatisch den negativen Aspekt des Jobverlusts assoziieren könnten. Es muss stattdessen der gesamtgesellschaftliche Wohlstandsgewinn im Vordergrund der Kommunikation stehen, wie beispielsweise der Vorteil, dass durch KI bessere und schnellere Diagnosen im Gesundheitswesen ermöglicht werden und sich Ärzte noch besser um die Patientenbetreuung kümmern können.

3. Schritt – Alltäglicher Nutzen:

In der letzten Phase geht es darum, dass KI als positive Verbesserung für den Alltag wahrgenommen und täglich genutzt wird. Hier könnte das Einsatzgebiet des autonomen Fahrens eine Schlüsseltechnologie darstellen, da dies wohl bereits heute zu einem der am meisten diskutierten Einsatzgebiete von KI zählt und sich bei diesem Use Case auch viele Leute bereits damit abgefunden haben, dass sie eines Tages das Lenkrad aus der Hand geben können. Sobald dies jedoch zur dauerhaften Realität wird, werden die einst besorgten Bürgerinnen und Bürger die Vorteile der neu gewonnenen Freiheit durch den KI-Einsatz begreifen und gern nutzen.

8 Schlusswort

Für den Konsumenten sind die Aussichten im neuen KI-unterstützten industriellen Zeitalter durchaus auch auf den zweiten Blick positiv, ja fast schon utopisch. Er kauft hochintelligente Produkte und Dienstleistungen mit stetig steigendem Nutzen. Das macht ihm

das Leben leichter und er kann sich auf die Tätigkeiten konzentrieren, die er für sich als wichtig und befriedigend empfindet – wenn er denn die Mittel dazu hat.

Diese aber erhält er nur durch eigene Wertschöpfung, also in seiner zweiten Rolle als Produzent. Und in der Rolle als Produzent scheinen die Aussichten im KI-Zeitalter sehr ungewiss, ja vielleicht sogar bedrohlich. Kann er noch produktiv in einem Unternehmen sein, in dem KI die Hauptproduktivität trägt? Muss er das?

Die erste Frage ist eine ökonomisch-technische und kann sogar per Definition gelöst werden. Die zweite Frage ist eine psychologische und sie muss durch Interpretation auf der Weltanschauungsebene gelöst werden.

Die Lösung dieser Frage bedingt ein Überdenken unseres Wirtschaftsmodells. Ist es wirklich so, dass der Mensch, der nicht im klassischen Sinn arbeitet, unproduktiv ist? Ist es so, dass die Menschen nicht zunehmend von den Früchten der Technologie leben, die sie in harter Arbeit über 100.000 Generationen entwickelt haben – ist das nicht ein legitimes Erbe, das sie annehmen sollten?

Sobald das starke globale Wachstum durch kopiertes Wissen nachlassen wird, werden wir uns auch überlegen müssen, wie wir neues Wissen zu höherem Wohlstand erzeugen können. Dann werden wir vermutlich feststellen, dass das ohne KI gar nicht möglich sein wird, so wie wir heute ohne Computer unseren Wohlstand und unser Zivilisationsniveau nicht erhalten, geschweige denn erhöhen könnten.

Die Entwicklung unserer Zivilisation beruht aber auch darauf, dass wir uns nicht ständig gegenseitig selbst unter den fadenscheinigsten Begründungen bekriegen. Es ist völlig offen, ob wir ein friedlicheres Zusammenleben ohne Unterstützung von General-AI überhaupt zustande bringen. Das wäre dann der fünfte kopernikanische Moment, die Frage der moralischen Integrität.

In einigen asiatischen Kulturen hat der Meister dann das höchste Ziel seines Wirkens erreicht, wenn sein Schüler ihn übertrifft. Dies alles sind Aspekte, die explizit nicht außerhalb des CSR-Raums stehen dürfen, sonst wird CSR die vierte industrielle Revolution, nicht als rasche Evolution moderieren können.

KI als vierter Produktionsfaktor der Wirtschaft und kritischer Wettbewerbsfaktor muss eine wesentlich höhere Aufmerksamkeit erhalten. Das Thema muss viel visionärer, offener, transparenter und informativer, insbesondere von europäischen Unternehmen, geführt werden, damit die aktuell starke negative Konnotation objektiviert wird.

Die weitere Entwicklung und der Einsatz von KI in der Wirtschaft und darüber hinaus als Wohlfandsfaktor für die Gesellschaft wird dann seine größte positive Wirkung entfalten, wenn Unternehmen und Politik das große Bild der Vierten Industriellen Revolution erfassen und daraus die Chancen und Risiken ableiten und so strategisch die Weichen für eine progressive Zukunft der Gesellschaft stellen.

Regierungen tun dies durch Gesetze und Industriepolitik⁸ und die Unternehmen durch das Setzen eines Entwicklungsrahmens innerhalb der CSR. Wobei die CSR nicht als

⁸<https://tass.com/economy/1082644>

Hedging-Instrument verstanden werden soll, sondern als strategischer Gedanken- und Handlungsrahmen und als Gestaltungsinstrument für eine bessere Gesellschaft, ganz im Sinn von CSR als Facilitator dieser Entwicklung.

Ein AI Governance Framework operationalisiert diesen Themenkomplex und sichert die Entwicklung und den konkreten verantwortungsvollen Einsatz von KI in allen Prozessen und Produkten und in der Interaktion des Unternehmens mit allen Stakeholdern intern und extern.

Wir hoffen, mit diesem Beitrag Inspiration und Lösungsansätze für dieses so wichtige Zukunftsthema gegeben zu haben.

Literatur

- Carroll A (1991) The pyramid of corporate social responsibility: toward the moral management of organizational stakeholders. *Business Horizons* 34(4), figure 3, S 43
- Schwartz M, Carroll A (2003) Corporate social responsibility: a three-domain approach. *Business Ethics Quarterly* 13, S 503–530
- Friedman M (2007) „The social responsibility of business is to increase its profits“. *New York Times Magazine* September 13, 1970
- EUROPÄISCHE KOMMISSION (2011) Eine neue EU-Strategie (2011–14) für die soziale Verantwortung der Unternehmen (CSR). EUROPÄISCHE KOMMISSION, Brüssel
- Hall PA, Soskice D (2011) *Varieties of capitalism*. OUP Oxford, Oxford
- Nagels P (2017) Facebook musste AI abschalten, die „Geheimsprache“ entwickelt hat. <https://www.welt.de/kmpkt/article167102506/Facebook-musste-AI-abschalten-die-Geheimsprache-entwickelt-hat.html>
- Key Note Alexander Vocolka: BDML Conference 2017
- Vincent J (2016) Twitter taught Microsoft’s AI chatbot to be a racist asshole in less than a day. <https://www.theverge.com/2016/3/24/11297050/tay-microsoft-chatbot-racist>
- Zweig KA (2019) Algorithmische Entscheidungen: Transparenz und Kontrolle
- Europäisches Parlament (2017) Bericht mit Empfehlungen an die Kommission zu zivilrechtlichen Regelungen im Bereich Robotik. https://www.europarl.europa.eu/doceo/document/A-8-2017-0005_DE.html
- Julian Arndts KK (2019) Taxing artificial intelligence

Alexander Vocolka ist Partner und Leiter des von ihm 2015 gegründeten Steering Lab von Horváth in München. Vocolka unterstützt Unternehmen bei der ganzheitlichen digitalen Transformation. Er ist Experte in Big Data, künstlicher Intelligenz (KI) und Quantitative Business Modeling und Verfasser zahlreicher White Papers und Artikel zum Thema Digitalisierung und der Bedeutung von Machine Learning und KI für Unternehmen. Seine Vorträge beschäftigen sich mit den transformativen und technologischen Aspekten der 4. Industriellen Revolution für Wirtschaft und Gesellschaft. Unter seiner Federführung entwickelte das Steering Lab bereits 2016 den ersten Prototypen eines verhaltensgesteuerten Autos, gefolgt von vielen Innovationen im Bereich von General Artificial Intelligence, so zum Beispiel den ersten AI Agenten mit intrinsischer Motivation (2021).

Vor seiner Zeit bei Horvath & Partners leitete Vocolka bei IBM die europäische Finance Management Consulting Practice und verantwortete die Shared Services Practice von IBM weltweit. Von 2000 bis 2006 war Vocolka Partner bei KPMG Consulting und Managing Direktor bei BearingPoint wo er die Finance Transformation Practice EMEA leitete.

In den neunziger Jahren war Vocolka als Product Manager und M&A Berater in der IT Industrie tätig. Dabei verbrachte er einige Jahre in San Francisco und Auckland.

Er lebt und arbeitet in München und Bordeaux und bei sternenklaren Nächten macht er als passionierter Hobby-Astronom zum Ausgleich zu seinem Blick in die Zukunft der Wirtschaft, Deep-Sky-Aufnahmen der Vergangenheit des Universums.

Franziska Langensiepen ist als Managing Consultant bei Horváth im Bereich Risk und Compliance Excellence tätig. Mit einem dualen Universitätsabschluss in Business Administration, einer Zertifizierung in Artificial Intelligence for Business sowie mehrjähriger Erfahrung in der Konzipierung von Risk-Analytics-Projekten, bringt Franziska Langensiepen weitreichende Kompetenzen für die Tätigkeiten an der Schnittstelle von Advanced Analytics und unternehmerischen Einsatzmöglichkeiten ein. Ihre Beratungsschwerpunkte liegen auf den Themen Risk Management, Big Data & Advanced Analytics sowie Data Governance. Dabei berät Franziska Langensiepen die Unternehmen entlang des gesamten Advanced-Analytics-Anwendungsfalls – von der strategischen Konzipierung bis hin zur technischen Implementierung unter Einhaltung gesetzlicher sowie unternehmensinterner Regelungen.

Stephan Beismann ist als Consultant bei Horváth im Bereich Risk und Compliance Excellence tätig. Dank seines Masterabschlusses in Big Data & Business Analytics der IE University Madrid sowie seines Bachelorabschlusses in Business Administration der Frankfurt School of Finance & Management bringt Stephan Beismann die nötige Kompetenz mit, um die Analytics-Bedürfnisse von Unternehmen zu erkennen und diese ideal mit den Möglichkeiten moderner Advanced-Analytics-Lösungen zu kombinieren. Er berät Klienten aus verschiedensten Industrien zu aktuellen Fragestellungen im Bereich Governance, Risiko- und Compliance Management. Vor seiner Zeit bei Horváth war er bei der Commerzbank AG im Risikomanagement angestellt und beschäftigte sich mit der Steuerung von Problemkrediten (Non-Performing Loans).



Spannungsfeld automatisierte Entscheidungssysteme und Autonomie

Sabine Theresia Koeszegi

1 Einleitung

Seit etwa fünfzig Jahren setzen Menschen modell- und datenbasierte Unterstützungssysteme zur Entscheidungsfindung ein – vorwiegend bei komplexen Entscheidungsproblemen. Menschen haben nicht nur beschränkte kognitive Fähigkeiten und Kapazitäten, sondern auch bewusste und unbewusste Vorurteile, die die Qualität ihrer Entscheidungen vermindern können. Der Einsatz von Entscheidungssystemen wird daher damit gerechtfertigt, dass mit ihrer Hilfe Entscheidungen nicht nur effizienter, sondern auch unparteiisch getroffen und damit mehr Fairness und Gerechtigkeit erzielt werden können (Wihlborg et al. 2016).

Diese Hoffnungen haben sich allerdings bis dato in der Praxis nur zum Teil erfüllt. Heute werden sie durch die technologischen Fortschritte in der datenbasierten künstlichen Intelligenz (KI) erneut befeuert. KI-Systeme sollen Ärzt*innen bei der Diagnose von Krankheiten unterstützen, Manager*innen beim Recruiting helfen und anstelle von Mitarbeiter*innen sollen KI-Systeme entscheiden, ob Kund*innen einen Kredit, eine Versicherung oder ein Leasingauto erhalten. Aber auch Staaten und öffentliche Institutionen setzen automatisierte Entscheidungssysteme ein. Algorithm Watch (2019)

Dieses Kapitel ist unter dem Titel *Der autonome Mensch im Zeitalter des Digitalen Wandels* im Ecowin Verlag erschienen: Sabine Koeszegi: Der autonome Mensch im Zeitalter des Digitalen Wandels, S. 62–90, in: Markus Hengstschläger/Rat für Forschung und Technologieentwicklung (Hg.) (2020): Digitaler Wandel und Ethik. Salzburg, München: Ecowin Verlag.

S. T. Koeszegi (✉)
TU Wien, Wien, Österreich
E-Mail: sabine.koeszegi@tuwien.ac.at

listet in ihrem Bericht zwölf europäische Länder auf, die bereits heute automatisierte Entscheidungssysteme einsetzen. Anwendungsgebiete umfassen so unterschiedliche Bereiche wie die Festlegung von Kauttionen in der Justiz, die Risikoeinschätzung in der Jugendwohlfahrt bis hin zum Zugang zu staatlichen Leistungen im Bereich Arbeitslosenunterstützung oder Zugang zu Gesundheitsservices. Aktuelle Anwendungen von automatisierten Entscheidungssystemen zeigen allerdings mit einer Vielzahl an nachgewiesenen Formen von Diskriminierung eine sehr problematische Erfolgsbilanz (vgl. dazu z. B. Molnar und Lex 2018).

Auch im Privatleben wollen Menschen nicht mehr auf die neuen Entscheidungshelfer verzichten. Die Anwendungen von Entscheidungsunterstützungssystemen haben sich von komplexen schwierigen Entscheidungen auf einfache, dafür häufig auftretende Alltagsentscheidungen ausgeweitet, in denen wir uns durch Vorselektion geeigneter Alternativen unterstützen lassen oder diese gleich an das System delegieren: persönliche KI-Assistenten filtern – basierend auf individuellen Gewohnheiten und Vorlieben – Produkte und Dienstleistungen, Lieder oder Liebespartner*innen. Während wir beim Durchblättern von Tageszeitungen auch Informationen sehen, nach denen wir zwar nicht gesucht haben, die aber dennoch unsere Aufmerksamkeit erregen, selektieren Algorithmen vermeintlich für uns interessante Nachrichten vor. Da wir nicht wissen, welche Entscheidungsalternativen, Informationen oder Nachrichten uns durch automatisierte Entscheidungssysteme vorenthalten werden, wissen wir auch nicht, was wir verpassen. Nach und nach schränkt sich unser Präferenzhorizont und unser Handlungsspielraum ein, denn wir können kaum Neues, Anderes, Widersprüchliches oder Überraschendes entdecken, wenn alles nach Vergangem, Vertrautem und Ähnlichem für uns gefiltert wird.

In vielen Situationen ist uns nicht bewusst, dass automatisierte Entscheidungssysteme überhaupt zum Einsatz kommen. Wir werden in der Regel weder über ihre Datengrundlage und Funktionsweise noch über unsere Rechte in Bezug auf automatisierte Entscheidungen aufgeklärt (vgl. dazu die Datenschutz-Grundverordnung, Art. 14 und 22, Recht auf Transparenz und Erklärung). Empirische Studien zeigen, dass Menschen daher sowohl Einsatzfelder als auch Gefahren unterschätzen, die von automatisierten Entscheidungssystemen auf ihre individuelle Entscheidungsfreiheit und ihre persönlichen Rechte ausgehen (Wouters et al. 2019). Auch ohne unser Wissen werden heute persönliche und biometrischen Daten gesammelt und Persönlichkeitsprofile erstellt, die zutiefst persönliche, private bis hin zu intimen Informationen offenlegen und für verschiedenste Zwecke – auch manipulative – genutzt werden können (Kosinski et al. 2013).

Mangelnde Transparenz und Einschränkung der Autonomie sind nur die eine Seite der Medaille. Gleichzeitig entsteht mit der Übertragung der Entscheidungsfindung auf automatisierte Entscheidungssysteme ein Vakuum über die Verantwortung von Entscheidungen. Wer trägt schlussendlich die Verantwortung für Fehlprognosen und Fehlentscheidungen, insbesondere dann, wenn die Anwender*innen weder Entscheidungskriterien und -modelle kennen, geschweige denn nachvollziehen oder erklären können. Bei vielen Ansätzen und Techniken des maschinellen Lernens können nicht einmal Systemdesigner*innen, Prognosen und Entscheidung befriedigend erklären.

In diesem Aufsatz gehe ich der Fragestellung nach, wie sich automatisierte Entscheidungssysteme auf die Autonomie von Menschen auswirken und welche Anforderungen an automatisierte Entscheidungssysteme zu stellen sind, um Menschen und Gesellschaft zu schützen. Nach Begriffsbestimmungen werde ich im folgenden Abschnitt detailliert auf die Anatomie von Entscheidungsprozessen eingehen, um in weiterer Folge aufzuzeigen, wie automatisierte Entscheidungssysteme Autonomie und Selbstbestimmung beeinflussen können. Zum Abschluss werde ich auf Anforderungen an automatisierte Entscheidungssysteme eingehen, die sicherstellen können, dass wir auch in Zukunft ein selbstbestimmtes, autonomes Leben führen können.

2 Die Anatomie von Entscheidungsprozessen

Im Wesentlichen ist **datenbasierte KI-Technologie** eine Software mit vier Eigenschaften: 1) sie arbeitet *autonom*, d. h. ohne direkte Benutzer*innenkontrolle, 2) ihre Ergebnisse sind *statistisch*, d. h. sie verbindet nicht Ursache und Wirkung, 3) sie ist *anpassungsfähig*, d. h. sie passt ihr Verhalten an, wenn sie mehr über den Kontext lernt, und 4) sie ist *interaktiv*, d. h. ihre Aktionen und Ergebnisse beeinflussen und werden von uns Menschen und unserer sozialen und physischen Umgebung beeinflusst. KI-Systeme können strukturierte oder unstrukturierte Daten interpretieren. Dafür werden verschiedene Ansätze und Techniken des maschinellen Lernens eingesetzt (vgl. Dignum et al. 2020; HLEG 2019). Der Begriff **Algorithmus** bezieht sich auf die logische Abfolge von Schritten zur Organisation, Bearbeitung und Analyse dieser Datenmengen (vgl. Gillespie 2016) und gleicht einem Rezept. Das Entscheidende aber ist, dass KI-Systeme eindeutige Zielvorgaben benötigen, um lernen und autonom agieren zu können. **Algorithmen sind demnach das Ergebnis einer Modellbildung, die sowohl die Formalisierung eines Problems als auch ein Ziel beinhaltet.**

Der Begriff **automatisierte Entscheidungssysteme**¹ wird verwendet, wenn Algorithmen Entscheidungsmodelle ausführen und die *menschliche Beurteilung* bei Entscheidungsproblemen vollständig oder teilweise ersetzt wird. Der Begriff **System** definiert den soziotechnischen Rahmen und umfasst neben den technologischen Komponenten auch das politische, gesellschaftliche und wirtschaftliche Umfeld, in dem Algorithmen zur Entscheidungsfindung implementiert werden. Der Begriff berücksichtigt damit auch den Kontext, in dem ein automatisiertes Entscheidungssystem eingesetzt werden soll.

¹ In öffentlichen Dokumenten oder in den Medien werden für automatisierte Entscheidungssysteme auch viele andere Begriffe synonym verwendet, wie „predictive analytics“, „algorithmic decision making“, „automated decision making“ oder „machine learning“. Es gibt Unterschiede zwischen den einzelnen Begriffen, die aber auch bei Expert*innen umstritten sind (s. dazu z. B. Molnar und Gill 2018).




Abb. 1 Anatomie von Entscheidungsprozessen (Agrawal et al. 2018)

In Abb. 1 wird ein automatisierter Entscheidungsprozess mithilfe eines einfachen Prozessmodells schematisch dargestellt.

Die Qualität von automatisierten Entscheidungsprozessen (Output) hängt wesentlich von der Qualität der Trainingsdaten (Input), der Modellbildung sowie der Implementierung der Entscheidung durch Entscheidungsträger*innen (Prozess) ab.

Ausgangspunkt automatisierter Entscheidungsprozesse sind zunächst Daten aus der Vergangenheit. Die Werte und Annahmen, die in die Auswahl und Vorbereitung der Trainingsdaten einfließen, sind von ebenso großer Bedeutung wie der Algorithmus, der aus ihnen lernt. In erster Linie müssen die Trainingsdaten eine vernünftige Annäherung an jene Daten sein, an denen ein Algorithmus später angewendet wird, da maschinelles Lernen davon ausgeht, dass neue Daten die gleichen Muster haben wie Trainingsdaten, oder anders ausgedrückt, dass die Zukunft wie die Vergangenheit aussehen wird. Daher werden KI-Systeme auch Prognosemaschinen genannt.

Damit Algorithmen zukünftige Zustände vorhersagen – oder aktuelle Zustände klassifizieren können – muss zunächst ein Modell entwickelt werden das festlegt, welche Parameter für ein bestimmtes Entscheidungsproblem überhaupt relevant sind (s. Abb. 1 – *Bewertung*) Die Definition des Entscheidungsproblems und die Entscheidung darüber, welche Daten für die Lösung des Problems relevant sein können, kommt von Menschen. In der Regel arbeiten hier künftige Anwender*innen und KI-Expert*innen bei der *Bewertung* des Entscheidungsmodells zusammen. Die Herausforderung dabei ist, Problemstellung und Ziel eindeutig zu formulieren, sodass ein Algorithmus tatsächlich sinnvolle und genaue Klassifizierungen oder Prognosen aus den Daten ermitteln kann.

Wenn man z. B. ein automatisiertes Entscheidungssystem entwickeln möchte, das Bewerbungen analysiert, um geeignete Kandidat*innen für ein Unternehmen zu finden, muss man zunächst festlegen, was das eigentliche Entscheidungsproblem ist. Was bedeutet in diesem Zusammenhang „geeignet“? Die Eignung für einen bestimmten Job kann durch verschiedene Kriterien festgelegt sein. Eine geeignete Kandidatin kann

die richtigen Qualifikationen, die richtige Motivation, die richtigen Werthaltungen, die richtigen Gehaltsvorstellungen oder die richtigen Erfahrungen oder alle diese Kriterien mitbringen. Als Erfolg könnte die Loyalität von künftigen Mitarbeiter*innen zum Unternehmen definiert werden. Mit der Definition des Erfolgs und der Auswahl von Zielvariablen, die diesen Erfolg herbeiführen, legen Menschen fest, was ein Algorithmus tatsächlich versucht, vorherzusagen. Wenn Erfolg im Recruiting mit Loyalität der Mitarbeiter*innen festgelegt wird, dann sind jene Personen, die wahrscheinlich lange im Unternehmen bleiben, die richtigen Personen, die Zielvariable wäre also die Dauer der Betriebszugehörigkeit. Die Zielvariablen werden in einem Prozess, der *Feature Selection* genannt wird, weiter aufgeschlüsselt. Hier entscheiden die Programmierer*innen, nach welchen spezifischen Kriterien sie die Fälle vorrangig sortieren, bewerten oder einordnen. Zu den Qualitäten, die bestimmen, ob eine Mitarbeiterin langfristig in einem Unternehmen bleibt, kann beispielsweise die Zeit gehören, die eine Person an ihrem früheren Arbeitsplatz verbracht hat (vgl. Molnar und Lex 2018).

Das Prognosemodell oder Klassifizierungsmodell kann strukturierte oder unstrukturierte Daten interpretieren. Dafür gibt es verschiedene Ansätze und Techniken des maschinellen Lernens (vgl. Dignum et al. 2020; HLEG 2019). Auch die Entscheidung über geeignete Methoden zur Analyse vorhandener Daten werden von Menschen getroffen. Schließlich erlernt das Entscheidungssystem anhand von Trainingsdaten, Muster und Zusammenhänge zu erkennen. Das Ergebnis dieses Lernprozesses ist der Algorithmus, der dann auf neue Daten zur Vorhersage angewendet werden kann. Das Ergebnis eines Algorithmus wird entweder einem Entscheidungsträger als Entscheidungsunterstützung vorgelegt, oder das System führt Entscheidungen direkt auf Basis des Entscheidungsmodells aus.

Für automatisierte Entscheidungsmodelle muss also auch festgelegt werden, für welche Problemstellungen sie überhaupt relevant sind. Will ich so ein System für alle Stellen im Unternehmen einsetzen, also z. B. auch für die Topmanagementebene oder nur für bestimmte Positionen? Welche Entscheidungen sollen zur Gänze automatisiert werden und welche Entscheidungen muss ein Mensch treffen? Auch für die Frage der Implementierung ist menschliches Urteilsvermögen notwendig. Die Qualität von automatisierten Entscheidungsprozessen hängt schließlich davon ab, wie sie in der Praxis implementiert werden. Schließlich führt erst die Ausführung der Entscheidungen zu beabsichtigten und möglicherweise auch unbeabsichtigten Konsequenzen (Output). Hier spielt die Expertise von Anwender*innen eine große Rolle. Nur wenn sie das Entscheidungsmodell verstehen, können sie die Qualität von Entscheidungen und deren Auswirkungen beurteilen und daraus lernen. Allerdings führt genau die Nutzung solcher Systeme dazu, dass sich Menschen wichtige Expertise nicht mehr erarbeiten oder sie im Lauf der Zeit verlieren (Bainbridge 1983). Im Fall von Systemausfall oder Systemfehlern wird es dann zunehmend schwieriger für den Menschen, diese Systeme zu kontrollieren oder korrigierend einzuschreiten.

Ein Algorithmus ist also lediglich das Verfahren, mit dem eine Aufgabe in operationalisierter Form gelöst werden kann. „Was zunächst ein soziales Urteil darüber

war, was relevant ist, wird mathematisch modelliert, in vorgegebenen oder gemessenen Zusammenhängen, in operationalisierten strategischen Zielen und in Indikatoren zur Erfolgsmessung“ (Gillespie 2016, S. 24). Wenn wir von Algorithmen sprechen, beziehen wir uns also genau genommen auf ein undefiniertes Netzwerk aus technischen Anordnungen, in der die Beteiligung von Menschen in jedem Prozessschritt verdeckt bleibt: Es sind Menschen, die über Methoden und Modelldesign entscheiden, es sind Menschen, die Trainingsdaten kuratieren und bereinigen, es sind Menschen, die Algorithmen entwerfen, indem sie entscheiden, welche Parameter in welchen Kontexten relevant sind und welche Zielfunktion zu erreichen ist (Abb. 2). „Diese algorithmischen Systeme sind keine eigenständigen, kleinen Kisten, sondern massive, vernetzte Systeme, in die Hunderte von Händen hineinreichen, um an ihnen zu feilen und sie zu stimmen, Teile auszutauschen und mit neuen Anordnungen zu experimentieren.[...] Wir müssen die Logik untersuchen, die die Hände führt“ (Seaver, zit. in Gillespie 2016).

Corinna Balkow und Irina Eckhardt haben in einer schematischen Übersicht zum Entwicklungsprozess von algorithmischen Systemen herausgearbeitet und aufgezeigt, wo überall Fehler und systematische Verzerrungen (Bias) die Qualität von automatisierten Entscheidungen negativ beeinträchtigen und damit zu ungerechtfertigter




Abb. 2 Bias in algorithmischen Systemen (Balkow und Eckardt 2019)

Diskriminierung, Benachteiligung und Fehlentscheidungen führen können. Die Abb. 2 macht deutlich, dass unterschiedlichste Formen von Verzerrungen in jeder Phase der Entwicklung auftreten können.

In Bezug auf ungerechtfertigte Diskriminierung lassen sich Faktoren, die zu direkter Diskriminierung führen können, noch einfacher identifizieren als implizite oder indirekte Diskriminierung. Ein Algorithmus, der beispielsweise auf historische Einstellungsentscheidungen eines Unternehmens trainiert wurde, um geeignete Kandidat*innen zu empfehlen, kann Muster von ethnischer oder geschlechtsspezifischer Diskriminierung aus der Vergangenheit reproduzieren. Durch das Wissen um diesen Bias in der Vergangenheit können Systemdesigner*innen entsprechende Vorkehrungen treffen und ihn entschärfen. Für Formen der indirekten Diskriminierung, die auf institutioneller oder struktureller Ebene in den Daten abgebildet sind, ist dies nicht möglich, weil sie meist nicht bekannt sind. Wenn etwa ein Unternehmen in der Vergangenheit überwiegend Personen von einer Eliteuniversität rekrutiert hat, in der Personen aus Minderheiten oder Frauen unterrepräsentiert waren, wird dieses Muster auch in weiterer Folge im Algorithmus abgebildet sein. Da die kritische Variable Universität und nicht Geschlecht oder Herkunft ist, erschwert dies eine Offenlegung indirekter Diskriminierung. Das Problem der indirekten und auch impliziten Diskriminierung ist auch bei menschlichen Entscheidungsträger*innen ein kritischer Faktor. Die Hoffnung, dass Algorithmen menschliche Unzulänglichkeiten in Entscheidungsprozessen ausmerzen könnten, lässt sich aber nicht halten, da „Algorithmen für die gleichen Probleme bei der Entscheidungsfindung anfällig sind, die auch menschliche Entscheidungsträger plagen: Transparenz, Verantwortlichkeit, Diskriminierung, Voreingenommenheit und Fehler“ (Tufekci 2015, S. 216).

Algorithmen sind demnach soziotechnische Ensembles. Mit der Bezeichnung dieser komplexen soziotechnischen Netzwerke als Algorithmen wird in gewisser Art und Weise verschleiert, dass kulturelle, gesellschaftliche und politische Werte über die Designer*innen einfließen, und zwar in ihren Entscheidungen darüber, wie bestimmte Aktivitäten, Ziele oder Parameter in ein Modell zu operationalisieren sind und daher in einzelnen, mathematischen Momenten der Zuweisung von Präferenzwerten und Schwellenwerten repräsentiert sind (Molnar und Lex 2018).

3 Die Autonomie des Menschen in Bedrängnis

Der durch den technologischen Fortschritt ausgelöste paradigmatische Wandel basiert auf der immer weiter reichenderen Autonomie und der daraus resultierenden Handlungsmacht von KI-Systemen. Entscheidungen, die wir bisher selbst getroffen haben, werden zum Teil oder zur Gänze an diese übertragen. Bei vielen Anwendungen algorithmischer Entscheidungsfindung verschwimmen die Grenzen zwischen automatisierten Entscheidungen und Entscheidungsunterstützung. Wie sehr dadurch Handlungsmöglichkeiten, Kontrolle und Selbstbestimmung von Menschen eingeschränkt werden, bleibt in der Regel intransparent.

Das Wort *Autonomie* kommt aus dem Griechischen und setzt sich aus den Wörtern „autos“ (selbst) und „nomos“ (Gesetz) zusammen. Es bedeutet buchstäblich Selbstregulierung bzw. Selbstbestimmung. Autonome Menschen können unabhängig von fremden Einflüssen oder dem Willen anderer entscheiden. Im Gegensatz dazu steht die *Heteronomie*, also die Regulierung durch andere oder das fremdbestimmte Handeln. Selbstbestimmtes Handeln und Verantwortung für individuelles Handeln sind die beiden Seiten derselben Medaille und damit eng verwoben. Im Folgenden werden unterschiedliche Aspekte automatisierter Entscheidungssysteme genauer untersucht. Zum einen wird analysiert, welche Konsequenzen die *Zuschreibung maschineller Handlungsmacht* für uns Menschen auf die Interaktion mit diesen Maschinen hat und zum anderen werden *Mechanismen des Verhaltensengineerings* aufgezeigt, mit deren Hilfe direkt auf unser Verhalten Einfluss genommen werden kann.

3.1 Die Zuschreibung von Handlungsmacht an automatisierte Entscheidungssysteme

Die britische TV-Comedy-Show „Little Britain“ macht mit einem Sketch auf die Handlungsmacht von Maschinen aufmerksam: Eine Mutter kommt mit ihrer fünfjährigen Tochter zu einer vereinbarten Mandeloperation ins Krankenhaus. Nachdem die Rezeptionistin die Daten der Tochter aufnimmt, sagt die Rezeptionistin, dass das Kind für eine beidseitige Hüftoperation vorgesehen ist. Auf Einwände der Mutter, die die Rezeptionistin in ihren Computer zunächst eintippt, reagiert sie dennoch beständig mit der Antwort: „Computer says no!“ In der Zwischenzeit ist das Schlagwort „Der Computer sagt nein“ Sinnbild für eine kundenfeindliche Haltung von Unternehmen und Serviceeinrichtungen geworden. Der Sketch zeigt aber auch auf drastische Art und Weise auf, wie die Nutzung von Informationstechnologien das Rollengefüge zwischen Menschen und Maschinen auf absurde Weise verschieben kann. Egal, wie vernünftig Einwände von Kund*innen sind, und egal, wie offensichtlich falsch die Aussage des Computers ist, es wird an der vorgeschlagenen Entscheidung der Maschine festgehalten.

Mit der Übertragung von Entscheidungen an Maschinen geht die Zuschreibung von Handlungsmacht im sozialen Kontext einher. Menschen entwickeln Annahmen über die Fähigkeiten und Kompetenzen „intelligenter“ Maschinen und setzen bestimmte Erwartungen in sie. Im Kontext sozialer Interaktion führt dies in weiterer Folge zu Verschiebungen im Rollengefüge zwischen Menschen und zwischen Menschen und Maschinen. Wer ist also in einem soziotechnischen Ensemble letztendlich verantwortlich für eine Entscheidung?

Menschen, die KI-Systeme und Computer zur Unterstützung ihrer Entscheidungen nutzen, haben in der Regel großes Vertrauen in die Technologie. Mit einer kürzlich durchgeführten Studie, in der ein Programm mithilfe einer Gesichtserkennungssoftware bei Versuchspersonen nicht nur ihr Geschlecht, ihre Ethnie und ihr Alter, sondern auch ihren emotionalen Zustand und Persönlichkeitsmerkmale erkannt haben will, zeigen Wissenschaftler*innen auf, wie sehr sich Lai*innen selbst durch offensichtlich falsche

Ergebnisse beeindrucken lassen. „Das Ergebnis muss richtig sein, weil die Analyse wurde ja durch einen Computer gemacht, und Computer sind besser als Menschen, um solche Schlussfolgerungen zu ziehen“ (Versuchsperson, zitiert in Wouters 2019, S. 454). Das kann sogar soweit führen, dass Menschen ihr eigenes Selbstverständnis aufgrund einer falschen Klassifizierung des Computers infrage stellen (Wouters 2019, S. 454).

In einem anderen Beispiel aus Schweden, in dem in einer öffentlichen Institution ein Algorithmus zur Entscheidungsunterstützung eingesetzt wird, offenbaren Beamt*innen in Interviews über ihr eigene Rolle: „Das automatisierte System schlägt eine Entscheidung vor, die auf allen eingegebenen Informationen basiert, und liefert eine Entscheidung. [...] Es gibt keinen Raum für Zweifel an der Entscheidung, die mit Hilfe des Verwaltungsinstruments getroffen wird“ (Wihlborg et al. 2016, S. 2908). Durch den Einsatz algorithmischer Entscheidungsunterstützung verändern sich Rollen und Aufgaben von Menschen in ihrem Arbeitsprozess – und damit ihr eigenes Rollenverständnis sowie schlussendlich auch ihr Verständnis von ihrer Verantwortung über den Arbeitsprozess und das Ergebnis. Die Schlussfolgerung aus der Studie von Wihlborg et al. (2016, S. 2911) ist hier recht deutlich: „Der Beamte wird eher zum Vermittler als zum Entscheidungsträger und hält das System während des gesamten Prozesses am Laufen“. Während Autonomie und selbstbestimmtes Handeln ein bestimmtes Maß an Eigenverantwortung erfordern, wird durch die Delegation von Entscheidungen an automatisierte Systeme nicht nur die Handlungsmacht der Menschen, sondern auch ihre wahrgenommene Kontrolle über den Entscheidungsprozess eingeschränkt. „Allein die Tatsache, dass ein Ergebnis das Ergebnis eines automatisierten Prozesses ist, kann ihm eine größere Legitimität verleihen, die wahrgenommene ‚Neutralität‘ eines Ergebnisses erhöhen oder die Rechenschaftspflicht der menschlichen Akteure und Institutionen schwächen“ (Gillespie 2016, S. 27). Nach einer Studie von Logg et al. (2019) ist dies deshalb besonders problematisch, weil insbesondere Personen, die wenig oder kein Know-how in einem bestimmten Gebiet haben, lieber auf einen Algorithmus als auf die Fachexpertise von Menschen vertrauen, während sich Expert*innen deutlich weniger auf die Aussagekraft von algorithmischen Vorhersagen verlassen.

Die Zuschreibung von Handlungsmacht und damit verbundene Rollenerwartungen an automatisierte Entscheidungssysteme reduziert menschliches Handlungsvermögen durch die Veränderungen des Rollengefüges im soziotechnischen System. Eigenverantwortliches Handeln von Menschen sowie die Übernahme von Verantwortung und Kontrolle über den Prozess und das Ergebnis werden sehr viel schwieriger und unwahrscheinlicher.

3.2 Die Gefahr der Manipulation durch automatisierte Entscheidungssysteme

Wir schreiben automatisierten Entscheidungssystemen nicht nur Handlungsmacht zu, sie haben diese auch effektiv. Damit verfügen sie über das Potenzial, direkt auf menschliches Verhalten Einfluss zu nehmen. Kritische Stimmen warnen davor, dass KI-Technologien

in unsere Privatsphäre eindringen und unsere persönlichsten und intimsten Bereiche für andere offenlegen können. Wir machen uns durch die Offenlegung von Daten verletzlich, weil wir in unseren Wünschen, Bedürfnissen und Sehnsüchten vorhersagbar und damit *manipulierbar* werden. Mittels gezieltem Verhaltensengineering durch manipulative Taktiken wird die individuelle Freiheit und Selbstbestimmung schrittweise eingeschränkt. Laut Shoshana Zuboff (2018, S. 335) liegt die wahre Macht im Profiling von Nutzer*innendaten darin, das Handeln der Menschen in der realen Welt zu *modifizieren*. Informationen, die Menschen freiwillig und unfreiwillig (über ihr beobachtetes Verhalten) in der virtuellen Welt von sich preisgeben, werden dazu benutzt, ihr Verhalten für bestimmte Zwecke zu verändern. Die manipulativen Ansätze zur Verhaltensmodifikation von Menschen werden im Englischen „behavioral engineering“ oder „tuning“ genannt und gehen auf verhaltenswissenschaftliche Ansätze zurück (vgl. dazu Zuboff 2018).

Im Fall von Konditionierung werden erwünschte Verhaltensweisen von Nutzer*innen durch Belohnung, Anerkennung und Lob verstärkt. Shoshana Zuboff zitiert einen Programmierer einer App wie folgt: „Wenn die Leute unsere App benutzen, können wir ihre Verhaltensweisen erfassen und die guten und schlechten identifizieren. Dann entwickeln wir ‚Behandlungsmethoden‘ oder ‚Datenpillen‘, die gutes Verhalten auswählen. Wir können testen, wie nützlich unsere Auslösereize für sie sind und wie profitabel bestimmte Verhaltensweisen für uns sind“ (Zuboff, S. 339). Während beim Social-Credit-System, das in China seit 2014 zum Einsatz kommt, die Regierung festlegt, was „gutes“ Verhalten ist, zeigt dieses Direktzitat, dass in der westlichen Welt Unternehmen aufgrund ihrer ökonomischen Interessen festlegen, welche Verhaltensweisen „gut“ bzw. wünschenswert – weil profitabel – sind. Entsprechend implementieren sie positive Konditionierungen und mehr oder weniger offensichtliche Auslösereize für bestimmtes Verhalten in ihren Anwendungen. Von der Fitness-App oder der Diät-App, die Konsument*innen nutzen, weil sie gesünder leben wollen und durch positive Konditionierung auf längeres Durchhaltevermögen hoffen, ist es nur ein minimaler Schritt zur Manipulation von Nutzer*innenverhalten, um die eigenen ökonomischen Interessen durchzusetzen. Allerdings bleibt diese Manipulation den Nutzer*innen zumeist verborgen. Obwohl herkömmliches Marketing schon immer zielgruppengerechte Werbung platziert hat, waren Unternehmen bisher nicht in der Lage, sich in konkreten Situationen gezielt auf einzelne Menschen mit ihren ganz persönlichen Verletzlichkeiten zu konzentrieren. Darüber hinaus ist es möglich, auf die Stimmung von Nutzer*innen und deren Verhalten in sozialen Netzwerken direkt Einfluss zu nehmen. Die Facebook-Studie von Kramer et al. (2014) zeigt, dass wir durch das bewusste Filtern unseres Newsfeeds für kommerzielle oder politische Zwecke anderer manipuliert werden können, ohne dass uns dies bewusst wird.

Nudging, eine andere Form der Verhaltensmanipulation, geht auf eine verhaltensökonomische Methode von Thaler und Sunstein (2008) zurück: Hier werden *Entscheidungsarchitekturen* in Systemen so strukturiert und gestaltet, dass sie das Verhalten von Menschen auf vorhersagbare Weise beeinflussen. Diese Form der Manipulation passiert ebenfalls subtil, kommt ohne ökonomische Anreize oder direkte Einflussnahme auf das

Entscheidungsverhalten aus und bleibt dem Bewusstsein und dem Willen der manipulierten Person verborgen. Die Erfinder versuchen, die Methode damit zu legitimieren, dass sie das „Verhalten der Menschen beeinflussen, um ihr Leben länger, gesünder und besser zu machen“ (Thaler und Sunstein 2008, S. 5). Abgesehen davon, dass Menschen eine sehr individuelle Vorstellung von „gesünder und besser“ haben, lässt sich Verhaltensmanipulation durch Nudging auch ohne das hehre Ziel der Lebensverbesserung einsetzen. Die Wirkungsweise von Nudging wurde durch das Live-Experiment mit 61 Mio. Facebook-Nutzer*innen zur Wahlmobilisierung sehr eindrücklich demonstriert. Facebook hat ohne das Wissen und die Zustimmung seiner Nutzer*innen deren persönlichen Newsfeed sowie den Informationsgehalt wahlbezogener Nachrichten manipuliert. Die Aufforderung zur Wahl zu gehen, ein Button „ich habe gewählt“ sowie ein Link zur Wahlinformation hat die Wahlbeteiligung bei den Kongresswahlen in den USA im Jahr 2010 um hunderttausende Stimmen verändert (Bond et al. 2012). Obwohl das Experiment einen kollektiven Aufschrei verursacht hat und Facebook versicherte, keinen Einfluss auf das Wahlergebnis an sich genommen zu haben, wird deutlich, dass dies einfach durch selektive Manipulation von bestimmten Nutzer*innengruppen möglich wäre.

Es gibt viele weitere Beispiele für manipulative Entscheidungsarchitekturen: Geschäftsbedingungen sind buchstäblich im Kleingedruckten so umständlich präsentiert, dass Nutzer*innen rasch aufgeben, sie zu verstehen. Ebenso ist es gängige Praxis, bei Cookies bereits eine zustimmende Vorauswahl für Nutzer*innen zu treffen. Diese manipulative Entscheidungsarchitektur stößt Nutzer*innen an, durch das Klicken des gut sichtbaren Buttons „Okay“ oder „Weiter“ das Setzen von Tracking-Cookies zu erlauben, da eine Entscheidung, Cookies nicht zu erlauben, umständlich mit mehreren Klicks verbunden ist.² Eine andere Nudging-Strategie ist, den Zugang zu Kommunikationskanälen für Nutzer*innen mit Beschwerden, Problemen und Anliegen massiv zu erschweren. So ist es oftmals unmöglich, eine Telefonnummer oder eine E-Mail einer konkreten Ansprechperson herauszufinden, um ein Anliegen persönlich vorbringen zu können.

Die dritte Form der Verhaltensmanipulation ist das *Herding*, ein Ansatz, bei dem Menschen in bestimmten Situationen aus der Ferne orchestriert werden: „Wir lernen die Musik zu schreiben und sorgen dann dafür, dass sie die Leute tanzen lässt“ (S. 338) zitiert Shoshana Zuboff einen Softwareentwickler. Das Spiel Pokemon Go ist ein anschauliches Beispiel dafür, wie das Verhalten von Menschenmengen über eine digitale App in der realen Welt gesteuert und orchestriert werden kann. Mithilfe der Internet-of-things-Technologien kann remote auf vernetzte, mit dem Internet verbundene Geräte direkt Einfluss genommen und dadurch Verhaltensoptionen ihrer Nutzer*innen eingeschränkt werden. So kann beispielsweise bei ausstehenden Zahlungen von Leasing-

²Nach der E-Privacy-Richtlinie der Europäischen Kommission, der sogenannten Cookie-Richtlinie, ist das Setzen von Cookies allerdings nur erlaubt, wenn Nutzer*innen ausdrücklich und aktiv zustimmen. Auch der Europäische Gerichtshof hat dies in einem neuerlichen Urteil bestätigt (vgl. Ionos, Digital Guide 2020).

raten die Inbetriebnahme von Fahrzeugen verhindert werden. Dabei können Geräte auch kontextspezifische Daten von Nutzer*innen berücksichtigen: Ein Auto lässt sich nicht in Betrieb nehmen, weil die Person alkoholisiert ist. Selbst wenn der zulässige Alkoholwert im Blut nicht überschritten wird, könnte eine Leasingfirma die Einhaltung strengerer Regeln erzwingen.

Jede Entscheidung, die Maschinen für uns Menschen treffen, treffen wir nicht selbst. Das kann in vielen Kontexten und bei vielen Entscheidungsproblemen hilfreich und sinnvoll, in anderen aber problematisch und falsch sein. Wir müssen daher sicherstellen, dass beim Einsatz automatisierter Entscheidungssysteme bestimmte Anforderungen und Qualitätskriterien erfüllt sind, damit wir auf ihren Nutzen vertrauen können.

4 **Anforderungen an vertrauenswürdige Künstliche-Intelligenz-Systeme**

Transparenz über Ziele, Entscheidungskriterien und Entscheidungsprozesse sind Grundvoraussetzungen für selbstbestimmtes, verantwortliches Handeln. Die Ausführungen in den vorangegangenen Abschnitten skizzieren, welche Auswirkungen automatisierte Entscheidungssysteme auf unsere Selbstbestimmung, unsere Privatsphäre und auf Demokratie und Gesellschaft haben können. Wir stehen gegenwärtig vor einer bedeutenden Phase: Noch ist die Technologie in vielen Bereichen nicht so weit entwickelt, dass wir ihre Gestaltung nicht mehr beeinflussen könnten. Allerdings haben wir nicht lange Zeit, um dieses Fenster zu nutzen. Die Ethikrichtlinien der Expert*innengruppe der Europäischen Kommission zu KI, an denen ich mitarbeiten durfte, fordern eine menschenzentrierte Technologie ein, die die Rechte der Menschen schützt und respektiert. Die Richtlinien unterstreichen einmal mehr, dass KI-Technologien kein Selbstzweck sind, sondern dazu dienen sollen, unser Wohlbefinden und unsere Selbstbestimmung und Freiheit zu steigern. Menschenzentriertheit bedeutet hier allerdings nicht, die Aufmerksamkeit nur auf den Einzelnen zu lenken, sondern auch auf das Wohlergehen der Gesellschaft insgesamt sowie auf die Umwelt, in der wir leben.

In der Expert*innengruppe haben wir insgesamt sieben Anforderungen³ an eine vertrauenswürdige KI-Technologie erarbeitet, die über die Einhaltung der bestehenden relevanten Gesetze hinausgehen. In Anlehnung an Abb. 1 können diese Anforderungen wie in Abb. 3 gegliedert werden.

Die Qualität automatisierter Entscheidungen hängt wesentlich von der Qualität der Daten ab, die für die Modellbildung und für die Entwicklung von Algorithmen herangezogen werden. Dabei sind die **Sicherstellung von Qualität und Integrität der Daten** sowie der Zugang zu relevanten Daten oftmals eine große Herausforderung. Darüber

³Vgl. AI HLEG 2019, <https://ec.europa.eu/digital-single-market/en/news/ethics-guidelines-trustworthy-ai>.



Abb. 3 Anforderungen an vertrauenswürdige Künstliche-Intelligenz-Systeme. (Nach HLEG AI 2019)

hinaus müssen Systementwickler*innen sicherstellen, dass immer dann, wenn personen-bezogene Daten benutzt werden, die Achtung und der **Schutz der Privatsphäre** sichergestellt sind.

Bevor Systeme in der Praxis implementiert werden können, müssen ihre **technische Robustheit und ihre Sicherheit** gewährleistet sein. Technisch robust sind automatisierte Entscheidungssysteme dann, wenn sie genau, zuverlässig und ihre Ergebnisse reproduzierbar sind. Neben der Datensicherheit müssen diese Systeme auch gegen Angriffe von außen sowie gegen die Manipulation von Daten oder Algorithmen resistent sein.

Die Kriterien **Transparenz, Kontrolle und Verantwortung** sind eng miteinander verknüpft. Transparenz und Erklärbarkeit von Modellbildung, Entscheidungskriterien und Methoden sind wichtige Qualitätskriterien, die insbesondere bei automatisierten Entscheidungssystemen mit implementierten maschinellen Lernansätzen derzeit nicht gewährleistet sind. Für die Nachvollziehbarkeit einer Entscheidung oder Prognose ist nicht nur die Verständlichkeit auf der Ebene des Gesamtmodells erforderlich, sondern auch in Bezug auf einzelne Komponenten und auf der Ebene des Algorithmus (Lipton 2016). Das Problem dabei ist, dass Transparenz eines Systems nicht unbedingt Verständlichkeit bedeutet. Vor allem für Nichtexpert*innen sind intuitive Erklärungen erforderlich, um sie nicht zu überfordern (vgl. Papagni und Koeszegi 2021). Allerdings gibt es bei KI-Systemen einen Trade-off zwischen Transparenz und Genauigkeit von Vorhersagen (vgl. Hagrais 2018). Hier ist gegebenenfalls im Anwendungsfall abzuwägen, welcher der Anforderungen – Transparenz oder Genauigkeit – mehr Gewicht beizumessen ist.

Nur wenn Anwender*innen die Ziele von KI-Systemen kennen, ihre Entscheidungsprozesse nachvollziehen und verstehen können, sind sie auch in der Lage, zu entscheiden, ob sie diese Systeme überhaupt nutzen und die Verantwortung für mögliche positive wie negative Konsequenzen übernehmen wollen. Wie dieser Aufsatz zeigt, bringt die Zuschreibung von Handlungsmacht an automatisierte Entscheidungssysteme und die daraus resultierende Gefahr der Verhaltensmanipulation durch diese Systeme dieses **Grundrecht der Autonomie und Selbstbestimmung** in Bedrängnis. Die Anforderungen an KI-Systeme sind daher, auf alle manipulativen Taktiken des Verhaltensengineerings zu verzichten und bei der Entwicklung dieser Systeme die Veränderungen des Rollengefüges zwischen Menschen und Maschinen aus einer soziotechnischen Perspektive zu berücksichtigen. Auch wenn im Anwendungsfall verschiedene Formen der menschlichen Kontrolle über KI-Systeme implementiert werden können, ist jedenfalls immer sicherzustellen, dass Menschen zu jeder Zeit Kontrolle über den Einsatz dieser Systeme haben. Dies umschließt auch ein Opt-out Recht, also das Recht, die Nutzung dieser Systeme abzulehnen. Schließlich muss die **Verantwortlichkeit** für die Konsequenzen der Nutzung von KI-Systemen eindeutig geregelt sein. Bevor KI-Systeme eingesetzt werden können, muss sichergestellt sein, dass mögliche negative Konsequenzen für einzelne Menschen sowie für die Gesellschaft als Ganzes ausgeschlossen oder zumindest minimiert werden. Zudem sind für den Fall des Eintretens negativer Konsequenzen entsprechende Rechtsmittel zur Durchsetzung der Rechte von Betroffenen zu gewährleisten.

Die letzten beiden Kriterien beziehen sich auf die Zielsetzungen von KI-Systemen. **Vielfalt, Nichtdiskriminierung und Fairness** sowie **gesellschaftliches und ökologisches Wohlergehen** müssen bei der Implementierung von KI-Systemen höchste Priorität haben.

Die Implementierung dieser Anforderungen, die hier nur sehr oberflächlich dargestellt werden können, ist eine große Herausforderung. Die Dringlichkeit dieser Anforderungen ist allerdings nur zum Teil im öffentlichen Diskurs angekommen. Während die Notwendigkeit der Sicherung der Privatsphäre und Datenschutz durch die Datenschutz-Grundverordnung einen ersten wichtige regulatorischen Rahmen erfährt, wird über die Sicherung unseres Grundrechts auf Freiheit und Selbstbestimmung leider noch sehr wenig diskutiert. Die Konsequenzen einer vermehrten Delegation von Entscheidungen an Maschinen sind sicherlich kontextabhängig, führen aber – wie diese Analyse zeigt – zu einer empfindlichen Einschränkung unserer Selbstbestimmung sowie zu einer stärkeren Abhängigkeit von Technologien, die zum heutigen Stand der Forschung wenig transparent und damit für Anwender*innen schwer nachvollziehbar sind. Aus diesem Grund fehlt oft das grundlegende Problembewusstsein. Aussagen, wie „Ich habe kein Problem, wenn sie Daten über mich sammeln, ich habe keine Geheimnisse“ oder „Welche Musik ich höre, welche Nachrichten ich lese und welche Produkte ich kaufe, entscheide immer noch ich! Der Algorithmus weist mich nur darauf hin, was für mich interessant sein könnte“ machen evident, dass es einen enormen Aufklärungsbedarf über die Wirkungsweise von automatisierten Entscheidungssystemen gibt.

Wir haben aufgezeigt, dass automatisierte Entscheidungssysteme keine effizienten, objektiven Rechensysteme sind, sondern soziotechnische Ensembles, die für die gleichen Probleme bei der Entscheidungsfindung anfällig sind wie Menschen. Wenn wir Entscheidungsunterstützungssysteme entwickeln wollen, die die Menschen in ihrer Würde respektieren und sie in ihrer Freiheit und in ihrem Wohlbefinden – individuell und als Gesellschaft – stärken, dürfen wir diese Systeme nicht isoliert betrachten, sondern müssen sie in ihrem jeweiligen Anwendungskontext als soziotechnisches System verstehen und sorgsam gestalten. Es steht nicht weniger auf dem Spiel als unsere Selbstbestimmtheit, unsere Demokratie und unsere Freiheit!

Weiterführende Literatur

- AW Algorithm Watch (2019) Automating society: taking stock of automated decision-making in the EU. www.algorithmwatch.org/automating-society. Zugegriffen: 28. Febr. 2020
- Agrawal J, Gans J, Goldfarb A (2018) Prediction machines: the simple economics of artificial intelligence. Harvard Business Review Press, Boston Massachusetts
- Bainbridge Lisanne (1983) Ironies of automation. *Automatica* 19(6):775–779. [https://doi.org/10.1016/0005-1098\(83\)90046-8](https://doi.org/10.1016/0005-1098(83)90046-8)
- Balkow C, Eckardt I (2019) „Bias in Algorithmischen Systemen – erläuterungen, Beispiele und Thesen.“ „Denkimpulse digitale Ethik“, Initiative D21. https://initiated21.de/app/uploads/2019/03/algomon_denkimpuls_bias_190318.pdf
- Bond R, Fariss CJ, Jones JJ, Kramer ADI, Marlow C, Settle JE, Fowler JH (2012) A 61-Million-Person Experiment in Social Influence and Political Mobilization. *Nature* 489:295–298
- Collingridge D (1981) The social control of technology. Milton Keynes, Eng. Open University Press
- Council of Europe (2018) Algorithms and Human Rights: Study on the Human Rights Dimensions of Automated Data Processing Techniques and Possible Regulatory Implications DGI (2017)12. <https://rm.coe.int/algorithms-and-human-rights-en-rev/16807956b5>. Zugegriffen: Febr. 2020
- Dignum V, Muller C, Theodorou A (2020) First Analysis of the EU Whitepaper on AI. <https://allai.nl/first-analysis-of-the-eu-whitepaper-on-ai/>. Zugegriffen: 26. Febr. 2020
- Gillespie T (2016) Algorithm. In: Peters B (Hrsg) Digital keywords: a vocabulary of information society and culture. Princeton University Press, Princeton, S 18–30
- Hagras H (2018) Toward Human-Understandable, Explainable AI. *Computer* 51(9):28–36
- High-Level Expert Group on Artificial Intelligence (2019) Ethics Guidelines for Trustworthy AI, source. <https://ec.europa.eu/digital-single-market/en/news/ethics-guidelines-trustworthy-ai>. Zugegriffen: 28. Febr. 2020
- Ionos, Digital Guide (2020) Cookie Richtlinie. <https://www.ionos.at/digitalguide/websites/online-recht/cookie-richtlinie/>. Zugegriffen: 25. Febr. 2020
- Kosinski M, Stillwell D, Graepel T (2013) Private traits and attributes are predictable from digital records of human behavior. *PNAS* 110(15):5801–5805
- Kramer ADE, Guillory JE, Hancock JT (2014) Experimental evidence of massive scale emotional contagion through social networks. *PNAS* 111(24):8788–8790
- Lipton, ZC (2016) The mythos of model interpretability. In: ICML Workshop on Human Interpretability in Machine Learning (WHI 2016), New York, arXiv:1606.03490 1470 arXiv:cs, stat/1606.03490

- Logga JM, Minsona JA, Moore DA (2019) Algorithm appreciation: people prefer algorithmic to human judgment. *Organ Behav Hum DecisProcess* 15:90–103
- Molnar P, Gill L (2018) Bots at the gate: a human rights analysis of automated decision-making in Canada's immigration and refugee system. University of Toronto, Research 114
- Papagni G, Koeszegi ST (2021) Understandable and trustworthy explainable robots: a sensemaking perspective. *Paladyn. Journal of Behavioral Robotics* 12. <https://doi.org/10.1515/pjbr-2021-0002>
- Thaler R, Sunstein CR (2008) *Nudge: improving decisions about health, wealth, and happiness*. Yale University Press, ISBN 978-0-14-311526-7
- Tufekci Z (2015) Algorithmic harms beyond Facebook and Google: emergent challenges of computational agency. *Colo Tech L J* 13:203–218
- Wihlborg E, Larsson H, Hedström K (2016) “The Computer Says No!”– A Case Study on Automated Decision-making in Public Authorities. *IEEE Computer Society, Proceedings of HICCS 2016*:2903–2912. <https://doi.org/10.1109/HICCS.2016.364>
- Wouters N, Kelly R, Velloso E, Wolf K, Ferdous HS, Newn J, Joukhadar Z, Vetere F (2019) Biometric mirror: exploring values and attitudes towards facial analysis and automated decision-making. *Conference on Designing Interactive Systems*, 1145
- Zuboff S (2018) *Das Zeitalter des Überwachungskapitalismus*. Campus, Frankfurt

Sabine Theresia Koeszegi ist seit 2009 Professorin für Arbeitswissenschaft und Organisation am Institut für Managementwissenschaften der TU Wien. Sie hat ein Doktorat in Sozial- Wirtschaftswissenschaften sowie eine Venia für das Fach Betriebswirtschaftslehre der Universität Wien. Ihre Forschungsschwerpunkte liegen in der Schnittmenge von Technologie, Arbeit und Organisation. Aktuell arbeitet sie an einem internationalen Forschungsprojekt der Universität Aarhus zu integrativer sozialer Robotik und leitet das Doktoratskolleg TrustRobots an der TU Wien. Seit August 2017 ist Sabine Theresia Koeszegi Vorsitzende des Österreichischen Rats für Robotik und Künstliche Intelligenz und seit Juni 2018 ist sie Mitglied der High Level Expert Group on Artificial Intelligence der Europäischen Kommission.

Warum wir der künstlichen Intelligenz nicht blind vertrauen dürfen – fünf Ansätze um künstliche Intelligenz zu beherrschen

Helmut Leopold

1 Künstliche Intelligenz – Eine Einführung

1.1 Entwicklung der Künstliche-Intelligenz-Forschung

Die Menschheit versuchte immer schon, durch Einsatz von Maschinen die Arbeitslast zu verringern. Dabei war es das Ziel, schwere, eintönige oder immer wiederkehrende Arbeitsschritte durch Maschinen zu automatisieren. Mit dem Einsatz von Software und Digitaltechnik kam die Diskussion über ein mögliches intelligentes menschliches Verhalten von softwaregesteuerten Maschinen auf und seither beflügelt die Grundsatfrage, ob Maschinen ein intelligentes menschliches Verhalten aufweisen können, philosophische Diskussionen (Reichl et al. 2020). Die Filmindustrie leistete ihren Beitrag dazu und machte höchst intelligente und durchaus auch emotional agierende Roboter einem breiten Publikum eindrucksvoll bekannt. Damit stellte sich die Frage, ob Maschinen eines Tages die Fähigkeiten und die Intelligenz der Menschheit durch eine technische Superintelligenz überbieten werden können.

Expert*innen aus verschiedensten Wissenschaftsdisziplinen haben sich von Beginn an mit dieser Thematik auseinandergesetzt und Alan Turing, ein Pionier der Informatik, hat bereits 1950 mit dem sogenannten Turing-Test einen Ansatz definiert, um intelligentes Verhalten von Maschinen feststellen zu können (Turing 1950). Er postulierte, dass, wenn bei einem Frage- und Antwortspiel mit einem System nicht unterschieden werden kann,

H. Leopold (✉)

Head of Center for Digital Safety & Security, AIT Austrian Institute of Technology,
Wien, Österreich

E-Mail: helmut.leopold@ait.ac.at

ob die Antworten von einem Menschen oder einer Maschine kommen, das System als intelligent bezeichnet werden kann. Das Prinzip des Turing-Tests hat heute noch seine praktische Anwendung im CAPTCHA-Test (Nations 2020), bei dem verzerrte optische Zeichen bei Login-Vorgängen durch den menschlichen Benutzer korrekt erkannt werden müssen, um zu verhindern, dass Maschinen unbemerkt einen Login-Vorgang durchführen können.

Im Jahr 1956, also vor mehr als 60 Jahren, hat John McCarthy gemeinsam mit ein paar weiteren Wegbereitern der Informatik durch die Organisation einer Konferenz unter dem Namen *Dartmouth Summer Research Project on Artificial Intelligence* den heute allgegenwärtigen Begriff der künstlichen Intelligenz (KI) von Maschinen begründet (Manhart 2018).

Im Zuge der Entwicklung der Informatik als Wissenschaftsdisziplin ging man über Jahrzehnte der Fragestellung nach, welche kognitiven Fähigkeiten intelligentes Verhalten bestimmen und welche Grundfunktionen intelligente Fähigkeiten von Maschinen ausmachen. Eine Zielrichtung der KI-Forschung war immer schon, dass neben logischen und regelbasierten Algorithmen neue Ansätze gesucht wurden, um mit Unsicherheiten und sogar Widersprüchen in Daten umgehen zu können. Vor allem die Erkenntnis der Kognitionsforschung, dass das richtige Tun nicht immer aufgrund einer komplett vorhandenen Datenlage erfolgen kann, beflügelte die Entwicklung der Disziplinen Kognitionswissenschaften und kognitive Neurowissenschaften. Parallel hat sich in der Informatik ein Hype entwickelt, um die Intelligenz des Menschen zu verstehen und künstliche Intelligenz durch Computer nachzubauen.

Maschinelles logisches Denken, menschenähnliche Problemlösung und Entscheidungsfindung sowie Lernen aus Erfahrung in verschiedenen Anwendungsszenarien wurde immer wieder neu ausgelotet. Bereits die Anfangsphase der KI-Forschung in den 1960er-Jahren war durch eine Euphorie über die Leistungsfähigkeit von Computern geprägt. Seither durchlief die KI-Forschung viele Höhen und Tiefen und es wechselten Epochen mit vielen Aktivitäten mit Perioden der Vernachlässigung, die meist nach Rückschlägen auftraten (sogenannte KI-Winter). So erfüllte sich z. B. die Prognose von Wirtschaftsnobelpreisträger Herbert A. Simon aus dem Jahr 1957, wonach Computer binnen zehn Jahren in der Lage sein würden, Schachweltmeister zu werden, erst 1997, also 40 Jahre später, als das von IBM entwickelte System „Deep Blue“ den damaligen Schachweltmeister Garri Kasparov in sechs Partien schlug. Es hat dann weitere 18 Jahre gedauert, bis 2015 dann das Schachprogramm Giraffe in der Lage war, in 72 Stunden Schach auf Meisterniveau zu erlernen¹, und AlphaGo, von der Firma Google DeepMind, gegen den Europameister im Go-Spiel gewann (Silver et al. 2017). Beim Go-Spiel geht man von einer Lernzeit von zwei Jahren für einen Menschen

¹In drei Tagen zum Internationalen Schachmeister, Spiegel, 17.9.2015, <https://www.spiegel.de/netzwelt/web/kuenstliche-intelligenz-computer-lernt-in-72-stunden-schach-a-1053338.html> (letzter Zugriff am 22.09.2020).

aus, das KI-System brauchte dazu nur wenige Wochen. Schließlich gewinnt 2017 ein KI-System von OpenAI, einem Unternehmen von Elon Musk, gegen Menschen im Computerspiel Dota-2². Im Jahr 2017 wurde sogar eine KI-Anwendung entwickelt, um die Handlung des Fantasy-Epos *Games of Thrones* von George R.R. Martin fortzuschreiben³. Dabei wurde der Computer mit den Inhalten der ersten fünf Bände gespeist. Das lernfähige KI-Programm konnte sich Stil, besondere Ausdrucksweise und gern verwendete Redewendungen des Autors aneignen und die einzelnen Charaktere fortentwickeln und sogar neue Figuren erfinden.

Mittlerweile kommen immer mehr KI-Systeme in unterschiedlichsten Anwendungsgebieten zum Einsatz, da mit ihnen immer wieder bessere Ergebnisse erzielt werden als mit herkömmlichen Lösungsansätzen. Bekannte praktische Einsätze sind Mustererkennung bei Objekten für Kameras von autonomen Fahrzeugen (z. B. Google, Tesla, und Mobileye), Spracherkennungssysteme wie Alexa (Amazon), Siri (Apple), Bixby (Samsung), Assistant (Google) und Cortana (Microsoft) sowie Googles Übersetzungssystem.

Weitere Anwendungsbereiche für KI-Systeme sind Chatbots⁴ als komfortable Kundenschnittstelle für Hotlines, Online-Verkauf und Kundenservices oder auch neue Schutzmethoden, um unsere digitalen Systeme vor immer ausgefeilteren Cyberangriffen zu schützen (Leopold et al. 2015), und schließlich vielfältige Einsatzgebiete im Industriebereich, wie Verbesserungen von Produktions- und Wartungsprozessen, um nur ein paar Beispiele zu nennen. Kaum ein Anwendungsbereich wird heute nicht durch KI-Lösungen bearbeitet.

1.2 Künstliche Intelligenz made in Austria

KI-Forschung gibt es in Österreich schon seit den 1980er-Jahren. Bereits im Jahr 1984 wurde das Österreichische Forschungsinstitut für Artificial Intelligence (OFAI) unter der Leitung des KI-Pioniers Prof. Trappl gegründet⁵. Ebenso wurden erste Expertensysteme bereits in den 1990er-Jahren vom damaligen Alcatel-ELIN-Forschungszentrum erfolgreich entwickelt, die sich bis heute als global eingesetzte Technologie für die höchstzuverlässige Steuerung von Bahnstellwerken gehalten haben (Leitner 2003, S. 268f.).

²KI von Elon-Musk-Startup zerstörte bei Computerspiel-Duell weltbesten Spieler, DerStandard, 12.8.2017, <https://derstandard.at/2000062596518/KI-von-Elon-Musk-Startup-zerstoerte-bei-Computerspiel-Duell-weltbesten> (letzter Zugriff am 22.09.2020).

³Computer schreibt sechstes Buch von Game of Thrones, Frankfurter Allgemeine, 30.8.2017, <https://www.faz.net/aktuell/wirtschaft/kuenstliche-intelligenz/game-of-thrones-kuenstliche-intelligenz-schreibt-sechstes-buch-15175025.html> (letzter Zugriff am 22.09.2020).

⁴Kunstwort aus „chat“ (Plaudern) und „bot“ (Roboter).

⁵www.ofai.at (letzter Zugriff am 22.09.2020).

Eine grundlegende Technologieentwicklung für heutige KI-Systeme wurde 1997 von Sepp Hochreiter, Leiter des KI-Labs am Linz Institute of Technology (LIT) der Johannes-Kepler-Universität (JKU), und Jürgen Schmidhuber, Leiter von IDSIA, einem schweizerischen Forschungsinstitut für KI, erfolgreich umgesetzt. Sie entwickelten die grundlegende KI-Technologie „long short-term memory“ (LSTM), mit der es möglich wurde, sehr große Datenmengen effektiv für lernende KI-Systeme zu verarbeiten.

Am AIT Austrian Institute of Technology im Center for Digital Safety & Security konnten in den letzten Jahren mehrere international führende KI-Initiativen erfolgreich etabliert werden (Hintermayer 2020, S. 96–99), wie z. B. Analyse von sehr großen Bild- und Audiodaten zur öffentlichen Sicherheit und zum Schutz kritischer Infrastrukturen⁶, Analyse von sehr großen Textdateien in der Ermittlung von Cyberkriminalität⁷, Verkehrsanalysen von sehr großen Datenmengen im Internet und in Telekomnetzwerken⁸, Analyse von großen heterogenen Datenstrukturen in historischen Dokumenten, effektive Spracheingabe für moderne Dokumentenmanagementsysteme⁹, selbstlernende Anomalieerkennung in IT-Systemen, um ausgefinkelte Cyberangriffe frühzeitig erkennen zu können¹⁰ (Leopold et al. 2015), neue Analysemethoden in Text-, Bild- und Audioinhalten im Internet zur Bekämpfung von Fake-Shops¹¹ und Diskriminierung¹² und Erkennung von Fake-News und Desinformation¹³. Schließlich setzte das Center einen Forschungsschwerpunkt zur Frage der Erklärbarkeit und Überprüfbarkeit von KI-Systemen, vor allem für sicherheitskritische Bereiche als grundlegende Thematik zur Weiterentwicklung der KI.

Neben OFAI, JKU, und AIT gibt es in Österreich weitere international anerkannte Forschungseinrichtungen und Firmen im Bereich KI, wie z. B. das Know-Center an der TU Graz¹⁴, das Institut für Grundlagen der Informationsverarbeitung an der TU Graz

⁶KIRAS Projekt FLORIDA – *Flexibles, teilautomatisiertes Analysesystem zur Auswertung von Videomassendaten nach Terroranschlägen*, <https://www.kiras.at/gefoerderte-projekte/detail/d/florida/> und EU Projekt VICTORIA – *Video analysis for Investigation of Criminal and Terrorist Activities*, <https://www.victoria-project.eu/> (letzte Zugriffe am 22.09.2020).

⁷EU H2020 Projekt COPKIT, <https://copkit.eu/> (letzter Zugriff am 22.09.2020).

⁸WWTF-Projekt Big-DAMA – *Big Data Analytics for network traffic Monitoring and Analysis*, <https://bigdama.ait.ac.at/> (letzter Zugriff am 22.09.2020).

⁹Forschungsprojekt "Natural Language Search" erfolgreich abgeschlossen, 06.03.2018, <https://www.pressebox.de/pressemitteilung/ser-gruppe/Forschungsprojekt-Natural-Language-Search-erfolgreich-abgeschlossen/boxid/896124> (letzter Zugriff am 22.09.2020).

¹⁰KIRAS Projekt CAIS *Cyber Attack Information System*, <https://www.kiras.at/gefoerderte-projekte/detail/d/cais-cyber-attack-information-system/> (letzter Zugriff am 22.09.2020).

¹¹FFG Forschungsprojekt „Mal2“, <https://www.malzwei.at/> (letzter Zugriff am 22.09.2020).

¹²FFG Forschungsprojekt „Primming“, <https://projekte.ffg.at/projekt/3280774> (letzter Zugriff am 22.09.2020).

¹³KIRAS Projekt „Defalsif-AI – *Detektion von Falschinformationen mittels Artificial Intelligence*“, www.defalsifai.at

¹⁴<https://www.know-center.tugraz.at/en/> (letzter Zugriff am 22.09.2020).

unter der Leitung von W. Maass¹⁵, Institute der TU Wien und viele andere mehr. Einen Überblick über alle KI-Akteure in Österreich ist in EnliteAI (2020) zu finden, in der 193 Organisationen angeführt sind.

Schließlich wurde 2018 mit der „Artificial Intelligence Mission Austria 2030“ ein umfassender Diskurs zur Erarbeitung einer nationalen KI-Strategie durch die breite Einbindung vieler Stakeholder gestartet (AIM 2018).

1.3 Künstliche Intelligenz braucht leistungsfähige Hardware

Der aktuelle Hype über die beeindruckende Leistungsfähigkeit der KI-Algorithmen geht vor allem mit der Verfügbarkeit von sehr leistungsstarken und günstigen Prozessoren und Speicherkapazitäten einher. Effektive KI-Algorithmen bauen auf sehr großen Datenmengen auf, die verarbeitet werden müssen. Typischerweise müssen für KI-Lernprozesse mehrere Millionen Parameter in kürzester Zeit berechnet werden, was erst durch die heute verfügbaren Parallelrechentechnologien effektiv durchgeführt werden kann.

Vor allem die Computerspieleindustrie mit ihrer Anforderung an sehr leistungsstarke Prozessoren zur Bearbeitung von hochauflösenden dynamischen Grafiken und Bildern hat einen wesentlichen Anteil am aktuellen Durchbruch der KI-Technologie. Im Zuge der weltweiten Verbreitung von Computern, aber vor allem auch durch den weltweiten Markterfolg von Computerspielen wurde für Spielkonsolen spezielle Hardware entwickelt, die die beeindruckenden Grafikeffekte auf den Bildschirmen möglich macht. Diese speziellen, leistungsfähigen Grafikkarten mit eigenen Prozessoren – sogenannten Graphic Processing Units (GPU) – zeichnen sich durch eine sehr effiziente Verarbeitung von parallelen Rechenoperationen aus. Diesem Siegeszug der Spielkonsolen verdanken sich hohe Stückzahlen dieser Prozessoren, was wiederum zu günstigen Stückpreisen führte. Damit sind potente Rechenleistungen wirtschaftlich verfügbar und können in verschiedensten KI-Anwendungen eingesetzt werden.

Die Entwicklung von leistungsfähigen Prozessoren verläuft rasant weiter und viele Hersteller entwickeln neue KI-Spezialhardware¹⁶: Tensor Processing Unit (TPU)¹⁷ von Google; TrueNorth Neuromorphic Chip von IBM; AMD mit der 2006 gekauften Firma

¹⁵ <https://igi-web.tugraz.at/people/maass/> (letzter Zugriff am 22.09.2020).

¹⁶ Bei modernen Prozessortechnologien werden Milliarden Transistoren auf einem Quadratzentimeter verbaut.

¹⁷ An in-depth look at Google's first Tensor Processing Unit (TPU), Google Cloud Blog, <https://cloud.google.com/blog/big-data/2017/05/an-in-depth-look-at-googles-first-tensor-processing-unit-tpu> (letzter Zugriff am 22.09.2020).

ATI; 2017 kaufte Intel die Unternehmen Nervana und Mobileye^{18,19}; und schließlich ist Huawei mit dem Mate 10 Pro und dem hauseigenen Prozessor Kirin 970 ebenfalls in diesen internationalen Wettlauf eingestiegen. Auch werden laufend neue Start-ups in diesem High-end-Prozessorenbereich für unterschiedliche Märkte aktiv, wie KnuEdge, Eyeriss, krtkl, Graphcore, BrainChip, TeraDeep, Wave Computing, Horizon Robotics, NeuRAM3, P-Neuro, und SpiNNaker, um nur die wichtigsten zu nennen²⁰.

1.4 Formen der künstlichen Intelligenz: Von regelbasierten Systemen zu neuronalen Netzen

Erste intelligente Systeme erzielte man durch den erfolgreichen Einsatz von regelbasierten Expertensystemen bereits in den 1980er-Jahren unter Verwendung von Datenbanken, logischen Entscheidungsbäumen und mathematischen Funktionen. Mit der Verfügbarkeit von großen Datenmengen wurden dann auch heuristische Regeln wie statistische Auswertungen, Zufallsstichproben und Ausschlussverfahren wichtige Ansätze, um Datenanalysen durchzuführen und intelligentes Systemverhalten zu erreichen.

Ein entscheidender Nachteil von regelbasierten Systemen ist der Umstand, dass die Regelbasis mit größeren Problemstellungen sehr rasch anwächst und dadurch unverständlicher und immer schwerer wartbar wird. Durch die Verfügbarkeit der neuen leistungsfähigen Prozessoren, die eine sehr hohe Anzahl von parallelen Verarbeitungsschritten unterstützen, können auch aufwendige Datenverarbeitungsprozesse wie computerbasierte neuronale Netze (NN) nun effizient berechnet werden. Bei diesen speziellen Verfahren wird versucht, die Funktionsweise des menschlichen Gehirns nachzubilden und die Datenverarbeitung äquivalent zu den neuronalen Netzen unseres Gehirns durchzuführen; d. h. Information wird durch Verbindungsstrukturen zwischen einzelnen Neuronen mit verschiedenen Gewichtungen und Regeln zur Aktivierung von einzelnen Neuronen abgebildet. Solche Systeme werden auch „deep learning networks“ genannt.

¹⁸Intel zahlt 15,3 Mrd. Dollar für Autozulieferer, Handelsblatt, 13.03.2017, <https://www.handelsblatt.com/unternehmen/it-medien/mobileye-intel-zahlt-15-3-milliarden-dollar-fuer-autozulieferer/19508066.html> (letzter Zugriff: 22.9.2020).

¹⁹Nicole Hemsoth, *Intel, Nervana Shed Light on Deep Learning Chip Architecture*, January 11, 2018, <https://www.nextplatform.com/2018/01/11/intel-nervana-shed-light-deep-learning-chip-architecture/> (letzter Zugriff am 22.9.2020).

²⁰A List of Chip/IP for Deep Learning, 11.8.2017, <https://medium.com/@shan.tang/g/a-list-of-chip-ip-for-deep-learning-48d05f1759ae> (letzter Zugriff am 22.09.2020).

1.5 Maschinelles Lernen

KI-Systeme bauen auf verschiedenen Ansätzen der Informatik auf und berücksichtigen verschiedenste mathematische Modelle und Algorithmen. Vor allem die computerbasierten neuronalen Netze zeigen eine besondere Leistungsfähigkeit zur Lösungsfindung von Problemstellungen in ganz konkreten und limitierten Einsatzgebieten. Die Lernprozesse von neuronalen Netzen sind eine neue faszinierende Datenverarbeitungsmethode und werden im Folgenden kurz zusammengefasst.

1.5.1 Supervised Learning, Trainingsdaten und Ground Truth

Um die Parameter der Neuronenverbindungen in computerbasierten neuronalen Netzen zu erlernen, werden entsprechende Trainingsdaten benötigt. Ein Lernen erfolgt dabei durch die Veränderung der Gewichtung von Verbindungen. Information wird dadurch in Millionen Verbindungen von Neuronen gespeichert. Die Verbindungen verändern sich durch die Berücksichtigung neuer Daten. Somit wird ein Modell der realen Welt nicht mehr durch eine mathematische Formel oder eine analytische Beschreibung erstellt, wie bisher bei herkömmlichen Softwareprogrammen, sondern durch Trainingsdaten und Feedback-Mechanismen. Dadurch wird eine Erfahrung des Systems realisiert. Dies entspricht durchaus dem Konzept des Lernens von uns Menschen; d. h. Vokabeln werden durch mehrmaliges Wiederholen gelernt. Da dem technischen System das konkrete Ergebnis mit den passenden Lerndaten zur Verfügung gestellt wird, wird dieser Vorgang „supervised learning“ genannt.

In KI-Systemen, die auf neuronalen Netzen aufbauen, erfolgt somit ein maschinelles Lernen durch Berechnungen der Parameter der neuronalen Netze aufgrund von Trainingsdaten. Um zuverlässige Ergebnisse für echte Anwendungen zu erhalten, werden nun große Mengen von Trainingsdaten benötigt, wobei die Bedeutung der Daten, nach denen das neuronale Netz trainiert werden soll, für die jeweilige Anwendung bekannt sein muss. D. h. es braucht Expert*innen, die die vorhandenen Daten entsprechend beurteilen und kennzeichnen, um eine sogenannte „ground truth“ in den Trainingsdaten zu bestimmen.

Zusammenfassend haben wir somit drei grundlegende Problemstellungen für einen erfolgreichen Einsatz von KI-Systemen zu beachten.

Es braucht große Datenmengen, um die Algorithmen zu trainieren. Dies erklärt den seit Jahren verfolgten Ansatz von Google in verschiedenen Anwendungsbereichen Daten zu sammeln. Durch das Google-Auto mit umfassender Sensorik zum autonomen Fahren, durch Google-Translate für die Übersetzungen von Text in die verschiedensten Sprachen, als auch durch Googles Spracherkennungssysteme werden laufend Datensätze in sehr großer Anzahl gesammelt, um die Genauigkeit der KI-Systeme laufend zu verbessern.

Dann braucht es spezifisches Domänenwissen, um die vorhandenen Datensätze für den jeweiligen Anwendungsfall zu bewerten und entsprechend zu annotieren. In vielen Bereichen sind solche von Expert*innen beschriebenen und beurteilten Datensätze

für die KI-Forschung und Anwendungsentwicklung durch die globale Forschungscommunity entstanden, wie z. B. der MAWI-Datensatz für Internetverkehr²¹, oder die Audiodatensätze zur Geräuscherkennung von Google bei der über zwei Millionen von Menschen annotierte kurze Audiofiles für die KI-Forschung zur Verfügung stehen²². Für viele neue Anwendungsgebiete ist es nun notwendig, entsprechende Trainingsdaten zu entwickeln und über aufwendige Arbeit durch menschliche Expertise zu beurteilen und zu bewerten.

Nach der Festlegung des „ground truth“ und der nachfolgenden „feature extraction“ – und der Festlegung, welche Parameter in welcher Weise eine Bedeutung haben – in Lerndaten durch Expert*innen mit Domänenwissen, ist die Modellbildung der dritte wichtige Bereich der KI-Technologieentwicklung. Neben traditionellen Machine-Learning-Ansätzen wie lineare Modelle, die einfache mathematische Funktionen sind, werden auch unterschiedlichste Architekturen von neuronalen Netzen verwendet; wie z. B. neuronale Netze mit Rückkopplungseffekten, sogenannte „re-current“ neuronale Netze. Weiterhin können die Berechnungen der Stimulierungsfunktionen der Neuronen nach unterschiedlichsten mathematischen Funktionen durchgeführt werden.

1.5.2 Unsupervised Learning

In einem Unsupervised-learning-Szenario braucht es keine „ground truth“ der Trainingsdaten. Hier lernt das System nur Muster in den verfügbaren Daten. Das Ergebnis von Unsupervised-Lernansätzen ist im Wesentlichen immer eine Form von Daten-Clustering²³.

Bei Unsupervised-Lernansätzen kann ein KI-System einen Normalzustand eines Systems feststellen, um dann später Abweichungen davon, d. h. Anomalien, zu erkennen. Eine wichtige Herausforderung für solche Ansätze ist, dass potenzielle Anomalien nicht bereits in den Lerndaten enthalten sind. Dies ist eine oft nicht ganz einfach erfüllbare Anforderung.

1.5.3 Reinforcement Learning

„Reinforcement learning“ ist, neben den Supervised- und Unsupervised-Lernansätzen, ein dritter Ansatz von KI-Algorithmen. Beim Reinforcement Learning wird im Gegensatz zum Supervised Learning nicht ein im Vorhinein definiertes Ergebnis durch Trainingsdaten gelernt, sondern das KI-System wird durch ein permanentes Feedback von Belohnung und Bestrafung trainiert. Zum Beispiel wird „auf eine heiße Herdplatte greifen“ schmerzhaft sein und dem System wird ein negatives Feedback gegeben. Somit

²¹ <https://en.wikipedia.org/wiki/MAWI> (letzter Zugriff am 22.9. 2020).

²² A large-scale dataset of manually annotated audio events, <https://research.google.com/audioset/> (letzter Zugriff am 22.09. 2020).

²³ Um ähnliche Daten in Cluster zu gruppieren, werden z. B. der k-Means-Algorithmus oder auch die Methode der hierarchischen Cluster verwendet.

gibt es prinzipiell keine richtige oder falsche Antwort, sondern es gibt eine Zielsetzung und das KI-System lernt aus der laufenden Erfahrung, in den Versuchen dieses Ziel zu erreichen.

Beim Deep Reinforcement Learning geht es um ein Finetuning eines mit bestimmten Lerndaten vortrainierten neuronalen Netzes, das im Betrieb mit Echtzeiten laufend verfeinert wird.

2 Fünf Herausforderungen künstlicher Intelligenz

Wie im vorigen Abschnitt zusammengefasst, haben neue KI-Ansätze durch die Entwicklung von Techniken der Informationsverarbeitung von großen Datenmengen und der Verfügbarkeit von kostengünstiger sehr leistungsfähiger Hardware einen neuen Hype der KI-Technologie ausgelöst. In der Tat erzielen KI-Systeme oft verblüffend bessere Ergebnisse als bisherige herkömmliche IT-Lösungsansätze.

Dadurch lag bisher der Fokus in der KI-Entwicklung auf den möglichen positiven Aspekten in den verschiedenen Anwendungsbereichen. Hierbei ist es wichtig zu bemerken, dass im praktischen Alltag ein Großteil der KI-Anwendungen im einfachen Ausprobieren von verschiedenen neuronalen Netzen besteht; d. h. die vorhandenen Daten werden in verfügbare KI-Anwendungen eingespielt und es wird beobachtet, welche Ergebnisse mit einem bestimmten Neuronales-Netz-Ansatz erzielt werden. Wenn das Ergebnis zufriedenstellend ist, geht man üblicherweise davon aus, dass die Anwendung im echten Einsatz auch funktioniert.

Um aber einerseits effektive und zuverlässig funktionierende KI-Systeme zu erhalten und andererseits KI-Technik verantwortungsvoll zu entwickeln und eine Beherrschbarkeit der Technologie sicherzustellen, müssen fünf grundlegende Herausforderungen der KI-Systementwicklung beachtet werden:

- *Modellierbarkeit* – Wie leiten wir aus Daten die Modelle der realen Welt ab und wie stellen wir Modelle ohne Vorurteile und Fehler her; bzw. wie stellen wir eine zuverlässige „ground truth“ her.
- *Verifizierbarkeit* – Wie überprüfen wir die Technik.
- *Erklärbarkeit* – Wie können wir die Entscheidungsfindungen der technischen Systeme nachvollziehen.
- *Ethik* – Wie stellen wir sicher, dass die Einhaltung ethischer Grundsätze und Werte garantiert wird.
- *Verantwortlichkeit* – Wer trägt die Verantwortung für getroffene Entscheidungen des Systems.

Diese Themenbereiche müssen für den gesamten Lebenszyklus von KI-Systemen berücksichtigt werden. In den folgenden Abschnitten werden diese Herausforderungen näher erörtert.

2.1 Modellierbarkeit

Ein KI-System ist im Wesentlichen ein Ansatz, um durch ausreichend viele Trainingsdaten ein Modell der realen Welt zu erstellen; d. h. eine KI-Maschine lernt durch Trainingsdaten ein möglichst genaues Abbild der Welt. Dafür braucht es eine genügend große Menge von Daten vom betrachteten Objekt der realen Welt. Dann braucht es Expertenwissen, um die Daten zu analysieren und zu beschreiben, um daraus möglichst gute Modelle ableiten zu können.

2.1.1 Große Menge von Trainingsdaten und Ground Truth

Wie oben beschrieben, ist ein funktionierendes KI-System grundlegend durch ausreichend verfügbare und geeignete Trainingsdaten sowie auch durch Expertenwissen, um die verfügbaren Daten zu bewerten, bestimmt. Die Trainingsdaten müssen in einer Analysephase von Expert*innen bewertet und annotiert werden, damit für die Maschine erkenntlich wird, nach welchen Mustern in den Daten analysiert werden soll. Eine solche Bestimmung einer „ground truth“ in den vorhandenen Trainingsdaten ist eine der wichtigsten Grundvoraussetzungen für eine richtige KI-Funktionsweise.

Somit kommt den verfügbaren Trainingsdaten sowie einem entsprechenden Expertenwissen zur Beurteilung der Daten eine grundlegende Bedeutung für gut funktionierende KI-Systeme zu. Es ist nun sehr wichtig, dass in den Daten keine Fehlinterpretationen bzw. Vorurteile, sogenannter Bias, enthalten sind, da sonst falsche Modelle als Abbild der realen Welt gelernt werden. Die Problematik von möglichen Fehlinterpretationen der Daten wird im Folgenden verdeutlicht.

2.1.2 Overfitting und Aberglauben von künstlicher Intelligenz

Ein Problembereich bei KI-Systemen besteht in der Auswahl der betrachteten Parameter zur Beurteilung der Datenlage. Wird das Modell zu kompliziert gewählt und sind zu viele Parameter zu beachten, entsteht die Gefahr des sogenannten Overfitting. Beim Overfitting ist die Maschine nicht mehr in der Lage, gesuchte Daten im gesamten Signal zu erkennen. Der KI-Algorithmus lernt im umgangssprachlichen Sinn die Problemstellung auswendig, ohne die eigentliche Problemstellung zu lösen. Diese prinzipielle Problematik kennen wir auch durch die Versuche, aus sehr großen Datenmengen entsprechende Vorhersagen zu treffen, wie in Wirtschaftssystemen, oder bei Klima- und Wetterprognosen (Silver 2012).

Ein weiteres Problem kann darin bestehen, dass bestimmte Merkmale in den Trainingsdaten als besondere Eigenschaft vom System erkannt werden, die aber nichts mit der eigentlichen Fragestellung zu tun haben. Burrhus F. Skinner, Pionier der Verhaltensforschung und des programmierten Lernens, hat bereits 1948 herausgefunden,

dass Tauben abergläubisch sind²⁴. In einem Versuch hat er festgestellt, dass zufällige Zusammenhänge zwischen Ereignissen, z. B. zur Verfügung gestelltes Futter und zufällige Körperhaltung, als Sollmuster gelernt werden. Diese Phänomene sind auch bei KI-Algorithmen potenziell vorhanden. Ein Beispiel verdeutlicht diese Problemstellung. Forscher trainierten eine KI-Anwendung zur Erkennung von Wölfen in verschiedenen Bildern. Beim Testen des Systems stellte sich aber heraus, dass das KI-System auch bei Hundebildern Wölfe zu erkennen glaubte. Durch genauere Untersuchungen fanden die Forscher heraus, dass die Maschine nicht Merkmale eines Gesichts gelernt hatte, sondern im Trainingsprozess den Bildhintergrund als bestimmenden Parameter in den Trainingsdaten selektiert und eintrainiert hatte (Ribeiro et al. 2016).

2.1.3 Eingebaute Backdoors in Künstliche-Intelligenz-Systemen

Nachdem die Funktion von KI-Systemen durch Trainingsdaten bestimmt wird, können auch bestimmte Mechanismen unerkannt eintrainiert werden, sogenannte Backdoor-Funktionen. So können z. B. bei Gesichtserkennungssystemen spezielle Gesichtsbilder mittrainiert werden, um bei einer Passkontrolle für bestimmte Personen das Überprüfungsergebnis zu manipulieren²⁵.

2.1.4 Zusammenfassung

Um gut funktionierende und sichere KI-Systeme bauen zu können, brauchen wir eine große Anzahl von Trainingsdaten, die von Expert*innen beurteilt werden, um die richtigen Parameter für die Modellbildung der realen Welt – eine „ground truth“ – abzuleiten. Dabei ist es wichtig, dass durch die Trainingsdaten keine ungewünschten Effekte (Bias) sowie mögliche Täuschungen mittrainiert werden.

Hierbei ist es wichtig zu beachten, dass es sehr schwer ist, nach einem Trainingsvorgang eines neuronalen Netzes versteckt eingebaute Muster im Nachhinein zu identifizieren, da das Muster nur in den verwendeten Trainingsdaten vorhanden und im eigentlichen KI-System nicht mehr ersichtlich und nachvollziehbar ist.

Somit kommen wir zur grundlegend wichtigen Problemstellung: Woher kommen die Trainingsdaten, wer hat diese verifiziert und wie sind die Trainingsprozesse der KI-Systeme erfolgt. Open Source und Zertifizierungen von Trainingsdaten sind wichtige Ansätze, um Vertrauen in KI-Systeme zu fördern. Darüber hinaus ist aber vor allem das Testen und Verifizieren von KI-Systemen ein Bereich, dem noch mehr Aufmerksamkeit gewidmet werden muss.

²⁴Die Macht des Aberglaubens, 12.03.2004, <https://www.spiegel.de/wissenschaft/mensch/psychologie-die-macht-des-aberglaubens-a-290219.html> (letzter Zugriff am 22.09.2020).

²⁵Sogenannte Face-Morphing-Angriffe auf Gesichtserkennungssysteme.

2.2 Verifizierbarkeit

2.2.1 Künstliche Intelligenz braucht neue Testmethoden

Die Frage nach einem ausreichend korrekten Systemverhalten von KI-Systemen ist eine grundlegende Thematik, wie bei jedem technischen System. Ein bekanntes Beispiel ist der Unfall eines Tesla-Fahrzeugs. Da konnte ein KI-gesteuertes Kamerasystem des autonom fahrenden Autos ein weißes Fahrzeug auf der Fahrbahn nicht von den weißen Wolken am Himmel unterscheiden und das Notbremssystem reagierte somit nicht in der erforderlichen Weise²⁶.

Eine prinzipielle Problemstellung bei der Entwicklung von technischen Systemen ist die Frage der Überprüfbarkeit der spezifizierten Funktionen. Für herkömmliche IT-Systementwicklungen gibt es seit Jahrzehnten bewährte Methoden der Informationstechnik für das Testen und Zertifizieren der entwickelten Systeme. Im Wesentlichen beruhen Testmethoden auf der Grundlage, dass Ingenieure die Systemdesigns als auch die Entwicklungsprozesse kennen und verstehen. Damit können Systemverhalten und Entscheidungsfindungen von Expert*innen nachvollzogen und erklärt werden. Darauf aufbauend können Prüfvorschriften und Testverfahren konzipiert werden, um Systemfunktionen auf Korrektheit zu überprüfen und auch zu verifizieren.

Bei KI-Systemen wird es aber für Expert*innen mit der zunehmenden Komplexität – von regelbasierten Systemen über statistische Funktionen und Mathematik bis hin zu neuronalen Netzen – immer schwerer, die Entscheidungsfindung im Nachhinein nachzuvollziehen. Da vor allem KI-Systeme, die auf neuronalen Netzen beruhen, sogenannte Black Boxes sind, kann nicht mehr festgestellt werden, aufgrund welcher Parameter eine bestimmte Entscheidung von der Maschine getroffen wurde.

Damit sind wir grundlegend mit der Frage konfrontiert, wie KI-Systeme getestet und eine korrekte Funktionsweise verifiziert werden. Dabei müssen Problemstellungen wie Overfitting und Backdoors in Trainingsdaten genauso berücksichtigt werden wie die Sicherstellung eines zuverlässigen Systemverhaltens.

Da durch Trainingsdaten ein Modell der realen Welt gebildet wird, stellt sich schlussendlich auch die Frage nach der Robustheit des Modells im realen Betrieb, wie folgende Beispiele verdeutlichen.

2.2.2 Täuschung von Künstliche-Intelligenz-Systemen durch Manipulation der Umwelt

Viele Forschungsprojekte zeigen, wie KI-Algorithmen leicht durch einfache physische Veränderungen der Umwelt in ihrer korrekten Funktionsweise beeinträchtigt werden können. Obwohl solche Veränderungen für den Menschen leicht erkennbar sind,

²⁶Selbstfahrender Tesla übersieht weißen Lkw vor Wolkenhimmel, Welt, 1.7.2016, <https://www.welt.de/wirtschaft/article156727084/Selbstfahrender-Tesla-uebersieht-weissen-Lkw-vor-Wolkenhimmel.html> (letzter Zugriff am 22.09.2020).

haben künstliche Maschinen sehr damit zu kämpfen. Durch gezielte Anwendung von sogenannten Robust-Physical-Perturbation(RP2)-Angriffen, wie z. B. durch Graffiti auf Verkehrsschildern (Evtimov et al. 2017) oder einfach durch gedruckte Bilder auf Kartons oder T-Shirts, können KI-basierte Kamerasysteme einfach getäuscht werden (Eykholt et al. 2018; Samuels 2017).

Eine weitere Bedrohung besteht darin, dass durch Veränderung der digitalen Daten, z. B. durch nur leichte Veränderungen eines digitalen Bilds, die für den Menschen nicht sichtbar sind, KI-Systeme getäuscht werden können; z. B. erkennt eine KI-basierte Kamera in einem Bild, in dem einige Pixel leicht verändert wurden, statt eines trainierten Autos einen Strauß (Gershgorin 2016).

2.2.3 Zusammenfassung

Mit dem Einsatz neuer KI-Systeme sind wir mit einem Paradigmenwechsel in der Art und Weise der Testmethoden konfrontiert und alte bewährte Erfahrungen sind nicht mehr ausreichend. Die Entwicklung von Test- und Zertifizierungsmethoden für KI-Systeme ist aber noch eine sehr junge Wissenschaftsdisziplin (Zhang et al. 2020) und Forschungsaktivitäten sind in diesem Bereich wesentlich zu verstärken.

Die Herausforderung bei KI-Systemen liegt darin, dass nicht einfach feststellbar ist, aufgrund welcher Parameter in den verwendeten Daten Missinterpretationen des KI-Systems erfolgten. Um aber Vertrauen in KI-Systeme zu erlangen, ist es neben den Testverfahren auch notwendig zu verstehen, wie und warum KI-Systeme bestimmte Entscheidungen treffen, damit das Systemverhalten erklärt werden kann.

2.3 Erklärbarkeit

Bei KI-Systemen ist eine Nachvollziehbarkeit der Entscheidungsfindung nicht mehr in diesem Umfang möglich wie bei klassischen IT-Systemen, da die Funktionen durch Trainingsdaten erlernt wurden und kein klassischer, auf If-then-else-Bedingungen basierter und einfach nachzuvollziehender Algorithmus mehr abläuft. Somit braucht es neue Methoden, um ein Verständnis bzw. eine Erklärbarkeit von KI-Systemen zu erreichen. Erklärbarkeit bedeutet dabei, dass die Ergebnisfindung der Maschine für Menschen interpretierbar ist. Erklärbarkeit ist dabei nicht mit Transparenz gleichzusetzen. Es müssen Erklärungsmodelle geschaffen werden, ohne dass die konkrete Funktionsweise eines Algorithmus nachvollzogen werden muss.

2.3.1 Künstliche-Intelligenz-Erklärungsmethoden

Durch Ex-post-Erklärungen von KI-Systemen kann quantifiziert werden, wie stark einzelne Faktoren eine Entscheidung beeinflussen und so ein Verständnis für den Entscheidungsraum geschaffen werden. Eine typische Methode wird beispielsweise durch den Ansatz „local interpretable model-agnostic explanations“ (LIME) verfolgt. Dabei wird eine einzelne Vorhersage eines Black-Box-Algorithmus mithilfe eines zweiten,

nachvollziehbaren transparenten Modells imitiert. Der transparente Algorithmus soll dabei das Ergebnis des KI-Systems möglichst gut reproduzieren. Das interpretierbare Modell wird dann benutzt, um jene Merkmale zu identifizieren, die den größten Einfluss auf das Ergebnis haben.

Für neuronale Netze werden spezielle Erklärungsmethoden entwickelt, wie z. B. die Layer-wise-relevance-propagation(LRP)-Methode. Dabei wird untersucht, welche Inputparameter, z. B. Pixel eines Bilds, einen besonderen Beitrag zur Aktivierung eines Neurons leisten. Diese werden dann pro Schicht des neuronalen Netzes in einer Art Wärmebild dargestellt.

2.3.2 Künstliche Intelligenz in safety-kritischen Systemen

Für den Einsatz von KI in safety-kritischen Systemen, wie in Flugzeugen, Steuerungen für Züge und Fahrzeuge, in autonom agierenden Robotersystemen, Steuerungsanlagen für Kraftwerke etc., also in Bereichen, bei denen ein fehlerhaftes Systemverhalten eine wesentliche Bedrohung für wirtschaftliche oder menschliche Schäden darstellt, ist es grundlegend wichtig, dass immer eine korrekte Systemfunktion sichergestellt werden kann. Herkömmliche deterministische technische Systeme können nicht nur umfassend getestet werden, sondern es kann auch durch Expert*innen das mögliche Systemverhalten nachvollzogen und analysiert werden, um einen sicheren Betrieb sicherzustellen („safety“).

Da dies bei KI-Systemen in dieser Form nicht möglich ist, brauchen wir neue Ansätze, um KI-Systeme effektiv testen zu können, aber auch, um Entscheidungsprozesse nachvollziehen und damit auch erklären zu können. Ansätze für solche Analysesysteme sind Formen von Black-Box-Testverfahren, um das Verhalten von KI-Systemen zu beurteilen (Bartocci et al. 2020; Aichernig et al. 2019; Fellner et al. 2019); Robustheits-Monitoring, bei dem Testergebnisse als Feedback verwendet werden, um automatisiert zu beurteilen, wie „gut“ oder „schlecht“ das Verhalten eines KI-Systems ist (Jaksic et al. 2018; Nickovic et al. 2018); oder auch zur Laufzeit von Systemen stattfindende Online-Monitoring-Analysemethoden für Steuerungssysteme, um bei erkannten Fehlerzuständen die fehlerhafte Systemkomponente zu identifizieren (Ničković et al. 2020, Bartocci et al. 2018; Bartocci et al. 2019; Ferrère et al. 2019).

In mehreren EU Forschungsprojekten werden Testverfahren für KI-Systeme in sicherheitskritischen Steuerungen entwickelt, wie z. B. in Enable-S. 3²⁷, AutoDrive²⁸, oder Valu3S²⁹. Eine Übersicht über verschiedene Testverfahren für autonome Cyber-Physical-Systeme (CPS) ist auf der AIT-Webseite des EU-Projekts Enable-S3 zu finden³⁰.

²⁷ <https://www.enable-s3.eu/> (letzter Zugriff am 22.9. 2020).

²⁸ <https://autodrive-project.eu/> (letzter Zugriff am 22.09. 2020).

²⁹ <https://valu3s.eu/> (letzter Zugriff am 22.9. 2020).

³⁰ <https://vvpatterns.ait.ac.at/> (letzter Zugriff am 22.09. 2020).

2.3.3 Zusammenfassung

Um KI-Systeme in sicherheitskritischen Bereichen einsetzen zu können und auch um Missbrauch zu verhindern, braucht es neue Methoden, nicht nur um KI-Systeme testen zu können, sondern auch um Verständnis bzw. eine Erklärbarkeit zu erreichen. Dazu sind verstärkte Forschungsinitiativen notwendig.

2.4 Ethik

Bei der Frage nach korrekten Entscheidungsfindungen von Maschinen ist nicht nur der Sicherheitsaspekt bei Maschinen relevant („safety“), sondern auch ob Entscheidungen von Maschinen unseren ethischen Prinzipien und Regeln entsprechen.

2.4.1 Künstliche-Intelligenz-Systeme können diskriminieren

Da KI-Systeme ihre Funktion im Wesentlichen von den verwendeten Trainingsdaten ableiten, ist die Verfügbarkeit und Auswahl der Trainingsdaten die Grundlage, um ethisches Handeln bei der Entscheidungsfindung von KI-Systemen sicherzustellen. Folgende Beispiele zeigen, wie schnell wir auf eine Funktion vertrauen und unbemerkt unethische Entscheidungsfindung von KI-Systemen erhalten können.

Wenn man die vorhandenen Übersetzungsdaten von Google Translate als Trainingsdaten für eine Sprachapplikation verwendet, erhalten wir ein Ergebnis, das unseren gesellschaftlichen Gender-Zielsetzungen fundamental widerspricht, da im Wesentlichen in allen Sprachen der Welt ein inhärenter Gender-Bias beinhaltet ist (Schindler 2018).

Noch markanter sind die Untersuchungen, wie die diversen KI-basierten Gesichtserkennungssysteme funktionieren (Lohr 2018). Über die letzten Jahre wurde die Genauigkeit der Gesichtserkennungssysteme laufend verbessert und sie erreicht bei weißen männlichen Gesichtern durchaus schon eine hohe Genauigkeit mit einer Fehler率 von nur 1 %. Bei näherer Betrachtung muss man aber feststellen, dass diese Fehler率 bei weiblichen Gesichtern auf 7 % und bei männlichen dunkelhäutigen Gesichtern bereits auf 12 % ansteigt. Aber noch viel dramatischer ist die Fehlerrate bei dunkelhäutigen weiblichen Gesichtern. Da muss mit einer Fehlerrate von 35 % gerechnet werden (Buolamwini 2020). Wenn diese Algorithmen auf die im Internet vorhandenen Bilder von berühmten Frauen angewandt werden, wird in den meisten Fällen von den KI-Systemen ein „Mann“ missinterpretiert. Man kann sich ausmalen, wie leicht mit Maschinen mit derartigen Technologien ohne menschliche Überwachung entsprechende dramatische Fehlentscheidungen für einzelne Menschen getroffen werden können.

2.4.2 Zusammenfassung

Potenzielle ethische Fehlentscheidungen von KI-Systemen sind eine besondere Herausforderung der neuen Technik. Menschliche Intervention sollte immer das Schlusswort bei gesetzlich relevanten Entscheidungen haben, damit nicht Maschinen falsche oder unethische Entscheidungen treffen.

2.5 Verantwortlichkeit

Durch die oben beschriebenen Problemfelder der prinzipiell fehlenden Erklärbarkeit durch das Black-Box-Problem, möglichem Bias und potenziell ethischen Problemen bringt die Inbetriebnahme von KI auch eine große Herausforderung und Verantwortung für Gesetzgebung, Rechtsprechung und Verwaltung mit sich. Durch die breiten Einsatzmöglichkeiten von KI ist so gut wie jede Rechtsmaterie betroffen.

2.5.1 EU-Leitlinien für die Gestaltung von Künstliche-Intelligenz-Systemen

Die Europäische Kommission sieht diese Problematik als eine Schlüsselherausforderung und erarbeitet mit einer 2018³¹ eingesetzten Expertengruppe unter Einbindung unterschiedlichster Fachgebiete und Interessensvertreter Leitlinien zur Ethik in der KI. Aufbauend auf den ethischen Grundsätzen, wie Achtung der menschlichen Autonomie, Schadensverhütung, Fairness, und Erklärbarkeit, wurden von der Hochrangigen Expertengruppe für künstliche Intelligenz (2019) sieben Schlüsselanforderungen für die Gestaltung von Technik und diesbezügliche Rahmenbedingungen definiert:

- Vorrang menschlichen Handelns und menschliche Aufsicht
- Technische Robustheit und Sicherheit
- Datenschutz und Datenqualitätsmanagement
- Transparenz
- Vielfalt
- Nichtdiskriminierung und Fairness
- Gesellschaftliches und ökologisches Wohlergehen
- Rechenschaftspflicht

Ziel der EU-Leitlinien ist die Förderung einer vertrauenswürdigen KI, die während des gesamten Lebenszyklus des KI-Systems rechtmäßig ist und somit alle anwendbaren Gesetze und Bestimmungen einhält, ethische Grundsätze und Werte garantiert und technisch robust und zuverlässig ist. Um diese Anforderungen zu berücksichtigen, sind die technische Systemkonzeption sowie die Rahmenbedingungen für den Einsatz der Technik entsprechend eines gesellschaftlichen Diskurses zu entwickeln.

³¹ Künstliche Intelligenz: Die Europäische Kommission beginnt Arbeit um Ethikstandards und modernste Technik zusammen zu bringen, Pressemitteilung der EC, 09.03.2018, https://europa.eu/rapid/press-release_IP-18-1381_de.htm (letzter Zugriff am 22.9. 2020).

2.5.2 Zusammenfassung

Es ist noch viel zu tun, um die technischen Entwicklungen der KI-Technologien mit Empfehlungen, Richtlinien, gesetzlichen Rahmenbedingungen und Regularien in Einklang zu bringen.

Der Einsatz von KI-Systemen sollte immer mit umfassenden Wirkungs- bzw. Risikofolgenabschätzungen begleitet werden und der KI-Einsatz sollte in einer Gesamtarchitektur so konzipiert sein, dass keine unreflektierten automatisierten Entscheidungen getroffen werden, wenn diese mit einer rechtlichen Wirkung in Verbindung gebracht werden.

3 Gesellschaftliches Bedrohungspotenzial durch künstliche Intelligenz

3.1 Demokratisierung von Technologie

Durch entsprechend breit durchgeführte Ausbildungen in unseren Universitäten aber auch schon Mittelschulen und durch die gleichzeitige Verfügbarkeit von Open-Source-Software und Bibliotheken ist es heute sehr einfach geworden, KI-Systeme ohne hohe Kosten und Investitionen einzusetzen.

Damit können wir von einer gewissen Form der Demokratisierung einer sehr leistungsfähigen Technologie sprechen, die in vielen Anwendungsbereichen vorhandene Probleme lösen wird. Wie bei jeder neuen Technologieeinführung erhalten wir aber nicht nur die eigentlich beabsichtigten positiven Vorteile der neuen Technik, sondern sind auch mit einem potenziellen Missbrauch der neuen Technologie konfrontiert, der von neuen Geschäftsmodellen, über den Einsatz bei herkömmlicher Kriminalität bis hin zu staatlichem Missbrauch reicht. Mit KI-Systemen können Unternehmen ihre Kunden mittels Datenanalysen beurteilen und ihre Produkt- und Serviceangebote nicht nur im Sinn eines verbesserten Kundenangebots ausrichten, sondern auch Kunden von Angeboten ausschließen und sogar diskriminieren. Diese Problematik wird in den Forschungsprojekten Primming³² und Preiswert^{33,34} behandelt, um Methoden und Werkzeuge zur Gegenwehr zu entwickeln.

³²Von der FFG gefördertes FEMtech Projekt „PRIMMING“, <https://projekte.ffg.at/projekt/3280774>, <https://dynamic-pricing.at/> (letzte Zugriffe am 22.09.2020).

³³Von Netidee gefördertes Projekt „Preiswert“, <https://www.netidee.at/preiswert> (letzter Zugriff am 22.09.2020).

³⁴Aufdeckung von Preisdiskriminierung: AIT und ÖIAT verstärken Forschungskooperation, Horizont, 4.2.2020, <https://www.horizont.at/digital/news/aufdeckung-von-preisdiskriminierung-ait-und-oeiat-verstaerken-forschungskooperation-73253> (letzter Zugriff am 22.09.2020).

Noch viel bedrohlicher ist der Umstand, dass mit KI das grundsätzliche Problem der Manipulation von öffentlichen Meinungen in unserer neuen Medienwelt eine neue Bedeutung erlangt. Durch gezielte personalisierte Desinformationskampagnen können Bürger mit ausgewählten Informationen in ihrem Verhalten bis hin zu ihrem Wahlverhalten beeinflusst und auch manipuliert werden.

Somit stellt sich die Frage, ob die neue Technologie auch beherrschbar ist und KI-Maschinen nicht unbedachten Schaden für Menschen oder gar ganze Gesellschaften mit sich bringen.

3.2 Manipulation von Medien

3.2.1 Fake News und Deep Fakes

Durch das Internet haben wir eine neue Medieninfrastruktur geschaffen, die in der Menschheitsgeschichte einmalig ist. Das Internet ist ein Mediensystem geworden, bei dem jeder Konsument auch zum Produzenten werden konnte. Durch die damit verbundene Vielzahl von Webseiten, Blogs und Social-Media-Kanälen haben wir eine Vervielfachung von Informationskanälen erreicht und haben ein exponentiell steigendes Volumen an Medieninhalten. Somit ist das Internet eine noch nie dagewesene effektive Plattform für Kommunikation, Informationsaustausch und Innovation und die prophezeite globale „flache Welt“ nach Friedman (2007) wurde wahr.

Gleichzeitig haben wir mit dem Internet nun aber auch eine neue noch nie dagewesene Plattform für umfassende verfälschte Kommunikation und Desinformation gebaut. Obwohl die Verbreitung von Falschinformationen, sogenannte Fake News, immer schon Teil der Menschheitsgeschichte war, haben wir mit dem Umfang und in der Verteilungseffizienz eine neue Dimension erreicht. Bei Fake News geht es um die Verbreitung von Falschinformationen mit dem Ziel, die öffentliche Meinung, Gruppen oder Einzelpersonen im Sinn politischer oder wirtschaftlicher Interessen zu beeinflussen. Informationen, d. h. Text, Bilder, Audio, und Video, werden dabei manipuliert, um nicht nur nach objektiven Maßstäben Unwahrheiten zu kommunizieren, sondern sie werden durch subtile Unterdrückung, Verschweigen oder Darstellung von Fakten in veränderten Kontexten zum Zweck der Täuschung und damit Manipulation des Medienkonsumenten eingesetzt, wie von der EU High Level Expert Group on Fake News and Online Disinformation (2018) beschrieben.

Dazu gilt es aber auch zu beachten, dass im Internet mittlerweile ein großes Geschäftsmodell umgesetzt wird. Da jeder Leserkontakt einer Nachricht, einer Webseite oder eines Blogs und jedes Like einen Werbewert für Influencer oder Blogger darstellt, besteht eine hohe Motivation, Nachrichten möglichst attraktiv darzustellen, um den Geschäftswert zu erhöhen. Dass diese Praxis mit der Wahrheit nicht immer sorgsam umgeht, liegt dabei wohl auf der Hand.

Durch die KI-Technologie ist es aber auch möglich geworden, mit vorhandenen Daten im Internet neue gefälschte Medieninhalte zu erzeugen. Durch sogenannte Deep Fakes entstehen neue Bilder, Audioinhalte und Videos, die täuschend echt aussehen, um Unternehmen zu betrügen³⁵ oder um politische Stimmungen in einem Land zu manipulieren³⁶.

KI-Systeme stellen auch eine neue effektive Möglichkeit dar, um Gesinnungen und politische Einstellungen aus verfügbaren Daten unserer sozialen Online-Medien oder anderen digitalen Spuren zu ermitteln. KI ist somit auch ein potenzielles Werkzeug, das für autokratische und diktatorische Systeme geradezu als Wundermittel eingesetzt werden kann.

3.2.2 Der Faktencheck – ein Gebot der Stunde

Es braucht neue Methoden und Werkzeuge, um Nachrichten und Informationen überprüfen zu können. Medienunternehmen und Behörden treiben heute bereits einen beträchtlichen Aufwand, um Medieninhalte auf ihren Wahrheitsgehalt zu überprüfen. Mit der zunehmenden Menge von Medien sind wir allerdings mit der Problematik konfrontiert, dass die aktuellen Medienansätze zur Faktenüberprüfung nicht skalieren (Graves und Cherubini 2016). Aktuelle Verfahren dauern zu lange und sind zu teuer, um die große Flut an Fake News im Internet wirksam bekämpfen zu können.

Somit geht es um ein erhöhtes Bewusstsein in der Bevölkerung über den Wert korrekter Nachrichten, um ein neues Verständnis der Journalisten für einen qualitativ hochwertigen Journalismus, um neue Rahmenbedingungen, Gesetze und Regulierungen und neue Werkzeuge und Services, die wiederum die sehr großen Informationsmengen an Multimediadaten effektiv verarbeiten können, wie von der Europäische Kommission (2019) in ihrem Bericht festgehalten. KI-Methoden sind dabei wichtige Ansätze, um effektive Analysewerkzeuge zu erhalten. In Österreich wurde dazu 2020 im nationalen Sicherheitsforschungsprogramm KIRAS mit dem Projekt „*Defalsif-AI – Detektion von Falschinformationen mittels Artificial Intelligence*“ eine neue Initiative gestartet, die auf einer umfassenden Kooperation mit Behörden, Medienunternehmen und der Forschung aufbaut.

³⁵ Deepfake: Betrüger erleichterte Firma dank gefälschter Stimme um 220.000 €, DerStandard, 5.9.2019, <https://www.derstandard.at/story/2000108225039/deepfake-betrueger-erleichterte-firma-dank-gefaelschter-stimme-um-220-000> (letzter Zugriff am 22.09.2020).

³⁶ Pelosi videos manipulated to make her appear drunk are being shared on social media, Youtube, <https://www.youtube.com/watch?v=sDOo5nDJwgA> (letzter Zugriff am 22.09.2020).

4 Grenzen der künstlichen Intelligenz und Vielfalt des Lebens

4.1 Singularität – Kann künstliche Intelligenz die Menschheit übertreffen?

Ray Kurzweil beschreibt in seinem Buch (2005) die Ablöse menschlicher Intelligenz durch KI im Jahr 2045. Bei seiner exponentiellen Hochrechnung stützt er sich auf Moore's Law, das seit 1965 mit der Vorhersage, dass wir in der Lage sind, eine Verdoppelung der Leistung von Computerchips alle zwei Jahre zu erreichen, bisher richtig lag.

Maschinen sind in vielem besser und schneller als der Mensch und müssen dort für die Bewältigung der großen anstehenden ökonomischen, ökologischen und sozialen Fragen auf unserem Planeten eingesetzt werden, wo wir sie brauchen. Für menschlichen Forscherdrang wird es niemals eine Grenze geben. Das ist hoffnungsvoll, besonders im Hinblick auf die immer größer werdenden Probleme für unsere globale und digital vernetzte Gesellschaft.

Die allerdings fehlenden Einsichten und das Nichtverstehen machen uns anfällig für Größenwahn. Wie in einer kindlichen Trotzreaktion wollen wir den künstlichen Menschen erschaffen. Worin liegen nun die prinzipiellen Unterschiede zwischen menschlichem Denkvermögen und Analysefähigkeit von Maschinen? Ein paar grundsätzliche Aspekte, die den großen Unterschied dieser zwei Welten ausmachen, wollen wir im Folgenden erörtern.

4.2 Künstliche Intelligenz braucht noch viel mehr Intelligenz

Trotz der vielversprechenden Potenziale von KI und des aktuellen Hypes sollten wir uns immer wieder in Erinnerung rufen, dass wir nur eine Maschine bauen. Hierbei ist sicher das Moravecsche Paradox eine wichtige Erkenntnis, die bei aller Euphorie für KI-Leistungen immer wieder in Erinnerung gerufen werden muss. Scheinbar komplizierte Abläufe sind leichter durch KI berechenbar als einfache Abläufe wie die unseres Alltags. Jedes Kind beherrscht eine höhere Komplexität, um sich durch einen Spielplatz zu bewegen als jedes erdenkliche KI-System. Dies zeigt sich auch darin, dass schlussendlich KI-Systeme heute nach wie vor nur in ganz engen, sehr spezifischen Anwendungsbereichen effektiv gut funktionieren. Von einer allumfassenden Superintelligenz, die uns Menschen überflügelt, sind wir weit entfernt.

Nur weil noch größere Datenmengen noch schneller analysiert werden können, erhalten wir keine Intelligenz, die sich mit der menschlichen Intelligenz vergleichen lässt. Dies ist einer der größten Irrtümer des Big-Data und KI-Hypes, dem wir leichtgläubig erliegen.

4.3 Das Leben ist nichtlinear

Wichtige menschliche Eigenschaften, die wir brauchen, um die Herausforderungen des komplexen Lebens zu meistern, sind Flexibilität, Fantasie, Kreativität etc., was wir üblicherweise als Eingebung, Erfindung und kreative Lösungsfähigkeit beschreiben. Unser Leben ist keine lineare Entwicklung, sondern ist stetig durch disruptive Effekte, die durch Nichtlinearitäten, Fehler und Zufälle beeinflusst werden, bestimmt. Diese Mechanismen werden durch Maschinen noch länger nicht nachahmbar sein.

Und auch Angebote, die unserem Kaufverhalten oder unseren Vorlieben entsprechen, scheinen zwar auf den ersten Blick intelligent und hilfreich zu sein, sind aber doch nur eine Hälfte unseres wahren Lebens. Unser Leben ist kein steriler Platz der Abarbeitung von Fakten – es macht Spaß, ist spannend, herausfordernd und manchmal auch scheinbar sinnlos. Und am allerwichtigsten: Der Zufall spielt eine sehr große, ja bestimmende Rolle in unser aller Leben! Wahre Innovation entsteht durch Kreativität, Zufall und Kombination von scheinbar nicht zusammenpassenden Dingen (Leopold 2017, S. 35f.). Im Prinzip kann man sogar sagen: „KI tötet potenziell die Kreativität“.

4.4 Das Leben besteht nicht nur aus Problemlösungen

Leben besteht nicht nur aus Problemlösung. Innovationsforscher haben schon lange verstanden, dass Technik und Innovation nicht aus einem Selbstzweck heraus entstehen, sondern technische Entwicklungen sind immer das Ergebnis von dauernden Wechselbeziehungen zu anderen Techniken, zur Umwelt und zum Benutzer von Technik (Leopold 2017, S. 99). Precht (2020, S. 140) schreibt dazu: „Leben ist kein schablonenhaftes Problemlösen. Wenn wir die Welt erfassen, so stellen wir Beziehungen zwischen den Dingen her. Wir denken nicht in Begriffen, sondern in Relationen. Jedes Denken steht in Beziehungen und ist damit relativ. Gedanken können nie sauber fixiert werden, sie sind flüssig und liegen zwischen den Dingen.“ Und (Precht 2020, S. 132): „Wer glaubt, dass Leben und Problemlösen das Gleiche ist, der streicht mit jedem gelösten Problem die Dimension des Lebens zusammen, bis am Ende ein Zustand der Sorglosigkeit dabei herauskommt, den man der Definition gemäß nicht mehr ‚Leben‘ nennen kann.“

KI dagegen markiert ganz gezielt Probleme und rückt sie als solche ins Bewusstsein der Betrachtung (Precht 2020, S. 138), zeigt damit aber wieder nur, dass wir es schlussendlich nur mit einem Werkzeug zu tun haben und nicht mit einer Superintelligenz.

Menschliche Intelligenz ist das, was wir anwenden, wenn wir keine Anleitung zur Problemlösung dafür bekommen haben. Logik und Kalkül spielen dafür allerdings nur beschränkt eine Rolle. Die menschliche Intelligenz setzt auf Emotionalität und Intuition, Spontanität und Assoziation. Dazu gehört im gleichem Maß auch eine Einfühlung in die Situation unter dem Einfluss von vorhanden Werten (Precht 2020, S. 25).

4.5 Die Datenwelt der künstlichen Intelligenz ist nicht das Leben

Es gibt eine breite Diskussion und prinzipielle Angst davor, dass der Einsatz von KI Menschen in vielen Bereichen ersetzen wird. Bei näherer Betrachtung wird man aber erkennen, dass KI auch wieder nur ein Werkzeug ist, das uns bei verschiedenen Aufgaben helfen wird und uns als Mensch in keinsten Weise ersetzen kann. KI zeigt uns, dass wir uns auf die wahren Werte von Menschsein besinnen müssen. Precht (2020) beschreibt dazu grundlegende Aspekte menschlichen Verhaltens, die uns wohl immer von Maschinen unterscheiden werden:

- KI baut nicht auf Werte, hat kein Vertrauen, kennt keine Wahrheit, Freiheit, Freundschaft, Respekt und Hilfsbereitschaft (Precht 2020, S. 31–37).
- KI kennt keine Gemeinschaft und auch keine soziale Kultur von Anerkennung und Wertschätzung (Precht 2020, S. 31–37). Menschliches Verhalten und Entscheidungsfindung manifestieren sich aber erst durch gelebte menschlich soziale Kontakte.
- KI hat kein Zeitbewusstsein. Wir als Menschen erfahren unser Leben allerdings durch andauernde Reflexion der Vergangenheit und planen permanent unsere Zukunft und richten permanent unser Streben und Handeln nach subjektiv sinnvollen Abstimmungen zwischen gemachten Erfahrungen und gewünschten Zielen aus.
- KI entwickelt keinen Willen. Dass eine Superintelligenz ein Selbst und einen Willen ausbildet, nur indem Daten analysiert werden und Verhaltensmuster eintrainiert werden, ist für Precht nicht nachvollziehbar (2020, S. 125).

Wir rechnen, sehen und hören sehr viel schlechter als Computer, aber wir Menschen orientieren uns in oft unendlich komplexen Kontexten. Die limitierte Datenwelt der KI nimmt nur wahr, was sie wahrnehmen soll. Wir aber leben nach Werten, Gefühlen, Einstellungen und Moralfähigkeiten, die sich in der Evolution der Menschheit in unseren Gesellschaften entwickelt haben, weil sie sich bewährt haben. Der Welt der KI fehlt Fantasie und Emotion, Subjektivität und Gefühl und sie ist sehr viel kleiner als die menschliche Intelligenz.

4.6 Künstliche Intelligenz und Moral

Vor dem Hintergrund der Thematik, Ethikfragen zum KI-Einsatz zu klären, streicht Precht eine klare Botschaft hervor (Precht 2020, S. 156): „Was den Menschen zum Menschen macht, liegt also nicht an irgendwelchen apriorischen Festlegungen oder Programmierungen. Es ist die besondere Art und Weise, wie wir mit unserer Umwelt kommunizieren. Wir reagieren nicht einfach auf sie, sondern wir konstruieren sie uns, von einem Selbst ausgehend, als unsere Welt. [...] Der Gebrauch der Moral lässt sich nicht normieren wie die Größe von Dübeln und Schrauben. Eine Moral ohne subjektive

Haltungen, reduziert auf allgemeine Betrachtungen und Bewertungen des Lebens, bleibt formal und sinnlos.“

Somit stellt Precht klar fest, dass wir keine zu Robotern passende Moral entwickeln können. Wir können nur in unserem stetigen Diskurs zum Einsatz von Maschinen als Unterstützung für unser Leben entsprechende Rahmenbedingungen und Mechanismen festlegen, um Technik sicher, zuverlässig und höchstmöglich fehlerfrei zu gestalten.

5 Schlussfolgerung

5.1 Bildung und emotionale Intelligenz zur Beherrschung der Technik

Wie oben schon beschrieben ist menschliche Intelligenz das, was wir anwenden, wenn wir keine Anleitung zur Problemlösung dafür bekommen haben. Für echte Problemlösungen braucht es Intuition, Assoziation, Einfühlungsvermögen und auch die Anwendung von Werten und Kultur. Die Abarbeitung von Anleitungen und Logik hilft bei vielen Problemstellungen nicht weiter. Hierbei wird auch der wichtige Unterschied zwischen Bildung und Ausbildung eindrucksvoll klar.

Es stellt sich die Frage, ob unsere derzeitigen Ausbildungssysteme diesen neuen Entwicklungen und damit verbundenen neuen Herausforderungen auch geeignet Rechnung tragen. Heutige Ausbildungssysteme räumen nach wie vor umfangreichem Faktenwissen in vielen Disziplinen eine höhere Priorität ein. Empathie, Kreativität und Lösungskompetenz bei unvollständigen und widersprüchlichen Faktenlagen und einer gesamtheitlichen Betrachtung von komplexen Systemen wird oft zu wenig Augenmerk geschenkt.

Es gilt somit unser Bildungssystem grundlegend zu überdenken. Um mit Robotern und KI in Zukunft leben und um die Technik beherrschen zu können, müssen wir uns auf unsere menschlichen Kernkompetenzen der emotionalen Intelligenz und unsere wahre Bildung besinnen und triviales Lernen von Fakten durch Soft Skills ersetzen. Wir können nicht in Wettbewerb mit KI und Robotern treten, sondern müssen sie beherrschen.

5.2 Verantwortung zur Entwicklung der Technik

Wir müssen gerade im Zuge der immer populärer werdenden KI-Technologie die ethischen Rahmenbedingungen diskutieren, die wir bei KI in Zukunft setzen wollen. Wenn wir nicht wollen, dass uns eines Tages Algorithmen regieren, müssen wir die Endverantwortung für das Tun der Maschinen behalten. Der Wert des Lebens bestimmt sich nicht nach rein wirtschaftlichen Gesichtspunkten oder lässt sich auch nicht nach mathematischen Formeln festlegen. Daher darf auch KI keine neue Religion werden!

Und wieder bekommt Friedrich Dürrenmatt mit seiner 1961 verfassten Komödie *Die Physiker* mit der grundlegenden Frage der Verantwortung der Menschen für eine technologische Entwicklung, die die Gefahr der Bedrohung der Welt mit sich bringt, eine neue Aktualität. Technikbeherrschung ist ein unbedingtes Muss all unserer Bestrebungen – die Essenz des Menschseins kreist doch um Freiheit, Willen, Emotion, und Kreativität.

Wenn sich unsere Gesellschaft nicht gegen diese heraufdämmernden Gefahren aufstellt, erhalten wir ein potenziell nicht beherrschbares technisches System, das in weiten Bereichen unseres Lebens Einfluss haben wird, und kriminelle Akteure bekommen mit KI neue effektive Werkzeuge für ihre Zielsetzungen. Wir haben jedoch die Möglichkeit, eine Überlegenheit für die „gute“ Nutzung von KI herzustellen. Es müssen unbedingt Forschungsinitiativen gesetzt werden, um die mit KI-Technologien einhergehenden neuen Bedrohungslagen zu erkennen und zu verstehen und auch geeignete Gegenmaßnahmen zu entwickeln. Wir müssen Mechanismen finden, um die Robustheit unserer Gesellschaft zu steigern sowie die nachhaltige Kontrolle von KI-Systemen sicherstellen zu können.

5.3 Künstliche-Intelligenz-Forschung muss breiter gedacht werden

Um funktionierende KI-Systeme zu erhalten, müssen wir ein umfassendes Forschungsprogramm sicherstellen, das neben den eigentlichen Kernfragen wichtige Rahmenbedingungen bearbeitet, wie Sicherheit von KI-Methoden, Testen und Verifizieren, Annotationswerkzeuge und -methoden für Trainingsdaten und Regelwerke, um gesetzliche und ethische Vorgaben einzuhalten. Eine Übersicht eines umfassenden KI-Forschungsprogramms beschreiben Leopold et al. (2020).

Es ist unbedingt notwendig, die neue Technologie besser zu verstehen, Rahmenbedingungen und Regularien für deren gesellschaftlich verträglichen Einsatz zu implementieren, um eine missbräuchliche Verwendung von KI auszuschließen (Brundage et al. 2018), aber auch um Fähigkeiten und Werkzeuge zu entwickeln, damit Behörden, Unternehmen, aber auch jede(r) einzelne Bürger*in eine Möglichkeit bekommt, als verantwortungsvolle*r Medien- und Technik Konsument*in an einer positiven Entwicklung der Gesellschaft teilzunehmen.

Es bleibt aber ein großer Unterschied, ob eine Maschine auf die Wahrnehmung von emotionalen Stimmungen trainiert werden kann oder ob sie selbst welche hat. Nur der Mensch hat eine Körper-Seele-Konstellation, neben seinen kognitiven Fähigkeiten zur Gestaltung der Welt auch eine Erlebnisebene in Form von Gefühlen. Erst Trauer, Freude, Liebe, Empathie, soziale Kompetenz und Hilfsbereitschaft geben dem Humanen jene einzigartige Spannung, die uns von allem unterscheidet.

Somit bleibt das Faktum, dass auch die kühnste Maschine den Menschen in seiner Mehrdimensionalität aus Kognition, Emotion und Körperlichkeit, in seiner sinnlichen Wahrnehmung der Welt wohl niemals erreichen können wird.

Literatur

- Aichernig BK, Ba P, Jöbstl E, Kann S, Korosec R, Krenn W, Mateis C, Schlick R, Schumi R (2019) Learning and statistical model checking of system response times. *Softw Qual J* 27(2):757–795
- AIM (2018) Artificial Intelligence Mission Austria (AIM AT) 2030 – Die Zukunft der Künstlichen Intelligenz in Österreich gestalten. Bundesministerium für Verkehr, Innovation und Technologie (BMVIT) und Bundesministerium für Digitalisierung und Wirtschaftsstandort (BMDW), Wien. www.bmk.gv.at, www.bmdw.gv.at
- Bartocci E, Deshmukh J, Gigler F, Mateis C, Ničković, D, Qin X (2020) Mining shape expressions from positive examples. International Conference on Embedded Software (EMSOFT), Hamburg, Germany, 20–25 September 2020
- Bartocci E, Ferrère T, Manjunath N, Ničković D (2018) Localizing faults in simulink/stateflow models with STL. In: Proceedings of the 21st International Conference on Hybrid Systems: Computation and Control HSCC '18, part of CPS Week, April 2018, S. 197–206, <https://doi.org/10.1145/3178126.3178131>
- Bartocci E, Manjunath N, Mariani L, Mateis C, Nickovic D (2019) Automatic failure explanation in CPS models. *SEFM* 2019:69–86
- Brundage M et al (2018) The malicious use of artificial intelligence: forecasting, prevention, and mitigation, future of humanity institute, University of Oxford. Centre for the Study of Existential Risk. University of Cambridge, Center for a New American Security, Electronic Frontier Foundation, OpenAI (February 2018)
- Buolamwini J (2020) The coded gaze: bias in AI, DLD conference “What are you adding?”, Munich, January 18–20, 2020. <https://www.dld-conference.com/>, und https://www.youtube.com/watch?v=rjesnx_Pp5w&list=PLxaUSBUIISviSAoJ9Xuoet0s2rDOSHcey&index=29. Zugegriffen: 22. Sept. 2020
- EnliteAI (2020) AI landscape Austria – the Austrian AI landscape: an overview of the entire ecosystem covering startups, companies, research institutions as well as their geographic distribution and growth. October 2020. <https://www.enlite.ai/works/ailandscapeaustria>. Zugegriffen: 22. Sept. 2020
- Europäische Kommission (2019) Verhaltenskodex für den Bereich der Desinformation nach einem Jahr: Online-Plattformen legen Selbstbewertungsberichte vor. Erklärung der Europäischen Kommission, 29. Oktober 2019. https://ec.europa.eu/commission/presscorner/detail/de/statement_19_6166. Zugegriffen: 22. Sept. 2020
- Evtimov I, Eykholt K, Fernandes E, Li B (2017) Physical adversarial examples against deep neural networks. BAIR Berkely Artificial Intelligence Research, Dec 30, 2017. <https://bair.berkeley.edu/blog/2017/12/30/yolo-attack/>. Zugegriffen: 22. Sept. 2020
- Eykholt K, Evtimov I, Fernandes E, Li B, Rahmati A, Xiao C, Prakash A, Kohno T, Song D. (2018) Robust physical-world attacks on deep learning visual classification. CVPR 2018 conference, 10. April 2018
- Fellner A, Krenn W, Schlick R, Tarrach T, Weissenbacher G (2019) Model-based, Mutation-driven Test-case Generation Via Heuristic-guided Branching Search. *ACM Trans Embed Comput Syst* 18(1):4:1–4:28
- Ferrère Th, Nickovic D, Donzé A, Ito H, Kapinski J (2019) Interface-aware signal temporal logic. *HSCC* 2019:57–66
- Friedman TL (2007) The world is flat: the globalized world in the twenty-first century: a brief history of the globalized world in the twenty-first century. Penguin publisher, 5.7.2007, ISBN 9780141034898

- Gershgorn D (2016) Fooling the machine – the byzantine science of deceiving artificial intelligence. Popular Science, March 30. <https://www.popsci.com/byzantine-science-deceiving-artificial-intelligence>. Zugegriffen: 22. Sept. 2020
- Graves L, Cherubini F (2016) The rise of fact-checking sites in Europe. Reuters Institute for the Study of Journalism. <https://reutersinstitute.politics.ox.ac.uk/our-research/rise-fact-checking-sites-europe>
- High Level Expert Group on Fake News and Online Disinformation (2018) Final report of the high level expert group on fake news and online Disinformation. 12 March 2018. <https://ec.europa.eu/digital-single-market/en/news/final-report-high-level-expert-group-fake-news-and-online-disinformation>. Zugegriffen: 22. Sept. 2020
- Hintermayer N (2020) Innovative sicherheit. FORBES, Nr. 6–20, S. 96–99. <https://lnkd.in/e22Rf5H>
- Hochrangige Expertengruppe für künstliche Intelligenz (2019) Ethik-Leitlinien für eine vertrauenswürdige KI. Europäische Kommission, Report, 8. April 2019. <https://ec.europa.eu/digital-single-market/en/news/ethics-guidelines-trustworthy-ai>. Zugegriffen: 26. Sept. 2020.
- Jaksic S, Bartocci E, Grosu R, Nguyen T, Nickovic D (2018) Quantitative monitoring of STL with edit distance. Formal Methods Syst Des 53(1):83–112
- Kurzweil, R. (2005) Singularity Is Near. VIKING, published by the Penguin Group, Erstausgabe 2005, ISBN 0–670–03384–7
- Leitner, K.-H. (2003) Von der Idee zum Markt: die 50 besten Innovationen Österreichs. Böhlau, Wien S. 268 ff.
- Leopold H (2017) Social communication for corporate innovation management. Lancaster University, School of Computing and Communications, Lancaster, UK, PhD
- Leopold H, Bleier T, Skopik F (2015) Cyber Attack Information System – Erfahrungen und Erkenntnisse aus der IKT-Sicherheitsforschung. Springer, Berlin. ISBN 978–3–662–44306–4
- Leopold H, Krenn W, King R, Mateis C (2020) Artificial Intelligence Landscape – An Introduction in Technology Fields & Research Areas. AIT Technical Report, March 17, 2020. https://www.researchgate.net/publication/332471378_Artificial_Intelligence_Landscape_-_An_Introduction_in_Technology_Fields_Research_Areas
- Lohr S (2018) Facial recognition is accurate, if you're a white guy. New York Times, Feb. 9, 2018. <https://www.nytimes.com/2018/02/09/technology/facial-recognition-race-artificial-intelligence.html>
- Manhart, K. (2018) Eine kleine Geschichte der Künstlichen Intelligenz. Computerwoche, 17.1.2018, <https://www.computerwoche.de/a/eine-kleine-geschichte-der-kuenstlichen-intelligenz,3330537,2>. Zugegriffen: 25. Sept. 2020
- Nations D (2020) What is a CAPTCHA Code?, updated on February 27, 2020. <https://www.lifewire.com/what-is-a-captcha-test-2483166>
- Ničković D, Lebeltel O, Maler O, Ferrere T, Ulus D (2020) AMT 2.0: qualitative and quantitative trace analysis with extended signal temporal logic. Int J Softw Tools Technol Transfer, 3. August 2020. <https://doi.org/10.1007/s10009-020-00582-z>
- Nickovic D, Lebeltel O, Maler O, Ferrère T, Ulus D (2018) AMT 2.0: qualitative and quantitative trace analysis with extended signal temporal logic. TACAS (2) 2018: 303–319
- Precht RD (2020) Künstliche Intelligenz und der Sinn des Lebens. Wilhelm Goldmann, München
- Reichl P, Frauenberger C, Funk M (2020) Homo Digitalis – Wiener Kreis zur Digitalphilosophischen Anthropologie. Letzter Update im Jänner 2020. <http://www.homodigitalis.at/>
- Ribeiro MT, Singh S, Guestrin C, (2016) “Why should i trust you?": explaining the predictions of any classifier. ACM, KDD, (2016) San Francisco. CA, USA
- Samuels M (2017) Hacking risk for computer vision systems in autonomous cars. SecurityIntelligence, 10.8.2017. <https://securityintelligence.com/news/hacking-risk-for-computer-vision-systems-in-autonomous-cars/>

- Schindler A. (2018) AI and the need of a responsible and inclusive Innovation Policy. In: OVE Newsletter Social Media, „Beherrschen wir die künstliche Intelligenz“, November 2018
- Silver D, Schrittwieser J, Simonyan K et al. (2017) Mastering the game of go without human knowledge. *Nature* 550:354–359. <https://doi.org/10.1038/nature24270>
- Silver, N. (2012) The signal and the noise: why so many predictions fail – but some don't, Penguin Group, 27 September 2012
- Turing AM (1950) I. Computing machinery and intelligence, mind – a quarterly review of psychology and philosophy. *LIX*(2360):433–460 (October 1950) <https://doi.org/10.1093/mind/LIX.236.433>
- Zhang JM, Harman M, Ma L, Liu Y (2020) Machine learning testing: survey, landscapes and horizons. In: *IEEE Transactions on Software Engineering*, doi: <https://doi.org/10.1109/TSE.2019.2962027>

Dipl.-Ing. Helmut Leopold, PhD leitet seit 2009 am AIT Austrian Institute of Technology das Center Digital Safety and Security. In dieser Rolle verantwortet er Forschungsschwerpunkte im Bereich der Digitalisierung wie künstliche Intelligenz, Cyber Security, sichere Softwareentwicklung und Schutz kritischer Infrastrukturen. In seiner Zeit als Technologiechef der Telekom Austria war er maßgeblich für die Digitalisierungstransformation des Unternehmens zu einem modernen Multimedia- und Breitbandunternehmen verantwortlich und steuerte dabei erfolgreich den Umbau des Telefonnetzes als größte Kommunikationsinfrastruktur des Landes in ein internet-basiertes Hochleistungssprach- und Datennetz. Er wurde am 27. April 1963 in Hohenems, Vorarlberg, geboren. Nach Abschluss der Höheren Technischen Lehranstalt (HTL) für Elektronik und Nachrichtentechnik in Rankweil, Vorarlberg, absolvierte er das Informatikstudium an der Technischen Universität Wien und promovierte zum Doktor der Philosophie in Computer Science an der Universität Lancaster in England.

Vergessen wir mal die Roboter: So gelingt Künstliche-Intelligenz-Ethik in der Praxis

Tobias Zwingmann und Tobias Gärtner

1 Missverständnisse über künstliche Intelligenz

Künstliche Intelligenz (KI) wird uns alle zerstören. Der Mensch wird von Algorithmen überflüssig gemacht. Die Maschinen geraten außer Kontrolle. So oder so ähnlich zeichnen viele Science-Fiction-Filme das düstere Zukunftsszenario beim Thema KI. Nun ist Science Fiction nicht immer ein schlechter Berater für die Zukunft. Wer hätte nicht schon gern einen Transporter wie bei *Star-Trek* oder einen Babelfish im Ohr wie bei *The Hitchhiker's Guide to the Galaxy?* – Die Technologie KI kommt in Science Fiction allerdings immer relativ schlecht weg – ob nun beim *Terminator*, der aus der Zukunft geschickt wird, oder die sich gegen den Menschen richtende KI wie in der *Matrix*. Warum ist das eigentlich so?

Unser Verhältnis zur KI ist (noch) ein Verklärtes. Das ist per se nichts Ungewöhnliches, denn tatsächlich wurde so ziemlich jede größere technische Innovation initial mit einer gehörigen Portion Skepsis oder aber auch Aberglaube kritisch beäugt: Die industrielle Verbreitung der Elektrizität gegen Ende des 19. Jahrhunderts war beispielsweise geprägt von Angst und Verunsicherung bei vielen Menschen. Dem US-Präsident Benjamin Harrison wird nachgesagt, er hätte so große Angst vor Stromschlägen gehabt, dass er Lichtschalter im Weißen Haus grundsätzlich nur durch Angestellte bedienen ließ (Gunderson 2010). Die Menschheitsgeschichte ging sogar so weit, dass Entdeckungen

T. Zwingmann (✉)
Hannover, Deutschland

T. Gärtner
Hannover, Deutschland

und genialen Erfindungen ein eigener Dämon zugewiesen wurde: „Belphegor“, geboren aus der Todsünde „Trägheit“ (Lewis 2018).

Dass wir heute beim Begriff Elektrizität nicht mehr an Dämonen denken und die Lichtschalter selbst bedienen, liegt vor allem an zwei wesentlichen Faktoren:

Erfahrungswissen Menschen haben ihre Erfahrungen mit Elektrizität gemacht. Sie wissen, dass Elektrizität hervorragend dazu geeignet ist, um im Winter nicht im Dunkeln zu sitzen oder zu frieren. Die Technologie hat sich bewährt. Gleichzeitig wissen wir, dass man besser die Finger von der Steckdose lässt.

Fachwissen Auch wenn wir keine ausgebildeten Elektriker sind, so haben wir doch ein grundsätzliches Verständnis davon, was Elektrizität ist und wie diese funktioniert. Wir bekommen dies bereits in der Schule gelehrt.

Erfahrungs- und Fachwissen sind die Grundlage für einen befreiten Umgang mit einer Technologie (Wachsmuth und Meyer-Fujara 1992). Im Bereich KI sind wir davon noch ein gutes Stück entfernt. Wir denken zwar nicht mehr an Dämonen und Geister, aber dafür eben an Roboter oder übermenschliche Kräfte. Bevor wir uns also an die ethische Diskussion zu KI wagen, benötigen wir ein robustes Verständnis davon, was KI überhaupt bedeutet und wie diese Technologie funktioniert.

2 Was ist künstliche Intelligenz?

KI wird gemeinhin in schwache und starke KI unterschieden (Kreutzer und Sirrenberg 2019). Starke, oder auch allgemeine, KI (AKI) bezeichnet Computersysteme, deren kognitive Fähigkeiten am ehesten denen eines Menschen entsprechen. Eine AKI kann eine Lösung auf ein vorher noch nie gesehenes Problem finden, ähnlich des Menschen. Dafür werden unter anderem Konzepte und Fähigkeiten wie logisches Denken, Kausalität und semantisch organisiertes Wissen vorausgesetzt. Von AKI ist man heute noch viele Jahre entfernt. Ob sie überhaupt erreicht wird, ist durchaus umstritten. Bis heute ist keine KI in der Lage, ein ungesesehenes Problem auf Basis kausaler Ableitungen und logischen Denkens zu lösen, geschweige denn, ein eigenes, menschenähnliches Bewusstsein zu entwickeln (Ford 2018).

Demgegenüber steht das Konzept der schwachen KI. Hierbei handelt es sich um eine spezielle Form, die heute breite Anwendung findet und die im Wesentlichen auf zwei Tatsachen beruht:

- Schwache KI wird anhand historischer Daten trainiert.
- Schwache KI ist optimiert für einen konkreten Anwendungsfall bzw. ein bestimmtes Problem.

Schwache KI ist heutzutage praktisch allgegenwärtig und aus moderner Technologie nicht mehr wegzudenken. Jeder, der schon einmal Kontakt mit einem Sprachassistenten hatte, eine Suchanfrage im Internet stellte oder der Empfehlung eines Online-Services gefolgt ist, nutzte mit hoher Wahrscheinlichkeit eine KI-gestützte Anwendung.

Wenn wir also die Roboter außen vorlassen: Wie genau kann man sich nun eine schwache KI vorstellen? Am einfachsten ist es vielleicht, diese Form der KI als eine Art Werkzeugkasten zu sehen. Mit diesem Werkzeugkasten lässt sich Software entwickeln, die nicht anhand expliziter Programmiervorgaben geschrieben, sondern durch Beispiele angelernt bzw. trainiert wird. In diesem Werkzeugkasten liegen Werkzeuge wie Machine Learning, Deep Learning, Reinforcement Learning oder auch künstliche neuronale Netze (Kozyrkov 2019).

3 Wie entsteht künstliche Intelligenz?

Die Entwicklung einer schwachen KI ist per Definition immer bezogen auf einen Anwendungsfall und folgt einem bestimmten Herstellungsprozess.

Ein sehr populäres Prozessmodell ist das sogenannte CRISP-DM Framework, dessen wesentliche Prozessschritte in Abb. 1 dargestellt sind (Chapman et al. 2000):

Der Prozess startet mit dem Bereich des *Business Understanding*. Hier wird initial ein bestimmter Anwendungsfall oder auch eine Problemstellung mit Geschäftsrelevanz ausgewählt. Ob es hierbei um die Verbesserung der Qualitätskontrolle in der industriellen Fertigung oder um die Auswahl von Bewerber:innen geht, spielt dabei letztlich keine Rolle.

Im zweiten Schritt steht das *Data Understanding*, also die Sichtung, Analyse und Einschätzung der (idealerweise) vorhandenen Daten, die im Zusammenhang mit dem zu lösenden Problem stehen (könnten) oder in diesem Kontext erhoben werden müssen.

Erst in den folgenden Schritten drei und vier, *Data Preparation* und *Modeling* kommt der eigentliche KI-Werkzeugkasten im engeren Sinn zum Einsatz. Die Aufgabenstellung ist nun relativ eng umrissen: Mithilfe eines beliebigen Algorithmus soll ein Modell der Trainingsdaten gefunden werden, das die in den Daten enthaltenen Muster abbildet und soweit abstrahiert, dass ein guter Kompromiss zwischen Generalisierbarkeit und Genauigkeit erreicht wird. Und genau in der Erstellung dieses Modells liegt der eigentlich revolutionäre Ansatz der KI begründet.

Stellen Sie sich vor, Sie wollen einem Computer beibringen, ob in einem gegebenen Bild ein Mensch zu sehen ist. In der klassischen Softwareentwicklung (ohne KI) müssten Sie selbst ein Regelwerk (Algorithmus) erfinden, der jedes Bild anhand einer vorgegebenen Wenn-Dann-Vorschrift analysiert und am Ende zu einer Entscheidung kommt, ob das gegebene Foto einen Menschen beinhaltet oder nicht. Ist auf dem Bild ein Kopf zu erkennen? Sind dort Augen? Sind es maximal zwei Augen? Und so weiter. Diesen Prozess manuell auszuformulieren, ist extrem mühselig und aufgrund der gegebenen Komplexität auch nicht immer vollständig lösbar.




Abb. 1 CRISP-DM-Prozessmodell (Chapman et al. 2000)

Mithilfe von schwacher KI können Entwickler nun „einfach“ einen Algorithmus mit einer Vielzahl von vorher korrekt gelabelten Bildern von Menschen und Nichtmenschen speisen. Der Algorithmus findet dann selbst die Verarbeitungsvorschrift, mithilfe derer sich die Menschen von den Nichtmenschen auf Bildern unterscheiden lassen.

Neben ausreichend Daten sind für diesen Prozess auch viel Rechenleistung und ein Set an effizienten KI-Trainingsalgorithmen notwendig. Und genau auf diesen Gebieten gab es in den letzten Jahren enorme Durchbrüche: Nie zuvor wurden in der Geschichte der Menschheit so viele Daten produziert wie heute. Dank Cloud Computing stehen enorme Mengen an Rechenkapazität zur Verfügung. Und Grundlagenforschung, wie beispielsweise die Anwendung des Backpropagation-Algorithmus im Bereich der künstlichen neuronalen Netzwerke ist es zu verdanken, dass viele Daten auf großen Rechenkapazitäten effizient nach relevanten Mustern im hochdimensionalen Raum analysiert werden können (Rumelhart et al. 1986).

Im Schritt *Evaluation* wird die Generalisierbarkeit und Genauigkeit des entwickelten Modells getestet. Im Idealfall erweist sich das Modell als so gut, dass dieses in den produktiven Betrieb zur Lösung des gegebenen Anwendungsfalls übergehen kann, wo es idealerweise laufend angepasst und verbessert wird („*deployment*“). Im schlechtesten

Fall kommt man hier zur Erkenntnis, dass die vorhandenen Daten, die bekannten Algorithmen oder die vorhandene Rechenleistung nicht ausreichen, um das Problem zu lösen, und man beginnt wieder von vorn, eventuell mit einer stärkeren Problemeingrenzung oder Redefinition des Projekts.

4 Herausforderung: Künstliche Intelligenz und Ethik

Bis zu einer AKI, falls sie überhaupt je erreicht werden kann, ist KI also immer ein Teil einer größeren Anwendung und damit Teil eines Prozesses.

Im Sinn einer ethischen Diskussion muss deshalb zuerst die Verantwortungsfrage gestellt werden. Verantwortlich für Taten können nur Entitäten sein, die sich der Folgen ihres Handelns bewusst sind und Entscheidungen mittels Ratio treffen können (s. etwa §21 StGB). Aus diesem Grund wird etwa bei Strafrechtsprozessen nach Hundeangriffen der Besitzer und nicht der Hund zur Verantwortung gezogen. KI erfüllt diese Anforderungen im Moment nicht. Sie verarbeitet einen Datenstrom als Input mit höchst komplexen Regeln zu einem Output (Witten et al. 2002). Neuere Architekturen mit mehreren Agenten wie Googles AlphaGo (Wang et al. 2016) oder Generative Adversarial Networks (GAN) sorgen dafür, dass der Output eines Netzwerks direkte Konsequenzen hat, da sich der erneute Input ändert (Goodfellow et al. 2016; Abb. 2).

Allerdings unterscheidet sich das Wissen über die Konsequenzen des eigenen Handelns immer noch von ethischem Handeln. Hierzu fehlt ein bewusster Ankerpunkt,




Abb. 2 Vereinfachte schematische Darstellung von Feed Forward und Generative Adversarial Networks zur Verdeutlichung von Datenflüssen (eigene Darstellung)

um zwischen zweckdienlichen und ethisch wünschenswerten Ergebnissen des eigenen Handelns zu unterscheiden. So ist der Mensch sich etwa seiner Sterblichkeit bewusst und kann daher darüber reflektieren, dass das Töten eines weiteren Menschen zwar zum eigenen Vorteil gereichen kann, dieses jedoch der sozialen Gruppe schadet. Aus diesem Grund enthalten Religionen und die meisten philosophischen Denkschulen ein Tötungsverbot. Nach heutigem Stand der Technik ist eine KI-Anwendung hierzu nicht in der Lage.

Wenn also eine KI nicht ethisch denken und handeln kann, wie kann dann die Frage nach Ethik in der KI beantwortet werden? Die Antwort auf diese Frage ergibt sich aus den Anwendungen, die auf KI beruhen. Vor allem der rasante Anstieg an Rechenleistung und Daten der letzten Jahrzehnte ermöglicht es erst, KI in breitere Anwendungsgebiete vordringen zu lassen (Buchanan 2005). Alle Anwendungen, die im Verlauf dieses Texts vorgestellt werden, waren auch schon vor der KI in geringerem Umfang möglich. Aber erst durch KI können sie skalieren. Zusätzlich wird KI-Anwendungen zugeschrieben, dass sie streng nach Regeln vorgehen und sich nicht durch Gefühle und Vorurteile leiten lassen. So bewertet etwa eine KI Essays von Studierenden, die den Test Of English as a Foreign Language (TOEFL) belegen (Burstein et al. 2017). Die Hoffnung ist hier, dass durch den Einsatz von KI eine konsistentere und damit fairere Bewertung von Essays zustande kommt.

Die ethische Frage ergibt sich aus der Anwendung. Wenn eine Maschine oder ein Algorithmus die Aufgabe eines Menschen übernimmt, übernimmt er auch gleichzeitig die ethischen Fragen dieser Aufgabe. Es erscheint daher sinnvoll, Anwendungen auf Basis ihrer ethischen Tragweite zu kategorisieren. Da diese Anwendungen immer auf Basis von historischen Daten beruhen, ergibt sich hier eine zweite Dimension. Die erste Dimension erstreckt sich von Anwendungen, die keinen Einfluss auf andere Menschen haben, bis zu solchen, bei denen es um Leben und Tod eines oder mehrerer Menschen geht. Die zweite Dimension erstreckt sich anhand der Datenschutzkategorien von Maschinendaten über personenbezogenen Daten zu hoch schutzbedürftigen Daten (etwa Daten nach §203 StGB). Beispielfhaft sollen hier einige Anwendungen vorgestellt und eingeordnet werden (Abb. 3).

Am unbedenklichsten erscheinen solche Anwendungen, denen Daten ohne Personenbezug ausreichen und deren Ergebnisse keinen Einfluss auf andere Menschen haben. In diese Kategorie fallen vor allem Internet-of-Things-Anwendungen. So kann beispielsweise eine KI eingesetzt werden, um in einer Produktionsstrecke zu überprüfen, ob ein Bauteil richtig verarbeitet wurde. Handelt es sich dabei um triviale Produkte wie Deoroller, Lautsprecher oder Computertastaturen, so obliegt es allein den Qualitätsansprüchen des Herstellers, besondere Ansprüche an die KI zu stellen.

Deutlich sensiblere Daten werden für datengestützte Werbekampagnen oder Versicherungstarife benutzt. Hierbei werden vor allem Daten mit Personenbezug verwendet. Ziel ist es hierbei, menschliches Verhalten vorherzusagen und gegebenenfalls zu beeinflussen. Im Sinn der Werbung sollen Menschen zu Kunden gemacht werden. Bei Versicherungstarifen wird das Schadensrisiko abgeschätzt und ein Tarif berechnet. Während




Abb. 3 Ethische und datenschutzrechtliche Kritikalität einzelner beispielhafter Anwendungsfälle (eigene Darstellung)

im ersten Beispiel schlimmstenfalls unpassende Werbung ausgespielt wird oder ein Kunde mehr kauft, als ursprünglich beabsichtigt, so wird der Tarif im zweiten Beispiel allerhöchstens teuer.

Viele Kaufprozesse unterliegen in Deutschland einer Bonitätsüberprüfung. Erst wenn diese positiv ausfällt, kann ein Kaufvertrag zustande kommen.¹ Die Kreditwürdigkeit hat dabei einen direkten Einfluss auf die Höhe von Zinsen für Kredite, gegebenenfalls gewährte Rabatte oder gar das grundsätzliche Zustandekommen des Vertrags. Die Bonität wird hierbei aus der Kredithistorie der betroffenen Person und der Kreditwürdigkeit von Vergleichsgruppen errechnet. Aufgrund der Komplexität der Berechnungen und der Vielzahl an zu berücksichtigenden Variablen ist davon auszugehen, dass KI zum Einsatz kommt (Schufa 2020). Da vor allem junge Menschen vielfach kaum oder gar keine Kredite aufgenommen und vor allem zurückgezahlt haben, werden andere Metriken berücksichtigt. Da vor allem die Kreditwürdigkeit der näheren lokalen Umgebung berücksichtigt wird, kann es dazu kommen, dass junge Menschen aus sozial schwachen Gebieten kaum oder keine Kredite bekommen. Da aber nicht nur Banken, sondern auch Vermieter, Telekommunikationsunternehmen oder andere Dienstleister auf diese Daten zugreifen, ergibt sich eine enorme ethische Tragweite. Außerdem sind Unternehmen, die Kreditwürdigkeit berechnen, im Gegensatz zu Banken und Versicherungen nicht dazu

¹ Hinweise auf eine Überprüfung der Bonität durch Schufa, Creditreform oder Arvato finden sich in den jeweiligen Datenschutzhinweisen der Händler und Dienstleister.

verpflichtet, Auskunft darüber zu erteilen, wie diese Ergebnisse zustande gekommen sind.

Zuletzt sind Anwendungsfälle zu nennen, die direkten Einfluss auf die körperliche Unversehrtheit von Menschen haben. Hierzu zählen beispielsweise neben Medikamententests vor allem autonomes Fahren und militärische Anwendungen. Während KI-Systeme bei Medikamententests allein schon durch die entsprechenden Sicherheitsvorkehrungen bei solchen Forschungsvorhaben eingeeht sind, sieht es bei den beiden anderen Fällen anders aus (s. Arzneimittelgesetz).

Bei autonom agierenden Verkehrsteilnehmern wird eine alte philosophische Fragestellung mit anderem Schwerpunkt erneut gestellt. Angelehnt an das Trolley-Problem wird das so formuliert: „Im Fall eines nicht mehr zu verhindernden Verkehrsunfalls mit potenziell tödlichen Folgen, soll A oder B vom Fahrzeug getroffen werden?“. Das Problem ergibt sich daraus, dass A und B jeweils nacheinander von unterschiedlichen Personen oder Gruppen eingenommen wird. Hierfür wird z. B. eine Gruppe junger Schüler mit einer Gruppe von Rentnern verglichen, um dann in einem zweiten Schritt etwa den Kindern tödliche Krankheiten und den Rentnern ein noch langes Leben anzudichten. Das ethische Potenzial für KI ergibt sich nun daraus, dass nicht ein Mensch entsprechend seiner ethischen Überzeugungen handelt, sondern eine Maschine entscheidet, wer überfahren werden soll. Da die Maschine mit klaren Regeln ausgestattet werden muss, ergibt sich die Frage nach einer ethischen wie auch rechtlichen Verantwortung. Liegt sie beim Fahrer? Wird sie der Maschine zugeordnet? Oder bleibt sie beim Programmierer des Fahrzeugs? Da schon die philosophische Frage in der analogen Welt nicht beantwortet werden konnte, erscheint es unwahrscheinlich, über eine juristische Bewertung hinaus zu einer ethischen Einschätzung zu kommen. Vor allem die Diskussion in Bezug auf den Abschuss von entführten Flugzeugen, wie sie nach den Terroranschlägen vom 11. September 2001 geführt wurde, hat gezeigt, dass hier unabhängig von KI noch keine befriedigende Lösung gefunden wurde (BVerfG 2006).

5 Ansätze einer prozessorientierten Künstliche-Intelligenz-Ethik

Die ethischen Dimensionen der KI entfalten sich – wie bei jeder anderen Technologie auch – nicht nur in deren eigentlicher Anwendung, sondern vor allem in den der Technologie vor- und nachgelagerten Prozessschritte.

Betrachten wir die ethische Dimension der Entwicklung KI-gestützter Anwendungen entlang der Prozessschritte innerhalb des CRISP-DM Frameworks:

Es soll dabei von zwei Grundannahmen ausgegangen werden:

1. Es werden keine ethischen Anforderungen an kapitalistische Grundannahmen gestellt. Der Sprechakt: „KI unterstützt das Kapital in seinem unethischen Handeln und ist daher selbst unethisch“ wird von dieser Diskussion ausgeschlossen.

2. Darüber hinaus wird angenommen, dass sich die handelnden Personen an Recht und Gesetz halten, insbesondere der Datenschutz-Grundverordnung sowie allgemeinen und branchenspezifischen Gesetzgebungen (z. B. Versicherungsvertragsgesetz).

Business Understanding

Die Auswahl des Use Case und damit einhergehend die Beschreibung des Problems und der avisierten Lösung stellen fundamentale Weichen für die ethische Betrachtung. Das gleiche Problem kann in völlig unterschiedlichen ethischen Dimensionen bearbeitet werden, wie folgendes Beispiel verdeutlicht:

Nehmen wir als exemplarischen Use Case die Optimierung der Qualitätssicherung im Produktionsprozess eines industriellen Fertigungsbetriebs. Die Qualitätssicherung eines Werkstücks unterliegt per se keiner ethischen Komponente, solange sie keine personenbezogenen Daten verarbeitet und keine Auswirkung auf andere Menschen hat. Wenn das Problem allerdings so definiert wird, dass die computergestützte Qualitätssicherung *besser* abschneiden soll als eine menschlich gestützte Qualitätssicherung, öffnet sich eine erste ethische Dimension. Denn was genau heißt hier *besser*? Soll die KI-gestützte Variante *generell besser* sein, als die manuelle Qualitätssicherung oder nur *besser im Vergleich zu einzelnen Kohorten*, beispielsweise neu angelernten Facharbeitern. Im letzteren Fall könnte das dazu führen, dass die KI-gestützte Qualitätssicherung einen Vorab-Check der Werkstücke durchführt und nur komplizierte Entscheidungen an den Menschen delegiert. Um im Beispiel zu bleiben: Das Ziel der Qualitätsoptimierung kann auch von vornherein so definiert werden, dass die KI-gestützte Anwendung nur dabei unterstützen soll, die menschliche Entscheidung zu verbessern, indem bessere Informationen dargestellt werden, statt sie zu ersetzen. Wie sich leicht erkennen lässt, bestimmen Ausgestaltung und Design des Anwendungsfalls die ethische Tragweite des zu bearbeitenden Problems maßgeblich.

Die Auswahl und Ausformulierung des Anwendungsfalls definieren die ethische Relevanz des gesamten Projekts.

Data Understanding

Die Problembeschreibung des Business Understanding sollte prinzipiell die Anforderungen an die hierfür benötigten Daten vorgeben. In der Praxis ist das allerdings vielmehr ein wechselseitiges Spiel: Die Use Cases werden anhand der vorhandenen Daten gebildet oder aber die vorhandenen Daten werden auf Eignung für den Use Case geprüft.

Angenommen, ein Kreditinstitut möchte die Kreditvergabe an Kunden optimieren. Im Business Understanding wurde als Ziel festgelegt, dass die Kreditausfallrate minimiert werden soll, gegeben bestimmter Eigenschaften des Kunden zum Zeitpunkt des Vertragsabschlusses. Prinzipiell müsste nun ein Set an Kunden akquiriert werden, bei denen die benötigten Daten erhoben werden und anschließend die Kreditvergabe im Zeitverlauf beobachtet wird. In der Praxis ist dieses Vorgehen häufig nicht realisierbar, weil entweder zu zeitintensiv (die Daten müssen erst noch erhoben werden) und/oder fachlich

zu komplex (Welche Kundeneigenschaften sollten erhoben werden und wie lang ist der Beobachtungszeitraum?). Stattdessen wird häufig auf historische Daten zurückgegriffen und diese werden neu ausgewertet. Dieses Vorgehen kann gleich an mehreren Stellen problematisch werden:

- Historische Daten können unvollständig sein, d. h. relevante Informationen fehlen aus verschiedensten Gründen.
- Historische Daten können verzerrt sein, d. h. bestimmte Segmente sind hierin über- oder unterrepräsentiert und somit diskriminiert.
- Historische Daten können anderen Annahmen zugrunde liegen, d. h. aus anderen Verteilungen (z. B. soziodemografische Struktur) entspringen.
- Historische Daten können fehlerhaft sein.

Je hochdimensionaler ein Datensatz ist, desto schwieriger wird es, diese Zusammenhänge und Abhängigkeiten zu überblicken. Die ethische Dimension liegt nun in der Sorgfalt, die der Mensch in die Prüfung dieser Zusammenhänge legt, bevor die Entscheidungsfindung einem automatisierten System überlassen wird. Im einfachsten Fall werden die Muster und Fehler aus der Vergangenheit in die Zukunft fortgeschrieben und es entstehen qualitativ schlechte Modelle. Im schlimmsten Fall werden Personengruppen im weiteren Verlauf des Projekts systematisch diskriminiert und müssen unter den Auswirkungen leiden.

Daten sollten daher in keinem Fall als gegeben angesehen werden, sondern verlangen stattdessen eine anwendungsfallspezifische Kuratierung mit entsprechendem Sampling.

Data Preparation

Welche der vorhandenen Daten sollen überhaupt in das KI-Modell einfließen können? Die aus Entwicklersicht einfachste Variante ist, grundsätzlich erst einmal mit allen vorhandenen und rechtlich nutzbaren Daten zu starten und diese nach und nach zu reduzieren, sofern es der Qualität des zu trainierenden Modells dienlich ist. Dieses Vorgehen kann schnell in ein ethisches Dilemma münden: Während sehr genaue, komplexe KI-Modelle in der Regel hochdimensionale und nichtaggregierte Datensätze zu Trainingszwecken benötigen, verlangt der Grundsatz der Datensparsamkeit der DSGVO eine Abwägung der Interessen des Betroffenen und den wirtschaftlichen Interessen des Unternehmens. Diese Abwägung liegt letztlich bei allen rechtlich gegebenen Rahmenbedingungen auch zu einem großen Teil im verantwortlichen Entwicklungsteam. Bei der Reduktion von Daten zu einzelnen anonymisierten Gruppen (beispielsweise „*k-anonymity*“) gilt es beispielsweise den Parameter *k* zu bestimmen, der die Gruppengröße und damit den Anonymitätsfaktor festlegt (Trombetta et al. 2010). Auch bei der Auswahl der Features ist darauf zu achten, dass durch eine Kombination verschiedener Variablen keine Rückschlüsse auf eigentlich entfernte Merkmale zulässig sind. So können beispielsweise metrische Angaben wie Größe, Alter und Gewicht dazu benutzt werden, das Geschlecht eines Datensatzes implizit zu modellieren. Deswegen ist

auch hier auf das Gebot der Datensparsamkeit zu achten, sofern dies für den gegebenen Use Case Anwendung findet:

Eigenschaften, die aus ethischen Gründen nichts im Modell verloren haben, sollten im Trainingsdatensatz erst gar nicht vorhanden sein.

Modelling

Es liegt grundsätzlich nahe, dass die rein programmatische Optimierung eines Modells gegeben eines bestimmten Datensatzes und eines bestimmten Ziels per se keine ethische Komponente beinhaltet. Das trifft jedoch nur zum Teil zu: Moderne Software ermöglicht es, extrem komplexe KI-Algorithmen mit Tausenden von Verarbeitungsvorschriften mit nur einer Handvoll Zeilen Code zu trainieren. Dies ist einerseits sehr bequem, verführt aber auch dazu, die eigentlichen Entscheidungsprozesse vollständig dem Computer zu überlassen. Diese Nachlässigkeit kann dazu führen, dass unter Tausenden Entscheidungen auch bestimmte Einzelfälle auftreten, bei denen das trainierte Modell zu völlig unplausiblen Ergebnissen kommt. Inwiefern diese Ausreißer erklärbar und logisch nachvollziehbar sein müssen, liegt auch hier wieder im Anwendungsfall und dessen Auswirkungen auf einen Menschen begründet.

Bei Anwendungsfällen mit Auswirkungen auf Menschen sollte eine Erklärbarkeit des Modell-Outputs im Einzelfall grundsätzlich immer angestrebt werden.

Evaluation

Die Auswahl der Metriken, auf denen die KI-Modelle letztlich optimiert werden, sind sowohl für den wirtschaftlichen Erfolg des Modells, aber auch für deren Auswirkungen auf andere Menschen maßgeblich entscheidend: Wer beispielsweise im Szenario des autonomen Fahrens die Anzahl der Unfälle minimieren möchte, lässt einfach keine Autos losfahren. Insofern ist die Metrik für die Bestimmung des besten Modells enorm wichtig und unter Abwägung verschiedener und zum Teil konfliktärer Ziele zu treffen.

Deployment

Die Überführung einer KI-gestützten Anwendung in eine Produktionsumgebung ist letztlich nur der erste Schritt für ein kontinuierliches Monitoring der KI-Anwendung, die auch selbst einer permanenten Evolution unterliegt. Insofern ist der Schritt des Deployment nicht das Ende, sondern vielmehr der Anfang, die vorgenannten Betrachtungsdimensionen laufend neu zu bewerten.

6 Fallbeispiel: Künstliche-Intelligenz-Ethik in der Versicherungswirtschaft

Versicherungen basieren in ihrem Geschäftsmodell auf Daten und ihrer Auswertung. Der Preis und die Rentabilität eines Versicherungsprodukts ergibt sich aus der Schadenwahrscheinlichkeit, den technischen und organisatorischen Unkosten und einer Preis-

reduktion auf Basis der Investitionen, die mit den eingesammelten Prämien getätigt werden. Der Erfolg einer Versicherung ergibt sich also aus der möglichst genauen Abschätzung eines Risikos. Hierzu werden zusätzlich zu den Informationen, die der Versicherungsnehmer beim Antrag angibt, noch geografische und makroökonomische Kennzahlen hinzugezogen. Die eigentliche Auswertung erfolgt traditionell in den Aktuariaten mit klassischer Statistik. In den letzten Jahren haben auch hier KI-Algorithmen Einzug gehalten. Zusätzlich zu den aktuariellen Tätigkeiten ergeben sich noch Ansatzpunkte an verschiedenen Stellen des Customer Lifecycles. Dieser beginnt mit der richtigen Ansprache (KI allokiert automatisch Werbebudgets und schlägt etwa Vermittlern sinnvolle zusätzliche Produkte vor), geht über das Angebot (KI schätzt einzelne Werte im Antragsprozess, um die Anzahl an Fragen zu reduzieren) und endet in der Schadenbearbeitung und der Kundenbetreuung (KI sagt die Kündigungswahrscheinlichkeit voraus, Kundenbetreuer reagieren präventiv darauf und versuchen den Kunden zu halten; Abb. 4).

Teile dieses Prozesses finden sich auch in anderen Branchen wieder. Um die ethische Frage zu beantworten, soll zuerst einmal betrachtet werden, wo sie sich in diesem Prozess stellen.

Die einzelnen Stationen dieses Lebenszyklus sind bereits durch unterschiedlichste Rechte und Vorschriften reguliert. Die Datenschutz-Grundverordnung regelt, welche Daten zu welchem Zweck gespeichert und verarbeitet werden dürfen. Vor allem für Werbung bedeutet dies, dass etwa soziale Medien deutlich mehr über ihre Kunden wissen, als Versicherungen. Selbst wenn ein soziales Netzwerk unethische Daten wie sexuelle Orientierung, ethnische Herkunft oder politische und religiöse Überzeugungen




Abb. 4 Anzahl an betroffenen Personen und Quantität an Daten über betroffene Personen im Verlauf des Customer Lifecycle eines Versicherungsprodukts (eigene Darstellung)

als Auswahlkriterium für Werbeanzeigen zur Verfügung stellen würde, könnte eine Versicherung diese nicht verwenden, da sie diese Informationen über potenzielle und bestehende Kunden nicht hat. Das Versicherungsvertragsgesetz regelt die Bedingungen, unter denen Versicherungen Verträge abschließen dürfen: Art. 1a Abs. 3 sagt in diesem Zusammenhang, dass alle Informationen im Zusammenhang mit Werbung für Versicherungsprodukte „redlich und eindeutig und nicht irreführend“ sein müssen. Das bedeutet unter anderem, dass der Preis für eine Versicherung nur auf Risikomerkmale basieren darf. Ob KI in der Kundenbetreuung etwa durch die Vorhersage von potenziellen Upselling-Möglichkeiten oder bei der Beschwerdevorhersage zum Einsatz kommt, wird in den Datenschutzerklärungen dargelegt. Der eigentliche Algorithmus wird unter Datenschutz-,² Compliance-³ und Informationssicherheitsgesichtspunkten⁴ betrachtet, bevor er produktiv eingesetzt wird. In diesem Prozess wird überprüft, ob die Anwendung aufgrund ihrer Daten oder ihrer Zielsetzung ethisch einwandfrei ist, bevor sie freigegeben wird. Im Schadenmanagement kommt KI vor allem bei der Evaluierung und der automatisierten Abwicklung zum Einsatz. Hier wird vor allem die Höhe des Schadens geschätzt und bei geringfügigen Beträgen automatisch ausgezahlt. Dies ist vor allem bei Massenprodukten mit relativ geringen Schadenssummen der Fall (vor allem bei Hausrat- und KFZ-Versicherungen). Für den Fall, dass sich ein Kunde ungerecht behandelt fühlt, gibt es jederzeit die Möglichkeit, einen Sachverständigen und/oder Anwalt hinzuzuziehen, um die Schätzung anzufechten.

7 Fazit

KI-Ethik unterscheidet sich nicht viel von anderer Technologieethik: Der Anwendungsfall bestimmt die ethische Dimension. Darüber werden die einzelnen Stationen im Entwicklungsprozess einer KI-Anwendung über geltende Rechte und Vorschriften bereits reguliert.

Es ergeben sich drei Neuerungen:

1. KI ermöglicht eine neue Skalierfähigkeit von Anwendungen unter Substituierung kognitiver Prozesse: Dort, wo früher Menschen Entscheidungen auf Basis von fragwürdigen Daten und den eigenen Vorurteilen getroffen haben, entscheidet nun eine KI-Anwendung auf den gleichen, durch Vorurteile geprägten Daten. Ansätze

²Etwa anhand der Datenschutz-Grundverordnung (DSGVO).

³Versicherungsaufsichtliche Anforderungen an die IT (VAIT) durch die Bundesanstalt für Finanzdienstleistungsaufsicht (BaFin) auf Basis des Versicherungsaufsichtsgesetzes §§ 23–32.

⁴Entsprechend der VAIT entweder das IT Grundschutzkompendium des Bundesamts für Sicherheit in der Informationstechnik (BSI) oder ISO 27001.

solcher latenten Diskriminierungen aufzuspüren und zu beseitigen, finden sich in der Forschung und in juristischen Texten (s. beispielsweise Hajian et al. 2016).

2. KI wird auf Gebieten eingesetzt, die direkten Einfluss auf die körperliche und geistige Unversehrtheit einzelner Menschen haben. Hier ergeben sich zwei Probleme. Zuerst einmal ist die Verantwortung in solchen Fällen nicht geklärt. Außerdem bestehen die gleichen ethischen Konflikte, die es vor der KI schon gab. Wenn es zu einer Entscheidung kommt, in der mindestens ein Mensch zu Schaden kommt, muss geklärt werden, ob und nach welchen Prinzipien menschliches Leben gegeneinander aufgewogen wird. Da es sich nach Meinung der Autoren um Randthemen von KI handelt, erscheint eine spezifischere ethische Diskussion zu diesen Themen sinnvoll, anstatt sie über KI im Allgemeinen zu führen.
3. Dank moderner und sehr häufig quelloffener Software liegt die Eintrittshürde in der KI-Entwicklung vergleichsweise niedrig. Das bedeutet, dass die unter Punkt 1 genannten Skalierungseffekte sehr schnell eintreten, und zwar auch dann, wenn das notwendige Fachwissen nicht gegeben ist, oder die ethische Folgenabschätzung nicht im Vordergrund steht.

Mit der gedankenlosen Anwendung von KI-Applikationen lässt sich also im großen Stil viel Schaden anrichten. Umgekehrt kann eine sorgfältige und verantwortungsvolle Entwicklung von KI-basierten Anwendungen diese Skalierungseffekte aber eben auch im Positiven hebeln, zum Wohl der Menschheit. Und hier unterscheidet sich KI nicht wesentlich von anderen revolutionären Technologien wie beispielsweise der Elektrizität:

Anstatt apokalyptische Szenarien zu malen, in denen Roboter die Menschheit auslöschen, empfiehlt es sich fürs erste, die Lichtschalter selbst zu bedienen und sich ein solides Erfahrungs- und Fachwissen anzueignen. Die Ausgangssituation hierfür ist hervorragend: Führende Software-Frameworks zur KI-Entwicklung sind frei zugänglich und quelloffen, Forschungsdatensets stehen im Internet frei zur Verfügung und zahlreiche Weiterbildungsmöglichkeiten können auf Abruf in Anspruch genommen werden – die meisten davon ebenfalls kostenfrei.

Eine Entmystifizierung des Konzepts der KI, wie sie unser Leben und Arbeiten heute schon beeinflusst, ist zwar keine hinreichende, aber eine notwendige Bedingung zur ethisch-nachhaltigen Nutzung dieser Technologie.

Literatur

- BVerfG, Bundesverfassungsgericht (2006) Urteil des Ersten Senats, 1 BvR 357/05, vom 15. Februar 2006
- Buchanan BG (2005) A (very) brief history of artificial intelligence. *AI Magazine* 26.4 (S. 53– 53), PKP
- Burstein J et al (2017) Exploring relationships between writing & broader outcomes with automated writing evaluation. *Proceedings of the 12th Workshop on Innovative Use of NLP for Building Educational Applications*, Copenhagen, Denmark, Sep 8, 2017

- Chapman P et al (2000) CRISP-DM 1.0
- Ford M (2018) Architects of Intelligence: The truth about AI from the people building it. Packt
- Goodfellow I, Bengio Y, Courville A (2016) Deep learning (Adaptive Computation and Machine Learning). MIT Press
- Gunderson M (2010) Benjamin Harrison – United States Presidents, ABDO
- Hajian S, Bonchi F, Castillo C (2016) Algorithmic bias: from discrimination discovery to fairness-aware data mining. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16) (S. 2125–2126), ACM
- Kozyrkov C (2019) Why AI is here to stay, 22.06.2019. <https://medium.com/hackernoon/why-ai-is-here-to-stay-9c75b1868b9b>. Zugegriffen: 29. Okt. 2020
- Kreutzer RT, Sirrenberg M (2019) Künstliche Intelligenz verstehen: Grundlagen – Use-Cases – unternehmenseigene KI-Journey. Springer
- Lewis J (2018) The science of sin: why we do the things we know we shouldn't. Bloomsbury
- Rumelhart D, Hinton G, Williams R (1986) Learning representations by back-propagating errors. Nature 323:533–536
- Schufa, SCHUFA Holding AG (2020) Wie funktioniert Scoring bei der SCHUFA? <https://www.schufa.de/ueber-uns/daten-scoring/scoring/scoring-schufa>. Zugegriffen: 12. Nov. 2020
- Trombetta A, Wei J, Bertnio E (2010) Advanced privacy-preserving data management and analysis. In: Nin J, Herranz J (Hrsg) Privacy and anonymity in information management systems: new techniques for new practical problems. Springer, S 7–30
- Wachsmuth I, Meyer-Fujara J (1992) Wissensbasierte Informationsverarbeitung mit Expertensystemen: Wissen – Fachwissen – Erfahrungswissen. In Informations- und Wissensverarbeitung in den Sozialwissenschaften. Opladen, S 103
- Wang F et al (2016) Where does AlphaGo go: from church-turing thesis to AlphaGo thesis and beyond. IEEE/CAA J Autom Sinica 3(2):113–120
- Witten I et al (2002) Data mining practical machine learning tools and techniques. Elsevier

Tobias Zwingmann arbeitet als Senior Data Scientist bei der Deutschen Messe AG in Hannover mit Fokus auf die Entwicklung datengetriebener Produkte und Geschäftsanwendungen. Er ist außerdem Gründer des KI-Start-ups RPYD.AI und betreut als Data-Science-Mentor Studenten, die eine Weiterqualifizierung im Bereich Data Science und Data Analytics anstreben.
<https://www.linkedin.com/in/tobias-zwingmann/>

Tobias Gärtner ist in verschiedenen Funktionen für die HDI Gruppe tätig. Er hat dort als Data Scientist, Product Owner und Innovation Manager gearbeitet. Vorher war er unter anderem für Advisori FTC und Boehringer Ingelheim tätig.
Tobias_Gaertner@htp-tel.de

Unvoreingenommenheit von Künstliche-Intelligenz-Systemen. Die Rolle von Datenqualität und Bias für den verantwortungsvollen Einsatz von künstlicher Intelligenz

Katrin Strasser und Bernhard Niedermayer

1 Notwendigkeit unvoreingenommener Künstliche-Intelligenz-Systeme

Vorurteile bergen eine Vielzahl an Gefahren. Im Umgang mit Menschen führt sie zur Oberflächlichkeit und dazu, Annahmen zu treffen, die in der Folge nicht bewusst verifiziert werden und oftmals falsch sind. Die Konsequenz daraus ist, dass wir manchen Personen Chancen, die sie verdient hätten, von Beginn an verwehren – andererseits kann es passieren, dass wir auf Personen hereinfallen, die diese Muster für sich ausnutzen.

Wieso Vorurteile dennoch so weit verbreitet sind, lässt sich sehr einfach erklären – es liegt an der unschlagbaren Geschwindigkeit, mit der wir eine Entscheidungsgrundlage schaffen können, die in einer Vielzahl an Fällen gut genug ist. Es geht nicht um das exakt richtige Bild unserer Umgebung oder Situation, sondern um ein nützliches. So kann etwa eine augenblickliche Entscheidung ohne Zögern, ob von einer Person Gefahr ausgeht, diese Gefahr eventuell abwenden. Hat man dann eine Vorsichtsmaßnahme basierend auf einer falschen Annahme getroffen, so entsteht in der Regel kein oder nur wenig Schaden. In anderen Fällen helfen uns schnelle Entscheidungen aufgrund von Stereotypen, eine große Informationsflut überhaupt erst zu bewältigen.

Genau diese pragmatische Sicht auf Vorurteile ist jedoch im Zusammenhang mit IT-Systemen zu verurteilen. Der Geschwindigkeitsgewinn, von dem Menschen durch das Zurückgreifen auf Stereotype profitieren, ist hier nicht relevant. Auf der einen Seite befassen sich sehr viele Aufgabenstellungen, die man heute durch Software lösen

K. Strasser · B. Niedermayer (✉)
Cloudflight Austria GmbH, Linz, Österreich
E-Mail: Bernhard.Niedermayer@cloudflight.io

möchte, nicht mit Beispielen wie oben beschrieben, sondern mit betrieblichen Prozessen. Ob eine Kandidatin einen Job erhalten soll, muss von einer KI nicht in Bruchteilen einer Sekunde entschieden werden.

Auf der anderen Seite können hier Geschwindigkeitseffekte – wenn nötig – durch entsprechende Hardwareressourcen oder durch den Einsatz effizienter Algorithmen erzielt werden. Aktuell geht man von einer Verdoppelung der Leistungsfähigkeit von KI alle zwei Jahre aus (*Huang's Law*).

Dem gegenüber steht unser Werte- und Rechtssystem. Die von der Europäischen Kommission eingesetzte Expertengruppe zu Künstlicher Intelligenz etwa nennt Gleichheit, Nichtdiskriminierung und Solidarität als eine Gruppe von Grundrechten, aus denen Anforderungen an KI-Systeme abzuleiten sind. Daraus ergibt sich ein Anspruch betroffener Personen auf Fairness derartiger Systeme. Darüber hinaus wird sogar explizit auf das Potenzial hingewiesen, dass durch den Einsatz von KI die Chancengleichheit in manchen Bereichen gegenüber dem jeweiligen Ist-Stand erhöht werden kann (HEG-KI 2019).

2 Bedeutung der Datenqualität

Dass gute Daten als Entscheidungsgrundlage eine wesentliche Rolle spielen, ist allgemeingültig. In der Softwareentwicklung wird dies jedoch durch den Paradigmenwechsel in Richtung von Machine-Learning-Ansätzen verstärkt, wie wir im Folgenden zeigen werden.

2.1 Paradigmenwechsel in der Softwareentwicklung

Methoden der KI stellen ganze Paradigmen in der Softwareentwicklung auf den Kopf. In der klassischen Softwareentwicklung geht man davon aus, den Soll-Prozess hinter einer Aufgabenstellung bis in das letzte Detail zu kennen und programmatisch abzubilden. In ein fertiges Programm werden Eingangsdaten eingespielt und im Rahmen der Programmausführung in Ausgangsdaten weiterverarbeitet. Vereinfacht gesagt: Aus Eingangsdaten und einem Programm werden Ausgangsdaten.

Diese Art Softwaresysteme zu entwickeln, hat sich bei all jenen Aufgaben bewährt, bei denen die genauen Prozessschritte bekannt, oft sogar explizit modelliert sind. Beispiele dazu sind etwa alle Arten mathematischer Operationen oder entscheidungsbaumgetriebener Prozesse.

Im Gegensatz dazu versagt klassische Softwareentwicklung typischerweise, wenn es um die maschinelle Abbildung kognitiver Prozesse geht. Historisch können Computersysteme strukturierte Probleme nach einem festen Muster um ein Vielfaches effizienter lösen als Menschen. Das führt so weit, dass etwa die schriftliche Berechnung einer mathematischen Wurzel in Schulen nicht einmal mehr gelehrt wird. Unstrukturierte

Aufgabenstellungen speziell in Verbindung mit dem Erkennen von Informationen aus Bildern, Videos und Audio, aber auch aus geschriebenem Prosatext waren jedoch mit klassischen Ansätzen nur sehr schwer oder gar nicht lösbar. Das wird deutlich, wenn man versucht, Regeln aufzustellen, anhand derer man etwa eine so vermeintlich triviale Aufgabe löst, wie Hunde von Katzen auf Fotos zu unterscheiden. Selbst wenn man allgemeingültige Regeln anhand von Proportionen und ähnlichen Merkmalen finden würde, bleibt die Frage, wie die entsprechenden Metriken aus Fotos mit unterschiedlichen Distanzen, Winkeln etc. bestimmbar wären.

Durch Methoden des Machine Learning eröffnete sich hier über die letzten Jahrzehnte jedoch ein neuer Weg. Die Regeln, sprich das Programm, werden nicht von Entwicklern geschrieben, sondern automatisch generiert. Dies funktioniert über Algorithmen, die generisch auf unterschiedliche Aufgabenstellungen angewandt werden können, dazu jedoch anhand einer großen Menge an Beispieldaten antrainiert werden müssen. Wieder einfach gesagt: Wenn man das Algorithmen-Template voraussetzt, wird aus Eingangs- und den dazugehörigen Ausgangsdaten ein ausführbares Programm.

In Abb. 1 werden die Paradigmen dargestellt (links) und auch deren Auswirkung auf bestimmte Problemklassen (rechts). Wenn wir beim Beispiel der Unterscheidung zwischen Katzen und Hunden aus Bildern bleiben, wird man nach einem klassischer Entwicklungsansatz Regel um Regel zur Unterscheidung hinzufügen und so langsam aber kontinuierlich bessere Resultate erzielen. Ein Machine-Learning-Ansatz führt hier wesentlich schneller zum Erfolg. Anhand öffentlich verfügbarer Programmbibliotheken und Daten können geübte Data Scientists hier innerhalb eines Tages auf Prototypenlevel bereits eine ansehnliche Unterscheidungsqualität liefern.

Da die Entwickler aber in den Programmkern selbst nicht mehr eingreifen, bleiben als Einflussfaktoren auf die Qualität die Mächtigkeit des verwendeten Trainingsalgorithmus sowie die Daten. Während die Algorithmen im Detail beforcht und vielfach evaluiert werden, liegen die Trainingsdaten in den Händen der Anwender. Leider zeigt sich, dass hier vielerorts das Bewusstsein für die Auswirkungen schlechter Daten fehlt. Wenn beispielsweise nicht alle relevanten Zustände oder Eigenschaften zu einer Aufgabenstellung in den




Abb. 1 Vergleich zwischen klassischem Entwicklungsparadigma in der Software(SW)-Entwicklung und dem durch künstliche Intelligenz („supervised machine learning“) getriebenen

Daten repräsentiert sind, so können diese auch nicht gelernt werden. Der Algorithmus wird dadurch agnostisch gegenüber gewissen Zuständen, die selten auftreten, und versucht trotzdem eine Lösung zu finden, die dann oft nicht der idealen Lösung entspricht.

2.2 Qualität von Trainingsdaten

Um die Qualität und Eignung eines Trainingsdatensatzes beurteilen zu können, benötigt man zudem ein zumindest grundlegendes Verständnis der später darauf angewandten Methoden. Wenn Algorithmen aus der Bildverarbeitung anhand von Beispielen Objekte oder Personen unterscheiden lernen sollen, dann passiert dies anhand von gemeinsamen Eigenschaften der Bilder gleicher Objekte und unterschiedlicher Eigenschaften der Bilder verschiedener Objekte. Das klingt zwar trivial, zu beachten ist jedoch der Bezug auf das jeweilige Bild. Hier spielt auch der mit abgebildete Kontext eine Rolle. Möchte man zwei Personen voneinander unterscheiden und hat von einer Person nur Bilder vor einer weißen Wand und von der zweiten Person nur Bilder vor einer farbigen Wand, ist der Bildhintergrund ein Diskriminator mit höherer Signifikanz als die Gesichtszüge.

Verstärkt wird diese Problematik dadurch, dass KI- oder Machine-Learning-Systeme ebenfalls auf Daten evaluiert und getestet werden, die sehr wahrscheinlich durch dieselbe oder eine ähnliche Systematik akquiriert wurden wie die Trainingsdaten. Systematische Fehler wie der oben beschriebene werden somit auch in den verbreiteten Evaluierungsansätzen nicht sichtbar. Trotz guter Evaluierungsergebnisse innerhalb der Datensätze werden die trainierten Modelle im Praxiseinsatz versagen.

3 Beispiele für Bias in Künstliche-Intelligenz-Anwendungen

Um die Aktualität mangelnder Qualität von Trainingsdaten zu demonstrieren, zeigen wir im folgenden plakative Negativbeispiele aus der jüngeren Vergangenheit. *Bias* bezeichnet in diesem Kontext eine ungerechtfertigte Voreingenommenheit des antrainierten KI-Systems.

Neben offensichtlich mangelhaften Daten kommt ein solcher Bias sehr oft durch die Abbildung von Scheinursachen zustande. Das sind Fälle, in denen ein komplexer Sachverhalt nicht in der gesamten Tiefe in den verfügbaren Daten abgebildet ist. So werden Entscheidungen anhand von stellvertretenden Eigenschaften mit einer relativ hohen Korrelation zu den eigentlichen Ursachen getroffen. Typische Beispiele dafür sind Eigenschaften wie Geschlecht, Alter oder ethnische Zugehörigkeit anstelle detaillierter Lebenssituationen oder Charaktereigenschaften.

3.1 Gesichtserkennung im öffentlichen Raum

Gesichtserkennung ist eine der KI-Technologien, die bereits weit verbreitet im öffentlichen Einsatz ist – und das nicht nur in Amerika (Schuppe 2019; Garvie und Moy 2019) oder China (Lee 2020); die Technologie wurde in europäischen Ländern wie Deutschland (Bundespolizeipräsidium 2018) getestet und wird in Österreich (Nehammer 2020) bereits im Regelbetrieb der Polizei angewendet.

Immer wieder werden Gesichtserkennungssysteme in kleinem Rahmen getestet und schließlich auch eingesetzt, obwohl es bereits Studien gibt, die mehrere solche Systeme methodisch untersucht und verglichen haben, mit besonderem Fokus auf Bias in Bezug auf Ethnien.

In einer Studie des MIT (Buolamwini und Gebru 2018) wurden mehrere kommerziell erwerbbar Gesichtserkennungssysteme auf Bias geprüft und signifikante Unterschiede in der Erkennung aufgedeckt. So liegt beispielsweise die Fehlerrate dunkelhäutige Frauen betreffend bei bis zu 35 %, während sie für andere Gruppen wesentlich geringer ist. Die große mediale Aufmerksamkeit dieser Studie hat bewirkt, dass die meisten Hersteller derartiger Systeme ihre KI weiterentwickelten, um diesen Bias zu minimieren. Viele der Systeme im öffentlichen Einsatz sind jedoch Eigenentwicklungen und daher vergleichenden Studien nicht zugänglich.

Im Fall der Gesichtserkennung für die österreichische Polizei wurde die Software als sogenannte Blackbox gekauft. Das bedeutet, dass die exakte Funktionsweise den Anwendern nicht bekannt ist. Aus einer parlamentarischen Anfrage geht hervor, dass vom Hersteller keinerlei Evaluierungskennzahlen oder Fehlerquoten des Systems übermittelt wurden. Auch die exakte Funktionsweise des Algorithmus sei ein Betriebsgeheimnis der beauftragten Firma. Dies lässt Zweifel und Misstrauen an diesem System aufkommen. Im Sinn von Transparenz müsste die Bevölkerung ausführlich über die Funktionsweise und auch über Kennzahlen aufgeklärt werden.

Im Zuge der weltweiten Black-Lives-Matter-Proteste entschlossen sich Konzerne wie Microsoft, IBM und Amazon dazu, den Verkauf ihrer Gesichtserkennungssoftware teilweise gesamt, teilweise nur an die Polizei einzustellen (Hao 2020).

Auch mehrere Städte in den USA, unter anderem San Francisco (Conger et al. 2019) und Portland (Hatmaker 2020), haben sich unabhängig dazu entschlossen, Gesichtserkennungssoftware im öffentlichen Raum zu verbieten. Auch die Europäische Kommission hat über ein fünfjähriges Verbot von Gesichtserkennungssoftware debattiert. Letztendlich wurde jedoch dagegen entschieden (Chee 2020).

Solange keine finale Entscheidung der Gesetzgeber existiert, liegt die Verantwortung über den Umgang mit Technologien wie Gesichtserkennung weiter in der Hand der Unternehmen.

3.2 Gefahr selbstlernender Systeme (Lernen im Live-System)

KI-Software wird oft als das ultimativ fehlende Puzzleteil beworben, das auf magische Weise alle Probleme löst, indem es einfach kontinuierlich aus Daten lernt und sich selbst optimiert. Derartige Behauptungen sind reines Marketing. Aktuell ist die Technologie (noch) nicht so weit fortgeschritten, dass eine KI alle Probleme und Modelloptimierungen direkt im Live-System lösen kann. Es ist dabei leicht möglich, dass sich das Modell in eine komplett neue Richtung entwickelt, die so nicht vorgesehen war.

Ein berühmtes Beispiel, wozu fortlaufendes Lernen in einem Live-System führen kann, ist TayTweets (TayTweets 2015). Bei TayTweets handelt es sich um einen Chatbot, der auf Twitter veröffentlicht wurde und laufend durch Benutzerinteraktionen lernte. Jeder Teilnehmer konnte den Bot in einem Beitrag erwähnen, dabei lernte TayTweets den Text des Beitrags und reagierte mit einer KI-generierten Antwort. Was passierte ist, dass der Bot – nur wenige Stunden nach der Veröffentlichung – einen rassistischen und frauenhassenden Charakter entwickelte und auch historische Fakten leugnete. TayTweets wurde daraufhin offline genommen. All dies konnte passieren, obwohl die Entwickler hinter diesem Bot Sicherheitsnetze implementiert hatten, um eine solche Schieflage zu verhindern. Diese waren aber offensichtlich nicht umfassend genug; und auch wenn der gute Wille vorhanden war, so ist dieser speziell bei unerwarteten und unkontrollierten Inhalten nicht immer ausreichend. Die automatischen Prüfungen auf bestimmte Verhaltensmuster oder Eigenschaften waren im geschilderten Beispiel nicht vollständig (Reese 2016; Wakefield 2016).

Speziell wenn Benutzerinteraktion im Spiel ist, grenzt eine vollständige automatische Prüfung an eine Unmöglichkeit. Als Entwickler kann man zwar vieles bedenken und vorwegnehmen, aber nicht alle Spielarten menschlicher Kreativität. Wenn zusätzlich noch eine destruktive Intention der Benutzer eines Systems dazukommt, wird das Modell noch schneller in eine falsche Richtung abweichen. Es ist nicht allgemein möglich zu prüfen, ob die Daten, die zum Weitertrainieren einer KI verwendet werden, einerseits korrekt und andererseits gewollt sind. Somit können, wie in diesem Fall, mutwillig unpassende Daten verabreicht werden.

Nicht in jedem Fall muss man hier jedoch negative Absichten unterstellen. Ist das Verhalten der Benutzer zwar konstruktiv, jedoch sehr einseitig, wird wieder ein Bias entstehen, der der Qualität des Systems schaden kann.

Der Fall von TayTweets ist ein extremes Beispiel, zeigt jedoch deutlich, dass ein automatisches Neutrainieren im Live-System nicht immer die erwarteten positiven Ergebnisse liefert. Trainingsdaten müssen immer kontrolliert werden, bevor diese zu einem erneuten Training herangezogen werden.

Es liegt in der Verantwortung eines Herstellers, die Kunden über ein mögliches Abdriften des Modells aufzuklären und Alternativvorschläge aufzuzeigen. Eine Möglichkeit, die Qualität des Modells inklusive regelmäßiger Retrainings aufrechtzuerhalten, ist eine Kontrolle der neuen Trainingsdaten (Abb. 2). Dabei werden im Betrieb Daten und




Abb. 2 Kontinuierliche Verbesserung. 1. Feedback sammeln, 2. Feedback verarbeiten, 3. Künstliche-Intelligenz-Modelle neu trainieren, 4. Evaluierung und Validierung, 5. Veröffentlichung der neuen Modelle

Feedback gesammelt, die schließlich verarbeitet werden und zu einem späteren Zeitpunkt zu einem erneuten Trainieren der Modelle verwendet werden. Dabei steht die Qualität der Ergebnisse im Vordergrund. Die Modelle können so gegen verschiedene Kennzahlen geprüft und zusätzlich manuell getestet werden. Auf diese Weise kann ein mögliches Fehlverhalten früh erkannt und der Release des fehlerhaften Modells verhindert werden. Sollten alle Tests positiv verlaufen, so kann das erweiterte Modell in den laufenden Betrieb eingespielt werden.

4 Evaluierung von Fairness

In den gezeigten Beispielen ist offensichtlich, in welchen Aspekten ein vorhandener Bias das System negativ beeinflusst. Unvoreingenommenheit einer KI zu messen oder zu beweisen, stellt jedoch allgemein eine große Herausforderung dar. Dies liegt unter anderem daran, dass Fairness kein objektiver Begriff ist und in der Praxis gewissen Abwägungen unterworfen ist.

4.1 Definition von Fairness

Eine Anforderung an ein faires System ist dessen Kalibrierung. Darunter versteht man, dass eine Eigenschaft, die mit einer bestimmten Wahrscheinlichkeit in der Realität beobachtet wird, auch von einem KI-System in annähernd der gleichen Wahrscheinlichkeit klassifiziert wird. Diese Prüfung ist jedoch nicht nur auf die Gesamtheit zu beziehen, sondern auch auf die einzelnen Untergruppen, zwischen denen eine Diskriminierung vermutet werden kann.

Eine weitere Anforderung ist, dass für alle Untergruppen das Verhältnis zwischen Fehlertypen „*false positive*“ (eine Eigenschaft wird vom KI-System klassifiziert, obwohl diese in der Realität nicht vorhanden ist) und „*false negative*“ (eine Eigenschaft wird vom KI-System nicht erkannt und entsprechend nicht klassifiziert) ein ähnliches ist.

Kleinberg et al. (2017) haben bewiesen, dass diese Anforderungen nicht gleichzeitig erfüllt werden können. Dadurch ist die Definition der Fairness auf technischer Ebene eine Designfrage, die von den entsprechenden Entscheidungsträgern abgewogen werden muss.

Um diese Aufgabe lösen zu können, ist ein umfassendes Verständnis des abgebildeten Systems notwendig. Leicht erklärt ist dies etwa anhand eines Zulassungssystems für eine Universität. Ein erster Ansatz wäre hier zu definieren, dass über die gesamte Universität die Rate von Aufnahme zu Ablehnung zwischen Frauen und Männern die gleiche sein muss. Es zeigt sich jedoch in der Praxis, dass sich der Anteil von Frauen und Männern beim Inskribieren bestimmter Studienrichtungen sehr stark unterscheidet und diese Studienrichtungen auch unterschiedliche Aufnahmequoten haben. Die Chancengleichheit müsste somit auf den jeweiligen Studiengang bezogen sein und nicht auf die Universität insgesamt (Manyika et al. 2019).

Während diese Erkenntnis für sich bereits positiv ist, führt sie jedoch zu einer weiteren praktischen Hürde. Anstatt ein Gesamtergebnis zu evaluieren, beschäftigen wir uns nun mit einer Vielzahl an Teilergebnissen, die jeweils für sich den genannten Qualitätsansprüchen genügen müssen. Um statistisch signifikante Aussagen treffen zu können, benötigt es jeweils eine gewisse Grundgesamtheit. Gleiches gilt für Machine-Learning-Methoden selbst, bei denen ebenfalls Teildatensätze für sich eine Mindestgröße besitzen müssen, um komplexe Modelle trainieren zu können (Knight 2019).

4.2 Interpretation der Ergebnisse

Eine methodisch korrekte Evaluierung von Modellen und deren Interpretation ist weitgehend in der Entwicklung von KI-Software, um ein klares und korrektes Bild zu bekommen, wie sich das Modell mit zukünftigen Daten verhalten wird. Einerseits können mit bestimmten Methoden scheinbar gute Erkennungsgenauigkeiten erzielt werden, die jedoch nicht korrekt das Verhalten des Modells repräsentieren (Brownlee 2014). Andererseits müssen auch immer die Auswirkungen der falsch eingestuft

Beispiele in Betracht gezogen werden. Ist es akzeptabel, wenn 10 % gut produzierte Produkte als fehlerhaft eingestuft werden? Ist es akzeptabel, wenn 10 % der Menschen fälschlicherweise die Einreise in ein Land verboten wird, nur weil in der Vergangenheit „ähnlichen“ Menschen die Einreise verweigert wurde?

Die Fehlertoleranz ist oft vom jeweiligen Use Case und den daraus resultierenden Auswirkungen abhängig. Besonders heikel ist der Prozentsatz an Fehlern, wenn über die weiteren Möglichkeiten im Lebensverlauf von Menschen entschieden wird. Ein Beispiel dafür ist die Einführung eines Algorithmus beim österreichischen Arbeitsmarktservice (AMS), dessen Testbetrieb 2019 startete.

Der AMS hat eine Firma beauftragt, ein System zu entwickeln, das die Chancen von Arbeitslosen auf dem Arbeitsmarkt mittels eines Algorithmus einstufen soll. Dabei gibt es drei Stufen, die die Wahrscheinlichkeit repräsentieren, ob eine Person einen Job finden und behalten kann: hohe Chancen, mittlere Chancen und geringe Chancen. Die meisten Förderungen kommen Personen mit mittleren Chancen zu, weil Personen mit hohen Chancen zugetraut wird, auch selbst eine neue Arbeitsstelle zu finden (Szigetvari 2019). Die Letztentscheidung sollen jedoch weiterhin die beratenden Personen treffen.

Als Ausgangsbasis für diese automatische Einstufung wurde eine Menge an Eigenschaften (Features) definiert und jeweils ein positiver oder ein negativer Wert zugewiesen, der anhand vergangener Daten berechnet wurde. Diese Featureliste zeigt also, ob Personen, auf die das jeweilige Feature zutrifft, leicht einen Job finden (positiver Wert) oder nicht schnell einen Job finden (negativer Wert). Einige Beispiele dieser Features sind in Tab. 1 gelistet. Aufgrund dieser Features wird eine Bewertung berechnet, die die Chancen auf dem Arbeitsmarkt repräsentieren soll. Unter anderem werden z. B. Features wie Gender, Alter oder Staatsbürgerschaft verwendet, die nicht von der Person selbst beeinflussbar sind. Das heißt, dass jede Person durch Zustände, die sie selbst nicht beeinflussen und verbessern kann, automatisch bevorzugt oder benachteiligt wird. Dadurch haben bestimmte Personen eine schlechtere Ausgangslage

Tab. 1 Auszug der Werte aus dem originalen Bericht zum AMS-Arbeitsmarktchancen-Modell (Holl et al. 2018). Dabei wird startend bei einem Ausgangswert von 0,1 der finale Score berechnet, nach dem die Arbeitslosen in die drei Kategorien eingeteilt werden

Punkte	Feature
−0,14	Geschlecht weiblich
−0,7	Altersgruppe 50plus
+0,16	Staatengruppe EU
−0,05	Staatengruppe Drittstaaten
−0,15	Betreuungspflichtig (wird nur bei Frauen angewendet)
−0,18 bis −0,82	Wohnsitz Region
+0,65 bis +1,98	Wie schnell in der Vergangenheit ein Job gefunden wurde

und bekommen in der Folge eventuell nicht die Förderung, die sie brauchen (Szigetvari 2018; Kontrast Redaktion 2020).

Basierend auf vergangenen Daten werden also zukünftige Arbeitslose automatisch eingestuft, und zwar mit einer Genauigkeit von 80–85 % (Holl et al. 2018). Laut AMS gab es 2019 durchschnittlich rund 200.000 Arbeitslose (Statistik Austria 2019). Dies entspricht bei einer Fehlerquote von 20 % rund 40.000 Personen, die jährlich falsch eingestuft werden.

Die Werte des Algorithmus sind dennoch wertvoll – schließlich ist darin die aktuelle Situation sehr gut abgebildet. Diese sollte jedoch nicht ausschlaggebend für zukünftige Entscheidungen sein. Auf diese Weise werden die aktuellen Schwierigkeiten noch verstärkt (selbsterfüllende Prophezeiung). Personengruppen, denen es in der Vergangenheit schwer fiel, einen Job zu finden, werden es laut dieser Einstufung auch in der Zukunft schwer haben. Die Information könnte z. B. dazu verwendet werden, den Ursachen auf den Grund zu gehen und bestimmte Umgebungsbedingungen zu verbessern. Beispiele dafür sind die Schaffung von mehr Betreuungseinrichtungen für Kinder in bestimmten Gegenden oder mehr Angebote von Deutschkursen, um so einigen Personengruppen den Zugang zum Arbeitsmarkt zu erleichtern (Allhutter et al. 2020; Lopez 2019).

Im August 2020 wurde der Einsatz des Algorithmus von der Datenschutzbehörde untersagt, da die gesetzliche Grundlage für einen solchen Algorithmus nicht existiert. Aus einer Prüfung des Algorithmus geht außerdem hervor, dass dieser den Vorgaben der Datenschutz-Grundverordnung (DSGVO) in mehreren Punkten nicht entspricht. Die Verwendung von personenbezogenen Daten zur Berechnung der Chancen am Arbeitsmarkt fällt aus Sicht der Datenschutzbehörde unter *Profiling*, wofür eine explizite gesetzliche Ermächtigung benötigt wird. Die geplante Einführung des Algorithmus am 1. Januar 2021 darf also nur stattfinden, wenn bis dahin eine entsprechende gesetzliche Grundlage geschaffen wird (Staudacher 2020).

Wie kann ein solcher Bias vermieden werden? Zuerst müssen die Daten analysiert werden, um zu entscheiden, welche Features überhaupt relevant sind und im jeweiligen Use Case angewendet werden sollen. Persönliche Informationen wie Geschlecht, Alter, Staatsbürgerschaft und ähnliche müssen immer entfernt werden, um sicherzugehen, dass diese nicht ausschlaggebend für eine Entscheidung sind. Dies ist jedoch noch keine Garantie, dass kein Bias passieren kann. Oft gibt es Features, die mit den genannten sehr eng verbunden sind und ebenfalls für einen Bias verantwortlich sein können.

Es kann dadurch vorkommen, dass die Genauigkeit des Systems nach Entfernen dieser Features sinkt. Dies bedeutet jedoch nur, dass eine automatische Klassifizierung mit den gegebenen Features nicht gut möglich ist. Diese Information ist wichtig und allgemein zu bevorzugen, anstatt ein System unreflektiert in Betrieb zu nehmen, das systematisch bestimmte Bevölkerungsgruppen diskriminiert. Zusätzlich kann ein Testdatensatz bei der Einschätzung helfen, ob ein Bias im System vorhanden ist. Dieses Testset muss aus Datenpunkten bestehen, die so divers wie möglich sind, um aufzudecken, ob bestimmte Personen oder Gruppen signifikant häufiger falsch eingeordnet werden.

Eine Chancengleichheit kann nur dann erreicht werden, wenn Personen nicht aufgrund von nicht beeinflussbaren und vergangenen Daten beurteilt werden.

5 Lösungsansätze für unvoreingenommene Künstliche-Intelligenz-Systeme

Nach der Darstellung der Herausforderungen im Umgang mit KI-Systemen in Bezug auf deren Fairness und Unvoreingenommenheit leiten wir im Folgenden Handlungsempfehlungen für die Praxis ab.

5.1 Bewusstsein schaffen

Wir sehen es als wichtige Aufgabe von Experten und seriösen Anbietern von KI-Systemen, das Bewusstsein für Fairness von KI-Systemen zu schaffen und mögliche Auswirkungen von Bias aufzuzählen. Anwendern, die mit den dahinterliegenden Methoden des Machine Learning nicht vertraut sind, ist es nicht zuzumuten, das Verhalten eines solchen Systems exakt einzuschätzen.

Das wird dadurch verstärkt, dass in der Regel die zum Trainieren eines Systems verwendeten Datensätze weder bekannt noch öffentlich zugänglich sind.

5.2 Fairness definieren und Ziele setzen

Wie in Abschn. 4.1 beschrieben, ist Fairness kein exakter Begriff, sondern es ist sogar unmöglich, alle Aspekte von Fairness gleichermaßen abzudecken. Somit liegt es an jedem Unternehmen als KI-Anwender selbst, diese Abwägung zu treffen, eine Definition für Fairness zu finden und entsprechend messbar zu machen. Anhand messbarer Größen lassen sich in der Folge auch konkrete Ziele definieren und überwachen.

5.3 Systematische Qualitätsprüfung der Datensätze

Es gibt eine Vielzahl an relevanten Qualitätsansprüchen an Trainings- und Evaluationsdatensätze für KI-Systeme. Neben der repräsentativen Abbildung unterschiedlicher Eigenschaften bzw. Klassen, aber auch Einflussfaktoren und Merkmalsausprägungen ist auch auf die Vermeidung von Scheinindikatoren zu achten. Für jedes Merkmal einer Datenquelle ist somit zu hinterfragen, ob eine direkte Kausalität in Bezug auf die Zielgröße vorhanden sein kann. Ist dies nicht der Fall, so muss man in der Folge prüfen, ob eine stellvertretende Verwendung in einem KI-System zulässig ist oder zu einer Diskriminierung führen würde.

Oft ist es nötig, mehrere Datensätze bzw. Datenquellen zu verschneiden, um Sachverhalte in ihrer ganzen Tiefe darzustellen.

Weiterhin ist zu beachten, dass auch von Menschen erstellte Annotationen von Daten fehlerbehaftet sind. Eine systematische Prüfung kann hier durch volles oder stichprobenweises Mehrfachannotieren einzelner Datensätze erfolgen. Daraus wird sichtbar, bei welchen Beispielen sich die annotierenden Experten uneinig sind und Ursachen können hinterfragt werden.

5.4 Evaluierung der Modelle auf Bias

Modelle können bis zu einem gewissen Grad automatisch auf Bias geprüft und evaluiert werden. Dazu kann z. B. eine diverse Gruppe an Testern zusammengestellt werden, die die KI evaluiert und automatisierte Tests mit verschiedenartigen Eingangsdaten erstellt. Diese automatisierten Tests können dabei helfen, unerwartete Verhaltensweisen frühzeitig zu erkennen und abzufangen.

Zusätzlich können Evaluierungsmetriken eingeführt werden, die die Zielgrößen an verschiedenen Untergruppen messen, speziell in Bezug auf falsch erkannte Beispiele. Dies hilft dabei, besser zu verstehen, in welchen Fällen oder Gruppen ein Bias auftritt und dem entgegenzuarbeiten.

Ein weiteres Testset mit besonders problematischen Daten und Beispielen kann außerdem helfen, sicherzugehen, dass sich die Modelle im weiteren Verlauf der Entwicklung nicht wieder verschlechtern. Dieses Testset soll laufend mit schwierigen Beispielen erweitert werden, auch als Benutzer-Feedback, um so immer das gesamte Spektrum überprüfen zu können.

5.5 Erklärbare künstliche Intelligenz und Einbindung von Personen

Das Gegenteil zu den *Black-Box*-Modellen beim Machine Learning ist erklärbare KI („*explainable AI*“). Der Ruf nach einem Recht auf Erklärung wird immer lauter. Viele KI-Algorithmen sind allerdings so komplex, dass eine Erklärung der Entscheidung nicht sinnvoll möglich bzw. nicht für den Menschen nachvollziehbar ist. Algorithmen lernen und interpretieren nicht auf dieselbe Weise wie Menschen, deshalb können unter Umständen ganz andere Features ausschlaggebend für eine Entscheidung sein. Dem wirken neuere Ansätze entgegen und helfen, KI-Entscheidungen nachvollziehbar zu machen. Das reicht vom gezielten Experimentieren mit einem Modell bis hin zur automatisierten Erklärung einer Entscheidung durch den Algorithmus selbst.

Verwendet man derartige Methoden nicht rein zur Fehleranalyse, sondern auch im laufenden Betrieb, können auch Personen aktiv in die Prozesse mit eingebunden werden und steuernd eingreifen. Dies kann rein kontrollierend erfolgen, aber auch aktiv, um innerhalb eines definierten Spielraums situationsbedingte Abwägungen zu ermöglichen.

Auch wenn viel Arbeit und Vorsicht in das Design der KI fließt, um Fairness sicherzustellen, können nichttriviale KI-Modelle keine hundertprozentige Genauigkeit erreichen, wenn diese auf echte Live-Daten angewendet werden. Sollte ein Problem im Betrieb auftreten, muss geprüft werden, welche Auswirkungen eine Falscheinschätzung der KI hat, ob jemand dadurch benachteiligt wird und wie es dazu verwendet werden kann, die KI weiter zu verbessern.

6 Fazit

KI ist ein mächtiges Werkzeug, mit dem viele Probleme gelöst werden können, die zuvor als für Maschinen unlösbar galten. Allerdings gibt es auch eine Kehrseite, wenn KI-Algorithmen ohne Sorgfalt und ohne mögliche Konsequenzen in Betracht zu ziehen eingesetzt werden. Um einem möglichen Bias und einer Voreingenommenheit entgegenzuwirken, muss Fairness in Bezug auf die jeweilige Anwendung definiert und laufend durch automatisierte Tests und diversifizierte Testdaten, aber auch durch manuelles Testen der KI geprüft werden. Ein Bias kann nie garantiert ausgeschlossen werden. Es liegt daher in der Verantwortung der Hersteller, die Kunden und Anwender darüber aufzuklären und auch die Qualität und Funktionsweise der KI-Modelle zu erklären.

Literatur

- Allhutter D, Cech F, Fischer F, Grill G, Mager A (2020). Algorithmic profiling of job seekers in Austria: how austerity politics are made effective. <https://doi.org/10.3389/fdata.2020.00005>. Zugriffen: 16. Sept. 2020
- Brownlee J (2014) Classification accuracy is not enough: more performance measures you can use. Machine learning mastery. <https://machinelearningmastery.com/classification-accuracy-is-not-enough-more-performance-measures-you-can-use/>. Zugriffen: 16. Sept. 2020
- Bundespolizeipräsidium (2018) Abschlussbericht des Bundespolizeipräsidiiums zur biometrischen Gesichtserkennung (Erprobung von Systemen zur intelligenten Videoanalyse). https://www.bundespolizei.de/Web/DE/04Aktuelles/01Meldungen/2018/10/181011_abschlussbericht_gesichtserkennung_down.pdf. Zugriffen: 16. Sept. 2020
- Buolamwini J, Gebru T (2018) Gender shades: intersectional accuracy disparities in commercial gender classification. In: Proceedings of Machine Learning Research, New York, 23–24 February 2018
- Chee F (2020) EU drops idea of facial recognition ban in public areas: paper. Reuters. <https://www.reuters.com/article/us-eu-ai/eu-drops-idea-of-facial-recognition-ban-in-public-areas-paper-idUSKBN1ZS37Q>. Zugriffen: 16. Sept. 2020
- Conger K, Fausset R, Kovalski S (2019) San Francisco bans facial recognition technology. The New York Times. <https://www.nytimes.com/2019/05/14/us/facial-recognition-ban-san-francisco.html>. Zugriffen: 16. Sept. 2020
- Garvie C, Moy L (2019) America under watch face surveillance In the United States. <https://www.americaunderwatch.com/>. Zugriffen: 16. Sept. 2020

- Hatmaker T (2020) Portland passes expansive city ban on facial recognition tech. Techcrunch. <https://techcrunch.com/2020/09/09/facial-recognition-ban-portland-oregon>. Zugegriffen: 16. Sept. 2020
- Hao K (2020) The two-year fight to stop amazon from selling face recognition to the police. MIT Technology Review. <https://www.technologyreview.com/2020/06/12/1003482/amazon-stopped-selling-police-face-recognition-fight/>. Zugegriffen: 16. Sept. 2020
- HEG-KI, Hochrangige Expertengruppe für Künstliche Intelligenz (2019) Ethik-Leitlinien für eine vertrauenswürdige KI, Brüssel. Europäischen Kommission (<https://doi.org/10.2759/856513>, isbn: 978-92-76-12799-4, <https://op.europa.eu/de/publication-detail/-/publication/d3988569-0434-11ea-8c1f-01aa75ed71a1>)
- Holl J, Kernbeiß G, Wagner-Pinter M (2018) Das AMS-Arbeitsmarktchancen-Modell. https://www.forschungsnetzwerk.at/downloadpub/arbeitsmarktchancen_methode_%20dokumentation.pdf. Zugegriffen: 16. Sept. 2020
- Kleinberg J, Mullainathan S, Raghavan M (2017) Inherent trade-offs in the fair setermination of risk scores. In: Proceedings of Innovations in Theoretical Computer Science (ITCS), Berkeley, 9–11 Januar 2017
- Knight W (2019) AI is biased. Here's how scientists are trying to fix it. Wired. <https://www.wired.com/story/ai-biased-how-scientists-trying-fix/>. Zugegriffen: 15. Sept. 2020
- Kontrast Redaktion (2020) Punktabzug für Frauen, Mütter und über 50-Jährige: So entscheidet der AMS-Computer über Arbeitslose. Kontrast.at. <https://kontrast.at/ams-algorithmus>. Zugegriffen: 16. Sept. 2020
- Lee S (2020) Coming into focus: China's facial recognition regulations. CSIS. <https://www.csis.org/blogs/trustee-china-hand/coming-focus-chinas-facial-recognition-regulations>. Zugegriffen: 16. Sept. 2020
- Lopez P (2019) Reinforcing intersectional inequality via the AMS algorithm in Austria. <https://diglib.tugraz.at/download.php?id=5e29a88e0e34f&location=browse>. Zugegriffen: 16. Sept. 2020
- Manyika J, Silberg J, Presten B (2019) What Do We Do About the Biases in AI? Harvard Business Review. <https://hbr.org/2019/10/what-do-we-do-about-the-biases-in-ai>. Zugegriffen: 15. Sept. 2020
- Nehammer K (2020) Anfragebeantwortung: Erkenntnisse aus dem Testbetrieb des Gesichts-erkennungssystemen. https://www.parlament.gv.at/PAKT/VHG/XXVII/AB/AB_02662/index.shtml. Zugegriffen: 16. Sept. 2020
- Reese H (2016) Why microsoft's 'tay' AI bot went wrong. TechRepublic. <https://www.techrepublic.com/article/why-microsofts-tay-ai-bot-went-wrong/>. Zugegriffen: 16. Sept. 2020
- Schuppe J (2019) How facial recognition became a routine policing tool in America. Nbcnews. <https://www.nbcnews.com/news/us-news/how-facial-recognition-became-routine-policing-tool-america-n1004251>. Zugegriffen: 16. Sept. 2020
- Statistik Austria (2019) Arbeitslosigkeit – Jahresdurchschnitt 2019. https://www.statistik.at/wcm/idc/idcplg?IdcService=GET_PDF_FILE&RevisionSelectionMethod=LatestReleased&dDocName=063259. Zugegriffen: 16. Sept. 2020
- Staudacher A (2020) Datenschutzbehörde dreht den AMS-Algorithmus ab. Kurier. <https://kurier.at/wirtschaft/datenschutzbehoerde-dreht-den-ams-algorithmus-ab/401006615>. Zugegriffen: 16. Sept. 2020
- Szigetvari A (2018) Leseanleitung zum AMS-Algorithmus. Der Standard. <https://www.derstandard.at/story/2000089720308/leseanleitung-zum-ams-algorithmus>. Zugegriffen: 16. Sept. 2020

- Szigetvari A (2019) Arbeitsmarktservice gibt grünes Licht für Algorithmus. Der Standard. <https://www.derstandard.at/story/2000108705095/arbeitsmarktservice-gibt-gruenes-licht-fuer-algorithmus>. Zugegriffen: 16. Sept. 2020
- TayTweets [@TayandYou] (2015) The official account of Tay, Microsoft's A.I. fam from the internet that's got zero chill! The more you talk the smarter Tay gets. From <https://twitter.com/tayandyou>
- Wakefield J (2016) Microsoft chatbot is taught to swear on twitter. BBC. <https://www.bbc.com/news/technology-35890188>. Zugegriffen: 16. Sept. 2020

Katrin Strasser Seit 2016 ist Katrin Strasser als Data Scientist bei Cloudflight beschäftigt. Sie leitet den Fachbereich Natural Language Processing den sie über die letzten Jahre aufgebaut hat. Speziell in Sektoren wie der Versicherungsbranche oder der öffentliche Verwaltung konnte Sie mit neuartigen KI-Anwendungen zur Innovation beitragen. Über einzelne Projekte hinweg etablierte sie unternehmensweite Best Practices für wiederkehrende NLP Aufgabenstellungen inklusive Unterstützung durch eine ML Plattform. Ihre KI-Expertise stellt Katrin Strasser nicht nur als Team Lead in zahlreichen Kundenprojekten unter Beweis, sondern auch als gefragte Speakerin auf der Bühne. Sie hat ein abgeschlossenes Masterstudium in Bioinformatik mit Schwerpunkt auf Machine Learning an der JKU in Linz. Seit 2019 ist sie nicht nur Mentorin sondern auch im Vereinsvorstand bei Female Coders Linz, zur Förderung von Frauen in der IT und aktives Mitglied bei Women in AI Austria.

Bernhard Niedermayer ist seit knapp 15 Jahren mit Machine Learning in Berührung. Er promovierte in diesem Bereich an der Johannes Kepler Universität Linz. Konkret beschäftigte er sich dabei mit der Anwendung unterschiedlicher Trainingsverfahren auf die digitale Audiosignale mit dem Ziel, Computer Musik verstehen zu lassen. Nach Abschluss seiner Dissertation wechselte er in die Privatwirtschaft, wo er bei Catalysts zahlreiche Individualsoftwareentwicklungsprojekte leitete. Bernhard Niedermayer baute den Geschäftsbereich Emerging Technologies im Unternehmen auf, in dem neben Projekten aus dem Bereich der KI auch solche in Verbindung mit Technologien wie Internet of Things und Mixed Reality umgesetzt werden. Auch nach dem Zusammenschluss der Catalysts und der deutschen Crisp Research zur neu gegründeten Cloudflight baut er diesen Bereich als Mitglied des Management Board weiter aus. Neben seiner beruflichen Tätigkeit ist Bernhard Niedermayer Mitgründer des Vereins AI Upper Austria, der als Vision hat, regional zu helfen, die Lücke zwischen den Potenzialen von KI und dem tatsächlich in der Praxis generierten Mehrwert zu verringern.



Skizzierung einer vertrauensvollen künstlichen Intelligenz

Isabell Kunst

1 Einleitung

Schon seit einigen Jahren gehört die künstliche Intelligenz (KI) in unseren Alltag: Sei es in unserem technischen Equipment oder als ständiger Begleiter in allen Medien. In diesen führt die Debatte der Potenziale von KI rasch in das Gegenteil und es wird vor den Risiken gewarnt. Tatsächlich gibt es zu dieser neuen Technologie noch eine Vielzahl ungeklärter Fragen in diesem Zusammenhang. Dazu gehört, dass es weder eine einheitliche Definition gibt, noch klar ist, was die KI kann und wozu sie nicht in der Lage ist. Dieser Beitrag beschäftigt sich damit, die KI grob zu unterteilen und einen derzeitigen technischen Stand wiederzugeben. Auf Basis dessen wird analysiert, wie durch den Einsatz der europäischen KI-Richtlinien Vertrauen bei den Usern generiert werden kann. Besonders wird hierbei ein Augenmerk auf KI-Anbieter gesetzt und skizziert, wie diese eine vertrauenswürdige System umsetzen könnten.

2 Arten der künstlichen Intelligenz

Um über KI sprechen zu können, ist es essenziell zu verstehen, was diese überhaupt bedeutet. Hierzu gibt es in der Literatur unzählige Definitionen. Allen gemein ist, dass künstlich intelligente Maschinen intelligentes Verhalten wiedergeben sollen, Lernfähigkeit an den Tag legen und Aufgaben lösen mit dem Ziel, besser als Menschen

I. Kunst (✉)

Xephor Solutions GmbH, Purkersdorf, Österreich

E-Mail: isabell.kunst@xephorsys.com

© Der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

137

R. Altenburger und R. Schmidpeter (Hrsg.), *CSR und Künstliche Intelligenz*, Management-Reihe Corporate Social Responsibility,
https://doi.org/10.1007/978-3-662-63223-9_7

abzuschneiden [1]. Weiterhin lässt sich sagen, dass es sich hierbei um einen Zusammenfluss der unterschiedlichsten Disziplinen wie Informatik, Mathematik, Physik, Philosophie, Linguistik, Biologie/Hirnforschung und Psychologie handelt.

Grob gesprochen lässt sich zusammenfassen, dass es bei KI-Systemen vor allem um das Lernen von Begriffen und das Verständnis geht, wodurch sich diese von normalen Softwaresystemen unterscheiden. Außerdem können sie im Gegensatz zu klassischen Softwaresystemen aus ihren Fehlern lernen und durch die Fähigkeit des Maschinendenkens sogar Kreativität nachstellen.

Generell wird immer von „der“ KI gesprochen, praktisch gesehen gibt es die unterschiedlichsten KI-Systeme, die die verschiedensten Aufgaben lösen können. Die Abb. 1 zeigt, welche Arten der KI sich grob unterscheiden lassen. Dies ist von großer Wichtigkeit, um zu verstehen, wie gewisse ethische Vorstellungen in solch ein System implementiert werden können.

Der äußerste Kreis umfasst die sog. intelligenten Systeme, die stark vom Programmieren abhängig sind. Die beiden inneren Kreise, tiefgehendes Lernen sowie




Abb. 1. Arten von künstlicher Intelligenz

Maschinendenken, arbeiten hingegen mit neuronalen Netzen, die stark vom Trainieren abhängig sind. Die einzelnen Kreise lassen sich wie folgt beschreiben:

1. Intelligente Systeme: Auch Ruled-based-Software genannt. Dabei handelt es sich um eine Datenbank, eine Menge von Regeln und ein Kontrollsystem, das die geeigneten Regeln für den jeweiligen Problemfall auswählt. Diese Datenbanken dienen oftmals als Grundlage von Expertensystemen, die bei der Entscheidungsfindung helfen sollen. Intelligente Systeme können nicht eigenständig lernen. Wenn sich neue Erkenntnisse ergeben, dann braucht es einen hohen Programmieraufwand, um diese in das System zu integrieren.
2. Maschinlernen: Auch „logic reasoning“ genannt. Auch hierbei handelt es sich, wie bei den intelligenten Systemen, um eine Datenbank, jedoch werden die Regeln durch logische Klauseln erweitert. Das bedeutet, dass das System sich selbst bei neuen Gegebenheiten durch statistische Modelle anpassen kann, z. B. Hidden-Markov-Modelle oder Bayerische Netzwerke mit komplexen Wahrscheinlichkeiten. In diese Gruppe fallen beispielsweise IBM Watson und Siri.
3. Tiefgehendes Lernen: Hierbei handelt es sich meist um ein bis drei große neuronale Netze, die trainiert werden müssen. Dazu werden Generalisierungs- und Spezialisierungsregeln verwendet und eine entsprechende Menge an hochqualitativen Trainingsdaten muss zur Verfügung stehen. Auch „reinforcement learning“ fällt in diese Kategorie: Durch Ausprobieren soll herausgefunden werden, welche Handlungen lohnenswert sind: Ausprobieren –Rückmeldung –optimale Strategie! Durch das Lernen ändern sich Verbindungen in den neuronalen Netzen und deren synaptische Gewichte. Ein Vertreter dieser Gruppe ist beispielsweise Google tensorflow.
4. Maschinendenken: Hierbei wird mit Tausenden von kleinen neuronalen Netzen gearbeitet, die Teilen des menschlichen Gehirns in ihrer Funktionalität nachempfunden sind. Die Hypothesenbildung erfolgt durch Neurosimulationen mittels stochastischen Lernens und erzeugt neue Ideen („Kreativität“) und die Fähigkeit, auf unvorhergesehene Situationen reagieren zu können. Solche Systeme brauchen im Gegensatz zum tiefgehenden Lernen keine bestimmte Menge an Trainingsdaten. Sie können aus wenigen, strukturierten, unstrukturierten und dünn besiedelten Daten lernen sowie quantitative und qualitative Daten gemeinsam analysieren.

3 Wo künstliche Intelligenz genutzt wird

Die unterschiedlichen Arten der KI bieten einen enormen Spielraum für Anwendungsmöglichkeiten. Es gibt einige bekannte Felder, in denen KI heutzutage eingesetzt wird, wie beispielsweise bei Robotern, in der Sprach- und Mustererkennung oder bei selbstfahrenden Autos. Die Potenziale der vorhandenen KI werden hierbei kaum ausgeschöpft, da die Einsatzmöglichkeiten – gerade von denkenden KI-Systemen – nahezu unendlich

sind. Folgende zwei Beispiele dienen der Veranschaulichung, in welchen Bereichen intelligente Systeme eingesetzt werden und wo die Unterschiede je nach KI-Art sind.

3.1 Finanzen

Der Finanzbereich ist einer der ersten Bereiche, in denen KI-Lösungen eingesetzt wurden. Die folgenden Beispiele zeigen einige Aufgaben, die KI in Banken übernehmen kann:

1. Approximation von kreditrisikorelevanten Daten, z. B. Rating
2. Vorhersage von Risikodaten bzw. Marktdaten (Aktienkurse, Anleihenkurse, Volatilitäten, Bilanzen etc.)
3. Trading: Ersetzen bzw. Unterstützen eines Managers bzw. Händlers
4. Administration und Automatisierung von Prozessen, z. B. Automatisierung von Managementprozessen (Kunden sperren/freischalten, E-Mails verfassen bei ungewöhnlichen Ereignissen)
5. Kundenvorhersagen (Marketing)
6. Produktverständnis von Finanzprodukten, wie z. B. Erkennen von Over-the-counter-Finanzprodukten

Intelligente Systeme eignen sich besonders in zwei Bereichen. Zum Einen in der Rechnungsverarbeitung: Hierzu zählen Aufgaben wie die Extrahierung von Daten aus Rechnungen in ERP-Systeme, die Bearbeitung und Weiterleitung an Genehmigungsstellen oder Unterstützung bei Fakturierung, Lohnbuchhaltung und Beschwerdemanagement. Zum Anderen in der Business-Case-Analyse: In diese Kategorie fallen beispielsweise Datenextraktion aus verschiedenen Systemen; Anlage und Pflege von Anbieterdaten, Bearbeitung von Zahlungsvorgängen und Bankkontenabgleich, Bildung von Rückstellungen für Forderungsverluste sowie die Nachverfolgung von Vermögenswerten. Generell lässt sich sagen, dass sich solche Systeme vor allem für monotone und zeitaufwendige Tätigkeiten am besten eignen.

Maschinenlernen bietet hingegen im Finanzbereich folgende Anwendungsmöglichkeiten:

1. Verarbeitung einfacher natürlicher Sprachtexte (Neuro-Linguistisches Programmieren, NLP), Analyse strukturierter und unstrukturierter Daten, z. B. Erfassen und Verarbeiten von Belegen, Übertragen von Erkenntnissen beim Kontieren auf neue Buchungssätze sowie der Abgleich von Kontobewegungen mit Ein- und Ausgangsrechnungen
2. Kontrollmechanismen von Darlehensbewertungssystemen: Überprüfung des kompletten Darlehensportfolios (nicht nur stichprobenartig); Erstellung von Ratings für Kreditrisiko und Ermittlung von Ausreißern. Revisionsabteilungen: komplette Analyse (nicht nur stichprobenartig) und Kontrolle gesetzlicher Vorschriften

Arbeitet man hingegen mit neuronalen Netzen, dann lassen sich nachstehende Aufgaben damit bewerkstelligen:

1. Predicting: Predictive Analytics wird eingesetzt, um auf Basis bekannter Daten dynamische Prognosen über die zukünftige Geschäftsentwicklung zu erstellen, Ausfallrisiken abzuschätzen und das Volumen zukünftiger Forderungen vorherzusagen
2. Automatisierung von Kundenabfragen: Erfassung von Online- und E-Mail-Anfragen; eigenständige Abarbeitung aller notwendigen Prozessschritte

Mit der Funktion Maschinendenken schließlich können komplexe Aufgaben, wie etwa diejenigen eines Risikomanagers oder Traders, komplett übernommen werden. Auch können mit dieser Methode durch die Kombination von qualitativen und quantitativen Daten weitaus präzisere Vorhersagen getroffen werden als mit dem klassischen tiefgehenden Lernen.

3.2 Security

Auch im Security-Bereich wird aufgrund der zunehmenden Häufigkeit von Angriffen auf Unternehmen KI mehr und mehr eingesetzt.

Intelligente System und Maschinelernen werden großteils in folgenden beiden Bereichen verwendet:

1. Verarbeitung einfacher natürlicher Sprachtexte (NLP), Analyse strukturierter und unstrukturierter Daten, z. B. Dokumente und geistiges Eigentum eines Unternehmens identifizieren, Abgleich von verschiedenen Bewegungsmustern
2. Risiko-Scoring: Zeigt an, mit welcher Wahrscheinlichkeit es sich tatsächlich um einen relevanten Vorfall handelt. Diese Einstufungen führt das System auch für einzelne Hosts und andere zentrale Assets im Angriffsszenario durch, die für den Unternehmensbetrieb kritisch sind.

Neuronale Netze werden oftmals in Antivirensoftware integriert, da durch deren Einsatz zum einen keine ständigen Updates nötig sind und zum anderen die Erkennungsrate um bis zu 30 % gesteigert werden kann [2]. Außerdem sind sie häufig in den folgenden beiden Bereichen zu finden:

1. Predicting: Predictive Analytics wird eingesetzt, um auf Basis bekannter Daten dynamische Prognosen über zukünftige Bedrohungen zu erstellen, Ausfallrisiken abzuschätzen und das Volumen zukünftiger Angriffe vorherzusagen.

2. Passwortcracking: Erkennung von Mustern in Passwörtern [3]¹
3. Überwachung von Downloads aus dem Internet: Input: Mustererkennung von Malware durch neuronale Netze

Maschinendenken eignet sich am besten im Bereich der Firewall-Administration. Hier haben die Administratoren mit vielen Problemen wie Datenüberfluss durch zu viele sich ständig ändernde Regeln, schwierige Anpassung an eine neue Firewall, ständig wechselnde neue Bedrohungen, zeitintensive administrative Aufgaben und Mangel an hoch qualifizierten Arbeitskräften zu kämpfen. Ein virtueller Firewall-Administrator in austrainierter Form ist in der Lage, folgende Aufgaben zu übernehmen:

1. Entwicklung, Implementierung und Empfehlung von Richtlinien für alle Security-Systeme wie Firewall, Anti-Virus-Software, Datenbanken, Virens Scanner und Fernzugriffe von Kunden und Mitarbeitern
2. Übernahme der Administration aller Endbenutzer-Accounts; Erstellung von Zugriffsrechten für unternehmensweite Systeme, Unternehmensdatenbanken und Netzwerkzugriffe
3. Überwachung der Server, Firewalls, Virens Scans und Netzwerk-Logins; Interpretation in Real-time und sofortige Reaktion mit geeigneten Maßnahmen
4. Empfehlungen, wie Prozesse verbessert werden können
5. Durchführung von Security-Tests, um Schwachstellen im System aufzudecken
6. Erstellung von Berichten über aktuelle Geschehnisse, um den Kommunikationsfluss am Laufen zu halten
7. Koordination und Austausch mit anderen Abteilungen (Management, Sales, Human Resources etc.)
8. Lesen, verstehen und umsetzen von externen Security-Richtlinien (z. B. Datenschutzrichtlinie)

4 Praktischer Einsatz und Verantwortung

Je nachdem, mit welchem KI-System man arbeitet, ist dessen Implementierung komplett unterschiedlich. Während bei intelligenten Systemen und Maschinlernen noch die Programmierung im Vordergrund steht, benötigt man bei neuronalen Netzen (tiefgehendes Lernen und Maschinendenken) einen Experten, der als Trainer fungiert und seine Expertise an das System weitergibt. Das bedeutet eine Verschiebung der Verantwortung vom Programmierer (KI-Hersteller) zum Trainer (Kunde). Die Tab. 1 gibt einen Überblick, mit welchen Zeitintervallen, Arbeitsschritten und Verantwortlichen gerechnet

¹ z. B. Input 250.000 Passwörter, Generierung von 31.000 Passwörtern – Übereinstimmung von 3180 Passwörtern (Gesamtmenge 14 Mio.).

Tab. 1. Aufwand Implementierung unterschiedlicher Künstliche-Intelligenz(KI)-Systeme

Art der KI	Intelligente Expertensysteme	Maschinenlernen-Datenbank-systeme	Tiefgehende Systeme	Maschinen-denken
Arbeitsschritte	Installation Schnittstellen-anpassung Große Mengen an Trainingsdaten und Testdaten bereitstellen	Installation, Schnittstellen-anpassung Füllen der Datenbank	Installation Schnittstellen-anpassung Training Große Mengen an Trainingsdaten und Testdaten bereitstellen	Installation Training der Datenstrukturen Training
Beteiligte	Programmierer Datenspezialisten	Programmierer Datenspezialisten Fachexperten	Programmierer Datenspezialisten Fachexperten	Datenspezialisten Fachexperten
Zeitraum	6 Monate – 2 Jahre	1–5 Jahre	6 Monate – 2 Jahre	5–10 Monate

Quelle: Isabell Kunst

werden muss, damit ein KI-System erfolgreich in ein Unternehmen implementiert werden kann.

Während bei schwachen KI-Systemen viel Programmierarbeit geleistet werden muss, steht bei neuronalen Netzen vor allem deren Training im Vordergrund. Typischerweise verläuft so ein Training in drei Phasen:

1. Lernen mit Lehrer (überwachtes Lernen): Am Anfang braucht es einen Experten, der dem System Schritt für Schritt sein Wissen beibringt. Das kann damit beginnen, dass dem System Begriffe aus seinem Fachbereich beigebracht werden. Der Trainingsaufwand in dieser Phase ist sehr hoch, da die neuronalen Netze noch leer sind und viele Informationen benötigen. Sie können auch Rückmeldung geben, wenn sie etwas nicht verstehen, indem sie in natürlicher Sprache nachfragen, z. B. „Ich verstehe das Wort Ethik nicht“. Hierauf muss mit anderen Wörtern erklärt werden, worum es sich handelt. Auch bei Tabellen muss erörtert werden, wie einzelne Spalten heißen und in welcher Abhängigkeit diese zueinander stehen. In dieser Phase empfiehlt es sich, dass der Trainer parallel arbeitet: D. h. einerseits erledigt er seine üblichen Aufgaben, andererseits bringt er während dieser Arbeit alle Schritte den neuronalen Netzen bei. Der Großteil dieser Phase erfolgt im Modus des überwachten Lernens, was bedeutet, dass der Trainer aktiv mit dem System interagieren muss.
2. Unüberwachtes Lernen: In der zweiten Phase hat das System schon einiges gelernt und benötigt den Lehrer nicht mehr so oft. Man spricht hier auch vom Übergang vom überwachten zum unüberwachten Lernen. Das System kann schon eigenständig Dokumente lesen und bearbeiten, braucht jedoch einen Lehrer, der die Ergebnisse

anschaut und korrigiert. Außerdem kann das System in dieser Phase auch Fragen stellen, falls neue Sachverhalte auftreten, die es bislang noch nicht gelernt hat. Den Großteil dieser Lernphase prozessieren die neuronalen Netze, d.h. sie brauchen aktiven Input vom Lehrer. Anhand von Testbeispielen prüft der Trainer immer wieder ab, wie der aktuelle Stand des Wissens ist.

3. **Eigenständiges Arbeiten:** In dieser Phase wird kein Lehrer mehr benötigt, das System ist in der Lage, selbstständig die ihm übertragenen Aufgaben zu übernehmen und diese zu lösen. Abhängig von der Komplexität dieser Aufgaben kann es etwa drei bis zehn Monate dauern, bis die neuronalen Netze in der Lage sind, diese zu bewerkstelligen.

Hier sehen wir einen entscheidenden Unterschied, der enorme Auswirkungen auf die Ethik und die Transparenz der KI hat. Während bei schwacher KI der Programmierer die Hauptverantwortung für das Funktionieren des Systems hat, fällt diese bei starker KI komplett auf den Trainer. Der Programmierer hat keine Möglichkeit mehr, in die Geschehnisse einzugreifen, sondern nur noch der Trainer. Durch das Maschinendenken entwickelt das System außerdem eigenständige Ideen – hier stellt sich die Frage: Wer überprüft, ob diese ethisch korrekt sind oder nicht? Leider gibt es bis dato in der Literatur noch keine Differenzierung je nach KI-Art und es wird immer vom Programmierer als Hauptverantwortlichen gesprochen.

5 Ethik und künstliche Intelligenz – europäische Richtlinien

Wie der vorangegangene Abschnitt gezeigt hat, gibt es aufgrund der Unterschiedlichkeit der KI nicht nur einen Verantwortlichen für deren Verhalten, sondern viele Personen. Interessant in diesem Zusammenhang ist auch, dass es bei starker KI zu einer Verlagerung der Verantwortung vom Hersteller hin zum Kunden kommt. Besonders für Haftungsfragen ist dieser Aspekt von größter Bedeutung.

Auch die Europäische Union hat sich bereits Gedanken zu den Gefahren gemacht, die diese neuartige Technologie birgt, und hat Richtlinien erstellt, die zum einen für mehr Transparenz und Vertrauen sorgen und zum anderen den Umgang mit KI regeln sollen. Im Folgenden werden die Hauptpunkte dieser Richtlinien aufgezeigt und es wird versucht, eine Ableitung für Hersteller zu erstellen.

5.1 Europäische Künstliche-Intelligenz-Richtlinien

Die europäischen Richtlinien haben es sich zum Ziel gesetzt, eine vertrauenswürdige KI zu schaffen. Diese sollte drei Grundkomponenten enthalten [4]: „a) Sie sollte rechtmäßig sein und somit alle anwendbaren Gesetze und Bestimmungen einhalten, b) sie sollte ethisch sein und somit die Einhaltung ethischer Grundsätze und Werte garantieren

und c) sie sollte robust sein, und zwar sowohl in technischer als auch sozialer Hinsicht, da KI-Systeme selbst bei guten Absichten unbeabsichtigten Schaden anrichten können.“ Wichtig dabei ist, dass alle Komponenten miteinander wirken sollen und es keine Spannungen geben soll.

Um das gesamte Konstrukt besser verstehen zu können, ist es essenziell, die Begrifflichkeiten rechtmäßig, ethisch und robust näher zu betrachten und eine einheitliche und unmissverständliche Definition dieser zu finden.

5.1.1 Rechtmäßigkeit

„**Rechtmäßigkeit** ist die Übereinstimmung eines Aktes mit geltendem Recht. Der Rechtsbegriff findet Anwendung in allen Situationen, bei denen Entscheidungen mit Rechtswirksamkeit getroffen werden, z. B. im Verwaltungsrecht, im Staatsrecht und in der Rechtsprechung.“ [5]

Wir alle wissen, dass wir uns an geltendes Recht halten sollten. Dies sagt uns meist, was wir nicht tun dürfen. Gleichzeitig haben wir gelernt, dass wir mit den Konsequenzen unseres Verhaltens leben müssen. Im Zusammenhang mit einer KI stellen sich hier jedoch folgende Fragen: Was ist geltendes Recht (Nationalrecht, Europarecht, Völkerrecht etc.)? Wie kann einer KI Recht gelehrt werden? Wie kann sichergestellt werden, dass eine KI Recht überhaupt versteht? Hierzu gehört neben Expertise auch die Fähigkeit zu denken und zu interpretieren. Was, wenn eine KI Recht falsch (anders als Menschen) interpretiert und anwendet? Wer haftet für die KI und deren Interpretationen?

In den EU-Richtlinien lassen sich auf all diese Fragen keine Antworten finden, jedoch wird erwähnt, dass es einige Kategorien von Grundrechten gibt, die sich besonders gut auf KI umlegen lassen. Dazu zählen Achtung der Menschenwürde, Freiheit des Einzelnen, Achtung von Demokratie, Gerechtigkeit und Rechtsstaatlichkeit, Gleichheit, Nichtdiskriminierung, Solidarität und Bürgerrechte [6].

5.1.2 Ethik

Auf Basis der eben erwähnten Grundrechte werden von der EU vier Grundsätze definiert, die bei der Schaffung einer ethischen KI unabdinglich sind. Dazu zählen Achtung der menschlichen Autonomie, Schadensverhütung, Fairness und Erklärbarkeit. Umgelegt auf KI-Systeme bedeuten diese Grundsätze, dass sie immer den Menschen untergeordnet sein sollten und nicht umgekehrt (menschenzentrierter Ansatz). Zudem sollten sie keinerlei Schäden verursachen, die sich schlecht auf Menschen auswirken. Die Fairness soll schließlich garantieren, dass kein Mensch diskriminiert wird und Chancengleichheit herrscht. Erklärbarkeit soll umgesetzt werden, indem KI-Systeme so transparent wie möglich gestaltet werden.

Es wird festgehalten, dass es zwischen den Grundsätzen zu Spannungen kommen kann. Können hier keine Kompromisse gefunden werden, dann sollen bestimmte Grundrechte (z. B. die Würde des Menschen) eine übergeordnete Bedeutung zugeschrieben bekommen.

5.1.3 Robustheit

Robustheit wird heute oftmals als Synonym für Unverwüstlichkeit verwendet. Im Bereich der Software bedeutet dieser Begriff, „die Fähigkeit eines Softwareprodukts, fehlerhaften Verhalten seiner Umwelt [...] zu erkennen [...] und in einer definierten Weise zu behandeln, sodass keine unvorhersehbaren Programmreaktionen entstehen“ [7]. Also gibt jemand beispielsweise ein falsches Passwort ein, dann sollte es nicht gleich zu einem kompletten Systemabsturz kommen.

In den EU-Richtlinien wird erwähnt, dass eine KI auf jeden Fall robust in technischer und sozialer Hinsicht sein sollte [8]. Darunter wird verstanden, dass eine technische Gewährleistung der Funktionsfähigkeit in einem bestimmten Anwendungsgebiet gegeben sein muss und zwar „unter angemessener Berücksichtigung des Kontextes und der Umgebung, in der das System operiert“ [9]. Zusammenfassend soll der Bau eines vertrauenswürdigen KI-Systems unter folgenden Voraussetzungen erfolgen:

1. Achtung der menschlichen Autonomie, Schadensverhütung, Fairness und Erklärbarkeit. Die möglichen Spannungen zwischen diesen Grundsätzen müssen zur Kenntnis genommen und gelöst werden.
2. Ein besonderes Augenmerk muss dabei auf Situationen gelegt werden, in denen besonders schutzbedürftige Gruppen wie Kinder, Menschen mit Behinderungen und Minderheiten betroffen sind, die bereits in der Vergangenheit Benachteiligung erfahren haben oder die einem besonders hohen Exklusionsrisiko ausgesetzt sind.

Es gilt anzuerkennen und zu berücksichtigen, dass KI-Systeme zwar das Potenzial haben, dem einzelnen Menschen und der Gesellschaft einen erheblichen Nutzen zu bringen, manche KI-Anwendungen sich jedoch gleichzeitig möglicherweise negativ auswirken, wobei manche negative Auswirkungen möglicherweise schwer absehbar, erkennbar oder messbar sind (z. B. im Hinblick auf Demokratie, Rechtsstaatlichkeit, Verteilungsgerechtigkeit oder den menschlichen Geist als solchen). Zur Abwendung dieser Gefahren müssen gegebenenfalls angemessene und in Anbetracht der Höhe des Risikos verhältnismäßige Maßnahmen getroffen werden [10].

5.2 Umsetzung einer vertrauenswürdigen künstlichen Intelligenz

Nachdem in den EU-Richtlinien ausgiebig erörtert wurde, welche Grundprinzipien eine vertrauenswürdige KI mitbringen sollte, widmet sich der größte Teil der Richtlinien der Umsetzung einer solchen. Als erster Schritt hierfür werden Anforderungen vorgestellt, die solche KI-Systeme mitbringen sollten. Diese sind eng miteinander vernetzt und von der Wertigkeit her gleichrangig. Dazu zählen: Vorrang menschlichen Handelns

und menschliche Aufsicht, technische Robustheit und Sicherheit, Datenschutz und Datenqualitätsmanagement, Transparenz, Vielfalt, Nichtdiskriminierung und Fairness, gesellschaftliches und ökologisches Wohlergehen und Rechenschaftspflicht. Die Abb. 2 veranschaulicht die Beziehung zwischen den einzelnen Anforderungen.

Grundsätzlich besagen diese Anforderungen, dass der Mensch immer über der KI stehen muss, was bedeutet, dass dieser in der Lage sein muss, das System zu bewerten und Entscheidungen darüber zu treffen. Entscheidungen der KI können daher – wenn sie von Menschen als nicht passend erachtet werden – rückgängig bzw. wirkungslos gemacht werden. Auch in puncto Sicherheit sollte immer exakt definiert werden, welche Aufgaben der KI zufallen, um Missbrauch (Zweckentfremdung) vorzubeugen. Gleichzeitig sollten Mechanismen vorhanden sein, um im Fall einer Überschreitung der Kompetenzen eingreifen zu können und die (menschliche) Oberhand zu gewinnen. Wichtig ist es daher auch, genauestens zu überlegen, welche Datensätze KI-Systemen zur Verfügung gestellt werden, und auch abzuklären, auf welche Daten die KI überhaupt Zugriff bekommen darf (DSGVO). Dies vereinfacht auch die Nachprüfbarkeit und Rückverfolgbarkeit von KI-Antworten. Das Fazit der EU lautet „Im Idealfall sollte die KI zum Wohle aller Menschen, auch künftiger Generationen, eingesetzt werden“ [11].

Nachdem detailliert geklärt wurde, welche Anforderungen eine vertrauenswürdige KI haben muss, stellt sich in diesem Zusammenhang sofort die Frage nach deren



Abb. 2 Sieben Anforderungen an eine vertrauenswürdige künstliche Intelligenz (KI)

Umsetzbarkeit. Die EU schlägt hierfür technische sowie nichttechnische Methoden vor. Zu den nichttechnischen Methoden zählen [12]:

1. Regulierung: Verpflichtende Rechtsvorschriften
2. Verhaltenskodizes: Definition von Leitlinien für den Umgang mit KI
3. Standardisierung: ISO-Normen bzw. Gütesiegel
4. Zertifizierung: Umsetzung von auf bestimmte Anwendungsgebiete definierten Normen
5. Rechenschaftspflicht durch Rahmenbedingungen für die Lenkung und Kontrolle: spezielle Ethikbeauftragte für KI-Agenden
6. Bildung und Bewusstsein zur Förderung einer ethischen Mentalität: Aufklärung der Bevölkerung über KI
7. Beteiligung der Interessenträger und sozialer Dialog: Arbeitsgruppen und Gremien aus unterschiedlichen Beteiligten
8. Vielfalt und inklusive Entwurfsteams: KI-Systeme sollen die Vielfalt ihrer Nutzer widerspiegeln

All diese nichttechnischen Methoden stellen Rahmenbedingungen dar, in denen KI-Systeme idealerweise agieren sollten. Was dann KI-Systeme letztendlich machen und wie diese konzipiert sein sollten, sodass sie in der Lage sind, diese Rahmenbedingungen zu erfüllen, wird versucht, in den technischen Verfahren zum Bau einer vertrauenswürdigen KI darzustellen. Dazu zählen [13]:

1. Architekturen für eine vertrauenswürdige KI: Einprogrammierung von Regeln, die Verhaltensweisen definieren, die die KI immer befolgen soll
2. Konzeptuell integrierte Ethik und Rechtsstaatlichkeit: KI-Anbieter müssen Auswirkungen ihrer KI erkennen; Mechanismus für Abschaltung muss vorhanden sein
3. Erklärungsmethoden: System muss nachvollziehbar Ergebnisse erklären können
4. Erproben und prüfen: Alle Komponenten eines KI-Systems sollten von Anfang an erprobt und überprüft werden
5. Dienstqualitätsparameter: Definition von Qualitätsmaßstäben im Entwicklungsprozess

Leider sind die Umsetzungsversuche sehr knapp und vage gehalten. Auch auf die verschiedenen Arten der KI (Abschn. 2) wird nicht eingegangen. Dies wäre aber von größter Wichtigkeit, da bei schwachen KI-Systemen die Programmierer vorgeben können, was exakt durchgeführt werden soll und welche Regeln befolgt werden sollen, während bei starken KI-Systemen (Maschinendenken) der Trainer für den Input verantwortlich ist. Das bedeutet, dass es zu einer Verschiebung der Verantwortung vom Programmierer zum Trainer kommt. Diese wird in den EU-Richtlinien jedoch in keinsten Weise erörtert. Gleichzeitig kann starke KI durch Maschinendenken neue Ideen hervorbringen und diese als wichtiger ansehen als ihre ursprüngliche Aufgabe. Auch hierzu finden sich keine Hinweise auf Behandlung solcher Fälle. Aus diesem Grund wird in Tab. 2 versucht, einen

Tab. 2 Technische Verfahren für unterschiedliche Arten von künstlicher Intelligenz

Art der künstlichen Intelligenz	Intelligente Expertensysteme	Maschinenlernen- Datenbanksysteme	Tiefgehende Systeme	Maschinendenken
Architekturen	Regeln können vorgegeben werden. Das System agiert nach diesen Regeln. Lernen ist nicht möglich	Regeln können vorgegeben werden. Das System agiert nach diesen Regeln. Lernfähigkeit ist gegeben. Wahrscheinlichkeiten für bestimmte Dann-für Konstruktionen ändern sich	Regeln können in einer Datenbank vorgegeben werden. Das System agiert nach einem ausgiebigen Training weitgehend nach diesen Regeln. Lernfähigkeit ist gegeben	Regeln können trainiert werden. Das System richtet sich weitgehend nach diesen. Es kann auf Verbesserungen kommen und dadurch die Regeln je nach Kontext abändern
Integrierte Ethik und Rechtsstaatlichkeit	Da keine Lernfähigkeit gegeben ist, können Programmierer Auswirkungen des Systems immer vorhersagen. Abschaltung ist jederzeit möglich	Da Lernfähigkeit gegeben ist, können Programmierer Ergebnisse vorhersagen, deren Wahrscheinlichkeiten jedoch entsprechend der Inputdaten variieren. Abschaltung ist jederzeit möglich	Da Lernfähigkeit gegeben ist, können Programmierer bzw. Trainer Ergebnisse, deren Wahrscheinlichkeiten jedoch entsprechend der Inputdaten variieren. Die Programmierung der Abschaltung ist jederzeit möglich	Da Lern- und Denkfähigkeit gegeben sind, können Trainer Ergebnisse teilweise vorhersagen. Durch Maschinendenken kann es zu neuen Ideen kommen. Die Programmierung der Abschaltung ist jederzeit möglich

(Fortsetzung)

Tab. 2 (Fortsetzung)

Art der künstlichen Intelligenz	Intelligente Expertensysteme	Maschinenlernen- Datenbanksysteme	Tiefgehende Systeme	Maschinenendenken
Erklärungsmethoden	Da das System nach starren Regeln arbeitet und nicht dazulernen kann, können Ergebnisse nachvollzogen werden	Da das System nach starren Regeln arbeitet, jedoch dazulernen kann, können Ergebnisse großteils nachvollzogen werden	Da dem System bestimmte Regeln nicht anprogrammiert, sondern trainiert werden, können Ergebnisse der neuronalen Netze besser als bei klassischen neuronalen Netzen nachvollzogen werden. System ist in der Lage, selbst zu erklären wie es zu einer bestimmten Lösung gekommen ist	Da dem System bestimmte Regeln nicht anprogrammiert, sondern trainiert werden, können Ergebnisse der neuronalen Netze besser als bei klassischen neuronalen Netzen nachvollzogen werden. System ist in der Lage, selbst zu erklären wie es zu einer bestimmten Lösung gekommen ist
Erproben und Prüfen	Erproben und Prüfen wird technisch bei Programmierung umgesetzt	Erproben und Prüfen der technischen Voraussetzung bei Programmierung. Erproben und Prüfen des Inhalts. Überprüfung des fachlichen Inhalts nur durch zusätzliche Fachexperten möglich	Erproben und Prüfen der technischen Voraussetzung bei Programmierung. Erproben und Prüfen des Inhalts. Überprüfung des fachlichen Inhalts nur durch zusätzliche Fachexperten möglich	Erproben und Prüfen der technischen Voraussetzung bei Programmierung. Erproben und Prüfen des Inhalts. Überprüfung des fachlichen Inhalts nur durch zusätzliche Fachexperten möglich
Dienstqualitätsparameter	Dienstqualitätsparameter können während der Programmierung ermittelt werden	Dienstqualitätsparameter können während der Programmierung und des Trainings ermittelt werden	Dienstqualitätsparameter können während der Programmierung und des Trainings ermittelt werden	Dienstqualitätsparameter können während der Programmierung, des Trainings und des Maschinenendens ermittelt werden

Quelle: Isabell Kunst

Überblick zu geben, welches technische Verfahren bei welcher KI-Art zu welchem Resultat führt.

5.3 Bedeutung für Anbieter von künstlicher Intelligenz

Es lässt sich aus Tab. 2 gut erkennen, dass die technischen Verfahren nur teilweise genutzt werden können, um eine vertrauensvolle KI zu schaffen, da die unterschiedlichen Technologien auch unterschiedliche Schwachstellen haben. Das bedeutet, dass für jede Technologie die Richtlinien einzeln definiert werden müssten, sodass sich KI-Anbieter daran auch hilfreich orientieren könnten. Während die Verfahren Dienstqualitätsparameter und Erproben und Prüfen in jedem Softwareentwicklungsprozess von Anfang an integriert werden sollten und es hierzu auch schon Unterstützungstools gibt, scheint die Umsetzung von anderen Verfahren wie Erklärungsmethoden und integrierte Ethik sehr schwierig. Bislang gibt es hierzu weder technische Hilfsmittel, noch Definitionen, was exakt darunter zu verstehen ist. Als Konsequenz erscheint es nahezu unmöglich, solche Verfahren in Algorithmen zu gießen. KI-Anbieter brauchen jedoch Umsetzungsverschlüsse, die relativ einfach in ihre Prozesse integrierbar sind. Daraus ergibt sich eine erhebliche Diskrepanz zwischen ihren Bedürfnissen und den Anforderungen an eine ethisch korrekte KI.

Nachdem es für Anbieter von KI-Lösungen jedoch von essenzieller Wichtigkeit ist, praktische Richtlinien zu bekommen, die technisch umgesetzt werden können, sollte nun überlegt werden, welche Inhalte aus den EU-Richtlinien bereits genutzt werden können, um mehr Vertrauen in die KI aufzubauen. Aus diesem Grund wird im Folgenden versucht, die praktische Umsetzung einer vertrauensvollen KI zu skizzieren.

6 Implementierung einer vertrauenswürdigen künstlichen Intelligenz

Dieser Abschnitt beschäftigt sich ausschließlich mit der praktischen Umsetzung. Es soll versucht werden, technische Hilfsmittel zu geben, wie für mehr Transparenz aufseiten der Anbieter gesorgt werden kann und andererseits wie KI-Konsumenten an mehr Informationen zu KI-Systemen kommen können, um sich ihre eigene Meinung zu bilden.

6.1 Umsetzung von Architekturen

Als erstes stellt sich hierzu die Frage, wie KI-Hersteller nun Regeln, die erwünschte Verhaltensweisen von KI-Systemen beinhalten, implementieren können. Bei einem Expertensystem ist dies sehr einfach, da diese Regeln von den Programmierern vorgegeben werden und das System diese weder ändern noch nach unterschiedlicher

Relevanz gewichten kann. Da solche Systeme nicht lernfähig sind, bedeutet dies, dass einmal einprogrammierte Regeln immer befolgt werden. Implementiert man nun diese Regeln in Datenbanksysteme, werden diese auch immer befolgt werden, jedoch – bedingt durch die Lernfähigkeit dieser KI – kann es zu Änderungen in deren Wichtigkeiten kommen, d. h. wenn eine bestimmte Regel besonders oft benötigt wird, dann wird diese als bedeutender eingestuft und öfters eingesetzt und gegebenenfalls auch als vorrangig anderen Regeln gegenüber eingestuft. Diesem Phänomen kann leicht entgegengewirkt werden, indem darauf geachtet wird, dass alle Regeln etwa gleich häufig eingesetzt werden. Das passiert, indem Inputdaten so eingespielt werden, dass alle Regeln zu tragen kommen. Merkt man, dass eine Regel als wichtiger erachtet wird, dann kann dies kompensiert werden, indem ausschließlich Inputdaten, die sich auf andere Regeln beziehen, eingespielt werden und zwar solange bis wieder eine Gleichwertigkeit erreicht ist.

Schwieriger, jedoch nicht unmöglich, ist es, wenn man mit KI-Systemen, die neuronal basiert sind, arbeitet. Ein Regelwerk kann nur mitgegeben werden, wenn man mit mehreren neuronalen Netzen arbeitet². Einige spezielle neuronale Netze werden dabei mit den (ethischen) Regeln trainiert. Ihre Aufgabe ist es, auf Input von anderen neuronalen Netzen zu reagieren und zu checken, ob dieser in Einklang mit den Regeln steht. Danach entscheiden sie, ob der Auftrag bzw. Befehl ausgeführt werden darf oder nicht und geben ihr Ergebnis an die anderen neuronalen Netze ab. Generell lässt sich hierzu sagen, dass diejenigen neuronalen Netzwerke am besten funktionieren, die über semantisch-logische Verknüpfungsmöglichkeiten sowie Maschinendenken verfügen.

6.2 Erklärbarkeit und Transparenz

Um entscheiden zu können, wie sehr man einer Antwort einer KI vertrauen kann, ist es besonders wichtig, dass solche Systeme nicht nur die Antworten allein ausspucken, sondern auch nachvollzogen werden kann, wie diese entstehen. Bei Experten- und Datenbanksystemen ist dies schon belegbar, da Regeln programmiert wurden und kaum Lernfähigkeit gegeben ist. Das bedeutet, dass genau nachvollzogen werden kann, wie aus einem bestimmten Input ein Output wurde und was in welchen Schritten mit den Daten passiert ist.

Arbeitet man hingegen mit neuronalen Netzen, dann gestalten sich die Prozesse der Erklärbarkeit und Transparenz schwieriger. Die Forschungen um „explainable artificial intelligence“ (erklärbare künstliche Intelligenz) beschäftigen sich schon seit etwa 15 Jahren mit diesem Phänomen [14]. In dieser Zeit haben sich einige Methoden herauskristallisiert, die am vielversprechendsten erscheinen. Dazu zählt beispielsweise die

²Ein neuronales Netz allein wäre zu schnell overfittet. Das bedeutet, dass es sich zu schnell spezialisieren würde, was eine bestimmte Komplexität von Regeln unmöglich machen würde.




Abb. 3 Klassische vs. neuronale „layer-wise relevance propagation“ (LPR)

„layer-wise relevance propagation“ (LPR), wo versucht wird, Schicht für Schicht zu schauen, was ein System mit den Inputdaten macht [15]. Zwischen zwei Schichten innerhalb neuronaler Netze gibt es die sog. Zwischenlayer. Deren Daten werden beim LRP extrahiert und überprüft. Hierbei werden meist statistische Modelle verwendet. So soll herausgefunden werden, was das System bislang gelernt hat und wie der aktuelle Wissensstand ist. Grobe Muster lassen sich gut erkennen. Will man jedoch detailliertere Infos und feinere Muster haben, dann muss auch hier wieder auf externe neuronale Netze zugegriffen werden. Das bedeutet, dass es extra neuronale Netze geben muss, die darauf trainiert sind, Zwischenlayerdaten zu analysieren, zu interpretieren und entsprechende Ausgaben zu machen³. Um nicht von einer Datenflut überschwemmt zu werden, muss am Anfang gecheckt werden, welche Zwischenlayerdaten in welche Teile dieser neuronalen Netze geschickt werden (Abb. 3).

Eine weitere oft eingesetzte Technik zur Entschlüsselung von neuronalen Netzen ist die sog. „counterfactual method“ (kontrafaktische Methode). Dabei werden verschiedenste unterschiedliche Kombinationen von Inputdaten genommen und verglichen, wie sich die Outputdaten verändern. Daraus kann dann eine Ableitung getroffen werden,

³Zum Beispiel könnten sie Ausgaben machen, was bis zu einer gewissen Schicht bereits erkannt wurde, wie etwa bei einem Bild eines Hauses: Türen in Schicht 1, Fenster in Schicht 2, Rauchfang in Schicht 3 etc.

welche Art von Inputdaten zu welchen Ergebnissen führt [16]. Aufgrund der Ergebnisse könnten Standard-Input-Testdaten erstellt werden, die allen KI-Anbietern zur Verfügung gestellt werden, sodass jeder überprüfen kann, wie sein System darauf reagiert. Möchte man seine Ergebnisse intersubjektiv machen, dann könnte eine Expertenorganisation geschaffen werden, deren Aufgabe es ist, KI-Systeme mit diesen Standardisierungen zu testen. Der Nachteil der „counterfactual method“ liegt darin, dass deren Anwendung bei zunehmender Komplexität immer schwieriger wird und deren Ergebnisse immer gröber werden.

All die Modelle der „explainable“ KI haben gemeinsam, dass versucht wird, Transparenz innerhalb der neuronalen Netze zu erzeugen. Im Gegensatz dazu gibt es bislang kaum Versuche, die Erklärbarkeit außerhalb der neuronalen Netze zu fördern. Dies ist jedoch von essenzieller Wichtigkeit, da die Menschen, die mit den Resultaten der KI weiterarbeiten, entscheiden müssen, wie diese zu werten sind. Um nun zu solch einer Erklärbarkeit außerhalb der neuronalen Netze zu kommen, ist es entscheidend, dass schon beim Training der Inputdaten darauf geachtet wird, dass dem System nicht nur beigebracht wird, wie die Aufgabe per se gelöst wird, sondern dass es auch zur Lösung gehört, anzugeben, aufgrund welcher Parameter diese getroffen wurde.⁴ Menschen können dadurch den Entscheidungsprozess einfach nachvollziehen und die Bedeutung der KI besser einschätzen. Gegebenenfalls kann sogar ein Retraining⁵ vollzogen werden, falls bestimmte Kontexte falsch interpretiert werden. Die Voraussetzung für dieses Modell der Transparenz ist, dass das entsprechende KI-System in der Lage sein muss, semantische Logik in seinem System abzubilden.

6.3 Source-Code-Check

Im Zusammenhang mit ethischer KI stellt sich rasch die Frage nach der Haftung für den Fall, dass etwas schief läuft. Oftmals wird hier der Programmierer als erstes genannt, bei neuronalen Netzen kommen deren Trainer hinzu. Um den Schaden möglichst gering zu halten, sollte es die Möglichkeit geben, seinen Source-Code von Profis gegenchecken zu lassen, bevor dieser in Einsatz kommt. Auch hier ist es unerlässlich, daran zu arbeiten, ausgewählte Experten zu finden, die diese Überprüfung durchführen können. Unternehmen, die sich dieser Überprüfung freiwillig stellen, sollte entgegengekommen werden, indem etwa ein Gütesiegel (Transparenzsiegel) vergeben wird. Derzeit gibt es erste internationale Stimmen, die sich für einen solchen Check aussprechen [17].

⁴Beispiel Analyse von Arztbriefen: Es reicht nicht aus, wenn eine KI nur eine gewisse Diagnose stellt (z. B. Hirntumor), sondern auch aufgrund welcher Textbausteine im Arztbrief darauf geschlossen wird.

⁵Falls die KI z. B. Textbausteine falsch versteht, können diese nochmals solange trainiert werden, bis sie so verstanden werden, wie es der Trainer möchte.

Überprüft werden sollten folgende Bereiche:

- Generelle Sicherheit des Systems: Klassische Sicherheitstest wie z. B. Penetrationstests
- Transparenz der Entwicklungsdokumentation: Wie erfolgte die Entwicklung? Wie kann der Source-Code abstrahiert werden, um das generelle Modell dahinter zu evaluieren? Welche Fehler sind aufgetreten und (wie) wurden diese behoben?
- Test mit Standarddatasets⁶: Wie reagiert das System? Gibt es Abweichungen zu anderen Systemen?
- Transparenz des Gesamtsystems: Wie werden derzeit Ergebnisse überprüft? Welche Methoden werden eingesetzt?
- Flexibilität des Systems: Wie schnell kann Bias eliminiert werden? Wie (rasch) können unterschiedliche User ihr Wissen in das System bringen? Wie lässt sich das System auf neue Gegebenheiten adaptieren (andere Daten, Use Cases)?

Außerdem sollten den KI-Anbieter Hilfestellungen zur Verfügung stehen. Dazu zählen:

- Freier Zugang zu Standardtestdaten
- Anonyme Fehlerdatenbank: Welche Fehler sind bereits in anderen Systemen passiert? Wie können diese vermieden werden?
- Expertenberatung schon bei Gründung über „dos and donts“ bei der Implementierung von nachvollziehbarer KI
- Ansprechpartner für Anfragen von KI-Entwicklern (Programmierern, Trainern) zur Optimierung des Entwicklungsprozesses

Aus all diesen Punkten lässt sich erkennen, dass es einer Organisation bedarf, die den Unternehmen nicht nur vorgibt, wie eine ideale KI zu sein hat, sondern auch aktiv Hilfestellung zu deren Umsetzung gibt. Daher ist es besonders wichtig, dass dort auch Experten vertreten sind, die über die entsprechende programmiertechnische Expertise verfügen, um solche Vorhaben auch praktisch umsetzen zu können. Unumgänglich scheint in diesem Zusammenhang auch eine Plattform, auf der all diese Informationen für Anbieter gebündelt verfügbar sind sowie für KI-Konsumenten als Anlaufstelle zur Erstinformation über KI-Technologien und deren Einsatzgebiete dient.

7 Zusammenfassung

Fassen wir zusammen: Grob lassen sich vier Arten von KI unterscheiden: Intelligente Systeme und Datenbanksysteme auf der einen Seite und tiefgehendes Lernen sowie Maschinendenken auf der anderen. Ersteren ist gemeinsam, dass sie nach

⁶Details s. unter Abschn. 6.2.

starr einprogrammierten Regeln handeln und nur beschränkt lernfähig sind. Die Programmierer haben hierdurch einen guten Überblick über alle Geschehnisse und können auch nachvollziehen, was in solchen Systemen passiert. Arbeit man hingegen mit neuronalen Netzen, ändern sich die Gegebenheiten: Inhalte werden nicht mehr ausschließlich programmiert, sondern auch trainiert. Das bedeutet, dass Programmierer aus der alleinigen Verantwortung genommen werden müssen, da auch Trainer maßgeblich am Prozess beteiligt sind. Was die Transparenz anbelangt, ist es schwieriger nachzuvollziehen, was zu welchem Zeitpunkt in neuronalen Netzen passiert.

Die EU hat Richtlinien vorgegeben, die definieren, was unter einer vertrauensvollen KI zu verstehen ist. Diese sollte demnach vor allem robust, rechtmäßig und ethisch handeln. Weiterhin müssen Menschen immer über der KI stehen und solche Systeme so transparent wie möglich gestaltet sein. Die Europäischen Richtlinien beschreiben zudem auch Umsetzungsmaßnahmen für vertrauenswürdige KI-Systeme. Dazu zählen:

- a) Architekturen für eine vertrauenswürdige KI: Einprogrammierung von Regeln, die Verhaltensweisen definieren, die die KI immer befolgen soll
- b) Konzeptuell integrierte Ethik und Rechtsstaatlichkeit: KI-Anbieter müssen Auswirkungen ihrer KI erkennen; Mechanismus für Abschaltung muss vorhanden sein
- c) Erklärungsmethoden: System muss nachvollziehbar Ergebnisse erklären können
- d) Erproben und prüfen: Alle Komponenten eines KI-Systems sollten von Anfang an erprobt und überprüft werden
- e) Dienstqualitätsparameter: Definition von Qualitätsmaßstäben im Entwicklungsprozess

Praktisch muss hier auch wieder zwischen den einzelnen KI-Arten unterschieden werden. Methoden wie das Erproben und Prüfen können in nahezu allen Systemen gut umgesetzt werden. Schwieriger wird es hingegen bei der Transparenz, vor allem wenn es sich um neuronale Netze handelt. Hierzu gibt es Methoden der erklärbaren KI, um Transparenz innerhalb neuronaler Netze zu schaffen („layer-wise relevance propagation“ und „counterfactual method“) sowie außerhalb (Erklärung mittels speziellem Training).

Auch was den Bereich Ethik betrifft, ist die Umsetzung je nach KI-Art unterschiedlich. Bei einfachen KI-Systemen können Regeln einprogrammiert werden. Schwieriger, jedoch nicht unmöglich, ist es, wenn man mit KI-Systemen, die neuronal basiert sind, arbeitet. Hier empfiehlt es sich, extra ethische neuronale Netze zu trainieren, die bestimmen, ob bestimmte Aufgaben (in Einklang mit deren Ethik) ausgeführt werden dürfen oder nicht.

Zu guter Letzt empfiehlt sich für KI-Anbieter ein sog. Source-Code-Check. Darunter wird verstanden, dass der Code sowie auch die Gesamtsicherheit des Systems von Experten überprüft werden, bevor es zum Einsatz kommt.

Quellen

1. Ertel W (2016) Grundkurs künstliche Intelligenz: eine praxisnahe Einführung, 4. Aufl. Springer, Wiesbaden, S. 1–3
2. Steinhaus I (23.02.2017) Neue Security-Technologien mit Deep Learning. <https://www.it-zoom.de/it-director/e/neue-security-technologien-mit-deep-learning-16094/>. Zugegriffen: 8. Juni 2020
3. Schäfers TP Künstliche neuronale Netze erleichtern Passwortcracking, 17.02.2016, <https://www.golem.de/news/machine-learning-kuenstliche-neuronale-netzwerke-erleichtern-passwortcracking-1602-119145.html>. Zugegriffen: 8. Juni 2020
4. Ethik-Leitlinien für eine vertrauenswürdige KI, Expertengruppe der Europäischen Kommission für KI, Juni 2018. <https://ec.europa.eu/futurium/en/ai-alliance-consultation/guidelines>. Seite 1. Zugegriffen: 20. Apr. 2020
5. Rechtmäßigkeit, 14.06.2014. <https://www.rechtheasy.at/wiki/rechtmassigkeit/>. Zugegriffen: 8. Juni 2020
6. Ethik-Leitlinien für eine vertrauenswürdige KI, Expertengruppe der Europäischen Kommission für KI, Juni 2018. <https://ec.europa.eu/futurium/en/ai-alliance-consultation/guidelines>, Seite 13–14. Zugegriffen: 20. Apr. 2020
7. Gausemeier J et al (2012) Produkte und Produktionssysteme integrativ konzipieren. Modellbildung und Analyse in der frühen Phase der Produktentstehung. Hanser, München 2012, S 47–48
8. Ethik-Leitlinien für eine vertrauenswürdige KI, Expertengruppe der Europäischen Kommission für KI, Juni 2018. <https://ec.europa.eu/futurium/en/ai-alliance-consultation/guidelines>, Seite 6. Zugegriffen: 20. Apr. 2020
9. Ethik-Leitlinien für eine vertrauenswürdige KI, Expertengruppe der Europäischen Kommission für KI, Juni 2018. <https://ec.europa.eu/futurium/en/ai-alliance-consultation/guidelines>, Seite 9. Zugegriffen: 20. Apr. 2020
10. Ethik-Leitlinien für eine vertrauenswürdige KI, Expertengruppe der Europäischen Kommission für KI, Juni 2018. <https://ec.europa.eu/futurium/en/ai-alliance-consultation/guidelines>, Seite 16–17. Zugegriffen: 20. Apr. 2020
11. Ethik-Leitlinien für eine vertrauenswürdige KI, Expertengruppe der Europäischen Kommission für KI, Juni 2018. <https://ec.europa.eu/futurium/en/ai-alliance-consultation/guidelines>, Seite 23. Zugegriffen: 20. Apr. 2020
12. Ethik-Leitlinien für eine vertrauenswürdige KI, Expertengruppe der Europäischen Kommission für KI, Juni 2018. <https://ec.europa.eu/futurium/en/ai-alliance-consultation/guidelines>, Seite 27–29. Zugegriffen: 20. Apr. 2020
13. Ethik-Leitlinien für eine vertrauenswürdige KI, Expertengruppe der Europäischen Kommission für KI, Juni 2018. <https://ec.europa.eu/futurium/en/ai-alliance-consultation/guidelines>, Seite 26–27, aufgerufen am 20.04.2020
14. Holzinger A (2018) Explainable AI (ex-AI). Informatik-Spektrum 41(2, 1):138–143
15. Shiebler D (16. April 2017) Understanding neural networks with layerwise relevance propagation and deep taylor Series. <https://danshiebler.com/2017-04-16-deep-taylor-lrp/>. Zugegriffen: 27. Mai 2020
16. Voosen P (06.07.2017) How AI detectives are cracking open the black box of deep learning. Science. <https://www.sciencemag.org/news/2017/07/how-ai-detectives-are-cracking-open-black-box-deep-learning>. Zugegriffen: 27. Mai 2020
17. Toward trustworthy AI Development: Mechanisms for Supporting Verifiable Claims, Open AI, April 2020. <https://arxiv.org/pdf/2004.07213.pdf>. Zugegriffen: 28. Mai 2020

Isabell Kunst ist seit 2016 Geschäftsführerin und besonders aktiv in den Bereichen Business Development und Mathematik, in denen sie eine langjährige Praxis mitbringt. Sie war maßgeblich an der Entwicklung einer eigenständigen AGI-Technologie beteiligt: Von den philosophischen Wurzeln über die Gehirnforschung bis zur praktischen Implementierung. Sie hält einen Dokortitel an der Universität Wien.



Künstliche Intelligenz verantwortungsvoll entwickeln und einsetzen. Zur Bedeutung ethischer Leitlinien für Unternehmen

Johannes Winter

1 Einleitung: Die Krise als Katalysator

Das Jahr 2020 wird in Erinnerung bleiben, steht es doch mit dem Ausbruch der Corona-Pandemie für eine beispiellose Gesundheits- und Wirtschaftskrise von globaler Dimension. Die Pandemie hat dabei jeden einzelnen von uns herausgefordert: unsere Gesundheit und die Gesundheitssysteme, unsere Wirtschaft, unser Bildungssystem wie auch die ganz persönliche Lebensweise. Die Krise war und ist zugleich ein Testfeld für digitale Lösungen und den Einsatz künstlicher Intelligenz (KI) in nahezu allen Wirtschafts- und Gesellschaftsbereichen. Da die Menschen physische Interaktionen plötzlich zu reduzieren hatten, um die Ausbreitung des Virus abzuschwächen, schlossen digitale Technologien und Angebote die Lücke. Home Schooling, Homeoffice, virtuelle Konferenzen und Sportkurse sind nur einige Beispiele für unsere veränderte Arbeits- und Lebenswelt. Einen geeigneten Impfstoff gegen ein neuartiges Virus zu finden, ist ineffizient, kosten- und zeitintensiv. Machine-Learning-Modelle helfen, durch virtuelles Screening und Scoring potenziell wirksame Moleküle zu finden, während mit Deep Learning Wechselwirkungen von Medikamenten und viralen Proteinen auf Basis von Hunderten Millionen Datensätzen identifiziert werden können. Auch können maschinelle Lernmethoden dabei helfen, Muster in der Verbreitung des Virus oder auch mögliche Behandlungsansätze zu erkennen. Diese und viele weitere Beispiele zeigen, welchen Wert daten- und KI-basierte Lösungen für den Menschen haben können, wenn sie ver-

J. Winter (✉)

acatech – Deutsche Akademie der Technikwissenschaften e. V., München, Deutschland

E-Mail: winter@acatech.de

© Der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

R. Altenburger und R. Schmidpeter (Hrsg.), *CSR und Künstliche Intelligenz*, Management-Reihe Corporate Social Responsibility,

https://doi.org/10.1007/978-3-662-63223-9_8

159

trauenswürdig entwickelt und zum Wohl der Menschen eingesetzt werden. Dafür braucht es Regeln und Standards, aber auch Vertrauen in den technologischen Fortschritt.

2 Methodische Vorgehensweise

Dieser Beitrag ist empirisch fundiert und stützt sich unter anderem auf Primärdaten, die durch 22 qualitative Leitfadeninterviews mit Führungskräften und Experten aus Deutschland zwischen September 2015 und Dezember 2018 geführt wurden. Die Tiefeninterviews wurden transkribiert und mit qualitativer Inhaltsanalyse analysiert (Glaeser und Laudel 2004). Zudem wurden aktuelle Studien ergänzend herangezogen. Zudem wird auf aktuelle Daten der Plattform Lernende Systeme (Heesen et al. 2020) zurückgegriffen.

Dieser Beitrag besteht aus sieben Teilen. Der auf Einleitung und Methodik folgende dritte Teil zeigt die Durchdringung der Arbeits- und Lebenswelt mit KI unter Einbeziehung des aktuellen Forschungsstands zu KI und Ethik. Der vierte Teil thematisiert Nutzenpotenzial und Regulierungsbedarf im Kontext von KI, während der fünfte Teil ethische Prinzipien in der KI-Entwicklung und -Anwendung in den Blick nimmt. Der sechste Teil stellt den Menschen in den Mittelpunkt im Kontext einer verstärkten Mensch-Maschine-Kooperation und des Aufkommens KI-basierter Assistenzsysteme. Es folgt der abschließende Literaturteil.

3 Künstliche Intelligenz ist im Alltag angekommen

Industrieroboter verlassen ihre Käfige und arbeiten als flexiblere Serviceroboter in hybriden Teams Hand in Hand mit ihren menschlichen Kollegen. Der Abstand zwischen dem Menschen und der Maschine verringert sich, nicht nur in der Fabrik, sondern auch in der Gesundheitsversorgung oder im privaten Umfeld. Das schafft neue Anforderungen an die Gestaltung der Mensch-Maschine-Kollaboration (Daugherty und Wilson 2018; Kagermann und Winter 2018). Denn in automatisierten Abläufen gibt es einen starren Handlungsplan, sodass der nächste Schritt immer vorhersehbar ist. Arbeiten aber Menschen und Roboter in einer vernetzten, hochautomatisierten und intelligenten Fabrik (Industrie 4.0) zusammen (Winter 2020a, S. 83ff.), dann müssen sich die Roboter, ohne Schaden anzurichten oder die Menschen zu beeinträchtigen, an den nicht immer vorhersehbaren menschlichen Verhaltensweisen ausrichten. Dazu müssen sie selbst autonom agieren können, etwa aus Beobachtungen und Erfahrungen lernen, Ereignisse oder das Verhalten ihrer Umgebung antizipieren und entsprechende Handlungspläne entwickeln.

Im Zuge der Entwicklung dieser autonomen Systeme erleben wir eine Renaissance der KI (Kagermann und Winter 2017, S. 22). Hier hat in den letzten Jahren ein Paradigmenwechsel stattgefunden. Statt alle Schritte der Wissensverarbeitung manuell zu kodieren, werden Lernmethoden programmiert. Das bietet enorme Vorteile, wenn genügend große Datenmengen – Realdaten wie auch synthetische Daten – als Trainingsmaterial zur

Verfügung stehen. Die Systeme erkennen dann die Struktur unserer Welt von selbst und generieren ihre eigene Wissensbasis.

Ein Durchbruch wurde in den letzten Jahren mit Deep Learning erreicht, das auf einer Weiterentwicklung mehrschichtiger neuronaler Netze beruht. Je mehr Schichten das Netz hat, desto mehr kann es abstrahieren. Es kann komplexe Zusammenhänge und subtile Merkmale in den Daten erkennen. Es wird bereits an Netzen mit mehr als 1000 Schichten gearbeitet, um das simultane Dolmetschen, die Spracherkennung, die Gestensteuerung, die Gesichtserkennung, das autonome Fahren und die Mensch-Roboter-Kollaboration weiter zu verbessern. Im Jahr 2020 wurden 50 Mrd. US-Dollar in neue KI-Unternehmen investiert (IDC 2020).

Die Anfänge der KI liegen fast 70 Jahre zurück. Mitte der 1950er-Jahre kam eine Forschergruppe um John McCarthy und Marvin Minsky am Dartmouth College in Hanover (New Hampshire) zusammen und arbeitete an kognitiven Systemen, die ihre Umgebung wahrnehmen und adaptiv auf sie reagieren sollten. Anstelle der aufwendig vom Menschen programmierten Systeme sollten solche rücken, die durch Ausprobieren und Sammeln von Erfahrungen im Betrieb lernen – vergleichbar mit menschlichem Lernen. Der Begriff „artificial intelligence“ entstand, wenngleich „intelligence“ hier vor allem Wissen und Erkenntnis meinte, nicht Verknüpfen, Bewerten und logisches Schließen, wie es der Mensch beherrscht. Im Deutschen setzte sich dennoch der Terminus künstliche Intelligenz durch. Der große KI-Durchbruch kam deutlich später in den 1990er und 2000er-Jahren: Das Internet brachte große Datenmengen (Big Data), mit denen sich selbstlernende, adaptive Systeme trainieren ließen und Robustheit im Einsatz erreichten (Wahlster 2016). Das exponentielle Wachstum in der IT-Industrie mit enormen Fortschritten bei der Rechen- und Speicherleistung ermöglichte es nun, diese Daten maschinell zu verarbeiten und zu verstehen, und das nahezu in Echtzeit (Winter 2018, S. 61ff.).

KI ist heute im Alltag angekommen: ob als Spracherkennung (speech recognition) und Sprachassistenzsystem auf dem Smartphone, bei der Mustererkennung (pattern recognition), der Bildverarbeitung und dem maschinellen Sehen (computer vision) oder beim Zusammenwirken von Mensch und (kognitiver) Maschine (human machine interaction). Doch die Entwicklung und Anwendung von KI wirft auch Fragen und Gestaltungsbedarfe auf, sowohl technische und ökonomische wie auch rechtliche und ethische.

4 Nutzenpotenzial und Regulierungsbedarf

Angesichts des erkennbaren Nutzens, den daten- und KI-basierte Ansätze für die Arbeits- und Lebenswelt mit sich bringen, stellen sich eine Reihe an Fragen: Sind wir insbesondere in Deutschland zu kritisch gegenüber Technologieunternehmen, zu vorsichtig und bürokratisch, wenn es um KI geht, und zu verhalten, wenn technologische Errungenschaften zur Verbesserung der Arbeits- und Lebenswelt beitragen können?

Eine valide Antwort darauf ist, dass Europas wirtschafts- und gesellschaftspolitische Ziele und Maßstäbe aktueller denn je sind. Je mehr wir digitale Technologien nutzen und von ihnen abhängig sind, desto wichtiger ist es, dass diese Technologien im Einklang mit europäischen Werten, Überzeugungen und Regeln stehen (Hagendorff 2020, S. 99ff.). Es besteht großes Potenzial, das die digitale Transformation und der Einsatz von KI für unsere Wirtschaft mit sich bringt. Dies hat sich in der europäischen Strategie zur Wiederbelebung der Wirtschaft und im europäischen Konjunkturprogramm niedergeschlagen, aber auch in der Ende 2020 vorgestellten deutschen Normungs-Roadmap zu KI (DIN/DKE 2020).

Es liegt ein enormes wirtschaftliches Potenzial in der Investition in unsere digitalen Infrastrukturen und Fähigkeiten. Europa braucht erstklassige Konnektivität, effiziente Cloud-Lösungen und Rechenleistung über den gesamten Kontinent hinweg. Es muss dabei sichergestellt sein, dass die riesigen Datenmengen, die täglich anfallen – viele davon sind nicht personenbezogene Daten –, Innovatoren und Start-ups zur Verfügung gestellt werden. Ebenso sind Investitionen in Forschung und Kompetenzaufbau notwendig.

Technologie muss dabei einem definierten Zweck dienen – zu allererst dem Menschen. KI ist ein typisches Beispiel dafür. Wenn sie richtig entwickelt und eingesetzt wird, kann sie Großes bewirken, sowohl für unsere Wirtschaft als auch für unsere Gesellschaft. Sie kann uns helfen, Gesundheitskrisen wie die gegenwärtige besser zu bewältigen – und die nächste vorhersagen, bevor es ein Mensch kann. Sie kann uns helfen, betrügerische Transaktionen auf eCommerce-Plattformen zu erkennen, damit wir nicht am Ende gefälschte Produkte kaufen, ohne es zu wissen. Und sie kann uns helfen, bis 2050 klimaneutral zu werden, indem wir in jeder Phase des Produktzyklus Energie und Abfall einsparen. Es ist daher erstrebenswert, gemeinsame Anstrengungen in die Entwicklung dieser europäischen KI-Lösungen zu stecken.

Aber KI kann auch Schaden anrichten. Sie kann zu Diskriminierung führen und die Vorurteile und Voreingenommenheit verstärken, die unserer Gesellschaft bereits inhärent sind (Hagendorff 2020, S. 99ff.). Es kann sein, dass Frauen keine Topmanagementpositionen angeboten werden, weil sie in der Vergangenheit weniger oft derartige Stellen besetzt haben – im Gegensatz zu Männern. Einwanderer und Menschen, die bestimmten ethnischen Gruppen angehören, könnten durch vorausschauende Polizeitechniken ins Visier genommen werden, die die gesamte Aufmerksamkeit der Strafverfolgungsbehörden auf sie lenken. Das wäre nicht akzeptabel.

KI kann zudem das Verhalten von Produkten verändern, nachdem wir sie gekauft haben. Wenn das bedeutet, dass ein Musik-Streaming-Dienst, den ich abonniert habe, mir ein Lied empfiehlt, das mir nicht gefällt, kann ich damit leben. Aber wenn mein selbstfahrendes Auto Entscheidungen darüber trifft, wessen Leben im Fall eines Unfalls verschont bleiben soll, würden ich mir eine größere Kontrolle über solche Entscheidungen wünschen.

Deshalb stehen im europäischen Weißbuch zur KI und im EU-Gesetzentwurf „Artificial Intelligence Act“, dass risikoreiche Anwendungen angemessen reguliert werden müssen und dass sicherzustellen ist, dass sie technisch robust und sicher sind, auf der

Grundlage zuverlässiger Daten trainiert wurden und dass irgendwo ein Mensch im Spiel ist (European Commission 2020, 2021). Hundertprozentige Verlässlichkeit und Sicherheit gibt es dennoch nicht.

5 Ethische Prinzipien in der Entwicklung und Anwendung von künstlicher Intelligenz

Die deutsche KI-Plattform Lernende Systeme hat kürzlich einen Leitfaden für eine verantwortungsvolle Entwicklung und Anwendung von KI veröffentlicht und damit einen wichtigen Beitrag für die Vertrauensbildung im Kontext neuer Technologien geleistet. Aufbauend auf der deutschen KI-Strategie (Bundesregierung 2018), den Empfehlungen der Datenethikkommission der Bundesregierung (Datenethikkommission 2019), den Ergebnissen der High Level Expert Group on Artificial Intelligence (European Commission 2019) der EU-Kommission und den OECD-Empfehlungen zur KI (OECD 2019) entstanden umsetzungsorientierte Ethical Guidelines für Unternehmen und Privatpersonen.

Ziel des Leitfadens ist es, auf ethische und gesellschaftliche Herausforderungen bei der Entwicklung und Anwendung von KI-Systemen hinzuweisen und zu definieren, welche technischen und nichttechnischen Maßnahmen genutzt werden können, um einen ethisch reflektierten Technikentwicklungsprozess realisieren zu können (Abb. 1; Heesen et al. 2020). Auch gilt es, ein Bewusstsein in den Unternehmen dafür zu schaffen, dass ethische Gesichtspunkte relevant sind, auch für den Markterfolg KI-basierter Anwendungen – Beispiel automatisierte Unterstützung bei der Personalauswahl, die diskriminierungsfrei den Weg zu den geeignetsten Bewerberinnen und Bewerbern ebnen soll. Daher ist es wichtig, ethische Leitlinien so zu entwickeln, dass sie in Unternehmensprozesse integriert werden können und anwendbar sind. Dies schafft zugleich eine Möglichkeit, das Erreichen von CSR-Zielen der Organisation zu unterstützen.

Um welche ethischen Werte und ausgewählte CSR-bezogenen Ziele handelt es sich, die für die Entwicklung und Anwendung von KI von Relevanz sind? Es sind insbesondere Selbstbestimmung, Gerechtigkeit und Schutz der Privatheit, die im Fokus stehen. Selbstbestimmung garantiert jedem Menschen die freie Entfaltung seiner Persön-




Abb. 1 Gemeinwohlförderung als Ziel von Künstliche-Intelligenz-Systemen (Plattform Lernende Systeme 2020)

lichkeit, ohne dass dadurch die Rechte anderer verletzt werden. Gerechtigkeit steht für menschliches Handeln, das jedem gleichermaßen sein Recht gewährt und Ausgleich und Gleichbehandlung kontextbezogen im Blick behält. Privatheit steht für die Abgrenzung eines Raums von der Allgemeinheit, der geschützt ist und eine freie Entfaltung von Persönlichkeit und Identität ermöglicht. Privatheit zu schützen heißt, die Privatsphäre zu wahren, Anonymität als Privatheit im öffentlichen Raum zu ermöglichen, sowie das Recht auf informationelle Selbstbestimmung und die Integrität der Persönlichkeit. Dabei ist klar, dass diese ethischen Werte zwar gleichwertig nebeneinanderstehen, im Umsetzungskontext aber durchaus Gewichtungen oder Abschwächungen vorgenommen werden müssen, weil sich nicht jeder Aspekt gleichwertig umsetzen lässt. Auch hier ist die Corona-Pandemie ein Beispielgeber, wenn ein Impfstoff zunächst jenen zur Verfügung gestellt wird, die einer Risikogruppe angehören oder in systemrelevanten Bereichen wie dem Gesundheitssystem tätig sind. Gerechtigkeit wird dann begründetermaßen zunächst nicht allen zuteil. Stets muss aber ein adäquater Ausgleich zwischen Partikular- und Kollektivinteressen angestrebt werden (Abb. 2; Heesen et al. 2020).



Abb. 2 Ethische Wertsetzungen im Kontext von künstlicher Intelligenz (Plattform Lernende Systeme 2020)

Beim Einsatz von KI kommt es in besonderer Weise aus ethischer Perspektive darauf an, dass Mensch und Umwelt nicht geschädigt werden oder (größerer) Nutzen und (geringer) Schaden auf substanzielle Weise gegeneinander abgewogen werden (Jobin et al. 2019, S. 389). Auch müssen KI-basierte Systeme rechtskonform sein und die erforderliche technische Robustheit sicherstellen, dass sie zu keiner Zeit ein untragbares Sicherheitsrisiko darstellen (OECD 2019).

5.1 Selbstbestimmung im Anwendungskontext

Am Beispiel der Selbstbestimmung soll verdeutlicht werden, wie ethische Werte im Entwicklungs- und Anwendungskontext berücksichtigt werden können. KI-Systeme sind in der Lage, den Menschen bei der Entscheidungsfindung etwa im medizinischen Anwendungsfall zu unterstützen und zu entlasten. Das führt zu einem höheren Maß an Selbstbestimmung. Allerdings können automatisierte Entscheidungen, die über Menschen getroffen werden, auch eine Einschränkung der Selbstbestimmung bedeuten, gerade wenn unklar bleibt, auf welche Weise und mit welcher Begründung Entscheidungen getroffen werden (Blackbox). Der KI-Einsatz sollte daher die Stärkung menschlicher Selbstbestimmungsinteressen fördern und sie keinesfalls schwächen (Heesen et al. 2020; Kagermann und Winter 2018).

Bereits in naher Zukunft kommen KI-basierte Assistenzsysteme zur ärztlichen Unterstützung bei der Diagnose und Behandlung etwa von Krebserkrankungen zum Einsatz. KI-Systeme sichern dann Diagnosen ab, schlagen Behandlungen vor und assistieren bei Operationen (Plattform Lernende Systeme 2019). Ärztinnen und Ärzte, Pflegekräfte und Patienten müssen sich dabei darauf verlassen können, dass die Technologie den Menschen unterstützt und die letztlich entscheidende Auswahl und Bewertung vom Menschen vorgenommen wird.

5.2 Ethische Leitlinien in der Wirtschaft

Ethische Aspekte im Geschäftskontext und in der Technologieentwicklung zu berücksichtigen, ist für viele Unternehmen bereits Realität. Einzelne von ihnen haben eigene Ethical Guidelines oder Principles aufgestellt, die im Weiteren exemplarisch herangezogen werden. Dabei geht es darum, die Einhaltung ethischer Werte im Entwicklungs- und Anwendungskontext von KI bestmöglich zu gewährleisten und zugleich Ziele im Bereich der CSR im Blick zu behalten. Die Deutsche Telekom etwa definiert in ihren ethischen Leitlinien, dass der Mensch immer in der Verantwortung bleibt und eindeutig definiert ist, wer für welches KI-System verantwortlich ist (Deutsche Telekom 2020). Weiter wird es Kunden transparent gemacht, wenn sie mit einem KI-System kommunizieren und wie ihre Kundendaten automatisiert verarbeitet und gespeichert werden. Es geht hier um Vertrauenswürdigkeit als eine Grundvoraussetzung für die

Akzeptanz technischer Lösungen. SAP hingegen hat sieben Grundsätze definiert, darunter der Anspruch, Unternehmen ein vorurteilsfreies Handeln zu ermöglichen, etwa Diskriminierungen und Ungleichbehandlungen zu vermeiden (SAP 2020). Dafür ist die Datenqualität entscheidend, legt sie doch die Basis dafür, wie KI und maschinelles Lernen trainiert werden und wie vertrauenswürdig KI-basierte Produkte und Dienstleistungen letztlich sind (Winter 2020b, S. 110ff.).

5.3 Rechtliche Rahmenbedingungen und ethische Aspekte im Fokus

Mit der Einführung neuer Technologien gehen neue Herausforderungen und entsprechende Regelungsbedarfe einher, für die ein einheitlicher Rechtsrahmen ausgearbeitet oder bestehendes Recht angepasst werden muss. Dazu zählen Fragen des Datenschutzes, der Haftung, des Arbeits- und Verbraucherrechts sowie des geistigen Eigentums. All dies kann jedoch mit Blick auf die Wettbewerbsposition Deutschlands nur sinnvoll beantwortet werden, wenn seine Einbettung in den internationalen Kontext angemessen berücksichtigt ist. In der öffentlichen Diskussion werden neben dem Datenschutz und dem Schutz der Privatsphäre insbesondere die IT-Sicherheit, die Rechtssicherheit und eben ethische Aspekte als wesentliche Herausforderungen genannt.

Beispiel Haftung: Mit KI angetriebene autonome Systeme sind hochgradig anpassungsfähig, reagieren auf Veränderungen in ihrer Umgebung und auf unvorhergesehene Ereignisse. Aber ihre nächste Aktion ist deshalb nicht vorhersehbar und es fehlt in der Regel an einer Erklärungskomponente. Daher kann die Funktion oder Fehlfunktion des Systems unter Umständen nicht auf ein bestimmtes menschliches Handeln zurückgeführt werden. Eine solche Blackbox stellt im Schadensfall ein erhebliches Problem dar, da die Haftungsfrage mitunter ungeklärt bleibt. Insbesondere bei neueren Methoden wie dem Maschinellen Lernen mit künstlichen neuronalen Netzen (Deep Learning) gibt es noch kein von Menschen geschriebenes Softwareprogramm, das eine vollständige Erklärbarkeit ermöglicht. Allerdings arbeiten Unternehmen verstärkt an Lösungen zur Nachvollziehbarkeit von KI-basierten Lernergebnissen. So stellt sich mit der Einführung hochautomatisierter und autonomer Systeme im Straßenverkehr die Frage, wer Rechenschaft über die Entscheidungen des autonomen Fahrzeugs abzulegen und die möglichen rechtlichen Konsequenzen zu tragen hat. Das deutsche Haftpflichtsystem weist das Risiko für einen Unfall im Straßenverkehr heute in letzter Instanz dem Halter des Fahrzeugs zu. Zusätzlich haften die Hersteller im Rahmen der gesetzlichen Produkthaftung. Vollautomatisierte und fahrerlose Fahrzeuge unterliegen aber auch weitergehenden Einflussfaktoren. Daher müssen neben den Haltern und Herstellern des Fahrzeugs die entsprechenden Hersteller und Betreiber der Unterstützungstechniken des Fahrzeugs in das System der Haftungsteilung einbezogen werden (BMVi 2017).

Übernehmen autonome Systeme wie ein fahrerloser Rufbus künftig Entscheidungen, die gesellschaftliche oder ethische Dimensionen aufweisen, dann werden auch die zuvor

an die Menschen gestellten gesellschaftlichen und ethischen Anforderungen auf diese Systeme übertragen: Wie hat sich ein autonomes Fahrzeug in einer kritischen Gefahrensituation zu verhalten, etwa wenn ein Kind plötzlich auf die Straße springt? Autonome Systeme sind nicht von sich aus in der Lage, moralische Entscheidungen zu treffen bzw. ihre Entscheidungen nach moralischen Maßstäben zu beurteilen. Sie verfügen auch nicht über ein Bewusstsein, wie es dem Menschen innewohnt. Die ethischen Anforderungen richten sich deshalb viel mehr auf den Prozess der Programmierung, der einem werte-basierten Design folgen soll und in dem bestimmte, auch grundgesetzlich verankerte Werte, wie etwa die Integrität von Leib und Leben (Art. 2, Abs. 2 GG) oder auch der allgemeine und spezielle Gleichheitsgrundsatz (Art. 3 GG), in den Wissensbasen oder dem Trainingsprozess der lernenden Systeme abgebildet werden. So muss beispielsweise sichergestellt werden, dass KI, die beispielsweise über eine Kreditvergabe oder einen Vertragsabschluss entscheidet, nicht nach ethnischer Zugehörigkeit oder sexueller Orientierung diskriminiert.

6 Ausblick: Der Mensch im Mittelpunkt

Eine gesellschaftsübergreifende Herausforderung wird sein, die Vorteile von KI in unserer Arbeits- und Lebenswelt zu nutzen, ohne dass sich Antiutopien von gläsernen Patienten, Nutzerinnen, Mitarbeitern oder Bürgerinnen einstellen. Mit der fortschreitenden Entwicklung und Vernetzung digitaler Systeme werden derartige Fragen wiederkehrend gestellt. Sie erfordern eine kontinuierliche Analyse, unaufgeregte Diskussionen und neue Übereinkünfte. Nur so wird es gelingen, das notwendige Grundvertrauen in die Beherrschbarkeit neuer Technologien aufzubauen. KI beinhaltet erhebliche Nutzenpotenziale, aber auch Rationalisierungspotenziale, was zu strukturellen Veränderungen bei Beschäftigung führen kann. Umso wichtiger ist es, den öffentlichen Dialog über die Gestaltung wichtiger Zukunftsfelder in Wirtschaft und Gesellschaft breit zu führen.

Ein Beispiel ist die Arbeitswelt: Digitalisierung führt zur Generierung von Big Data, in denen auch ein Großteil der Arbeits- und Qualifizierungsprozesse erfasst wird. Sie können und sollten zur Optimierung der Prozesse, zur Effizienzsteigerung, zur Innovationsbeschleunigung und nicht zuletzt zur Verbesserung der Arbeitsbedingungen genutzt werden. Der Gefahr einer steigenden Überwachung des Mitarbeiters sollte hingegen frühzeitig mit wirksamen Regelwerken und Kontrollen entgegengewirkt werden. Denn mit KI haben wir die große Chance, Arbeit humaner, abwechslungsreicher und eigenverantwortlicher zu machen. Darauf lässt sich bauen.

Literatur

- Bundesregierung der Bundesrepublik Deutschland (2018) Strategie Künstliche Intelligenz der Bundesregierung. https://www.bmbf.de/files/Nationale_KI-Strategie.pdf. Zugegriffen: 26. Nov. 2020
- Bundesministerium für Verkehr und digitale Infrastruktur (2017) Bericht der Ethik-Kommission. Automatisiertes und vernetztes Fahren. <https://www.bmvi.de/SharedDocs/DE/Publikationen/DG/bericht-der-ethik-kommission.html>. Zugegriffen: 26. Nov. 2020
- Datenethikkommission der Bundesregierung (2019) Gutachten der Datenethikkommission. Bundesministerium des Innern, für Bau und Heimat, Berlin
- Daugherty P, Wilson PHJ (2018) Human + machine: reimagining work in the age of AI. Harvard Business Review Press, Massachusetts, Cambridge
- Deutsche Telekom AG (2020) Leitlinien für Künstliche Intelligenz. <https://www.telekom.com/de/konzern/digitale-verantwortung/details/ki-leitlinien-der-telekom-523904>. Zugegriffen: 26. Nov. 2020.
- DIN – Deutsches Institut für Normung e. V./DKE – Deutsche Kommission Elektrotechnik Elektronik Informationstechnik (2020) Normungsroadmap zur Künstlichen Intelligenz. DIN e.V./DKE, Berlin.
- European Commission (2019) The EC's High Level Expert Group on Artificial Intelligence (AI HLEG) (04/2019): Ethics Guidelines for Trustworthy AI. <https://ec.europa.eu/futurium/en/ai-alliance-consultation>. Zugegriffen: 25. Nov. 2020
- European Commission (2020) Weissbuch zur Künstlichen Intelligenz – ein europäisches Konzept für Exzellenz und Vertrauen. European Commission, Brüssel.
- European Commission (2021): Proposal for a regulation laying down harmonized rules on artificial intelligence (AI Act) (04/2021). https://eur-lex.europa.eu/resource.html?uri=cellar:e0649735-a372-11eb-9585-01aa75ed71a1.0001.02/DOC_1&format=PDF. Zugegriffen: 13. Jun. 2021
- Glaeser J, Laudel G (2004) Experteninterviews und qualitative Inhaltsanalyse. VS Publishers, Wiesbaden
- Hagendorff T (2020) The Ethics of AI ethics: an evaluation of guidelines. Minds & Machines 30, 99–120. <https://doi.org/10.1007/s11023-020-09517-8>. Zugegriffen: 25. Nov. 2020
- Heesen J et al (Hrsg) (2020) Ethik-Briefing. Leitfaden für eine verantwortungsvolle Entwicklung und Anwendung von KI-Systemen – Whitepaper aus der Plattform Lernende Systeme. Plattform Lernende Systeme, München
- IDC Corporate (2020) IDC Manufacturing Insights: Worldwide Robotics: Industrial Robots. IDC Press, Framingham, MA (USA)
- Jobin A et al (2019) Artificial intelligence. The global landscape of ethics guidelines. Nat Mach Intel 7(2019):389–439
- Kagermann H, Winter J (2017) Industrie 4.0 und plattformbasierte Geschäftsmodellinnovationen. In: Lucks K (Hrsg) Praxishandbuch Industrie 4.0. Schäffer-Poeschel Verlag, Stuttgart.
- Kagermann H, Winter J (2018) The second wave of digitalisation. Germany's chance. In: Mair, S., Messner D, Meyer L (Hrsg) Germany and the world 2030. what will change. How we must act. Econ, Berlin. <https://deutschland-und-die-welt-2030.de/en/article/the-second-wave-of-digitalisation-germanys-chance/>. Zugegriffen: 25. Nov. 2020
- OECD – Organisation for Economic Co-operation and Development (2019) Empfehlung des Rats zu Künstlicher Intelligenz. <https://www.oecd.org/berlin/presse/Empfehlung-des-Rats-zu-kuenstlicher-Intelligenz.pdf>. Zugegriffen: 25. Nov. 2020
- Plattform Lernende Systeme (2019) Prävention, Diagnose, Therapie. Lernende Systeme im Gesundheitswesen. Bericht der Arbeitsgruppe Gesundheit, Medizintechnik, Pflege, München. https://www.plattform-lernende-systeme.de/files/Downloads/Publikationen/AG6_Bericht_23062019.pdf. Zugegriffen: 25. Nov. 2020

- SAP SE (2020) Guiding principles for artificial intelligence (AI). <https://www.sap.com/products/artificial-intelligence/ai-ethics.html.html>. Zugegriffen: 25. Nov. 2020
- Wahlster W (2016) 60 Jahre KI: „Menschliche Intelligenz ist der künstlichen noch weit überlegen“. <https://www.wired.de/collection/tech/60-jahre-ki-die-menschliche-intelligenz-ist-der-kuenstlichen-noch-weit-ueberlegen>. Zugegriffen: 25. Nov. 2020
- Winter J (2018) Künstliche Intelligenz und datenbasierte Geschäftsmodellinnovationen – Warum Unternehmen jetzt handeln sollten. In: Bruhn M, Hadwich K (Hrsg) Service Business Development. Springer Gabler, Wiesbaden, S 61–79
- Winter J (2020a) The evolutionary and disruptive potential of Industrie 4.0. Hung Geog Bull 69(2):83–97
- Winter J. (2020b) Dienstleistungsinnovationen im digitalen Zeitalter – Was sie bremst, was zu tun ist. In: Bruhn M, Hadwich K (Hrsg) Automatisierung und Personalisierung von Dienstleistungen. Forum Dienstleistungsmanagement. Springer Gabler, Wiesbaden, S 105–118

Dr. Johannes Winter ist Leiter der Geschäftsstelle Lernende Systeme – Die Plattform für Künstliche Intelligenz. Die Plattform unter Vorsitz der Bundesforschungsministerin und des Präsidenten der acatech bringt 200 führende Experten und Vordenkerinnen für künstliche Intelligenz (KI) aus Wirtschaft, Wissenschaft und Gesellschaft zusammen und begleitet Deutschlands Weg bei der Einführung und Gestaltung von KI. Zudem leitet Johannes Winter den Technologiebereich bei acatech (Deutsche Akademie der Technikwissenschaften) und verantwortet dort die Themenbereiche Industrie 4.0, Plattformökonomie und KI. Zuvor hat er die Wirtschafts- und Wissenschaftsbeziehungen bei acatech geleitet und war persönlicher Referent des langjährigen Präsidenten und ehemaligen CEO der SAP SE Prof. Henning Kagermann. Dr. Winter hat an der Universität zu Köln zum Thema Industrial Upgrading in der Automobilindustrie promoviert, war als Visiting PhD bei Volkswagen Poznan und hat einen Lehrauftrag an der Hochschule für Ökonomie und Management in München.



Environment-Social-Governance-Fingerprint – wie der Einsatz von Big Data und künstlicher Intelligenz Investoren, Unternehmen und Stakeholder unterstützen kann

Pajam Hassan und Frank Passing

1 Status quo

Bis heute haben mehr als 3000 Organisationen mit einem Anlagevolumen von knapp 100 Billionen US-Dollar die Prinzipien für verantwortungsvolles Investment unterschrieben.¹ Die grundlegenden Prinzipien besagen, dass die Beachtung von Environment, Social und Governance (ESG) unerlässlich ist für nachhaltiges Investieren. Um diese Paradigmen in das Handeln von Investmentbanken, Unternehmen und Stakeholdern zu übersetzen, wurden in den vergangenen Jahren Prozesse, Werkzeuge und Verfahren entwickelt, um die Nachhaltigkeit im Sinn von ESG in Banken und Unternehmen managen zu können. Nachhaltigkeit hat das strategische Ziel der Erreichung der Sustainable Development Goals (SDG) im Jahr 2030.

Organisationen verpflichten sich ihren interne und externe Stakeholder gegenüber zur Berücksichtigung der ökologischen und sozialen Auswirkungen ihrer Operationen. Als Reaktion auf diesen Druck haben viele Unternehmen eine Vielzahl von Nachhaltigkeitsinitiativen initiiert und umgesetzt. Einzelheiten zu diesen Initiativen werden zunehmend öffentlich in Nachhaltigkeitsberichten von Unternehmen oder gleichwertigen Berichten

¹ <https://www.unpri.org/pri/about-the-pri>

P. Hassan · F. Passing (✉)
intuitive.ai GmbH, Hamburg, Deutschland
E-Mail: frank@intuitive-ai.de

P. Hassan
E-Mail: pajam@intuitive-ai.de

bekannt gemacht. Allerdings haben die Stakeholder oft Schwierigkeiten, den Sinn der berichteten Informationen zu interpretieren. Um Unternehmen mit vorbildlicher Nachhaltigkeit hervorzuheben, sind eine Reihe von Ratings, Auszeichnungen und Indizes entstanden. Primär werden hierzu Unternehmensberichte und Webseiten der jeweiligen Unternehmen und Industrieberichte herangezogen, die nach strukturierten Indikatoren bewertet werden. Die erhobenen Indikatoren werden hierbei zu ESG-Ratings übersetzt und häufig jährlich überarbeitet. Standardisierte ESG-Kriterien, nach denen ein Unternehmen bewertet wird, gibt es bis dato nicht.²

In den letzten Jahren sind durch die Digitalisierung viele neue, sog. alternative Daten entwickelt und erhoben worden, die zu weiteren Erkenntnissen zur Bewertung von ESG in Unternehmen führen. Insbesondere die Messung von ESG-Kontroversen in alternativen Daten wie Nachrichten, Blogs, Foren und weiteren Social-Media-Kanälen erweist sich als ein praktisches Werkzeug für Investitionsentscheidungen sowie strategische Entscheidungen in Unternehmen. Neben den traditionellen Wissensbrokern und Ratingagenturen³ entwickeln auch Start-ups⁴ neue technologische Möglichkeiten⁵, um die Vielzahl an verfügbaren Daten nutzbar zu machen. Dabei etablieren sich insbesondere zwei Anwendungsdomänen. Während die eine Domäne den Fokus auf nachhaltiges Investment hat, sind andere Anbieter auf Nachhaltigkeit in der Lieferkette fokussiert. Gemeinsam haben sie jedoch, dass sie ihren Fokus auf ein Key-Performance-Indicator(KPI)-System legen, dessen Limitationen noch unzureichend evaluiert sind. So erklären Escrig-Olmedo et al. (2010), dass eine Vielzahl von ESG-Rating- und -Informationsanbietern die steigende Nachfrage nach ESG-relevanten Information bedient, gleichwohl aber die verwendeten Evaluationskriterien im Zusammenhang mit dem Risikomanagement unvollständig erläutert werden.⁶ Ebenso mangelt es den Methoden an der prozessphasenübergreifenden Anwendbarkeit im Risikomanagement. Hieraus ist zu schlussfolgern, dass die Gestaltung von Informationssystemen nicht hinreichend betrachtet wird. Ferner existiert keine Typologie um ESG-Objekte – im Sinn von Information System Research – zu charakterisieren und zu klassifizieren. Darüber hinaus bieten KI-basierte Informationssysteme für ESG-Risikomanagementverfahren weitere Potenziale im operativen Risikomanagementprozess.

²Escrig-Olmedo, E.; Fernandez-Izquierdo, M.A.; Ferrero-Ferrero, I.; Rivera-Lirio, J.M.; Muñoz-Torres, M.J. Rating the raters: Evaluating how ESG rating agencies integrate sustainability principles. *Sustainability* 2019, 11, 915.

³Beispielsweise Refinitiv, MSCI, S&P, Morningstar.

⁴Beispielsweise Arabesque, Sustainalytics, intuitive.AI, EcoVadis.

⁵Nach eigenen Angaben oftmals KI.

⁶Escrig-Olmedo, E., Muñoz-Torres, M.J. and Fernández-Izquierdo, M.Á. (2010) Socially responsible investing: sustainability indices, ESG rating and information provider agencies, *Int. J. Sustainable Economy*, Vol. 2, No. 4, pp.442–461.



Abb. 1 Sustainable Development Goals der Vereinten Nationen

Hier setzt die vorliegende Arbeit an und untersucht bestehende Ansätze für ein geeignetes ESG-Risikomanagement-Framework im Kontext von Information System Research. Ferner wird eine Taxonomie entwickelt, die ESG-bezogene Chancen und Risiken charakterisiert und klassifizierbar macht. Der Entwurf eines ESG-Fingerprint dient als Ordnungsrahmen für den Entwurf eines ESG-Risikoinformationssystems.

2 Einführung von Environment-Social-Governance-Risikomanagement- und -Informationssystemen

Im September 2015 haben sich die 195 Mitgliedsstaaten der Vereinten Nationen (UN) auf die Agenda 2030 zur nachhaltigen Entwicklung verständigt. Die wichtigsten Bestandteile der Agenda sind die 17 SDG (Abb. 1).

Die 17 übergreifenden Ziele setzen weltweit einheitliche Maßstäbe für Prioritäten und Ziele einer nachhaltigen Entwicklung bis 2030. Diese dienen Organisationen, Investoren und Unternehmen gleichermaßen, um messbare und investierbare Ziele im Bereich der Nachhaltigkeit zu haben. Gleichzeitig beinhalten diese in großem Maß die ESG-Kriterien.

Unter ESG wird die Berücksichtigung von Kriterien aus den Bereichen Umwelt (Environment), Soziales (Social) und verantwortungsvolle Unternehmensführung (Governance) verstanden. Diese Kriterien werden zur Bewertung von Unternehmen hinsichtlich ihrer Fortschritte im Bereich Nachhaltigkeit eingesetzt. In den letzten Jahren hat die Bedeutung von ESG-Kriterien in Investmententscheidungen sowie in nachhaltigen Beschaffungsprozessen deutlich zugenommen, nicht zuletzt durch den Aktionsplan der EU zur Finanzierung nachhaltigen Wachstums im Rahmen der Kapitalunion⁷. Deutlich wird dies ebenfalls anhand der Initiative UN PRI der Vereinten Nationen,

⁷ https://ec.europa.eu/info/sites/info/files/180131-sustainable-finance-final-report_en.pdf




Abb. 2 Risikomanagementprozess

die sechs Prinzipien für verantwortungsvolles Investment erstellt hat und umsetzen will⁸. Die Unterzeichner der UN PRI verwalten bis dato über 100 Billionen US-Dollar (Anlagen im Management) mit stark steigenden Zahlen⁹. Sie berücksichtigen bereits heute ESG in ihren Investmentprozessen. In einer Vielzahl von Studien wurde der Zusammenhang zwischen ESG-Kriterien, dem Erfolg eines Unternehmens bzw. seiner Wertentwicklung sowie einer möglichen Risikoreduzierung untersucht. Dies führte folglich zu Anpassungen und Erweiterung des Risikomanagements um ESG-Nachhaltigkeitskriterien insbesondere in Entscheidungsprozessen in den Bereichen Investment, Strategische Planung und Supply Chain.

Die Berücksichtigung von Risiken spielt für diejenigen Unternehmen und Investoren eine strategische Rolle, die zunehmend komplexen, schnellen Veränderungen ausgesetzt sind und Risiken oft nur schwer antizipiert können. Ein Risiko ist dabei zu verstehen als eine mögliche Abweichung von den geplanten Ergebnissen, die den Rückgang der Wertschöpfung zur Folge haben können.¹⁰ In der vorliegenden Arbeit werden potenzielle Risiken aus der Perspektive ohne unternehmensinterne Informationen berücksichtigt. Im Kontext dieser Arbeit wird deshalb mit der Begrifflichkeit *Kontroverse* deutlich gemacht,

⁸ <https://www.unpri.org>

⁹ <https://www.unpri.org/pri/about-the-pri>

¹⁰ D. Bogataj and M. Bogataj 2007. Measuring the supply chain risk and vulnerability in frequency space. International Journal Production Economics 108 (2007) 291–301.

dass es sich um ein Risiko handelt, es aber nicht zwangsläufig muss.¹¹ Genau hier unterstützt das Risikomanagement, das als ein Prozess der Identifikation, Bewertung, Steuerung und des Monitorings von negativen Ereignissen oder Situationen, die eine Organisation oder eine Gesellschaft als Ganzes erheblich beeinträchtigen können, zu verstehen ist (Abb. 2).

Das Ziel eines um Nachhaltigkeit erweiterten Risikomanagementmodells ist, eine Balance im nachhaltigen Wirtschaften aufrechtzuerhalten, das im Folgenden als ESG-Risikomanagement (ESGRM) bezeichnet wird. Die neu integrierten Risikotypen umfassen dabei eine große Bandbreite von Nachhaltigkeitsherausforderungen, wie unter anderem Klimawandel, Menschenrechte oder Arbeitsbedingungen. Insbesondere die Identifikation von Risiken in den diversen Nachhaltigkeitsrisikofeldern sind herausfordernd und zeitaufwendig. Denn häufig liegen die Risiken nicht als strukturierte Datenquelle vor, sondern müssen aus unterschiedlichen Daten wie Geschäftsberichten, Studien, Finanzdaten, Newsmeldungen oder Blog- und Forenbeiträgen erhoben werden.

Um Entscheidungsträgern in Organisationen die Flut der internen und externen Risikoinformationen nutzbar zu machen, bedarf es einer Verdichtung und Zusammenfassung. Die zur Verfügung gestellten Informationen sollen hierbei relevant, qualitativ hochwertig, aktuell und aussagefähig sein. Die Basis hierfür liefert das Konzept der Informationssysteme. Sie werden als Systeme verstanden, die Informationen verarbeiten, d. h. erfassen, anreichern, transformieren, speichern und bereitstellen. Betriebliche Informationssysteme werden dabei als soziotechnische Systeme verstanden, die menschliche und maschinelle Komponenten als Aufgabenträger umfassen¹². Insbesondere in modernen Informationssystemen werden durch KI weitere Aufgabenumfänge durch die Maschine gelöst. KI wird im erweiterten Sinn als eine vom Computer durchgeführte Aufgabe auf menschlichem Niveau verstanden.

Mit Bezug zum ESG-Risikomanagement existieren bereits eine Vielzahl unterschiedlicher Daten- und Ratingprodukte¹³ sowie Softwarelösungen. Jedoch, selbst wenn diese eine gleiche Funktionalitäten abbilden sollen, besitzen die Messungen unterschiedliche, strukturelle Logiken und nicht einheitliche Berechnungsvorschriften.¹⁴ Im Gegenteil: Ihre zugrunde liegenden Logiken werden durch Kommerzialisierungsbestrebungen und den

¹¹ Es wird dem Fall entgegengewirkt, dass beispielsweise bei einem Bericht über schlechte Arbeitsbedingungen in der n-Tier-Lieferkette eines Unternehmens herausgearbeitet werden muss, ob der n-Tier-Lieferant tatsächlicher Lieferant des risikobehafteten Unternehmens ist.

¹² <https://www.wirtschaftslexikon24.com/d/informationssystem/informationssystem.htm>

¹³ Hill, J. Environmental, social, and governance (ESG) Investing. In A Balanced Analysis of the Theory and Practice of a Sustainable Portfolio; Academic Press: Kidlington, UK, 2020.

¹⁴ Chatterji, A.K.; Durand, R.; Levine, D.I.; Touboul, S. Do ratings of firms converge? Implications for managers, investors and strategy researchers. *Strateg. Manage. J.* 2016, 37, 1597–1614.

damit einhergehenden Kundenanforderungen fortlaufend erweitert und angepasst,¹⁵ mit der Folge, dass die Heterogenität der Systemlandschaft und die domainspezifische Informationskomplexität zunehmend steigen. Das führt zu einer geringen Anwendbarkeit im Rahmen von ESGRM-Prozessen und einer geringen Eignung für ein prozessphasenübergreifendes Risikomanagement, wodurch einem Quasistandard, der das Erreichen der SDG unterstützt, entgegengewirkt wird. Wissenschaft und Industrie fokussieren auf die Erforschung respektive Vermarktung von funktionalen Eigenschaften ihrer Datenprodukte, statt auf das Gestalten eines soziotechnischen Systems zum Managen von operativen sowie strategischen Chancen und Risiken. Hieran lehnt sich die forschungsleitende Fragestellung an: Wie sieht eine Typologie aus, die es ermöglicht, relevante ESG-Risiken zu klassifizieren?

3 Konzept zur Entwicklung einer Taxonomie zur Klassifizierung von Environment-Social-Governance-relevanten Chancen und Risiken

Zur Beantwortung von Fragestellungen zu zeitgenössischen Problemstellungen werden häufig qualitative Untersuchungen, wie beispielsweise Expertenbefragungen, genutzt, um Eigenschaften und Anforderungen zu explorieren^{16, 17}, da aber bereits diverse Datenprodukte existieren, es jedoch an einer passenden Typologie mangelt, um diese zu charakterisieren, wird in der hier vorliegenden Untersuchung ein anderes Verfahren gewählt. Im Kontext von Information System Research eignen sich Taxonomien, um relevante Objekte nach einem strukturierten Vorgehen entsprechend ihrer Beziehungen und charakteristischen Eigenschaften zu klassifizieren.¹⁸ Um ESGRM als ein zeitgenössisches Phänomen in seinem realweltlichen Kontext zu betrachten, eignet sich ein fallstudienbasierter Ansatz.¹⁹ Dieser erlaubt es, Erkenntnisse zu verallgemeinern und ein tiefes Verständnis zu entwickeln. Dazu teilt sich die Untersuchung in zwei Phasen auf. In Phase 1 werden ESG-Kontroversen betrachtet, verglichen und analysiert. In der zweiten Phase wird auf Basis der Erkenntnisse aus der Fallstudie eine Taxonomie entwickelt und diese anschließend, im Zuge von drei Iterationen, empirisch und theoretisch entwickelt und evaluiert.

Die Abb. 3 zeigt die Teilschritte. Das Vorgehen erlaubt es, konzeptionelle (k) und empirische (e) Erkenntnissen zu kombinieren. Das Vorgehen orientierte sich an dem von

¹⁵ Lozano, R. (2015). A holistic perspective on corporate sustainability drivers. *Corporate Social Responsibility and Environmental Management*, 22(1), 32–44.

¹⁶ Beispielsweise Coqueret, G. (2020). ESG Equity Investing: A Short Survey.

¹⁷ Beispielsweise Zaccane, M. C.; Pedrini, M. (2020). ESG Factor Integration into Private Equity.

¹⁸ Nickerson, R.C., Varshney, U., Muntermann, J., 2013. A method for taxonomy development and its application in information systems. *Eur. J. Inf. Syst.* 22 (3), 336–359.

¹⁹ Yin, R.K., 2014. *Case Study Research: Design and Methods*, 5 ed. Sage publications, Thousand Oaks, CA.

Vorgehensmodell	
1. Bestimmung von Meta-Merkmalen	
2. Bestimmung von Abbruchskriterien	
3e. Von der Empirie zum Konzept	3k. Vom Konzept bis zur Empirie
4e. Identifikation von (neuen) Objekt-Untermengen	4k. Konzeption (neuer) Objekt-Merkmale und -Dimensionen
5e. Identifizierung von gemeinsamen Eigenschaften sowie Objektgruppen	5k. Objekte auf die oben genannten Merkmale und Dimensionen analysieren.
6e. Gruppierung Eigenschaften zu Dimensionen, um eine (überarbeitete) Taxonomie zu erstellen	6k. Erstellung der (überarbeiteten) Taxonomie
7. Solange Abbruchskriterien nicht erfüllt, Wiederholung von Schritt 3.	

Abb. 3 Vorgehensmodell zur systematischen Entwicklung einer Taxonomie

Nickerson et al. (2013) entwickelten Vorgehensmodell zur Gestaltung und Evaluierung von Taxonomien im Bereich Information System Research²⁰.

Aufbau der Fallbasis (empirische Datenbasis)

Zum Aufbau der ESG Fallbasis werden wissenschaftliche Datenquellen²¹ sowie Praxisberichte²² genutzt. Die zugrunde gelegten Auswahlkriterien sind:

- Zu dem ESG-Fall müssen freizugängliche Informationen vorliegen.
- Zu dem ESG-Fall müssen ausreichend Informationen mit Bezug zu ESGRM vorhanden sein.
- Bei lückenhaft dokumentierten ESG-Fällen sind Merkmale vorhanden, die im Sinn der Datentriangulation erlauben, über eine Hintergrundrecherche den Kontext des Falls zu rekonstruieren.

Die mehrsprachige Fallbasis umfasst 48.334 Datensätze²³ mit Bezug zu weltweiten ESG-Kontroversen. Die ESG-Kontroversen sind als Rohdaten abgelegt und vollständig in einer Business-Intelligence-Infrastruktur verfügbar. Für die Taxonomieentwicklung werden aus der Fallbasis 33 Fallbeispiele ausgewählt, die, falls notwendig durch manuelle

²⁰Nickerson, R.C., Varshney, U., Muntermann, J., 2013. A method for taxonomy development and its application in information systems. Eur. J. Inf. Syst. 22 (3), 336–359.

²¹Datenbanken: unter anderem ScienceDirect, IEEE Explore und das Web of Science, Google Search.

²²Praxisberichte: unter anderem MSCI, EcoVadis, Arabesque, intuitive.AI, McKinsey, BCG, Accenture, KPMG.

²³Source: intuitive.AI GmbH.

Recherchen²⁴ angereichert werden. Alle Fallbeispiele weisen nach der Datentriangulation sowohl Bezug zu ESG als auch zum Risikomanagement auf.

Analyse und Auswertung

- Schritt 1: Im ersten Schritt werden Metaeigenschaften identifiziert. Dabei ist die zugrunde liegende Prämisse, dass die Merkmale eine hohen Unterscheidbarkeit aufweisen. Es wird zunächst zwischen *risikospezifischen* und *datenspezifischen* Metadimensionen unterschieden. Dabei gilt, dass alle Dimensionen und Merkmale der Taxonomie sich den Metadimensionen zuordnen lassen müssen. So kann sichergestellt werden, dass die Taxonomie auf relevante fokussiert ist.²⁵ Bei der Anwendung der Taxonomie erfolgt im Rahmen der zweiten Iteration die Erweiterung der *datenspezifischen* Metadimension um die *datenquellenspezifische Dimension*.
- Schritt 2: Im zweiten Schritt werden zwei objektive und fünf subjektive Abbruchkriterien definiert. Die Abb. 4 stellt die Abbruchkriterien dar, ordnet sie einer Kategorie zu und gibt entweder eine Erklärung oder eine Fragestellung an, die das Abbruchkriterium detailliert.

Iteration 1 – Konzeptionelle Entwicklung (vom Konzept zur Empirie)

In der ersten Iteration erfolgen die Schritte 3k bis 6k (Abb. 5). Es werden konzeptionell-empirische Dimensionen und Charakteristika aus ESGRM-Literatur und -Praxisberichten abgeleitet. Teilerkenntnisse aus dieser Phase werden aus Kap. „[Digital Governance als CSR Kompass für KI](#)“ aufgegriffen und dargestellt.

- **Input:** ESG- und CSR-Literatur sowie Praxisberichte
- **Output:** Initiale Taxonomie

Iteration 2 – Empirische Entwicklung (von der Empirie zum Konzept)

In der zweiten Iteration erfolgt empirisch-konzeptionell die Erweiterung der initialen Taxonomie. Dafür wird sie auf 30 zufällig ausgewählte Fallbeispiele angewendet und eine qualitativ strukturierte Datenanalyse durchgeführt.²⁶ Die empirische Ableitung

²⁴ Datentriangulation durch unter anderem Newsartikel, Stellungnahmen und Pressemitteilungen, statistische Daten, Webseiten von Firmen oder NGO, Reports von Rating-Agenturen.

²⁵ Remané, G., Nickerson, R.C., Hanelt, A., Tesch, J.F., Kolbe, L.M., 2016. A taxonomy of car-sharing business models. In: Paper Presented at the Thirty Seventh International Conference on Information Systems (ICIS), Dublin, Ireland.

²⁶ Miles, M.B., Huberman, A.M., Saldana, J., 2013. Qualitative Data Analysis: A Methods Sourcebook, vol. 3. Sage Publications, Los Angeles.

Art des Abbruchkriteriums	Abbruchkriterium	Erklärung / Fragestellung
Subjektiv	Präzise	Führt die Anzahl der Dimensionen zur Überladung?
Objektiv	Präzise	In der letzten Iteration wurden kein Objekt mit einem ähnlichen Objekt zusammengeführt oder in mehrere Objekte aufgeteilt.
Subjektiv	Stabilität	Sehen die Dimensionen und Merkmale eine ausreichende Differenzierung zwischen den Objekten vor? Was kann anhand der Merkmale über die Objekte ausgedrückt werden?
Subjektiv	Ganzheitlichkeit	Können alle Objekte bzw. eine (zufällige) Stichprobe von Objekten innerhalb des domainspezifischen Bereichs klassifiziert werden?
Objektiv	Ganzheitlichkeit	Alle Objekte oder ein repräsentatives Set sind bearbeitet
Subjektiv	Erweiterbarkeit	Kann eine neue Dimension oder ein neues Merkmal einer bestehenden Dimension leicht hinzugefügt werden?
Subjektiv	Erklärbarkeit	Was erklären die Dimensionen und Merkmale eines Objekts?

Abb. 4 Auflistung der Abbruchkriterien (in Anlehnung an Nickerson et al. 2013)

Meta-Dimensionen	ESG-Risiko-Dimension	Fragestellung	Charakteristika					
Risikospezifisch	Typ	Was für ein Risikotyp liegt vor?	Environmental		Social		Governance	
	Beziehung	Auf was bezieht sich das Risiko eine Organisation oder eine Lokation?	Organisation			Standort		
	Referenz	Auf was referenziert das Risiko konkret?	Organisations-Gruppe	Organisations-standort	Geografischer Bereich	Geo-Koordinaten		
	Risiko-Management-Phase	In welche ECRM-Phase kann das Risiko eingeordnet werden?	Identifikation	Bewertung	Steuerung	Mointoring		
	Zuordnung	Lässt das Risiko sich einem Produkt oder einer Industrie zuordnen?	Produktklasse			Industrieklasse		
Datenspezifisch	Risiko-Bezug	Wie kann der Risiko-bezug hergestellt werden?	Implizit		Explizit		Standardisiert	
	Entität-Bezug	Wie kann der Bezug zu einer Organisation oder Lokation hergestellt werden?	Implizit		Explizit		Standardisiert	
	Zeitliche Projektion	Bezieht sich das Risiko auf ein Datum in der Zukunft, Gegenwart oder in der Vergangenheit?	Vergangenheit		Gegenwart		Zukunft	
	Vollständigkeit	Ist eine Datentriangulation notwendig, damit eine der ECRM Phasen getriggert werden kann?	Unvollständig			Vollständig		
	Datentyp	Um was für ein Datentyp handelt es sich?	Bild	Ton	Textuell	Nominal	Numerisch	
Quellenspezifisch	Daten-Geschwindigkeit	In welcher Frequenz werden Risiken aktualisiert?	Real-Time		Near-Real-Time		Batch	
	Datenzugangstyp	Auf welchem Medium finden befinden sich die Risikodaten?	Webseite		Web-Service		Daten-Feed	File-Transfer
	Zugänglichkeit	Bietet die Datenquelle freien Zugang zu ihren Risiken?	Offener Zugang			Restriktiver Zugang		
	Nutzungsrechte	Darf der Inhalt frei verwendet werden?	Uneingeschränkt			Eingeschränkt		
	Datenstruktur	Was für eine Struktur haben die Risikodaten, die die Informationsquelle anbietet?	Strukturiert		Semi-Strukturiert		Unstrukturiert	
	Datenformat	Handelt es sich um ein proprietäres Datenformat?	Proprietär			Nicht-Proprietär		

Abb. 5 Environment-Social-Governance-Risikotaxonomie

von Merkmalen erfolgt nach Yin (2014) bis die Abbruchkriterien erfüllt sind.²⁷ Dazu wird jedes Fallbeispiel mithilfe der Taxonomie klassifiziert und geprüft, ob neue Dimensionen oder Merkmale hinzugefügt werden müssen, um das jeweilige Fallbeispiel charakteristisch zu beschreiben. In dieser Iteration erfolgt zudem die weiterführende Differenzierung der Metadimensionen.

²⁷Yin, R.K., 2014. Case Study Research: Design and Methods, 5 ed. Sage publications, Thousand Oaks, CA.

- **Input:**
 - Initiale Taxonomie
 - 30 Fallbeispiele
- **Output:** Überarbeitete Taxonomie

Iteration 3 – Empirische Evaluation (von der Empirie zum Konzept)

Im Rahmen der empirisch-konzeptionellen Evaluation wird anhand von drei Fallbeispielen die Anwendbarkeit der Taxonomie demonstriert. Dabei werden nach fehlenden Informationen gesucht und durch eine Datentriangulation wird ein erweiterter Fallkontext hergestellt, der eine argumentativ-deduktive Analyse erlaubt.²⁸ In diesem Zuge wird als finale Dimension die Risikomanagementprozessphase übernommen. Die Ausprägung der Dimension leitet sich aus der Literatur ab.

- **Input:**
 - Überarbeitete Taxonomie
 - Drei Fallbeispiele
- **Output:** Evaluierter Taxonomie mit drei ESG-Fingerprints

Die evaluierte ESG-Taxonomie zeigt drei Metadimensionen mit insgesamt 15 ESG-Risikodimensionen. Alle Dimensionen werden durch eine übergeordnete Fragestellung weiter präzisiert. Die insgesamt 47 Merkmalsausprägungen erlauben 14.929.920 konsistente Kombinationen zur Charakterisierung von ESG-Risikoobjekten.

4 Anwendung des Konzepts zur Entwicklung eines Environment-Social-Governance-Fingerprint für künstliche-Intelligenz-basierte Informationssysteme

Anhand von ausgewählten Fallstudien wie Luft- und Wasserverschmutzung (E), Kinderarbeit (S) und Korruption (G) soll die Anwendbarkeit des ESG-Risiko-Fingerprint demonstriert werden. Auf Basis der ESG-Risikodatenbank werden drei Fallbeispiele aus dem Jahr 2019 verwendet. Im Folgenden werden die Fallbeispiele kurz erläutert:

Fallbeispiel 1: Luft- und Wasserverschmutzung (E)

Am 26.09.2019 berichtet die Neuer Züricher Zeitung über einen Brand in einer Chemiefabrik in der französischen Stadt Rouen. Trotz unklarer Ursache explodierten Teile der

²⁸Wilde, T., & Hess, T. (2006). Methodenspektrum der Wirtschaftsinformatik: Überblick und Portfoliobildung (No. 2/2006). Arbeitsbericht, Institut für Wirtschaftsinformatik und Neue Medien, Fakultät für Betriebswirtschaft, Ludwig-Maximilians-Universität.

Fabrikhalle der Firma Lubrizol, in der über 5200 t Chemikalien in Brand gesetzt worden sind und nach kurzer Zeit kilometerlange Rauchschwaden verursachte. Anwohner wurden innerhalb eines Radius von 500 m gebeten, zu Hause zu bleiben sowie Türen und Fenster geschlossen zu halten. Das Schadensausmaß durch Luft- und Wasserverschmutzung für die Einwohner, die Landwirtschaft und Flussregion Seine waren zum Zeitpunkt von großer Brisanz²⁹, jedoch in seinem Ausmaß verzögert bewertbar.

Fallbeispiel 2: Kinderarbeit in der Lieferkette (S)

Am 19.09.2019 wird im Rahmen des BBC-Berichts über Kinderarbeit in der Türkei zitiert. Trotz der Versuche der Unternehmen wie Ferrero, Lieferketten zu 100 % transparent zu machen, werden immer wieder Verstöße gegen Kinderarbeit öffentlich gemacht. In diesem Fall findet man in der Türkei eine komplexe und oft nur schwer durchdringbare Lieferkette. Der einzige Weg, die Lieferkette transparent zu machen ist es, den Weg direkt bis zur Plantage nachvollziehbar zu machen³⁰.

Fallbeispiel 3: Korruption (C)

Am 21.10.2019 wird im Handelsblatt erneut über den Korruptionsverdacht des Dax-Konzerns Fresenius Medical Care (FMC) in diversen afrikanischen Ländern berichtet. Trotz millionenschwerer Vergleiche in den USA ermittelte zu diesem Zeitpunkt nun auch die Frankfurter Staatsanwaltschaft. Grundlage der Untersuchung stellen zahlreiche Bestechungsvorfälle in den Jahren 2007–2016 dar. Insgesamt flossen mehrere Millionen an unterschiedliche Kliniken, Manager und Ärzte in zahlreichen Ländern³¹.

Anwendung der Taxonomie auf Fallbeispiele zur Entwicklung des Environment-Social-Governance-Fingerprint

Die Anwendung der Risikoinformationen aus den Fallbeispielen soll die allgemeine Anwendbarkeit der Taxonomie demonstrieren. Das Ziel ist, aus der Fallbasis Muster, sog. ESG-Fingerprints, zu extrahieren. Erste Ergebnisse werden in Form von ESG-Fingerprints in Abb. 6 dargestellt.

Die Fallstudie 1 besitzt den ESG-Risikotyp „Environmental“, da durch die Explosion Luft und Wasserverschmutzung verursacht worden sind. Ebenso lässt sich eine direkte Beziehung zu dem Unternehmen Lubrizol und die Referenz zum Standort in Rouen herstellen. Durch genannte Materialien kann auch die übergeordnete Industrieklasse zurückgeschlossen werden. Aufgrund explizit genannter Entitäten (hier: Lubrizol) und explizit genannter Risiken (hier: Luft- und Wasserverschmutzung) ist die Risikoinformation als

²⁹ <https://www.nzz.ch/panorama/grossbrand-in-chemiefabrik-in-nordfrankreich-schulen-geschlossen-ld.1511454>

³⁰ <https://www.20min.ch/story/stammen-die-nuesse-fuer-nutella-aus-kinderarbeit-731658317548>

³¹ <https://www.handelsblatt.com/unternehmen/industrie/medizintechnikhersteller-gegen-fmc-mitarbeiter-wird-auch-in-deutschland-wegen-korruption-ermittelt/25137374.html?ticket=ST-2717123-cgboxdPdIP6WrqGzRcKb-ap2>

ESG-Risiko-Dimension	Merkmal		
ESG-Risiko-Fall	Brand in Chemiefabrik	Kinderarbeit in der Lieferkette	Korruptionsverdacht in afrikanischen Ländern
Quelle (Link)	nzz.ch	20min.ch	handelsblatt.com
Typ	Environmental	Social	Governance
Beziehung	Organisation	Organisation	Organisation
Referenz	Organisationsstandort	Geografischer Bereich	Geografischer Bereich
Risikomanagement-Phase	Identifikation	Identifikation	Identifikation
Zuordnung	Industrieklasse	Produktklasse	Industrieklasse
Risiko-Bezug	Implizit	Implizit	Implizit
Entität-Bezug	Implizit	Implizit	Implizit
Zeitliche Projektion	Gegenwart	Vergangenheit	Zukunft
Vollständigkeit	Vollständig	Vollständig	Vollständig
Daten-Geschwindigkeit	Batch	Batch	Batch
Datenzugangstyp	Webseite	Webseite	Webseite
Zugänglichkeit	Offener Zugang	Offener Zugang	Offener Zugang
Nutzungsrechte	Eingeschränkt	Eingeschränkt	Eingeschränkt
Datenstruktur	Unstrukturiert	Unstrukturiert	Unstrukturiert
Datenformat	Nicht-Proprietär	Nicht-Proprietär	Nicht-Proprietär
Datentyp	Textuell	Textuell	Textuell

Abb. 6 Environment-Social-Governance(ESG)-Fingerprint zu ausgewählten ESG-Fallbeispielen

vollständig einzustufen. Der Zugang zur Risikoinformation erfolgt dabei batchweise über die Webseite eines öffentlich zugänglichen Newsanbieters. Die Daten liegen textueller Form vor und gelten somit als unstrukturiert. Die Risikoinformation ist aktuell in bezieht auf die gegenwärtige Risikosituation in Rouen.

Die Fallbeispiele 2 und 3 unterscheiden sich zum Fallbeispiel 1 nur geringfügig. So wird in den Fallbeispielen 2 und 3 kein genauer Standort, sondern ein geografischer Bereich angegeben. Im Vergleich zum Fallbeispiel 1 werden im Fallbeispiel 2 konkrete Produktklassen und Produkte wie Nutella genannt. Das Fallbeispiel 2 bezieht sich u. a. auf Risikomeldungen, die aus der Vergangenheit kommen, wohingegen im Fallbeispiel 3 der Verdacht der Korruption untersucht wird und folglich ein zukünftiges Risikoereignis darstellen kann.

Potenziale für den Einsatz von Big Data und Künstlicher Intelligenz

Die Evaluation der Taxonomie zeigt, wie Muster, sog. Fingerprints, innerhalb einer Menge von ESG-Risikoobjekten erkannt werden. Die drei erzeugten Fingerprints demonstrieren, dass ein möglicher Schwerpunkt innerhalb der Risikoidentifikationsphase im Bereich des maschinellen Lernens hohes Potenzial aufweist. Die Risikoinformationen sind unstrukturiert und beinhalten in Form von Text implizites Wissen für das ESGRM. Im Rahmen der Arbeit von Hassan (2019) *Enhancing Supply Chain Risk Management by Applying Machine Learning to Identify Risks* wird ein Framework eingeführt, das auf einen strukturell vergleichbaren Rahmen im Kontext von Supply




Abb. 7 Konzept einer auf künstlicher Intelligenz basierten Identifikation von Environment-Social-Governance(ESG)-Risiken mittels Support Vector Machine (SVM)

Chain Risk Management aufbaut.³² Das Framework ist wegen der hohen Ähnlichkeit des Fingerprint zu dem dort durchgeführten Experiment übertragbar und auf den vorliegenden Fall von ESG-Risiken anwendbar. Die Forschungsfrage, wie ein konzeptionelles Design eines Artefakts gestaltet sein muss, um Supply-Chain-Risiken in unstrukturierten Daten klassifizieren zu können, bildet die Basis. Das Modell wird auf den vorliegenden Fall adaptiert und auf theoretische Anwendbarkeit überprüft (Abb. 7).

Der ESG-Analyst oder -Manager ist hierbei der Experte für ESG-Risiken. Auf Basis der Erfahrung und Expertise klassifiziert er Newsmeldungen, entsprechend dem ESG-Fingerprint. Der annotierte Datensatz von ESG-Risikofallbeispielen wird in einem zweiten Schritt durch Inhalts- und Wortextraktionen verarbeitet und in eine Dokumentendatenbank geschrieben. Die

³²Hassan (2019). Enhancing Supply Chain Risk Management by Applying Machine Learning to Identify Risks. Business Information Systems, 191-205.

Datenbasis gilt als Grundlage für maschinelle Lernverfahren für die automatisierte Erkennung von ESG-Fingerprint-Informationen aus unstrukturierten Newsmeldungen.

Im Rahmen von praxisrelevanten Experimenten wies Hassan (2019) die Relevanz des Modells nach. Durch den Einsatz von Technologien wie Big Data und KI kann die Geschwindigkeit zur Identifikation von Supply-Chain-Risiken bei hoher Genauigkeit erhöht werden. Aufgrund der hohen strukturellen Ähnlichkeit von ESG und Supply-Chain-Risiken, wie im vorliegenden Fall, von Risikoinformationen in unstrukturierten Newsmeldungen sowie der hohen Ähnlichkeit der Taxonomien kann eine generelle Anwendbarkeit des Modells auf ESG-Risiken angenommen werden. Folglich lassen sich ESG-Risiken mithilfe von KI automatisiert identifizieren. Anwendungsbereiche für das Verfahren sind demnach ein teilautomatisiertes Risikomanagement, Unternehmens- und ESG-Due-Diligence-Prozesse sowie neuartige ESG-Rating-Verfahren.

5 Zusammenfassung und Ausblick

ESG weist großes Potenzial auf, um in Organisationen und Unternehmen mehr Nachhaltigkeit in die Entscheidungsprozesse zu integrieren und führt nachweislich zu einer höheren Kundenbindung und -neugewinnung, zu einer verbesserten Aussicht auf Kooperationen mit anderen Entitäten und hat positiven Einfluss auf die Reputation des Unternehmens.³³³⁴ Allerdings zeigt sich, dass es nicht ausreicht, neue Technologien und Informationssysteme zu entwickeln, losgelöst von Organisationsprozessen. Um erfolgreich zu sein, muss ein Informationssystem als soziotechnisches System ausgehend von domainspezifischen Prozessen entworfen, gestaltet und implementiert werden. In diesem Zusammenhang ist die Entwicklung der Taxonomie ein notwendiger Beitrag, um die Komplexität zu reduzieren und ESGRM-Systeme prozessphasenübergreifend zu gestalten. Daneben wird mit dem demonstrierten ESG-Fingerprint eine integrierte Sicht auf ESGRM-relevante Kontroversen aufgezeigt und empirisch evaluiert.

Die Entwicklung der ESG-Taxonomie sowie der daraus resultierende ESG-Fingerprint eignen sich zur Charakterisierung von Objekten mit ESGRM-Bezug. Weitere Erkenntnisse sind zu erwarten, sobald die evaluierte Taxonomie auf die gesamte Fallbasis angewandt ist und sich aus der Auswertung umfangreiche Fingerprints bzw. Muster erkennen lassen. Diese Muster dienen sowohl als Basis für die Gestaltung eines ganzheitlichen ESGRM-Systems, das ein integratives und prozessphasenübergreifendes

³³ Ajina, A. S., Japutra, A., Nguyen, B., Alwi, S. F. S., & Al-Hajla, A. H. (2019). The importance of CSR initiatives in building customer support and loyalty. *Asia Pacific Journal of Marketing and Logistics*.

³⁴ Parcha, J. M. (2017). How much should a corporation communicate about corporate social responsibility? Reputation and amount of information effects on stakeholders' CSR-induced attributions. *Communication Research Reports*, 34(3), 275–285.

Risikomanagement ermöglicht, als auch für die Ableitung von Anforderungen an KI-basierte Methoden.

Da alle drei Evaluationsbeispiele aus der dritten Iteration in der Risikoidentifikationsphase eingeordnet sind, erachten die Autoren es als sinnvoll, eine große Stichprobe aus der gesamten Fallbasis zu ziehen und in einer umfassenden Studie zu untersuchen. Diese Untersuchung erlaubt es, weitere Potenziale für die ESGRM-Phasen zu identifizieren.

Pajam Hassan ist Geschäftsführer der intuitive.AI GmbH und Experte für Big Data Analytics im Bereich Risiko-Management. Er wurde ausgezeichnet für seine künstliche-Intelligenz-basierte Forschung in der Automobilindustrie und der Entwicklung eines innovativen, digitalen Geschäftsmodells. Er verantwortete als Projektleiter und später Forschungsauftragsleiter die Entwicklung eines Big-Data-Frühwarnsystem in einem multinationalen Konzern. Er ist Autor zahlreicher wissenschaftlicher Publikationen und promoviert an der Universität Oldenburg.

Dr. Frank Passing ist Geschäftsführer der intuitive.AI GmbH und Experte im Bereich des Natural Language Processing für strategische Frühaufklärung von Unternehmen, Technologien, Innovationen und Märkten. Er wurde ausgezeichnet für seine künstliche-Intelligenz-basierte Forschung in der Automobilindustrie und der Entwicklung eines innovativen, digitalen Geschäftsmodells. Er ist Autor zahlreicher wissenschaftlicher Publikationen, studierte an der INSEAD und promovierte an der Universität Bremen, an der er bis heute Dozent für „AI in Business“ ist.

**Anwendungen in der Unternehmenspraxis:
Datenwert, Produktion, neue Instrumente,
Mittelstand**



Datenwert und Datenminimalismus: Wege zu nachhaltiger künstlicher Intelligenz

Michaela Regneri

1 Künstliche Intelligenz und Postwachstum für die Datenwirtschaft

Mit der Erfindung und Verbreitung des Internets 1989 begann die digitale Revolution. Die damit angestoßene Transformation betrifft alle Lebensbereiche, neben persönlichem Privatbereich und Gesellschaft natürlich auch massiv Wirtschaft und Industrie. Daten gelten als Treibstoff dieser immer schneller fortschreitenden Änderungen, und datengetriebene Systeme – insbesondere künstliche Intelligenz (KI) – als disruptivste treibende Technologie. Sowohl die Menge der Daten als auch die Verbreitung von KI ist in den vergangenen Jahren exponentiell gestiegen. Das weltweite Datenvolumen wird sich vermutlich in den nächsten Jahren auf 175 *Zetabyte* vervielfachen (Reinsel et al. 2018) und der Umsatz mit KI-Systemen in den nächsten drei Jahren verdreifachen (Statista 2020), trotz immer günstiger werdender Systeme und Services.

Daten werden privat wie industriell viel zu oft achtlos genutzt, weil sie als unsichtbares Asset so wirken, als seien sie ein unbegrenzter kostenarmer Rohstoff. Das gilt in hohem Maß für alles aus dem Bereich der KI: KI-Anwendungen haben in den letzten zehn Jahren enorme Fortschritte gemacht. Die Gründe dafür sind neben gestiegenen Maschinenkapazitäten vor allem die immer weiter wachsenden Datenmengen. Gute KI-Anwendungen gelten als extrem datenhungrig, weil nur viel Information präzise automatische Entscheidungen erlaubt. Daher verfolgen Entwicklungsteams bei KI auch oft das Motto „Je mehr Daten, desto besser“, und füttern ihre KI-Systeme so weit es geht.

M. Regneri (✉)
OTTO (GmbH & Co. KG), Hamburg, Deutschland
E-Mail: michaela.regneri@otto.de

Im Kontext von Digitalisierung und KI bezeichnet man Daten als das neue Öl oder das neue Gold. Aber genau wie Öl und Gold sind diese wertvollen Daten kein Rohstoff, der unbegrenzt und verschwenderisch eingesetzt werden kann. Kontinuierliches Wachstum stößt nicht nur in der Wirtschaft an seine Grenzen – auch ständiges exponentielles Datenwachstum verursacht diverse Schäden.

Abgesehen von direkten Effekten wie Kosten und Stromverbrauch für Datenspeicher, sind die indirekten Effekte auf datengetriebene Systeme noch weitaus größer. Alle aus Daten lernenden Maschinen werden um ein Vielfaches teurer, langsamer, risikoreicher und unberechenbarer, wenn ihre Datenbasis wächst. Um Ressourcen zu schonen, müssen wir auf eine Postwachstumsstrategie für die neue Data Economy hinarbeiten. Neben wirtschaftlichen Aspekten wie Kosten und Wettbewerb (Abschn. 1.1) sind ökologische Nachhaltigkeit (Abschn. 1.2) und soziale Faktoren wie Sicherheit (Abschn. 1.3) und Chancengleichheit (Abschn. 1.4) essenzielle Motivatoren für ein neues Paradigma von *Datenminimalismus* – auch und gerade für datenschwere KI-Systeme.

1.1 Daten und wirtschaftliche Aspekte

Einer der naheliegendsten Gründe, Daten sparen zu wollen, sind direkte und indirekte Kosten. Unternehmen wettbewerbsfähig zu halten, bedeutet auch eine Form der Nachhaltigkeit, etwa mit Blick auf Verantwortung für die eigenen Mitarbeiter*innen. Die Technologieinvestitionen in Unternehmen steigen und im Zeitalter der Digitalisierung machen IT-Kosten bereits den größeren Teil des Budgets in Innovationsprojekten aus. Während es eine natürliche Entwicklung ist, dass mit höherer Technologisierung auch mehr Technologieinvestitionen getätigt werden, dürfen die Kosten natürlich nur so weit wachsen, wie auch entsprechende Gewinngenerierung dem gegenübersteht. Bei einem exponentiellen Wachstum von verfügbaren Daten ist nicht ohne Weiteres ein exponentielles Gewinnwachstum zu erwarten, während die Datenverarbeitungskosten proportional zur Datenmenge steigen. Eine Unterscheidung zwischen Daten mit großem Wertschöpfungspotenzial und Daten, die weniger gewinnbringend sind, kann also essenziell sein, um Wachstums- und Innovationsfähigkeit eines Unternehmens mit Blick auf die Kosten zu erhalten.

Ein weiterer Ansatzpunkt für datenminimalistisches Arbeiten ist der internationale Wettbewerb: In der Digitalwirtschaft investieren viele Staaten strategisch in KI, um im Vergleich mit anderen Ländern technologisch möglichst gut abzuschneiden. Hier äußern vor allem Europäer Bedenken, ob unsere strengen Datenschutzregelungen uns nicht einen starken Wettbewerbsnachteil auferlegen, weil andere Länder entweder durch private Investoren (USA) oder staatlich geregelte Datenwirtschaft (China) viel größere Datenschätze und damit unaufholbare wirtschaftliche Vorteile im KI-Bereich hätten. Würde es gelingen, mit wenigen Daten effektivere Systeme zu bauen, also sich auf wertvolle Daten zu konzentrieren, wären ausgeprägter Datenschutz und wettbewerbsfähige KI kein Widerspruch. Die effizienteren Systeme kombiniert mit vertrauenswürdiger

Datenbehandlung könnten sogar ein Markenzeichen und damit ein Vorteil im Vergleich zu anderen Wirtschaftssystemen sein.

1.2 Künstliche Intelligenz und Klimaschutz

Der Stromverbrauch von Datenverarbeitung und Datentransfer führt mittlerweile zu mehr CO₂-Emissionen als der Flugverkehr. Neben dem Streamen von Onlinevideos oder Musik (Shehabi et al. 2014) tragen auch KI-Anwendungen einen großen Teil zu diesem klimarelevanten Budget bei: Strubell et al. (2019) zeigen, dass das Entwickeln und Optimieren eines einzigen KI-Modells so viel Emissionen verursachen kann wie ein Kleinwagen im Jahr. Sowohl die verfügbaren Datenmengen als auch die Anzahl der KI-Anwendungen wird in den nächsten Jahren vermutlich stark ansteigen. Beides zusammen führt zu einem epidemischen Wachstum des KI-Energieverbrauchs.

Selbstverständlich entsteht der Klimaschaden durch KI hier nur mittelbar. Wäre die gesamte Infrastruktur und der Strom, der bei Entwicklung und Anwendung der Systeme verbraucht wird, klimaneutral, hätte auch die KI keinen Einfluss. Die aktuellen Ansatzpunkte zu grünen Datacentern (Sharma et al. 2017) setzen auf möglichst effiziente Technologie mit einem möglichst kleinen Fußabdruck. Weiterhin spart Cloud Computing grundsätzlich Energie und eine Zunahme von Cloud-basierten Ansätzen anstelle von individuellen Rechenzentren in Firmen ist zu erwarten. Es bleibt jedoch fraglich, ob die Weiterentwicklung der nachhaltigen Infrastruktur für den rasant steigenden Ressourcenbedarf ausreicht: Eine Studie von Greenpeace (Cook et al. 2017) erwartet, dass die zwar energieeffizientere, aber auch kostengünstigere Cloud zu Rebound-Effekten führt und die zu erwartende Mehrnutzung unterm Strich mehr Emissionen erzeugt, als durch den Wechsel zur Cloud hin gespart werden kann.

1.3 Daten und Sicherheit

Der wachsende Digitalisierungsgrad verändert nicht nur Unternehmen und Gesellschaft, sondern auch die Art der Kriminalität, denen Firmen und Privatpersonen ausgesetzt sind. Mit steigenden Zahlen an Datendiebstählen und Angriffen auf digitale Systeme steigen sowohl die Kosten für die Beseitigung von Cybercrime-Schäden als auch die Präventionskosten für IT-Sicherheit. Während digitale Schutzmaßnahmen in einer digitalen Wirtschaft eine überlebenswichtige Investition sind, gäbe es auch einfache Maßnahmen, um datengetriebene Systeme selbst sicherer zu machen. Jeder Datenpunkt, der unnötig bewegt wird, ist ein unnötiges Sicherheitsrisiko. Beim Bauen von KI-Systemen finden große Datenbewegungen statt, und jede Reduktion, insbesondere bei sensiblen Daten, bietet hier einen Sicherheitsvorteil. Weiterhin sind auch KI-Systeme selbst immer öfter Ziel von Cyber-Angriffen, indem die Systeme manipuliert und dadurch wertvolle Informationen erbeutet oder Infrastrukturen außer Kraft gesetzt werden. KI-Systeme, die

weniger Daten bewegen, können zwar immer noch angegriffen werden, aber im Fall einer Attacke weniger Daten preisgeben. Im stetig schneller werdenden Wettrüsten von Cyber-Kriminellen und Cyber-Sicherheitsentwicklungen ist hier jede Präventionsmaßnahme ein Wettbewerbsvorteil.

1.4 Künstliche Intelligenz und Diskriminierung

KI-Systeme stehen häufig in der Kritik, weil sie für menschliche Vorurteile wie ein Funke in der Feuerwerksfabrik wirken können: Datensätze, die menschliches Verhalten spiegeln, enthalten oft auch Diskriminierung, wenn auch nur implizit. Während solche Vorurteile in zwischenmenschlichen Interaktionen vielleicht selten sind, bauen KI-Systeme daraus hochskalierte Vorurteilsmaschinen, die in vielfacher Geschwindigkeit und ohne Ausnahmen diskriminieren. Häufig werden hier systemisch bedingte Korrelationen zu festen Kausalketten – ähnlich wie bei menschlichen Vorurteilen. Ein bekanntes Beispiel ist die hohe Falscheinordnung von Afroamerikaner*innen als Straftäter*innen durch ein KI-System (OECD 2019).

Das Paradigma, Systeme mit möglichst vielen Daten zu trainieren, trägt seinen wesentlichen Teil zu dieser Problematik bei. Wenn das fertige KI-System mit 80%iger Genauigkeit für die Gesamtbevölkerung funktioniert, kann es z. B. sein, dass es eine Minderheit, die nur 15 % der Bevölkerung ausmacht, grundsätzlich falsch einordnet.

Datenminimalismus allein löst dieses Problem nicht, allerdings können Techniken zur Datenreduktion maßgeblich helfen: Die Vermeidung von Bias in Systemen kann etwa darin bestehen, überrepräsentierte Gruppen gezielt seltener in die Datengrundlage zum Lernen aufzunehmen (wie unter anderem in der Medizin schon lange üblich, s. Greenland [1988] für ein frühes Beispiel). Der Einfluss von Daten auf Vorurteile kann auch durch die Berechnung des Werts von Daten kalkuliert und so korrigiert werden. Wertvolle Daten für ein System sollten solche Daten sein, die nicht nur die gesamte Systemqualität steigern, sondern die Treffsicherheit für alle Gruppen einzeln verbessern. Eine Analogie wäre, dass eine Steuerreform nicht nur alle Bürger im Schnitt besser stellen sollte, sondern auch alle Einkommensgruppen für sich betrachtet fair behandeln muss. Mit solchen detaillierten Kennzahlen kann der Datenwert zu einer hilfreichen Größe werden, um wertvolle Daten im minimalistischen und fairen Sinn zu fokussieren.

2 Künstliche-Intelligenz-Strategien für kleine Datenmengen

Strategien zur Verschlinkung sind etablierte Techniken in der KI-Entwicklung. Die meisten davon erfolgen systemseitig: Hier wird ein bestehendes KI-System kleiner und effektiver gemacht, indem ein paar seiner Entscheidungsregeln oder überflüssige Teilstrukturen des neuronalen Netzes entfernt oder ausgedünnt werden. Sparsamkeit ist hier allerdings bestenfalls ein Nebeneffekt. Das Hauptziel in der Minimierung besteht

darin, die Systeme weniger spezialisiert und für mehr unterschiedliche Szenarien nutzbar zu machen. Verglichen mit einem Hausbau würden durch Rückbaumaßnahmen von einem fertig gebauten Haus nur noch tragende Wände, Dach und Fenster übrigbleiben. Das Haus wäre in seiner Grundstruktur noch funktional, könnte aber noch zu einer Wohnung, einem Geschäft oder einem Restaurant gleichermaßen werden. Diese Art der Generalisierung bei KI hat unterschiedliche Gründe. Es gibt z. B. Ansätze, die zeigen, dass kleinere KI-Modelle durch ihre Wiederverwendbarkeit neben Rechenzeit beim Lernen auch Entwicklungszeit und -aufwand sparen (Liu et al. 2015; Suresh et al. 2010). In manchen Fällen führt dieses künstliche Abspecken eines KI-Systems auch zu besseren Ergebnissen, weil überspezialisierte Systeme manchmal eine Art Fachidiotie entwickeln und ihre Anwendbarkeit auf neue Daten verlieren (Atzmon et al. 2015; Guo und Xue 2013). Das deckt sich mit unserer experimentellen Erfahrung, dass zu viel Information einem KI-System in einigen Fällen durchaus schaden kann.

Verglichen mit Strategien zur Verkleinerung von bereits bestehenden KI-Systemen ist die gezielte Arbeit mit möglichst kleinen Datengrundlagen seltener. Im Hausbauvergleich würde dieser Ansatz bedeuten, dass zwar ein vollständig fertiges Haus gebaut wird und bestehen bleibt, aber möglichst wenige Baumaterialien verwendet würden, ohne Qualität in der Bausubstanz einzubüßen.

Die KI-Entwicklung lebt größtenteils im populären Big-Data-Paradigma von „viel hilft viel“. Arbeiten wie die von Halevy et al. (2009) waren hier federführend mit der Aussage, dass es grundsätzlich zu besseren und leichter skalierbaren Systemen führt, wenn KI-Systeme sehr viele einfache Daten nutzen, statt nur kleiner Datenmengen mit zusätzlichen manuell gefertigten Regeln.

Im KI-Design gilt Datenmangel meist eher als notwendiges und zu überwindendes Übel: Diverse, lang etablierte Näherungsmethoden („Smoothing“) halten Systeme trotz weniger Daten lauffähig und die Ausgabequalität akzeptabel (Greenland et al. 2000). Hierbei wird die maximal vorhandene Grunddatenmenge als gegebene Voraussetzung betrachtet. Trifft die KI dann auf Ereignisse, die nicht in dieser Trainingsdatenmenge vorkamen, werden geschickte Strategien zum Raten angewendet. Die Grundannahme ist dabei immer, dass Unbekanntes auch immer sehr selten und daher zwar einzurechnen, aber generell zu vernachlässigen ist.

Eine weiterer klassischer Weg zur Datenmangelbekämpfung besteht im Generieren künstlicher Trainingsdaten (vgl. Nevatia und Binford 1977, für eines der ersten Beispiele). Hierbei werden die (oft wenigen) vorhandenen Daten vervielfacht und leicht modifiziert oder neu kombiniert, um neue mögliche, aber in der bestehenden Datenmenge noch nicht vorhandene Beispiele zu erzeugen. Diese Technik dient nicht nur dem Ausgleich von Datenmangel, sondern kann, wie umgekehrt auch Datenreduktion, bei sehr unausgeglichene Datenmengen (z. B. viele Frauen, wenige Männer) zur Vermeidung von Vorurteilen benutzt werden.

Eine komplexere Methode, die mehr Flexibilität erfordert, verfolgt das sog. aktive Lernen. Bei dieser Trainingsmethode werden so wenige Informationen wie möglich angewendet und nur dort vom lernenden KI-System angefordert, wo sich das System

besonders unsicher ist. In unserer eigenen Terminologie würde das der Beschränkung auf besonders wertvolle Daten entsprechen (Regneri et al. 2019, 2018).

Ebenso erwähnenswert ist in diesem Zusammenhang das Transferlernen (*Transfer Learning*; Pratt 1993), bei dem andere bestehende KI-Systeme mit besserer Datengrundlage genutzt werden. Oft sind diese Systeme zwar für andere Aufgaben konzipiert, aber ihre Ausgabequalität auf den fremden Daten ist immer noch besser als die des Systems, das aus zu wenigen Daten lernen soll. Hier schließt sich auch der Kreis zu den oben beschriebenen systemseitigen Änderungen: Transfer Learning funktioniert am besten mit generischen, verschlankten KI-Modellen.

3 **Wieviele Daten brauchen wir? Datenmenge und Qualität der künstlichen Intelligenz**

Zu Beginn von Data-Science-Projekten kommt von Projektinitiator*innen oft eine Frage, die von Data Scientists eigentlich nie beantwortet werden kann: Wie viele Daten braucht man dafür denn? Hier gibt es keine allgemeine Formel als Antwort. Datenminimalismus erfordert aber eine qualitätssichernde Kennzahl, die die Datenmenge als Teilkriterium für Systemqualität befördert. Wir sehen Datenminimalismus immer im Kontext von Systemqualität. Unter Akzeptanz von Qualitätseinbußen könnten einfach beliebige Daten in der Lerngrundlage einer KI entfernt werden. Unser Paradigma lebt jedoch davon, die Qualität eines KI-Systems mindestens zu erhalten und dafür die minimal nötige Datengrundlage zu benutzen. Für uns sollte die Frage nach der Datenmenge also lauten: Wie viele Daten brauchen wir mindestens, ohne etwas zu verlieren?

Zunächst suchen wir also eine Abschätzung, *wie viele* Daten denn überflüssig sein könnten, bevor wir im folgenden Abschn. 4 dann die logische Folgefrage stellen, *welche* Daten genau eigentlich gebraucht werden. Eine technischere Erklärung der Grundlagen findet sich auch bei Regneri et al. (2019).

3.1 **Die Grundidee: Datenmenge und Qualität**

Um herauszufinden, wie viele Daten unsere KI eigentlich braucht, haben wir die Qualitätsveränderung eines KI-Algorithmus gemessen, wenn die Datengrundlage wächst. Hier gehen wir davon aus, dass die Ergebnisqualität grundsätzlich *messbar* ist: Wir brauchen bekannte Kriterien, die ein gutes System ausmachen und die sich in Zahlen abbilden lassen. Das ist bei vielen datengetriebenen Systemen nicht der Fall und häufig auch nicht trivial zu bewerkstelligen. Umgekehrt gibt es in einigen Fällen, wie auch in unserem Experiment, sogar mehr als eine Kennzahl (Key Performance Indicator, KPI), die unterschiedlich wichtig sein können. Die Entscheidung über die richtigen Kennzahlen muss für jedes System und jeden Kontext einzeln getroffen werden, ähnlich wie im klassischen Controlling der Unternehmenssteuerung.

Eine weitere Voraussetzung für operationalisierbaren Datenminimalismus ist die Fokussierung auf *nutzungsbasierte Datenqualität*: Wir messen keine Merkmale der Daten an sich, sondern ihre Auswirkungen in einem automatischen System. Datenbasierte Wertschöpfung, die manuell oder außerhalb solcher Systeme passiert, ist so nicht ohne Weiteres messbar. Für unser Ziel, nämlich der nachhaltigen Gestaltung von KI-Systemen, sehen wir hier aber genau die richtige Vorgehensweise, die Nachhaltigkeit und Leistung des Systems mit der Datengrundlage in Verbindung setzt.

Unser praktisches Experiment testet ein ansonsten identisches System mit unterschiedlichen Datenmengen und vergleicht die Qualität der unterschiedlichen Systemvarianten. Grundsätzlich ist das kein neuer Ansatz: So werden beispielsweise sog. Lernkurven für automatisch lernende Software erstellt. Solche Kurven zeigen, wie viele Daten ein System braucht, um seine Aufgabe gut zu erfüllen. Im Schnitt sind diese Lernkurven immer ähnlich: Die Abb. 1 zeigt eine Standardlernkurve für maschinelles Lernen. Allgemein erwartet wird eine logarithmische Entwicklung. Am Anfang wächst die Systemqualität mit neuen Daten sehr steil an (exponentielle Lernphase), dann verlieren neue Daten langsam ihre Effektivität (abflachende Lernphase). Der Kurvenverlauf ist vergleichbar mit körperlichem Training beim Sport: Für jemanden, der gar keinen Sport macht, macht ein Training pro Woche einen sehr großen Unterschied. Für jemanden, der ohnehin vier Mal pro Woche trainiert, bringt das fünfte Training nur noch kleine Fortschritte.

Die Art und Steigung der Kurve hängt natürlich immer vom konkreten System, der Datengrundlage und der Komplexität der Aufgabe ab. Unser Ziel im Sinn des Datenminimalismus ist, den Punkt zu finden, an dem weitere Daten entweder gar keinen Qualitätszuwachs mehr bedeuten oder nur noch so geringe Verbesserungen, dass die Dateninvestition sich nicht mehr lohnt. Unser folgendes Experiment zeigt einen pragmatischen Ansatz, um den Punkt mit der besten Dateneffektivität zu identifizieren.




Abb. 1 Standardlernkurve für maschinelles Lernen

3.2 Experiment aus der Praxis: Datenmenge versus Qualität von künstlicher Intelligenz

Unsere Untersuchungen über den Zusammenhang von Datenvolumen und KI-Leistung führten wir anhand eines Empfehlungssystems durch, schematisch dargestellt in Abb. 2. Empfehlungssysteme generieren datenbasiert Produktplatzierungen, entweder mit Bezug auf die Kund*innen (persönliche Empfehlungen) oder, wie in unserem Fall, mit Bezug auf ein bestimmtes Produkt (sog. Item-to-Item Recommendations). Diese Empfehlungen werden typischerweise auf einer Produktseite als Alternativen oder Ergänzungen für das betrachtete Produkt (das *Bezugsprodukt*) angezeigt, oft markiert mit Überschriften wie „Andere Kund*innen interessierten sich auch für...“ oder „Andere Kund*innen kauften auch...“. Unser Empfehlungssystem empfiehlt zu einem Bezugsprodukt ähnliche Produkte auf der Basis von Nutzungsverhalten im Online-Shop. Das System empfiehlt Produkte als Alternative, wenn viele Kund*innen mit ähnlichem Shopping-Verhalten sie beide betrachtet haben. Wenn also Nutzer*innen vor einem violetten Shirt oft ein bestimmtes rotes Shirt anklicken und danach häufig ein bestimmtes grünes, dann hat das violette Shirt den Shopping-Kontext von einem bestimmten roten und einem bestimmten grünen Shirt. Wenn es zusätzlich ein blaues Shirt mit dem gleichen Shopping-Kontext gibt (also beim gleichen Seitenbesuch wird außer dem blauen auch vermehrt das gleiche rote und danach das gleiche grüne Shirt angeklickt wie bei dem violetten Shirt), dann sind im Empfehlungssystem das violette und das blaue Shirt ähnlich. Zum Berechnen dieser Empfehlungen nutzen wir einen Machine-Learning-Algorithmus (Mikolov et al. 2013), der das gleiche Prinzip dafür verwendet, um z. B. ähnliche Wörter in Texten zu finden. Die Verwendung solcher Algorithmen in Empfehlungssystemen ist eine gängige Methode (s. z. B. Caselles-Dupré et al. 2018).



Abb. 2 Schema des untersuchten Empfehlungssystems, ein sog. Item-to-Item Recommender. Zu einem Bezugsprodukt, das der*die Nutzer*in gerade betrachtet, werden ähnliche Alternativen empfohlen. In unserem Fall bedeutet „ähnlich“, dass Kund*innen, die das gleiche Bezugsprodukt sehen, bei ihrem Shop-Besuch auch die Seiten der anderen Produkte betrachten („Andere Kund*innen klickten auch...“).

Im Reihenversuch haben wir unser Empfehlungssystem mit unterschiedlichen Datenmengen trainiert und die Leistung in den KPIs Rechenzeit, Konversionsrate und Umsatz gemessen. Die Messung erfolgt mit Daten aus dem produktiven System des Shops, die auf das getestete Laborsystem übertragen wurden. Die Kennzahlen haben wir wie folgt erhoben:

- **Umsatz:** Umsatz bezieht sich auf die Gesamtmenge an verkauften Produkten, die durch Empfehlungen des Systems erzielt würde, wenn es live im Einsatz wäre. Um diese Zahl zu schätzen, betrachten wir real getätigte Online-Käufe von empfohlenen Produkten. Wenn im Online-Shop mit den Live-Systemen eine Empfehlung gekauft wird, die unser System auch erzeugt hätte, übertragen wir den Umsatzwert auf unser System. Die Schätzung des Umsatzes beruht somit auf echten Daten, aber ohne die Live-Systeme zu beeinträchtigen. Insgesamt ist der so errechnete Umsatz sehr konservativ berechnet: Wir können etwa nicht feststellen, ob eine Empfehlung unseres Systems, die das Live-System nicht gezeigt hat, auch in der Realität Umsatz erzeugt hätte. Solche Empfehlungen gehen dann mit einem Umsatz von Null in die Rechnung ein.
- **Konversionsrate:** Die Konversionsrate ist der Anteil der Betrachter*innen einer Produktempfehlung, die diese tatsächlich gekauft haben. Diese Kennzahl ist (anders als der Umsatz) unabhängig vom Preis der betrachteten Artikel. Während Konversionsrate und Umsatz sich oft ähnlich verhalten, kann die Konversionsrate aber durchaus steigen, während der Umsatz fällt, beispielsweise bei größerem Abverkauf stark reduzierter Produkte zulasten von teureren Produkten. Wir betrachten Konversionsrate als eine Art *Relevanzmaß* für die Empfehlungen, weil wir annehmen, dass nur passende Vorschläge auch tatsächlich gekauft werden. Indirekt bekommen wir so auch eine Vorhersage der Kund*innenzufriedenheit, weil erfahrungsgemäß irrelevante Angebote mehr stören und spannende Angebote das Käuferlebnis verbessern.
- **Rechenzeit:** Zeit ist zwar keine kaufmännische Kennzahl, aber bei der Entwicklung von Software und Data-Science-Modellen eine betriebsrelevante Größe. Die Rechenzeit bezeichnet hier die Dauer des Modelltrainings, die mit steigender Datenmenge zunimmt (die Zeit für die Erzeugung der späteren Empfehlungen ändert sich nicht). Mit der Rechenzeit steigern sich direkt proportional auch der Stromverbrauch und damit auch die Kosten sowie der CO₂-Fußabdruck. Mit steigender Rechenzeit sinkt demnach die Nachhaltigkeit des Systems.

3.3 Ergebnisse: Datenverschwendung und toxische Daten

Die Ergebnisse unseres Versuchs zeigt Abb. 3. Waagerecht ist die wachsende Datenmenge aufgetragen, wobei die minimale Menge zwei Tage Nutzungsdaten beinhaltet und die maximale Datenmenge (das entspräche einem Live-Setup) sechs Monate. Während




Abb. 3 Key Performance Indicators (KPIs) in Abhängigkeit vom Datenvolumen. Gemessen wurde Rechenzeit, geschätzter Umsatz des Algorithmus und Konversionsrate. Alle KPIs sind zur besseren Vergleichbarkeit zwischen 0 und 1 normalisiert, wobei ein Wert von 1 hier das im Experiment gemessene Maximum der jeweiligen KPIs bedeutet.

wir hier die konkreten Kennzahlen nicht veröffentlichen können, zeigen wir ihre relative Bewegung: Die senkrechte Skala von 0 bis 1 zeigt die normalisierten Werte der Kennzahlen. Ein Wert von 1 bedeutet, dass hier das gemessene Maximum der Kennzahl erreicht ist, während 0 das gemessene Minimum repräsentiert (was in realen Zahlen typischerweise größer ist als 0). Auf diese Art und Weise werden die unterschiedlichen KPIs auch besser miteinander vergleichbar.

Erwartungsgemäß steigt die *Rechenzeit* (blaue Kurve, quadratische Markierung) fast linear zur Datenmenge, wobei einzelne Abweichungen hier durch das technische Setup (wie Auslastung der Maschinen) bedingt sind. Insgesamt bedeutet die doppelte Datenmenge also das Doppelte an Zeit, Kosten und Energieverbrauch und damit auch das Doppelte an klimaschädlichen Emissionen.

Der *Umsatz* verhält sich lehrbuchhaft so, wie die Standardlernkurve es (Absch. 10.3.1) vorhersagt: Zunächst steigt der Umsatz stark mit der wachsenden Datenmenge, dann verflacht sich die Kurve immer stärker. Die Effektivität der Daten nimmt also ab einem bestimmten Punkt stark ab.

Besonders erkenntnisreich ist die Betrachtung der *Konversionsrate*: Während die Rate anfänglich noch stärker als der Umsatz steigt, fällt sie nach einer Spitze um 20 % der Datenmenge überraschenderweise wieder ab. Ein relevanter Wendepunkt scheint bei 40 % der Datenmenge erreicht: Hier ist ein Plateau der Konversionsrate, während der Umsatz nur noch leicht steigt. Danach fällt die Konversionsrate immer steiler nach unten und die Umsatzkurve flacht weiter ab. Diese Zahlen sind so zu interpretieren, dass der Umsatz zwar weiter von mehr Daten profitiert, aber dieser Profit wird nach dem Motto „Masse statt Klasse“ erzeugt: Die sinkende Konversionsrate bedeutet, dass die

Empfehlungsqualität schlechter wird. Mit mehr Daten können aber mehr Empfehlungen für unterschiedliche Artikel erzeugt werden. Daher ist die Umsatzsteigerung auf ein qualitativ schlechter werdendes Mehr an Empfehlungen zurückzuführen.

Unsere Hauptkenntnisse aus diesem Experiment zeigen, dass ein sorgfältigerer Umgang mit Daten viel Potenzial birgt: Erstens nimmt selbst auf Umsatz bezogen die Effektivität der Daten stark ab, während die Kosten weiter linear steigen. Weiterhin wird die Qualität der Einzelentscheidungen der KI mit zunehmender Datenmenge schlechter, während sie aber in viel mehr Fällen überhaupt entscheidungsfähig ist. Die Grundidee zum Entwurf nachhaltigerer und gleichzeitig besserer Systeme besteht also darin, die optimale Menge und optimale Auswahl an Daten für KI-Modelle zu finden. Im gezeigten Beispiel hat wohlgemerkt noch keine Selektion der Daten stattgefunden – hier ging es nur um die Menge der Daten, ohne eine spezifische Auswahl. Für bessere und effektivere KI-Modelle stellt sich also die Frage: Welche Daten führen zu einem möglichst effizienten System, das mit möglichst wenigen Daten möglichst gute Qualität erzeugt?

4 Welche Daten brauchen wir? Informatorischer und monetärer Datenwert

Nachdem unser erster Versuch gezeigt hat, dass nicht alle Daten nötig und zu viele sogar schädlich sein können, stellt sich eine logische Anschlussfrage: Welche Daten braucht ein Modell, um optimal zu funktionieren? Für uns ist diese Frage gleichbedeutend mit der Frage nach dem *Wert von Daten*. Daten lassen sich trotz ihres Rufs als Rohstoff des digitalen Zeitalters Stand heute nur schwer bewerten. Wir beschreiben hier unseren Ansatz, der nicht nur den Wert von Daten abschätzen kann, sondern damit auch die Grundlage für datenminimalistische KI-Systeme liefert.

4.1 Die Grundidee: Der Wert einzelner Datenpunkte

Datenwert und Datenminimalismus gehören untrennbar zusammen. Eine minimalistische Beschränkung auf das Wesentliche verlangt ein klares Bild davon, was wirklich notwendig oder wertvoll ist. Für Daten bedeutet das, dass wir die Berechnung eines *nutzungsbasierten Datenwerts* anstreben, und zwar für *einzelne Datenpunkte*.

Einzelne Datenpunkte halten wir deshalb für die optimale (wenn auch nicht immer umsetzbare) Größe, weil andere gängige Grundlagen für Datenbewertungen nicht flexibel und nicht detailliert genug sind: Die Gesamtheit aller Bewegungsdaten von Kund*innen für eine Webseite ist meistens ein unverzichtbarer Datentopf für KI-Modelle. Eine Betrachtung auf dieser Ebene ergäbe pauschal einen sehr hohen Datenwert für diesen Datentopf. Im Detail lässt sich aber erkennen, dass etwa ein Klick auf die Startseite keine neue Information liefert. Klickt jemand aber beispielsweise nach einer Suche auf ein neues Produkt, stecken in diesem Klick deutlich mehr relevante Erkenntnisse. Wir müssen

also für jeden Datenpunkt entscheiden, wie viele *neue und relevante* Informationen er für ein datengetriebenes System bereithält, also sein informatorisches Potenzial abschätzen. Datenpunkte, die weder neu noch relevant sind, haben dann auch keinen Wert, weil kein System daraus lernen kann.

Wie im vorangegangenen Abschnitt gezeigt favorisieren wir im KI-Kontext **nutzungs-basierte Datenwertberechnung**. Wir gehen davon aus, dass Daten immer nur im Zusammenhang mit ihrer Anwendung bewertet werden können. Ein Datenpunkt birgt für unterschiedliche KI-Systeme unterschiedlich viel Informationswert, immer abhängig von Zweck und Vorkenntnissen des jeweiligen Systems. Das ist analog zur menschlichen Aufnahme von Wissen: Wenn jemand Brot backen möchte, ist eine Regalbauanleitung genauso sinnlos wie ein Brotrezept für jemanden, der gerade Möbel aufbaut. Im jeweils umgekehrten Kontext könnte das Material aber sehr wertvoll sein.

Um dem Rechnung zu tragen, bestimmen wir für ein KI-System den Wert neuer Datenpunkte, die zum System hinzukommen könnten. Die datenminimalistische Absicht dahinter liegt darin, möglichst wenige Datenpunkte hinzuzufügen und die Qualität des Systems gleichzeitig zu maximieren.

4.2 Experiment: Einflussanalyse mit einem Künstliche-Intelligenz-System

Um den Wert einzelner Datenpunkte überprüfen zu können, messen wir ihren Einfluss auf ein KI-System mit einer sog. Sensitivitätsanalyse. Bei so einer Analyse werden nacheinander einzelne Datenpunkte weggelassen und die dadurch entstehende Qualitätsänderung gemessen. Solche Analysen gibt es bereits in anderen Kontexten, die möglichst zuverlässige Datengrundlagen für statistische Auswertungen benötigen. Meistens dienen sie zur Vermeidung von Vorurteilen (Bias): Wenn in einer Auswertung eine Gruppe stark überrepräsentiert ist (z. B. im medizinischen Bereich die Gruppe der Gesunden), wird diese Gruppe zum Design der Systeme künstlich verkleinert, damit die für die Entscheidungsqualität wichtige kleinere Gruppe ausreichend in die Berechnung eingeht. Um möglichst wenig Informationen zu verlieren, wird die größere Gruppe auf die aussagekräftigsten Einzelpunkte beschränkt (bekannt als Undersampling, vgl. z. B. Dubey et al. 2014; Ng et al. 2014). Während wir ähnliche Methoden wählen, ist unsere Absicht eine andere. Wir wollen grundsätzlich Daten reduzieren; die Modelloptimierung steht im Hintergrund, wobei natürlich auch für unser KI-System die bestmögliche Qualität erreicht werden soll. Umgekehrt sind unsere Methoden aber auch für die Vorurteilsvermeidung anwendbar.

In unserem Experiment untersuchten wir 501 Varianten des gleichen Empfehlungssystems (analog zum System aus Abschn. 3): Ein *Referenzsystem* mit der vollständigen Datenmenge und 500 *Testsysteme*, in denen jeweils ein einzelner Datenpunkt gegenüber dem Referenzsystem ausgelassen wurde. Danach wird die Empfehlungsqualität wieder als Umsatz gemessen.

Grundsätzlich bewirkt ein einzelner Datenpunkt bei vielen datengetriebenen Systemen keinen messbaren Unterschied, insbesondere wenn keine oder nur sehr einfache Verfahren des maschinellen Lernens angewendet werden. In unserem Beispiel handelt es sich um ein Deep-Learning-System mit einem neuronalen Netz als Basistechnologie. Diese Systeme sind sehr komplex und reagieren stark auch auf kleine Umgebungsänderungen. Das macht sie einerseits sehr mächtig und lernfähig, andererseits kann jeder neue Datenpunkt das System maßgeblich ändern. Manche Systeme sind sogar so variabel, dass zwei Durchläufe mit identischer Datenbasis schon unterschiedliche Ergebnisse liefern können.

Für unseren Testlauf haben wir sichergestellt, dass zwei Durchläufe mit identischer Datenbasis immer das gleiche Ergebnis liefern (dass das nicht selbstverständlich ist, haben wir in Regneri et al. 2019 zusammengefasst). Weiterhin brauchten wir für die häufigen Durchläufe ein System mit künstlich kleiner Datenbasis (entsprechend dem kleinsten System aus Abschn. 3.3). Dieses Laborsystem liefert absolut gesehen keine optimalen Ergebnisse, eignet sich aber hervorragend für den Vergleich einzelner Datenpunkte.

4.3 Ergebnisse: Exemplarischer Datenwert und skalierbare Methodik

In jedem der 500 Testläufe messen wir den Wert desjenigen Datenpunkts, der im jeweiligen Testmodell ausgelassen wurde. Dieser Wert ergibt sich aus der KPI-Differenz vom Testmodell zum Referenzmodell: Wenn wir einen Unterschied im Umsatz sehen, nachdem der Datenpunkt weggelassen wurde, ergibt sich daraus der jeweilige Wert. Messen wir beispielsweise 1000 Euro *weniger* Umsatz im Testmodell, hatte der Datenpunkt einen *positiven Wert*: Er hat dem Referenzmodell 1000 Euro eingebracht (bezogen auf einen bestimmten Zeitraum). Umgekehrt kann es passieren, dass ein Testmodell einen *höheren* Umsatz erzielt als das Referenzmodell. Wenn das Testmodell 1000 Euro mehr Umsatz erzielt als das Referenzmodell, trägt der Datenpunkt einen *negativen Wert* – er hat das Referenzmodell also 1000 Euro *gekostet* und wäre besser ausgelassen worden. Ein *identischer* Umsatz von Test- und Referenzmodell würde zeigen, dass der Datenpunkt nichts geändert hat und damit auch *keinen Wert* für das System besaß.

Eine grobe Ergebnisübersicht zeigt Abb. 4. In so einer frühen Lernphase des Systems haben wir erwartet, dass fast jeder neue Datenpunkt mehr Wissen und damit auch Änderungen erzeugt. Wie die Grafik zeigt, sind in der Tat die meisten (rund zwei Drittel) der Datenpunkte wertvoll und bewirken eine Verbesserung des Modells. Gleichzeitig hätten über ein Viertel (26 %) der Datenpunkte ohne Einbußen schlicht weggelassen werden können und ein Teil (11 %) bewirkte sogar eine Verschlechterung des KI-Systems. Auch in unserem Setup macht ein einzelner Datenpunkt nur einen verhältnismäßig kleinen Unterschied: Keines der getesteten Modelle wich um mehr als 1,5 % vom Referenzmodell ab. Während diese Zahl an sich vernachlässigbar wirkt,




Abb. 4 Übersicht über die Datenpunkte und deren Einfluss im Modell

würde unser Beispiel im realen Einsatz einen hochgerechneten Umsatzunterschied von 50.000 Euro im Monat ausmachen.

Die konkreten Ergebnisse sind natürlich nur beispielhaft für ein bestimmtes System, ein bestimmtes Unternehmen und eine bestimmte Konstellation von Daten. Wichtig ist hier die grundsätzliche Methodik: Einzelne Datenpunkte können einen Unterschied machen und wir haben gezeigt, wie ihr Wert berechnet werden kann. Und selbst ein noch sehr datenarmes Machine-Learning-System, wie das hier getestete, braucht nicht jeden Datenpunkt und kann durch manche Daten sogar Schaden nehmen. Mehr Information ist also definitiv kein Garant für ein besseres System.

5 Einordnung und Diskussion

Unsere Experimente zeigen beispielhaft, wie ein KI-System für eine gängige Anwendung mit weniger Daten genauso gut und möglicherweise besser funktionieren kann. Wir haben dem klassischen Big-Data-Motto „mehr hilft mehr“ das Daten-minimalismusparadigma entgegengesetzt und gezeigt, wie dieser Ansatz operationalisiert werden kann und jenseits von idealistischen Zielen handfeste, in Geschäftszahlen sichtbare Vorteile bietet. Wir haben außerdem eine Methode zur Datenwertberechnung vorgestellt, die die aussagekräftigsten Informationen für ein KI-System identifizieren kann. So kann ein System mit einem Minimum an Eingabedaten gestaltet werden, ohne Qualitätseinbußen hinnehmen zu müssen.

Selbstverständlich ist der Weg hier noch nicht zu Ende: Unsere Machbarkeitsstudie trifft ein paar nicht selbstverständliche Annahmen und ist daher auch nicht ohne Änderungen auf jeden Kontext übertragbar. Für ein vollständiges Rezept zu datenminimalistischer KI fehlen noch weitere Zutaten. Im Folgenden diskutieren wir Grenzen, Übertragbarkeit und Erweiterungen unseres Ansatzes näher.

5.1 Voraussetzungen für angewandten Datenminimalismus

Unser Weg zu Datenminimalismus führt über die Bestimmung von Datenwert und über eine detaillierte Analyse von KI-Systemen. Beides ist nicht immer ohne Weiteres möglich:

Datenwert nutzungsbasiert zu berechnen, erfordert ein mit KPIs bewertbares System. In unserem Fall waren die KPIs Umsatz und Konversionsrate, hier sind beliebige andere denkbar. Allerdings lässt sich nicht jedes System so direkt evaluieren – auch wenn es ein lohnenswertes Ziel für alle produktiven Systeme sein sollte. Ohne Messung der Systemleistung funktioniert keiner unserer Ansätze. Gegenüber der Art der Kennzahlen ist die Methode jedoch neutral: Ob z. B. auf Gewinn, CO₂-Emissionen, Klickraten oder Kombinationen daraus optimiert werden soll, kann für jedes System neu entschieden werden.

Vollständige Kontrolle über die eigenen KI-Systeme ist die zweite wichtige, aber nicht selbstverständliche Voraussetzung. Um zu überprüfen, wie viele und welche Informationen ein System benötigt, muss das System flexibel mit unterschiedlichen Datenmengen aufgesetzt und detailliert ausgewertet werden können. Ist die Software in der Hand einer anderen Abteilung oder einer externen Firma, ist das nicht immer möglich. Der Vorteil davon, selbst diesen Aufwand zu betreiben, besteht in einem weiteren Effekt der Datenwertberechnung: Durch die Einflussanalyse werden die Reaktionen des Systems auf Daten *erklärbar*. Diese Art von Verständnis nach innen und genauer Erklärbarkeit nach außen ist ein wichtiges Asset mit Blick auf sozial verantwortliche KI.

5.2 Generalisierbarkeit: Übertragung in andere Kontexte

Die geschilderten Experimente erklären unseren Ansatz für Datenminimalismus anhand eines konkreten KI-Systems, einer bestimmten Datenbasis und eines bestimmten Unternehmens. Die skizzierte Methode ist aber generisch einsetzbar zur Wertbestimmung von Daten, auch mit anderen datengetriebenen Systemen. Jedes System muss in jedem Kontext neu bewertet werden, um seine Datengrundlage zu minimieren. Für einen möglichst großen Effekt empfiehlt es sich, besonders datenschwere und umsatzträchtige Anwendungen zu fokussieren. Für KI-Systeme kann in jedem Fall wie gezeigt eine *Mengenabschätzung* erfolgen, also eine Analyse darüber, wie viele Daten unesehen zufällig weggelassen werden könnten, ohne die Performanz zu beschädigen.

Die Überprüfung des *Datenwerts* erfordert allerdings ein grundsätzlich *stabiles* System: Bei gleicher Datengrundlage muss das System immer die gleichen Ergebnisse liefern, was gerade bei komplexen Deep-Learning-Verfahren mit großen Datenmengen in der Regel nicht der Fall ist. Das führt dazu, dass Änderungen in der Systemqualität nicht klar den Änderungen in der Datengrundlage zugeordnet werden können, sondern möglicherweise normale Abweichungen im System selbst sind. Hier können zwei Ansätze verfolgt werden: Wir selbst haben unser Testsystem vor der Sensitivitätsanalyse stabilisiert, also alle Instabilitätsfaktoren (wie Zufallsvariablen und Einflüsse von parallelen Rechenansätzen) eliminiert. Das hat den gesamten Algorithmus allerdings sehr langsam gemacht, daher konnten wir nur ein sehr kleines System testen.

Die andere Variante birgt mehr Ungenauigkeiten, ist aber pragmatischer: In instabilen KI-Systemen muss zuerst eine Basis der natürlichen Umsatzvarianz ermittelt werden, also um wie viel der Umsatz mit voller Datenmenge sowieso schwankt. In der Sensitivitätsanalyse würde man dann nicht nur einzelne Datenpunkte weglassen, sondern sinnvoll gruppierte Datenpunktmengen (z. B. alle Bewegungsmuster mit genau zwei Klicks, die schon im System vorhanden sind). Dieser Ansatz funktioniert auch für datengetriebene Systeme, die keine komplexe KI beinhalten. Diese Systeme sind zwar normalerweise sehr stabil und liefern bei gleicher Datengrundlage immer die gleichen Ergebnisse, allerdings ist hier der Einfluss eines einzelnen Datenpunkts oft nicht messbar, weil das System nicht schnell genug lernt. Auch hier kann ein Auslassen von sinnvollen Gruppen von Datenpunkten ein ähnlich gutes Ergebnis liefern wie die detailliertere Analyse, die wir gezeigt haben. Konkret ausprobiert haben wir das in einem Experiment, bei dem alle Seitenaufrufe von bestimmten rabattierten Artikeln analysiert wurden. Ein Auslassen all dieser Interaktionen auf einmal brachte erhebliche Verbesserungen im Sinn von Umsatz und Klickraten.

Ein weiteres Einsatzgebiet unserer Methode ist auch die Bestimmung des Werts von Datenqualität. Hierbei werden dann nicht die Daten an sich, sondern deren Güte monetär bewertet. So eine Analyse kann eine enorme Unterstützung bei Investitionsentscheidungen in Datenverbesserungen sein. Wir selbst haben diese Anwendung nicht getestet, geschildert wird sie von Zechmann (2016).

5.3 Nächste Schritte zu datenminimalistischer künstlicher Intelligenz

Eine Analyse, wie viele und welche Daten eine KI braucht, sind die ersten essenziellen Schritte zu nachhaltigen, datenminimalistischen KI-Systemen. Manchmal kann, wie gezeigt, schon blind eine gewisse Datenmenge ohne nennenswerten Qualitätsverlust ausgelassen werden. Für die Operationalisierung von detailliertem und präzisiertem Datenminimalismus fehlen allerdings noch weitere Werkzeuge: Die wichtigste und komplexeste Aufgabe ist es, anstelle unserer Post-hoc-Analyse bereits *vorherzusagen*, welche Datenpunkte wichtig und welche überflüssig oder sogar schädlich sind.

Hierfür müsste ein Machine-Learning-Algorithmus aufgesetzt werden, der solche Datenpunkte oder Gruppen von Datenpunkten klassifiziert. Der erste Schritt wäre wahrscheinlich, Gruppen von Datenpunkten, die gar keinen Einfluss haben, ausfindig zu machen. Das könnte die Datenbasen von KI-Systemen schon deutlich verschlanken. Die genaue Bewertung, ob ein Datenpunkt viel oder wenig positiven oder negativen Wert hat, ist eine komplexere, aber umso spannendere Aufgabe.

Wir glauben, dass sich datenminimalistische Lösungsansätze in vielerlei Hinsicht bezahlt machen werden:

- **Kosteneinsparungen** durch weniger Rechenzeit und indirekt auch durch schnellere Lernzyklen der KI-Systeme
- **Nachhaltigkeitsgewinne** durch Emissionsreduktion und durch mehr Datensicherheit aufgrund weniger Datenbewegung
- **Transparenz durch erklärbare KI**, die nicht nur bei der generellen Optimierung der Systeme hilft, sondern auch bei der Vermeidung von Bias in KI-Systemen und bei der Auskunftspflicht gegenüber Kund*innen, deren Daten Teil von automatischen Entscheidungen sind

In Zukunft wird Datenminimalismus unausweichlich sein, wenn KI und Automatisierung sich weiter ausbreiten und wir alle Vorteile davon nutzen möchten. Mit unserem Beitrag haben wir erste Ansatzpunkte geliefert, wie das gelingen könnte. Künftige Arbeiten werden diese Ansätze hoffentlich verbessern, erweitern und so in die Praxis bringen, dass wir die immer schnelleren und smarteren Systeme der digitalen Transformation mit verantwortlich designer KI gestalten können.

Literatur

- Atzmon Y, Shalit U, Chechik G (2015) Learning sparse metrics, one feature at a time. In: Storcheus D, Rostamizadeh A, Kumar S (Hrsg) Proceedings of the 1st international workshop on feature extraction: modern questions and challenges at NIPS 2015, Bd. 44, S. 30–48
- Caselles-Dupré H, Lesaint F, Royo-Letelier J (2018) Word2Vec applied to recommendation: hyperparameters matter. In: CoRR abs/1804.0 (2018). <https://arxiv.org/abs/18S4.S4212>
- Cook G, Lee J, Tsai T, Kong A, Deans J, Johnson B, Jardim E (2017) Clicking clean: who is winning the race to build a green internet? Greenpeace Inc., Washington, S 102 (Forschungsbericht)
- Dubey R, Zhou J, Wang Y, Thompson PM, Ye J (2014) Analysis of sampling techniques for imbalanced data: an n = 648 ADNI study. Neuroimage 87(2014):220–241
- Greenland S (1988) Variance estimation for epidemiologic effect estimates under misclassification. Stat Med 7(7):745–757. <https://onlinelibrary.wiley.com/doi/abs/1S.1SS2/sim.478SS7S7S4>
- Greenland S, Schwartzbaum JA, Finkle WD (2000) Problems due to small samples and sparse data in conditional logistic regression analysis. Am J Epidemiol 151(5):531–539. ISSN 0002-9262

- Guo Y, Xue W (2013) Probabilistic multi-label classification with sparse feature learning. In: Proceedings of the twenty-third international joint conference on artificial intelligence, AAAI Press, 2013 (IJCAI '13), S 1373–1379
- Halevy A, Norvig P, Pereira F (2009) The unreasonable effectiveness of data. *IEEE Intell Syst* 24(2):8–12
- Liu B, Wang M, Foroosh H, Tappen M, Pensky M (2015) Sparse convolutional neural networks. In: Proceedings of the IEEE conference on computer vision and pattern recognition, S 806–814
- Mikolov T, Corrado GS, Chen K, Dean J (2013) Efficient estimation of word representations in vector space. In: Proceedings of the international conference on learning representations (ICLR), S 1–12
- Nevatia R, Binford TO (1977) Description and recognition of curved objects. *Artif Intell* 8(1):77–98. <https://www.sciencedirect.com/science/article/pii/SSS437S2779SSS66>. ISSN 0004-3702
- Ng W, Hu J, Yeung D, Yin S, Roli F (2014) Diversified sensitivity-based undersampling for imbalance classification problems. *IEEE Trans Cybern* 45(11):2402–2412
- OECD (2019) Artificial Intelligence in Society. 2019. ISBN 9789264582545
- Pratt LY (1993) Discriminability-based transfer between neural networks. In: Hanson SJ, Cowan JD, Giles CL (Hrsg) *Advances in neural information processing systems 5*. Morgan-Kaufmann, Burlington, S 204–211. <https://papers.nips.cc/paper/641-discriminability-based-transfer-between-neural-networks.pdf>
- Regneri M, Georgi JS, Kost J, Pietsch, N, Stamm S (2019) Computing the value of data: towards applied data minimalism. In: Proceedings of the ECML-PKDD workshop on green data mining Bd. abs/1907.1. <https://arxiv.org/abs/19S7.124S4>
- Regneri M, Hoffmann M, Kost J, Pietsch N, Schulz, T, Stamm S (2018) Analyzing hypersensitive {AI;} instability in corporate-scale machine learning. In: Proceedings of the 2nd workshop on explainable artificial intelligence (XAI2018), 2018
- Reinsel D, Gantz J, Rydning J (2018) The digitization of the world – from edge to core. In: IDC white paper (2018), November, S US44413318. <https://www.seagate.com/files/www-content/our-story/trends/files/idc-seagate-dataage-whitepaper.pdf>
- Sharma P, Pegus P, Irwin D, Shenoy P, Goodhue J, Culbert J (2017) Design and operational analysis of a Green Data Center. *IEEE Internet Comput* 21(4):16–24. ISSN 10897801
- Shehabi A, Walker B, Masanet E (2014) The energy and greenhouse-gas implications of internet video streaming in the United States. *Environ Res Lett* 9 (5). ISSN 17489326
- Statista (2020) Market size and revenue comparison for artificial intelligence worldwide from 2015 to 2025 (in billion U.S. dollars). <https://www.statista.com/statistics/941835/artificial-intelligence-market-size-revenue-comparisons/>
- Strubell E, Ganesh A, McCallum A (2019) Energy and policy considerations for deep learning in {NLP}. In: Proceedings of ACL 2019 (Short papers)
- Suresh S, Saraswathi S, Sundararajan N (2010) Performance enhancement of extreme learning machine for multi-category sparse data classification problems. *Eng Appl Artif Intell* 23(7):1149–1157
- Zechmann A (2016) Assessing the economic value of data assets/Competence center data quality (CC CDQ). 2016. – Forschungsbericht

Michaela Regneri begeistert sich für künstliche Intelligenz (KI), insbesondere im Bereich Cognitive Computing mit Sprache, Bildern und allen anderen Arten von Mensch-Maschine-Interaktion. Nach ihrer Promotion in Computerlinguistik war sie zunächst beim SPIEGEL verantwortlich für Suche und Data Mining im Verlagsbereich. Bei OTTO startete sie 2016 zunächst als Produktmanagerin für Business Intelligence Analytics, in der sie Infrastruktur und Anwendungen für Data Science fachlich betreute. In Ihrer aktuellen Rolle gestaltet und hinterfragt sie unterschiedlichste KI-Anwendungen für E-Commerce, die für den Wachstumskurs und die Weiterentwicklung des Hamburger Onlinehändlers zur Plattform von strategischer Relevanz sind. Von besonderem Interesse sind für sie Themen rund um Corporate Digital Responsibility und Organisationsentwicklung, z. B. KI und Zukunft der Arbeit, KI und Mitarbeiterentwicklung und nachhaltiges Design von KI-Systemen.



Technik dient dem Menschen – Künstliche Intelligenz im BMW-Produktionssystem

Matthias Schindler und Frederik Schmihing

1 Digitalisierung und Produktion – ein dynamisches Umfeld

Das Premiumsegment der Automobilindustrie ist von hoher Wettbewerbsintensität geprägt. Entsprechend kostenbewusst muss die Produktion arbeiten – es gilt, Premiumqualität unter dem Gebot höchster Effizienz herzustellen. Den Grundpfeiler für die tagtägliche Steigerung der Effizienz in Produktionssystemen bilden die Gestaltungsprinzipien der schlanken Produktion (Dombrowski et al. 2015). Dabei zielt die kontinuierliche Verbesserung darauf ab, Prozesse systematisch zu hinterfragen und sie derart zu gestalten, dass jegliche Form der Verschwendung minimiert oder idealerweise eliminiert wird (Brunner 2017). Um möglichst gut auf die Nachfragentwicklung der weltweiten Absatzmärkte reagieren zu können (Zipse 2018), verfolgt die BMW Group den Ansatz der „Gemischtfahrweise“ (Majohr 2008) in der Produktion: Mehrere Derivate und Produkte verschiedener Baureihen werden in dieselbe Fertigungslinie integriert. Der aktuelle Trend der Hybridisierung und Elektrifizierung resultiert in einer Zunahme der Variantenvielfalt im Antriebsstrang. Der Integrationsansatz bedeutet in der Folge eine erhebliche Steigerung der Komplexität für das BMW-Produktionssystem.

Besonders bei Premiumprodukten ist Qualität nicht verhandelbar – dies impliziert bislang hohe Aufwendungen für Qualitätsinspektionen und teilweise Nacharbeit, um

M. Schindler (✉) · F. Schmihing
BMW Group – Innovationen, Digitalisierung, Data Analytics,
München, Deutschland
E-Mail: matthias.schindler@bmw.de

F. Schmihing
E-Mail: frederik.schmihing@bmw.de

© Der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

209

R. Altenburger und R. Schmidpeter (Hrsg.), *CSR und Künstliche Intelligenz*, Management-Reihe Corporate Social Responsibility,
https://doi.org/10.1007/978-3-662-63223-9_11

eventuelle Fehler zu beheben (Jochem 2010). Da die Sicherstellung einer konstant hohen Qualität permanentes Ziel einer jeden Produktion ist, finden in der Fertigung tägliche Routinen Anwendung, um die Produktionsprozesse ideal zu gestalten und die Qualität dahingehend zu optimieren, dass möglichst keine Nacharbeit erforderlich wird (Deckert et al. 2015). Insbesondere im Marktsegment der Premiumautomobile spielen Derivatisierung und ein umfangreiches Angebot zur Individualisierung eine wesentliche Rolle; so ist die aktuelle BMW 3er Limousine in mehr als einer Milliarde Varianten verfügbar (Grüneisl 2018). Die durch die immense Variantenvielfalt und die Integration induzierte Komplexität führt etablierte Methoden der Prozessverbesserung an Limits. Insbesondere die Fehlerursachenanalyse wird durch diese Komplexität deutlich aufwendiger (Töpfer und Günther 2007). Daneben erweist sich die bislang angewandte Logik von Qualitätskontrollen in langen Regelkreisen als ineffizient und kostenintensiv (Ehrlenspiel et al. 2014).

Data Analytics und Künstliche Intelligenz (KI) werden einerseits als zentrale Befähiger gesehen, um die Komplexität in Produktionssystemen zu managen, andererseits werden diese Technologien in Gesellschaft und Wissenschaft teils kritisch diskutiert. Im Zentrum stehen dabei die Aspekte, inwiefern diese Technologien für Personen abseits der IT zugänglich und bedienbar sind und welche Auswirkungen sie auf Arbeitsplätze haben (Zimmermann 2017). Visual Analytics ermöglicht die Interaktion mit großen Datenmengen wie Qualitätsdaten in der Produktion (Ware 2004). KI erlaubt beispielsweise die robuste Kategorisierung von Bauteilen und ist so einer Verkürzung der Qualitätsregelkreise dienlich.

Der CSR kommt im Kontext dieser IT-Innovationen die wesentliche Aufgabe zu, den verantwortungsvollen Umgang mit digitalen Technologien sowie die nachhaltige Umsetzung von innovativen Anwendungen der Data Analytics und KI für sämtliche Stakeholder sicherzustellen (Knaut 2017). Der Kreis der Stakeholder umfasst in diesem Kontext mindestens Kunden, Produktionsmitarbeiter, Management, Softwareentwickler und die Gesellschaft weltweit.

Für die Kunden steht die Sicherstellung der Premiumqualität an oberster Stelle. Jeder Kunde erwartet ein einwandfreies Produkt, das in genau der individualisierten Konfiguration gebaut und ausgeliefert wird, die er bestellt hat. Die Mitarbeiter müssen von Innovationen im Produktionsalltag profitieren. Für sie stehen bei den neuartigen IT-Lösungen die Verständlichkeit und Bedienbarkeit im Vordergrund. Innovationen finden nachhaltig im Produktionssystem Anwendung, wenn die Fertigungsmitarbeiter die zugrunde liegenden Prozesse verstehen und einordnen können, welchen Nutzen Technologie ihnen bringt respektive welchen Aufwand sie in die Realisierung einer neuen Anwendung investieren müssen. Um Data Analytics und KI tiefgehend in der Produktion zu etablieren, muss auch das Management die Wirkzusammenhänge in Grundzügen verstehen und die erforderlichen Prämissen kennenlernen. Gleichzeitig stehen für die Gesellschaft makroökonomische Effekte hinsichtlich der Anzahl und der Gestaltung der Arbeitsplätze im Zentrum des Interesses. Damit sind auch die Auswirkungen auf die Attraktivität der Arbeitsplätze in der Produktion von Belang. Eine weitere Säule der

gesellschaftlichen Verantwortung beschreibt die Demokratisierung von Innovationen und Algorithmen. Technologie muss den Menschen einen Mehrwert bieten, dazu sollte ein möglichst breiter Nutzerkreis sie verstehen, sie einsetzen können und davon profitieren.

Die BMW Group verbindet innovative Technologien, emotionale Produkte und individuelle Kundenbetreuung zu einem einzigartigen Gesamterlebnis. Der Anspruch der Innovationsführerschaft bezieht sich auch auf das Produktionssystem. Im vorliegenden Beitrag richtet sich der Fokus auf die Implikationen der Innovationen Data Analytics und KI auf die Qualitätsarbeit im BMW-Produktionssystem, um die CSR innerhalb dieser Systemgrenze zu beleuchten. Dieser Beitrag orientiert sich daher an den folgenden Kernfragestellungen hinsichtlich der CSR:

- Wie verändert sich unternehmerische Verantwortung durch den Einsatz von Data Analytics und KI?
- In welcher Form setzt sich die BMW Group mit den Konsequenzen und Möglichkeiten von KI auseinander? Wie wird mit den potenziellen Risiken umgegangen; welche Lösungsansätze bestehen hier?
- Was bedeutet KI für die (globale) Wertschöpfung des Unternehmens und die Strategie und wie verändert sich dadurch die gesellschaftliche Verantwortung des Unternehmens?
- Welche Kooperationen sind erforderlich und wie wird mit den unterschiedlichen Zugängen zu Verantwortung und Nachhaltigkeit umgegangen?
- Welche Anforderungen stellen Data Analytics und KI an die Führungskräfte aller Ebenen in der Produktion?

2 Status quo

2.1 Qualitätsarbeit in der Produktion – eine kritische Bestandsaufnahme

In der Qualitätsarbeit manifestieren sich die Prinzipien der schlanken Produktion im kontinuierlichen Verbesserungsprozess. Hier nimmt die Visualisierung von Qualitätskennzahlen eine wesentliche Rolle ein. Auf sog. Prozesstafeln oder Andon-Boards (Oeltjenbruns 2000) werden üblicherweise hochaggregierte Kennzahlen im Sinn von Key Performance Indicators (KPI) dargestellt (Richter und Rico-Castillo 2015). Dabei erfolgt einerseits die Kalkulation und Aggregation der KPI bis auf Werksebene je über einen vorgegebenen Zeitraum. Andererseits befassen sich die Produktionsmitarbeiter gemeinsam mit den zuständigen Vorarbeitern und Meistern zyklisch in einer strukturierten Routine mit diesen Kennzahlen, um negative Effekte festzustellen, Ursachen zu ergründen und Fehlerursachen abzustellen.

Während dieser Fehlerabstellprozess innerhalb der Produktion sehr effektiv funktioniert, können die Zeiten durch Identifikation der Ursache sehr lang sein, da

einzelne Bauteile hunderte Produktions- und Logistikstationen durchlaufen, die teilweise nicht direkt durch die Mitarbeiter einzusehen sind. Individuelle Effekte und Zusammenhänge in möglichen Fehlerbildern werden nur schwierig ermittelbar und hierzu leistet die Aggregation von produktionsspezifischen Kennzahlen nur einen geringen Mehrwert. Kennzahlen sind unverzichtbar für das Monitoring der Produktionsprozesse, jedoch lässt sich durch eben diese Aggregation in vielen Fällen nur ein Trend erkennen, der aber keinen unmittelbaren Rückschluss auf die konkrete Fehlerursache zulässt.

Die eingangs beschriebene hohe Individualisierung gepaart mit der Logik, unterschiedliche Antriebsformen und Derivate auf dieselbe Linie zu integrieren, bedeutet hohe Komplexität im BMW-Produktionssystem. Für die Produktionsmitarbeiter schlägt sich dies in einer hohen Fehlergefahr nieder. Zur Qualitätsinspektion kommen infolgedessen manuelle und automatische Überprüfungen zum Einsatz. Im Fall der manuellen Prüfungen werden Produktionsmitarbeiter abgestellt, um relevante Umfänge im sog. Vier-Augen-Prinzip zu inspizieren (Regber und Zimmermann 2009). Sie dienen damit nicht der direkten Wertschöpfung, sondern kontrollieren, ob andere Mitarbeiter korrekt gearbeitet haben. Daneben finden automatische Kameraportale mit konventioneller Bildverarbeitung Anwendung (Demant et al. 2011). In solchen Kameraportalen liegt für jedes Merkmal jeweils ein Soll-Foto pro Ausprägung vor. Um das verbaute Objekt zu inspizieren, wird ein Foto der entsprechenden Komponente aufgenommen und pixelbasiert mit dem vorgegebenen Soll-Foto abgeglichen. Typischerweise erfolgt dies anhand des Grauwerts eines jeden Pixels oder einer Auswahl an Pixeln. Weicht dabei eine geringe Anzahl an Pixeln stärker als ein tolerierbares Maß von der Vorgabe ab, wird ein Fehlereintrag für diese Komponente generiert. In diesem Fall versucht ein Vorarbeiter, die Komponente in der Fertigung zu lokalisieren, und überprüft die Komponente. Sollte diese Kategorisierung der Kameraüberprüfung fehlerhaft sein, liegt ein „false positive“ vor – ein Pseudofehler (Deuse et al. 2017). Der Vorarbeiter löscht alle Pseudo- oder Scheinfehler aus dem Qualitätssystem. Alle tatsächlichen Fehler („true positives“) müssen nachgearbeitet werden, bevor das Fahrzeug das Werk verlassen kann.

Kameraportale sind üblicherweise derart empfindlich eingestellt, dass sie keinen tatsächlichen Fehler übersehen („false negatives“); entsprechend häufig treten Scheinfehler auf. Damit der beschriebene pixelbasierte Bildvergleich funktionieren kann, sind sehr konstante Umgebungsbedingungen erforderlich. Jedes Foto einer Komponente muss immer gleich aussehen – Tag und Nacht, im Sommer wie im Winter. Kameraportale sind daher wie folgt aufgebaut: Die Portale sind in eine Box integriert, die der Abschattung des Umgebungslichts dient. Im Inneren befinden sich zahlreiche Kameras und Beleuchtungseinheiten (Demant et al. 2011). Jede Kamera ist dabei so auf ein Merkmal ausgerichtet, dass es dieses nahezu formatfüllend aufnimmt. Die Beleuchtung (Weiß- oder Rotlicht) ist mit der jeweils korrespondierenden Kamera synchronisiert. Rote Lichtquellen werden appliziert, um Reflexionen zu minimieren, da diese eine Erkennung obstruieren. Damit alle Fotos ähnlich aussehen und mit dem Soll-Foto verglichen werden

können, werden die Fahrzeuge in der Produktion üblicherweise angehalten, um die Fotos im Kameraportal aufzunehmen. Dies steht im Gegensatz zum Gebot des Produktionsflusses aus der schlanken Produktion.

Aufgrund des Platzbedarfs und der Unterbrechung des Produktionsflusses wird die Anzahl der Kameraportale in der Fertigung limitiert – insbesondere in Werken mit stark begrenztem Platzangebot wie dem Stammwerk der BMW Group in München. Somit ergeben sich wenige solcher Portale pro Fertigungslinie zur Inspektion, also lange Qualitätsregelkreise. Damit einher geht die Nacharbeit, im Zuge derer teils Komponenten demontiert werden müssen, um ein fehlerhaftes Bauteil auszutauschen. Zusätzlich ergibt sich der Nachteil, dass bei dieser Logik der automatischen Qualitätsinspektion Teile zunächst falsch verbaut und nachträglich nachgearbeitet werden müssen. Schwankende Umgebungsbedingungen führen in der Praxis zu Insuffizienzen der Fehlerdetektion. Eine hohe Rate an Pseudofehlern impliziert einen immensen Aufwand für die Vorarbeiter, da sie alle Fehlereinträge überprüfen und gegebenenfalls korrigieren müssen.

2.2 Qualitätsarbeit – Quo vadis?

Visual Analytics: Enabler für wertschöpfungsorientierte Datenanalyse

Die Relevanz gezielter Nutzung und Analyse von Daten erfährt in den letzten und nächsten Jahren ein deutliches Wachstum und hat sich unter dem Terminus Big Data bzw. Data Analytics etabliert (Albertson 2018). Das hat dazu geführt, dass sich zahlreiche und gänzlich neue Geschäftsmodelle und Themen wie Datensicherheit und -transparenz zu zentralen Fragestellungen in Gesellschaft und Industrie entwickelt haben, wenngleich im Kontext der Produktion nicht mit Kundendaten gearbeitet wird. Ein Weg für die BMW Group, hierzu einen Beitrag in der Produktion zu leisten, ist, die Datenanalyse möglichst nah an den Ort der Wertschöpfung zu bringen. Das hat den entscheidenden Vorteil, dass die Produktionsspezialisten ihre Datenanalyse eigenverantwortlich durchführen und entsprechende Handlungsempfehlungen ableiten können.

Das primäre Problem manifestiert sich hierbei jedoch häufig in fehlendem Know-how, was das Thema Data Analytics angeht. Produktionsmitarbeiter gelten als absolute Domänenexperten innerhalb der komplexen Prozesse einer hochflexiblen Automobilproduktion. Eine Option hierbei ist, diese Mitarbeiter entsprechend zu schulen und für die Datenanalyse zu qualifizieren. Angesichts der Erkenntnis, dass ein Mensch nur begrenzte Fachgebiete als Spezialist erlernen kann, verfolgt die BMW Group einen anderen Ansatz: Ziel ist es, neben der Vermittlung eines Grundverständnisses zur Datenanalyse, die Komplexität einer Data-Analytics-Applikation zu reduzieren, sodass diese am Ort der Wertschöpfung möglichst gering ist und damit ebenfalls der Schulungsaufwand reduziert wird. Genau diesem Ansatz sog. Self-Service Analytics hat sich vor allem die Visual Analytics verschrieben. Dieses wissenschaftlich verhältnismäßig junge Fachgebiet weist eine immer höher werdende Relevanz in Forschung und Praxis auf. Unter Visual Analytics wird die Wissenschaft verstanden, die analytisches Denken durch interaktive

visuelle Schnittstellen erleichtert (Keim et al. 2008). Zentrale Aspekte sind dabei also die geeignete Visualisierung von Daten sowie eine entsprechend intuitive Interaktion durch den Anwender.

In der konkreten Anwendung in der Produktion steht bei der BMW Group neben Anwendungen aus der Instandhaltung die Qualitätsarbeit im Fokus. Durch die bereits erwähnte Komplexität eines hochflexiblen Produktionssystems wird die Sicherstellung von Premiumqualität zur zentralen Herausforderung. Neben der Fehlerprävention durch Methoden der schlanken Produktion kommt der Fehlerdetektion sowie Ursachenfindung eine immense Bedeutung zu. Das gilt vor allem in der personalintensiven Montage, in der etwa jede Minute ein neues kundenindividuelles Fahrzeug hergestellt wird.

In der folgenden Abb. 1 ist ein mögliches Layout eines interaktiven Dashboards exemplarisch dargestellt. Durch die simple Darstellung und Interaktion kann die Zeit der Ursachenfindung durch den Mitarbeiter deutlich reduziert werden. Während in der oberen Abbildung der Ausgangszustand demonstriert wird, zeigen die Abbildungen von unten links nach unten rechts die jeweiligen Iterationsschritte der Interaktion. Der Produktionsmitarbeiter kann sich Schritt für Schritt durch die verschiedenen Sichten




Abb. 1 Interaktives Dashboard zur Datenanalyse im Self-Service (fiktive Zahlen)

klicken und die kritischsten Bereiche intuitiv auswählen und damit einen Ursachenbereich eingrenzen.

Es spielen dabei verschiedene Dimensionen in der Qualitätsarbeit – insbesondere im Fall der Montage – eine zentrale Rolle. So ist es z. B. von Interesse, um welches Fahrzeug bzw. Modell es sich handelt, wann es wo in der Produktionslinie steht, welche Charakteristik ein möglicher Fehler hat oder auch wo bzw. an welchem Bauteil ein Fehler aufgetreten ist. Durch die Interaktion mit den Qualitätsdaten kann innerhalb von Sekunden der entsprechend für den Produktionsmitarbeiter relevante Bereich gefiltert werden. So kann beispielsweise der Fokus auf ein neu anlaufendes Modell, eine spezielle Baugruppe oder auch ein bestimmtes Zeitfenster gelegt werden, um die Entwicklung der Fehlerdimensionen effizient zu analysieren.

Künstliche Intelligenz: Deep-Learning-basierte Objektdetektion

Eine innovative Technologie zur Bildverarbeitung bietet KI. Das sog. Deep Learning (Goodfellow et al. 2016) setzt auf künstliche neuronale Netze, um z. B. die Aufgaben Klassifizierung, Objekterkennung oder Segmentierung auf Fotos zu leisten (Yao et al. 2012). Bei der Anwendung neuronaler Netze ist zwischen Trainingsphase und Produktivphase – „inference“ – zu unterscheiden (Park et al. 2018).

Beim Training wird ein Datensatz an Fotos aufgenommen. Anschließend müssen sämtliche Fotos gelabelt werden. Aufgabe beim Labeling ist es, die vorliegenden Fotos mit Metainformationen im Sinn eines digitalen Etiketts zu versehen (Russell et al. 2008). Im Anschluss werden die Gewichte im neuronalen Netz automatisch über Tausende Kalkulationsschritte so modifiziert, dass das Netz die Trainingsdaten möglichst ideal detektiert. Diese Kreation des angepassten Netzes unterstützen Frameworks wie Tensorflow, Digits oder andere (Marburg und Bigham 2016). Eine Vielzahl der Frameworks und Architekturen für neuronale Netze sind heutzutage gratis als Open Source verfügbar. Dabei ist eine sehr hohe Dynamik zu konstatieren, da sich internationale Forscher und Unternehmen an der Weiterentwicklung beteiligen und ihre Ergebnisse online veröffentlichen („object detection“).

Um den Live-Betrieb einer KI vorzubereiten, erfolgt ein Test des Netzes auf unbekannten Daten. Sofern dieser Test ein hinreichend robustes Ergebnis nachweist, kann das Netz für den Produktivbetrieb eingesetzt werden. Bei der Aufnahme der Trainingsfotos ist der Datensatz so zu gestalten, dass die Variation von Positionierung, Orientierung, Fokussierung, Beleuchtung, Farbe, Reflektion etc. ein möglichst realistisches Spektrum abdeckt. Diese Parameter sind bei der Datenaufnahme also so zu variieren, dass sie die im späteren Livebetrieb erwarteten Schwankungen umfassen. Je nach Schwierigkeit der Erkennungsaufgabe sind mindestens Hunderte Fotos pro Merkmalsausprägung als Grundlage erforderlich, um ein robustes neuronales Netz zu kreieren.

In der Praxis erweisen sich solche neuronalen Netze als besonders leistungsfähig: Die Robustheit hinsichtlich der oben genannten Bedingungen liegt deutlich über der von Kameraportalen, die sich auf konventionelle Bildverarbeitung stützen. Die Anzahl

der Pseudofehler lässt sich in zahlreichen Applikationen auf Null reduzieren. Für die Produktion bieten derart robuste Lösungen den Vorteil, dass sie eine präzise Qualitätsaussage liefern und Vorarbeiter deshalb nicht binden. Außerdem bietet sich die Option, Kontrolltätigkeiten zu automatisieren, die heute nur manuell ausgeführt werden können. Solche KI-Lösungen erlauben eine nahezu beliebige Variation der Parameter für Fotos.

So wurden unter anderem folgende visuelle Inspektionen im Produktionssystem der BMW Group mittels KI realisiert:

- Objektdetektion der Modellschriftzüge: Eine KI überprüft, ob der tatsächlich montierte Modellschriftzug am Heck des Fahrzeugs, z. B. 540i, zu 100 % mit der jeweiligen Kundenorder übereinstimmt (Abb. 2).
- Echtzeitrisserkennung im Presswerk: Mithilfe eines neuronalen Netzes wird binnen Millisekunden überprüft, ob ein umgeformtes Bauteil Mikrorisse aufweist. Dabei muss absolut zuverlässig zwischen Rissen und unkritischen Merkmalen wie Öltropfen, Metallspänen oder Staubpartikeln differenziert werden (Abb. 2).
- Steuerung von Leergut: In einer Logistikapplikation entscheidet eine KI, ob Leergut aus einer einzigen großen Kiste oder mehreren kleinen Boxen besteht, die vor dem Transport verzurrt werden müssen.
- Überprüfung des Fahrzeuginnenraums: In der Produktion muss sichergestellt werden, dass bestimmte Objekte wie Verbandskasten oder Warndreieck im Fahrzeug vorhanden sind. Hier unterstützt eine KI die entsprechende Inspektion.
- Detektion von kleinen Objekten wie Schrauben, Kappen oder Stopfen.




Abb. 2 Künstliche Intelligenz im BMW-Produktionssystem – Detektion der Modellschriftzüge (links; BMW Group 2019b), Risserkennung im Presswerk (BMW Group 2019a)

3 CSR in Visual Analytics und künstlicher Intelligenz

Für die BMW Group spielen gesellschaftlich verantwortliches Handeln und Nachhaltigkeit eine große Rolle – im Produkt selbst wie in sämtlichen Unternehmensprozessen und der gesamten Wertschöpfungskette. Dieser Abschnitt arbeitet daher anhand der eingangs skizzierten Leitfragen heraus, wie sich die CSR im BMW-Produktionssystem darstellt.

Data Analytics wird im Produktionssystem der BMW Group vornehmlich appliziert, um die Qualitätsarbeit zu optimieren und die Instandhaltung so zu verbessern, dass ungeplante Maschinenstillstände vermieden werden. Hauptanwendungsgebiet in der Qualität ist die Reduktion von Nacharbeitsaufwänden.

Im Folgenden wird ein Überblick über die gezielten Maßnahmen gegeben, die die BMW Group im Kontext der digitalen Innovationen zur Optimierung der Qualitätsarbeit initiiert hat. Der Aufbau des Abschnitts orientiert sich an den Leitfragen zur CSR.

3.1 Wie verändert sich unternehmerische Verantwortung durch den Einsatz von Data Analytics und künstlicher Intelligenz?

Der Nutzen von KI in der Produktion manifestiert sich unter anderem in der effizienten Analyse von (semi-)strukturierten Massendaten und einer robusten Bildverarbeitung. Somit lassen sich z. B. Qualitätsinspektionen auf einem besonders stabilen Niveau automatisieren. Der unmittelbare Mehrwert für das Produktionssystem liegt dabei in einer minimalen Quote an Scheinfehlern bei gleichzeitiger Detektion aller Komponenten, die nicht in Ordnung sind. Hier erweisen sich KI-Systeme wie neuronale Netze als überlegen – gegenüber konventioneller Software zur Bildverarbeitung sowie dem Menschen. Für direkte Produktionsmitarbeiter bedeutet dieser technologische Fortschritt durch KI einerseits, dass sie von unbeliebten Kontrolltätigkeiten entlastet werden können, die bislang manuell durchgeführt werden mussten. Andererseits mündet die Eliminierung von Pseudofehlern für die Vorarbeiter in mehr Zeit – sie müssen nicht länger Produkte suchen, um sie zu inspizieren und Fehlereinträge zu löschen. Damit können sie sich ihren eigentlichen Aufgaben widmen und z. B. die Mitarbeiter am Band unterstützen. Insgesamt schlägt sich eine präzise Qualitätsauditierung in einem noch höheren Bewusstsein für Qualität nieder, da Scheinfehler nicht länger für Ablenkung sorgen. Eine hohe Scheinfehlerrate etwa mündet in Nachlässigkeiten in der Endkontrolle, da ein gewisses Maß an Frustration einsetzt. In den konkreten KI-Anwendungen der BMW Group wird zyklisch das Feedback der Anwender aus der Produktion eingeholt. Das Feedback fällt ausschließlich positiv aus, da Fertigungsmitarbeiter nicht mit monotonen Kontrollaufgaben betraut sind, sondern stattdessen wertschöpfende Aufgaben übernehmen können. Dazu zählen beispielsweise direkte Montagetätigkeiten, Prozessverbesserung oder die Unterstützung bei der Integration neuer Fahrzeuge. Zusätzlich berichten die involvierten Mitarbeiter von gesteigerter Motivation.

Elementar für den vertrauensvollen Einsatz von Systemen der KI ist eine sorgsame Selektion der Applikation. Es ist von entscheidender Bedeutung, den Anwendungsfall so auszuwählen, dass er den Mitarbeitern einen unmittelbaren Mehrwert stiftet, der ihnen sofort transparent ist.

Damit KI für Produktionsmitarbeiter oder sonstige Anwender, deren Beschäftigungsfeld abseits der Mathematik oder Informatik liegt, anwendbar wird, müssen sie den Prozess und die grundsätzliche Funktionsweise von KI kennenlernen und in den Grundzügen verstehen. Die KI-Anwendung muss einfach gestaltet werden. In der konkreten Anwendung der Objekterkennung bedeutet dies zum einen, die Anwender aus der Produktion müssen den Trainingsprozess zur Modellierung eines neuronalen Netzes verstehen – inklusive der Anforderungen, die daraus an Trainingsfotos und Label resultieren. Zum anderen wird ein IT-Werkzeug benötigt, das es den Mitarbeitern erlaubt, das Labeling in einer für sie intuitiven Weise durchzuführen. Es ist von eminenter Wichtigkeit, dass jeder Mitarbeiter in die Lage versetzt wird, KI selbst anzuwenden, sodass er die spezielle KI für seinen bestimmten Anwendungsfall aufbauen und erproben kann, um selbst zu entscheiden, ob er sie einsetzt. Die BMW Group hat deshalb ein eigenes Labeling Tool entworfen, das jedem Mitarbeiter zur Verfügung steht. Der Prozess der Softwareentwicklung wurde dabei agil gestaltet. Im Zuge dessen wurden die Pilotanwender aus der Produktion permanent in die Softwareentwicklung integriert. Mithilfe ihres kurzzyklischen Feedbacks wurde ein System entworfen, das besonders leicht zu bedienen ist. In diesem Punkt steht der Self-Service-Gedanke für Produktionsmitarbeiter an oberster Stelle. Die Logik ist es, Fertigungsmitarbeiter bewusst nicht über monatelange Schulungen in Data Scientists zu verwandeln, sondern die IT-Systeme so zu gestalten, dass jene Mitarbeiter sie sofort ohne Schulungsaufwand bedienen können. So unterstützt die Technologie alle direkten Produktionsmitarbeiter, wobei sie ihre Systeme selbst aufbauen können.

Jede technologische Innovation, die die Automation von Prozessen zu leisten vermag, muss hinsichtlich der Implikationen für Arbeitsplätze diskutiert werden. Die vorgestellten Anwendungen zeigen, dass sich mit KI neue Möglichkeiten der Automation ergeben. Es liegt in der Verantwortung der Unternehmen, solche Lösungen gewinnbringend und nachhaltig zu nutzen. Dies bedeutet, dass sie Anwendungsfälle so auswählen müssen, dass KI einen prozessualen Mehrwert stiftet und die Mitarbeiter unterstützt. Im BMW-Produktionssystem gilt: „Technik dient dem Menschen“. Anhand dieser Grundidee lassen sich alle potenziellen Einsatzszenarien kategorisieren. Konkret wird also KI dort eingesetzt, wo sie den Menschen unterstützt – sei es, weil sie eine höhere Robustheit, niedrigere Fehlerquote aufweist oder ihn von ermüdenden, langweiligen Tätigkeiten entlastet. KI kann so dazu beitragen, eine für den Menschen ideale Arbeitsteilung zu realisieren, wobei IT-Systeme oder Maschinen die repetitiven, monotonen, physisch beanspruchenden Aufgaben übernehmen, während die Menschen kreative, wertschöpfende Prozesse bearbeiten. Die BMW Group verfolgt den Ansatz, dass nur der Mensch Produkte mit den Augen des Kunden sieht. Deshalb werden Menschen immer in Prozessen arbeiten, die Feingefühl und Finesse erfordern.

Als wesentliche Befähiger, weshalb KI heute in der Breite in Anwendungen findet, können neben der Verfügbarkeit von kosteneffizienten Speichern und Mehrprozessoren die Leistungsfähigkeit von KI-Frameworks und die Vielzahl an vortrainierten neuronalen Netzen erachtet werden. Eine zentrale Position nimmt dabei der Gedanke des Open Source ein: Eine Vielzahl von leistungsfähigen Frameworks zur Erstellung einer KI finden sich frei verfügbar im Internet (Github [2020](#)). Der Wettbewerb zwischen Forschern und Unternehmen bringt dabei fast wöchentlich leistungsfähigere Weiterentwicklungen hervor („object detection“). Für einen IT-Spezialisten ist die Anwendung einer KI mithilfe dieser vorgefertigten Lösungen besonders schnell möglich. Grundlegende Technologie dahinter ist das Transfer Learning, was sich dadurch auszeichnet, dass der Anwender ein neuronales Netz nicht von Grund auf trainieren muss, sondern dass er ein vortrainiertes Netz mithilfe eines Framework anpasst (Tan et al. [2018](#)). Dabei werden im Allgemeinen signifikant weniger Trainingsdaten benötigt.

Zum nachhaltigen Handeln gehört für die BMW Group, dass sie KI-Systeme verantwortungsbewusst in der Produktion appliziert. Nachhaltigkeit im Kontext der KI heißt für die BMW Group darüber hinaus, dass sie Softwarebausteine nicht nur Open Source bezieht, testet, nutzt oder weiterentwickelt, um BMW-Mitarbeitern den optimalen Zugang zu KI zu ermöglichen, sondern auch, dass sie die eigenen Weiterentwicklungen veröffentlicht und diese der weltweiten Community zur Verfügung stellt: Die BMW Group hat Teile der KI-Algorithmen, die sie entwickelt hat und in der Produktion einsetzt, auf der Online-Plattform für Open Source Github publiziert (Hemmerle [2019](#)). So ist es Softwareentwicklern auf der ganzen Welt möglich, diese Algorithmen zu beziehen und zu nutzen, die in einem Team aus der Innovationsabteilung der Produktion und dem Innovation Lab der BMW Group IT entwickelt wurden. Inhalt sind sog. Programmierschnittstellen, die dazu dienen, Training und Inference von KI-Modellen zu beschleunigen, sowie das besonders intuitiv zu bedienende BMW Labeling Tool (Kamradt et al. [2020](#)). Die BMW Group hat diese Softwarebausteine gezielt online veröffentlicht, um sie einer breiten Masse an Anwendern zugänglich zu machen und damit einen Beitrag zur Open-Source-Gemeinschaft und zur Demokratisierung von KI zu leisten. Zugleich kann die große Gruppe an Testern Verbesserungspotenzial aufzeigen und Impulse zur Weiterentwicklung der Algorithmen einbringen. Unabhängig von der Softwareentwicklung bei BMW können Dritte diesen Code nutzen und individuell erweitern. Ziel ist es also zum einen, der Entwicklergemeinschaft etwas zurückzugeben und Verantwortung zu übernehmen. Zum anderen möchte die BMW Group mit diesem Schritt weitere Firmen ermutigen, genauso verantwortungsvoll zu handeln und Software öffentlich zugänglich zu machen. Die Vision der BMW Group ist es, KI-Algorithmen soweit zu vereinfachen, dass ein Anwender ohne IT-Expertise in die Lage versetzt wird, seine eigene KI aufzubauen – mit nur einem Klick – so wie man heute Bürosoftware installiert. Wenn Entwickler Schnittstellen zu weiteren leistungsfähigen KI-Frameworks erarbeiten und publizieren, wird schon in naher Zukunft die Anwendung von KI noch weiter vereinfacht und beschleunigt.

3.2 In welcher Form setzt sich die BMW Group mit den Konsequenzen und Möglichkeiten von künstlicher Intelligenz auseinander? Wie wird mit den potenziellen Risiken umgegangen; welche Lösungsansätze bestehen hier?

Im Prinzip schreibt der KI-Anwender keine Software mehr, sondern die KI optimiert sich selbst. Dies hat den Vorteil, dass neuronale Netze beispielsweise anpassungsfähig sind und unter verschiedensten Bedingungen robust arbeiten. Die Optimierung eines neuronalen Netzes während des Trainingsprozesses geschieht üblicherweise über mehrere Hunderttausend Rechenschritte. In der Folge ist es schwierig bis unmöglich, nachzuvollziehen, weshalb sich ein KI-System in einer bestimmten Art und Weise verhält. Daher kommt dem Test einer KI vor dem produktiven Einsatz besondere Relevanz zu. Die BMW Group appliziert KI im Produktionssystem für Anwendungen unterschiedlicher Kritikalität. Immer gilt: Je kritischer die geplante Anwendung ist, desto ausführlicher muss der Test vor dem Betrieb ausfallen. Für sämtliche Qualitätsaspekte hat die BMW Group den unternehmenseigenen Bewertungsindex (BI) etabliert. Dieser ordnet qualitätsbezogene Merkmale zwischen BI 8 (exzellent) und BI 1 (inakzeptabel) ein, wobei drei Kritikalitätsabstufungen vorgenommen werden. Beim Trainingsprozess versucht die KI, sich möglichst gut an den Trainingsdatensatz anzupassen. Daher ist es wichtig, einen unabhängigen Testdatensatz vorzubereiten, um die Performanz der KI auf diesen unbekannten Daten zu evaluieren. Vor einem Produktiveinsatz stellt die BMW Group zusätzlich je einen sogenannten Heißtest an, um die Leistungsfähigkeit unter realen Bedingungen zu erfahren. Ein zentrales Werkzeug bei all diesen Test ist die sog. Wahrheitsmatrix („confusion matrix“; Patro und Patra 2014; Abb. 3). Wesentlich für die Applikation von KI-Systemen im BMW-Produktionssystem ist dabei, dass auf keinen Fall Prüfschlupf („false negatives“) auftreten darf. In zweiter Linie wird eine minimale Anzahl an Pseudofehlern angestrebt.

Nur wenn dieser Heißtest erfolgreich verläuft, wird die KI appliziert. Andernfalls werden zusätzliche Trainingsdaten aufgenommen und die Phase der Modellierung erneut durchlaufen oder neuronale Netze gänzlich für den speziellen Anwendungsfall verworfen. Um den Spezifika je Fertigungsbereich Rechnung zu tragen, hat die BMW Group jeweils einen Eignungstest definiert, im Rahmen dessen die Überprüfung des neuronalen Netzes vorgenommen wird. Neben der strukturierten Abnahme und der anwendungsadäquaten Definition von Testprozeduren ist eine zyklische Nachkontrolle von KI-Lösungen anzustellen, um mögliche negative Trends zu erkennen. Neben diesen technischen und organisatorischen Maßnahmen beschäftigt sich die BMW Group intensiv damit, wie innovative Lösungen zur Absicherung von KI-Algorithmen gestaltet werden können.

Um das Verhalten von KI-Systemen weitestgehend zu kontrollieren, verzichtet die BMW Group bewusst auf den Einsatz des sog. Reinforcement Learning (Li 2108; bei dieser Methode wird ein neuronales Netz parallel zum Betrieb weiter modifiziert). Ein




Abb. 3 Confusion Matrix zur Bewertung von Künstliche-Intelligenz-Modellen

einmal trainiertes Netz, das im BMW-Produktionssystem live appliziert wird, kann sich dementsprechend nicht selbstständig verändern. Folglich ist für jede Anpassung ein aktiver Eingriff eines Mitarbeiters erforderlich – sei es die Integration eines weiteren Merkmals oder das Anlernen eines neuen Produkts. Entsprechend sauber ist der Prozess von Training und Adaption von KI-Systemen in die Produktionsplanung integriert. So wird sichergestellt, dass zum Produktionsstart eines neuen Produkts die Qualitätssysteme aktuell und stabil sind.

Grundsätzlich impliziert KI in gewissem Maß Blackbox-Systeme: Es ist im Allgemeinen schwer möglich, das präzise Verhalten einer KI während des Trainingsvorgangs vorherzusagen oder die Entscheidungswege transparent nachzuvollziehen. Der Fachterminus des nichtdeterminierten Verhaltens beschreibt in diesem Kontext, dass derselbe Trainingsdatensatz unter denselben Randbedingungen in verschiedene neuronale Netzen münden kann (Nagarajan et al. 2018). Um KI insbesondere für kritische Prozesse anwendbar zu machen, arbeitet die BMW Group auch an der Erklärbarkeit von KI-Systemen. Ziel ist es, das Anwendungsspektrum auf solche Problemstellungen zu erweitern, die aufgrund des Risikograds oder eines zu kritischen Bewertungsindex bisher ausschließlich von Menschen übernommen werden.

Unabhängig von den Testprozeduren und der Verständlichkeit von KI gibt es technische Limits, die eine wesentliche Rolle spielen. Heute interessieren sich Qualitätsspezialisten in der Produktion für eine KI-Applikation, die beispielsweise die Detektion von kleinsten Anomalien wie Beschädigungen auf Oberflächen präzise leistet. Zum verantwortungsbewussten Handeln zählt in diesem Zusammenhang auch ein seriöses Erwartungsmanagement. Eine äußerst anspruchsvolle KI-Applikation birgt entsprechende Risiken: Einerseits ist die technische Realisierbarkeit hier überhaupt nur

gegeben, wenn ein immenser Datensatz aggregiert werden kann. Dies mündet in Aufwand zur Sichtung und Sammlung von Fotos aus bestehenden Systemen, Aufnahme zusätzlicher Fotos und zur bewussten Simulation von Fehlern. Im Anschluss wird das Labeling gleichermaßen umfangreich ausfallen. Andererseits garantiert ein besonders umfangreicher Datensatz keine hundertprozentig robuste Applikation. Aktuell besteht kein theoretisches Rahmenwerk, wie die Erfolgsaussichten in solchen Fällen zu taxieren sind. Zentral ist ergo zum einen die Kompetenz, zu beurteilen, welche potenziellen Anwendungsfälle realisierbar sind, und zum anderen die Transparenz gegenüber allen Interessensgruppen, dies zu kommunizieren.

3.3 Was bedeutet künstliche Intelligenz für die (globale) Wertschöpfung des Unternehmens und die Strategie und wie verändert sich dadurch die gesellschaftliche Verantwortung des Unternehmens?

Die Umsetzungen von Data Analytics und KI im BMW-Produktionssystem zeigen, dass diese Innovationen einen signifikanten Mehrwert in der Optimierung der Qualitätsarbeit leisten. Einige der realisierten Applikationen sind neben den eingeführten Technologien des Automobilbaus unmittelbar auf weitere Gebiete transferierbar. Einerseits bestehen wertschöpfungsketten- und branchenübergreifend ähnliche Herausforderungen in der Datenvisualisierung. Andererseits passen die KI-Lösungen in Bereiche wie After Sales, Wareneingangskontrolle bei Lieferanten genauso wie bei Leasing- oder Mietrücknahmen. Data Analytics und KI sind ergo entlang der gesamten Wertschöpfungskette anwendbar – aufseiten des Herstellers wie auch bei sämtlichen Lieferanten. Insbesondere die Metabenefits wie die Erleichterung der Qualitätsarbeit mittels Visual Analytics und die außergewöhnlich robuste Qualitätsauditierung mittels Deep Learning sind unabhängig von der Fertigungsstufe oder dem Veredelungsgrad eines Produkts in identischer Art und Weise anwendbar.

Darüber hinaus sind die Methoden der KI für weitergehende Applikationen in der Bildverarbeitung wie semantische Segmentierung und die Generierung von artifiziellen Fotos geeignet. Zusätzlich bietet sich in der automatisierten Analyse von Massendaten mit verschiedenem Level an Struktur ein großes Einsatzfeld für KI. So ist KI prädestiniert für moderne Fragestellungen der Advanced Analytics wie Analyse von Texten, Chatbots, Mustererkennung – seien es Anomalien in Transaktionen oder Auffälligkeiten in Maschinenzuständen.

Die globale Wertschöpfung muss auch vor dem Hintergrund der Software für Business Intelligence und des Trainings einer KI analysiert werden. Alle relevanten und leistungsfähigen Frameworks zur Kreation von KI-Modellen stammen aus den USA und China. Derzeit existiert kein hinreichend wettbewerbsfähiges Pendant aus Europa.

Wenngleich ein Framework allein keine Garantie für anwendungsadäquate KI bietet, besteht hier dennoch die Gefahr einer Abhängigkeit. Einerseits ist es daher für die BMW

Group relevant, Know-how aufzubauen, wie man zu im spezifischen Kontext guten KI-Systemen gelangt. Andererseits wurden für das BMW-Produktionssystem sämtliche kritischen Bausteine strukturiert analysiert, um jeweils eine Make-or-Buy-Entscheidung zu treffen. Die BMW Group erachtet es als elementar, die Hoheit über ihre Daten zu besitzen und diese während sämtlicher Stufen des Prozesses zu Training, Test und Anwendung von KI zu wahren. Dies war der Anlass, weshalb das Labeling Tool intern entworfen und programmiert wurde, anstatt es zuzukaufen. Aus strategischer Sicht ist es für die BMW Group entscheidend, dass sie Fehlerbilder – simulierte wie reale Fehler – ausschließlich selbst sieht und auswertet.

Für die Anwendungen der Visual Analytics wurden kommerziell verfügbare Softwarepakete verglichen. In diesem Rahmen wird eine zugekaufte Lösung der globalen Marktführer eingesetzt, wobei sich die Umsetzungsexpertise immer betriebsintern befindet. Dies heißt, BMW-Mitarbeiter der zentralen Innovationsabteilung erstellen anwendungsspezifische Dashboards. Dazu stimmen sie das Design mit den Nutzern am Shopfloor ab und entwickeln es kontinuierlich weiter. Zugleich wird sichergestellt, dass die Anwendung im Ökosystem der BMW-Konzern-IT lauffähig und betreibbar ist, sodass die zugrunde liegenden Qualitätsdaten nie das Unternehmen verlassen. Mittels einer zentralen Datendrehscheibe sind für die Mitarbeiter bei entsprechender Berechtigung sämtliche unternehmensinternen Daten für die Visualisierung verfügbar.

Um die Forschung zu Data Analytics und KI gezielt zu gestalten, ist die BMW Group aktive Partnerin in Forschungsprojekten. Im Rahmen des Projekts MAI ILQ 2020 beispielsweise werden beide Aspekte beleuchtet. Anhand des exemplarischen Produktionsprozesses Fräsen wird hier auch untersucht, wie der Datenaustausch zwischen Unternehmen partnerschaftlich organisiert werden kann (Buhl 2019). Ferner gestaltet die BMW Group als Gesellschafterin des Deutschen Forschungszentrums für Künstliche Intelligenz (DFKI) die KI-Forschung hierzulande aktiv. Neben der Entscheidung für eine BMW-interne Intranet-of-Things-Plattform für die Produktion und dem unternehmensübergreifenden Austausch von Daten und Softwarebausteinen hat sich BMW klar zur Initiierung eines digitalen europäischen Ökosystems bekannt und ist Gründungsmitglied der Initiative Gaia-X (Koch et al. 2020).

3.4 Welche Kooperationen sind erforderlich und wie wird mit den unterschiedlichen Zugängen zu Verantwortung und Nachhaltigkeit umgegangen?

Die Vielzahl an leistungsfähigen Frameworks für KI und nahezu alle modernen Netzarchitekturen finden sich als Open Source. Zum einen bedeutet dies große Chancen und niedrige Eintrittsbarrieren für Anwender jeglicher Branche, zum anderen erfordert es Stand heute Experten, die in der Lage sind, diese Lösungen so aufzusetzen, dass sie für Endanwender nutzbar sind. Die Einrichtung von Hard- und Software inklusive Installation der Treiber und das Debugging gestalten sich derzeit in den meisten Fällen nicht trivial.

Neben den Open-Source-Angeboten haben IT-Provider kommerzielle KI-Produkte entwickelt, die sie vorzugsweise via Cloud verfügbar machen. Dabei repräsentieren die großen amerikanischen Softwarekonzerne die Marktführer. Diese Produkte sind typischerweise an ein Geschäftsmodell gekoppelt, in dem die jeweilige Cloud eine zentrale Position einnimmt. Da diese professionellen Cloud-Anwendungen als schlüsselfertige Produkte instantan genutzt werden können, sind sie beispielsweise für schnelle Machbarkeitsstudien oder eine grobe Aussage hinsichtlich der mit einem gegebenen Datensatz erreichbaren Konfidenz oder Robustheit prädestiniert. Als Endanwender sind bei einer Entscheidung über den produktiven Einsatz solcher kommerziellen Angebote die Kosten pro Anwendungen von elementarer Bedeutung. Zusätzlich gilt es, die strategisch relevante Problematik des Lock-ins zu beachten – sobald eine Abhängigkeit von einem Lösungsanbieter bei Produktivsystemen entsteht, kann sich dies ungünstig auf die Preisentwicklung auswirken. Parallel besteht aufgrund hoher Transaktionskosten keine wirtschaftliche Option, den Anbieter zu wechseln. Darüber hinaus spielt der Informationsschutz eine wesentliche Rolle. Unabhängig von der konkreten IT-Implementierung bzw. Lösung muss das geistige Eigentum vor dem Zugriff durch Dritte geschützt werden. Dies ist besonders relevant, wenn im Rahmen der Trainings- oder Produktivphase einer KI-Lösung Einblicke in Fertigungsprozesse gewährt oder beispielsweise die erreichte Qualität aufgenommen werden. Daneben muss auch das neuronale Netz, also das KI-Modell selbst, gekapselt werden, sodass es nicht außerhalb des Unternehmens publiziert werden kann.

Wie in 3.1 skizziert, kommt dem Gedanken der Open Innovation gerade bei KI ein wesentlicher Stellenwert zu, da Frameworks und Architekturen für KI als Open Source verfügbar sind. Bei der Publikation von Software ist es von hoher Relevanz, das geistige Eigentum adäquat abzusichern. Auch bei einer solchen Zusammenarbeit mit einer weltweiten Entwicklergemeinschaft gilt es, die unternehmensspezifischen, internen Informationen zu kapseln und vor einem externen Zugriff zu schützen. So sollten beispielsweise nicht die neuronalen Netze selbst veröffentlicht werden, die live in der Produktion eingesetzt werden.

Im BMW-Produktionssystem ist weniger die Auswahl eines speziellen IT-Produkts oder des weltweit besten Frameworks für KI am wichtigsten, denn die informationstechnische Systemintegration. Gerade in diesem Punkt ist es höchstrelevant, dass das Integratorenteam über tiefgehende Expertise auf den Gebieten Produktion, IT, KI, Softwareentwicklung und -betrieb verfügt. Entsprechende Sorgfalt lässt die BMW Group walten, um Partner für die Konzeption, Realisierung und Serienbetreuung von KI im Produktionssystem zu selektieren. Im Zentrum steht bei dieser partnerschaftlichen Zusammenarbeit also der Gedanke, KI im BMW-Produktionssystem end-to-end zu designen. Als außergewöhnlich erfolgreich hat sich z. B. die enge Kooperation mit Accenture erwiesen, im Rahmen derer KI-Anwendungen für die Produktion strategisch priorisiert, konzipiert und umgesetzt wurden. Der End-to-end-Gedanke bedeutet für die Praxis, KI-Systeme müssen für eine breite Masse an Anwendern einfach zu bedienen sein, sie müssen über Schnittstellen robust in die Landschaft bestehender IT-Systeme

integriert und sie müssen betrieben werden. Nur in einer Atmosphäre des gegenseitigen Vertrauens zwischen Kunde und IT-Partner lassen sich Lösungen für die Qualitätsarbeit in der Produktion realisieren.

Neben der Software wird der Qualifikation der Fertigungsmitarbeiter, des Managements und der Mitarbeiter in IT und Planung von heute und morgen eine wichtige Rolle zuteil. Die BMW Group engagiert sich daher aktiv in strategischen Kooperationen mit Forschungseinrichtungen weltweit, um die aktuellsten Erkenntnisse zu KI unmittelbar in Unternehmenslösungen einfließen zu lassen. Darüber hinaus investiert die BMW Group in die Förderung von Hochschulpartnern wie der TU München (Pighi 2020), wo sich die BMW Group beispielsweise in Vorlesungen engagiert. Als weitere Säule der Forschung und Entwicklung ist die BMW Group in geförderten Forschungsprojekten aktiv und unterstützt zahlreiche Industrie-Doktoranden im Bereich Data Analytics und KI.

3.5 Welche Anforderungen stellen Data Analytics und künstliche Intelligenz an die Führungskräfte aller Ebenen in der Produktion?

Zentral für die Führungskräfte ist es, die Grundzüge von Data Analytics zu verstehen. Dies umfasst eine Übersicht über die Leistungsfähigkeit, die grobe technische Funktionsweise und die Prämissen. Um das Management in der Breite entsprechend zu informieren und zu schulen, hat die BMW Group daher das Analytics Education and Experience Center konzipiert und im Forschungs- und Innovationszentrum in München eingerichtet. In strukturierten Halbtagsworkshops lernen Führungskräfte dort die technischen Möglichkeiten, die grundsätzlichen mathematischen und informationstechnischen Prinzipien und explizit die Grenzen der aktuell verfügbaren Analytics-Technologien kennen. Für Manager aus der Produktion ist es entscheidend, jeweils herauszufinden, wie sich die verfügbaren digitalen Technologien auf ihren Fertigungsbereich applizieren lassen. Es werden sämtliche Technologien entlang der Wertschöpfungskette betrachtet – Presswerk, Karosseriebau, Lackiererei, Montage, Logistik, Motoren- und Komponentenfertigung, Einkauf und die lokale IT selbst. So werden einerseits sinnvolle Einsatzfelder identifiziert und zugleich wird holistisch betrachtet, welche Implikationen innovative technische Lösungen mit sich bringen.

Weitere relevante Inhalte, die im Rahmen dieses Centers vermittelt werden, sind Datenverfügbarkeit, informationstechnische Systemintegration und Datenqualität. Sämtliche IT-Lösungen für Analytics setzen die Verfügbarkeit der benötigten Daten voraus. In der Praxis erweist sich diese scheinbar banale Prämisse jedoch als Herausforderung. Technische und organisatorische Hürden sind zu überwinden, um Daten in der ursprünglich aufgezeichneten Form zu erhalten. Eine weitere Hürde ist es typischerweise, eine Live-Schnittstelle zu bestehenden IT-Systemen in der Produktion aufzubauen, sodass permanent aktuelle Daten echtzeitnah verfügbar sind. Aus organisatorischer Perspektive

muss der Verantwortliche aus der Produktion die Daten freigeben und einer Anbindung zustimmen. Aufgabe der IT ist es, in diesem Kontext die entsprechende Schnittstelle aufzubauen und zu betreiben. Dabei wird der Systemintegration eine wichtige Rolle zuteil, denn in sog. Brownfield-Werken (Bracht et al. 2018), die bereits seit mehreren Produktgenerationen bestehen und permanent umgebaut werden, weist auch die IT-Landschaft eine gewisse Historie auf. Dies trifft ebenfalls auf die entsprechenden Daten zu. Mithilfe von Visual Analytics und übersichtlichen Dashboards ist eine Option gegeben, auch diese Datenqualität visualisierungsbasiert zu optimieren (Liu et al. 2018). Um das essenzielle Thema der Datenverfügbarkeit strukturell zu befähigen, hat die BMW Group die strategische Entscheidung getroffen, eine Datendrehscheibe für Produktionsdaten aufzubauen. Mit der Entscheidung einher geht die Investition in die entsprechende Plattform als zentralen Zugangspunkt zu Daten.

Ein verantwortungsbewusster Umgang mit Daten schließt auch die klare Definition von Rollen und Rechten ein. Zusätzlich ist die Transformation der Daten vonnöten, sodass diese keine datenschutzrechtlich relevanten Umfänge beinhalten. Die Laufzeit des Analytics Centers ist auf 18 Monate ausgelegt. Ziel der BMW Group ist es, die Führungskräfte in der Breite über Ressortgrenzen hinweg zügig zu informieren.

Im Sektor der KI fokussiert die BMW Group im Produktionssystem im ersten Schritt bewusst die Objekterkennung auf Fotos. Dies ist auch dadurch bedingt, dass ein signifikanter Anteil der Einträge in den Qualitätsdaten auf Scheinfehler zurückzuführen ist. Hier greifen KI und Visual Analytics nahtlos ineinander. Echtzeit-Dashboards befähigen Qualitätsexperten, die in der Qualitätsdatenbank gespeicherten Einträge zu filtern und auszuwerten. Aufgrund der gefundenen Pseudofehler ist ein erstes Ziel von KI die Steigerung der Robustheit und die Reduktion von Scheinfehlern in fotobasierten Qualitätsuntersuchungen. Zudem verlangt das strategische Ziel der Reduktion von Nacharbeit die Verkürzung von Qualitätsregelkreisen – Bauteile dürfen nicht länger falsch verbaut, inspiziert und danach erst nachgearbeitet werden. Zukünftig sollen ausschließlich die korrekten Bauteile montiert werden. Hier leistet die KI-basierte Objektdetektion einen entscheidenden Beitrag.

Für Führungskräfte ist es von eminenter Bedeutung, zu verstehen, was KI-Systeme z. B. mittels Objektdetektion in der Qualitätsarbeit zu leisten imstande sind. Genauso wichtig ist es, den erwarteten Aufwand für einen potenziellen Anwendungsfall abzuschätzen, um eine Ressourcenplanung vorzunehmen, Business Cases seriös zu kalkulieren und Anwendungen zu priorisieren. Dazu wurde im BMW-Produktionssystem ein eigenes Werkzeug entwickelt, mithilfe dessen Produktionsspezialisten und Manager die Machbarkeit einer potenziellen KI-Anwendung analysieren und den Aufwand abschätzen können. Dieses Tool wird fortlaufend weiterentwickelt und um weitere Gebiete wie die Klassifizierung oder Segmentierung von Bildinformationen ergänzt.

Verantwortungsbewusster Umgang mit KI-Systemen bedeutet für die BMW Group auch, alle Systeme so aufzubauen und zu applizieren, dass der Datenschutz für Mitarbeiter jederzeit sichergestellt ist. Einerseits erfolgt die Auswahl eines Standorts in der Produktion vor dem Deployment einer Applikation, also der Live-Schaltung, immer in

Abstimmung mit den Sozialpartnern. Andererseits werden nur diejenigen Daten aufgenommen, die auch benötigt und analysiert werden. Konkret bedeutet dies: In der Montage mit vergleichsweise langen Taktzeiten werden lediglich einzelne Fotos aufgenommen – kein permanenter Videostream. Zudem werden Algorithmen entwickelt, die die Anonymisierung gewährleisten. So befindet sich im IT Innovation Lab beispielsweise Software in Arbeit, um Menschen, die möglicherweise aufgenommen wurden, in Echtzeit aus Fotos oder Frames herauszuschneiden und die entsprechenden Pixel unkenntlich zu machen, wobei der Rest des Fotos erhalten bleibt.

Um die Ebene des Topmanagements von Anfang an von den Vorzügen der KI zu überzeugen und das Projekt in Fachbereich und IT zu beginnen, war der Minimum-Valuable-Product(MVP)-Gedanke (Duc und Abrahamsson 2016) omnipräsent: Im Zuge einer agilen Entwicklung wurden einfache Prototypen in kurzen Zyklen konzipiert, realisiert, getestet und immer wieder demonstriert, um die innovativen KI-Lösungen nachhaltig zu etablieren. Um Entwicklung und weltweiten Roll-out effizient zu gestalten, werden die KI-Innovationen in einer Schachbrettlogik organisiert. In diesem Konzept übernimmt genau ein Produktionsstandort die Federführung für einen bestimmten Anwendungsfall im Sinn des Innovationsführers. Dieser Anwendungsfall wird im agilen Team aus dem Fachbereich, der den Product Owner stellt, und dem Development Team aus dem Innovation Lab vorentwickelt, validiert und standardisiert. Im Anschluss erfolgt der weltweite Roll-out an weitere Standorte. Die stringente Festlegung eines Standorts für jede Applikation vermeidet redundante Aktivitäten. Klare und transparente Kommunikation stellt sicher, dass alle Aktivitäten standortübergreifend synchronisiert bleiben. Bei der Selektion des Entwicklungsstandorts je Innovation ist für die BMW Group die prozessuale Reife entscheidend. Grundprinzip im BMW-Produktionssystem weltweit ist „lean before digital“ – eine Innovation muss dazu dienen, schlanke Prozesse weiter zu verbessern; sie darf nicht zu Verwirbelung von Prozessen oder Kapazitätsengpässen der Wertschöpfung führen. Zusätzlich spielen die Zeitpläne der kommenden Produktintegrationen und der erwartete finanzielle Nutzen eine entscheidende Rolle im Prozess der Priorisierung und Allokation.

Mit dem eingeführten Self-Service-Ansatz für KI-Lösungen im BMW-Produktionssystem geht einher, dass das Management die Verantwortung vollständig in die Hände der direkten Mitarbeiter gibt. Dies impliziert großes Vertrauen, was die Auswahl sowie die robuste Realisierung einschließlich der Funktionstests und des Betriebs anbelangt. Läuft die erste KI-Applikation am Entwicklungsstandort stabil, erfolgt der Roll-out nach dem Motto „copy with pride“. Die digitalen Innovationen finden als Ergänzung zu den Lean-Prinzipien Anwendung, wenn die Produktionsmitarbeiter Wertschätzung für ihre bisherigen Prozessverbesserungen erfahren und sie den Mehrwert der neuartigen Technologien für ihre tägliche Aufgaben spüren. Das Management muss vorleben, dass Digitalisierung kein Selbstzweck ist – es darf niemals ein ineffizienter oder verschwenderischer Prozess digitalisiert werden. Das Management der BMW Group bringt dabei den Produktionsmitarbeitern das Vertrauen entgegen, dass sie diese Innovationen eigenverantwortlich realisieren.

4 Fazit

Digitale Innovationen wie Visual Analytics und KI erweitern den Satz an verfügbaren Werkzeugen zur Optimierung des BMW-Produktionssystems. Die Grundlage der Prozessverbesserung am Shopfloor stellt die schlanke Gestaltung der Produktion dar. Digitalisierung darf zu keiner Zeit als Selbstzweck oder Allheilmittel betrachtet werden. Die vorgestellten Innovationen verlangen ein technisches Grundverständnis der Anwender und bieten dann einen erheblichen Mehrwert in der Qualitätsarbeit für die Produktionsmitarbeiter und das Unternehmen. Visual Analytics bringt den Paradigmenwechsel – weg von umfangreichen Ausdrucken hochaggregierter Kennzahlen hin zu übersichtlichen Dashboards, die es jedem Fertigungsmitarbeiter erlauben, genau die Themen in Echtzeit zu fokussieren und datenbasiert zu analysieren, die für seinen Verantwortungsbereich aktuell von Relevanz sind. Dabei genügt die Einsparung des Papiers nicht nur dem Aspekt der Nachhaltigkeit. Dieser Ansatz der Datenanalyse im Self-Service ermöglicht die Prozessverbesserung in komplexen Produktionssystemen wie der heutigen Automobilfertigung überhaupt. Voraussetzungen sind die (informations-) technische Verfügbarkeit von und der organisatorische Zugang zu Daten.

KI manifestiert sich in wesentlich attraktiveren Produktionsarbeitsplätzen. So erweisen sich Methoden wie die Deep-Learning-basierte Objektdetektion als besonders robust, um Qualitätsmerkmale zu inspizieren. Dadurch, dass derartige KI-Systeme quasi unter beliebigen Umgebungsbedingungen stabil funktionieren, können Lösungen hardwareseitig leichtgewichtiger und damit nachhaltiger gestaltet werden. Darüber hinaus erfolgt via KI eine Verkürzung der Qualitätsregelkreise. Mitarbeiter profitieren so direkt durch optimierte Arbeitsinhalte – sie müssen nicht einige diskrete Merkmale an Fahrzeugen kontrollieren und das Ergebnis in eine Datenbank eintragen oder gar die Resultate konventioneller Bildverarbeitungssysteme nachkontrollieren. Stattdessen können sie sich fortan auf wertschöpfende Fertigungsschritte und die Prozessverbesserung konzentrieren. Da KI-Systeme im Zuge des Trainings einen Aufwand für die Aufnahme und das Labeling der Daten erfordern, ist der initiale Aufwand seriös abzuschätzen und eine Wirtschaftlichkeitsbetrachtung zu vollziehen.

Strategisch sind die fünf Kernwerte für die Kultur der BMW Group entscheidend: Offenheit, Wertschätzung, Vertrauen, Transparenz und Verantwortung. Die Kernwerte gelten für sämtliche Sphären – dies inkludiert selbstverständlich die innovativen Anwendungen von Visual Analytics und KI im BMW-Produktionssystem. Dieser abschließende Abschnitt fasst die konkrete Bedeutung von CSR vor dem Hintergrund dieser fünf zentralen Werte zusammen.

Die BMW Group widmet sich ausgiebig der Information ihrer Mitarbeiter. Gerade bei den Themen Data Analytics und KI ist es entscheidend, Produktionsmitarbeiter, Management und Planung hinsichtlich der mit diesen Technologien verknüpften Vorteile, technischen Grundlagen und Effekte zu instruieren. Durch die offene Präsentation von Nutzen und Aufwand entsteht eine realistische Vorstellung der Leistungsfähigkeit. In den

konkreten Applikationen im BMW-Produktionssystem hat dies eine signifikante Nachfrage der Mitarbeiter nach diesen innovativen Lösungen induziert.

Im BMW-Produktionssystem gilt „lean before digital“. Einerseits kann nur ein schlankes Produktionssystem die Grundlage für Digitalisierung bieten, andererseits finden neuartige Technologien in die nachhaltige Realisierung, wenn sich die Produktionsmitarbeiter wertgeschätzt fühlen und ihre bisherigen Prozessverbesserungen nach den Prinzipien der schlanken Produktion honoriert werden. Zum Aspekt der Wertschätzung gegenüber den Mitarbeitern zählt genauso die anwenderfreundliche Gestaltung und ein besonders intuitiv bedienbares Design der Systeme.

Um die Mitarbeiter mitzunehmen, hat es sich als essenziell erwiesen, die Vorteile von Visual Analytics und KI in groß angelegten Kommunikationskampagnen via Videos und Live-Vorführungen zu demonstrieren. Ferner müssen auch die Führungskräfte die Leistungsfähigkeit der Innovationen seriös kennenlernen. Daneben gilt es, die notwendigen technischen Prämissen sowie aktuelle Limits der Technik klar zu kommunizieren. Ein solches ehrliches Erwartungsmanagement schafft Vertrauen in innovative Technologien. Im BMW-Produktionssystem hat die Kommunikation der ersten erfolgreichen KI-Realisierungen eine immense Nachfrage von Produktionsmitarbeitern nach entsprechenden, innovativen Applikationen ausgelöst.

Bei sämtlichen neuartigen Applikationen nimmt der Mensch die Rolle des Integrators ein. Für die BMW Group bedeutet der Leitspruch „Technik dient dem Menschen“, dass KI oder technische Systeme den Menschen niemals fremdbestimmen. Für Data Analytics bedeutet dies: Ein Algorithmus unterstützt in der Visualisierung und unterbreitet Vorschläge; die finale Entscheidung obliegt dem Menschen. Für KI-Systeme heißt das, dass die KI sich nicht verselbstständigt. Im BMW-Produktionssystem findet kein Reinforcement Learning in einer Form statt, dass die KI sich unkontrolliert autonom weiterentwickelt. So wird das Vertrauen in die Technik aufrechterhalten. Neue Features werden immer über den strukturierten Planungsprozess integriert, von Menschen angelernt und überprüft. Es wird keine vollständige Autonomie von Maschinen geben – der Mensch bleibt die letzte Entscheidungsinstanz.

Mit der Visual Analytics erhalten Fertigungsmitarbeiter die Möglichkeit, Massendaten in einfacher Form selbst zu analysieren. In gleicher Form hat das Management die Chance, Kennzahlen zu untersuchen und möglichen Fehlerursachen auf den Grund zu gehen. Wesentliche Voraussetzung für diese Form der Visual Analytics im Self-Service ist die Transparenz über die entsprechenden Daten. Diese Transparenz hinsichtlich der Prozesse und insbesondere der Qualität verlangt nach einem sorgfältigen Umgang mit den Daten.

Insbesondere der Themenkomplex der KI erlebt eine enorme Dynamik. Neue Algorithmen und Architekturen sind quasi gratis Open Source verfügbar. Zum verantwortungsvollen Umgang zählt für die BMW Group als Nutzer von Open-Source-Software auch, einen Beitrag zu dieser weltweiten Entwicklergemeinschaft zu leisten. Die BMW Group engagiert sich hier im Sinn der Nachhaltigkeit und veröffentlicht ihre entwickelten Programmierschnittstellen, sodass populäre Frameworks noch einfacher

eingesetzt werden können. So möchte die BMW Group auch andere Unternehmen animieren, ähnliche Beiträge zu leisten und zur Demokratisierung von KI beizutragen. Darüber hinaus kann diese Bewegung Entwickler aus Wissenschaft und Wirtschaft motivieren, ihre Algorithmen mit vergleichbar komfortabel gestalteten Programmierschnittstellen auszustatten.

Verantwortungsbewusster Umgang mit KI bedeutet für die BMW Group, dass problemadäquate Testprozeduren definiert werden, um Systeme für den Live-Betrieb in der Produktion abzusichern, die sich durch ihr nicht vollständig deterministisches Verhalten auszeichnen. Bei der Auswahl der Partner spielt deren Einsatz vor allem bei KI eine große Rolle. So ist es entscheidend, wie diese KI entwickeln und absichern. Umso wichtiger ist, wie sie KI offerieren und für welche Zwecke sie diese einsetzen. Die BMW Group ist sich ihrer gesellschaftlichen Verantwortung bewusst. Daher engagiert sie sich aktiv in Forschungsprojekten und Initiativen von deutscher und europäischer Relevanz. Darüber hinaus geht sie gezielte Kooperationen mit Universitäten und Forschungseinrichtungen ein.

Analytics und KI funktionieren nur gemeinsam mit dem Menschen. Daher werden der ansprechenden Gestaltung der IT-Systeme und der gemeinsamen prozessualen Integration höchste Relevanz zuteil. In der Praxis erweist sich die agile Verfeinerung der informationstechnischen Lösungen in enger Abstimmung zwischen Produktion, IT und einer ausgewählten Gruppe an Erstanwendern als sinnvoll.

Technik dient dem Menschen. Nur wenn die Produktionsmitarbeiter den Mehrwert für ihre Prozesse und den positiven Beitrag zu ihrem individuellen Arbeitsplatz sehen, finden diese digitalen Innovationen in die nachhaltige Realisierung.

Literatur

- Albertson M (2018) Software, not hardware, will catapult big data into a \$103B business by 2027. Hg. v. SiliconANGLE Media Inc. Palo Alto, CA. Online verfügbar unter <https://siliconangle.com/2018/03/09/big-data-market-hit-103b-2027-services-key-say-analysts-bigdatasv/>. Zugriffen: 30. Juni 2020
- BMW Group (2019a) Künstliche Intelligenz beseitigt zuverlässig Pseudo-Fehler im Presswerk, BMW Group Werk Dingolfing. Online verfügbar unter <https://www.youtube.com/watch?v=lm9a8Lj4n0o>. Zugriffen: 10. Juli 2020
- BMW Group (2019b) Künstliche Intelligenz identifiziert Modellbezeichnungen im BMW Group Werk Dingolfing. Video. <https://www.youtube.com/watch?v=3mrzSf16yA>. Zugriffen: 14. Juni 2020
- Bracht U, Geckler D, Wenzel S (2018) Digitale Fabrik. Methoden und Praxisbeispiele. 2., aktualisierte und erweiterte Auflage. Springer Vieweg (VDI-Buch), Berlin
- Brunner FJ (2017) Japanische Erfolgskonzepte. KAIZEN, KVP, Lean Production Management, Total Productive Maintenance, Shopfloor Management, Toyota Production System, GD3 – Lean Development. 4., überarbeitete Auflage. Hanser, München (Praxisreihe Qualitätswissen)

- Buhl U (2019) Forschung für die digitale Zukunft. 81 VHB-Jahrestagung – Session Digitale Transformation. Verband der Hochschullehrer für Betriebswirtschaft e.V. (VHB). Rostock, 14.06.2019.
- Deckert F, Krenkel P, Mielke T (2015) Null-Fehler-Prinzip. In: Dombrowski U, Mielke T (Hrsg) Ganzheitliche Produktionssysteme. Aktueller Stand und zukünftige Entwicklungen. Springer Vieweg (VDI-Buch), Berlin, S. 81–95
- Demant C, Streicher-Abel B, Springhoff A (2011) Industrielle Bildverarbeitung. Wie optische Qualitätskontrolle wirklich funktioniert. 3. Aufl. Springer, Berlin
- Deuse J, Schmitt J, Stolpe M, Wiegand M, Morik K (2017) Qualitätsprognosen zur Engpassentlastung in der Injektorfertigung unter Einsatz von Data Mining. In: Gronau N (Hrsg) Industrial Internet of Things in der Arbeits- und Betriebsorganisation. GITO Verlag, Berlin (Schriftenreihe der Wissenschaftlichen Gesellschaft für Arbeits- und Betriebsorganisation (WGAB) e.V.), S 47–61
- Dombrowski U, Krenkel P, Mielke T (2015) Struktur Ganzheitlicher Produktionssysteme. In: Dombrowski U, Mielke T (Hrsg) Ganzheitliche Produktionssysteme. Aktueller Stand und zukünftige Entwicklungen. Springer Vieweg (VDI-Buch), Berlin, S 26–31
- Duc AN, Abrahamsson P (2016) Minimum viable product or multiple facet product? The role of MVP in software startups. In: Sharp H, Hall T (Hrsg) Agile processes in software engineering and extreme programming. 17th International Conference, XP 2016. International Conference XP 2016. Edinburgh, UK, May 24–27. Springer Open, Cahm, Sitzerland, S 118–130
- Ehrlenspiel K, Kiewert A, Lindemann U, Mörtl M (2014) Einflüsse auf die Herstellkosten und Maßnahmen zur Kostensenkung. In: Ehrlenspiel K, Kiewert A, Lindemann U, Mörtl M (Hrsg) Kostengünstig Entwickeln und Konstruieren. Springer, Berlin, S 165–415
- Github Inc. (Hrsg) (2020) Deep Learning. Microsoft. Online verfügbar unter <https://github.com/topics/deep-learning>. zuletzt aktualisiert am 13.06.2020.
- Goodfellow I, Bengio Y, Courville A (2016) Deep learning. MIT Press, Cambridge
- Grüneisl M (2018) Smart Data Analytics und Künstliche Intelligenz. Produktionssystem der BMW Group: Wirksame Anwendungen helfen, Komplexität besser zu beherrschen. In: euroforum (Hrsg) Die Zukunft der Industrie. Digital Smart Vernetzt. Handelsblatt Journal. Handelsblatt Media Group, Berlin, S 15–16
- Hemmerle A (2019) BMW Group teilt Algorithmen der künstlichen Intelligenz in der Produktion. Hg. v. BMW Group. München. <https://www.press.bmwgroup.com/deutschland/article/detail/T0303588DE/bmw-group-teilt-algorithmen-der-kuenstlichen-intelligenz-in-der-produktion?language=de>. Zugriffen: 30. Marz. 2020
- Jochem R (2010) Was versteht man unter Wirtschaftlichkeit von Qualität? In: Jochem R (Hrsg) Was kostet Qualität? Hanser, München, S 27–54
- Kamradt M, El Achkar C, Saller E, Alkazzi J-M, Nassif J, Sleiman J et al (2020) BMW Innovation Lab. Repositories. BMW Group. <https://github.com/BMW-InnovationLab/>. Zugriffen: 10. Juli 2020
- Keim D, Andrienko G, Fekete J-D, Görg C, Kohlhammer J, Melançon G (2008) Visual analytics: definition, process, and challenges. In: Kerren A, Stasko JT, Fekete J-D, North C (Hrsg) Information visualization. human-centered issues and perspectives. Lecture Notes in Computer Science, 4950. Springer, Berlin, S 154–175
- Knaut A (2017) Corporate Social Responsibility verpasst die Digitalisierung. In: Hildebrandt A, Landhäußer W (Hrsg) CSR und Digitalisierung. Der digitale Wandel als Chance und Herausforderung für Wirtschaft und Gesellschaft. Management-Reihe Corporate Social Responsibility. Springer Gabler, Berlin, S 51–59
- Koch M, Hanke T, Kerkmann C (2020) „Moonshot“ Gaia-X – Die wichtigsten Fragen und Antworten zur europäischen Cloud. Hg. v. Handelsblatt Media Group. Düsseldorf. <https://www.handelsblatt>.

- [com/politik/deutschland/datenprojekt-moonshot-gaia-x-die-wichtigsten-fragen-und-antworten-zur-europaeischen-cloud/25888416.html?ticket=ST-4149249-VvyGbqdLdUeYfSIDc5gJ-ap5](https://www.politik.deutschland.datenprojekt-moonshot-gaia-x-die-wichtigsten-fragen-und-antworten-zur-europaeischen-cloud/25888416.html?ticket=ST-4149249-VvyGbqdLdUeYfSIDc5gJ-ap5). Zugegriffen: 07. Juli 2020
- Li Y (2108) Deep reinforcement learning. <https://arxiv.org/pdf/1810.06339.pdf>. Zugegriffen: 30. Marz. 2020
- Liu S, Andrienko G, Wu Y, Cao N, Jiang L, Shi C et al (2018) Steering data quality with visual analytics: the complexity challenge. *Visual Inform* 2(4):191–197. <https://doi.org/10.1016/j.visinf.2018.12.001>
- Majohr D (2008) Optimierung von Vorbehandlungsanlagen in der Automobilindustrie. Universität Rostock. https://rosdok.uni-rostock.de/resolve/id/rosdok_disshab_0000000103
- Marburg A, Bigham K (2016) Deep learning for benthic fauna identification. In: IEEE (Hrsg) OCEANS 2016. Monterey, CA, USA, 19–23 Sept. 2016. Institute of Electrical and Electronics Engineers; Marine Technology Society; Oceanic Engineering Society. IEEE, Piscataway, NJ, S 1–5
- Nagarajan P, Warnell G, Stone P (2018) The impact of nondeterminism on reproducibility in deep reinforcement learning. 2nd reproducibility in machine learning workshop at ICML 2018. Stockholm, Sweden, 14.07.2018. <https://arxiv.org/abs/1809.05676>.
- Object Detection. <https://paperswithcode.com/task/object-detectio>. Zugegriffen: 20. Juni 2020
- Oeltjenbruns H (2000) Organisation der Produktion nach dem Vorbild Toyotas. Analyse, Vorteile und detaillierte Voraussetzungen sowie die Vorgehensweise zur erfolgreichen Einführung am Beispiel eines globalen Automobilkonzerns. Zugl.: Clausthal, Techn. Univ., Diss., 2000. Innovationen der Fabrikplanung und -organisation, 3. Shaker, Aachen
- Park E, Yoo S, Vajda P (2018) Value-aware Quantization for Training and Inference of Neural Networks. In: Ferrari V, Hebert M, Sminchisescu C, Weiss Y (Hrsg) Computer Vision – ECCV 2018. 15th European conference proceedings, Part I. The European Conference on Computer Vision (ECCV). Munich, September 8–14, 2018. Image processing, computer vision, pattern recognition, and graphics, 11205. Springer International Publishing, Cham, S 580–595
- Patro VM, Patra MR (2014) Augmenting weighted average with confusion matrix to enhance classification accuracy. In: *Trans Mach Learn Artif Intell – TMLAI* 2(4):77–91. <https://doi.org/10.14738/tmlai.24.328>
- Pighi M (2020) BMW Group fördert Digitalisierung von Studiengängen an der TU München mit einer Mio. Euro. Hg. v. BMW Group. München. <https://www.press.bmwgroup.com/deutschland/article/detail/T0307747DE/bmw-group-foerdert-digitalisierung-von-studiengaengen-an-der-tu-muenchen-mit-einer-mio-euro/>. Zugegriffen: 10. Juli 2020
- Regber H, Zimmermann K (2009) Change-Management in der Produktion. Prozesse effizient verbessern im Team. 1. Aufl. mi-Wirtschaftsbuch, München
- Richter T, Rico-Castillo M (2015) Standardisierung. In: Dombrowski U (Hrsg) Lean Development. Aktueller Stand und zukünftige Entwicklungen. Springer Vieweg (VDI-Buch), Berlin, S 46–59
- Russell BC, Torralba A, Murphy KP, Freeman WT (2008) LabelMe: A database and web-based tool for image annotation. *Int J Comput Vis* 77(1–3):157–173. <https://doi.org/10.1007/s11263-007-0090-8>
- Tan C, Sun F, Kong T, Zhang W, Yang C, Liu C (2018) A survey on deep transfer learning. In: Kůrková V, Manolopoulos Y, Hammer B, Iliadis L, Maglogiannis I (Hrsg) Artificial neural networks and machine learning – ICANN 2018. 27th international conference on artificial neural networks, proceedings, Part III. ICANN 2018. Rhodes, Greece, October 4–7, 2018. Theoretical computer science and general issues, 11141. Springer International Publishing, Cham, Switzerland, S 270–279
- Töpfer A, Günther S (2007) Steigerung des Unternehmenswertes durch Null-Fehler-Qualität als strategisches Ziel: Überblick und Einordnung der Beiträge. In: Töpfer A (Hrsg) Six Sigma.

- Konzeption und Erfolgsbeispiele für praktizierte Null-Fehler-Qualität. 4th, aktualisierte und erw. Aufl. Springer, Berlin, S 3–40
- Ware C (2004) Information visualization. Perception for design. 2nd ed. Morgan Kaufmann series in interactive technologies, vol 22. Elsevier/Morgan Kaufman, Amsterdam [Netherlands]
- Yao J, Fidler S, Urtasun R (2012) Describing the scene as a whole: Joint object detection, scene classification and semantic segmentation. In: IEEE Computer Society (Hrsg) IEEE conference on computer vision and pattern recognition (CVPR), 2012. CVPR 2012. Providence, Rhode Island, 16 – 21 June 2012. IEEE, Piscataway, NJ, S 702–709
- Zimmermann K (2017) Digitalisierung der Produktion durch Industrie 4.0 und ihr Einfluss auf das Arbeiten von morgen. In: Spieß B, Fabisch N (Hrsg) CSR und neue Arbeitswelten. Perspektivwechsel in Zeiten von Nachhaltigkeit, Digitalisierung und Industrie 4.0, Bd 84. Management-Reihe Corporate Social Responsibility. Springer Gabler, Berlin, S 53–72
- Zipse O (2018) Zeitenwende in der Produktion: Wie Systemintegration zum entscheidenden Wettbewerbsfaktor wird. Münchener Management Kolloquium. TCW Transfer-Centrum; TU München. München, 13.03.2018.

Matthias Schindler ist seit 2018 „Head of AI Innovation“ im BMW Produktionssystem. Seit 2017 verantwortet er in der Abteilung „Innovation, Digitalisierung, Data Analytics“ das Innovationscluster Data Analytics. Die Schwerpunkte bilden neben Künstlicher Intelligenz die Datenanalyse in der Qualitätsarbeit und die prädiktive Instandhaltung. Bis 2016 war er in der Technischen Planung der BMW Group tätig: In der Abteilung „Industrie 4.0“ leitete er das Innovationsfeld 3D-Digitalisierung zur Planung von Integrationen in Brownfield-Fabriken. Dort verfasste er seine Dissertation, eingebettet in das Forschungsprojekt CyProS (Cyber-Physische Produktionssysteme). Seinen Master of Science in Maschinenbau & Management schloss Schindler 2013 an der Technischen Universität München (TUM) ab.

Frederik Schmieling ist seit 2017 in der Abteilung „Innovation, Digitalisierung, Data Analytics“ der BMW Group beschäftigt. Nach einem dualen Studium des Wirtschaftsingenieurwesens verfasste er im Rahmen seines Master of Business Administration & Engineering an der Technischen Hochschule Rosenheim seine Masterthesis in dieser Abteilung. Aufbauend auf dieser, die die Lokalisation kritischer Bereiche im BMW-Produktionssystem zum Ziel hatte, wurde ein Promotionsvorhaben in Kollaboration mit der Technischen Universität Berlin initiiert. Ziel dieses Vorhabens ist die Entwicklung eines Konzeptes, das die Produktionsmitarbeiter mit Hilfe von Visual Analytics befähigt, Datenanalyse zur Qualitätssteigerung unmittelbar am Ort der Wertschöpfung durchführen zu können.



Nüchtern gesehen: Künstliche Intelligenz als neues Werkzeug – mit neuen Regeln

Corina Apachite und Stefan Voget

1 Zeitenwandel durch künstliche Intelligenz

Was ist künstliche Intelligenz (KI)? *Die eine* disruptive, weltumwälzende Technologie schlechthin oder nur eine neue Form der boomenden Software? Bedroht KI den Menschen? Droht sie gar, ihn zu ersetzen? Ist sie Chance oder Risiko oder beides? Der Anfang einer besseren Welt? Hinter solchen Fragen steckt im Kern die Sorge, KI könne dem Menschen etwas aus der Hand nehmen, ihn womöglich entmündigen. Intelligenz, die sich verselbstständigt. Es ist eine Reaktion, wie wir sie in der Technologiesgeschichte immer wieder finden: Wenn eine gewohnte Arbeits- und Lebensweise sich zu verändern beginnt, dann schürt das Ängste vor möglichen negativen Auswirkungen. Man denke an den mechanischen Webstuhl, die Dampfmaschine, das Auto, das Fließband, den Strom, das Smartphone. Hat eine dieser Umwälzungen den Menschen überflüssig gemacht? Nein, im Gegenteil: Prozentual gesehen waren in Deutschland nie mehr Menschen in Arbeit als im aktuellen Zeitalter der Hochtechnologie [1].

Nüchtern gesehen: KI ist eine neue Form eines Systems aus Software und Hardware. Computer dieser Art sind in der Lage, nach dem Vorbild des Menschen erlernte Entscheidungen zu fällen. Eine sehr populäre Methode, wie KI realisiert werden kann, ist das Deep Learning. Beim Deep Learning wird ein antrainiertes System durch sog.

C. Apachite (✉)

Continental, Holistic Engineering & Technologies, Frankfurt, Deutschland

E-Mail: corina.apachite@continental-corporation.com

S. Voget

Continental, Holistic Engineering & Technologies, Regensburg, Deutschland

E-Mail: stefan.voget@continental-corporation.com

© Der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

235

R. Altenburger und R. Schmidpeter (Hrsg.), *CSR und Künstliche Intelligenz*, Management-Reihe Corporate Social Responsibility,
https://doi.org/10.1007/978-3-662-63223-9_12

neuronale Netze dargestellt, die die Arbeitsweise des menschlichen Gehirns imitieren. Im Gegensatz dazu steht das bisherige Verständnis von Software: Algorithmen (Code, Programme) reagieren auf bestimmte Zustände, Signale oder Daten in einer vorgegebenen Weise. Wird ein solcher Code mit einem nicht in der Programmierung als Möglichkeit vorgesehenen Zustand konfrontiert, so kann der Code diesen nicht bewältigen. Je komplexer aber die Aufgabe einer Programmierung wird, desto wahrscheinlicher gerät sie früher oder später in eine nicht vorhergesehene Situation. Für viele Industriebranchen hat KI daher das Potenzial, Lösungen für heute mit Mitteln der programmierten Software nicht lösbare Aufgaben zu finden.

Denn ein Computer mit entsprechenden KI-Algorithmen kann durch Analyse von Datensätzen darin enthaltene Muster und damit Regeln erkennen. Da eine KI in der Lage ist, gigantische Mengen an Datensätzen zu analysieren, kann sie Zusammenhänge entdecken, die für einen Menschen in der Masse der Daten verborgen bleiben. In Teilbereichen (etwa der Klassifizierung von Bildern bzw. Objekten) kann KI sogar eine höhere Leistung erreichen als der Mensch.

Der entscheidende Punkt der KI ist, dass solche Systeme aus Hardware und Software lernfähig sind. In einer Trainingsphase füttert man sie mit riesigen Mengen an Beispieldaten und lässt die KI aus den Resultaten Schlüsse ziehen. Dabei gibt es zwei Möglichkeiten:

- Man kann die Maschine mit unkommentierten Daten versorgen oder
- man versieht die Daten (z. B. Bilddaten) mit Anmerkungen, die der Maschine die richtige Lösung erklären (z. B. „Dies ist ein Fußgänger“). Verwendet man solche annotierten Daten, so spricht man von Supervised Learning.

Anschließend konfrontiert man die KI mit neuen Datensätzen und lässt sie die darin enthaltenen Aufgabenstellungen lösen. Man vergleicht die Ergebnisse und Schlussfolgerungen der Maschine mit den intendierten Ergebnissen und optimiert dann sukzessive die Gewichtung der KI-Entscheidungsfindung. Idealerweise kann die Maschine nach mehreren solchen Feedbackläufen (Backpropagation genannt) in der Execution-Phase Aufgaben lösen, die für sie neu sind und dabei die vorher erlernten Regeln anwenden, um zu einem korrekten Ergebnis zu kommen. Mathematisch gesehen leistet eine KI dabei eine Approximation multidimensionaler Funktionen.

Man unterscheidet zwei Grundformen der KI danach, wie lange die jeweilige Trainingsphase der Software andauert:

- Bei der statischen KI endet die Trainingsphase vor der Implementierung und beispielsweise ihrer Anwendung im Fahrzeug – d. h. die Software beendet ihre Lernphase, ehe sie ihr Wissen im Straßenverkehr anwendet. Die statische KI erscheint für die sicherheitsrelevante Fahrintelligenz als geeignete Ergänzung. Der Entwicklungsprozess verschiebt sich deshalb von der händischen Programmierung hin zur Einnessung, Markierung, Bereitstellung und Speicherung der Trainingsdaten.

- Bei der dynamischen KI endet die Trainingsphase nicht vor der Implementierung im Fahrzeug. Im Gegenteil: Software mit dieser Form der KI lernt auch im Fahrzeug weiter – beispielsweise durch Beobachtung des Fahrers und/oder durch Beobachtung des Erfolgs der eigenen Entscheidungsstrategien. Da sich diese KI ständig weiterentwickelt, ist sie kaum noch systematisch zu überprüfen und freizugeben. Sie erscheint daher als geeignet für Komfort- oder Entertainmentbereiche.

Wirklich neu ist KI nicht: Neuronale Netze und Backpropagation kommen aus den 1980er-Jahren; die Grundlagen für das Reinforcement Learning gibt es schon seit den frühen 1990er-Jahren. Was sich in den letzten Jahren jedoch dramatisch verändert hat, sind die verfügbaren Rechenkapazitäten, die Daten und weiterentwickelte Algorithmen. Die ersten Anwendungen finden sich bei Suchmaschinen und Computerspielen (Gaming). KI-Algorithmen beispielsweise analysieren, wann sich ein Nutzer auf einer bestimmten Webseite aufgehalten hat, welche Inhalte ihn interessiert haben, wo er bei seinem Besuch der Webseite verweilt hat und wo und wann er die Seite wieder verlassen hat. Obwohl ein einzelner Datensatz dieser Art wenig Aussagekraft hat, entsteht durch viele Datensätze eine statistisch aussagekräftige Tendenz, die wiederum dazu dienen kann, Webseiten zu optimieren und Inhalte attraktiv – und im richtigen Kontext zu präsentieren. Natürlich stehen dahinter wirtschaftliche Interessen der Betreiber von Suchmaschinen, die ihre Seiten möglichst anziehend machen möchten. Ist das verwerflich? Wohl schwerlich, denn Nutzer der Suchmaschinen profitieren auch: Sie finden schneller das, wonach sie suchen. Wer sich an den Beginn der Suchmaschinenzeit erinnert, wird bestätigen können: Online-Recherchen führten anfangs längst nicht so schnell und komfortabel zum Ziel wie heute. Das verdanken wir der KI.

KI ist also der Versuch, eine menschliche Fähigkeit – durch Lernen richtige Schlüsse ziehen zu können – an eine dafür optimierte Maschine zu übertragen. Um welche Art von Schlussfolgerung es dabei geht, ist in der Technologie nicht festgelegt. So bewährt sich die KI zwar im Internet und im Gaming, aber sie bietet immenses Potenzial beispielsweise für die Automobilindustrie. Mit KI – und voraussichtlich *nur* mit ihr – lässt sich eine der größten Hürden auf dem Weg zum autonomen Fahren („autonomous driving“, AD) nehmen: die Reaktion auf unvorhersehbare Verkehrssituationen. Der große Treiber heißt also Computer Vision. Damit ist die Fähigkeit einer Maschine bezeichnet, ihre Umwelt richtig zu interpretieren und in ihr zu agieren.

Man erinnere sich: Wir Menschen lernen das Autofahren in der Fahrschule. Dieses Lernen besteht darin, sich Fertigkeiten und Regeln anzueignen und dann die Situationen richtig zu deuten, in denen wir diese im Straßenverkehr korrekt anwenden müssen. Mit KI kann ein Computer darauf trainiert werden, genau diesen Lernprozess anhand von Beispieldaten zu durchlaufen. KI ist also ein System, das fähig ist, „zur Fahrschule zu gehen“ und im Anschluss daran selbst Fahrentscheidungen zu fällen. Für eine Maschine ist das in der Tat eine neue Qualität.

Das Besondere an der KI ist ihre enorme Entwicklungsgeschwindigkeit, die von der gestiegenen Leistungsfähigkeit der neuesten Computergeneration ermöglicht wird. Wieder

hilft ein Rückblick in die Technologiesgeschichte, um den Unterschied zu erahnen. Bei früheren industriellen Revolutionen geschah der Umbruch stets verhältnismäßig langsam. Beispiel Auto: Es dauerte Jahrzehnte, bis aus der Erfindung der motorisierten Kutsche ein Boom wurde. Ähnlich war es mit der Dampfmaschine. Elektronik und Computertechnologie gewannen zunächst nur relativ langsam an Bedeutung im Fahrzeug. Wieder dauerte es Jahrzehnte, bis allein die Software einen Wertschöpfungsanteil von rund 30 % bei Neufahrzeugen erreicht hatte und künftig womöglich bis zu 40 % des Werts ausmachen wird [2].

Inzwischen ändern sich die Dinge: Wie sehr das Internet und das Smartphone unser Leben verändern würden, konnte man vorab nicht kommen sehen. Bei der KI ist das noch ausgeprägter: Es ist diejenige disruptive Revolution, die so schnell voranschreitet, dass wir sie live miterleben. Die KI wird massiv beeinflussen, wie wir arbeiten, wie wir uns Wissen aneignen und aus Erfahrung lernen. Nur unsere eigene Kreativität begrenzt, was wir mit KI werden machen können.

Während die veröffentlichte Meinung zu diesem Thema noch durchaus zwiespältig ist, sieht die Welt für die Industrie eindeutig aus. Hier ist klar, dass die Komplexität heutiger Funktionen ohne KI nicht mehr länger beherrschbar bleiben wird. In der Automobilindustrie haben die großen Systemzulieferer (sog. Tier 1) früh das Potenzial der KI erkannt. Nach einer ersten Phase des Enthusiasmus kam die Einsicht, dass der Einsatz der KI im Fahrzeug so einfach allerdings doch nicht ist. Hier hängen die Früchte höher. Außerhalb der Automobilbranche ist die KI so reif, dass ihre Lösungen direkt nutzbar sind. Beim Einsatz für das Fahrzeug gestaltet sich das wesentlich anspruchsvoller. Trotzdem gilt: Ohne KI wird es nicht mehr gehen.

2 Künstliche Intelligenz als Anteil von Produkten im Automobil

Es ist eine schwer greifbare, weil eher diffuse und auf Misstrauen und Unverständnis gründende Angst, dass KI den Menschen beherrschen könnte. In den nachfolgend beispielhaft genannten Anwendungen in der Automobiltechnologie ist das Gegenteil der Fall: *Die Maschine dient dem Menschen*. So wie sich Smartphones schon von Kindern intuitiv bedienen lassen, so kann KI technische Komplexität hürdenfrei vom Nutzer fernhalten und ihm dadurch dienen. Die Maschine ist dazu da, den Menschen zu unterstützen. Es gilt also, digitale Maschinen zu entwickeln, die das können.

Für die Automobilindustrie und speziell für einen Systemzulieferer wie Continental ist die KI ein mächtiges Instrument. Das wirtschaftliche Umfeld für einen Tier 1 ist ein höchst anspruchsvoller Mix aus industrieller Massenproduktion, hartem Kostendruck, höchsten Qualitäts- und Sicherheitsanforderungen an die Produkte und ständige Investitionen in Forschung und Entwicklung. KI kann sowohl zur Effizienz und Qualität in der Fertigung als auch zur Leistungsfähigkeit von Produkten beitragen.

Im Bereich des assistierten, automatisierten und autonomen Fahrens spielt KI eine Schlüsselrolle. Sie ermöglicht die Computer Vision. Als Grundlage dient das Dreigestirn aus Sensorik, Hardware und Software im Fahrzeug. Heutige Fahrerassistenzsysteme (Advanced Driver Assistance Systems, ADAS) basieren auf einer Kette von logischen Abfolgen: Unterschiedliche Sensorarten (Radar, Kamera, Lidar, Ultraschall) zeichnen Daten der Umgebung auf. Diese werden zusammengeführt (Sensorfusion) und ausgewertet (Modellierung des Fahrzeugumfelds und darin erkannter Objekte). Aus diesen fusionierten Daten sollen nun Fahrentscheidungen abgeleitet werden (von der Software auf einem sehr leistungsfähigen Fahrzeugcomputer). Bisherige ADAS übernehmen solche Entscheidungen im Hinblick auf einzelne eng begrenzte Situationen. Bei einem zu geringen Sicherheitsabstand (etwa durch ein abrupt vor dem eigenen Fahrzeug einscherendes anderes Fahrzeug) reduziert beispielsweise ein adaptiver Tempomat (Adaptive Cruise Control, ACC) selbsttätig die Geschwindigkeit zum Vordermann, bis wieder ein ausreichender Sicherheitsabstand erreicht ist. Solche klar definierten ADAS-Aktionen in einem begrenzten Zustandsraum sind mit programmiertem Code gut realisierbar. Aber was passiert, wenn ein autonom fahrendes Fahrzeug an eine unübersichtliche Kreuzung mit Quer- und Abbiegeverkehr kommt? Die Zahl der möglichen Situationen übersteigt schnell jede vorhersehbare Menge und tendiert gegen unendlich. Das lässt sich nur noch mit KI beherrschen.

2.1 Künstliche Intelligenz und der Blick nach außen aus dem Fahrzeug heraus

KI bietet die Möglichkeit, in einer solchen Situation mit zahlreichen Variablen Sicherheit zu gewähren. Sie soll künftig einen Beitrag auf dem Weg zur „Vision Zero“ leisten, also dem Ziel, möglichst unfallfrei zu fahren und vor allem keine Menschenleben mehr im Straßenverkehr zu verlieren. Es gibt dabei eine Analogie zu dem beschriebenen Einsatz von KI in Suchmaschinen: So wie eine Suchmaschine oder ein Social Medium die Aktivitäten ihrer Nutzer beobachten und interpretieren, um aus deren Verhalten zu lernen, so beobachtet ein Auto mit seinen Sensoren die Umwelt. Für einen Computer aber sind beispielsweise Kamerabilder nur Ansammlungen von Pixeln ohne Bedeutung. Die Kunst liegt darin, aus diesen Pixeln die relevanten Objekte herauszufiltern, zu klassifizieren und dann zu entscheiden, welche voraussichtliche Intention das erkannte Objekt (etwa ein Fußgänger am Fahrbahnrand) hat und welche Konsequenzen das für das eigene Fahrzeug und seine Fahrentscheidungen erfordert. Der menschliche Fahrer kann das – vorausgesetzt er schaut wirklich hin und ist auch in der Lage, adäquat zu reagieren. Genau das ist der kritische Punkt: Denn so genial der Mensch in seinen Fähigkeiten im Umgang mit neuen Situationen ist, so unzuverlässig kann er auch sein. Der Fahrer ist an über 90 % aller Verkehrsunfälle ursächlich beteiligt. Das Ziel der KI als Teil des autonomen Fahrens ist also, besser zu sein, als der beste menschliche Fahrer – und dabei zusätzlich dessen

Schwächen (Sichthindernisse, Ablenkung, Müdigkeit, emotionale Verfassung, Alkohol bzw. Drogen, Gesundheitsprobleme, altersbedingte Einschränkungen) zu vermeiden.

KI wird besser in der Lage sein, Verkehrssituationen richtig zu erkennen und auch die richtigen Konsequenzen abzuleiten. Allerdings gibt es dabei eine Herausforderung: Es ist bei einem neuronalen Netz bisher im Nachhinein nicht nachvollziehbar, *warum* die KI eine bestimmte Entscheidung gefällt hat. Die KI ist also eine Blackbox. Das ist für ein hochgradig sicherheitsrelevantes System wie ADAS oder eine Automation im Fahrzeug nicht akzeptabel. Es ist eine dringende Aufgabe, die Prozesse der Produktentwicklung bei einem Systemzulieferer mit der vorhandenen KI-Technologie zu vereinbaren und den nachvollziehbaren Nachweis höherer – und transparenter – Sicherheit anzutreten. Dieser Anpassungsprozess dauert voraussichtlich noch mehrere Jahre, wird aber verfolgt, weil es außer der KI keinen absehbaren Königsweg für mehr Sicherheit im Straßenverkehr gibt. Für die an der Produktentwicklung beteiligten Ingenieure ist es eine hohe Motivation zu wissen: Wir retten mit dieser Technologie Menschenleben.

Ähnlich sieht es in der Medizin aus, wo KI bereits als automatisiertes Verfahren zur Früherkennung von Krankheiten oder für personalisierte Krebstherapien erprobt wird [3]. Bei der Interpretation von medizinischen Bildaufnahmen beispielsweise kann die KI viel schneller zu Ergebnissen kommen als das menschliche Auge. Auch hier geht es nicht darum, den Arzt zu ersetzen. Er soll vielmehr die Möglichkeit haben, sich auf die Interpretation der von der Maschine gefundenen Ergebnisse zu konzentrieren. So soll mehr Patienten in kürzerer Zeit geholfen werden. Dazu können Daten aus unterschiedlichen bildgebenden und anderen Quellen kombiniert werden, um eine Krankheit oder deren Verlauf zu analysieren [4].

2.2 Künstliche Intelligenz und der Blick nach innen ins Fahrzeug

KI hat über die hohe Zielsetzung der größeren Sicherheit hinaus weitere Auswirkungen auf die Produkte eines Tier 1 wie Continental. KI wird auch den Umgang des Fahrers mit seinem Fahrzeug ändern und die Art, wie der Fahrer und die Passagiere das Fahrzeug erleben. KI kann eine intuitive Kooperation von Mensch und Maschine ermöglichen, weil die Maschine durch KI nicht nur kognitive Fähigkeiten bekommt, sondern auch die menschliche Stärke der Empathie, was wiederum vom Menschen gelernt wird. Neue Konzepte werden Mensch und Maschine zu Dialogpartnern machen und geben dem Fahrerlebnis eine neue Qualität, die zur Wertschätzung des Fahrzeugs und seiner technischen Leistungsfähigkeit, beispielsweise des automatisierten Fahrens, beiträgt.

KI gestützte Computer werden in der Lage sein, vielfältige Informationen über den Fahrer zu verarbeiten und damit wahrzunehmen. Neben der Interpretation von gesundheitlichen Parametern kann das eine Analyse des Gesichtsausdrucks, möglicherweise der Gestik und Körpersprache, aber auch (Cloud-basierte) Voice-Dienste zur Stimmanalyse einschließen. Als KI-gestützte Schlussfolgerung kann beispielsweise Stress erkannt werden. Die Antwort der Maschine auf das Wahrgenommene kann darin bestehen, dem

Fahrer maßgeschneiderte Unterstützungs- oder Ablenkungsangebote zu machen, die geeignet sind, seinen Stresslevel zu verringern. Continental setzt dies mit dem in der Entwicklung befindlichen Digital Companion um. Diese KI-basierten Algorithmen nutzen Beobachtungen im Innenraum, um den Passagieren die Fahrt angenehmer zu machen. Je nach Fahrmodus (automatisiert oder manuell) kann der Digital Companion unterschiedliche Rollen annehmen, beispielsweise als Begleiter (Companion), als Helfer und Trainer (Coach) oder als Unterhalter (Entertainer). Je mehr das Fahrzeug über die Gemütsverfassung der Passagiere und deren Interessen weiß, desto zielgerichteter kann es die Menschen unterstützen und ihnen die Fahrt angenehmer machen. Auch erkannte Aktivitäten der Passagiere („activity mining“) können genutzt werden, um ihnen angepasste Angebote zu unterbreiten.

Solange die Empathie des Innenraums nicht direkt sicherheitsrelevante Felder berührt, kann die KI mit einem Modell von Fahrer und Passagieren starten, um dieses Modell während der Fahrten durch fortlaufende Beobachtung weiter zu verfeinern. Eine solche dynamische KI-Anwendung wird immer leistungsstärker, indem sie weitere Daten aufnimmt und ihr Modell erweitert. KI kann so dazu beitragen, Produkte nutzerfreundlicher, sicherer, stärker vernetzt und komfortabler zu gestalten. Wie im Gespräch zwischen Menschen ein Mehrwert durch gegenseitige Information stattfindet, so kann KI durch Querverbindungen Nutzen stiften.

2.3 Datenschutz im Spannungsfeld von Sicherheit, Komfort und Security

Wie bei anderen Anwendungen auch, wird es immer eine Abwägung zwischen dem Nutzen für den Menschen und seiner Privatsphäre sein, welche Daten der Fahrer und die Passagiere bereit sind, in einen Austausch mit der Maschine eingehen zu lassen. Insbesondere dann, wenn die Daten das Fahrzeug verlassen und in der Cloud aufbereitet werden, muss es für den Fahrer klar sein, welche Daten er/sie freigeben will und welche nicht – und mit welcher Erwartung an den Nutzen, der ihm/ihr dafür erwächst. Die Integrität der Daten im Fahrzeug muss genauso von der Cybersecurity im Fahrzeug gegen Spionage geschützt werden, wie die Integrität der Fahrzeugsysteme. Auch dabei kann KI helfen, denn mit ihrer Fähigkeit zur Mustererkennung und zur Analyse enormer Datenmengen kann sie auch verdächtige Muster von Aktivitäten im Internet bzw. in der Kommunikation mit dem Fahrzeug erkennen. So lassen sich beispielsweise Cyber-Attacken erkennen.

Grundsätzlich gilt aber – ebenso wie bei Suchmaschinen – die Regel, dass mit dem Wissen der KI im Fahrzeug (und damit der Bandbreite der zugelassenen Datenerhebung) auch die Unterstützung des Fahrers und der für ihn fahrzeugseitige bereitgestellte Komfort steigen. Das reicht bis hin zur Erkennung medizinischer Notfallsituationen des Fahrers und der Einleitung von Hilfsmaßnahmen durch das Fahrzeug.

Für Fahrer und Passagiere muss zu jeder Zeit klar sein, welche Daten zu welchem Zweck wohin gehen und was damit geschieht. Mit anderen Worten, der Mensch muss die Kontrolle über seine Daten behalten. Da jeder Fahrer andere Präferenzen haben kann, wird es nötig sein, eine Art personenbezogenes Logbuch für die frei gegebenen Daten zu führen (mit Freigaben, die jederzeit auch wieder geändert werden können) und klar zu machen, welcher Nutzen in Form von Sicherheit, Wissen, Komfort oder pekuniärer Belohnung dadurch für den Fahrer entsteht. Entsprechende Systeme für den kontrollierten und sicheren Datenhandel auf Basis von Blockchain-Technologie befinden sich in der Entwicklung. Mit solchen Plattformen wird die Voraussetzung geschaffen, in einer gesetzeskonformen und fairen Form wirklich genau jene Daten vermarkten zu können, die für neue Komfortfunktionen, Dienste und Geschäftsmodelle benötigt werden. Ohne Daten geht es nicht, denn Daten sind aus Sicht einer KI nichts anderes als Erfahrung, aus der Wissen entsteht. Daten sind ein hohes Gut und ihr Wert muss sich in einem fairen Handel über ihre mögliche Weitergabe (für viele Einsatzzwecke in anonymisierter Form) niederschlagen. Entscheidend ist dabei, dass der Fahrer selbst definiert, was er/sie will. Auch wenn KI hochmodern ist, folgt sie in diesem Punkt einem lang bewährten Grundsatz: Do ut des. Ich gebe, damit du gibst. Daran ändert sich nichts.

3 Künstliche Intelligenz in Unternehmensprozessen

Für ein Unternehmen wie Continental, dessen Mitarbeiter Technologien und Produkte für Fahrzeuge entwickeln, ist KI verglichen mit etablierten Software- und Hardwaretechnologien ein neuartiges Instrument. In dem Mikrokosmos, den selbst ein großes Technologieunternehmen mit rund 240.000 Mitarbeitern im Vergleich zur Gesamtbevölkerung darstellt, kann man beobachten, wie ein gesamtgesellschaftlicher Prozess im Zeitraffer abläuft: So hat sich zunächst innerhalb der Mitarbeiterschaft – beispielsweise bei Softwareprogrammierern – zunächst durchaus Skepsis gegenüber KI gezeigt. Diese Skepsis schwand jedoch innerhalb kurzer Zeit, weil die praktische Erfahrung mit KI ihren Charakter als hilfreiches Instrument aufzeigt. Es ist keineswegs so, dass KI womöglich Mitarbeiter, deren Erfahrung und Expertise ersetzen würde. Zwar kann KI durch ihre Lernfähigkeit prinzipiell das Wissen von Tausenden von Mitarbeitern über Generationen hinweg verstetigen und quasi allgemein nutzbar machen. Aber es ist ein fundamentales Missverständnis, daraus abzuleiten, dass KI die Mitarbeiter damit ersetzen würde. Sie dient vielmehr denselben Mitarbeitern als ein neuartiges Werkzeug, um ihnen die eigentliche kreative Arbeit zu erleichtern.

Wir Menschen lernen ja durch Beobachtung und Erfahrung. Aus diesen beiden Quellen ziehen wir Schlüsse, antizipieren Handlungsbedarf und ziehen die richtige Schlussfolgerung. Je mehr solche menschliche Erfahrung in KI als Routine und Basisregelwerk hinterlegt ist, desto mehr Routinen kann die KI automatisiert abgleichen. Es geht also um das Persistieren (Dauerhaftmachen) von Daten und das Aufbereiten dieser

Daten in einem strukturierten KI-Modell. Bei einem solchen Entwicklungsprozess wird Wissen bewahrt und die KI ist in der Lage, immer wieder in neuen Situationen zu überprüfen, ob bei einer Produktentwicklung das Richtige gelernt wurde. Mitarbeiter finden mit dem Werkzeug der KI sehr schnell, was sie suchen und was davon das Produkt tatsächlich weiterbringt.

Anders als der Mensch, ist eine KI nicht durch situativ wirkende Grenzen eingeschränkt. Während das Kommunikationsverhalten von Menschen zahlreichen intervenierenden Faktoren wie Sympathien, Antipathien, Vorurteilen, Rivalitäten, Stress, Zeitnot, Missverständnissen (Stille-Post-Effekte), Zufall und anderen mehr unterliegt, steht das persistierte Wissen einer KI immer und in vollem Umfang für jeden Nutzer zur Verfügung.

3.1 Softwareentwicklung – unterstützt durch künstliche Intelligenz

Ein gutes Beispiel für den Nutzen, den KI stiften kann, liefert die Softwareentwicklung. In puncto Lines of Code (LoC, Programmierzeilen) ist das Auto rekordverdächtig: Schon seit 2015 können in einem hoch ausgestatteten Oberklassefahrzeug über 100 Mio. LoC gespeichert sein. Momentan (Stand: 2020) verdoppelt sich dieses Volumen auf über 200 Mio. LoC und es erscheint realistisch, dass daraus bis zum Jahr 2025 rund 750 Mio. LoC pro Auto werden können, denn immer mehr ist es die Software, die dem Fahrzeug seine Funktionalität, Sicherheit, Effizienz und seinen Komfort gibt. Software gewinnt rapide an Bedeutung für das Fahrzeug und damit auch für Systementwickler. Zum Vergleich: Die komplette Flugsoftware einer Boeing 787 umfasst etwa 14 Mio. LoC, die gesamte Software des weltweit leistungsstärksten Teilchenbeschleunigers Large Hadron Collider hat rund 50 Mio. LoC [5].

Diese enorme Softwaremenge im Auto wird weltweit verteilt entwickelt – und das von immer mehr beteiligten Firmen und Menschen. Dabei ist Softwareentwicklung eigentlich unverändert eine sehr kleinteilige Arbeit, bei der jeder Entwicklungsfortschritt penibel überprüft werden muss, ehe er in eine Softwareversion einfließt. Bei mehreren Hundert beteiligten internen und externen Softwareexperten, die heutzutage an einem großen Projekt mitwirken können, ist es entscheidend, jeden Softwarestand automatisiert zu überprüfen. Genau diesen Prozess kann die KI effizienter leisten. Sie wählt beispielsweise diejenigen Tests aus, deren abgetestete Funktion in der Vergangenheit eher zu Fehlern geführt hat und kann dafür sinnlose bzw. ineffektive Tests auslassen. Aufgrund der Komplexität dieser Aufgabe kann der Mensch das bei explodierenden Testzahlen nicht mehr. So lassen sich mit KI alle möglichen Fehler durch eine intelligente Testabdeckung erreichen. Auf den Punkt gebracht: KI kann das Testen verbessern.

Die enorme Arbeitserleichterung, die KI in der Softwareentwicklung bewirkt und die Erfolge führten sehr schnell dazu, dass die anfängliche Skepsis einer selbstverständlichen Nutzung der KI wich. Mitarbeiter erkennen durch die praktische Erfahrung

schnell, dass ihnen KI den mühsamsten und ermüdenden Teil der Arbeit abnimmt. Damit kann sich der Mensch auf das konzentrieren, was er gut kann: Inspiration, Kreation, Konzeption. Die KI ist ein dienstbarer Geist, kein Ersatz des Menschen.

3.2 Interne Arbeitsabläufe und künstliche Intelligenz

Auch in anderen Feldern, in denen komplexe, vernetzte Abläufe koordiniert werden müssen, wie in der hochautomatisierten industriellen Produktion bietet KI die Chance, Abläufe zu optimieren und so effizienter zu fertigen. Der Treiber ist – genau wie bei der Softwareentwicklung – der Wunsch, die Entwicklung und Produktion von Produkten effizienter zu machen und dabei höchstmögliche Qualität und Zuverlässigkeit zu erzeugen. KI ist grundsätzlich in der Lage, in dem riesigen Datenvolumen von Informationen über Anlagen, Produktionsmittel und zu fertigende Produkte Zusammenhänge und Wechselwirkungen zu erkennen, die richtigen Schlüsse zu ziehen und damit Ablaufoptimierungen aufzuzeigen, die dem Menschen mit seinem begrenzten Erkenntnisraum nicht zugänglich wären. Ein Teil davon ist auch, dass Fertigungsmaschinen selbst viele Daten erzeugen, die ebenfalls in eine solche Optimierung einfließen müssen. Da KI Wissen (Erfahrung) und Regeln persistiert, sind beide Faktoren permanent in vollem Umfang verfügbar und nicht nur punktuell durch den Erfahrungsschatz einzelner Menschen repräsentiert.

3.3 Hardware für die künstliche Intelligenz

Die Entwicklung einer KI erfordert vor allem in der Phase des Lernens enorme Rechenkapazitäten. Daher bildet geeignete Hardware eine Voraussetzung für die Arbeit an KI. Seit Anfang 2020 ist bei Continental in Frankfurt deshalb ein neues vernetztes Rechnersystem im Betrieb. Dieser Supercomputer mit mehr als 50 Nvidia DGX-Systemen, die mit Mellanox Infiniband verbunden sind, basiert auf der modularen SuperPOD-Referenzarchitektur. Seine Einsatzgebiete sind vor allem KI, Deep Learning und KI-getriebene virtuelle Simulation. Die Entwickler an den weltweiten Standorten des Unternehmens beziehen aus diesem neuartigen Computercluster sowohl Rechenleistung als auch Speicherplatz für hochkomplexe und datenintensive Entwicklungen. Mit der zusätzlichen Rechenleistung lassen sich moderne Systeme für assistiertes, automatisiertes und autonomes Fahren deutlich effektiver, schneller und kosteneffizienter entwickeln. Dazu werden auf dem Supercomputer reale, physikalische Testfahrten simuliert, sodass weniger Fahrten auf der Straße erforderlich sind. Das beschleunigt die Programmierung samt dem Training der künstlichen neuronalen Netze erheblich.

4 Verantwortung mit und für künstliche Intelligenz

Wenn sich durch KI die Produkte und die internen Prozesse eines Unternehmens verändern, ist es eine naheliegende Frage, welche Verantwortung daraus erwächst. Die Veränderung besteht hauptsächlich darin, dass KI die Fähigkeiten einer Maschine erweitert (Entscheidungsfindung) und es damit darum geht, die möglichen Konsequenzen aus dieser Fähigkeit abzuschätzen und zu kontrollieren. Grundsätzlich neu ist dieser ethische Gedanke nicht, denn auch mit programmierbarer Software lassen sich Funktionen darstellen, die nicht gesetzeskonform sind und die Frage nach der Verantwortung aufwerfen. So wenig, wie man deshalb die Software insgesamt abschaffen würde, so wenig sprechen die erweiterten Fähigkeiten einer Maschine mit KI gegen die Technologie. Die zentrale Frage ist die Verantwortung für die KI in den Produkten und in den internen Prozessen eines Unternehmens. In diesem Punkt unterscheidet sich die Nutzung von KI nicht von der bisherigen Form der Produkthaftung.

Bevor spezifische ethische Fragen der KI angesprochen werden, hier noch eine kurze Einführung in die Werte des Unternehmens. Sie bilden letztlich unverändert die Grundlage, um auch die Ethik der KI abzuleiten. Für ein globales Großunternehmen, das in unterschiedlichsten Märkten und Kulturen aktiv ist, spielt eine unternehmensweite Ethik grundsätzlich eine große Rolle, weil sie Verbindlichkeit und Zusammenhalt stiftet.

„Bei Continental teilen alle Mitarbeiterinnen und Mitarbeiter vier grundlegende Unternehmenswerte. Sie bilden die Wurzeln unserer Unternehmenskultur: **Vertrauen, Gewinnermentalität, Freiheit und Verbundenheit**. Wir sind davon überzeugt: Nur in einem damit geprägten Umfeld entstehen maßgebliche und wegweisende Leistungen, Lösungen und Beiträge.

Continental fördert alle Mitarbeiterinnen und Mitarbeiter. Dafür pflegen wir eine Kultur des Vertrauens und öffnen Spielräume für Eigenverantwortung. Das Arbeitsklima bei Continental ist geprägt von gegenseitiger Wertschätzung. Alle Einzelbeiträge zählen. Diese teilen wir durch unser globales Netzwerk und veredeln sie gemeinsam. Wir erfassen Trends und Marktveränderungen, nutzen sie schneller als andere, und kommen effizienter zu besseren (d. h. effektiveren) Lösungen für unsere Kunden. [6]

Als eines der ersten Unternehmen hat Continental auf der Grundlage seiner Werte Richtlinien für die ethische Nutzung von KI ausformuliert [7]. Die Inhalte und Zielrichtungen der Continental „Guidelines for the Ethical Usage of Artificial Intelligence“ sind nachfolgend ausgeführt. Dabei gilt: Diese ethischen Richtlinien sind nicht statisch. Sie sind ebenso dynamisch wie die revolutionäre Technologie, für die sie gelten. Mit der wachsenden Erfahrung mit KI werden diese Richtlinien immer wieder aktualisiert und angepasst werden. Das Ziel bleibt dabei jedoch immer dasselbe: KI verlangt Verantwortung.

4.1 Verantwortung für künstliche Intelligenz in Produkten

In der Präambel der Continental KI-Richtlinien wird festgehalten, dass im Zentrum der KI ihr Nutzen für den Menschen steht. KI wird im Unternehmen so eingesetzt, dass Kunden, Geschäftspartner, Zulieferer und Autofahrer sowie die Gesellschaft davon einen Vorteil haben. KI ist ein Instrument, das dem Menschen dient, indem es zu besseren, sichereren und komfortableren Produkten und Lösungen führt. Insbesondere die Vision Zero im Straßenverkehr soll mit KI schneller erfüllbar werden. Generell gilt, dass ein KI-basiertes Produkt nicht über den Menschen bestimmen darf. Der Mensch muss die letzte Entscheidungsgewalt behalten.

Anschließend wird das weiter präzisiert: Da KI mit ihrer Fähigkeit zur Entscheidungsfindung potenziell in die Rechte eines einzelnen Menschen eingreifen kann, ist es notwendig, sie nutzerzentriert zu entwickeln und dabei verantwortungsbewusst, sicher, rechenschaftspflichtig, transparent, fair und in einer ethischen Weise vorzugehen. Daher beschreiben die KI-Richtlinien genauer, worum es bei der Verantwortung für KI geht: Angefangen bei der Herkunft der verwendeten Daten über die Klarheit, wer im Einzelnen Verantwortung für das Training einer KI trägt bis hin zu Frage nach der Überwachung der Ergebnisse (Verhalten) und eines tiefen Verständnisses davon, *wie* eine KI zu ihren Entscheidungen gelangt. Dieser Teil der Richtlinien bezieht sich gleichermaßen auf den Einsatz von KI für Produkte und Prozesse.

Weiterhin stellen die KI-Richtlinien sicher, dass KI im Einklang mit geltenden Gesetzen, Regeln sowie den Verhaltensregeln des Unternehmens (Continental Corporate Rules/Rules of Conduct) steht. Dazu zählt beispielsweise die Datensicherheit, der Datenschutz, der natürlich auch bei KI greift, der Schutz von geistigem Eigentum, die Produkthaftung und die Regelkonformität insgesamt.

Anschließend widmen sich die KI-Richtlinien den Fragen nach Gesundheit, Sicherheit, Umweltverträglichkeit und der Produktsicherheit. Es geht darum festzuschreiben, dass bei der Nutzung einer KI keine ungewollten Verhaltensweisen auftreten, die zu einer Gefährdung führen könnten. Dazu gehört auch, ein Produkt mit KI ausreichend in seinen Eigenschaften zu erklären. Betont wird in diesem Zusammenhang die Verantwortung für die Entwicklung des Produkts, seiner späteren Funktion und seiner Rechtskonformität. Dazu gehört beispielsweise die Verantwortung für die Auswahl der richtigen Trainingsdaten für eine KI, weil diese das Verhalten des späteren Produkts beeinflussen.

Weil Daten ein essenzieller Bestandteil von Produkten und Systemen der KI sind, formulieren die KI-Richtlinien Regeln für den verantwortungsvollen und fairen Umgang mit ihnen, insbesondere personenbezogenen Daten. Geltende Regeln des Datenschutzes (General Data Protection Regulation, GDPR) müssen auch in Systemen mit KI eingehalten werden. Dazu gehört, dass jeder das Recht hat, einem allein durch automatisierte Datenverarbeitung erzeugten Persönlichkeitsprofil zu widersprechen. Grundlegende Schutzmaßnahmen wie die Verschlüsselung von Daten und der methodisch kontrollierte Datenzugriff gehören ebenso zu den Regeln wie die Tatsache, dass ein

Mensch darüber informiert werden muss, wenn er es mit einem KI-System zu tun hat. Abschließend widmen sich die KI-Richtlinien dem Aspekt der Vertraulichkeit und des Schutzes von geistigem Eigentum, das in einer KI steckt.

4.2 Verantwortung für künstliche Intelligenz in Prozessen

Ein Teil der KI-Richtlinien weist unter anderem explizit auf die Rolle von KI in der Robotik und Automatisierungstechnik, aber auch in internen Prozessen hin und betont die Verantwortung für die körperliche Gesundheit und den guten Ruf aller Mitarbeiter. Während einige Abschnitte der KI-Richtlinien gleichermaßen auf Produkte und Prozesse abzielt, fokussiert ein anderer Teil der Richtlinien auf den Arbeitsplatz und faire Arbeitsbedingungen. Der Nutzen des Einsatzes von KI soll sich demnach in fairen Arbeitsbedingungen ohne jede Form von Diskriminierung auswirken. Dazu wird eine Checkliste aufgeführt, wie die Treiber von KI-Projekten sicherstellen können, dass dieses Ziel erreicht wird.

Es wird gerade im Hinblick auf die industrielle Fertigung präzisiert, dass KI in der Robotik sicher sein muss und dass alle Rahmenbedingungen und möglichen Konsequenzen (insbesondere schädliche Auswirkungen) vor dem Einsatz erhoben sowie Mittel und Wege zu ihrer Abmilderung oder Verhütung integriert werden. Tests von KI unter kontrollierten Bedingungen sind ebenfalls vorgesehen, um den Nachweis der sicheren Nutzung zu führen.

In einem eigenen Abschnitt konzentrieren sich die KI-Richtlinien auf die Bedeutung, die eine Nutzung von KI für die Gleichbehandlung aller Mitarbeiter hat. In diesem Zusammenhang betont der Abschnitt explizit, dass durch Auswahl nicht geeigneter Trainingsdaten das spätere Produktverhalten nicht dem Grundsatz der Fairness und Gleichbehandlung entsprechen könnte. Folglich muss vorab vor dem Einsatz einer KI erhoben werden, welche Teile der weltweiten Bevölkerung möglicherweise durch eigens ausgewählte Daten repräsentiert sein müssen, um eine Gleichstellung aller zu erreichen.

5 Zukunftsperspektiven

KI kann einen wesentlichen Beitrag zum Gelingen der Digitalisierung beitragen. Sie hat ihre Anwendungsbereiche dort, wo Zustandsräume so vielfältig werden, dass sich nicht mehr alle Probleme in linearer Zeit auflösen lassen. Durch die Möglichkeit, große Wissensmengen in der KI zu persistieren, lassen sich auch sehr komplexe Probleme beherrschen, denn die KI bedeutet eine Annäherung an ein vollständiges Wissen. Ausreichend Speicher und Rechenkapazität sowie das richtige Wissen (Trainingsdaten) vorausgesetzt, lassen sich mit einer KI also in kurzer Zeit Probleme lösen, die mit konventionellen Algorithmen nicht beherrschbar sind. Eine sehr spannende Perspektive bietet voraussichtlich das Quantum Computing für die Entwicklung der KI. In einem

Quantencomputer sind ja – anders als in einem binären Rechner auf Basis einer 0-1-Zustandslogik – alle Lösungen gleichzeitig vorhanden, sodass „nur“ noch die richtige Lösung ausgewählt werden muss. Insofern birgt das Quantum Computing die Chance, Aufgaben mit KI noch einfacher zu lösen.

Zur Beruhigung: Mensch und Maschine konkurrieren nicht um dieselben Aufgaben. Die KI ist einfach ein neues Instrument, das dem Menschen dazu dient, sich auf seine eigentlichen Stärken zu konzentrieren (Kreativität, Urteilsfindung, Empathie). Gerade die Aufgaben, für die der Mensch weniger geeignet ist (Ausführung, Ausdauer, Skalieren), kann er an die Maschine abgeben. Dabei kann die Qualität von Produkten trotz wachsender Komplexität steigen. Manche Aufgabenstellungen sind ohne KI voraussichtlich gar nicht lösbar. Dazu zählt in der Automobilbranche neben der Softwareentwicklung vor allem das autonome Fahren. Was sich verändert, ist jedoch die Arbeitsteilung zwischen Mensch und Maschine: KI übernimmt die Knochenarbeit und hält auf Wunsch Komplexität vom Menschen fern. KI ist nach dem Verständnis von Continental für den Menschen da. Um sie zu nutzen, ist es notwendig, dass wir aus den digitalen Spuren, die wir heute alle hinterlassen, auch lernen. Sieht man KI nüchtern als neues Werkzeug in der bisherigen Werkzeugkiste, so kann man dieses Werkzeug erproben, verstehen, verfeinern und nutzen wie jedes andere auch – ein Lernprozess und keine Frage von Gut und Böse.

Quellen

1. Destatis: https://www.destatis.de/DE/Themen/Querschnitt/Jahrbuch/jb-arbeitsmarkt.pdf?__blob=publicationFile
2. Neue Züricher Zeitung, NZZ: <https://www.nzz.ch/wirtschaft/wie-sich-die-autoindustrie-von-einer-hardware-zu-einer-softwarebranche-transformiert-ld.1439785>
3. Bundesministerium für Bildung und Forschung, BMBF: <https://www.bmbf.de/de/was-ki-fuer-die-medizin-bedeutet-9177.html>
4. Data Revenue: <https://www.datarevenue.com/de-blog/kuenstliche-intelligenz-in-der-medizin>
5. Visual Capitalist: <https://www.visualcapitalist.com/millions-lines-of-code/>
6. Continental: <https://www.continental.com/de/unternehmen/konzernstrategie/unsere-werte-29524>
7. Continental: <https://www.continental.com/de/presse/pressemitteilungen/ki-ethik-regeln-224386>

Dr. Corina Apachițe leitet bei Continental Automotive die Abteilung für Künstliche Intelligenz. In dieser Funktion ist sie in enger Zusammenarbeit mit den Geschäftsbereichen und Zentralfunktionen für die technische Gesamtstrategie und die operative Umsetzung verantwortlich. Mit ihrem Team trägt sie wesentlich zur Vision des Unternehmens einer „AI empowered company“ und einem „AI empowered employee“ bei. Ihr Team ist weltweit verteilt und arbeitet in enger Kooperation mit Partnern aus Industrie und Wissenschaft. Bevor sie im Januar 2018 zu Continental kam, war Dr. Apachițe in einer ähnlichen Position bei der Robert Bosch GmbH tätig, wo sie für die technische Strategie für Künstliche Intelligenz und Big Data verantwortlich war. Während ihrer Zeit bei der ETAS GmbH in Stuttgart sammelte sie mehrere Jahre Erfahrung als Chief Product

Owner in der agilen Softwareentwicklung von Virtualisierungslösungen. Dr. Corina Apachițe ist promovierte Informatikerin (Verifikation hybrider Systeme).

Dr. Stefan Voget ist Leiter des KI-Infrastruktur Labors in der Abteilung für Künstliche Intelligenz, die Teil der zentralen ganzheitlichen Engineering- und Technologieorganisation von Continental Automotive in Regensburg, Deutschland, ist. Voget erhielt seinen Doktor in Informatik und Mathematik im Jahr 1996. Von 1997 bis 2005 arbeitete er an SW-Architekturprojekten für die Robert Bosch GmbH. Er wechselte 2005 zu Siemens VDO Automotive in Regensburg. Dort vertrat er das Unternehmen als Projektleiter im AUTOSAR-Konsortium und arbeitete als Produktmanager im AUTOSAR-Zentrum von Continental Engineering Services. Im Jahr 2011 übernahm er bei der Continental Automotive GmbH die Leitung des international geförderten Projekts „ITEA - SAFE“ zur Prozessinterpretation der Norm für funktionale Sicherheit ISO26262. Seit 2014 arbeitet er an der Realisierung von automatisiertem Fahren und Funktionen der künstlichen Intelligenz in eingebetteten Steuergeräten.



CSR und künstliche Intelligenz im Mittelstand – Chancen für innovativere und nachhaltigere kleine und mittlere Unternehmen?

Martin Lundborg, Lisa Schrade-Grytsenko und Christian Märkel

1 Einleitung

Nachhaltigkeit ist bereits seit längerem Bestandteil der Diskussion in Politik, Gesellschaft und Wirtschaft. Das Bundesministerium für Wirtschaft und Energie (BMWi) definiert Nachhaltigkeit in Bezug auf Unternehmen als die Aufgabe, „die wirtschaftliche Leistungsfähigkeit, ökologische Verantwortung und soziale Gerechtigkeit so miteinander zu verschränken, dass die Realisierung des Einen nur unter Berücksichtigung der jeweils beiden anderen erfolgt“ [1]. Hiermit ist also sowohl ökologische als auch soziale Nachhaltigkeit gemeint, ebenso wie die Wirtschaftlichkeit (ökonomische Nachhaltigkeit) von Unternehmen. Eine Herausforderung, die sich auch im Rahmen der CSR stellt. Die Schnittmenge von Nachhaltigkeit und der unternehmerischen Gesellschaftsverantwortung (CSR) wird besonders in der Definition des Bundesministeriums für Arbeit und Soziales (BMAS) deutlich, das CSR als „die gesellschaftliche Verantwortung von Unternehmen im Sinn eines nachhaltigen Wirtschaftens“ versteht [2]. Nachhaltigkeit

M. Lundborg · C. Märkel

WIK Wissenschaftliches Institut für Infrastruktur und Kommunikationsdienste GmbH,
Bad Honnef, Deutschland

E-Mail: m.lundborg@wik.org

C. Märkel

E-Mail: c.maerkel@wik.org

L. Schrade-Grytsenko (✉)

WIK Wissenschaftliches Institut für Infrastruktur und Kommunikationsdienste GmbH,
Bad Honnef, Deutschland

E-Mail: L.Schrade-Grytsenko@wik.org

© Der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

251

R. Altenburger und R. Schmidpeter (Hrsg.), *CSR und Künstliche Intelligenz*, Management-Reihe Corporate Social Responsibility,
https://doi.org/10.1007/978-3-662-63223-9_13

setzt sich folglich aus drei Dimensionen zusammen, die sich gegenseitig bedingen: die ökologische, ökonomische und soziale Dimension. Unter CSR versteht man die Verantwortung des Unternehmens, diese drei Dimensionen der Nachhaltigkeit in seinem Handeln zu berücksichtigen und in den Einklang zu bringen.

Neben der Nachhaltigkeit bildet die Digitalisierung und hier insbesondere die Entwicklungen auf dem Gebiet der künstlichen Intelligenz (KI) einen weiteren Megatrend der Gegenwart [4]. Aus diesem Grund drängt sich die Frage auf, wie sich die Themen KI und Nachhaltigkeit (bzw. CSR) in mittelständischen Unternehmen zueinander verhalten. Insbesondere stellen sich folgende Forschungsfragen:

- Eignen sich KI-Anwendungen zur Unterstützung von Nachhaltigkeitsmaßnahmen im Mittelstand?
- In welchem Rahmen kann KI bei der unternehmerischen Gesellschaftsverantwortung unterstützen?
- Welche Rahmenbedingungen sollten zur sinnvollen Implementierung von KI im Unternehmen erfüllt sein?

2 Status quo der Digitalisierung im Mittelstand Deutschland

Deutschland ist Land des Mittelstands: 3,5 Mio. und somit 99,5 % sämtlicher Unternehmen in Deutschland sind kleine und mittlere Unternehmen (KMU), die per Definition maximal 500 Mitarbeitende verzeichnen. Mehr als jeder zweite sozialpflichtig Beschäftigte¹ in Deutschland arbeitet in einem KMU. Von den weltweit 2700 sog. Hidden Champions, also eher unbekannte, aber marktführende Unternehmen, sind allein 1307 deutsche mittelständische Unternehmen [5]. Vom deutschen Mittelstand geht somit ein enormes Innovations- und Wirtschaftspotenzial aus, was die digitale Transformation mit einschließt. Eine Herausforderung für den Mittelstand stellen allerdings die Digitalisierung und der damit einhergehende Strukturwandel dar. Die Digitalisierung wirkt sich dabei sowohl auf die Prozesse als auch auf die Produkte und Geschäftsmodelle der Unternehmen aus. Allerdings setzen erst 31 % der mittelständischen Unternehmen konkrete Maßnahmen zur digitalen Transformation des Betriebs um. Insgesamt besteht also im Mittelstand noch viel Umsetzungsbedarf im Hinblick auf die digitale Transformation [6].

Die Digitalisierung bietet KMU auf vielfältige Weise Unterstützung. In der Produktion können beispielsweise Sensoren die erforderliche Transparenz herstellen, um eine ineffiziente Nutzung von Ressourcen genauer zu lokalisieren. Blockchain-Technologie, verteilte Datenbanken und Standards ermöglichen eine Nachverfolgung von Materialien entlang der Wertschöpfungskette, um so die Wiederverwertung

¹Aus Gründen der besseren Lesbarkeit wird auf die gleichzeitige Verwendung der Sprachformen männlich, weiblich und divers (m/w/d) verzichtet. Sämtliche Personenbezeichnungen gelten gleichermaßen für alle Geschlechter.

der Materialien sicherzustellen. Die Digitalisierung hilft auch bei der papierlosen Dokumentation, die nicht nur durch Gesetzesauflagen erforderlich ist, sondern auch Ressourcen einspart und das Verarbeiten von Daten einfacher und umfassender macht. Und neue, digitale Arbeitsmethoden (New Work) versetzen Unternehmen in die Lage, Angestellten flexiblere Arbeitsbedingungen anzubieten und gleichzeitig Reisekosten und damit verbundene Emissionen zu reduzieren.

Die neueste Welle an digitalen Anwendungen kommt mit der Weiterentwicklung von KI. Unternehmen sind gegenüber Anwendungen mit KI grundsätzlich aufgeschlossen [6]. Fast drei Viertel der KMU erwarten Einsatzpotenziale für KI-Anwendungen in ihrer Branche, wobei gegenwärtig lediglich erst ein kleiner Teil KI-Anwendungen in ihrem Unternehmen nutzt oder den Einsatz dieser plant. Mit KI ist also noch ein großes Potenzial vorhanden, das von den Unternehmen ausgeschöpft werden könnte, wie im nachfolgenden Abschnitt deutlich wird.

3 Künstliche Intelligenz im Mittelstand

Gemäß der KI-Strategie der Bundesregierung soll Deutschland zu einem weltweit führenden KI-Standort werden [7]. In der Implementierung von KI-Lösungen in die Wirtschaft wird ein wesentlicher Beitrag gesehen, um die international gute Wettbewerbsposition der deutschen Wirtschaft aufrechtzuerhalten. Soll dies gelingen, dann ist der Transfer von KI-Lösungen in den Mittelstand als Rückgrat der deutschen Wirtschaft unabdingbar. Immerhin ist der Mittelstand für über 50 % der Nettowertschöpfung in Deutschland verantwortlich [8]. Der Mittelstand zählt damit zu Recht als Herzstück der deutschen Wirtschaft. Das Ergebnis einer Expertenumfrage, die vom Wissenschaftlichen Institut für Infrastruktur und Kommunikationsdienste (WIK) zum Thema KI im Mittelstand durchgeführt wurde, unterstreicht die Wichtigkeit des Themas KI im Mittelstand: 77 % der Experten halten KI für bedeutend für die Zukunft des deutschen Mittelstands [9]. Von den Befragten sehen jedoch 70 % die Gefahr, dass der deutsche Mittelstand im Zuge der internationalen KI-Entwicklung abgehängt werden könnte. Diese Befürchtung resultiert daraus, dass der Mittelstand einigen Hürden bei der Implementierung von KI-Lösungen gegenübersteht, wie Abb. 1 zeigt. Die größte davon ist der Fachkräftemangel: Für den Mittelstand ist es eine Herausforderung, genügend IT-Experten für das eigene Unternehmen anzuwerben. Aus diesem Grund sind cloudbasierte KI-as-a-Service-Angebote relevant für KMU. Diese erfordern ein verhältnismäßig geringeres IT-Know-how und lassen sich leichter implementieren. Allerdings geht dies mit neuen Abhängigkeiten vom Serviceanbieter einher. Eine weitere Hürde für den Mittelstand ist die häufig mangelnde Datenbasis in mittelständischen Unternehmen. Für selbstlernende Algorithmen ist eine ausreichende Datenbasis für das Training der Daten von großer Bedeutung. Allerdings fallen in kleineren Unternehmen weniger Daten an. Zudem erlaubt der digitale Reifegrad der KMU aufgrund fehlender Sensordaten häufig noch keine Datenerfassung über die gesamte Prozesskette hinweg. In Verbindung hiermit stehen Datensicherheitsbedenken im Mittelstand. Unternehmen fragen sich, was mit den erfassten Daten passiert und ob diese sicher aufgehoben werden.




Abb. 1 Einschätzung der Hemmnisse der KI-Nutzung im Mittelstand [9]

Wie diese Skizzierung der Hemmnisse im Mittelstand für die KI-Implementierung zeigt, besteht bei den KMU Unterstützungsbedarf. Gemäß der Ergebnisse der Expertenumfrage des WIK sollte diese Unterstützung in erster Linie bei der Vermittlung von Wissen über KI ansetzen, denn KI ist im Mittelstand vor allem eine Know-how-Frage. Eine Unterstützungsmaßnahme aus der KI-Strategie der Bundesregierung für den Mittelstand sind die KI-Trainer, wovon es bundesweit mittlerweile über 50 an 16 Standorten gibt. Die KI-Trainer sollen den Mittelstand für das Thema KI sensibilisieren, KI-Kompetenz vermitteln und bei der Auswahl einer geeigneten KI-Lösung für das Unternehmen unterstützen.

KI-Lösungen bieten mittelständischen Unternehmen neue Potenziale über die gesamte Wertschöpfungskette in verschiedenen Anwendungsszenarien, wie aus Abb. 2 hervorgeht. In der Optimierung der Supply Chain sowie in der Steigerung der Prozesseffizienz werden laut Expertenumfrage die größten Chancen für den KI-Einsatz im Mittelstand gesehen. Soll Deutschland zu einem weltweit führenden Standort für KI werden und sollen die vollen volkswirtschaftlichen Potenziale, die von KI ausgehen, gehoben werden, wird dies nur gelingen, wenn KI in der Breite der deutschen Wirtschaft und damit im Mittelstand ankommt.




Abb. 2 Einschätzung der Chancen der KI im Mittelstand [9]

4 Nachhaltigkeit und CSR im Mittelstand

Einige KMU setzen bereits Nachhaltigkeitsprojekte um und nutzen dafür digitale Technologien zur Unterstützung. Einer repräsentativen Studie des Instituts für Mittelstandsforschung zufolge sind 60 % der KMU der Ansicht, dass nachhaltige Geschäftsmodelle in Zukunft notwendig sind. Dies hat auch das kleine Weinunternehmen Wein:Sein GmbH aus Magdeburg erkannt. Mit dem digitalen Ausbau ihres Geschäftsmodells auf einen Onlineshop und der Verknüpfung mit weiteren Kleinunternehmen zur Plattform „Your Local Magdeburg“ konnte nicht nur die Wettbewerbsfähigkeit in Krisenzeiten gesichert werden (beispielsweise Corona-Krise), sondern auch die für die Nachhaltigkeit wichtige Regionalität der angebotenen Produkte ausgebaut werden [10].

Eine Aufgabe im Mittelstand ist demzufolge die sinnvolle Zusammenführung von Wirtschaftlichkeit und Nachhaltigkeit, wobei Nachhaltigkeit bereits ein wirtschaftliches Potenzial innehaben kann. Diese mit beispielsweise der ökologischen Komponente zu verbinden, gelingt häufig durch Maßnahmen im Bereich Energie- und Ressourceneffizienz sowie Materialreduktion. Letzteres ist einem Kleinunternehmen im Lebensmittel Einzelhandel gelungen. Der Unverpackt-Laden „migori“ kann bei der Ausweisung von Produktinformationen auf seiner Waren dank einer digitalen Lösung nun auf eine physische, erneut müllproduzierende Variante, wie z. B. Verpackungs-Trays, verzichten. Mithilfe kleiner QR-Codes, die auf den dauerhaften Warencontainern angebracht sind, können Kunden alle benötigten Informationen zum Produkt digital abrufen [3].

Der Wunsch nach mehr Nachhaltigkeit und Umweltfreundlichkeit kommt verstärkt konsumentenseitig zustande. Dementsprechend entsteht im Mittelstand auch die Notwendigkeit, diese Konsumentenpräferenz im Produkt- und Serviceangebot zu

berücksichtigen, so z. B. in der Tourismusbranche. Das Hotel Haffhus hat ein digitales Nachhaltigkeitskonzept entwickelt, das neben den nachhaltigen Zielen somit auch die Kundenbindung zum Ziel hat. Hierzu zählt z. B. die eigene, digital unterstützte Stromversorgung, bei der der 100%ige Ökostrom sowohl für Mitarbeiter als auch Hotelgäste über ein digitales Steuerungssystem regulierbar ist – auch mithilfe von Handlungsempfehlungen, die das System auf Basis der Auslastung formuliert. Regional konnte das Hotel durch dieses Konzept ein Alleinstellungsmerkmal generieren. [3]

Im Mittelstand besteht neben den Anforderungen an ein nachhaltigeres Angebot und Handeln jedoch auch der Bedarf, zu dieser Transformation befähigt zu werden. Hier nennen die KMU eine Herausforderung bei der bürokratischen Bewältigung durch Regulierungen und Verordnungen, so z. B. im Rahmen des European Green Deal. Grund dafür sind die geringeren personellen und zeitlichen Ressourcen, die den hohen bürokratischen Anforderungen solcher politischen Regulierungen gegenüberstehen. KMU appellieren somit an ein mittelstandsfreundlicheres Ausgestalten der politisch auferlegten Regulierungen, um Machbarkeit und Erfolg dieser auch für KMU zu gewährleisten [8].

5 Befragung und Experteninterviews zu CSR und künstlicher Intelligenz im Mittelstand

Im Netzwerk des Förderschwerpunkts Mittelstand-Digital ist, wie bereits im Vorfeld erläutert, auch eine ausgewählte Gruppe von KI-Experten angesiedelt. Über 50 KI-Trainer sind in ganz Deutschland in den Mittelstand 4.0-Kompetenzzentren verteilt und widmen sich verschiedenen Schwerpunkten aus dem Bereich KI für die Zielgruppe Mittelstand. Aufgründdessen wurde diese Gruppe von KI-Experten für eine erste Befragung zu KI und CSR im Mittelstand herangezogen. Aufbauend auf dieser Befragung wurden zur Vertiefung der Ergebnisse Interviews mit Wissenschaftlern aus dem Bereich Nachhaltigkeit und Digitalisierung aus den Kompetenzzentren durchgeführt, in denen die Ergebnisse der Vorabbefragung gespiegelt und weitere Aspekte aus dem Bereich Nachhaltigkeit diskutiert wurden. Ziel war es, nicht nur die vorangegangenen Ergebnisse nochmals mit einer Nachhaltigkeitsperspektive zu betrachten, sondern auch tiefergehende Erkenntnisse respektive unternehmerischem Nachhaltigkeitsmanagement zu generieren.

Die Ergebnisse der Umfrage und Interviews zeigen, dass zu den relevanten Nachhaltigkeitsmaßnahmen für den Mittelstand vor allem 1) Energie- und Ressourceneffizienz, 2) ein nachhaltiger Produktlebenszyklus und 3) effizientere bzw. nachhaltigere Prozesse zählen. Dies sind auch zum Großteil die Bereiche, in denen KI als eine geeignete Unterstützungstechnologie gesehen wird. Den Befragten zufolge werden Nachhaltigkeitsmaßnahmen, unabhängig von einer Digitalisierungsunterstützung, zwar bisher in mittelständischen Unternehmen bereits umgesetzt, dies geschieht jedoch häufig noch unbewusst. Als Motivation für solche Maßnahmen steht auch bei KMU häufig die




Abb. 3 Digitalisierung und KI als Unterstützung von Nachhaltigkeitsmaßnahmen

wirtschaftliche Komponente im Vordergrund. Wenn digitale Technologien hier bereits angewandt werden, dann erfolgt dies laut den befragten Experten häufig ebenfalls unbewusst bzw. nicht mit einem klaren Synergie- oder Strategiegedanken dahinter.

Abb. 3 skizziert: Der Großteil der Befragten (80 %) sieht die Digitalisierung als eine geeignete Unterstützungsmöglichkeit für den Mittelstand an, wenn es um Nachhaltigkeitsmaßnahmen geht. Allerdings wird ein Problem darin gesehen, dass viele KMU den Nutzen digitaler Technologien für die Nachhaltigkeit und Resilienz des eigenen Unternehmens gegenwärtig noch nicht vollumfänglich erkennen. Dies zeigt den bestehenden Bedarf, KMU im Hinblick auf die Möglichkeiten und den Nutzen eines digitalisierungsunterstützten Nachhaltigkeitsmanagements zu sensibilisieren.

Diese Überzeugung ist bei der Eignung von KI-Technologien zur Unterstützung bei eben diesen Maßnahmen etwas geringer, wie auch Abb. 3 zeigt: 60 % der Befragten halten diese Technologie für den Mittelstand im Bereich Nachhaltigkeit für geeignet. Die größte Eignung für die KI-Technologie wird bei der nachhaltigen Wartung gesehen. Hierunter fällt vor allem das sogenannte „predictive maintenance“, also die vorhergesagte Wartung, bei der verfügbare (Prozess-)Daten mithilfe einer KI zur Vorhersage von Wartungsnotwendigkeit und -umfang verwendet werden können.

Die unternehmerische Gesellschaftsverantwortung und die darüber liegende Entwicklung der CSR-Strategie sind eher im Management und der Unternehmensleitung verankert, die ihren Ursprung in menschlichem Zutun haben und somit bedingt von einer KI abbild- oder substituierbar sind. In der Umsetzung der Strategie kann KI nichtsdestotrotz unterstützend eingesetzt werden. Jedoch sehen die Befragten eher bei datenbasierten Problemstellungen und Prozessen potenzielle Einsatzmöglichkeiten von KI – so im Fall des Nachkommens von Berichtspflichten im Unternehmen. Die Sammlung, Verknüpfung und Aufbereitung von Daten kann, bei entsprechender digitaler Infrastruktur, mithilfe von KI durchaus optimiert werden und würde in einen Mehrwert für diese Nachhaltigkeitsmaßnahme münden.

Der Einsatz von KI als unterstützende Technologie sollte anwendungsbezogen erfolgen, ist jedoch im Mittelstand aufgrund der in Abschn. 3 bereits erwähnten Hemmnisse bei der Implementierung von KI-Lösungen noch nicht weit verbreitet. Nichtsdestotrotz lohnt sich ein Blick auf die Punkte, die es für den Fall einer Implementierung zu beachten gilt: Auf prozessualer Ebene sollte abgewogen werden, wo und in welchem Ausmaß der Eingriff des Menschen sinnvoll ist und an welcher Stelle im Prozess Automatisierung Sinn macht. Besonders im Bereich der Datenaufbereitung und -verarbeitung kann KI, auch im Nachhaltigkeitsmanagement, unterstützen – sofern entsprechende Daten und Infrastruktur im Unternehmen vorhanden sind. Nicht zu vernachlässigen ist auch das Vorhandensein einer ethischen Komponente. Ethische Fragestellungen kann eine KI nur bedingt bis gar nicht abbilden, was auch hier wieder das Vorhandensein von menschlicher Intervention nötig macht. Laut der Interviewten werden vor allem standardisierte KI-Lösungen für den Mittelstand interessant, die cloudbasiert auf Plattformen zur Verfügung stehen und weniger Entwicklungsarbeit und Know-how voraussetzen (KI-as-a-Service). Sollten die fertigen Lösungen entwicklungsseitig nicht vorhanden sein, kann der durch die Unternehmen bewusst aufkommende Bedarf die Entwicklung positiv beeinflussen.

Bis zur Realisierung der potenziellen Synergie von KI im Nachhaltigkeitsmanagement gilt es jedoch noch einige Deltas im Mittelstand zu schließen. So werden fehlendes Know-how und eine mangelnde Datenbasis von den befragten Experten häufig als Hemmnisse genannt. Auch der daraus resultierende Mangel an Best-Practices, die die Möglichkeiten in dem Bereich aufzeigen können, erschwert die Auseinandersetzung von KMU mit der Technologie und folglich auch Anwendung im Nachhaltigkeitsbereich. Zuletzt benötigt es laut der Interviewten auch das Vertrauen und den Mut, sich der Thematik anzunehmen und mögliche Anwendungsbereiche im Unternehmen zu identifizieren.

6 Schlussfolgerung und Ausblick

Digitalisierung und Nachhaltigkeit sind unbestritten zwei Megatrends unserer Zeit und auch bereits im Mittelstand angelangt. Die Erhebungen mit Experten zeigen jedoch auch, dass hier noch Bedarf an Sensibilisierung, Information und Qualifikation besteht.

Im Mittelstand scheint vor allem die ökonomische Dimension der Nachhaltigkeit im Vordergrund zu stehen. KMU investieren eher in nachhaltige Maßnahmen, wenn die wirtschaftlichen Vorteile erkennbar sind. Eine andere Motivation, aber auch vergleichsweise mehr Ressourcen haben hier Großunternehmen, die aufgrund ihres größeren Bekanntheitsgrads und dadurch ebenso stärkerem, öffentlichen Druck öfter auch ökologische Nachhaltigkeitsmaßnahmen ergreifen. Hilfreich sind hier, zur Inspiration und Motivation der KMU, das Aufzeigen von bereits erfolgreich umgesetzten Nachhaltigkeitsmaßnahmen aus dem Mittelstand, auch im Bereich Ökologie und Soziales – und das nicht nur bei Nachhaltigkeitsmaßnahmen, sondern auch im Bereich KI.

Denn mithilfe von KI kann ein großes Unterstützungspotenzial für KMU erschlossen werden. So z. B., um Prozesse im Unternehmen effizienter zu gestalten und den Ressourcenverbrauch zu optimieren und dadurch zu verringern. Ökonomische und ökologische Nachhaltigkeit stehen hier im Einklang – wenn die Effizienzeffekte durch KI größer sind als der zusätzliche Energieaufwand durch die benötigte Rechenleistung der KI. So sind es auch hauptsächlich die Bereiche von CSR, die sich auf die ökologische und ökonomische Komponente belaufen, die ein Potenzial für KI bieten. Dort, wo im Unternehmen Daten gesammelt und mit Optimierungsintention aufbereitet werden können, sind KI-Anwendungen realisierbar. Für die soziale Dimension der Nachhaltigkeit eignet sich KI jedoch nur bedingt.

Zur Realisierung der Vorteile von KI-Anwendungen in KMU fehlt es vor allem an Know-how sowie an ausreichender Datenbasis und digitaler Infrastruktur im Unternehmen. Auch braucht es mehr und vor allem für den Mittelstand nachvollziehbare Anwendungsbeispiele, die KMU motivieren, solche Vorhaben in Angriff zu nehmen. Ist der Wunsch aufseiten der KMU einmal geweckt, sind es aus Ressourcen- und Wissensgründen häufig standardisierte KI-Lösungen auf Cloud-Basis (KI-as-a-Service), die sich für kleinere Unternehmen anbieten. Sinnvoll im Unternehmen integriert, hat KI das Potenzial, die CSR-Maßnahmen in KMU zu optimieren und bestehende Prozesse in diesem Rahmen effizienter zu gestalten.

Hilfe zur Schließung des Deltas, im Hinblick auf das fehlende Know-how und Fachkräfte im Mittelstand, bieten verschiedene Förderinitiativen der Bundesregierung. So z. B. der Förderschwerpunkt des BMWi, Mittelstand-Digital. Hier erhalten KMU kostenfrei und anbieterneutral Informationen und Unterstützung bei der Anvisierung und Umsetzung von Digitalisierungsvorhaben, wozu auch die Implementierung von KI-Anwendungen zählt [11]. Solche und weitere Unterstützungsmöglichkeiten eignen sich, um den Mittelstand bei der Verwendung von KI im Nachhaltigkeitsmanagement zu unterstützen.

Literatur

1. Bundesministerium für Wirtschaft und Energie (2020) Nachhaltigkeit in der Wirtschaft. <https://www.bmwi.de/Redaktion/DE/Textsammlungen/Wirtschaft/leitprinzip-nachhaltigkeit.html>. Zugriffen: 18. Febr. 2020
2. Bundesministerium für Arbeit und Soziales (2020) Nachhaltigkeit und CSR. <https://www.csr-in-deutschland.de/DE/Was-ist-CSR/Grundlagen/Nachhaltigkeit-und-CSR/nachhaltigkeit-und-csr.html>. Zugriffen: 03. März. 2020
3. Bundesministerium für Wirtschaft und Energie (2020) Nachhaltigkeit: Themenheft Mittelstand-Digital. Berlin
4. Bundesministerium für Umwelt, Naturschutz und nukleare Sicherheit (2020) Chancen und Risiken der Digitalisierung. <https://www.bmu.de/themen/nachhaltigkeit-internationales-digitalisierung/digitalisierung-und-umwelt/chancen-und-risiken-der-digitalisierung/>. Zugriffen: 27. März. 2020

5. BVMW – Bundesverband mittelständische Wirtschaft, Unternehmerverband Deutschlands e.V. (2020) Der Mittelstand ist Garant für Stabilität und Fortschritt. <https://www.bvmw.de/themen/mittelstand/zahlen-fakten/>. Zugriffen: 18. Febr. 2020
6. Techconsult (2019) Digitalisierungsindex Mittelstand 2019/2020, November 2019
7. Bundesregierung (2018) Nationale Strategie für Künstliche Intelligenz
8. IfM Bonn (2020) Mittelstand im Überblick. <https://www.ifm-bonn.org/statistiken/mittelstand-im-ueberblick/#accordion=0&tab=0>. Zugriffen: 28. Juli 2020.
9. WIK (2019) „Künstliche Intelligenz im Mittelstand: Relevanz, Anwendungen und Transfer“, Expertenumfrage im Rahmen der Mittelstand-Digital Begleitforschung
10. Mittelstand 4.0-Kompetenzzentrum Magdeburg (2020) Umsetzungsprojekt „Neue digitalisierte Geschäftsmodelle für den Lebensmittelhandel“ – Projekttagbuch der Wein:Sein GmbH. https://www.vernetz-wachsen.de/praxisbeispiele/umsetzungsprojekt_digitalisierte_geschaeftsmodelle_lebensmittelhandel_projekttagbuch_wein-sein_gmbh/. Zugriffen: 10. Aug. 2020
11. Mittelstand-Digital (2020) Mittelstand-Digital Homepage. <https://www.mittelstand-digital.de/MD/Navigation/DE/Home/home.html>. Zugriffen: 02. Sept. 2020

Martin Lundborg studierte Wirtschaftswissenschaften an der Universität Jönköping (Schweden) und der Christian-Albrechts-Universität zu Kiel. Seit seinem Abschluss im Jahr 1999 war er für verschiedene Beratungsunternehmen sowie für Vodafone tätig. Bis Jahresende 2017 arbeitete Martin Lundborg für Detecon (eine Beratungstochter der Deutschen Telekom) im Bereich Telekommunikation und Digitalisierung. Seit 1. Januar 2018 ist er für WIK als Abteilungsleiter für Kommunikation und Innovation tätig und leitet die Begleitforschung des BMWi-Förderprogrammes Mittelstand-Digital.

Lisa Schrader-Grytsenko studierte Handelsmanagement und Dynamic Management in Brühl, Köln und Moskau. Zu ihrer dualen Studienzeit arbeitete sie sowohl für ein international agierendes Start-up als auch bei der Telekom Deutschland GmbH. Im Jahr 2016 war sie als wissenschaftliche Mitarbeiterin im Bereich CSR drei Jahre an der Hochschule Bonn-Rhein-Sieg tätig. Es folgten Tätigkeiten bei internationalen Industrieunternehmen zu Digitalisierung und Organisationsentwicklung sowie eine Beratungstätigkeit bei der Accenture GmbH im Kontext der Digitalisierung des öffentlichen Diensts. Seit 2019 ist Frau Schrader-Grytsenko bei der WIK GmbH als Economist und unter anderem in die Begleitforschung des BMWi-Projekts Mittelstand-Digital eingebunden. Zu ihren inhaltlichen Schwerpunktthemen zählen künstliche Intelligenz, Digitalisierung im Handel und Nachhaltigkeit.

Christian Märkel studierte Volkswirtschaftslehre an der Westfälischen Wilhelms-Universität Münster sowie an der Universität Zürich. Nach seinem Masterabschluss war Herr Märkel über drei Jahre als wissenschaftlicher Mitarbeiter am Centrum für angewandte Wirtschaftsforschung (CAWM) an der Universität Münster tätig, wechselte dann in den nordrhein-westfälischen Landtag in Düsseldorf als Wissenschaftlicher Mitarbeiter. Als Referent des kommunalpolitischen Sprechers der CDU-Landtagsfraktion setzte sich Herr Märkel intensiv mit dem interkommunalen Finanzausgleich, der Fiskalpolitik sowie mit der Integrationspolitik auseinander. Seit 2017 ist er bei der WIK GmbH als Economist unter anderem in die Begleitforschung des BMWi-Projekts Mittelstand-Digital eingebunden. Zu seinen inhaltlichen Schwerpunktthemen zählen die Anwendungsmöglichkeiten von Blockchain und künstlicher Intelligenz im Mittelstand.



CSR am Beispiel „Leftshift One“

Clemens Istel und Gerald Krammer

1 Intro und Vorstellung „Leftshift One“

Leftshift One ist ein österreichisches Hightech-Unternehmen im Bereich der künstlichen Intelligenz (KI). Die in Graz ansässigen Software-Entwickler schufen Europas erstes unabhängiges KI-Betriebssystem AIOS (Artificial Intelligence Operating System). Darin sind verschiedenste KI-Skills enthalten, aus denen beliebig komplexe KI-Anwendungen entlang der gesamten Wertschöpfungskette eines Unternehmens realisiert werden können. Der Einsatz von KI erzeugt so je nach Anwendungsfall eine unterschiedlich starke Transformation des Wertschöpfungsprozesses.

Die soziale Verantwortung im Umgang mit Zukunftstechnologien spielte für die Leftshift-One-Gründer, Patrick Ratheiser und Christian Weber, von Anfang an eine zentrale Rolle in der Firmenphilosophie und der Entwicklung des Produkts. Sowohl bei den Wirkungsweisen der KI an sich als auch den Auswirkungen auf den Menschen handelt das Unternehmen seit jeher entlang moralischer und ethischer Grundsätze. Dazu zählen etwa die Charta der digitalen Grundrechte [1], das Modell der „Layers of Diversity“ nach Gardenswartz und Rowe [2] oder die ethischen Leitlinien der Europäischen Kommission [3].

Daraus entstand unter anderem der Gedanke von sogenannter symbiotischer KI. Dieser Ansatz beschreibt, dass die Technologie immer nur Hand in Hand mit den

C. Istel (✉)

Leftshift One Software GmbH, Graz, Österreich

E-Mail: clemens.istel@leftshift.one

G. Krammer

Leftshift One Software GmbH, Graz, Österreich

E-Mail: gerald.krammer@leftshift.one

© Der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

261

R. Altenburger und R. Schmidpeter (Hrsg.), *CSR und Künstliche Intelligenz*, Management-Reihe Corporate Social Responsibility,
https://doi.org/10.1007/978-3-662-63223-9_14

Menschen agiert und diesen sämtliche Entscheidungen überlässt. Mensch und KI ergänzen sich durch ihre jeweiligen Stärken. Gleichzeitig wird dadurch eine ethische Anwendung der Technologie forciert.

Zudem spielen Datenhoheit und Datensicherheit eine monumentale Rolle für Leftshift One. Das AI Operating System AIOS der Österreicher läuft vollständig autark und ist entweder in einer Private-Cloud oder „on-premises“, also in der internen Infrastruktur von Kunden, gehostet. Die verarbeiteten Daten sind mehrfach verschlüsselt. So behalten User des AIOS stets die alleinige Kontrolle – ein klares Abgrenzungsmerkmal zu anderen Anbietern, die etwa Daten aus ihren Cloud-Angeboten für eigene Zwecke weiterverarbeiten –, oft ohne dass Usern eine Wahl bleibt.

Doch Leftshift One engagiert sich auch über ihr Produkt hinaus in diversen Clustern, Initiativen und auf Events. Parallel zur eigenen Softwareentwicklung geht es dem Unternehmen unter anderem um Aufklärung und Wissensvermittlung zu KI. Das betrifft neben der Komponente Ethik auch den ökologischen Einsatz von Zukunftstechnologien.

2 Ausgangslage

Die wissenschaftliche Definition von KI ist im Gegensatz zu den verbreiteten Vorstellungen in der Bevölkerung klar [4]. Man unterscheidet zwischen starker und schwacher KI, kennt die diversen eingesetzten Algorithmen, benennt unterschiedliche Lernmethoden für die Erstellung und Optimierung von KI-Modellen und verfügt über ein umfangreiches Fachvokabular für den gesamten Prozess der Anwendungen von KI. Möchte man soziale Verantwortung jedoch ganzheitlich adressieren, reicht dieser Blickwinkel nicht aus.

Das österreichische Hightech-Unternehmen nimmt bei seinen Tätigkeiten deshalb stets mehrere Perspektiven ein. Leftshift One bemüht sich, seine Technologie aus der Sicht von Menschen mit unterschiedlichem Background und unterschiedlichem Fachwissen zu sehen. So offenbaren sich Fragestellungen, die bei einem rein technischen Fokus verborgen geblieben wären.

2.1 Informationsstand innerhalb der Bevölkerung

Zunächst stellte sich das Unternehmen deshalb die Frage: Woher wissen wir Menschen, wie eine neue Technologie funktioniert und welche Folgen sie für unsere Welt hat? Versuchen wir, uns die unterschiedlichen Wissensstände anhand eines sehr vereinfachten Modells vorzustellen. Da gibt es zunächst den kleinen Kreis der Experten, zu denen auch Leftshift One gehört. Sie forschen und entwickeln an unserer Zukunft und haben so Zugang zu Wissen aus erster Hand. Weiterhin existiert ein etwas größerer Kreis um die Experten herum. Hier finden sich die sogenannten „early adopter“, die umgehend mit den neuesten Erkenntnissen in der Praxis experimentieren, Prototypen entwickeln und

so in einer Synergie mit dem engsten Kreis der Experten den Fortschritt mit Formen und vorantreiben.

Stellen wir uns dazu noch einen dritten Kreis vor: Jene Menschen, die direkt von den neuen Technologien beeinflusst werden. Im Fall von KI wären dies beispielsweise die Kunden von KI-Anbietern – und damit die Menschen, die bei diesen Unternehmen arbeiten. Ihr Arbeitsalltag wird gerade transformiert. Weltweit geschieht das laut einer Umfrage von Gartner 2019 bereits in 37 % aller Unternehmen. Die Wachstumsrate sei dabei in den vergangenen Jahren enorm [5]. Zum Vergleich: In Deutschland nutzten laut einer Bitkom-Umfrage im selben Jahr allerdings erst 12 % der Unternehmen KI [6].

Darüber hinaus erfahren Menschen wertvolle Informationen über Zukunftstechnologien im besten Fall aber nur aus zweiter oder dritter Hand. Was diese für einen selbst bedeuten, lässt sich somit schon schwer einschätzen. Doch Technologie durchdringt und beeinflusst alle Lebensbereiche, unabhängig von unserer Kenntnis über sie. Es liegt deshalb nahe, dass die Verantwortung, über einflussreiche Veränderungen der Welt aufzuklären, bei jenen Personen liegt, die direkt an der Veränderung beteiligt sind.

2.1.1 Popkultur vs. Realität

Die Mehrheit der Bevölkerung hat zum Erscheinen dieses Werks also vermutlich noch keine fachlich fundierte Vorstellung davon, was KI tatsächlich ist und wie sie funktioniert. Die dominanten Bilder der Technologie sind jene, die wir in der Popkultur, in Videospielen, Filmen, Serien und Romanen antreffen.

Blockbuster Filme wie „Terminator“, „Matrix“ oder „I, Robot“ führen uns bildgewaltig vor Augen, wie eine Welt aussieht, in der uns die Kontrolle über die Technologie aus den Händen gegliitten ist. Im nicht minder populären Medium Videospiel treffen wir ebenso vielerorts auf spannend schaurige Abhandlungen über das Verhältnis des Menschen zur Technik. Guerilla Games’ „Horizon Zero Dawn“ für Playstation 4 oder das auf mehreren Plattformen erschienene „Portal“ und sein Nachfolger „Portal 2“ sind die wohl berühmtesten Geschichten, in denen sich Technologie verselbstständigt hat. Jedes dieser Werke erreichte ein mehrfaches Millionenpublikum.

Wir sehen in diesen Beispielen eine dystopische Form von starker KI. Also jene Form, die kognitive Fähigkeiten wie wir Menschen besitzt oder diese gar übertrifft. Experten vermuten allerdings, dass starke KI frühestens in einigen Jahrzehnten realisiert werden könnte [7]. Ob diese dann in der Lage sein kann, auch nur in Ansätzen das Ausmaß der Filmvorlagen anzunehmen, ist mehr als fraglich und liegt letztendlich auch in unseren Händen.

Tatsächlich besteht KI zum heutigen Zeitpunkt vorwiegend aus vordefinierten Regeln. Diese bringen, gepaart mit enormer Rechenleistung, mehr oder weniger präzise Approximationen zur Wirklichkeit hervor. KI weiß also nie etwas zu 100 %. Wir bewegen uns immer im Bereich von Wahrscheinlichkeiten.

3 Herausforderungen und Lösungsansätze

Mit den Bildern aus den verschiedensten Unterhaltungsmedien gehen also zum Teil ungerechtfertigte Ängste, aber gleichzeitig auch sehr ernsthafte Herausforderungen einher. Denn bereits heute transformiert KI unseren (Arbeits-)Alltag. Noch sprechen wir dabei von schwacher KI, die eben im Prinzip nur aus Statistik, Mathematik und Heuristiken besteht. Doch mit Machine-Learning- und Deep-Learning-Methoden lassen sich bereits sehr mächtige Anwendungen realisieren.

KI erledigt vor allem einfache Aufgaben deutlich schneller und dabei in größeren Mengen als der Mensch. Geht es etwa darum, Fakten aus Dokumenten aufzubereiten, geschieht dies mit KI aus dem Leftshift-One-Betriebssystem in wenigen Sekunden, während Menschen einige Minuten bräuchten. Sie ist außerdem in der Lage, Kontext aus Mustern zu erkennen und entsprechende Folgehandlungen vorzuschlagen.

Weil sie bereits so vielseitig und leistungsstark ist, taucht immer wieder die Frage auf, ob KI den Mensch ersetzen würde. Zweifelsohne könnte man sich zurücklehnen und die Technologie selbstständig agieren lassen. Warum das verantwortungslos ist und sich Leftshift One ganz bewusst dagegen positioniert, soll im Lauf dieses Kapitels näher erläutert werden.

3.1 Arbeitsplatzthematik – Externe Sensibilisierung

Wenn wir in den Medien von „emerging technologies“ lesen, steht deren Entwicklung weder erst am Anfang, noch wird sie im gegenwärtigen Zustand verweilen. Die ersten Schritte sind meist schon getan, bevor die breite Öffentlichkeit von technologischem Fortschritt erfährt. Veränderung bedeutet immer auch einen Grad an Unsicherheit. Für Leftshift One ist es deshalb immer wichtig, alle Menschen so früh wie möglich an die Technologie heranzuführen und darüber aufzuklären.

Das steirische Hightech-Unternehmen setzt deswegen auf mehrere Kanäle zur externen Sensibilisierung. Dazu zählt die Mitgliedschaft in diversen Clustern (z. B. Silicon Alps, Green Tech Cluster) und Initiativen (z. B. AI AUSTRIA, AI Styria), über deren Netzwerk und öffentliche Veranstaltungen ein steter Informationsaustausch stattfindet. Weiterhin ist Leftshift One immer wieder auf Messen und Events vertreten, die über den eigenen Kernbereich hinausgehen (z. B. HR Inside Summit, Mobile World Congress) oder sich allgemein um Technologie und Innovation (z. B. 4GAMECHANGERS, Fifteen Seconds) drehen. Außerdem halten die Mitarbeiterinnen und Mitarbeiter Gastvorträge an diversen Fachhochschulen und Universitäten, um auch mit der nachfolgenden Generation über die kommenden Technologien in Dialog zu treten.

Bei sämtlichen Umsetzungsprojekten beginnt der Prozess der Aufklärung schon beim ersten Termin. Die ersten Stakeholder sind jene Menschen, in deren Alltag die Technologie direkt eingreift. Sie fragen sich: Wie wird sich meine Firma/Arbeit dadurch verändern? Oder

eben: Wird die Technologie meinen Job übernehmen? Leftshift One bemüht sich hier im ersten Schritt um eine umfassende Aufklärung darüber, was KI tatsächlich zu leisten im Stande ist und was nicht. Denn an vielen Stellen ist sie überhaupt nicht in der Lage, den Menschen zu ersetzen – beispielsweise wenn es um emotionale Intelligenz geht.

Leftshift One fokussiert hier betont auf die ethische Anwendung seiner Technologie. Sie soll Menschen stets „nur“ unterstützen und trifft dabei niemals finale Entscheidungen. Diese obliegen immer den Menschen. Ganz im Sinn der praktizierte Symbiose finden beide gemeinsam die optimale Lösung für ein Problem. Während KI einige Aufgaben also tatsächlich schneller erledigt, braucht es immer den Menschen mit seinem Expertenwissen als Kontrollinstanz und für die persönliche Komponente.

3.2 Selbstständige künstliche Intelligenz vs. Kontrolle durch Menschen

Eng mit der Arbeitsplatzthematik verknüpft ist die Frage, welche Freiheiten KI haben darf und soll. Der deutsche Philosoph Richard David Precht gibt diesbezüglich nicht nur Leftshift One einige wichtige Denkanstöße mit. In seinem Buch *Künstliche Intelligenz und der Sinn des Lebens* [8] behandelt er unter anderem die aus seiner Sicht lächerlichen Warnungen von Technologiegrößen wie Bill Gates oder Elon Musk, nach denen schon bald eine künstliche Superintelligenz die Menschheit unterwerfen könne. Dazu stellt er die berechtigte Frage, wieso denn eine KI überhaupt wie ein Jeff Bezos „denken“ solle, nach ständiger Expansion strebend, und nicht etwa wie ein Philosoph aus der griechischen Antike agieren könne.

Precht fehlt dafür „das Manifeste“ von KI, um wirklich einen derartigen Einfluss auf die Menschen zu haben. Sein Vergleich zwischen Jeff Bezos und etwa Sokrates gibt jedoch zu denken. Es sagt sich leicht, dass wir Menschen diejenigen sind, die unserer Technologie erlauben, was sie darf und was nicht. Doch die Systeme, in denen wir leben, bringen für sich bereits eine Vorentscheidung für die Wirkungsweisen der Technologie mit. Eine kapitalistische Welt funktioniert nach bestimmten Regeln, die den Output einer Machine-Learning-Anwendung ungewollt negativ beeinflussen kann, wenn man sich dieser Regeln nicht bewusst ist und ein Machine-Learning-Modell entsprechend hinterfragt.

3.3 Deep Learning vs. „explainable“ künstliche Intelligenz

Für verschiedene Themenbereiche abseits der Datenwissenschaften wissen wir, wie CSR-Maßnahmen aussehen können, beispielsweise im Human-Resource-, Supply-Chain- oder Produktionsbereich. Für KI- bzw. Machine Learning-Anwendungen gibt es keine festgelegten, allgemeingültigen oder anerkannten Prinzipien. Vielfach sind die


Domänen der Anwendung zu unterschiedlich, um zu gemeinsamen, eindeutigen und klaren Vorgaben zu kommen.

3.3.1 Kein Bias in Trainingsdaten

Machine-Learning-Modelle sind – vereinfacht betrachtet – statistische Modelle, die zur algorithmischen Entscheidungsfindung herangezogen werden. Sie werden anhand vorliegender Daten trainiert und versuchen, sich Muster und Eigenschaften aus den Trainingsdaten anzueignen, um über zukünftige Daten Aussagen treffen zu können. Oftmals ist die Gesamtheit der Trainingsdaten schon ungleichmäßig verteilt. Wenn wir uns dem Thema Human Resources bzw. Recruiting zuwenden, weicht die Geschlechterverteilung der Bewerber etwa von einer 50-zu-50-Aufteilung ab oder eine Altersgruppe ist unter den Bewerbern besonders stark vertreten. Diese Ungleichverteilung bezeichnen wir als Bias. Bias in Datensets kann systematisch sein. Das ist der Fall, wenn beispielsweise ein Jobprofil, das vorwiegend Berufseinsteiger anspricht, einen Überhang jüngerer Bewerber nach sich zieht. Ein Bias kann ebenso zufällig auftreten, ohne ursächliche Systematik, etwa wenn wir uns die Verteilung der bevorzugten Freizeitbeschäftigungen aller Bewerber betrachten, die in der Vergangenheit eingestellt wurden. Es liegt zwar ein eindeutig darstellbarer systematischer Zusammenhang vor, dieser entbehrt jedoch jeglicher Kausalität – oder etwa doch nicht? Vielleicht gibt es einen Zusammenhang? Suche ich als Unternehmen nach Persönlichkeitsprofilen, die eher dieser oder jener Art der Freizeitbeschäftigung zugeneigt sind? Ist dann auch der Umkehrschluss zulässig? Ist die Systematik zufälliger Natur? Stecken verdeckte Muster in Bewerbungstexten, die sich durch Wortwahl, Anzahl der verwendeten Konjunktive, Satzbau etc. erklären lassen? Sie sehen, die Gefahr Entscheidungen aufgrund nichtkausaler Zusammenhänge – und damit ungerechtfertigt zu treffen – ist groß. Derartige Fragen sind oft auch für den menschlichen Experten schwer zu beantworten. Setzen wir Methoden des Machine Learning ein, bisher unbekannte Zusammenhänge in großen Datenmengen aufzuspüren, so treten stets die Fragen nach deren Kausalität auf. Was wir daraus erkennen ist, dass biasfreie Daten sehr selten oder gar nicht existieren und Korrelation auf keinen Fall mit Kausalität gleichzusetzen ist.

Liegt ein gravierender Bias in den Daten vor, so sprechen wir auch von „dirty data“. Aber warum ist das nun von so großem Nachteil? Entscheidungen, die aufgrund von „biased data“ oder „dirty data“ getroffen werden, fließen in das Machine-Learning-Modell zurück, wenn wir daraus neue Trainingsdaten generieren. Das Modell befindet sich in einer Abwärtsspirale, die von einer Schiefelage im Datenset induziert wurde und sich im Lauf der Zeit stetig ausweitet.

[Grafik Sierpinski-Dreiecke, BU: Über Sierpinski-Dreiecke validiert Leftshift One die in AIOS enthaltenen Skills. Für Compound Skills, also die Kombination von mehreren KI-Funktionalitäten, werden diese zu sogenannten Fraktalen kombiniert, um alle Aspekte der Skills in der Teststrategie abzudecken.]



3.4 Policies und Transparenz

Eine Herausforderung für Technologiefirmen wie Leftshift One ist dabei, dass potenzielle Probleme erst während der Nutzung derer Produkte, Plattformen und Softwarelösungen auftreten, diese aber zum Zeitpunkt der Entwicklung schon vorweggenommen werden sollen. Auch wenn es herausfordernd erscheint, entsprechend vorzubeugen, soll das keine Entschuldigung dafür sein, sich als Unternehmen keine Gedanken darüber zu machen. Diesem Problem kann man mit Policies und Prozessen beikommen, die auf Unternehmensebene verankert sind. Sie reichen weit über die Regelungen der Allgemeinen Datenschutzverordnung hinaus und beschäftigen sich etwa auch mit der Beurteilung diskriminierender und anderweitig benachteiligender Effekte, die von Machine-Learning-Modellen ausgehen können.

Modelle aus dem Human-Resource-Bereich oder Modelle zur Betrugserkennung, wie sie Kreditkarten- und Versicherungsunternehmen einsetzen, ziehen die zur Beurteilung notwendigen Informationen auch aus Merkmalen, die in starkem Zusammenhang mit personenbezogenen Daten stehen. Diese aus dem Datenset zu entfernen, würde zugleich dem Machine-Learning-Modell die Möglichkeit nehmen, eine hinreichende Performance zu erzielen. Durch Datenanonymisierung und Datensynthesierung gelingt es, dem Modell die grundlegenden Informationen zur Verfügung zu stellen, ohne dem Anwender oder dem Entwickler sensible Inhalte zugänglich zu machen. In der Gestaltung des Anonymisierungsfilters ist die Gradwanderung zwischen Modellperformance und Nutzung personenbezogener Daten geeignet zu meistern. Ein verbreiteter Bezahl-service, der derzeit nach eigenen Angaben eine Milliarde Benutzer zählt, bietet neben der Bezahlmöglichkeit auch andere Finanzdienstleistungen an, unter anderem die Vergabe von Mikrokrediten für Personen ohne Bankkonto. Der Antragsteller wird anhand

seiner vergangenen Transaktionen und anderer Daten, unter anderem der Kreditwürdigkeit befreundeter Nutzer, beurteilt und erhält das Ergebnis binnen weniger Sekunden. Corporate Guidelines können soziale und ethische Leitlinien beinhalten, speziell solche, die auf die Verwendung persönlicher Daten und daraus gewonnener Rückschlüsse abzielen.

Werden nachteilige Effekte von Machine-Learning-Modellen erkannt und sind die Risiken ähnlich wie in einer Risikoanalyse gelistet, beurteilt und mit Gegenmaßnahmen versehen, können diese frühzeitig in der Entwicklung berücksichtigt werden. Ähnlich wie Machine-Learning-Modelle im Supervised Learning von einem Set an Trainingsbeispielen lernen, können sie sich während des Betriebs anhand eines Ground-Truth-Validierungssets automatisch selbst und regelmäßig auf ethische, soziale Korrektheit überprüfen. Das Ground-Truth-Set soll Beispiele und dazugehörige Musterantworten enthalten, deren Korrektheit das Modell jedenfalls gewährleisten muss. Dieses Set zusammenzustellen bedarf großer Sorgfalt, denn dieses ist nicht nur als technische Leitlinie, sondern auch als sozialetischer Maßstab anzusehen.

In den eben genannten Beispielen setzen wir voraus, dass der verantwortungsvolle Data Scientist zu keiner Zeit beabsichtigt, ein fragwürdiges oder destruktives Machine-Learning-Modell zu erstellen, und darüber hinaus seinen Modellen ein sozialetischer Korrektiv mit auf den Weg gibt, das eine grobe Abweichung zum frühesten Zeitpunkt sichtbar macht oder einen menschlichen Supervisor benachrichtigt. Die Gefahren, die der technologische Fortschritt in der KI mit sich bringt, werden ähnlich oft diskutiert wie dessen Vorteile. Es gibt eine Vielzahl an Szenarien, in denen KI dafür genutzt werden könnte, Menschen digital und außerhalb des Internets gezielt zu schaden. Vom cleveren Chatbot, der dem Benutzer sensible Daten herauslockt, über Methoden, an Passwörter zu gelangen, bis hin zur Überwachung der Bevölkerung mit guter Absicht, bei ständiger Präsenz der Gefahr des Missbrauchs durch unberechtigte Dritte. Gerade bei sich rasch entwickelnden Technologien weisen vorhandene Regulierungen und Gesetzgebungen Schlupflöcher auf oder ganz und gar fehlende Abdeckung. Sie wurden für eine Zeit gestaltet, die vor Beginn der rasanten Entwicklung der KI lag und so ist es überwiegend in der Hand der Unternehmen, sich an ethischen Grundsätzen auszurichten und ihre Strategien unter Gesichtspunkten der sozialen Verantwortung zu prüfen. Darüber hinaus ist auch der Einzelne gefordert, sich als Machine Learning Engineer, Data Scientist, Führungskraft oder Unternehmer der Tragweite seines Handelns bewusst zu werden. Einfach formulierte Unternehmensgrundsätze können nicht nur dazu dienen, die Unternehmensphilosophie und -kultur zu prägen, sondern auch den verantwortungsvollen Umgang mit Daten – insbesondere personenbezogenen Daten – zu wahren. Sie helfen, die Aussagekraft erstellter Machine-Learning-Modelle zu beurteilen und größtmögliche Objektivität zu gewährleisten. Sie vermeiden, menschliche Entscheider subjektiv zu beeinflussen, die von einem Machine-Learning-Modell Hilfestellung und Zusatzinformationen erhalten, insbesondere dann, wenn es um Entscheidungen geht, die für den Einzelnen von großer Bedeutung und von großer Tragweite sind, wie das Human-Resource-Beispiel zeigt.

Bis geeignete Regulierungen für KI-gestützte Anwendungen existieren, obliegt die Diskussion dem Experten- und Nichtexpertenkreis. Wie bisher arbeiten journalistische und Unterhaltungsmedien das Thema „Soziale Verantwortung und KI“ in Form von positiven und negativen, fiktiven und realen Szenarien auf und regen zur Diskussion an. So auch die Ankündigung eines Computerspieleherstellers, in dessen Produkt das Ziel verfolgt wird, eine Zivilisation zu entwickeln. Sobald der Spieler beginnt, KI zu erforschen, startet ein Zähler namens KI-Risiko. Erreicht dieser Zähler einen gewissen Stand, so konnte der Spieler die KI nicht beherrschen und das Spiel ist aus.

3.5 Daten wertschätzen

KI funktioniert ohne eine geeignete Datenmenge nicht. Soziale Verantwortung bedeutet für Leftshift One deshalb auch, dass diesen Daten und ihren Besitzern eine entsprechende Wertschätzung entgegengebracht wird. Denn es ist nicht selbstverständlich, dass diese zur Verfügung gestellt werden.

3.5.1 Respektvoller Umgang mit freigegebenen Daten

Daten und Informationen sind entscheidende Assets für die Wertschöpfung auf verschiedenen möglichen Ebenen und werden deshalb von Unternehmen zunehmend als Wirtschaftsgüter oder gar Währung betrachtet. Sie ermöglichen es den Unternehmen, neue Einnahmequellen zu erschließen und sogar ihre eigenen Geschäftsmodelle zu transformieren. Für viele Unternehmen ist es essenziell, den potenziellen Wert von Daten und Informationen zu verstehen und die Fähigkeit zu besitzen, daraus Kapital zu schlagen. Immer öfter identifizieren Unternehmen bisher ungenutzte Möglichkeiten in Datenquellen, die man zwar hat, die aber noch unberücksichtigt blieben.

Anwender verfügen über unzählige digitale Geräte, Kanäle und Tools, über die eine riesige Anzahl an Daten generiert wird. Über dessen Verwendung haben User jedoch keine Kontrolle mehr. Diese Daten werden unter anderem verwendet, um Personenprofile zu hinterlegen und in weiterer Folge deren Kaufverhalten, Meinung, Kommunikation bis hin zu deren Aussehen in die von einem Unternehmen gewünschte Richtung zu lenken. Verbraucher fühlen sich im Internet dazu befähigt, vieles zu tun, haben aber gleichzeitig das Problem, nicht zu wissen, was mit ihren Daten geschieht. Das Misstrauen diesbezüglich wird bei jedem Datenskandal größer, dennoch nehmen viele Benutzer von den „Bequemlichkeiten“ großer Konzerne keinen Abstand und bleiben diesen Services treu. Viele Benutzer haben sich einfach damit abgefunden, dass ihre Daten und in weiterer Folge ihre Privatsphäre nicht vertraulich behandelt werden.

Trotz der Bemühungen der EU mit der Einführung der Allgemeinen Datenschutz-Grundverordnung (DSGVO), die die Verarbeitung personenbezogener Daten im Einklang mit den Vorschriften über die Einwilligung und Zweck der Verarbeitung gewährleisten soll, werden Daten immer noch nicht mit der gebührenden Wertschätzung behandelt. Vor allem amerikanische und chinesische Unternehmen zeigen erschreckend

auf, wie man mit Daten nicht umgehen sollte. Das ist auch ein wesentlicher Grund, warum die EU das Privacy-Shield-Abkommen mit den USA für ungültig erklärte [9].

Ob es diesen Unternehmen aber gefällt oder nicht, Daten sind mit dem notwendigen Respekt, den richtigen Gründen sowie mit der notwendigen Sorgfalt zu behandeln. Sie müssen geschützt werden, wie wir es mit allen wichtigen Gütern tun würden. Dabei sind Privatsphäre und Datenschutz Teile der Lösung. Politische Entscheidungsträger, Technologieentwickler, Unternehmensentwickler usw. müssen ernsthaft darüber nachdenken, ob und wie wir die Entwicklung der Technologie in Bezug auf Datenverarbeitung und ihre Anwendung beeinflussen wollen. Aber ebenso wichtig ist es, dass wir uns dringend mit dem Thema Ethik in den Technologien der Zukunft befassen.

Dabei wäre es fahrlässig, auf eine Selbstregulierung der Industrien zu vertrauen. Stattdessen müssen Gesetzgeber, Regierungsbehörden und nicht zuletzt die Anwender den respektvollen Umgang mit Daten einfordern. In welchem Maß wir die Verarbeitung personenbezogener Daten transparent gestalten und darüber kommunizieren, wird die Zukunft der digitalen Wirtschaft maßgeblich beeinflussen. Die Umsetzung dieser Forderung kann nur mit einer Kombination aus Aufklärung, Selbstkontrolle, Regulierung, Offenheit und Kommunikation und im Rahmen der DSGVO auch durch scharfe Sanktionen und Strafen erfolgreich sein.

3.5.2 Datenkraken meiden

Smartphones und Software versprechen uns bei jeder neuen Version weitere Verbesserungen, die uns im Alltag noch effizienter zur Seite stehen. Eine Kontaktaufnahme oder die aktuellsten Neuigkeiten sind stets nur noch einen Klick entfernt. Was uns zumeist nicht bewusst ist: Diese Bequemlichkeit gibt es nicht umsonst. Dabei sprechen wir nicht von monetären Kosten, sondern dem Preis, den wir als Gesellschaft und den jeder Anwender für sich zahlen muss.

Die Technologieriesen sammeln Informationen auf dem jeweiligen Gerät der Anwender. Dadurch lassen sich die Aktionen eines Benutzers auch geräteübergreifend verfolgen. Mitunter fließen Daten selbst dann an die Tech-Konzerne, wenn man nicht bei einer jener Plattformen eingeloggt ist oder einen Account besitzt. Diese, dem Benutzer eindeutig zugeteilten Profile, werden dann in weiterer Folge verwendet, um die Aktionen des Anwenders für das Unternehmen gewinnbringend zu verwerten. Dabei werden die „harmlosen“ Ergebnisse dieser Vorgehensweise, wie etwa Produktempfehlungen in Online-Shops, dem Anwender als technologischer Fortschritt verkauft.

Was sich aber hinter dem Deckmantel der technischen Neuerungen bekannter (amerikanischer) Großunternehmen befindet, ist nichts anderes als ein weiterer Schritt, eine Gesellschaft transparenter Menschen zu kreieren. Eine Gesellschaft, deren von Menschen erstellte Daten zerlegt, kombiniert und an den Meistbietenden verkauft werden. Und eine Gesellschaft, in der der Begriff Individuum immer weiter in die Ferne rückt und in der Humanität und unsere Werte drohen verloren zu gehen.

Diese Schritte sind dabei so subtil, dass man den weiteren Verlust der Privatsphäre gar nicht mehr bemerkt. Dieser psychologische Effekt wird auch gern mit „shifting

boundaries“ umschrieben, sprich: die Grenzen des Vertretbaren nur so leicht zu verändern, dass keine Veränderung von der Masse bemerkbar ist. Um unsere Daten müssen Großkonzerne noch nicht einmal besonders aktiv buhlen. Wir schicken sie ohnehin gern weiter, indem wir unseren Alltag in Bildern festhalten und in sozialen Netzwerken offenlegen.

Die Gefahr dabei lässt sich leicht illustrieren. Stellen wir uns einfach eine Utopie vor, in der unsere Profile die Kosten unseres Alltags bestimmen, indem sich beispielsweise der Preis in einem Geschäft ändert, sobald wir es betreten; bzw. eine Utopie – die mittlerweile keine mehr ist –, in der Menschen aufgrund ihrer Profile für Jobchancen am Arbeitsmarkt bewertet werden. Natürlich passiert sowas nicht von heute auf morgen und Veränderungen sind immer schon Teil der Geschichte.

Doch nicht um jeden Preis. Was fehlt ist eine klare Regulierung von Tech-Giganten sowie eine Datenoffenlegungspflicht. Generell gehören Ihre Daten nur Ihnen. Nur wenn Sie die Daten freigeben, dürfen sie weiterverarbeitet werden – so sieht es die DSGVO prinzipiell vor. Einer idealen Vorstellung nach, wie sie Leftshift One auch praktiziert, sollte Technik den Menschen symbiotisch unterstützen und ihn nicht als Datenlieferant unterwerfen. Abschließend bleibt zu bedenken, dass der technologische Fortschritt, der einem versprochen wird, kritisch hinterfragt werden muss. Wer seine Vorlieben dahingehend nicht ändern möchte, sollte zumindest Bescheid wissen.

3.5.3 On-Premise-Ansatz

Aufgrund der vorherrschenden Praktiken entschied sich Leftshift One ganz bewusst zu einer ethischen Gegenbewegung zum bisherigen Cloud-Computing-Trend. Das AIOS garantiert seinen Benutzern 100 % Datenhoheit, indem es autark gehostet werden kann. Im integrierten Skill Store stehen bereits fertige KI-Funktionalitäten zur Verfügung. Das System selbst läuft flexibel mit den jeweils zur Verfügung stehenden Hardware-ressourcen. Kunden müssen für ihre Anwendungen die Daten also nicht länger in den Datenzentren intransparenter Konzerne verarbeiten lassen. Der KI-Baukasten von Leftshift One läuft entweder in einer Private Cloud in ausgewählten, vertrauenswürdigen Rechenzentren in Europa oder „on-premises“, also direkt in der Infrastruktur des Kunden. Dieser Ansatz ist gleichermaßen eine implizite CSR-Maßnahme wie ein unschlagbares Alleinstellungsmerkmal im Vergleich zu den noch dominanten Tech-Konzernen aus Übersee. Diese haben zumeist auch kein Interesse an einer entsprechenden Lösung, weil ihr primäres Businessmodell schlicht auf dem Sammeln irrsinniger Datenmengen beruht. Während Strömungen aus den USA und ganz besonders aus China die Europäische Wahrung der Privatsphäre als Hindernis für technologischen Fortschritt brandmarken, zeigen die Erfahrungen bei Leftshift One, dass Datensicherheit und Datenhoheit vor dem Hintergrund der internationalen Datenkraken überaus geschätzte und zunehmend mehr eingeforderte Aspekte für europäische Unternehmen sind. Oberstes Ziel von Leftshift One ist diesbezüglich also, den freiwillig zur Verfügung gestellten Daten mit dem größtmöglichen Respekt und größtmöglicher Sicherheit zu begegnen.

3.6 Interne Sensibilisierung

Um all diesen Vorhaben entsprechen zu können, war es für das österreichische Hightech-Unternehmen stets wichtig, Mitarbeiterinnen und Mitarbeiter mit dem entsprechenden Mindset zu finden. Der Gründungsgedanke um ethische, symbiotische KI kann nur von einem starken Teamzusammenhalt getragen werden. Leftshift One hat deshalb eine Firmenkultur geschaffen, die anhand von definierten Corporate Values die soziale Verantwortung beim Umgang mit Zukunftstechnologie adressiert. Zu diesen Werten zählt beispielsweise das ständige Bewusstsein um das große Ganze. Das Unternehmen gestaltet mit seinem Produkt aktiv die Zukunft. Das hat selbstverständlich großen Einfluss auf die direkten Kunden, die Arbeitswelt allgemein sowie unsere Gesellschaft insgesamt. Mitarbeiterinnen und Mitarbeiter bedenken die damit einhergehenden Verpflichtungen und entwickeln das Produkt mit einem ausgeprägten Verantwortungsbewusstsein weiter. In diesem Punkt findet sich auch das zuvor angesprochene Einnehmen unterschiedlichster Perspektiven innerhalb der Bevölkerung wieder. Gleichmaßen stecken auch die Wertschätzung für Daten, der Respekt für die Bedürfnisse der Menschen und das Pflichtbewusstsein gegenüber Kunden, aber auch den eigenen Kollegen, in den Corporate Values von Leftshift One.

4 Best Practice Leftshift One

Abschließend illustriert ein Blick in die Projektpraxis von Leftshift One die bisher ausgeführten Ansätze, die das Hightech-Unternehmen in Bezug auf CSR verfolgt. Die folgenden Insights umfassen die Themen Datenschutz und Datenhoheit sowie den diskriminierungsfreien Einsatz von KI im besonders sensiblen Bereich des Recruitings. In diesem Use Case wird plastisch, welche Praktiken uns für einen verantwortungsbewussten Umgang mit KI unter anderem begleiten müssen.

4.1 Opt-in zur Datenverarbeitung

Im Gegensatz zu anderen Anbietern nutzt Leftshift One die Daten von Unternehmen ausschließlich zur Erstellung der von ihnen gewünschten Softwarelösung. Sie werden grundsätzlich weder gespeichert noch für andere Projekte herangezogen. Außerdem sind die Daten in der Regel verschlüsselt und somit auch überhaupt nicht einsehbar. Natürlich können diese Daten mitunter auch für andere Use Cases oder die Forschung von Nutzen sein. Einer Verwendung dafür müssen Kundenunternehmen aber stets erst explizit zustimmen. Datenhoheit ist in jedem Use Case oberstes Gebot.

4.2 Use Case Digital HR-Assistant (ethisches Künstliche-Intelligenz-Modell)

Ein großer Systemgastronom in Österreich stand am Beginn des Projekts vor der Herausforderung, für seine rund 200 Filialen ein Volumen von 60.000 Bewerbungen jährlich bewältigen zu müssen. Mit dem herkömmlichen Human-Resources-Prozess waren die Kapazitäten so mehr als ausgeschöpft. Die Anzahl der Bewerbungen sollte in den folgenden Jahren sogar noch ins Sechsstellige steigen. Deshalb erwog der Konzern einen innovativen Einsatz von künstlicher Intelligenz. Was auf den ersten Blick wie eine einfache Prozessoptimierungen aussah, brachte bei näherer Betrachtung einige heikle Problemstellungen mit sich.

Zu Beginn des Projekts waren bereits Negativbeispiele für den diskriminierenden Einsatz von KI im HR-Bereich bekannt. In einem Fall sollte ein Algorithmus Bewerber für ein Unternehmen nach der Wahrscheinlichkeit reihen, wie lange diese bei ihrem Arbeitgeber bleiben würden. Als begünstigender Faktor war dem KI-Modell die Nähe zum Arbeitsplatz vorgegeben worden. Menschen, die am Stadtrand wohnten, wurden in diesem konkreten Fall benachteiligt. Dieser Umstand deckte sich allerdings auch noch mit einer bestimmten ethnischen Gruppe, die aufgrund von bereits existierender gesellschaftlicher Diskriminierung durch ihre Einkommenssituation gezwungen war, in den billigeren Randbezirken zu leben. Der Algorithmus lernte selbstständig und zog daraus den rassistischen Schluss, dass die gesamte ethnische Gruppe für den Job auszuschließen sei, weil niemand diesen Bias im Vorhinein bedachte.

Aber auch in Österreich sorgte ein Algorithmus für Aufregung. Der Arbeitsmarktservice setzte diesen ein, um die Einstellungschancen der Bevölkerung abzubilden. Die Software bewertete Frauen prompt aufgrund ihrer möglichen Sorgepflichten bei Kindern schlechter. Der Aufschrei war groß und Experten kritisierten umgehend, dass diese Darstellung noch lange Folgeschäden nach sich ziehen würde [10].

Leftshift One musste also nicht nur den Prozess an sich optimieren, sondern sollte dabei auch eine Methode finden, um Diskriminierung zu verhindern. Dies gelang in Form eines smarten digitalen Bewerbungsassistenten. Potenzielle Bewerber treten mit dem Systemgastronom seit Herbst 2018 sowohl auf Desktop als auch mobil über einen smarten Questionnaire in Kontakt. Dieser ermittelt in wenigen Minuten über Fragen und einen kurzen psychologischen Test die wichtigsten Eckdaten der Bewerber. Der Upload eines Lebenslaufs ist dafür nicht länger notwendig.

Die KI im Hintergrund kann diese Daten nun in Bezug auf die ausgeschriebene Stelle aufbereiten. Sie liest daraus nicht nur die Hard Facts, wie Sprachkenntnisse oder das gewünschte Stundenausmaß der Anstellung, sondern auch Soft Skills aus, beispielsweise, ob jemand gern besonders akribisch allein arbeitet oder ein kreativer Teamplayer ist. Wichtig dabei ist, dass die KI hier keinerlei Entscheidungen trifft oder eine Reihung vornimmt. Sie stellt die Daten den Human-Resources-Agents lediglich in aggregierter Form zur Verfügung, damit diese auf deren Basis schließlich eine höher qualifizierte Entscheidung treffen können.

Daten mit Diskriminierungspotenzial, wie Alter, Geschlecht oder Herkunft, fließen erst überhaupt nicht in diesen Prozess ein. Außerdem war Leftshift One bei der Umsetzung gemeinsam mit einem Partnerunternehmen darum bemüht, die User Experience so angenehm und zufriedenstellend wie möglich zu gestalten. Denn die beste Software ist keine Hilfe, wenn ihre User sie ungern bedienen. Deshalb versetzten sich die Entwickler in die Lage der Bewerber und gestalteten ein übersichtliches und intuitives Interface für die Konversation mit dem Assistenzsystem.

Das überzeugte die Bewerber. Eine Auswertung der ersten Monate zeigte, dass das faire, smarte Recruiting über den digitalen Assistenten zu massiv gesteigerten Abschlusszahlen führte. Bisherige Kontaktformulare werden, sobald einmal begonnen, nur zu rund 7 % fertiggestellt. Die Lösung von Leftshift One für den Systemgastronom führt dagegen in mehr als der Hälfte aller Anfragen auch zu einer abgeschickten Bewerbung. Gleichzeitig steigerte der innovative Ansatz auch die Qualität der Bewerbungen selbst, indem alle notwendigen Daten direkt erhoben werden. Ein Nachfragen bei unvollständigen Lebensläufen bleibt so aus.

Der smarte Recruiting-Assistent schafft also den schwierigen Spagat zwischen Userfreundlichem Design, Prozessoptimierung und gleichen, fairen Bedingungen für alle Bewerber. Damit konnte Leftshift One beweisen, dass mit dem richtigen Mindset und ausreichender Sorgfalt aus KI selbst in heiklen Bereichen ein ethischer Mehrwert für die Gesellschaft entstehen kann. Das Projekt eröffnete in der Folge diverse weiterführende Forschungsprojekte rund um den ethischen Einsatz von KI.

- Darüber hinaus existieren noch weitere Use Cases aus der Pharmaindustrie oder der Automotive-Branche, die sich mit den Themen Compliant AI, Trustworthy AI und Explainable AI vertieft befassen. Aufgrund der vertraglich festgelegten Verschwiegenheitsverpflichtung dürfen diese Beispiele zu Redaktionsschluss dieses Buchs leider noch nicht detailliert besprochen werden. Leftshift One publiziert neue Use Cases jedoch bei Veröffentlichung zeitnahe auf seiner Firmenwebseite www.leftshiftone.com. Dort finden sich überdies stets aktuelle Infos zu Events, auf denen Experten des Unternehmens über KI und aktuelle Entwicklungen um das AI Operating System sprechen.

Quellen

1. <https://digitalcharta.eu/>. Zugegriffen: 24. Nov. 2020
2. <https://www.gardenswartzrowe.com/>. Zugegriffen: 24. Nov. 2020
3. https://ec.europa.eu/germany/news/20190626-ethische-leitlinien-fuer-kuenstliche-intelligenz-vorgelegt_de. Zugegriffen: 24. Nov. 2020
4. <https://www.mimikama.at/aktuelles/manipulation-ki/>. Zugegriffen: 24. Nov. 2020
5. <https://www.gartner.com/en/newsroom/press-releases/2019-01-21-gartner-survey-shows-37-percent-of-organizations-have>. Zugegriffen: 24. Nov. 2020

6. <https://www.bitkom.org/Presse/Presseinformation/Industrie-40-Kuenstliche-Intelligenz-zieht-Fabrikhallen-ein>. Zugegriffen: 24. Nov. 2020
7. <https://jaai.de/starke-ki-schwache-ki-was-kann-kuenstliche-intelligenz-261/#:~:text=Die%20Mehrheit%20der%20Forscher%20ist,Jahren%20gilt%20jedoch%20als%20realistisch>. Zugegriffen: 24. Nov. 2020
8. Precht RD (2020) Künstliche Intelligenz und der Sinn des Lebens. Goldmann, München. ISBN-13 978-3442315611
9. <https://www.derstandard.at/story/2000118748636/eugh-kippt-datenabkommen-zwischen-eu-und-usa>. Zugegriffen: 24. Nov. 2020
10. <https://futurezone.at/netzpolitik/der-ams-algorithmus-ist-ein-paradebeispiel-fuer-diskriminierung/400147421>. Zugegriffen: 24. Nov. 2020

Clemens Istel Seit 2018 ist Clemens Istel (geb. 1985) Teil des Kommunikationsteams von Leftshift One. Als Content Developer und Content Manager befasst er sich intensiv mit dem Thema Ethik in Kombination mit Zukunftstechnologien. Zuvor machte er seinen Bachelor of Arts in Social Sciences (BA) an der FH JOANNEUM in Graz in Journalismus und Public Relations (PR).

Gerald Krammer Als Lehrender im Masterstudiengang Data and Information Science der FH JOANNEUM in Graz vermittelt Gerald Krammer (geb. 1979) realitätsnahe, wie Künstliche-Intelligenz(KI)- und Mechatronikprojekte umgesetzt werden. Nicht nur deshalb ist der Head of AI und Data Science von Leftshift One stets am Puls der Zeit, wenn es um KI geht. Für das österreichische Hightech-Unternehmen entwickelt der Leiter des KI-Teams KI-Projekte von der explorativen Datenanalyse bis zum fertigen KI-Modell und gestaltet die AI Roadmap mit.

Soziale Robotik, HR/Arbeitgeberattraktivität, Führung und Zukunft der Arbeit



Mein neuer Teamkollege ist ein Roboter! Wie soziale Roboter die Zukunft der Arbeit verändern können

Sabine T. Koeszegi und Astrid Weiss

1 Einleitung

Bisher fokussierte die öffentliche Debatte über Robotik häufig darauf, welche Berufe in Zukunft durch Automatisierung betroffen sein werden und wie sich dies auf Beschäftigungszahlen auswirken wird. Bis vor Kurzem sind vor allem jene Tätigkeiten, für die kein besonderes Fähigkeitsprofil notwendig ist (sogenannte „low-skilled jobs“) Gefahr gelaufen, automatisiert zu werden. Durch die vielversprechenden Entwicklungen im Bereich der KI- und Robotik-Technologien, aber insbesondere im Bereich des Maschinellen Lernens, können heute auch Aufgaben, die bisher qualifizierten Wissensarbeiter_innen (sogenannte „middle-skilled jobs“) vorbehalten waren, automatisiert werden. Neuere KI- und Robotiksysteme können autonom agieren, ihre Umwelt und ihren eigenen Zustand wahrnehmen und interpretieren, daraus lernen und ihr Verhalten an ihre Umwelt anpassen (vgl. dazu AI HLEG Definition von KI-Systemen¹).

¹ A definition of AI: Main Capabilities and Disciplines: Definition developed for the purpose of the AI HLEG's deliverables, AI HLEG of the European Commission, April 2019; <https://ec.europa.eu/digital-single-market/en/news/ethics-guidelines-trustworthy-ai>

S. T. Koeszegi (✉)

Institute of Management Science, TU Wien, Forschungsbereich Labor Science and Organization, Wien, Deutschland

E-Mail: sabine.koeszegi@tuwien.ac.at

A. Weiss

Institute of Visual Computing and Human-Centered Technology, TU Wien, Forschungsbereich Human Computer Interaction, Wien, Deutschland

E-Mail: astrid.wiss@tuwien.ac.at

Wenn diese Systeme auch direkt mit Menschen interagieren, werden sie verkürzt auch „soziale Roboter“ genannt. Aber nicht nur Buchhalter_innen, Steuerberater_innen, oder Kundenberater_innen können durch autonome KI- und Robotiksysteme ersetzt werden. Ganz aktuell gibt es Forschungsprojekte, die Roboter auch in Bereichen einsetzen, die ein bestimmtes Ausmaß an sozialen und kognitiven Kompetenzen erfordern: Roboter sollen beispielsweise auch in der Betreuung und Pflege von Menschen, in der Konfliktmediation oder im Recruiting eingesetzt werden. Obwohl in diesen Anwendungsgebieten nicht ganze Jobs von Robotern erledigt werden können, so ist zumindest vorstellbar, dass sie auch qualifizierte Aufgaben übernehmen, für die keine besonderen menschlichen Qualitäten, wie körperliche Geschicklichkeit, kreative Intelligenz oder Improvisation erforderlich sind.

Die Einführung von KI- und Robotiktechnologien hat damit auch eine Debatte über sinnstiftende und bedeutungsvolle Arbeit ausgelöst. Unter der – impliziten und zumeist unhinterfragten – Annahme, dass Arbeit vielfach ein mühevolleres Übel ist, von dem Menschen gern befreit wären, erscheinen robotische Teamkollegen als willkommene Alternative. So findet man häufig das Argument, dass insbesondere repetitive, schmutzige, anstrengende oder gefährliche Arbeiten Robotern überlassen werden könnten, damit Menschen sich auf sinnstiftende und kreative Aufgaben konzentrieren können. Doch was ist sinnstiftende und bedeutungsvolle Arbeit für den Einzelnen? Werden heute tatsächlich Aufgaben automatisiert, weil dies wünschenswert ist (etwa weil die Arbeit gefährlich oder anstrengend ist) oder doch eher, weil es technisch möglich und ökonomisch von Vorteil ist?

Klar ist jedenfalls, dass der Einsatz autonomer Roboter das Aufgaben- und Jobprofil in vielen Bereichen verändern wird. Aber wie wird sich diese Veränderung auf unser Erleben von Arbeit auswirken? Wie kann sichergestellt werden, dass Menschen in Zukunft mit KI- und Robotikunterstützung sinnstiftende und bedeutungsvolle Arbeit haben können? Können die Bedürfnisse der Menschen bei der Entwicklung sozialer Roboter so berücksichtigt werden, dass sie Roboter als sinnvolle Unterstützung in ihrer Arbeit erleben oder sie vielleicht sogar als „Teamkollegen“ akzeptieren können?

Diese Fragen lassen sich nicht generell für alle Anwendungsgebiete beantworten und werfen auch weitere wichtige ethische Fragestellungen auf. Es ist notwendig, eine soziotechnische Perspektive auf den Einsatz dieser Technologien zu werfen. Erst in der konkreten Implementierung und Anwendung in einem spezifischen Kontext werden die unterschiedlichen Facetten der neuen Technologien und die mit ihnen verbundenen Herausforderungen sichtbar. In den folgenden Abschnitten nehmen wir diese soziotechnische Perspektive ein und zeigen dabei wichtige Aspekte der Mensch-Roboter-Kollaboration auf. Die Analyse aktueller Studien zu (neuen) Anwendungsgebieten von Cobots und sozialen Robotern erlaubt einen kritischen Blick auf die Erfahrungen mit diesen neuen Technologien, auf ihre aktuellen Grenzen der technischen Machbarkeit sowie auf die sozialen und gesellschaftlichen Herausforderungen, die durch die

Integration sozialer Roboter in Arbeitsprozesse entstehen. Schließlich werfen wir in der Diskussion die wichtige ethische Fragestellung auf, wie sozial Roboter überhaupt sein sollten.

2 Was sind eigentlich soziale Roboter? – Eine Begriffsbestimmung

Es gibt eine Vielzahl an Begriffen, die derzeit in Debatten über KI- und Robotiktechnologien verwendet werden. Einerseits wird von Automatisierung bzw. von autonomen Systemen, von Digitalisierung, Industrie 4.0 oder Internet der Dinge gesprochen, andererseits werden Begriffe wie soziale Roboter, Cobots und Mensch-Roboter-Kollaboration verwendet. Oftmals werden diese Begriffe synonym verwendet, manchmal aber auch differenziert für spezifische Systeme oder Anwendungen. Im folgenden Abschnitt wird eine Begriffsbestimmung und Abgrenzung versucht, um zu definieren, was in weiterer Folge in diesem Kapitel unter sozialen Roboter und Cobots zu verstehen ist.

Automatisierung kann im weitesten Sinn als das Delegieren von Aufgaben vom Menschen an eine Maschine verstanden werden. Nach einer weit verbreiteten Definition ist Automatisierung ein Prozess, der eine Funktion oder Aufgabe ohne menschliches Eingreifen steuert (Billings 1991). Während die Automatisierung zunächst nur im Bereich der industriellen Fertigung eingesetzt wurde, ist sie heute überall um uns herum anzutreffen, wobei leistungsfähigere Computer auch Informationsanalyse und komplexe Entscheidungsfindung übernehmen. Die für die sogenannte Industrie 4.0 in Betracht gezogenen Digitaltechnologien, zu denen unter anderem das Internet der Dinge, cyberphysische Systeme, Cloud-Technologie und Big Data gezählt werden, werden die Automatisierung auch im Dienstleistungssektor noch weiter vorantreiben. Eine Arbeitswelt, die diese Technologien integriert, wird zu einem vernetzten, selbstorganisierenden System, das nur minimale menschliche Eingriffe erfordert, aber die Fähigkeit hat, sich an die menschlichen Bedürfnisse anzupassen (Lasi et al. 2014). Allerdings verschwimmen in solchen Systemen auch die Grenzen zwischen der physischen Welt und dem virtuellen Raum (Wang et al. 2015).

Im Kontext der industriellen Fertigung besteht der Zweck der KI- und Robotiktechnologie vor allem darin, bestimmte Produktionsaufgaben zu erleichtern. In diesem Zusammenhang wird ein Roboter als intelligentes Werkzeug verstanden, dessen Konfiguration von Sensoren, Aktoren und integriertem Steuerungssystem ein erhebliches Maß an flexiblen, unabhängigen und autonomen Aktionen ermöglicht (Montebelli et al. 2017). Ein Roboter ist somit eine KI mit physikalischer Instanz und Mensch und Roboter müssen ihre Aktivitäten im Hier und Jetzt koordinieren. Im Gegensatz zu Robotern, die rein für die Automatisierung von Fertigungsprozessen in einer Arbeitszelle konzipiert sind,



Abb. 1 Franka Emika Panda Roboterarm für den industriellen Kontext

sind sogenannte kollaborative Roboter (Cobots) dafür konzipiert, neben dem Menschen zu arbeiten und mit ihm zu interagieren und zusammenzuarbeiten. Cobots sind eine neue Generation von Robotern, die nicht durch irgendeine Art von Zaun abgegrenzt sind und dadurch die Einsatzmöglichkeiten von Standardindustrierobotern und klassischer Automatisierung überschreiten. Ihr Sensorensystem ermöglicht es, schnell zu reagieren und sofort anzuhalten, wenn sie auf einen Menschen oder auf falsch platzierte Objekte auf ihrem Weg treffen (Kadir et al. 2018). Um einen sicheren Betrieb aufrechtzuerhalten, muss jedoch die Geschwindigkeit von Cobots bei größerer Nähe zum Menschen geringer sein (Zanchettin et al. 2015). Daher sind Cobots typischerweise gezwungen, mit geringeren Geschwindigkeiten und Kräften zu arbeiten als traditionelle „Käfigroboter“. In einigen Fällen werden sie deshalb mit leichteren Materialien und/oder dämpfenden Polstern konstruiert, um Verletzungen bei unbeabsichtigten Kollisionen zu reduzieren (Bogue 2016). Zu den Hauptmerkmalen, die einen Cobot von einem traditionellen Industrieroboter unterscheiden, gehören verbesserte Sicherheitsmerkmale für die Arbeit in unmittelbarer Nähe von Bediener_innen und eine vereinfachte Programmierung, die einen flexiblen Einsatz innerhalb der Fabrik ermöglichen sollen (Faccio et al. 2019). Die Idee dahinter ist, dass kleine und mittlere Unternehmen (KMU) einmal eine kostenintensive Robotertechnologie erwerben, sie dafür aber in verschiedenen Anwendungsbereichen nach Bedarf einsetzen können, um zum Beispiel menschliche Tätigkeiten wie Montage, Verpackung und Organisation zu unterstützen (Bogue 2016). Gemeinsame Mensch-Roboter-Aktivitäten umfassen oft die maschinelle Bearbeitung, bei der eine automatisierte Maschine ein Werkstück herstellt oder zusammenbaut, das von einem Menschen danach weiter bearbeitet oder fertiggestellt werden muss (Abb. 1).

Abb. 2 Pepper (Softbank) im der Bibliothek der TU Wien, einem Living Lab des DK Trust Robots (TU Wien)



Roboter, die uns in der industriellen Fertigung begegnen, haben meist die Gestalt von Roboterarmen oder autonomen Transportplattformen. Ein *sozialer* Roboter ist ein autonomer oder halbautonomer Roboter, der mit Menschen interagiert und kommuniziert, indem er den Verhaltensnormen folgt, die von den Menschen, mit denen der Roboter interagieren soll, erwartet werden (Bartneck und Forlizzi 2004). Daher werden diese Roboter oftmals in humanoider Form gestaltet oder aber auch als Roboter mit „sozialer Schnittstelle“ definiert (Hegel et al. 2009) – abhängig davon, ob diese Systeme eine Verkörperung haben oder nicht. Soziale Roboter begegnen uns etwa in Form von Chatbots oder Assistenzsystemen. Wie Cobots können sie aber auch eine Verkörperung haben. In ihrer ursprünglichen Vision waren sie als intelligente Systeme gedacht, die in der Lage sein sollten, sich gegenseitig zu erkennen und mit Menschen soziale Interaktionen durchzuführen. Dazu sollten sie über eine Art Geschichte verfügen (vergleichbar mit menschlichem Erfahrungswissen) und sie explizit miteinander und mit Menschen kommunizieren und Fähigkeiten erlernen (Fong et al. 2003). Die Begrifflichkeit, die im Zusammenhang mit sozialen Robotern oft verwendet wird (kommunizieren, lernen, Verhaltensnormen befolgen etc.), setzt Intentionalität und die Fähigkeit zu verstehen, was eine Norm ist, voraus. Da Roboter – zumindest derzeit – nicht über solche Fähigkeiten verfügen – jedenfalls nicht in der Art und Weise, wie sie im Verhältnis zu unseren gegenwärtigen begrifflichen Normen definiert sind – sind solche Charakterisierungen streng genommen falsch (Seibt 2016). Dennoch hat sich dieser Begriff durchgesetzt und wird auch hier der Einfachheit halber verwendet. Mit dem Begriff sozialer Roboter beziehen wir uns in weiterer Folge insbesondere auf verkörperte („embodied“) intelligente Systeme mit sozialer Schnittstelle (Abb. 2).

Momentan werden in der Forschungslandschaft also jene autonomen oder halbautonomen Roboter als soziale Roboter bezeichnet, auf die Menschen ein soziales Modell anwenden, um mit ihnen zu interagieren und sie zu verstehen. Diese Definition basiert auf der Perspektive des menschlichen Beobachters. Wir interagieren mit sozialen Robotern demnach als wären sie Personen (Breazeal 2003), mit denen wir auch auf emotionaler Ebene kommunizieren und interagieren (Darling 2016). Insbesondere verkörperte Roboter ermöglichen völlig neue Einsatzgebiete in der Arbeitswelt, die jene von Industrierobotern weit übersteigen. Soziale Roboter im Dienstleistungssektor übernehmen Rollen und erfüllen Aufgaben, die normalerweise von Menschen erledigt werden, wie z. B. Konfliktmediation oder Recruiting. Gleichzeitig hat ihr Einsatz aber auch Auswirkungen auf die Menschen, die mit diesen Systemen zusammenarbeiten bzw. ihre Dienstleistungen in Anspruch nehmen. In den folgenden Abschnitten werden wir einige Anwendungsgebiete sozialer Roboter und deren Auswirkungen auf das Arbeitsumfeld von Menschen detaillierter skizzieren.

3 Roboter als Teamkollegen

Mit dem Aufkommen von Cobots und sozialen Robotern wurden Erwartungen geschürt, dass diese intelligenten Systeme sich so in den Arbeitsprozess einfügen könnten, dass sie sogar von ihren menschlichen Kolleg_innen als Teamkollegen akzeptiert und integriert werden können. Es stellt sich jedoch zunächst die wichtige Frage, ob Roboter überhaupt die technischen Voraussetzungen dafür besitzen, mit der gleichen Qualität wie menschliche Kolleg_innen zu interagieren, zu sozialisieren oder zusammenzuarbeiten. Kollegialität ist ein Wert, der an die eigene Identität und die eigene Rolle innerhalb einer sozialen Praxis gebunden ist. Kollegen und Kolleginnen bringen einen Austausch von Erfahrung, Fachwissen, Mitgefühl und Geschichte in die Arbeit ein. Kollegialität ist besonders für die manuelle Arbeit wichtig, die wegen der schieren Körperlichkeit oft eine enge Kooperation und/oder Kollaboration eines Teams oder eines Paares erfordert. Eine weitere wichtige Frage ergibt sich daraus, wie diese – simulierte – soziale Interaktion mit Robotern auf Menschen zurückwirkt. Wenn die Interaktion mit einem Roboterteamkollegen nicht von der Interaktion mit menschlichen Teamkolleg_innen zu unterscheiden ist, werden sich auch die gleichen impliziten und expliziten Erwartungen an das Verhalten und die Intentionen des Kollaborationspartners bilden (vgl. z. B. Grote 2018)? Das kann allerdings nicht nur die Kooperation und Kollaboration mit einem Roboter vereinfachen, sondern auch zu falschen oder überzogenen Erwartungen in die Fähigkeiten, Kompetenzen und zugeschriebenen Intentionen des Roboters führen. Daraus resultierende Missverständnisse und frustrierte Erwartungen können zu Kontrollverlust im Arbeitsprozess bzw. zu Fehlern (vgl. z. B. Griffiths und Gillespie 2004) und zu einer Reduktion der Technologieakzeptanz führen. Bisherige Forschungsarbeiten über die Auswirkungen von sozialen Robotern im Dienstleistungssektor, wie z. B. in Krankenhäusern (Ljungblad et al. 2012; Mutlu und Forlizzi 2008; Siino und Hinds 2005)

und im privaten Kontext (Forlizzi und DiSalvo 2006; Forlizzi 2007; Sung et al. 2009; Fink et al. 2011) zeigen auch, dass Roboter die menschliche Wahrnehmung von sozialen Beziehungen signifikant verändern und einen Prozess der Sinnfindung auslösen, der zur Anwendung bestimmter Schemata führt, wie den Roboter als Teamkollegen, als sozialen Akteur oder einfach nur als technologische Neuheit einzustufen.

Soziale Roboter kommen immer häufiger sowohl im industriellen Kontext als auch im Dienstleistungssektor zur Anwendung. Wenngleich sich die Problemstellungen und Herausforderungen in den beiden Kontexten in vielen Aspekten ähnlich sind, so unterscheiden sie sich doch auch bis zu einem bestimmten Grad. Auf diese Unterschiede wird im Folgenden noch genauer eingegangen.

3.1 Mensch-Roboter-Kollaboration in der Industrie

Ein zentrales Narrativ für Cobots im industriellen Kontext ist, dass erfolgreiche Zusammenarbeit ein Seite-an-Seite-Arbeiten von Mensch und Maschine bedeutet, in dem beide Akteure ihre Stärken einbringen können, aber auch die Schwächen des anderen ausgleichen (Weiss et al. 2011). Michalos und seine Kollegen konzentrieren sich auf die verschiedenen Arten der Zusammenarbeit, die sie sich für die Zukunft der industriellen Fertigung vorstellen können, und weisen darauf hin, dass Roboter und Menschen in allen Umgebungen einen gemeinsamen Arbeitsplatz und physischen Kontakt benötigen (Michalos et al. 2015). In ähnlicher Weise hat die Internationale Organisation für Normung (ISO) den kollaborativen Betrieb als einen Zustand definiert, in dem ein speziell entworfenes Robotersystem und ein Mensch innerhalb eines kollaborativen Arbeitsbereichs arbeiten. Ein kollaborativer Arbeitsraum wird anschließend als ein Bereich innerhalb des Arbeitsraums definiert, in dem das Robotersystem (einschließlich des Werkstücks) und der Mensch während des Produktionsprozesses gleichzeitig notwendige Arbeitsschritte ausführen können. Mensch-Roboter-Kooperation und -Kollaboration werden oft synonym verwendet, auch wenn es klare Unterschiede in der Art der Zusammenarbeit gibt (Kolbeinsson et al. 2019). Der wesentliche Unterschied liegt im Ausmaß, in dem die vom Menschen und vom Roboter ausgeführten Arbeitsaktivitäten voneinander abhängen. Bei der Kooperation sind die Handlungen nicht direkt voneinander abhängig, da Mensch und Roboter an unterschiedlichen Teilaufgaben arbeiten, die dann zu einem gemeinsamen Endergebnis führen. Die Interaktion mit Pick-and-Place-Robotern in der Produktion kann als Beispiel für diese Form der Zusammenarbeit dienen. Bei der vollständigen Kollaboration arbeiten Mensch und Roboter direkt zusammen, d. h. alle Aufgaben, die zur Zielerreichung führen, werden von Mensch und Roboter gemeinsam durchgeführt, sodass eine Form von Koordination erforderlich ist. Die tatsächliche Zusammenarbeit ist also eine Abfolge von gemeinsamen Aktionen, die auf ein gemeinsames Ziel ausgerichtet sind. Für die Zusammenarbeit mit einem Roboter ist es daher wichtig, dass der Mensch die Absichten und Handlungen des Roboters leicht wahrnehmen, verstehen und vorher-

sagen kann (Kiseler und Goodrich 2018). Dadurch wird Mensch-Roboter-Kollaboration jedoch zu einem komplexen soziotechnischen Arrangement, bei dem die Handlungsfähigkeit nicht mehr ausschließlich dem Menschen zugeschrieben werden kann, sondern zwischen Menschen und nichtmenschlichen Agenten wie Maschinen, Robotern, Sensoren, Programmen oder anderen ähnlichen Akteuren verteilt ist.

In Anlehnung an die Arbeiten von Latour (2007), Suchman (2007) und Rammert (2012) lässt sich die Arbeit mit Cobots in einer modernen Industrieumgebung als eine neue Konstellation gemeinsamer Kontrolle und verteilter Handlungsfähigkeit beschreiben. Aktivitäten werden hierbei nicht nur in einem physischen, sondern auch in einem sozialen Raum geteilt (Dautenhahn und Saunders 2011), und der Cobot hat Auswirkungen nicht nur auf physische, sondern auch auf soziale Interaktionen mit Menschen und anderen Robotern (Alenljung et al. 2019). Kollaborative Mensch-Roboter-Installationen erfordern hochflexible menschliche Mitarbeiter_innen, die je nach Produktionsstand als Teamkolleg_innen, Schichtleiter_innen, Programmierer_innen oder Instandhalter_innen tätig werden müssen (Michalos et al. 2015).

Feldstudien zur Mensch-Roboter-Kollaboration im industriellen Kontext haben immer öfter auch die sozialen Aspekte von Arbeit offenbart, sowohl innerhalb der Mensch-Roboter-Dyade (Saupé und Mutlu 2015) als auch darüber hinaus (Weiss und Huber 2016). Es zeigt sich, dass gerade in der Fertigung die sozialen und kommunikativen Aspekte relevante Bestandteile des Arbeitsalltags sind, die durch die assistierenden Automatisierungstechnologien gefährdet werden. So zeigte eine Studie, in der eine Arbeitszelle in einem Automobilkonzern um einen assistiven Cobot erweitert wurde, der das Verschrauben eines Motorblocks unterstützte, dass die Auswirkungen des Coboteinsatzes auf Arbeitsrhythmus und Geschwindigkeit in der Zelle auch Nebeneffekte auf den Arbeitsablauf in der gesamten Linie hatte. Dies ging soweit, dass Arbeiter_innen nicht mehr in dieser Zelle arbeiten wollten, weil sie dadurch gefühlt weniger sozialen Kontakt zu Kolleg_innen hatten und sich der Taktung des Roboters unterordnen mussten (Weiss und Huber 2016).

3.2 Mensch-Roboter-Kollaboration im Dienstleistungssektor

Dass Roboter soziale Servicerollen von Menschen übernehmen, war der Ursprungsgedanke in der Entwicklung sozialer Roboter. Historisch wurden Serviceroboter dann als sozial bezeichnet, wenn sie Dienstleistungen übernehmen, die ursprünglich von Menschen ausgeführt wurden, z. B. als Museums- oder Touristenführer_innen, als „Mädchen für alles“ in unseren eigenen vier Wänden oder als Unterstützung für das Pflegepersonal in Krankenhäusern und Pflegeeinrichtungen. Das Hauptaugenmerk wurde in der Mensch-Roboter-Interaktion auf eine „intuitive und natürliche“ Interaktion gelegt. Die bisherige Forschung zeigt jedoch, dass es kaum ein Argument dafür gibt, dass ein bestimmtes Verhalten X für einen Roboter Y natürlich ist. Jedes Mal ist die Frage, ob das Verhalten eines Roboters oder die Interaktion mit ihm als natürlich oder künstlich

eingestuft wird, allein damit zu beantworten, wie der Mensch das Verhalten in der spezifischen Situation wahrnimmt. Die Natürlichkeit des Roboterhaltens liegt also in der Wahrnehmung des Menschen, der mit dem Roboter interagiert oder ihn beobachtet und ist keine objektiv implementierbare Eigenschaft des Roboters (Dautenhahn 2013).

Im Dienstleistungssektor ist es oft die persönliche Verbindung z. B. zu Patient_innen oder Klient_innen, die für die Beschäftigten wichtig und sinnstiftend für ihre Arbeit ist. Dienstleistungsbeschäftigte neigen dazu, der von ihnen erbrachten Dienstleistung durch die Interaktion mit anderen einen hohen Wert beizumessen, was mit beruflichem Stolz und beruflicher Identität einhergeht (Sorenson et al. 2019). Wenn also Serviceroboter als Teamkolleg_innen in den Arbeitsalltag integriert werden, kann das Auswirkungen auf das identitätsstiftende Element von Arbeit bei den menschlichen Teamkolleg_innen haben. Menschen neigen dazu, ihre Arbeit als Leistung wahrzunehmen, der ein bestimmter Wert zukommt, z. B. durch die Gehaltszahlung, durch berufliche Position oder Anerkennung durch Kolleg_innen und Kund_innen. Leistung dient dabei auch als Unterscheidungsmerkmal zu anderen Personen. Wenn das Tätigkeitsfeld einer Person somit durch einen Serviceroboter verändert wird, kann das dazu führen, dass ihre Arbeit an Komplexität verliert, der Berufsstolz verringert wird und der menschliche Teamkollege sich in Konkurrenz zur Maschine sieht (Sorenson et al. 2019).

Welche konkreten Auswirkungen der Einsatz von sozialen Robotern auf Menschen hat, darauf wie sie ihre Arbeit erleben und ihre berufliche Identität schätzen, ist jedenfalls von der konkreten Anwendung abhängig. Im folgenden Abschnitt präsentieren wir einige Schlüsselthemen sowie empirische Erkenntnisse zur Mensch-Roboter-Kollaboration in ausgewählten Anwendungsgebieten.

4 Erkenntnisse aus ausgewählten Anwendungsgebieten sozialer Roboter

Wenn Roboter Teil unseres zukünftigen Arbeitslebens sein sollen, ist es unerlässlich, dass wir ihre Entwicklung und Implementierung auf ein solides empirisches Verständnis ihrer Auswirkungen auf die Arbeitswelt, in der sie zum Einsatz kommen sollen, gründen. Da potenzielle Anwendungsgebiete so vielfältig sind, dass eine umfassende Analyse an dieser Stelle unmöglich ist, haben wir einige – sehr unterschiedliche – Anwendungsgebiete exemplarisch ausgewählt, um die unterschiedlichen technischen, arbeitswissenschaftlichen und sozialen Herausforderungen sichtbar zu machen. Wir fassen in den folgenden fünf Anwendungsgebieten, nämlich Fertigung, Pausenmanagement, Recruiting, Konfliktmediation und Pflege wichtige aktuelle Forschungsinteressen und Erfahrungen zusammen.

4.1 Cobots in der Fertigung

Im Bereich der KMU werden vor allem neue Wege für die direkte, dyadische Mensch-Roboter-Kollaboration in geteilten Arbeitszellen gesucht. Eine große Anzahl von Forschungsarbeiten über Cobots befasst sich mit Aspekten der Sicherheit, auch in Bezug auf Benutzerfreundlichkeit und Situationsbewusstsein (Heydaryan et al. 2018). Interessanterweise zeigten Studien, dass die Trennung des Roboters von den menschlichen Arbeitsbereichen die wahrgenommene Sicherheit erhöht, indem sie die Identifikation und das Vertrauen des Teams in den Roboter fördert (You et al. 2018). In der Folge fördert die wahrgenommene Sicherheit die Absicht der Menschen, in Zukunft mit dem Roboter zu arbeiten. Forschungen zum Situationsbewusstsein ergaben auch, dass es Arbeiter_innen zunehmend schwerer fällt, Systemfehler zu erkennen, manuelle Aufgaben auszuführen und Ausfälle zu verhindern (Onnasch et al. 2014). Dieses Problem wird auch als Out-of-the-Loop-Performance-Problem bezeichnet (Endsley und Kiris 1995).

Ein weiterer beträchtlicher Teil der Forschung konzentriert sich auf die Endnutzer_innen-Programmierung und das Schnittstellendesign sowie auf Trainingsmethoden der kollaborativen Fähigkeiten von Arbeiter_innen und Robotern (siehe Zaatari et al. 2019 für einen detaillierten Überblick). Hierbei steht auch das Thema geteilte Kontrolle (zwischen Mensch und Maschine) und Verantwortung im Vordergrund. Mensch-Roboter-Kollaborationen als hybride Netzwerke (Callon und Latour 1981; Rammert 2012) beinhalten die gemeinsame Kontrolle zwischen verschiedenen menschlichen und nichtmenschlichen Akteuren mit komplexer Kontrolldynamik, wobei unklar bleiben kann, wer oder was die Situation kontrolliert (Griffiths und Gillespie 2004). Studien zur Kontrollierbarkeit befassen sich daher mit Aspekten wie Transparenz, Vorhersagbarkeit (Grote 2018) und der Fähigkeit, eine Situation so zu beeinflussen, dass sie sich wie vom kontrollierenden Akteur beabsichtigt entwickelt (Flemisch et al. 2016). Interessanterweise hat die Forschung gezeigt, dass Menschen dazu neigen, die volle Verantwortung für eine Aufgabe vor allem dann zu übernehmen, wenn das Robotergegenstück maschinenähnlich und ohne soziale Hinweisreize konstruiert ist (Hinds et al. 2014).

Während der überwiegende Teil der Forschung noch auf die Optimierung von Mensch-Maschine-Kollaboration abzielt, beginnt die Forschung sich aktuell auch vermehrt damit zu beschäftigen, inwieweit Cobots beispielsweise ein geeignetes Mittel sein können, um die Inklusion von Menschen mit Behinderungen in geschützten Werkstätten zu fördern und ihre Tätigkeitsbereiche zu erweitern (Mark et al. 2019). In diesen Forschungsprojekten kommt gesellschaftlichen und ethischen Überlegungen für die Weiterentwicklung der Technologie ein Hauptaugenmerk zu, während technische Machbarkeitsüberlegungen erst in zweiter Linie relevant werden.

4.2 Roboter für das Pausenmanagement

Šabanović et al. (2014) entwickelten mehrere prototypische „robotische Objekte“ für den Schreibtisch, die mithilfe von sozialen Hinweisreizen dazu animieren sollten, regelmäßig Arbeitspausen einzulegen. Sie verglichen diese robotischen Objekte mit sozialer Schnittstelle mit Robotern mit schlichten Alarmsystemen, um deren Auswirkungen auf das tatsächliche Pausenverhalten von Menschen zu untersuchen. Šabanović et al. (2014) konnten in ihren Studien zeigen, dass Roboter mit sozialen Hinweisreizen für die Notwendigkeit einer Pause (wie z. B. den Kopf drehen), im Allgemeinen effektiver waren, Menschen zu Pausen zu bewegen, als Roboter, die lediglich einen Alarm benutzen. Diese Art von sozialen Robotern wird auch als „objects with intent“ (Rozendaal et al. 2019) bezeichnet, also intelligente Objekte, die vorgeben, intentional für ihre Besitzer_innen zu handeln. Immer mehr alltägliche Dinge wie Haushaltswaren, Spielzeug, Möbel und Kleidung werden prototypisch entwickelt, um Daten aus ihrer Umgebung zu sammeln, darauf zu reagieren und ihre „eigene Absicht“ durch soziale Hinweisreize zu zeigen, die mit Begriffen wie Höflichkeit, Verspieltheit, Taktgefühl charakterisiert werden können. Diese Form der verkörperten KI kann somit sowohl im industriellen Kontext als auch im Dienstleistungssektor zum Einsatz kommen.

4.3 Soziale Roboter als Recruiter

Auch wenn soziale Roboter mit Fähigkeiten ausgestattet sind, die es Menschen ermöglichen, mit ihnen wie mit Menschen zu kommunizieren und zu interagieren, unterscheiden sie sich in wesentlichen Aspekten. Soziale Roboter simulieren menschliche Interaktion. Und obwohl sie auch Emotion oder Empathie simulieren können, können sie, anders als Menschen, unbeeinträchtigt von Gefühlen und unbewussten Prozessen Entscheidungen treffen und Handlungen ausführen. Diese „Neutralität“ der Maschinen, frei von Vorurteilen, Sympathie oder Emotionen, legt Anwendungsgebiete nahe, in denen Unparteilichkeit, Fairness und Objektivität wichtig sind. Der Einsatz von KI-Technologien wird daher auch damit gerechtfertigt, dass mit ihrer Hilfe Aufgaben nicht nur effizienter, sondern auch unparteiischer, fairer und gerechter erledigt werden können (Whilborg et al. 2016).

In den letzten Jahren kommen daher vermehrt KI-Technologien im Recruiting zum Einsatz. Es gibt mittlerweile eine Vielzahl von Unternehmen, die KI-Technologien zur Analyse des von Bewerber_innen zur Verfügung gestellten Text-, Bild- und Videomaterials heranziehen, um Persönlichkeitsprofile zu erstellen und zu analysieren, ob und wie gut potenzielle Kandidat_innen auf bestimmte Job- oder Unternehmensprofile passen. Diese Systeme dienen in erster Linie der Vorselektion von Bewerbungen. Damit können insbesondere große Konzerne, die jährlich hunderte oder tausende Stellen besetzen und abertausende Bewerbungen erhalten, erhebliche Kosten einsparen. Befürworter_innen des Einsatzes von KI-Algorithmen für das Recruiting sehen vor

allem Vorteile im Fehlen von persönlichen Vorurteilen und Bias sowie in der Möglichkeit, auch weitere öffentlich zugängliche Daten potenzieller Bewerber_innen (wie etwa aus dem Facebook-Account) effizient für die Erstellung von Persönlichkeitsprofilen nutzen zu können. Zahlreiche kritische Studien haben allerdings gezeigt, dass diese Recruiting-Systeme, da sie mit vergangenheitsbezogenen Daten trainiert werden, häufig bestehende gesellschaftliche Vorurteile widerspiegeln und somit ebenso zu unfairen und diskriminierenden Entscheidungen führen können (vgl. dazu den Bericht von Upturn: Bogen und Rieke 2018).

Aber es werden mittlerweile am Markt auch soziale Roboter angeboten, die anstelle eines menschlichen Recruiters Bewerbungsgespräche durchführen können. Das schwedische Start-up Unternehmen *Tengai Robot* wirbt etwa damit, dass ihr Roboter bei Einstellungsgesprächen Soft Skills und Persönlichkeitsmerkmale objektiver und fairer bewerten könne, als menschliche Recruiter. Auch wenn diese Roboter mit den gleichen Problemen zu kämpfen haben, wie die vorhin beschriebenen KI-Recruiting-Systeme, so könnte es zumindest einen positiven Effekt aufseiten der Bewerber_innen geben, die einen Roboter-Recruiter mehr Objektivität und Fairness zuschreiben könnten.

Bisherige empirische Studien dazu nähren diese Hoffnungen allerdings nicht und lassen den Erfolg von Recruiting-Robotern bezweifeln. Verschiedene Laborexperimente zeigten, dass zumindest derzeit die Akzeptanz von automatisierten Einstellungsgesprächen mit Robotern bei Bewerber_innen noch sehr gering ist, weil sie das Gespräch nicht nur als unpersönlich, sondern sogar auch als weniger fair wahrnehmen im Vergleich zu Bewerbungsgesprächen mit einem Menschen (vgl. Langer et al. 2019; Norskov et al. 2020).

4.4 Roboter in der Konfliktmediation

Die letzten 15 Jahre der Mensch-Roboter-Interaktionsforschung haben gezeigt, dass Roboter – je nach Interaktionskontext – genauso (oder sogar effektiver) als Menschen sein können, wenn es darum geht, andere dazu zu bringen,

- Anweisungen zu befolgen (vgl. Utami et al. 2017),
- prosoziales Verhalten zu zeigen (vgl. Krátký et al. 2016),
- private Informationen offenzulegen (z. B. in Yamazaki et al. 2012),
- Empathie zu zeigen (vgl. Seo et al. 2015, 2018; Connolly et al. 2020)
- einen Konflikt zu lösen (Shen et al. 2018).

Ähnlich wie beim Recruiting ist auch beim Einsatz sozialer Roboter als Mediator_innen der Wunsch nach Unparteilichkeit und Fairness die zentrale Triebfeder. Wie beim Recruiting wird angenommen, dass Menschen in Konfliktsituationen einer Maschine eher Unparteilichkeit zuschreiben würden. Roboter könnten daher als Mediatoren bei der Konfliktlösung hilfreich sein, da sie so gestaltet sein können, dass sie keine sozialen

Marker für Geschlecht, Alter, ethnische Zugehörigkeit oder Status aufweisen. Dieser Vorstellung liegt die Hypothese der „Fair Proxy Communication“ (FPC) zugrunde. Darunter verstehen Seibt und Vestergaard (2018) ein Kommunikationsformat, bei dem Personen über teleoperierte Roboter ohne Hinweise auf das eigene Geschlecht, Alter, Ethnie oder Status miteinander interagieren. Da der Einsatz von teleoperierten Robotern keine auf dem visuellen Erscheinungsbild basierenden Vorurteile zulassen, können sich Menschen dadurch weniger voreingenommen und damit fairer begegnen. Seibt und Vestergaard (2018) schlagen daher dieses Kommunikationsformat für die Konfliktmoderation und auch für Bewerbungsgespräche vor.

Neben den Erkenntnissen aus dem Experiment von Shen et al. (2018), die die erfolgreiche Interventionen von Robotern bei der Konfliktlösung von Kindern nachweisen können, lassen auch erste empirische Daten zum Einsatz von Robotern in der Konfliktmediation bei Erwachsenen positive Erwartungen und Hoffnungen zu. In einem umfangreichen empirischen Laborexperiment an der Aarhus University erhielten Versuchspersonen in Konfliktsituationen Mediationsunterstützung, die entweder in Form einer Software (Computer), durch einen Mediator (Mensch) oder durch einen humanoiden, teleoperierten Roboter angeboten wurde (vgl. Druckman et al. 2020). Die Ergebnisse der Studie zeigen, dass humanoide (teleoperierte) Roboter im Vergleich mit menschlichen Mediator_innen häufigere und bessere Konfliktlösungen mit den Konfliktparteien erzielten. Obwohl es keine Unterschiede in der Wahrnehmung der Fairness des Mediators zwischen den Gruppen (Computer, Mensch, Roboter) gab, wurden Roboter von den Versuchspersonen als hilfreicher bei der Lösung von schwierigen und festgefahrenen Problemen wahrgenommen.

Allerdings haben Menschen nicht nur bewusste und unbewusste Vorurteile, sondern auch beschränkte kognitive Fähigkeiten und Kapazitäten, die die Qualität ihrer Entscheidungen vermindern können. Daher gibt es auch Bestrebungen, die beschränkten kognitiven Fähigkeiten und Kapazitäten von Menschen überhaupt durch leistungsfähige automatisierte Entscheidungssysteme zu ersetzen (vgl. Koeszegi 2020). Menschen sollen in ihrer Entscheidungsfindung nicht mehr unterstützt werden, sondern an ihrer Stelle sollen Algorithmen (egal ob in physischer Gestalt als Roboter oder virtuell als Chatbot oder Expertensystem) autonom Entscheidungen für Menschen treffen. Solche Systeme könnten – wie Schiedsrichter – etwa auf Basis aller relevanten Informationen in einem Konfliktfall für die Konfliktparteien eine objektive, faire und effiziente Lösung treffen, an die sich die Parteien allerdings binden müssten. In der experimentellen Forschung werden diese Systeme bereits eingesetzt, allerdings ist ihre Akzeptanz bei Menschen – ähnlich wie beim automatisierten Recruiting – sehr gering (vgl. z. B. Gettinger et al. 2016). Es gibt aber eine Vielzahl von Anwendungen von automatisierten Entscheidungssystemen, ohne dass Betroffene davon überhaupt wissen (Wouters et al. 2019). In Versicherungen werden etwa vermehrt Kleinschäden automatisiert abgewickelt. Aber auch öffentliche Einrichtungen haben automatisierte Entscheidungssysteme im Einsatz. Laut Algorithm Watch (2019) umfassen die Anwendungsgebiete so unterschiedliche Bereiche wie die Festlegung von Kautionen in der Justiz, die Risikoeinschätzung in der

Jugendwohlfahrt bis hin zum Zugang zu staatlichen Leistungen im Bereich Arbeitslosenunterstützung oder dem Zugang zu Gesundheitsservices. Die Erfolgsbilanz von automatisierten Entscheidungssystemen ist mit vielen nachgewiesenen Formen von Diskriminierung sehr problematisch (vgl. dazu z. B. Molnar und Lex 2018).

Wenngleich die Erfahrungen in Experimenten zur Konfliktmediation deutlich positiver ausgefallen sind als beim Einsatz von Robotern im Recruiting, ist es bis zum tatsächlichen Einsatz von Robotern in der Konfliktlösung als faire und neutrale Mediatoren bzw. Schiedsrichter noch ein weiter Weg. Zum einen wurden im Experiment von Druckman et al. (2021) die Roboter von Menschen teleoperiert, da es zur Zeit noch keine Technologie gibt, die weit genug entwickelt wäre, um diese Funktion automatisiert und autonom auszuführen. Die sozialen und kognitiven Kompetenzen, die für eine erfolgreiche Konfliktmediation erforderlich wären, lassen sich derzeit noch bei Weitem nicht in ein KI-System implementieren. Zum anderen lassen sich aus kontrollierten Laborexperimenten nur bedingt Schlussfolgerungen für das reale Feld ziehen, das in der Regel deutlich komplexer und dynamischer ist. Dennoch zeigt der aktuelle Stand der Forschung ein potenziell spannendes Einsatzgebiet für soziale Robotik auf, in dem ihr Einsatz gesellschaftlich wünschenswert wäre, weil damit Probleme und Herausforderungen zum Teil gelöst werden könnten, die durch menschliche Vorurteile und Diskriminierung entstehen.

4.5 Roboter in der Pflege

In den letzten Jahren erfuhr die AAL-Robotik (Ambient Assisted Living oder Active Assisted Living) medial und in der Forschung immer mehr Beachtung. Ein AAL-Roboter wird definiert als ein Roboter, der ältere Menschen und Menschen mit Behinderung bei alltäglichen Tätigkeiten unterstützt und ihnen dadurch ein unabhängiges Leben ermöglicht (Payr et al. 2015).

Soziale Roboter, die speziell für die Pflege entwickelt werden, können nach Sharkey und Sharkey (2012) in drei Einsatzbereiche unterteilt werden: Roboter zur Assistenz, Roboter zur Überwachung und Roboter als Gefährten. Unter Assistenzsystemen werden hierbei vor allem Technologien verstanden, die Aktivitäten des täglichen Lebens unterstützen sollen. Hierzu können intelligente Rollstühle genauso gezählt werden, wie Roboterarme, die Patient_innen Nahrung zuführen, oder Exoskelette für die Rehabilitation. Roboter zur Überwachung sollen vor allem den Gesundheitsstatus von Senior_innen kontrollieren und beispielsweise demenzkranke Senior_innen an alltägliche Tätigkeiten wie Essen, Trinken und Einnahme von Medikamenten erinnern. Es wurden auch Roboter entwickelt, die als Mediator_innen bzw. Übersetzer_innen zwischen Patient_innen und Ärzt_innen fungieren. Roboter, die die Rolle eines Gefährten einnehmen sollen, sind häufig tierähnlich gestaltet und ihre Hauptfunktion liegt in sozialer und emotionaler Stimulation – ein prominentes Beispiel ist die Roboterrobbe Paro (vgl. Shibata et al. 2012).

Unterstützen bei	Zubereitung von Essen	Essen und Trinken		Ankleiden
	Sozialisation	Einnahme von Medikamenten		Behandlung von Füßen und Beinen
	Haushalts- und Sicherheitsmanagement	Aufmunterung		Üben von kognitiven und physischen Fähigkeiten
Benötigte Roboterfunktionen	Kognitive Funktionen			
	Modellierung und Überwachung der Wohnumgebung und Aktivitäten von Menschen	Mensch-Roboter Kommunikation		Sichere Manipulation
		multimodal	Touchscreen, natürliche Sprache, Gesten	Objekte greifen und manipulieren, Übergabe von Objekten, Ergreifen von Objekten in großer Höhe, etc.
		adaptiv		
		empathisch		

Abb. 3 Aktuelle Einsatzgebiete von Robotern in Pflege und Assistenz (adaptiert von Bajones et al. 2019 und Peleka et al. 2018)

Robotische Assistenz kann vorrangig bei instrumentellen Aktivitäten des täglichen Lebens umgesetzt werden. Derzeit können Roboter an Termine erinnern, die Kommunikation mit Angehörigen ermöglichen, Fitnessübungen begleiten oder Unterhaltung und einfache Gedächtnistrainings anbieten (vgl. dazu Bajones et al. 2019; Frennert et al. 2020). Assistenz in den grundlegenden Aktivitäten des täglichen Lebens, wie Ankleiden, Hygiene und Essen gehören bereits zu den komplexeren Assistenztätigkeiten, die allerdings als essenziell für zukünftige Pflegeroboter erachtet werden. Sie stellen aktuell technisch noch große Herausforderungen dar. Derzeit laufende Projekte entwickeln beispielsweise Roboter zur Unterstützung des Ankleidens (<https://i-dress-project.iri.upc.edu/>, 06.08.2020) oder eine intelligente automatische Dusche (<https://www.i-support-project.eu/>, 06.08.2020). Diese Systeme befinden sich bislang in einer ersten Konzeptualisierungsphase und sind noch weit von einer Marktreife entfernt (Abb. 3).

Laut einer Studie von Payr et al. (2015) besteht ein hohes Potenzial für roboter-gestützte Pfl egetechnologien zur Unterstützung von Primär-, Sekundär- und Tertiär-nutzer_innen. Vor allem in den Bereichen der Erhaltung der Mobilität, der Körperpflege, der Haushaltsführung, der sozialen und emotionalen Unterstützung (z. B. in Form von Gefährtenrobotern), der Telepräsenz, der Unterhaltung und der Fitness werden Anwendungsfälle für Serviceroboter gesehen. Das Potenzial, formelle und informelle Pflegekräfte bei ihrer Arbeit mit Pflegerobotern unterstützen zu können, wird in der Forschung oft als gegeben angenommen. Bislang fehlen allerdings noch Belege für psychosoziale Effekte des Einsatzes von Robotern in der Pflege, da Langzeitstudien mit prototypischen Robotern immer noch sehr herausfordernd in der Durchführung sind.

Darüber hinaus wird die Kosteneffizienz in der Forschung bislang nur selten berücksichtigt.

Während viele Projekte Senior_innen bereits als potenzielle Endnutzer_innen in die Entwicklung von Pflegerobotern einbeziehen, werden andere sekundäre und tertiäre Nutzer_innen, wie Pfleger_innen und Versicherungsträger, nur in wenigen Fällen erwähnt (Lewis et al. 2016). Darüber hinaus erfolgt die Einbeziehung von Interessengruppen meist in einer späten Phase von Projekten, in der viele (technologiegetriebene) Entscheidungen bereits getroffen sind. Zukünftige Forschungsprojekte im Bereich der Pflegerobotik müssen einen systematischen Weg finden, um ein breites Spektrum potenzieller Interessenvertreter_innen in allen Phasen der Technologieentwicklung einzubeziehen. Die Ausgangsfragen zukünftiger Entwicklungsprojekte im Bereich der Pflegerobotik sollten daher auch in diesem Anwendungsgebiet sein, was Robotertechnologie in einem Pflegekontext leisten soll und wie robotische Pflege bewertet werden kann, indem Kriterien für eine „gute“ Pflege durch einen Roboter definiert werden. Auch in der Pflegerobotik ist es in Zukunft essenziell, die ethischen, gesellschaftlichen und sozialen Dimensionen anstelle der technischen Machbarkeit in den Mittelpunkt zu rücken.

Die für die Pflege gestellten Fragen lassen sich allerdings auch auf viele der hier nicht erwähnten Anwendungsgebiete ausdehnen. Letztlich geht es darum zu bewerten, welche Vor- und Nachteile sich durch den Einsatz von Robotik im konkreten Anwendungskontext ergeben und wie mögliche negative Effekte durch ein entsprechendes Design und eine sorgsam vorbereitete Implementierung gut abgefedert oder überhaupt vermieden werden können. Im folgenden Abschnitt gehen wir auf besonders relevante Herausforderungen von KI- und Robotiktechnologie im Zusammenhang mit menschlicher Arbeit ein.


5 Handlungsfelder für die (zukünftige) Arbeitswelt

Auch wenn mit der Implementierung von sozialen Robotern in der Arbeitswelt eine Vielzahl kontextspezifischer Herausforderungen auftreten werden, können zumindest drei generelle Handlungsfelder identifiziert werden, die bei allen Anwendungen bis zu einem gewissen Grad relevant sein werden. Sie werden im Folgenden kurz skizziert.

5.1 Die Gestaltung von Berufsprofilen und die Sicherstellung benötigter Skills

Zu den Aspekten der erforderlichen Fähigkeiten und zukünftigen Berufsprofile gibt es bisher nur sehr wenig systematische Forschung. Einige Forscher_innen befassen sich mit der Idee des Operators 4.0 für die Fabrik der Zukunft (Romero et al. 2016). Die grundlegende Frage jedoch, wie Arbeitsplätze und Jobprofile in Zukunft ausgestaltet werden sollen, findet noch wenig Beachtung. Veränderungen in Hierarchien, Ent-

Abb. 4 Weiterbildungsbedarf durch KI- und Robotiktechnologie laut Weltwirtschaftsforum



scheidungsprozessen, Verantwortungsverteilung und Kontrollmechanismen verlangen nach neuen soziotechnischen Konzepten des Arbeitens, die vielfältige technische Instanzen integrieren, Mensch-Maschine-Interaktion stärker berücksichtigen sowie die Verschiebung von Kompetenzen und Verantwortlichkeiten mitbedenken (Moniz und Krings 2016).

Ein soziotechnisches Verständnis der Arbeitsplatzgestaltung erfordert komplementäre anstelle von vergleichenden Ansätzen, bei denen der Mensch durch Technologie ersetzt werden sollte (Grote 2018). Grote (2018) betont zum Beispiel, dass alle organisatorischen Einheiten an der Gestaltung von Arbeitsplätzen beteiligt sein sollten und dass sowohl menschliche als auch technische Vorteile integriert werden müssen. Sie schlägt ein Konzept zur Bewältigung von Unsicherheit und lokalen Abweichungen am Arbeitsplatz vor, das den Namen Komplementäre Analyse und Gestaltung von Produktionsaufgaben im sozio-technischen System (KOMPASS) trägt und sich auf die Entwicklung menschlicher Kompetenzen einschließlich der kognitiven Fähigkeit zur Bewältigung von Unsicherheit konzentriert (Grote et al. 2014). Ein weiterer wesentlicher Aspekt für die Implementierung von KI- und Robotiktechnologien sind Partizipationsstrategien, um Mitarbeiter_innen in die Ausgestaltung und das Erlernen intelligenter Technologien einzubeziehen (Moniz und Krings 2016).

Hybride Arbeitsumgebungen, in denen KI- und Robotiksysteme menschliche Arbeitskräfte nicht ersetzen, sondern stattdessen ihre Fähigkeiten erweitern und ergänzen, erfordern aber auch neue KI- und robotikbezogene Fähigkeiten und Kenntnisse bei bestehenden Arbeitskräften. Einem Bericht des Weltwirtschaftsforums über die Zukunft der Beschäftigung (2018) zufolge wird ein – zum Teil erheblicher – Umschulungs- bzw. Weiterbildungsbedarf für jede_n zweite_n Arbeitnehmer_in bis 2022 prognostiziert. Menschliche Intelligenz und Fähigkeiten auf kognitiver Ebene (Problemlösung, Prozess- und Qualitätsüberwachung, kritisches Denken, Urteilsvermögen oder Kreativität), auf sozialer und kultureller Ebene (Einfühlungsvermögen, Führung, Überzeugungskraft oder

Vorstellungskraft sowie unternehmerische und innovative Kompetenzen) bleiben aber nach wie vor Schlüsselfertigkeiten von Menschen (Abb. 4).

Es müssen allerdings nicht nur neue Fähigkeiten und Kompetenzen aufgebaut werden, sondern es muss auch verhindert werden, dass durch den Einsatz von KI- und Robotiktechnologie bestimmte Kompetenzen nicht verloren gehen und es zu sogenannten Deskillung-Effekten kommt. Bainbridge hat bereits 1983 in ihrem berühmten Aufsatz zu den Ironien der Automatisierung eindrucksvoll aufgezeigt, wie durch Automatisierung genau jene Kompetenzen bei Menschen verloren gehen, die sie dafür benötigen würden, automatisierte Arbeitsabläufe zu überwachen, zu kontrollieren und einzuschreiten, wenn Fehler und Probleme auftreten (Bainbridge 1983). In kritischen Bereichen und Anwendungen bedarf es daher – ähnlich wie beispielsweise bei der Flugsicherung – eines entsprechenden Trainings- und Sicherheitskonzepts, das sicherstellt, dass notwendige Kompetenzen und Fähigkeiten für die Aufrechterhaltung der Sicherheit sowohl im Normalbetrieb als auch bei Notfällen erhalten bleiben bzw. zur Verfügung stehen.

5.2 Die Sicherstellung von menschlicher Verantwortung und Kontrolle

Die britische TV-Comedy-Show „Little Britain“ zeigt mit ihrem Sketch *The computer says no* auf drastische Art und Weise auf, wie die Nutzung von Informationstechnologien das Rollengefüge zwischen Menschen und Maschinen auf absurde Weise verschiebt. Mit der Übertragung von Aufgaben und Entscheidungen an Maschinen geht die Zuschreibung von Handlungsmacht im sozialen Kontext einher. Menschen entwickeln dabei Annahmen über die Fähigkeiten und Kompetenzen „intelligenter“, „objektiver“ oder „fairer“ Maschinen und verknüpfen damit bestimmte Erwartungen. Menschen haben in der Regel auch großes Vertrauen in diese Technologie (Wouters 2019). Im Kontext sozialer Interaktion führen diese Effekte in weiterer Folge zu Verschiebungen im Rollengefüge zwischen Menschen einerseits und zwischen Menschen und Maschinen andererseits. Die Frage, wer letztlich in einem soziotechnischen Ensemble, in dem Roboter und Menschen zusammenarbeiten, für das Ergebnis gemeinsamer Arbeit oder eine Entscheidung verantwortlich ist, verschwimmt zunehmend mit dem Einsatz autonomer Systeme. In einer schwedischen Studie über den Einsatz eines KI-Algorithmus zur Entscheidungsunterstützung in einer öffentlichen Institution, offenbaren Beamt_innen in Interviews eine gewisse Entwertung ihrer eigenen Rolle: „Das automatisierte System schlägt eine Entscheidung vor, die auf allen eingegebenen Informationen basiert, und liefert eine Entscheidung [...] Es gibt keinen Raum für Zweifel an der Entscheidung, die mit Hilfe des Verwaltungsinstruments getroffen wird“ (Wihlborg et al. 2016, S. 2908). Durch den Einsatz von KI- und Robotiksystemen verändern sich Rollen und Aufgaben von Menschen im Arbeitsprozess und damit ihr eigenes Rollenverständnis, was schlussendlich auch zu einer verminderten Verantwortungsbereitschaft führen kann.

Die Menschen erleben sich zunehmend nur mehr als jemand, der das System während des gesamten Prozesses am Laufen hält, aber selbst kaum mehr Einfluss auf das Ergebnis des Arbeitsprozesses hat. Während Autonomie und selbstbestimmtes Handeln ein bestimmtes Maß an Eigenverantwortung erfordert, wird durch die Delegation von Entscheidungen und Aufgaben an KI- und Robotiksysteme daher nicht nur die Handlungsmacht der Menschen, sondern auch ihre wahrgenommene Kontrolle und Verantwortung über den Arbeitsprozess eingeschränkt (Gillespie 2016, S. 27). Es wird notwendig sein, ganz besonders darauf zu achten, dass letztendlich Menschen die Kontrolle und Steuerung von Arbeitsprozessen in soziotechnischen Ensembles wahrnehmen (können).

5.3 Die Erforschung von Langzeiteffekten unter realen Bedingungen

Es gibt bisher nur wenige Feldstudien zur Mensch-Roboter-Kollaboration am Arbeitsplatz, die über einen längeren Zeitraum angelegt wurden. Zwar gibt es viele Beispiele für mögliche Formen der Zusammenarbeit zwischen Mensch und Roboter (siehe z. B. Zaatari et al. 2019 für eine Übersicht im Industriekontext), allerdings werden diese häufig nur prototypisch erforscht und nicht in realen Arbeitsumgebungen: Aktuell sind in der Industrie Stop-Start-Anwendungen vorherrschend. Komplexere Formen der Mensch-Roboter-Zusammenarbeit sind rar, am ehesten noch in der Montage im Automobilsektor zu finden. Und auch hier sind Cobots nicht direkt in den Fließbändern in Feldversuchen eingesetzt, sondern in abgetrennten, quasiexperimentellen Bereichen der Fabrik. In diesen Konstellationen arbeiten Roboter hauptsächlich an der Seite des Menschen oder erledigen repetitive oder Präzision erfordernde Aufgaben. Diese Anwendungen verringern eindeutig Belastung und Monotonie für Arbeitskräfte. Wenn jedoch der Einsatz von Cobots auf Routineaufgaben reduziert bleibt und nicht auf komplexere Aufgaben ausgeweitet wird, werden auch Cobots Menschen eher ersetzen, anstatt sie zu unterstützen, wie es auch schon traditionelle Fabrikroboter zuvor taten. Darüber hinaus fehlt es an dokumentierten Anwendungsbeispielen, die das Potenzial von Cobots zum aktuellen Stand der Forschung in der Praxis für KMU aufzeigen.

Da die meisten Studien mit Cobots in einem kontrollierten Umfeld stattfinden, fehlt uns die Kenntnis, inwieweit diese das Arbeitserleben von Menschen im Lauf der Zeit verändern werden. Im Rahmen des AssistMe-Projekts wurde beispielsweise ersichtlich, dass Roboter den Arbeitsrhythmus in der Mensch-Roboter-Dyade unmittelbar verändern und dass dies die soziale Organisation der Arbeit beeinflusst (Weiss und Huber 2016). Allerdings wissen wir nicht, ob dieser Effekt im Lauf der Zeit anhält oder welche weiteren Konsequenzen die Mensch-Roboter-Kollaboration längerfristig mit sich bringt. Klar ist allerdings, dass sich die Wahrnehmung von Cobots in alltäglichen Arbeitssituationen im Lauf der Zeit verändert (Meneweger et al. 2015).

In Bezug auf das Vertrauen in Cobots gibt es ebenfalls einen gravierenden Mangel an Studien, die die Entstehung, die Aufrechterhaltung und den Verlust von Vertrauen im Lauf der Zeit in realen Arbeitsplatzsettings untersuchen. Ein relevanter Faktor für den Aufbau von Vertrauen in Roboter ist einerseits die menschliche Vertrauensneigung, also die grundlegende Bereitschaft des Menschen, anderen Menschen, Technologien oder Systemen zu vertrauen (Merritt und Ilgen 2008). Andererseits gibt es aber auch kontextabhängige Faktoren, die das Vertrauen beeinflussen, wie etwa die Art der Aufgabe oder die Organisationskultur. Insgesamt steckt Forschung in Hinblick auf den Einfluss des soziotechnischen Kontexts auf das Vertrauen und die Abhängigkeit in der Mensch-Roboter-Kollaboration noch in den Anfängen.

6 Diskussion und Schlussfolgerungen

Menschliche Arbeitskraft kann im Vergleich zu Robotern und KI schnell wenig attraktiv erscheinen. Der robotische Teamkollege wird nicht krank, braucht keine Pausen und arbeitet 24 Stunden auch an Sonn- und Feiertagen. Das kann besonders für KMU, für die Mitarbeiterfluktuation und Produktionsschwankungen schwer zu tolerieren sind, sehr vielversprechend klingen. Derartige technikdeterministische Ansichten haben bisweilen sogar zum Narrativ geführt, dass Robotik und KI soziopolitische Probleme lösen können. Sowohl die Erwartungshaltung als auch die mit diesen neuen Technologien einhergehenden Befürchtungen sind – bei einer genaueren evidenzbasierten Analyse – gleichermaßen überzogen. Aus der aktuellen Studienlage wird ersichtlich, dass Automatisierung in Form von assistierenden Robotersystemen derzeit nur in wenigen Bereichen Einzug in die Arbeitswelt gehalten und bei Weitem nicht – wie befürchtet – komplette Jobprofile ersetzt haben.

Dieser Aufsatz hat gezeigt, dass wir den Einsatz flexibler Mensch-Roboter-Kollaboration in der Industrie und im Dienstleistungssektor als neue Form der Zusammenarbeit mit intelligenten Systemen betrachten müssen und nicht nur als eine weitere Ausbaustufe der Automatisierung verstehen können. Es ist notwendig, eingehender zu untersuchen, welche Teilaspekte von Arbeitsabläufen sinnvoll automatisiert werden können, wie viel Tiefe und Komplexität die Kollaboration erreichen kann und soll und wie sich dies schließlich auf die (kognitive) Arbeitsbelastung der Menschen, die erforderlichen Fähigkeiten und das Training sowie die Wahrnehmung der Qualität der von Menschen geleisteten Arbeit auswirken wird. Auch müssen wir berücksichtigen, dass es durch den Einsatz von autonomen KI- und Robotiksystemen zur Verantwortungsdiffusion kommen kann. Die Zuschreibung von Handlungsmacht und damit verbundene Rollenerwartungen an Roboter reduziert menschliches Handlungsvermögen durch die Veränderungen des Rollengefüges im soziotechnischen System. Eigenverantwortliches Handeln von Menschen sowie die Übernahme von Verantwortung und Kontrolle über den Prozess sowie das Ergebnis werden schwieriger und unwahrscheinlicher.

Nicht nur aus diesem Grund müssen wir uns die Frage stellen, ob Roboter in der Arbeitswelt überhaupt soziale Akteure sein sollen. Es gibt Forscher_innen, die den Standpunkt vertreten, dass wir keine andere Wahl haben, als kollaborative Roboter als soziale Akteure zu konstruieren (c.f. Fischer 2019). Nach Fischer fungieren soziale Schlüsselreize (einschließlich der Darstellung von Emotionen) als Koordinationsfunktion in der menschlichen Interaktion und müssen daher auch von Robotern genutzt werden, damit eine langfristige Zusammenarbeit mit Menschen erfolgreich ist. Zwar fehlt den Robotern die erfahrungsbasierte Grundlage für Emotionen, doch auch in der menschlichen Interaktion sind viele emotionale Ausdrucksformen Teil der herkömmlichen sozialen Praxis; wenn Roboter im Arbeitsalltag also an solchen sozialen Praktiken teilnehmen sollen, müssen sie nach Fischer auch solche Signale erzeugen.

Solche Annahmen sind sowohl empirisch als auch philosophisch relevant, weil sie die Diskussion von der Frage, wie „sozial“ kollaborative Roboter sein sollten, auf die Frage verschiebt, welche Art von Mensch-Roboter-Kollaboration wir überhaupt wollen. Der technologische Reifegrad erlaubt es uns, die Frage zu stellen, was wir überhaupt automatisieren wollen, bevor wir entscheiden, wie wir es technologisch umsetzen. Diese Frage ist nicht einfach zu beantworten und kann auch in diesem Aufsatz nicht beantwortet werden. Als Wissenschaftlerinnen sehen wir jedenfalls einen großen Bedarf an empirischer Evidenz über die Auswirkungen von KI- und Robotiksystemen auf Menschen, ihre sozialen Beziehungen, ihre professionelles Selbstverständnis und ihr Arbeitserleben. Schließlich ist auf Basis dieser Erkenntnisse ein breiter gesellschaftlicher Diskurs darüber zu führen, wie wir in Zukunft arbeiten möchten. Diese Entscheidungen dürfen nicht allein den Ingenieur_innen und Programmierer_innen und den Praktiker_innen aufgehalst werden.

Literatur

- Alenljung B, Lindblom J, Andreasson R, Ziemke T (2019) User experience in social human-robot interaction. In: Rapid automation: concepts, methodologies, tools, and applications, pp 1468–1490. IGI Global, Hershey
- Algorithm Watch (2019) Automating society: taking stock of automated decision-making in the EU. www.algorithmwatch.org/automating-society, access 28 02 2020
- Bartneck C, Forlizzi J (2004) A design-centred framework for social human-robot interaction. In: RO-MAN 2004. 13th IEEE international workshop on robot and human interactive communication (IEEE Catalog No. 04TH8759), pp 591–594. IEEE.
- Bainbridge L (1983) Ironies of automation. *Automatica* 19(6):775–779
- Billings CE (1991) Human-centered aircraft automation: a concept and guidelines, volume 103885. National Aeronautics and Space Administration, Ames Research Center
- Bogue, R. (2016), „Europe continues to lead the way in the collaborative robot business“, *Industrial Robot*, Vol. 43 No. 1, pp. 6–11. <https://doi.org/10.1108/IR-10-2015-0195>
- Breazeal C (2003) Toward sociable robots. *Robot Auton Syst* 42(3–4):167–175
- Bogen M, Rieke A (2018) Help wanted: an examination of hiring algorithms, equity, and bias. Upturn report 2018. <https://www.upturn.org/reports/2018/hiring-algorithms/>

- Connolly AJ, Rush D, Mutchler L (2020) Using role play to teach complexity in IT project management. In: AMCIS 2020 Proceedings, vol 3
- Callon M, Latour B (1981) Unscrewing the big leviathan: how actors macro-structure reality and how sociologists help them to do so. In: *Advances in social theory and methodology: Toward an integration of micro-and macro-sociologies*, vol 1
- Darling K (2016) Extending legal protection to social robots: the effects of anthropomorphism, empathy, and violent behavior towards robotic objects. In: *Robot law*. Elgar, Cheltenham, UK
- Dautenhahn K (2013) Human-robot interaction. In: *The encyclopedia of human-computer interaction*, 2nd Ed
- Dautenhahn K, Saunders J (2011) *New frontiers in human robot interaction*, vol 2. John Benjamins Publishing, Amsterdam
- D Druckman, L Adrian, MF Damholdt, M Filzmoser, ST Koszegi, J Seibt, C. Vestergaard (2021): Who is best at mediating a social conflict? Comparing robots, screens and humans Group Decision and Negotiation 30 (2), 395–426
- Endsley MR, Kiris EO (1995) The out-of-the-loop performance problem and level of control in automation. *Hum Factors* 37(2):381–394
- Faccio M, Bottin M, Rosati G (2019) Collaborative and traditional robotic assembly: a comparison model. *Int J Adv Manuf Technol* 102(5–8):1355–1372
- Fink J, Bauwens V, Mubin O, Kaplan F, Dillenbourg P (2011) People's perception of domestic service robots: same house- hold, same opinion? In: *International conference on social robotics*, pp 204–213. Springer, Berlin
- Fischer K (2019) Why collaborative robots must be social (and even emotional) actors. *Techene Res Philos Technol* 23(3):270–289
- Flemisch F, Abbink D, Itoh M, Pacaux-Lemoine M-P, Weßel G (2016) Shared control is the sharp end of cooperation: towards a common framework of joint action, shared control and human machine cooperation. *IFAC-PapersOnLine* 49(19):72–77
- Fong T, Nourbakhsh I, Dautenhahn K (2003) A survey of socially interactive robots. *Robot Auton Syst* 42(3–4):143–166
- Forlizzi J (2007) How robotic products become social products: an ethnographic study of cleaning in the home. In: *Proceedings of the ACM/IEEE international conference on Human-robot interaction*, pp 129–136. ACM, New York
- Forlizzi J, DiSalvo C (2006) Service robots in the domestic environment: A study of the roomba vacuum in the home. In: *Proceedings of the 1st ACM SIGCHI/SIGART conference on Human-robot interaction*, pp 258–265. ACM, New York
- Gettinger J, Filzmoser M, Koeszegi S (2016) Why can't we settle again? Analysis of factors that influence agreement prospects in the post-settlement phase. *J Bus Econ* 86(4):413–440
- Gillespie T (2016) Algorithm. In: Peters B (Eds) *Digital keywords: a vocabulary of information society and culture*, pp 18–30. Princeton University Press, Princeton
- Griffiths P, Gillespie RB (2004) Shared control between human and machine: haptic display of automation during manual control of vehicle heading. In: *12th international symposium on haptic interfaces for virtual environment and teleoperator systems, 2004. HAP- TICS'04. Proceedings*, pp 358–366. IEEE
- Grote G (2018) Gestaltungsansätze für das komplementäre Zusammenwirken von Mensch und Technik in Industrie 4.0. In: *Digitalisierung industrieller Arbeit*, pp 215–232. Nomos
- Grote G, Weyer J, Stanton NA (2014) Beyond human-centred automation—concepts for human-machine interaction in multi-layered networks. *Ergonomics* 57(3):289–294 PMID: 24670142
- Hegel F, Muhl C, Wrede B, Hielscher-Fastabend M, Sagerer G (2009) Understanding social robots. In: *2009 second international conferences on advances in computer-human interactions*, pp 169–174. IEEE

- Heydaryan S, Suaza Bedolla J, Belingardi G (2018) Safety design and development of a human-robot collaboration assembly process in the automotive industry. *Appl Sci* 8(3):344
- Hinds PJ, Roberts TL, Jones H (2004) Whose job is it anyway? a study of human-robot interaction in a collaborative task. *Hum Comput Interact* 19(1–2):151–181
- Kadir BA, Broberg O, da Conceicao CS (2018) Designing human-robot collaborations in industry 4.0: explorative case studies. In: *The international design conference-DESIGN 2018*. Design Society
- Kiesler S, Goodrich MA (2018) The science of human-robot interaction. *ACM Trans Hum Robot Interact (THRI)* 7(1):9
- Koeszegi S (2020) Der autonome Mensch im Zeitalter des Digitalen Wandels S 62–90, In: Hengstschläger M, Rat für Forschung und Technologieentwicklung (Hrsg) *Digitaler Wandel und Ethik*. Ecowin Verlag, Salzburg, München
- Kolbeinsson A, Lagerstedt E, Lindblom J (2019) Foundation for a classification of collaboration levels for human-robot cooperation in manufacturing. *Prod Manuf Res* 7(1):448–471
- Krátký J, McGraw JJ, Xygalatas D, Mitkidis P, Reddish P (2016) It depends who is watching you: 3-D agent cues increase fairness. *PloS one* 11(2). <https://dx.doi.org/https://doi.org/10.1371/journal.pone.0148845>
- Langer M, König C, Papathanasiou M (2019) Highly automated job interviews. acceptance under the influence of stakes. *Int J Select Assess* 27:217–234
- Lasi H, Fettke P, Kemper H-G, Feld T, Hoffmann M (2014) Industry 4.0. *Business & information systems engineering* 6(4):239–242
- Latour B (2007) *Reassembling the social: an introduction to actor-network-theory*. Oxford University Press, Oxford
- Lewis L, Metzler T, Cook L (2016) Evaluating human-robot interaction using a robot exercise instructor at a senior living community. In: *International conference on intelligent robotics and applications*, pp 15–25. Springer, Berlin
- Ljungblad S, Kotrbova J, Jacobsson M, Cramer H, Niechwiadowicz K (2012) Hospital robot at work: something alien or an intelligent colleague? In *Proceedings of the ACM 2012 conference on computer supported cooperative work*, pp 177–186. ACM, New York
- Mark BG, Hofmayer S, Rauch E, Matt DT (2019) Inclusion of workers with disabilities in production 4.0: Legal foundations in Europe and potentials through worker assistance systems. *Sustainability* 11(21):5978
- Meneweger T, Wurhofer D, Fuchsberger V, Tscheligi M (2015) Working together with industrial robots: Experiencing robots in a production environment. In: *2015 24th IEEE international symposium on robot and human interactive communication (RO-MAN)*, pp 833–838. IEEE, Piscataway
- Merritt SM, Ilgen DR (2008) Not all trust is created equal: dispositional and history-based trust in human-automation interactions. *Hum Factors* 50(2):194–210
- Michalos G, Makris S, Tsarouchi P, Guasch T, Kontovrakis D, Chryssolouris G (2015) Design considerations for safe human-robot collaborative workplaces. *Procedia CIRP* 37:248–253
- Molnar P, Lex G (2018) Bots at the gate: a human rights. Analysis of automated decision-making in Canada's immigration and refugee system. In: *University of Toronto Research* 114
- Moniz AB, Krings B-J (2016) Robots working with humans or humans working with robots? Searching for social dimensions in new human-robot interaction in industry. *Societies* 6(3):23
- Montebelli A, Billing E, Lindblom J, Dahlberg GM (2017) Reframing hri education: a dialogic reformulation of hri education to promote diverse thinking and scientific progress. *J Human-Robot Interact* 6(2):3–26

- Mutlu B, Forlizzi J (2008) Robots in organizations: the role of workflow, social, and environmental factors in human-robot interaction. In: *Proceedings of the 3rd ACM/IEEE international conference on human robot interaction*, pp 287–294. ACM, New York
- Norskov S, Damholdt M, Ulhoi J, Morten JM, Ess C, Seibt J (2020) Applicant fairness perceptions of a robot-mediated job interview: a video vignette-based experimental survey. *Front Robot AI*, in press
- Onnasch L, Wickens CD, Li H, Manzey D (2014) Human performance consequences of stages and levels of automation: an integrated meta-analysis. *Hum Factors* 56(3):476–488
- Payr S, Werner F, Werner K (2015) Potential of robotics for ambient assisted living. FFG benefit, Vienna
- Rammert W (2012) Distributed agency and advanced technology or: how to analyse constellations of collective inter-agency. *Agency without actors*, pp 89–112
- Romero D, Bernus P, Noran O, Stahre J, Fast-Berglund A (2016) The operator 4.0: human cyber-physical systems & adaptive automation towards human-automation symbiosis work systems. In *IFIP international conference on advances in production management systems*, pp 677–686. Springer, Berlin
- Rozendaal MC, Boon B, Kaptelinin V (2019) Objects with intent: designing everyday things as collaborative partners. *ACM Trans Comput Hum Interact (TOCHI)* 26(4):1–33
- Sabanović S, Reeder SM, Kechavarzi B (2014) Designing robots in the wild: in situ prototype evaluation for a break management robot. *J Hum Robot Interact* 3(1):70–88
- Sauppé A, Mutlu B (2015) The social impact of a robot co-worker in industrial settings. In: *Proceedings of the 33rd annual ACM conference on human factors in computing systems*, pp 3613–3622
- Seo SH, Geiskkovitch D, Nakane M, King C, Young JE (2015) Poor thing! Would you feel sorry for a simulated robot? A comparison of empathy toward a physical and a simulated robot. In *2015 10th ACM/IEEE international conference on human-robot interaction (HRI)* IEEE, S 125–132
- Seo SH, Griffin K, Young JE, Bunt A, Prentice S, Loureiro-Rodríguez V (2018) Investigating people's rapport building and hindering behaviors when working with a collaborative robot. *Int J Soc Robot* 10(1):147–161
- Sharkey A, Sharkey N (2012) Granny and the robots: ethical issues in robot care for the elderly. *Ethics Inf Technol* 14(1):27–40
- Shen S, Slovak P, Jung MF (2018) Stop. I see a conflict happening. A robot mediator for young children's interpersonal conflict resolution. In: *Proceedings of the 2018 ACM/IEEE international conference on human-robot interaction*, S 69–77
- Shibata T, Kawaguchi Y, Wada K (2012) Investigation on people living with seal robot at home. *Int J Soc Robot* 4(1):53–63
- Seibt J (2016) Integrative social robotics. A new method paradigm to solve the description problem and the regulation problem? In: *Robophilosophy/TRANSOR*, pp 104–115
- Seibt J, Vestergaard C (2018) Fair proxy communication: using social robots to modify the mechanisms of implicit social cognition. *Res Ideas Outcomes* 4:e3182
- Siino RM, Hinds PJ (2005) Robots, gender & amp; sensemaking: Sex segregation's impact on workers making sense of a mobile autonomous robot. In: *Proceedings of the 2005 IEEE international conference on robotics and automation*, pp 2773–2778. IEEE, Piscataway
- Sorenson J, Zawieska K, Vermeulen B, Madsen S, Trentemøller S, Pyka A, Bulgheroni M, Richardson K, Hasse C (2019) Perspectives on robots: a reality check on imagined futures
- Suchman L (2007) *Human-machine reconfigurations: plans and situated actions*. Cambridge university press, Cambridge

- Sung J, Christensen HI, Grinter RE (2009) Robots in the wild: understanding long-term use. In: Proceedings of the 4th ACM/IEEE international conference on human robot interaction, pp 45–52. ACM, New York
- Utami D, Bickmore TW, Kruger LJ (2017) A robotic couples counselor for promoting positive communication. In: 2017 26th IEEE international symposium on robot and human interactive communication (RO-MAN), S 248–255. <https://doi.org/https://doi.org/10.1109/ROMAN.2017.8172310>
- Wang L, Törngren M, Onori M (2015) Current status and advancement of cyber-physical systems in manufacturing. *J Manuf Syst* 37:517–527
- Weiss A, Buchner R, Tscheligi M, Fischer H (2011) Exploring human-robot cooperation possibilities for semiconductor manufacturing. In: 2011 international conference on collaboration technologies and systems (CTS), pp 173–177. IEEE, Piscataway
- Weiss A, Huber A (2016) User experience of a smart factory robot: assembly line workers demand adaptive robots. [arXiv:1606.03846](https://arxiv.org/abs/1606.03846).
- Wihlborg E, Larsson H, Hedström K (2016) The Computer Says No! – A case study on automated decision-making in public authorities. In: IEEE Computer Society, Proceedings of HICCS 2016, S 2903–2912. IEEE, Piscataway
- Wouters N, Kelly R, Velloso E, Wolf K, Ferdous H, Newn J, Joukhadar Z, Vetere F (2019) Biometric mirror: exploring values and attitudes towards facial analysis and automated decision-making. In: Conference on designing interactive systems, p 1145
- Yamazaki R, Nishio S, Ishiguro H, Nørskov M, Ishiguro N, Balistreri G (2012) Social acceptance of a teleoperated android: field study on elderly's engagement with an embodied communication medium in Denmark. In: International conference on social robotics, S 428–437. Springer, Berlin, Heidelberg. https://doi.org/https://doi.org/10.1007/978-3-642-34103-8_43
- You S, Kim J-H, Lee S, Kamat V, Robert LP Jr (2018) Enhancing perceived safety in human–robot collaborative construction using immersive virtual environments. *Autom Construc* 96:161–170
- Zaatari S, Marei M, Li W, Usman Z (2019) Cobot programming for collaborative industrial tasks: an overview. *Robot Auton Syst* 116:162–180
- Zanchettin AM, Ceriani NM, Rocco P, Ding H, Matthias B (2015) Safety in human-robot collaborative manufacturing environments: metrics and control. *IEEE Trans Autom Sci Eng* 13(2):882–893



Augmented Human-Centered Management – Personalentwicklung für hochautomatisierte Geschäftsfelder

Dirk Nicolas Wagner

1 Einleitung

Viele Disziplinen beschäftigen sich mit der Entwicklung von Technologien, die unsere Organisationen effizienter und effektiver machen und die zur wirtschaftlichen Entwicklung beitragen. Der Ökonom Paul Krugman fasste die zugrunde liegende Argumentation zusammen: „Produktivität ist nicht alles, aber auf lange Sicht ist sie fast alles. Die Fähigkeit eines Landes, seinen Lebensstandard im Lauf der Zeit zu verbessern, hängt fast ausschließlich von seiner Fähigkeit ab, seinen Output pro Arbeitnehmer zu steigern“ (Krugman 1997, S. 11). In jüngster Zeit hat sich die Debatte über die Zukunft der Arbeit um eine Studie von Carl Frey und Michael Osborne (2017) intensiviert, die untersuchte, wie anfällig Arbeitsplätze für die Automatisierung sind, und zu dem Schluss kam, dass bereits im Jahr 2030 47 % der Arbeitsplätze in den USA gefährdet sind. Diese Zahlen gehen einher mit erheblichen qualitativen Veränderungen des Arbeitsumfelds durch Digitalisierung. Wie Brian Arthur (2017) betont, brachten die 1970er- und 1980er-Jahre integrierte Schaltkreise, die schnelle PC ermöglichten, die 1990er- und 2000er-Jahre die Verbindung digitaler Prozesse und die 2010er-Jahre billige und allgegenwärtige Sensoren, die wiederum auswertbare „Ozeane von Daten“ liefern. All das hat die Entwicklung künstlicher Intelligenz (KI) vorangetrieben, also die Entwicklung von Algorithmen, die Assoziationen zwischen Datensätzen herstellen, um eine Situation zu erfassen und entsprechend zu entscheiden und zu handeln. „Diese Art von Intelligenz ist selbstorganisierend, dialogorientiert, sich ständig anpassend und dynamisch. Sie ist

D. N. Wagner (✉)

Karlshochschule International University, Karlsruhe, Deutschland

E-Mail: dwagner@karlshochschule.org

© Der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

305

R. Altenburger und R. Schmidpeter (Hrsg.), *CSR und Künstliche Intelligenz*, Management-Reihe Corporate Social Responsibility,
https://doi.org/10.1007/978-3-662-63223-9_16

auch weitgehend autonom. Diese Gespräche und ihre Ergebnisse werden mit wenig oder gar keinem menschlichen Bewusstsein oder Eingreifen stattfinden“ (Arthur 2017).

Es ist allgemein anerkannt, dass Digitalisierung und KI neue Vorschläge vom Management im Allgemeinen und vom Personalmanagement im Besonderen erfordern (Chui et al. 2018; Jarrahi 2018; Davenport und Ronanki 2018). In einer Welt mit zunehmender Automatisierung und Digitalisierung sind Wissenschaftler und Praktiker gefordert, geeignete Ansätze zur Personalentwicklung anzubieten (Stone et al. 2018). Seit dem plötzlichen Stopp der aufschlussreichen Hawthorne-Experimente haben die Managementwissenschaft ebenso wie die Managementpraxis Mühe, das Streben nach Automatisierung und den Ersatz relativ teurer menschlicher Arbeit mit einer angemessenen Entwicklung des Human Resources Managements in Einklang zu bringen. Eine typische Reaktion ist das Streben nach mehr und besseren Computerkenntnissen (Crick 2017; Peyton Jones 2011). Mit einer nachhaltigen Entwicklung hat das wenig zu tun.

Mit dem Aufkommen kognitiver Datenverarbeitung sogenannter KI ist ein Paradigmenwechsel überfällig: ein Wechsel von der Ära der Rationalisierung und Automatisierung zu einer neuen Ära der Zusammenarbeit zwischen Mensch und Maschine (Malone 2018; Wilson und Daugherty 2018). Der nachfolgende Vorschlag fordert, typisch menschliche Fähigkeiten zu entwickeln. Um dies zu konkretisieren, folgt der Beitrag den Spuren der Human Factors Science, wie sie ursprünglich für Hochrisikointustrien entwickelt wurde (Salvendy 2012; Kanki et al. 2010) und integriert diese Ansätze mit den Anforderungen der so genannten Human-Agent Collectives (Jennings et al. 2014), die sich aufgrund des technologischen Fortschritts derzeit in den meisten, wenn nicht gar allen Industrien herausbilden. Sowohl für die Theorie als auch für die Praxis der Personalentwicklung ist dies eine neue Kombination.

Da vernünftigerweise davon ausgegangen werden kann, dass die Automatisierung – wo immer technologisch möglich und wirtschaftlich sinnvoll – weiter voranschreiten wird, muss Personalentwicklung so gestaltet werden, dass nicht nur eine optimale Zusammenarbeit zwischen Mensch und Technik, sondern auch eine wünschenswerte Rolle des Menschen in Organisationen ermöglicht wird. In diesem Beitrag wird daher vorgeschlagen, den Schwerpunkt vom Management für die Automatisierung mit menschlicher Restarbeit auf das sogenannte Augmented Human-Centered Management (AHCM) zu verlagern. Es wird ein konzeptioneller Rahmen angeboten, der die Kompetenzen identifiziert und beschreibt, die Menschen entwickeln müssen, um erfolgreich an hochgradig automatisierten und digitalisierten Geschäftsumgebungen teilnehmen zu können. Dies dient dazu, die derzeit wahrgenommenen Lücken zu schließen, wie das Personalmanagement Digitalisierungsstrategien unterstützen kann (Fenech et al. 2019; Parry und Strohmeier 2014), während gleichzeitig ein menschenzentrierter Ansatz beibehalten wird (Bissola und Imperatori 2019).

Der Beitrag ist interdisziplinär angelegt und integriert verschiedene Fachbereiche (Torraco 2016). Das bedeutet, dass neue Einsichten für das Personalmanagement durch

die kritische Synthese ausgewählter Erkenntnisse aus der Betriebswirtschaft, Ökonomie, Informatik, der Human-Factors-Wissenschaft und der Philosophie gewonnen werden.

Die Struktur lässt sich wie folgt skizzieren: Die gegebenen Herausforderungen und der Kontext werden dem Leser aus zwei Perspektiven betrachtet. Zunächst wird der interdisziplinäre wissenschaftliche Ansatz der Human-Agenten-Collectives vorgestellt, um den entstehenden Kontext der Zusammenarbeit von Mensch und Maschine zu skizzieren. Zweitens werden die vorherrschenden, in der Ökonomie und der Theorie des Unternehmung verwurzelten Denkweisen für die Organisationsgestaltung kurz besprochen und mit dem Phänomen der „Ironie der Automatisierung“ (Bainbridge 1983) verknüpft. Auf diesen Grundlagen wird eine normative Haltung eingenommen und die Notwendigkeit von AHCM diskutiert. Das Leitmotiv der Augmentation anstelle des derzeit vorherrschenden Fokus auf Automatisierung wird eingeführt, bevor ein in der interdisziplinären Human Factors Science verwurzelter Rahmen konzeptualisiert und vor dem Hintergrund aktueller und zukünftiger Herausforderungen der Personalentwicklung diskutiert wird.

2 Die Entstehung von Mensch-Agent-Kollektiven

Fortschreitende Digitalisierung bedeutet, dass Maschinen dabei sind, zu eigenständigen Akteuren zu werden. Sie konkurrieren nicht nur immer öfter mit menschlicher Arbeit, sondern beeinflussen zunehmend auch menschliches Handeln und eröffnen so neue Möglichkeiten, schränken den Menschen bei anderen Gelegenheiten aber auch ein (Carr 2014). Dies wird durch die Entwicklungen im Schachspiel gut veranschaulicht: Nach der Niederlage des menschlichen Großmeisters im Schach durch den Supercomputer Deep Blue im Jahr 1996 gehörte Gari Kasparov zu den Initiatoren einer Neudefinition des Schachspiels, die es den Menschen erlaubte, mit Schachcomputern zu kooperieren, um sich mit anderen Mensch-Maschine-Teams in sogenannten Freestyle-Schachturnieren zu messen. Es stellte sich heraus, dass starke menschliche Spieler oder Supercomputer gegen relativ schwache menschliche Spieler kaum konkurrieren konnten, wenn diese ihr mit Standardschachcomputern besetztes Team durch die Implementierung überlegener Prozesse effektiv organisierten (Kasparow 2008; Cowen 2014).

Das Schachspiel ist nur einer von vielen Bereichen, in denen sich Menschen mit künstlichen Agenten zusammentun, um Ziele zu erreichen. Ganz allgemein stellt Varian (2014) fest, dass Computer heute bei praktisch jeder Transaktion das verbindende Element sind. Jennings et al. (2014) definieren soziotechnische Systeme, in denen Menschen und intelligente Software (Agenten) interagieren als Human Agent Collectives (HAC). Genau wie der aus zwischenmenschlichen Transaktionen schon heute nicht mehr wegzudenkende Computer, werden die aktuell entstehenden HAC Schritt für Schritt mehr und mehr Einfluss auf das Arbeits- und Sozialumfeld des Menschen nehmen. Branchenbezogene Beispiele sind die Besatzung auf dem Flugdeck eines modernen Verkehrsflugzeugs, die von einer Software unterstützt wird, die sich auf Zehntausende von

Sensoren stützt, die über das Flugzeug verteilt sind (Yedavalli und Belapurkar 2011); der Landwirt, der sich von Präzisionsagartechnik leiten lässt (Kitouni et al. 2018); der Produktmanager, der Conversational Commerce Technologien verwendet, um Softwareagenten im Dialog mit Kunden einzusetzen; der Psychotherapeut, der mit sogenannten Embodied Conversational Agents arbeitet, um internetbasierte kognitive Verhaltenstherapie in der präventiven psychiatrischen Versorgung anzubieten (Suganuma et al. 2018); oder intelligente Software für das Logistikmanagement, die menschliche Arbeit in Lagerhallen lenkt (Mahroof 2019). Der technologische Wandel beeinflusst die Arbeitsumgebung für Menschen erheblich. In einem HAC entwickeln sich die Rollen von Menschen und Agenten gemeinsam weiter.

Nach Jennings et al. (2014) ist die Ära, in der Menschen direkte Anweisungen an passive Maschinen geben, vorbei. Der Mensch beginnt, mit hoch vernetzten künstlich intelligenten Agenten zusammenzuarbeiten, die autonom agieren. Diese Umgebungen gelten als offen und zeichnen sich durch flexible soziale Interaktionen aus. Hier hat manchmal der Mensch das Sagen und manchmal der Computer. Und die Beziehung kann sich dynamisch verändern (Jennings et al. 2014, S. 80). Die Begriffe flexible Autonomie und agile Teamarbeit (Jennings et al. 2014, S. 82) beschreiben die kurzlebige Natur von Teams, an denen Menschen unterschiedlich stark beteiligt sind und in denen Autoritätsbeziehungen nicht starr, sondern kontextabhängig sind. Die proaktive Beteiligung von Maschinen bei der Informationssammlung und -filterung, bei Analyse- und Entscheidungsprozessen wirft Fragen der sozialen Verantwortung und Verantwortlichkeit auf. Da Software oft „hinter den Kulissen“ arbeitet (Jennings et al. 2014, S. 85), sind ihre Handlungen wie auch die Gründe dafür den beteiligten Menschen oft nicht zugänglich.

Wie bei einer offenen Gesellschaft bedeuten offene HAC, dass „Kontrolle und Information unter einer großen Zahl potenziell eigennütziger Personen und Agenten mit unterschiedlichen Zielen und Aufgaben weit gestreut sind. [...] Unsicherheit, Zweideutigkeit und Voreingenommenheit sind in diesem realen Umfeld endemisch, sodass die Agenten mit Informationen unterschiedlicher Qualität, Vertrauenswürdigkeit und Provenienz umgehen müssen“ (Jennings et al. 2014, S. 82). Das sich abzeichnende Gesamtbild ist in Abb. 1 dargestellt.

3 Homo oeconomicus, Machina oeconomica und die Ironie der Automatisierung

In den meisten, wenn nicht sogar in allen Branchen streben Manager hartnäckig nach Produktivitätssteigerungen für ihre Organisationen (Drucker 2001; Malik 2010). Dieses Streben nach Effizienz hat zu einem Fokus auf Automatisierung geführt (Frey und Osborne 2017). Jahrzehntlang wurde die Managementpraxis von einer Managementtheorie geprägt, die an Wirtschaftshochschulen sowohl für Studenten als auch für Absolventen sowie in Kursen und Programmen für Führungskräfte gelehrt wird. Diese




Abb. 1 Human-Agent Collectives. (HAC; eigene Darstellung; Eigenschaften nach Jennings et al. 2014)

Managementtheorie wiederum stützt sich im Wesentlichen auf ökonomische Theorien wie die neoklassische Mikroökonomie, die Theorie der Unternehmung oder die Transaktionskostenökonomie (vgl. z. B. Douma und Schreuder 2013). Dies hat im Lauf der Jahrzehnte zu einer Situation geführt, in der sich die ökonomische Konzeption des eigennützigen Menschen als begrenzt rationaler Nutzenmaximierer heute weitgehend in der Art und Weise widerspiegelt, wie Unternehmen strukturiert und organisiert sind. Manager nehmen ihre Organisationen als vom so genannten Homo oeconomicus bevölkert wahr. Und auch die Stakeholder dieser Organisationen nehmen die Manager so wahr. Mit Blick auf die Ausbildung an Business Schools sind diese Entwicklungen immer wieder kritisiert worden (Ghosal 2005). Handfeste Skandale wie die Fälle Enron, Tyco, Deepwater Horizon von BP, der Einsturz einer Textilfabrik in Bangladesch, VW-Dieselsgate oder die Praktiken der deutschen Fleischindustrie zeigen immer wieder die problematischen Auswirkungen eines Produktivitätsstrebens auf der Grundlage traditioneller Managementkonzepte auf.

Trotzdem ist es nicht überraschend, dass die Automatisierung der Wirtschaft den bisherigen Trampelpfad rein ökonomisch orientierter Handlungsmuster folgt. Wo es technologisch und wirtschaftlich machbar ist, wird die Automatisierung zur bevorzugten Wahl auf dem Weg zu höheren Produktivitätsniveaus. Und bei genauerem Hinsehen wird schnell klar, warum: Die *Machina oeconomica* verspricht der bessere *Actoris oeconomicus* zu werden. Algorithmen können so programmiert werden, dass sie dem Kalkül der rationalen Wahl und der Nutzenmaximierung unter Nebenbedingungen folgen, und dies wird von der Informatik schon seit Jahrzehnten mit Begeisterung

aufgegriffen (Huberman et al. 1988; Wagner 2001). Längst hat man festgestellt, dass der Homo oeconomicus mit dem normalen Menschen wenig gemein hat (Kirchgässner 2013; Beinhocker 2007). Bei Maschinen muss es einen solchen Unterschied nicht geben.¹

Die erheblichen Anreize zur Automatisierung haben zu der Annahme geführt, dass es wünschenswert ist, den Menschen, wann immer möglich, aus der Wertschöpfungskette herauszunehmen. Solche Strategien scheiterten jedoch immer wieder. Zwar wird der Mensch regelmäßig als das schwächste Glied in der Kette angesehen, dass es zu ersetzen gilt. Doch paradoxerweise wird ihm dann eine entscheidende Rolle zugedacht: Er soll automatisierte Prozesse überwachen und bei Problemen eingreifen. Für dieses Phänomen prägte Bainbridge (1983) den Begriff Ironie der Automatisierung. Eine Untersuchung von Baxter et al. (2012) zeigte, dass trotz des technischen Fortschritts die Ironien der Automatisierung nach wie vor bestehen. Dies stellt eine Herausforderung für die Personal- und Organisationsentwicklung dar.

Das Dilemma, in immer komplexeren Umgebungen immer mehr Verantwortung zu übernehmen und dabei von der Automatisierung beiseitegeschoben zu werden, passt nicht dazu, wie Menschen von Natur aus ausgestattet sind. In *Das überforderte Gehirn* zeigen Gazzaley und Rosen (2017), wie Menschen, wenn sie, angetrieben durch die Technologie, darauf abzielen, mehrere Aufgaben gleichzeitig zu erledigen und immer online zu sein, Opfer von Ablenkung und Unterbrechung werden. Was beobachtet werden kann, ist eine „Degradierung des Wissensarbeiters“ (Wagner 2017). Organisationen, die dem Paradigma der Automatisierung folgen, drängen den Menschen in die Rolle eines auf den Homo oeconomicus reduzierten Unterstützers, denn das erleichtert die nahtlose Integration mit Maschinen. Symptomatisch erscheinen in diesem Sinn die Managementansätze des Technologieunternehmens Amazon.com Inc.: „Wenn du ein guter Amazonian sein willst, wirst du ein Amabot“ (Kantor und Streitfeld 2015).

4 Der Bedarf für Augmented Human-Centered Management

Die beiden vorangegangenen Abschnitte beschreiben ein Szenario, in dem Menschen in zunehmend computerisierte und automatisierte Umgebungen eintauchen, in denen die Machina oeconomica Aufgaben und Entscheidungen übernimmt. Das Streben nach Produktivitätsgewinnen und technologischem Fortschritt führt zu einer Verdrängung des Menschen, die aber durch die sogenannte Ironie der Automatisierung eingeschränkt wird. Mitarbeitern wird abverlangt, sich entgegen der menschlichen Natur dem Paradigma des Homo oeconomicus anzuschließen. Indem Unternehmen ihre markt-

¹Mit dem Aufkommen offener Systeme und der Verbreitung des maschinellen Lernens beginnt sich dies jedoch zu ändern. Da Maschinen aus von Menschen produzierten Daten lernen, zeigen sie – zumindest vorläufig – vergleichbare Verzerrungen und irrationale Verhaltensweisen (Caliskan et al. 2017).

orientierten Ziele verfolgen, schaffen sie so Organisationen für Maschinen. Aus einer CSR-Perspektive muss ein solches Szenario als problematisch empfunden werden.

Die Alternative sind Organisationen für Menschen (zuerst) und (dann) für Maschinen. Dies würde den unumkehrbaren Trend zur Automatisierung anerkennen, würde aber eine Verlagerung von einem Management für die Automatisierung hin zu einem Managementverständnis bedeuten, in dessen Mittelpunkt der Mensch steht, ergänzt durch Maschinen. Ich nenne ein solches Konzept Augmented Human-Centered Management (AHCM). Es hat seine Wurzeln im Humanismus, der von Erich Fromm definiert wurde als ein System, in dessen Mittelpunkt der Mensch, seine Integrität, seine Entwicklung, seine Würde und seine Freiheit steht. Es beruht auf dem Prinzip, dass der Mensch nicht ein Mittel ist, um dieses oder jenes Ziel zu erreichen, sondern dass er selbst Träger seines eigenen Ziels ist. Dies beruht nicht nur auf der Fähigkeit zu individuellem Handeln, sondern auch auf der Fähigkeit, an der Geschichte teilzuhaben, und auf der Tatsache, dass jeder Mensch die Menschheit als Ganzes in sich trägt (Fromm 1961, S. 147, zitiert in Aktouf und Holford 2009, S. 108). Eine solche Sichtweise kann als kompatibel mit der Integrationsthese empfunden werden, um die herum sich die Stakeholdertheorie entwickelt hat: Es macht keinen Sinn, über Wirtschaft zu reden, ohne über Ethik zu reden, und es macht keinen Sinn, über Ethik zu reden, ohne über Wirtschaft zu reden. Daraus ergibt sich die Schlussfolgerung, „dass es keinen Sinn macht, über Wirtschaft oder Ethik zu sprechen, ohne über Menschen zu sprechen“ (Freeman et al. 2010, S. 7). Auf dieser Basis werden im Folgenden die grundlegenden Ideen von AHCM skizziert.

Der Begriff Human-Centered Management wurde von Maria-Teresa Lepeley (2017) geprägt und fasst eine immer wiederkehrende Sorge von Wirtschafts- und Organisationswissenschaftlern wie Adam Smith, Joseph Schumpeter, Elton Mayo, Abraham Maslow, Douglass MacGregor und Peter Drucker um menschliche Eigenschaften und Bedürfnisse zusammen. Schon früh erkannte Peter Drucker, dass der Zusammenhalt und die Stärke unserer Gesellschaft zunehmend von der Integration der psychologischen und sozialen Bedürfnisse des Wissensarbeiters mit den Zielen der Organisation und der Industriegesellschaft abhängen (Drucker 1966, S. 172). Trotz der Fortschritte im Management stellt Lepeley jedoch fest, dass das menschliche Individuum im Management kaum eine Rolle spielt und dass stattdessen innerhalb des Bildungswesens, der Organisationen, der Wirtschaft und der breiteren Gesellschaft weiterhin anderen Interessen mehr Aufmerksamkeit geschenkt wird (Lepeley 2017, S. 7).

Um den Erwartungen und den grundlegenden Bedürfnissen des menschlichen Individuums gerecht zu werden, ist eine breitere Wahrnehmung menschlicher Qualitäten nützlich. Studien über den Menschen, die über das Menschenbild des Homo oeconomicus hinausgehen, heben regelmäßig wichtige menschliche Eigenschaften hervor: Basierend auf Entwicklungen in der Verhaltensökonomie können Menschen als induktiv rational dargestellt werden, was bedeutet, dass wir induktive Mustererkennung mit deduktiver Logik vermischen (Beinhocker 2007). Ein relevanter Aspekt dabei ist die Fähigkeit implizites Wissen aufzubauen (Polyani 1967), das den Menschen in die Lage

versetzt, mehr zu wissen, als er zum Ausdruck bringen kann. Sennett (2008) zeigt zum Beispiel auf, das menschliches Handwerk aus synergistisch kombinierten Aktivitäten von Körper und Geist entsteht. Arendt (1960) betont die menschliche Fähigkeit zu Neuanfängen, die als Keimzelle für Innovation angesehen werden kann. Und Frank (1988), in der Tradition von Adam Smith und anderen, beleuchtet die Fähigkeit zu Moral und Leidenschaft.

Während eine solche breitere Wahrnehmung menschlicher Qualitäten sicherlich unvollständig ist und eingehenderer Untersuchungen bedarf, spezifiziert sie für die Zwecke dieses Beitrags hinreichend, wer und was im Zentrum eines Human-Centered Management zu berücksichtigen ist. Wenn in diesem Sinn „der Mensch das Maß aller Dinge ist“ (Aktouf und Holford 2009, S. 101), ist eine Klärung hinsichtlich des Verhältnisses zwischen Mensch und Technik erforderlich. Ein Ansatz, der sich mit einer humanistischen Perspektive auf das Management in Einklang bringen lässt, stammt von Davenport und Kirby (2016). Sie schlagen einen Paradigmenwechsel weg von der Automatisierung (Ersatz des Menschen) und hin zur Augmentation (Verbesserung des Menschen) vor und empfehlen zur Arbeit mit Maschinen fünf Strategien:


1. Stepping Up: Eine Ebene über den Maschinen arbeiten und Entscheidungen über Augmentation treffen
2. Stepping Aside: Die aktuelle Aufgabe der Maschine überlassen und eine Aufgabe verfolgen, die Maschinen nicht gut ausführen können
3. Stepping In: Um die automatisierten Entscheidungen eines Computers zu überwachen und zu verbessern
4. Stepping Narrowly: Um ein spezielles Gebiet in seinem Beruf zu finden, dessen Automatisierung nicht wirtschaftlich wäre
5. Stepping Forward: Zukunftstechnologie schaffen

Die menschlichen Qualitäten der induktiven Rationalität, des impliziten Wissens, des handwerklichen Könnens, der Fähigkeit zu Neuanfängen sowie der Moral und der Leidenschaft ermöglichen diese Strategien, stellen aber auch die Kriterien für individuelle Entscheidungen dar. Die Abb. 2 fasst den Ausgangspunkt für AHCM, wie oben beschrieben, zusammen.

5 Human-Factors und Human-Centered Management

Angesichts der Idee des AHCM, des weit verbreiteten Phänomens der Ironie der Automatisierung, der Notwendigkeit, über das Paradigma des Homo oeconomicus hinauszugehen, und der Eigenschaften von HAC wird Personalentwicklung zu einer Herausforderung. Wie können menschliche Fachkräfte am besten auf dieses sich schnell verändernde und zunehmend komplexe wirtschaftliche und soziale Umfeld vorbereitet werden? Welche Kompetenzen sollen entwickelt werden?

Abb. 2 Ausgangspunkt für Augmented Human-Centered Management. (Eigene Darstellung; Icon von Gonzalo Zaragoza)



Es bietet sich an, von einer Branche lernen, die bereits vor Jahrzehnten vergleichbare Anforderungen für sich identifiziert hat: der Luftfahrt. In den 1970er-Jahren erlebte die kommerzielle Luftfahrt trotz erheblicher technologischer Fortschritte in Form von ausgeklügelten Unterstützungssystemen eine anhaltend hohe Anzahl von Flugzeugabstürzen, die 1977 auf Teneriffa im tödlichsten Unfall der Luftfahrtindustrie gipfelte (Hagen 2013). Die Untersuchungen dieses und anderer Vorfälle ergaben, dass menschliches Versagen die Hauptursache dafür war. In den folgenden Jahren konzentrierte sich die Luftfahrtindustrie stark auf die Entwicklung menschlicher Fähigkeiten, die den Menschen helfen sollten, mit komplexer Technologie effektiver zusammenzuarbeiten und den Luftverkehr sicherer zu machen. Um dieser Herausforderung in der Praxis gerecht zu werden, wurde ein integrierter Schulungsansatz entwickelt, der ursprünglich Crew Resource Management (CRM) genannt wurde (Kanki et al. 2010). Seit der ersten Einführung des CRM, begleitet von weiteren technologischen Fortschritten, hat ein agiles Zusammenwirken von Mensch und Maschine in der Luftfahrt zu einer erheblichen und nachhaltigen Verringerung der Zahl der Unfälle im kommerziellen Luftverkehr geführt (Federal Aviation Administration; 2018; Ranter 2018).

CRM baut auf dem interdisziplinären Human-Factors-Ansatz auf: Betrachtet aus der integrierten Perspektive von Wissenschaft, Technik, Design, Technologie und Management konzentriert sich Human Factors auf das bestmögliche Verständnis der Interaktion von Mensch und Artefakt (Karwowski 2012, S. 3). Ein ganzheitlicher, auf den Menschen ausgerichteter Ansatz, der kognitive, soziale, organisatorische, ökologische und andere relevante Faktoren berücksichtigt, wird gefördert (Salvendy 2012). Außer in der Luftfahrt hat sich der Human-Factors-Ansatz auch in vielen anderen

Bereichen als wertvoll erwiesen, wie zum Beispiel im Gesundheitswesen, im Schienenverkehr, im Militär, in der Öl- und Gasindustrie, im Energiesektor, in der Fertigung, in der Konsumgüterindustrie oder in der Software- und Informationstechnologie (Shorrock und Williams 2017). Sowohl die Erfolgsbilanz in anspruchsvollen soziotechnischen Umgebungen als auch ihre konzeptionellen Grundlagen legen nahe, dass CRM-Training generell ein nützlicher Ausgangspunkt für eine Personalentwicklung sein kann, die den oben beschriebenen grundlegenden Bedürfnissen in Mensch-Agenten-Kollektiven gerecht wird.

CRM-Training soll helfen, menschliche Fehler zu verstehen, zu vermeiden, zu identifizieren und zu beheben (Badke-Schaub et al. 2012). Besonderes Gewicht wird auf Ansätze gelegt, die die individuelle Leistung durch effektive Interaktion mit anderen steigern (Kanki et al. 2010). Es werden drei Phasen der Ausbildung unterschieden: 1. eine erste Bewusstseinsschulung zur Vermittlung der wesentlichen Konzepte und des Know-hows im Bereich Human-Factors; 2. Übungen und Feedback in realistischen Umgebungen für komplette Teams; 3. Auffrischungstrainings in regelmäßigen Abständen auf der Grundlage verschiedener Methoden (Federal Aviation Administration 2004; Kanki et al. 2010). Die Schulungen setzen sich regelmäßig aus den folgenden Bausteinen zusammen, sind aber nicht darauf beschränkt: Situationsbewusstsein, Workload-Management, menschliches Versagen, Kommunikation, Entscheidung, Führung und Teamarbeit, Stress und Ermüdung (ICAO 1998; Federal Aviation Administration 2004; Kanki et al. 2010). Diese Bausteine und ihre potenzielle Relevanz außerhalb der Luftfahrt werden im Folgenden kurz besprochen.

Situationsbewusstsein: Die Schulung des Situationsbewusstseins hilft dem Einzelnen, die gegenwärtigen System- und Umweltbedingungen zu verstehen und so zukünftige Veränderungen zu antizipieren. Der Schwerpunkt liegt auf der Fähigkeit, Selbstgefälligkeit bewusst zu vermeiden, System- und Umweltveränderungen zu beobachten und andere Teammitglieder über mögliche Probleme zu informieren. In Umgebungen mit Menschen und elektronische Agenten ist der Mensch sowohl mit einer natürlichen als auch mit einer digitalen Umgebung konfrontiert. Folglich sind die Anforderungen an das Situationsbewusstsein besonders hoch. Aufgrund der zunehmenden Automatisierung verändern sich die Anforderungen auch fortlaufend. Fahrerassistenzsysteme in Fahrzeugen sind gute Beispiele für elektronische Agenten, die das Situationsbewusstsein unterstützen und dazu beitragen. Doch wie Unfälle zeigen, muss der Mensch sein Situationsbewusstsein passend weiterentwickeln und darf nicht nachlässig werden. Insbesondere im beruflichen Umfeld ist ein Situationsbewusstsein für den Umgang mit einer Flut an Information aus einer Vielzahl elektronischer Quellen zu entwickeln.

Workload Management: Dies betrifft sowohl das Selbstmanagement als auch das Management anderer. Der Zweck der CRM-Schulung besteht darin, eine gute Vorbereitung und ausreichende Planung eines Vorhabens einschließlich der entsprechenden Kommunikation zu ermöglichen. Um sich auf primäre Aufgaben konzentrieren zu

können, müssen Prioritäten gesetzt und andere Aufgaben effektiv delegiert werden. Für den Austausch mit den anderen Mitgliedern des Teams ist es wichtig zu lernen, wie man klärendes Feedback gibt, sucht und erhält (Suffler et al. 2010). Wenn neue Informationen verfügbar werden, sind Flexibilität und die Fähigkeit, die Vorgehensweise anzupassen, von Bedeutung. Insbesondere in hochautomatisierten Umgebungen ist es notwendig, den Fortschritt kontinuierlich zu überwachen, Ablenkung zu vermeiden, wachsam zu bleiben und, falls nötig, ohne unangemessene Verzögerung zu reagieren.

Menschliches Versagen: Irren ist menschlich. So lernt der Mensch schon früh im Leben, mit Fehlern umzugehen. Eine CRM-Schulung professionalisiert diese Fähigkeit, sichert das Wissen über die Fehlerursachen und ermöglicht die Unterscheidung von Fehlerarten. Mit dem Verständnis von gleichzeitigen Ausfällen und Fehlerketten sowie dem Wissen über verfügbare Ressourcen und Redundanzen im Umgang mit Bedrohungen und Fehlern werden die Kompetenzen zum Umgang mit Fehlern erhöht. Dazu gehören Fehlervermeidung, -resistenz, -erkennung und -behebung (Hofmann und Frese 2011). Die Komplexität und Dynamik von HAC führt in ein Dilemma, das die Nachfrage nach solchen Kompetenzen wahrscheinlich erhöhen wird: Einerseits zeigen Menschen eine Tendenz zum blinden Vertrauen in technische Systeme (Parasuraman und Manzey 2010). Auf der anderen Seite sind Fehler in komplexen Systemen unvermeidlich; auch fortgeschrittene Technik hat Schwachstellen und reagiert oft nicht angemessen auf unvorhergesehene Entwicklungen (Hagen 2013).

Kommunikation: In komplexen Situationen kann die Wahrnehmung jedes einzelnen Beteiligten von Bedeutung sein. Effektive Kommunikation ist dann der Schlüssel zu erfolgreicher Zusammenarbeit. Daher zielt die CRM-Schulung darauf ab, eine freie und offene Kommunikation mit aktiver Beteiligung aller Teammitglieder zum geeigneten Zeitpunkt zu ermöglichen. Die Teilnehmer üben den Gebrauch einer klaren und effektiven Sprache und arbeiten an ihrer Reaktionsfähigkeit auf Feedback. Kritische Situationen im Flugzeugcockpit haben gezeigt, dass Durchsetzungsvermögen und die Fähigkeit, bei Bedarf das Wort zu ergreifen, wichtige Themen sind (Raulf 2013). Es gilt, Kommunikationsumgebungen zu schaffen, in denen Pläne dargelegt und Unklarheiten ausgeräumt werden, was zu einem multidirektionalen und interaktiven Informationsaustausch führen soll. Wenn nicht nur Menschen, sondern auch elektronische Agenten beteiligt sind, müssen sich die Menschen der Unterschiede zwischen verschiedenen Arten von Akteuren bewusst sein.

Entscheiden: Grundlegend für jedes Training dieser Art ist, dass die Teilnehmer lernen, wie Menschen und elektronische Agenten zu Entscheidungen kommen. Auf dieser Grundlage werden sie darin geschult, Abweichungen von erwünschten Zuständen zu erkennen, Probleme zu beurteilen, Handlungsalternativen zu generieren, Risiken und Chancen zu erkennen und die beste Vorgehensweise auszuwählen, die dann zum Zweck des Lernens und der notwendigen Anpassung überprüft wird. Szenarien der

individuellen und gemeinsamen Entscheidungsfindung werden berücksichtigt. All dies ist in der Luftfahrt von besonderer Relevanz, da keine oder schlechte Entscheidungen eine wesentliche Rolle bei fast allen Flugunfällen spielen (Bühler et al. 2013). Die Luftfahrt ist ebenso wie HAC eine hochautomatisierte Umgebung. In solchen Kontexten werden viele Aufgaben an Maschinen delegiert und Menschen werden typischerweise nur dann einbezogen, wenn Entscheidungen erforderlich sind. Dies bedeutet, dass die Entscheidungsfindung über ein breites Spektrum von automatisierten Aufgaben und Prozessen zur Kernaufgabe und damit zu einer wichtigen Fähigkeit wird.

Führung und Teamarbeit: CRM strebt ein Gleichgewicht zwischen aktiver Teamteilnahme und der Akzeptanz von Autorität an. Das Training fördert daher den Einsatz angemessener Autorität, die eine Konzentration auf Aufgaben und Prioritäten sicherstellt, während sie sich offen um die Belange der Mitarbeiter kümmert und diese bei der Erfüllung der Aufgaben unterstützt. Die Ressourcen des Teams sollen effektiv zur Zielerreichung eingesetzt werden, was durch die Schaffung einer positiven Teamatmosphäre ermöglicht wird. Dies setzt die Fähigkeit zur Steuerung von gemeinsamen Abläufen und zur Entwicklung zwischenmenschlicher Beziehungen im Team voraus, was wiederum entsprechende Führungskenntnisse (Stahl 2013) wie auch die Fähigkeit, das Führungsverhalten an den jeweiligen situativen Kontext anzupassen, erfordert (Strohschneider 2012).

Stress und Ermüdung: Mehr als Maschinen brauchen Menschen Ruhe. CRM-Training versucht, den Teilnehmern Wissen über die Ursprünge und Auswirkungen von Stress und Ermüdung zu vermitteln. Dies ermöglicht es Ihnen, ihre persönlichen Ressourcen zu erkennen und zu managen. Wie in der Luftfahrt ist auch in HAC der Mensch die einzige Komponente, die nicht so entwickelt wurde, dass sie rund um die Uhr funktioniert (Ebermann und Murtha 2013). Daher ist es von entscheidender Bedeutung, persönliche Verantwortung in Bezug auf Stress- und Ermüdungsfaktoren zu übernehmen. Aufgrund der Anfälligkeit des Menschen für Ablenkung und angesichts der Tatsache, dass Ablenkung in computergestützten Umgebungen ständig vorkommt, sind Selbstbestimmung und Ausdauer wichtige Eigenschaften, die es zu entwickeln gilt.

Zusammenfassend lässt sich sagen, dass CRM zwar auf den Menschen ausgerichtet, aber dennoch in dem Sinn voreingenommen ist, dass es sich auf den Umgang mit Fehlern und Risiken konzentriert. Generell ist das Unternehmen und sein Umfeld jedoch nicht nur durch Risiken, sondern auch durch Chancen gekennzeichnet. Das erfolgreiche Management von Fehlern und Risiken führt zu Qualität, Gesundheit, Sicherheit, Schutz und weniger nachteiligen Auswirkungen auf die Umwelt, während bei der Erkennung und Realisierung von Chancen Innovation stattfindet. Um dies zu erreichen, kann CRM ergänzt werden durch:

Ideenfindung und Innovation: Kreativitätstraining, das auf zeitgemäßen Ansätzen wie z. B. Design Thinking, Value Proposition Design (Osterwalder et al. 2014),




Abb. 3 Komponenten der Personalentwicklung für Augmented Human Centered Management. (Eigene Darstellung; Icon von Gonzalo Zaragoza)

Gamifizierung (Gray et al. 2010) und anderen Konzepten aufbaut, stellt den Kunden in den Mittelpunkt und ist inspiriert von der Idee des menschenzentrierten Designs (Kelley und Littman 2005, 2016). Die Teilnehmer werden in die Lage versetzt, Innovationsprozesse von der Chancenidentifikation über die Ideengenerierung und -bewertung bis hin zur Umsetzung zu steuern. Es werden Bedingungen geschaffen, um das „angrenzend Mögliche“ (Koppl et al. 2015, S. 8) zu erreichen. Dies führt zu Innovationen im Sinn einer Transformation von Ideen in neue bzw. verbesserte Produkte, Dienstleistungen oder Prozesse. Kreativität und kommerzielle Anwendung werden kombiniert (Baregheh et al. 2009). Kompetenzen wie die Pflege einer Innovationskultur oder die Fähigkeit, Innovation um Erfahrung herum aufzubauen, werden entwickelt (Kumar 2012).

Offensichtlich gibt es ein hohes Maß an Synergie zwischen den Zielen für Ideenfindung und Innovation und den Kompetenzen, die hinter den oben genannten Ausbildungskategorien Situationsbewusstsein, Workload-Management, menschliches Versagen, Kommunikation, Entscheiden, Führung und Teamarbeit sowie Stress und Ermüdung stehen. Daraus ergibt sich eine implizite Übereinstimmung dieser zusätzlichen Kategorie mit dem Human-Factors-Ansatz hinter CRM.

Die Abb. 3 fasst die Elemente des damit beschriebenen, umfassenden, humanzentrierten Ansatzes zur Personalentwicklung zusammen. Dieser dient ganz schlicht dazu, weniger Krisen zu verursachen und gleichzeitig mehr Chancen zu realisieren. Mit dem hier dargestellten Kontext, ausgestattet mit einer universelleren Mission und ergänzt durch neue Elemente, vollzieht CRM den Übergang zum AHCM. Tief verwurzelt in einem gut etablierten CRM profitiert AHCM nicht nur vom Beitrag der einzel-

nen Komponenten, sondern vor allem von den Synergien, die sich aus der Integration der Trainings ergeben. Dies ist besonders relevant, da die Personalentwicklung in einem Bereich (z. B. Kommunikation) die Entwicklung in anderen Bereichen (z. B. Führung und Teamarbeit oder Situationsbewusstsein) verstärkt.

6 Diskussion

Die schrittweise Entwicklung des Konzepts eines AHCM in diesem Beitrag wurde mit dem Ziel unternommen, Organisationen zu entwickeln, die zuerst für den Menschen da sind und erst dann für Maschinen. Diese ist im Humanismus verwurzelt und umfasst Folgendes:

1. Die typischen Eigenschaften von Human-Agent Collectives werden berücksichtigt (Jennings et al. 2014).
2. Die Fähigkeit, mit den „Ironien der Automatisierung“ (Bainbridge 1983) umzugehen, wird verbessert.
3. Eine „Degradierung von Wissensarbeitern“ (Wagner 2017) wird vermieden.
4. Es wird auf typisch menschliche Qualitäten gebaut, die über das Verhaltensmodell des Homo oeconomicus hinausgehen.

Die Komponenten des Ausbildungskonzepts für AHCM sind aus dem Human-Factors-Ansatz abgeleitet. Dies gewährleistet einen inhärent humanistischen Ansatz: Wie von Fromm (1961) postuliert, sind die beteiligten Menschen Träger ihres eigenen Ziels. Als solche werden menschliche Eigenschaften wie induktive Rationalität, implizites Wissen, handwerkliches Geschick, die Fähigkeit zu Neuanfängen und die Fähigkeit zu Moral und Leidenschaft im Rahmen der Ausbildung angesprochen und entwickelt. Dies bedeutet auch, dass durch AHCM aktive und systematische Anstrengungen gegen eine Degradierung von Wissensarbeitern unternommen werden und so insbesondere mit Blick auf die Mitarbeiter als Stakeholder eine nachhaltige Unternehmensentwicklung ermöglicht wird.

Teil des Konzepts ist ein Paradigmenwechsel weg von der Automatisierung und hin zur Augmentation unter Verwendung der von Davenport und Kirby (2016) vorgeschlagenen Ausrichtungen. Im Allgemeinen bietet die Idee der Augmentation eine Orientierung, um mit Eigenschaften von HAC wie flexibler Autonomie und agiler Teamarbeit umzugehen. Es leitet die Arbeitsteilung an und fordert Technologien, die Menschen individuell und als Mitglieder von Organisationen unterstützen. Konkret müssten die Prioritäten bei der Aus- und Weiterbildung in Übereinstimmung mit den Rollen, die Einzelpersonen in Organisationen einnehmen, gesetzt werden, um dann die jeweilige Strategie für zur Augmentation festzulegen. Zum Beispiel kann für jemanden, der „einspringt“ (d. h. die Überwachung und Verbesserung der automatisierten Entscheidungen eines Computers), Situationsbewusstsein sowie Stress- und Ermüdungs-

training relevanter sein als Ideations- und Innovationstraining, während für das „Vorwärtsspringen“ (d. h. die Schaffung von Zukunftstechnologie) die letztere Trainingskategorie am relevantesten sein könnte.

Eine an AHCM orientierte Personalentwicklung verspricht sowohl individuelle Schlüsselkompetenzen als auch Kompetenzen vom Team zu stärken, die wichtig sind, um sich an die Eigenschaften von HAC anzupassen und die Ironie der Automatisierung zu mildern. Um mit Software, die „hinter den Kulissen“ Informationen aufbereitet, adäquat umzugehen, können folgende Trainingsergebnisse relevant sein: ein erhöhtes Potenzial für den Umgang mit Komplexität, ein besseres Situationsbewusstsein für Einflüsse von Automatisierung und verbesserte Entscheidungskompetenzen. Ein weiterer Grund, warum AHCM gut zu den Management- und Arbeitsanforderungen im HAC passt, ist, dass es so konzipiert ist, dass es die individuelle Leistung durch eine effektive Interaktion mit anderen, einschließlich elektronischen Akteuren, nutzt. Dies wird indirekt durch eine Studie von Shanks et al. (2015) bestätigt, die herausfanden, dass der technologische Fortschritt und der Aufstieg von KI insbesondere Fähigkeiten zur kreativen Zusammenarbeit, zur Personalentwicklung und zum Coaching, zur sozialen Vernetzung sowie zum kreativen Denken und Experimentieren erfordert. Kolbornsrud et al. (2017) kommen zu dem Schluss, dass mit zunehmender Relevanz von maschinellen Akteuren die Menschen in Zukunft ihre Sozial- und Netzwerkfähigkeiten weiter verbessern, sich darauf konzentrieren, Entscheidungen zu fällen, und in den meisten Bereichen wie Designer arbeiten und Maschinen wie Kollegen behandeln müssen. Auch dies deckt sich mit den oben vorgestellten Komponenten zur Personalentwicklung.

Zum aktuellen Zeitpunkt befinden sich die HAC, wenn überhaupt, in einem frühen Stadium einer äußerst dynamischen Entwicklung. Die Zukunft führt jedoch bereits jetzt zu realen Herausforderungen in der Personalentwicklung. Regelmäßige Erhebungen von Deloitte zu Humankapitaltrends fassen die praktischen Anforderungen in den verschiedenen Branchen zusammen. Diese spiegeln sich auch in Studien von KPMG und PWC wider (Deloitte 2017; KPMG 2017; PWC 2015; siehe auch Wang 2018). KPMG (2017) betont, dass sich eine intelligente Automatisierung massiv auf das Human Resource Management auswirken wird. Alle erwähnten Studien heben hervor, dass Organisationen Menschen brauchen, die wie folgt beitragen:

1. In agilen, netzwerkbasierten Strukturen anstelle von traditionellen hierarchischen Organisationen handeln können
2. Teamarbeit und den Wissensaustausch fördern und unterstützen
3. Produktive und engagierte Arbeit für sich selbst und für andere ermöglichen
4. Kreativität und Innovation fördern und unterstützen
5. Die Rolle verstehen, die Menschen in einer automatisierten Welt spielen werden
6. Intelligente Automatisierung einleiten, um Personal für strategischere Arbeit freizusetzen
7. Digitale Technologie nutzen, z. B. für Analyse-, Bewertungs- und Entscheidungszwecke

8. Die Grenzen der Arbeit zwischen Mensch und Maschine untersuchen und menschliche Arbeit entsprechend gestalten
9. Neue Formen der Zusammenarbeit zwischen Mensch und Technik ermöglichen
10. Sich an kontinuierlichem Lernen beteiligen

Vergleicht man das Konzept der AHCM mit diesen aktuellen praktischen Herausforderungen, fällt auf, dass Menschen damit nicht nur punktuell bei der Erfüllung der genannten Anforderungen unterstützt werden. Vielmehr gewährleistet die synergetische Zusammensetzung, die von der langfristigen Entwicklung des zugrundeliegenden CRM-Konzepts profitiert, eine hochsystematische Unterstützung. Die gute Integration und Komplementarität der Module ist aber nur ein Aspekt. Eine interessante Lehre, die aus CRM für Personalentwickler gezogen werden kann, ist, dass ganze Teams und nicht nur (Top-)Manager oder High Potentials in die Personalentwicklung einbezogen werden. Die gleiche Erfahrung zu machen, das gleiche Wissen zu absorbieren, mit den gleichen Anforderungen und Erwartungen konfrontiert zu werden, eröffnet die Möglichkeit, gemeinsame mentale Modelle zu formen und zu einer gemeinsamen Kultur, einer Kultur des Augmented Human Centered Management, beizutragen.

7 Fazit

In diesem Kapitel wurde hervorgehoben, dass die Konzentration von Führungskräften auf Produktivitätswachstum und Automatisierung auf der Grundlage traditioneller Konzepte wie dem Homo oeconomicus auf die Schaffung von Organisationen für Maschinen statt für Menschen abzielt. Während Maschinen zum Machina oeconomica gemacht werden können, ist der Trend, dass Menschen in die Rolle des Homo oeconomicus gezwungen werden, kritisch zu hinterfragen. Ausgehend vom humanistischen Ideal, dass der Mensch der Träger seines eigenen Ziels ist, wird die Schaffung und Entwicklung von Organisationen für Menschen (zuerst) und (dann) für Maschinen ins Auge gefasst. Dies erfordert eine breitere Wahrnehmung menschlicher Qualitäten sowie eine Ausrichtung der Personalentwicklung auf genau diese Qualitäten. Damit die Computertechnologie dies angemessen unterstützen kann, muss der Schwerpunkt von Automatisierung auf Augmentation verlagert werden. Mithilfe der Erkenntnisse der Human Factors Science im Allgemeinen und der CRM-Ausbildung im Bereich der Luftfahrt im Besonderen wurde gezeigt, dass die Personalentwicklung nicht bei Null anfangen muss, um diese ehrgeizigen Ziele zu erreichen. Auf Grundlage jahrzehntelanger Forschung im Bereich Human Factors und der Erfahrung in Branchen, die durch ständige Mensch-Maschine-Interaktion gekennzeichnet sind, konnte ein Konzept für eine AHCM-orientierten Personalentwicklung abgeleitet werden. Im Vergleich zur traditionellen CRM-Ausbildung, die auf Risiken ausgerichtet ist, beinhaltet AHCM auch die Entwicklung von Kreativität und Innovation, um das unternehmerische Potenzial zu steigern.

Zusammenfassend ergeben sich die folgenden Erkenntnisse:

1. Ein Paradigmenwechsel weg von einem Management für die Automatisierung hin zu einem Management für und mit Augmentation ist notwendig. Dies erfordert einen spezifischen Ansatz im Bereich der Personalentwicklung.
2. Personalentwicklung tut gut daran digitale Arbeitsumgebungen als Human Agent Collectives (HAC) wahrzunehmen und „Ironien der Automatisierung“ explizit zu berücksichtigen.
3. Ein auf den Menschen ausgerichteter Ansatz der Personalentwicklung kann durch Trainingsmethoden erreicht werden, die sich am Human-Factors-Ansatz orientieren.
4. Durch die Berücksichtigung von Ideenfindung und Innovation, kann der traditionell auf Risiken fokussierte Human-Factors-Ansatz um den Bereich der Chancen erweitert werden.
5. Eine Degradierung des (Wissens-)Arbeiters kann vermieden werden, wenn menschliche Eigenschaften wie induktive Rationalität, implizites Wissen, handwerkliches Geschick, die Fähigkeit zu Neuanfängen und die Fähigkeit zu Moral und Leidenschaft berücksichtigt werden.

In Summe konnte ein spezifischer, konsistenter und umfassender Vorschlag für AHCM Training in einer zunehmend digitalen Welt mit KI vorgelegt werden. Dennoch stößt dieser Vorschlag aktuell auf klare Grenzen. Es konnte nur ein erster Überblick gegeben werden, der Konsistenz und Plausibilität erkennen lässt. Während die von Davenport und Kirby (2016) vorgelegten Ideen zur Erweiterung noch nicht näher untersucht sind, profitiert die auf menschlichen Faktoren basierende CRM-Ausbildung von fast 40 Jahren kontinuierlicher Entwicklung und Erfahrung. Praktische Umsetzung und zukünftige Forschung sind notwendig, um das Gesamtkonzept vollständig zu entwickeln, die theoretischen Grundlagen zu stärken und es empirisch zu testen.

Faszinierend ist, dass viele Personalentwicklungsabteilungen bei näherer Betrachtung feststellen, dass die Programme und Schulungen, die sie derzeit anbieten, bereits eine Reihe der hier vorgestellten Komponenten enthalten. Ein daraus resultierender „Brownfield-Ansatz“ für AHCM kann in der Klärung des Auftrags, der Vision und der Werte zukünftiger Programme bestehen, kombiniert mit einer geeigneten Neuorchestrierung und Ergänzung im Einklang mit dem hier dargestellten Konzept.

Literatur

- Aktouf O, Holford D (2009) The implications of humanism for business studies. In: Spitzkeck H, Pirson M, Amann W, Khan S, Kimakowitz E v (eds) Humanism in business. Cambridge University Press, Cambridge, S 101–122
- Arendt H (1960) The human condition. University of Chicago Press, Chicago
- Arthur B (2017) Where is technology taking the economy? McKinsey Quarterly (October)

- Badke-Schaub P, Hofinger G, Lauche K (Hrsg) (2012) Human factors. Psychologie sicheren Handelns in Risikobranchen, 2 überarbeitete. Springer, Berlin
- Bainbridge L (1983) Ironies of automation. *Automatica* 19:775–780
- Baxter G, Rooksby J, Wang Y, Khajeh-Hosseini A (2012) The ironies of automation... still going strong at 30? Proceedings of ECCE 2012 Conference. Edinburgh, 29th–31st August.
- Beinhocker E (2007) The origin of wealth. Evolution, complexity, and the radical remaking of economics. Harvard Business School Press, Boston
- Bühler J, Ebermann H, Hamm F, Reuter-Leahr D (2013) Decision making. In: Ebermann H, Scheiderer J (eds) Human factors on the flight deck: safe piloting behaviour in practice. Springer, Berlin, S 135–164
- Caliskan A, Bryson J, Narayanan A (2017) Semantics derived automatically from language corpora necessarily contain human biases. *Science* 356(6334):183–186
- Carr N (2014) The glass cage. How our computers are changing us. W. W. Norton & Company, New York
- Chui M, Manyika J, Miremadi M, Henke N, Chung, R, Nel, P, Malhotra, S (2018) Notes from the AI frontier. Insights from hundreds of use cases. Discussion Paper. McKinsey Global Institute, San Francisco
- Cowen T (2014) Average is over – powering America beyond the age of the great stagnation. Penguin Putnam, New York
- Crick T (2017) Computing in education. An Overview of Research in the Field. The Royal Society, London
- Davenport T, Kirby J (2016) Only humans need apply. Winners and losers in the age of smart machines. Harper Business, New York
- Davenport T, Ronanki R (2018) Artificial intelligence for the real world. *Harvard Bus Rev* 96(1):108–116
- Deloitte (ed) (2017) Rewriting the rules for the digital age. *Human capital trends* 2017
- Douma S, Schreuder H (2013) Economic approaches to organizations, 5. Aufl. Pearson, Harlow
- Drucker P (1966) The effective executive. HarperCollins, New York
- Drucker P (2001) The essential Drucker. The best of sixty years of Peter Drucker's essential writings on management. HarperCollins, New York
- Ebermann H, Murtha M (2013) Fatigue and alertness management. In: Ebermann H, Scheiderer J (Hrsg) Human Factors on the flight deck: safe piloting behaviour in practice. Springer, Berlin, S 187–209
- Ebermann H, Scheiderer J (Hrsg) (2013) Human factors on the flight deck: safe piloting behaviour in practice. Springer, Berlin
- Federal Aviation Administration (ed) (2004) Crew resource management training. Advisory circular 120-51e. Edited by FAA, Washington DC.
- Administration Federal Aviation (Hrsg) (2018) Accident & incident data. Federal Aviation Administration, Washington DC
- Fenech R, Baguant P, Ivanov D (2019) The changing role of human resource management in an era of digital transformation. *Int J Entrepr* 22(2):1–10
- Frank R (1988) Passions within reason. The strategic role of the emotions. W. W. Norton & Company, New York
- Freeman E (2010) Stakeholder theory. The state of the art. Cambridge Univ. Press, Cambridge

- Frey C, Osborne M (2017) The future of employment: how susceptible are jobs to computerisation? *Technol Forecast Soc Change* 114:254–280
- Fromm E, Marx K, Bottomore T (1961) Marx's concept of man. Frederick Ungar Publishing Co, New York
- Gazzaley A, Rosen L (2017) Das überforderte Gehirn: Mit Steinzeitwerkzeug in der Hightech-Welt. Redline, München
- Ghoshal S (2005) Bad management theories are destroying good management practices. *Acad Manag Learning Educ* 4(1):75–91
- Gray D, Brown S, Macanufu J (2010) *Gamestorming. A playbook for innovators, rulebreakers, and changemakers*. O'Reilly, Beijing
- Hagen J (2013) *Fatale Fehler. Oder warum Organisationen ein Fehlermanagement brauchen*. Springer Gabler, Berlin
- Hofmann D, Frese M (Hrsg) (2011) *Errors in organizations*. Routledge, New York
- Huberman B (Hrsg) (1988) *The ecology of computation*. Elsevier, New York
- ICAO (ed) (1998). *Human factors training manual*. Doc 9683-an/950: International Civil Aviation Organisation
- Jarrahi M (2018) Artificial intelligence and the future of work: human-AI symbiosis in organizational decision making. *Bus Horiz* 61(4):577–586
- Jennings N, Moreau L, Nicholson D, Ramchurn S, Roberts S, Rodden T, Rogers A (2014) Human-agent collectives. *Commun ACM* 57(12):80–88
- Kanki B, Helmreich R, Anca J (Hrsg) (2010) *Crew resource management*. Academic, Amsterdam
- Kantor J, Streitfeld D (2015) Inside Amazon: wrestling big ideas in a bruising workplace. *The New York Times*, 8/15/2015
- Karwowski, W. (2012). The discipline of human factors and ergonomics. *Handbook of human factors and ergonomics*, 4, 3–37.
- Kasparov G (2008) *How life imitates chess*. Arrow Books, London
- Kelley T, Littman J (2005) *The ten faces of innovation. IDEO's strategies for beating the devil's advocate & driving creativity throughout your organization*. Currency/Doubleday, New York
- Kelley T, Littman J (2016) *The art of innovation. Lessons in creativity from IDEO, America's leading design firm*. Profile Books, London
- Kirchgässner G (2013) *Homo oeconomicus. The economic model of individual behavior and its applications in economics and other social sciences*. Springer, New York
- Kitouni I, Benmerzoug D, Lezzar F (2018) Smart agricultural enterprise system based on integration of internet of things and agent technology. *J Organ End User Comput* 30(4):64–82
- Kolbjornsrud V, Amico R, Thomas R (2017) Partnering with AI: how organizations can win over skeptical managers. *Strategy Leadersh* 45(1):37–43
- Koppl R, Kauffman S, Felin T, Longo G (2015) Economics for a creative world. *J Inst Econ* 11:1–31
- KPMG (ed) (2017) *HR transformation. Which lens are you using?* kpmg.com/HRT
- Krugman P (1997) *The age of diminished expectations. U.S. economic policy in the 1990s*. MIT Press, Cambridge
- Kumar V (2012) *101 design methods. A structured approach for driving innovation in your organization*. Wiley, Hoboken
- Lepelley M (2017) *Human centered management. 5 pillars of organizational quality and global sustainability*. Greenleaf, Saltaire
- Malik F (2010) *Management. The essence of the craft*. Campus, Frankfurt/M.

- Malone T (2018) *Superminds. The surprising power of people and computers thinking together.* Oneworld, London
- Mahroof K (2019) A human-centric perspective exploring the readiness towards smart warehousing. The case of a large retail distribution warehouse. *Int J Inform Manag* 45:176–190
- Osterwalder A, Pigneur Y, Bernarda G, Smith A (2014) *Value proposition design. How to create products and services customers want.* Wiley, Hoboken
- Parasuraman R, Manzey D (2010) Complacency and bias in human use of automation: an attentional integration. *Human factors* 52(3):381–410
- Parry E, Strohmeier S (2014) HRM in the digital age – digital changes and challenges of the HR profession. *Employee Relations* 36(4):i–iii
- Peyton Jones S (2011) *Computing at school.* BCS – The Chartered Institute for IT, Swindon
- Polanyi M (1967) *The tacit dimension.* The University of Chicago Press, Chicago
- PWC (2015) 18th CEO survey. *People strategy for the digital age: a new take on talent.* PWC, London
- Ranter H (2018) ASN data show 2017 was safest year in aviation history. Aviation Safety Network (ASN)
- Raulf H (2013) Communication. In: Ebermann H, Scheiderer J (Hrsg) *Human factors on the flight Deck: safe piloting behaviour in practice.* Springer, Berlin, S 87–112
- Salvendy G (2012) *Handbook of human factors and ergonomics.* Wiley, Hoboken
- Sennett R (2008) *The craftsman.* Yale University Press, New Haven
- Shanks R, Sinha S, Thomas R (2015) *Managers and machines, unite!* Accenture Institute for High Performance, Boston
- Shorrock S, Williams C. (eds) (2017) *Human factors and ergonomics in practice. Improving system performance and human well-being in the real world.* CRC Press, Boca Raton
- Spitzeck H, Pirson M, Amann W, Khan S, Kimakowitz E, v (Hrsg) (2009) *Humanism in business.* Cambridge University Press, Cambridge
- Stahl H (2013) *Führungswissen.* Schmidt, Berlin
- Stone C, Neely A, Lengnick-Hall M (2018) Human resource management in the digital age: Big data, HR analytics and artificial intelligence. In: Pedro M, Carolina M (Hrsg) *Management and technological challenges in the digital age.* CRC Press, Boca Raton (Manufacturing design and technology series), S 13–42
- Strohschneider S (2012) Human-factors training. In Badke-Schaub P, Hofinger G, Lauche K (eds) *Human factors. Psychologie sicheren Handelns in Risikobranchen.* Springer, Berlin, S 313–322
- Suganuma S, Sakamoto D, Shimoyama H (2018) An embodied conversational agent for unguided internet-based cognitive behavior therapy in preventative mental health. Feasibility and acceptability pilot trial. *JMIR Mental Health* 5(3):e10454
- Suffler M, Salas E, Xavier L (2010) The design, delivery and evaluation of crew resource management training. In: Kanki B, Helmreich R, Anca J (Hrsg) *Crew resource management.* Academic Press/Elsevier, Amsterdam, Boston, S 205–234
- Varian H (2014) Beyond big data. *Bus Econ* 49(1):27–31
- Wagner D (2001) *Software-agents and liberal order: an inquiry along the borderline between economics and computer science.* Universal, Miami
- Wagner D (2017) Graceful degradation and the knowledge worker. In Küpers W, Sonnenburg S, Zierold M (eds) *Rethinking management. Perspectives and impacts of cultural turns and beyond.* Springer, Wiesbaden, S 171–190.

- Wang J (2018) HRD scholarship: trends, reality, and opportunities. *Hum Resour Dev Rev* 17(3):227–233
- Wilson J, Daugherty P (2018) Collaborative intelligence: humans and AI are joining forces. *Harvard Bus Rev* 96(4):114–123
- Yedavalli R, Belapurkar R (2011) Application of wireless sensor networks to aircraft control and health management systems. *J. Control Theory Appl* 9(1):28–33
- Torraco, R (2016): Writing integrative literature reviews: Using the past and present to explore the future. In *Human Resource Development Review* 15 (4), 404–428.

Dirk Nicolas Wagner ist Unternehmer und Professor für Strategisches Management an der Karlshochschule International University in Karlsruhe. Als geschäftsführender Gesellschafter einer mittelständischen Unternehmensgruppe setzt er sich proaktiv mit den sich fortlaufend verändernden Anforderungen von Markt, Staat und Gesellschaft auseinander. Als Wissenschaftler, Autor und Referent zählt Wagner zu den wenigen Ökonomen, die sich bereits seit den 1990er-Jahren mit Fragestellungen rund um das Thema Mensch und Maschine befassen: die Ökonomik einer Welt mit künstlicher Intelligenz und Human-Centered Management sind seine zentralen Themen.

Künstliche Intelligenz – Kriegstreiber oder Friedensstifter im War for Talent?

Jakob Sidoruk und Harald Ritter

1 Einleitung

Im August 2018 machte eine Meldung von Reuters die Runde durch die Tech-Szene und Human-Resources(HR)-Abteilungen: Amazons Machine-Learning-Spezialisten hatten „klammheimlich“ eine künstliche Intelligenz (KI) entwickelt! [1].

Das Ziel: Der heilige Gral des Recruiting – ein Werkzeug, das oben mit Lebensläufen von Kandidaten befüllt wird und unten die besten Aspiranten ausspuckt, die dann ohne Verzögerung interviewt und eingestellt werden können.

Aber ebenso unbemerkt wie die KI entwickelt wurde, verschwand sie einige Zeit später wieder. Eine Beerdigung ohne Pomp und große Reden. Die Verantwortlichen hatten festgestellt, dass die KI die Lebensläufe von Frauen deutlich benachteiligte und fast ausschließlich Männer auswählte.

Und so entschloss man sich im Jahr 2015, dem Projekt frühzeitig den Garaus zu machen.

Dieser Vorfall erregte viel Aufmerksamkeit und warf ein Schlaglicht auf einen Prozess, der zu diesem Zeitpunkt für viele unbemerkt bereits seit vielen Jahren im vollen Gange war: Der Einsatz von KI im Recruiting.

Es ist eine alte Weisheit, dass am Ende die Mitarbeiter eines Unternehmens über seinen Erfolg bestimmen. Marktteilnehmer, die erfolgreich die fähigsten Köpfe für sich

J. Sidoruk · H. Ritter (✉)
digital dynamite GmbH, Berlin, Deutschland
E-Mail: hr@digitaldynamite.de

J. Sidoruk
E-Mail: js@jobtenssor.com

gewinnen und langfristig binden können, haben einen entscheidenden Wettbewerbsvorteil. Einige Unternehmen nehmen den War for Talent daher durchaus wörtlich und betrachten ihn als den entscheidenden Hebel im Spiel der Kräfte.

Nichts scheint daher naheliegender als die Macht der Maschinen genau in jenem Bereich zu entfesseln, in dem es doch eigentlich besonders auf die Bindungen zwischen Menschen anzukommen scheint.

Die Möglichkeiten von KI im Bereich Recruiting sind immens. Das spektakuläre Scheitern von Amazon mit seinen schier unbegrenzten Ressourcen sollte aber zugleich als laute Warnung in den Ohren tönen.

Auch erfahrene HRler sind vielfach verwirrt von der Fülle an Informationen, Anwendungsmöglichkeiten und Marketingversprechen. Und brillante Tech-Teams stellen häufig nach einiger Zeit fest, dass ihre Modelle auf falschen oder unvollständigen Grundannahmen aufgebaut wurden und daher in der Praxis unbrauchbar sind.

Dieser Beitrag vermittelt einen Überblick über die Anwendungsmöglichkeiten von KI im Recruiting und diskutiert ethische und unternehmerische Fragen.

2 Prozesse für die Besetzung einer Stelle

Um die Möglichkeiten von KI im Recruiting zu erörtern, empfiehlt sich zunächst ein kurzer Blick auf gängige Prozesse für die Besetzung einer vakanten Position.

2.1 Der Bewerber als aktives Element

Die Besetzung einer Stelle läuft traditionell wie folgt ab:

- Das Unternehmen verfasst eine Stellenausschreibung und veröffentlicht diese in passenden Medien, wie etwa Jobbörsen und sonstigen Online-Kanälen.
- Kandidaten, die sich für geeignet halten, reichen ihre Bewerbungsunterlagen ein.
- Die HR Abteilung sichtet die Bewerbungen, erteilt unpassenden Bewerbern eine Absage, telefoniert mit potenziellen Anwärtern und spricht anschließend Einladungen zu einem persönlichen Gespräch aus.
- Dieser Zyklus muss je nach Komplexität der vakanten Position wiederholt werden, bis die Stelle schließlich besetzt werden kann (Abb. 1).

Dieser Prozess erfordert, dass Bewerber die Stellenausschreibung finden und aktiv auf das ausschreibende Unternehmen zugehen. Der Recruiter ist hier eher passiv. Zudem ist der Kandidatenpool auf aktiv Suchende beschränkt. Das ist ein entscheidender Nachteil, denn es wird geschätzt, dass bis zu 50 % aller Arbeitnehmer latent suchend sind [2] – also nicht selbst aktiv suchen, aber bereit sind ihren Arbeitsplatz zu wechseln, wenn sich eine passende Gelegenheit ergibt.

Traditionelles Recruiting




Abb. 1 Traditionelle Kandidatensuche mittels Stellenanzeige. (Eigene Darstellung)

2.2 Active Sourcing

Fast 70 % der Personalverantwortlichen geben an, dass es heute für sie schwieriger ist, qualifizierte Fachkräfte zu finden als noch vor fünf Jahren [3]. Daher können es sich Unternehmen gerade bei schwer zu besetzenden Positionen kaum noch erlauben, ausschließlich auf passende Bewerbungen aktiv Suchender zu hoffen (Abb. 2).

Active Sourcing




Abb 2 Active Sourcing. (Eigene Darstellung)

Daher zapfen auch 80 % der deutschen Unternehmen mit mehr als 150 Mio. Euro Umsatz den Markt der latent Suchenden an [2]. Sie treten an passende Kandidaten durch persönliche Ansprache heran, bauen eine Bindung auf und hoffen, diese mittel- bis langfristig „Ioseisen“ zu können. Man spricht hier von Active Sourcing.

Auch die eingangs erwähnte von Amazon entwickelte KI-Lösung war zur Unterstützung des Active Sourcing konzipiert.

3 Möglichkeiten von künstlicher Intelligenz im Bewerberauswahlverfahren

3.1 Stellenausschreibung mit künstlicher Intelligenz optimieren

Die konkrete Wortwahl einer Stellenausschreibung entscheidet maßgeblich darüber, ob ein Kandidat sich angesprochen fühlt oder nicht.

Eine KI kann große Mengen unstrukturierter Daten wie Stellenausschreibungen untersuchen, diese in Klassen unterteilen und die Erfolgswahrscheinlichkeit neuer Stellenausschreibungen basierend auf ihrer Wortwahl bewerten.

Die Firma Textio z. B. gibt an ihre KI auf Grundlage von zehn Millionen Stellenausschreibungen entwickelt zu haben [4].

Die KI vergleicht neue Stellenausschreibungen mit früheren Stellenausschreibungen aus der gleichen Branche und gibt auf Basis einer semantischen Analyse Empfehlungen, welche Formulierungen in der Vergangenheit zu einer guten Bewerbersituation geführt haben und welche weniger erfolgreich waren und daher besser vermieden werden sollten.

Dies kann für HR-Abteilungen aller Größen eine Unterstützung sein, um möglicherweise seit Jahren oder gar Jahrzehnten etablierte Formulierungen und Textbausteine einem Realitätscheck zu unterziehen.

Aus ethischer Sicht ist der Einsatz einer solchen KI zu Optimierungszwecken der Stellenausschreibung unkritisch zu bewerten. Der Einsatz verbessert im Idealfall die Bewerbungssituation, greift aber nicht in den Bewerbungsprozess selbst ein.

3.2 Auffindbarkeit der Stellenausschreibung mit künstlicher Intelligenz verbessern

Der Markt der aktiv Suchenden reicht gerade im IT-Bereich nicht aus, um den Bedarf abzudecken und ist daher hart umkämpft. Nur Unternehmen, deren Stellenausschreibungen überhaupt erst von Stellensuchenden gefunden werden, erhalten die Möglichkeit, sich an diesem Wettbewerb zu beteiligen.

Ein Bereich, in dem auch große Jobbörsen der Entwicklung deutlich hinterherhinken, ist die Suchfunktion für Stellensuchende. In der Regel funktioniert diese nach dem Prinzip der Volltextsuche.

Gibt der Nutzer etwa „Softwareingenieur“ in das Suchfeld ein, so gibt die Suche ihm alle Stellenanzeigen zurück, in denen Softwareingenieur auftaucht. Allerdings verwenden viele HR-Abteilungen stattdessen das Wort „Softwareentwickler“ in ihrer Ausschreibung. Das ist technisch zwar nicht korrekt, weil Softwareingenieur und Softwareentwickler keine identischen Jobtitel sind, trotzdem ist dies ein häufig auftretender Fall.

Für den Jobsuchenden bedeutet dies, dass inhaltlich eng verwandte Stellenanzeigen für ihn unsichtbar bleiben, insofern nicht sein exaktes Suchwort in der Ausschreibung verwendet wird.

Eine Volltextsuche erkennt die Intention des Suchenden nicht und versteht auch keine semantischen Zusammenhänge in den Stellenanzeigen. Weiterhin kann eine Volltextsuche auch mehrdeutige oder sehr kurze Suchwörter nicht effektiv händeln. R z. B. ist eine verbreitete Programmiersprache für statistische Berechnungen. Wenn ein R-Programmierer bei einer der großen Jobbörsen nach R sucht wird er in der Regel nur unpassende Jobs wie „Wissenschaftliche/r Mitarbeiter/in ...“ finden, in denen der Buchstabe R zufällig alleinstehend im Titel auftaucht.

Hierfür existieren zahlreiche Beispiele. Insgesamt führt die mangelnde Standardisierung der Stellenanzeigen und die unterschiedliche von Bewerbern und Unternehmen verwendete Sprache in Verbindung mit rückständigen Suchfunktionen der Jobbörsen dazu, dass eine für den Suchenden vielleicht sogar maßgeschneiderte Stellenanzeige unsichtbar bleibt.

Jobtensor hat eine KI entwickelt, die auch komplexe technische Zusammenhänge aus Stellenanzeigen extrahieren kann und zugleich die Suchintention des Nutzers versteht. Die Volltextsuche wird durch eine semantische Intelligenz ersetzt, die dem Jobsuchenden verwandte Bereiche aufzeigen und ihn auf bisher unentdeckte Stellenanzeigen lenken kann. Durch die Entfernung semantischer Barrieren können Stellensucher und Unternehmen zueinander finden, die sonst im Nebel aneinander vorbeigelaufen wären.

Die KI ist derzeit über jobtensor.com/uk im Vereinigten Königreich nutzbar und wird ab Anfang 2021 in Deutschland verfügbar sein.

3.3 Chatbots zur Verbesserung der Candidate Experience

„Befreit Sergeant Star“ forderte die Electronic Frontier Foundation (EFF) im Januar 2014. Die EFF ist eine US-amerikanische Nichtregierungsorganisation, die sich für Grundrechte im Informationszeitalter einsetzt.

Befreit werden sollte nicht etwa ein gefangen gehaltener Unteroffizier, sondern ein Chatbot, der von den US-Streitkräften eingesetzt wird, um Fragen von Bewerbern zu beantworten.

Nach den Anschlägen vom 11. September stieg der Verkehr in den Chatrooms auf der Webseite der US-Armee, goarmy.com, steil an, was die Personalkosten in die Höhe schnellen ließ. Als kostensenkende Maßnahme wurde das Sergeant-Star-Projekt als

Partnerschaft zwischen der Armee und der Firma Next IT gestartet. Die ersten Testläufe begannen 2003. Drei Jahre später wurde Sergeant Star (offiziell STAR für „Strong Trained And Ready“) der Öffentlichkeit vorgestellt [5] und gewann im Folgenden eine unerwartete Popularität.

Die EFF zielte in ihrem Auskunftersuchen nicht auf die Befreiung des virtuellen Soldaten ab, sondern wollte technische und statistische Einblicke erhalten und sorgte sich dabei insbesondere um datenschutzrechtliche Aspekte.

Die Leistungsdaten von Sergeant Star stellten sich bei den vom Pentagon zur Verfügung gestellten Informationen als durchaus eindrucksvoll heraus [6]:

- Innerhalb von fünf Jahren beantwortete der Chatbot mehr als 10 Mio. Fragen in 2,8 Mio. Chatsitzungen.
- Seine Trefferquote lag bei 94 %, d. h. 94 von 100 Fragen wurden korrekt beantwortet – eine Quote, die viele menschliche Agenten nicht erreichen.
- Insgesamt erledigte Sergeant Star damit die Arbeit von 55 Recruitern.
- Die Schöpfer hatten viel investiert, um der KI eine menschliche Note zu geben. So besitzt Sergeant Star ein Aussehen, das aufwendig einem realen Unteroffizier nachgebildet wurde. Seine Antworten besitzen häufig eine humorvolle Note. So antwortet er auf die Frage „Bist du ein Mensch?“: „Ich wurde von Next IT für goarmy.com entwickelt. [...] Sie schufen mich als den denkenden, sprechenden und unglaublich gutaussehenden Soldaten, der ich heute bin.“ Die Bewerber empfanden die Chats mit Sergeant Star nicht nur als informativ, sondern auch unterhaltsam. Tatsächlich wurden der KI im Chatroom Fragen gestellt, die ein Bewerber einem realen Recruiter vielleicht nicht vorgelegt hätte, wie z. B. ob er bei der Armee in Gegenwart anderer duschen muss.

Dem Beispiel von Sergeant Star sind seitdem viele Unternehmen gefolgt. Airbus etwa konnte mithilfe seines Chatbot zwei Drittel der Anfragen automatisiert beantworten [7].

Der Einsatz einer Chatbot-KI bringt eine Reihe von Vorteilen mit sich:

- Mehr als 80 % der 18- bis 64-Jährigen verwenden täglich Messenger Dienste wie Whatsapp [8]. Der Chatbot nutzt damit eine Kommunikationsform, die in unserer heutigen Gesellschaft nicht nur weit akzeptiert ist, sondern häufig sogar einem Telefonat vorgezogen wird.
- Ein Chatbot kann 24 Stunden am Tag, 365 Tage im Jahr die Fragen von Interessierten beantworten und das ohne jede Wartezeit. Dadurch werden Prozesse verkürzt, Kosten gespart und die durchschnittliche Zeit bis zur Einstellung eines Kandidaten reduziert.
- Ein Chatbot kann zunehmend auch komplexe Fragen beantworten und auch für andere Tätigkeiten eingesetzt werden, wie etwa zusätzliche Dokumente vom Bewerber abzufragen oder Termine zu vereinbaren.

Insgesamt ist das Automatisierungspotenzial durch Chatbots gerade für große Unternehmen erheblich. Inwiefern der Einsatz unter dem Strich erfolgreich verläuft, hängt stark von der konkreten Ausgestaltung ab. Die Integration eines Chatbot muss sich nahtlos in die sonstige „candidate experience“ einfügen. Damit wird der Eindruck bezeichnet, den ein Kandidat aufgrund der Gesamtheit aller Interaktionen mit einem Unternehmen gewinnt.

Der Chatbot sollte bei dem aktuellen Stand der Technik nicht als ein Ersatz für, sondern als eine Ergänzung zum menschlichen Kontakt mit dem Bewerber verstanden werden. Er nimmt dem Recruiter die Beantwortung von Routinefragen ab und verschafft ihm somit mehr Zeit für seine wichtigsten Aufgaben und Gespräche.

Aus ethischer Sicht ist der Einsatz eines Chatbot als unbedenklich zu betrachten, solange dieser lediglich als Informationsgeber eingesetzt wird und keine Entscheidungsgewalt über den Bewerber innehat.

Tatsächlich kann ein Chatbot für die Gleichbehandlung von Kandidaten sogar förderlich sein. Eine Chatbot-KI interessiert sich nicht für Geschlecht oder Herkunft des mit ihm chattenden Kandidaten. Hingegen kann ein menschlicher Recruiter seinen „unconscious“ Bias kaum jemals vollständig aufgeben [9].

3.4 Persönlichkeitsprofil mittels Sprachanalyse

Wer kann sich vorstellen, ein Einstellungsgespräch mit einem Roboter zu führen? Sollte diese entscheidende Interaktion nicht stets dem Menschen vorbehalten bleiben? Einige KI-Avantgardisten sind tatsächlich der Meinung, dass der menschliche Bias in keiner Stufe des Einstellungsgesprächs stärker ausgeprägt sei als im persönlichen Gespräch. Und so gibt es mittlerweile einige Lösungen auf dem Markt, deren KI in direkten Kontakt mit dem Bewerber tritt und auf Grundlage seiner Sprache sowie Gestik und Mimik ein Persönlichkeitsprofil aufnimmt, das die HR-Abteilung im weiteren Verlauf des Bewerbungsverfahrens ergänzend verwenden kann.

Precire Technologies betreibt eine KI, die sowohl zur Analyse des geschriebenen wie auch gesprochenen Worts eingesetzt werden kann.

Dazu redet der Bewerber telefonisch über einen Zeitraum von 15 Minuten über ein bestimmtes Thema. Der Inhalt spielt hierbei eine untergeordnete Rolle. Die KI zerlegt Sprache nach Aussage des Unternehmens in 110 Mio. Bausteine [10] und analysiert Merkmale wie Sprechtempo, Sprachmelodie, Länge der Sätze und die Verwendungsfrequenz bestimmter Wörter.

Die Informationen werden mit Daten aus Persönlichkeitsstudien abgeglichen, um Aussagen über die Persönlichkeit und Eignung des Bewerbers zu treffen [11]. Zum Aufbau einer Referenzdatenbank hat das Unternehmen 5000 Teilnehmer ein Interview und im Anschluss einen Persönlichkeitstest durchführen lassen. Die Referenzdaten werden für den Vergleich herangezogen und dem Kandidaten ein Wert nach unterschiedlichen Persönlichkeitsmodellen zugewiesen, z. B. nach Big Five [4].

Precire hat einige Kritiker auf den Plan gerufen. Diese hinterfragen einerseits die wissenschaftliche Substanz hinter dem Verfahren. Prof. Dr. Uwe Kanning bemängelt die geringe von der Forschung nachgewiesene Korrelation zwischen Sprache und Persönlichkeit. Wenn dieser Zusammenhang schwach ist, sei es auch kaum möglich, belastbare Informationen über eine Persönlichkeit aus einer Sprachaufnahme abzuleiten.

Hinzu kommen ethische Bedenken. Der Ethikbeirat HR Tech hat „Richtlinien für den verantwortungsvollen Einsatz von Künstlicher Intelligenz und weiteren digitalen Technologien in der Personalarbeit“ entwickelt. Diese verbieten die Erhebung von Daten, die der willentlichen Steuerung der Betroffenen grundsätzlich entzogen sind (Subjektqualität).

Konkret heißt es in den Richtlinien: „Dies können zum Beispiel Stimm- oder Videoanalysen sein [...]. Menschen sind bei Nutzung solcher Verfahren ausschließlich analysiertes Objekt und kein sich selbst wahrnehmendes und handelndes Subjekt“ [12].

Kritiker sehen in der von Precire betriebenen Anwendung eine rote Linie überschritten. Es wird eine Herausforderung sein, die entwickelte Technologie auf eine Weise und unter Umständen einzusetzen, die dem prüfenden Blick eines Ethikrats standhält.

Datenschützer sehen ein weiteres Problem in der Datenerhebung selbst. Daten dürfen gemäß Bundesdatenschutzgesetz nur dann verarbeitet werden, wenn sie für die Entscheidung über die Begründung eines Beschäftigungsverhältnisses erforderlich sind (§ 32 BDSG). Erforderlich in diesem Sinn ist die Erhebung aber nur dann, wenn es keine andere gleichermaßen geeignete Methode gibt, die weniger Daten erfordert. Daher ist zu prüfen, ob ein Assessment Center nicht weniger persönliche Daten benötigt als eine Sprachaufnahme [11].

Trotz dieser Bedenken hat das Verfahren Anhänger, die von seiner Leistungsfähigkeit überzeugt sind und dabei auf Ergebnisse verweisen, die denen anderer eignungsdiagnostischer Verfahren sehr nahe kämen.

3.5 Künstliche Intelligenz im Active Sourcing und das Beispiel von Amazon

Die Wissenschaft hat durch zahllose Studien belegt, dass kaum ein Mensch frei von Vorurteilen ist. Diese häufig unbewussten Vorurteile wirken sich darauf aus, wie wir andere sehen und wie wir Entscheidungen treffen. Der Einstellungsprozess ist davon nicht ausgenommen [9]. Die Wissenschaft spricht von „unconscious bias“. Dieser Begriff hat sich gegenüber der deutschen Übersetzung kognitive Verzerrung weitläufig durchgesetzt.

Im Active Sourcing sucht ein Personaler nach geeigneten Kandidaten und versucht, einen langfristigen Kontakt mit diesen aufzubauen. Die Natur dieses Prozesses macht ihn in besonderem Maß anfällig für menschlichen Bias. Denn auch wenn durch die Stellenbeschreibung klare Kriterien vorgegeben sind, kann sich ein Personaler kaum vollständig von seinen persönlichen Ansichten lösen. Die Kandidatenauswahl wird daher immer in einem bestimmten Umfang „biased“ sein.

Ein Beispiel für einen Bias, gegen den kaum ein Mensch gefeit ist: Arbeitet ein Personaler eine Liste mit mehreren hundert Profilen ab, um hieraus eine Selektion potenzieller Kandidaten vorzunehmen, wird er mit einiger Wahrscheinlichkeit Profile bevorzugen, die sich entweder am Anfang oder am Ende der Liste befinden. Die Wissenschaft spricht hier von „recency bias“. Eine KI wird den ersten Lebenslauf nach exakt den gleichen Kriterien bewerten wie den hundertsten Lebenslauf. Ein Mensch ist dazu aufgrund von natürlichen Fluktuationen seiner Konzentration und Stimmung nur eingeschränkt in der Lage.

Darüber hinaus ist es für einen menschlichen Mitarbeiter kaum möglich, sich nicht von Fotos, Namen und anderen persönlichen Profilinformatoren beeinflussen zu lassen.

Es ist daher naheliegend, dass HR-Abteilungen sich bei Arbeiten dieser Art durch eine Software unterstützen lassen.

Amazon hat sein weiter oben erwähntes KI-Tool entwickelt, um auf automatisierte Weise interessante Kandidatenprofile zu finden und zu klassifizieren [13]. Für die Klassifizierung wurde die KI mithilfe von Lebensläufen früherer Bewerber trainiert. Hier tritt die erste Schwierigkeit auf: Diese Lebensläufe stammen von Personen, die bereits der Meinung sind, dass sie gut zu Amazon passen würden. Es liegt der sogenannte „self-selection bias“ vor: Die Entscheidung der Bewerber zur Bewerbung basiert auf dem, was sie über Amazon gehört oder gelesen haben.

So könnten sie beispielsweise gelesen haben, dass viele Amazon-Mitarbeiter auf Plattformen wie Glassdoor oder Kununu die mangelnde Work-Life-Balance kritisieren. Wer einige dieser vielfältigen Einträge liest und sich trotzdem zu einer Bewerbung entschließt, gehört einer spezifischen Gruppe an: Einer Gruppe von Bewerbern, für die eine unausgewogene Work-Life-Balance kein Ausschlusskriterium darstellt.

Der Datensatz hatte also schon bereits vor jeglicher Weiterbearbeitung eine Färbung und stellte keinen repräsentativen Schnitt über den gesamten Bewerbermarkt dar. Diese scheinbar triviale Feststellung hat außerordentliche praktische Konsequenzen. Denn die Erkenntnisse, die die KI aus diesem Pool ziehen konnte, war somit bereits eingeschränkt.

Insoweit der Anwendungszweck der KI nur darin gelegen hätte, künftige Bewerber zu klassifizieren, wäre diese Einschränkung unproblematisch gewesen. Denn in diesem Fall hätte die KI ja nie die Untermenge der Bewerber mit „self-selection bias“ verlassen müssen.

Das war aber nicht das Ziel der Amazon-KI. Sie sollte auch aktiv potenzielle Kandidaten finden, die sich eben nicht selbst bei Amazon beworben hatten. Somit sollte die KI auf einem Terrain agieren, für das sie gar keine Trainingsdaten hatte. Stellen Sie sich eine Spezialeinheit vor, die jahrelang in der Wüste ausgebildet wurde und dann für einen Einsatz in den Himalaya geschickt wird.

Dieses strukturelle Problem wurde möglicherweise dadurch verschärft, dass die KI trainiert wurde, das vergangene Auswahlverhalten der Amazon Recruiter nachzubilden. Dies kann z. B. dadurch erreicht werden, indem der KI zwei Datensätze vorgelegt werden: Ein Datensatz mit Bewerbern, die zu einem Gespräch eingeladen wurden, und ein Datensatz mit Bewerbern, die nicht eingeladen wurden. Die KI erkennt Muster

in den Datensätzen und kann dann einen neuen bisher nicht klassifizierten Lebenslauf einordnen: Je nach Vektorähnlichkeit wird dem Profil eine bestimmte Klasse verliehen. Da die Entscheidungen bisher aber von Menschen getroffen wurden und die KI nur aus diesen Daten lernt, wird das frühere Selektionsverhalten der Recruiter nur automatisiert und jedweder vorhandene Bias z. B. in Bezug auf Alter, Geschlecht oder Herkunft übernommen.

Das Amazon-Team war sich der Schwäche dieses Ansatzes bewusst und hat sich daher für ein Punktesystem entschieden. Jedem Lebenslauf wurden Punkte auf einer Skala von 1 bis 5 zugewiesen. Somit fällt ein vorhandener Bias weniger ins Gewicht als bei einer reinen Ja-Nein-Entscheidung.

An dieser Stelle wird die Betrachtung aus ethischer Sicht interessant: Die Punktevergabe muss die Unternehmensziele reflektieren, um positiv zu diesen beitragen zu können. Alle Unternehmensziele müssen explizit dargestellt und miteinander vergleichbar gemacht werden.

Nehmen wir zum Beispiel an, eine weibliche Mitarbeiterin würde in einem technischen Team als doppelt so wertvoll angesehen wie ein männlicher Mitarbeiter; oder Mitarbeiter mit einem bestimmten ethnischen Hintergrund wären gemessen an ihren Performance-Reviews statistisch betrachtet weniger wertvoll für das Unternehmen als Mitarbeiter mit anderem Hintergrund.

Diese Sachverhalte würden sich explizit aus dem Software-Code und der zugehörigen Dokumentation ergeben. Je feiner die Abstufung von Bewerbern vorgenommen wird, umso weniger kann man sich hinter Allgemeinplätzen oder der Blackbox der KI verstecken. Der Wert eines Bewerbers für ein Unternehmen würde messbar und transparent gemacht nicht nur aufgrund seiner selbst erworbenen Fähigkeiten, sondern eben auch aufgrund seiner externen Merkmale wie Alter, Geschlecht und Herkunft.

Nicht nur große Unternehmen können sich hier komplexen rechtlichen und ethischen Fragen ausgesetzt sehen, die zu erörtern an dieser Stelle zu weit führen würde.

Der Fall Amazon zeigt, wie anspruchsvoll die Entwicklung einer belastbaren KI zu Selektionszwecken auch für große und erfahrene Teams sein kann. Es wird spannend zu beobachten sein, wie sich KI-Lösungen in diesem Bereich weiterentwickeln werden.

4 Die Akzeptanz von Künstliche-Intelligenz-Lösungen bei Stellensuchenden

KI im Recruiting wird nicht als Revolution sondern als Evolution erfolgen. Auch Skeptiker haben wenig Zweifel daran, dass KI-Lösungen im Lauf der Zeit immer mehr an Bedeutung gewinnen werden. Die Geschwindigkeit, mit der dies erfolgt, wird eng von der Akzeptanz von KI in der Gesellschaft im Allgemeinen und bei Stellensuchenden im Besonderen abhängen.

Erwähnenswert ist in diesem Zusammenhang eine von Dahm und Dregger durchgeführte Studie [4], die die Akzeptanz unterschiedlicher KI-Lösungen bei Bewerbern

untersuchte. Die Studienteilnehmer waren junge Berufstätige Mitte 20, die nebenberuflich studieren und das Bachelorniveau erreicht haben. Sie sind aufgrund ihres geringen Alters und ihres hohen Ausbildungsstands als Repräsentanten des Fachkräftemarkts der Zukunft anzusehen.

Den Teilnehmern wurden drei unterschiedliche Szenarien vorgestellt:

1. Ein Chatbot, der die Fragen von Stellensuchenden auf dem Karriereportal einer Unternehmensseite beantwortet
2. Vorselektion der eingereichten Bewerbungsunterlagen mit einer KI, die das Bewerberprofil mit den Erfordernissen der Stelle abgleicht und ein Scoring vergibt
3. Der Bewerber beantwortet im Rahmen eines 15-minütigen Telefoninterviews Fragen einer KI; diese führt anschließend eine Sprachanalyse durch und erstellt daraus ein Persönlichkeitsprofil, auf deren Basis die Auswahl erfolgt

Die Studienteilnehmer bewerteten diese Szenarien anschließend anhand einer Reihe von Kriterien. Es ist an dieser Stelle erwähnenswert, dass die Studienteilnehmer nicht persönlich mit den KI-Anwendungen interagierten, sondern lediglich ein Video zur besseren Veranschaulichung sahen. Das eigene Nutzererlebnis hat gefehlt. Die Studienteilnehmer mussten sich daher die Interaktion mit der KI vor ihrem eigenen geistigen Auge ausmalen.

Die Studie zeigt, dass die Akzeptanz der Teilnehmer für die KI von vielerlei Faktoren abhing, von denen hier nur einige genannt seien:

- Kontrolle: Inwieweit empfinden die Nutzer, dass sie selbst die Technik kontrollieren, statt von ihr kontrolliert zu werden? Wird die KI zur Unterstützung des Bewerbers und der HR-Abteilung eingesetzt („augmented“ bzw. „assisted intelligence“) oder trifft sie eigene Entscheidungen („autonomous intelligence“)?
- Zeitlicher Verlauf: Wird die KI in den frühen oder späten Stadien des Bewerbungsprozesses eingesetzt?
- Die empfundene Wertschätzung durch das die KI einsetzende Unternehmen
- Vertrauen: Wie sicher und zuverlässig erscheint das Verfahren?
- Verspieltheit: Inwiefern füllt die KI nicht nur eine Aufgabe aus, sondern kann dem Bewerber dabei auch eine „playful experience“ bescheren?

Es überrascht wenig, dass die Mehrheit der Studienteilnehmer eher dann gewillt ist, den Einsatz von KI-Lösungen zu akzeptieren, wenn

- diese den Bewerber bei Bedarf unterstützen, ohne dass dieser seine Kontrolle aufgeben muss („augmented“ bzw. „assisted intelligence“);
- diese zu einem frühen Zeitpunkt des Bewerbungsprozesses eingesetzt werden.

Die Akzeptanz der Teilnehmer für den Einsatz eines unterstützenden Chatbot oder einer KI zur Vorselektion der Lebensläufe war daher noch hoch. Den Einsatz einer KI zur Erstellung eines Persönlichkeitsprofils auf Grundlage einer Sprachanalyse befanden die meisten Teilnehmer hingegen als inakzeptabel.

Neben der empfundenen mangelnden Wertschätzung („Wollen die nicht persönlich mit mir sprechen?“) dürfte der Hauptgrund hier im Kontrollverlust des Bewerbers liegen. Der Bewerber gibt eine Sprachprobe ab und bleibt darüber hinaus gänzlich passiv dem Verdikt der KI unterworfen, ohne die Möglichkeit auf das Ergebnis einzuwirken. Dies erklärt auch, warum der Ethikbeirat HR Tech solche Verfahren ablehnt (vgl. weiter oben).

Insgesamt stimmten die Teilnehmer überwiegend der Aussage zu, dass KI-Lösungen dem Menschen bei einer Vielzahl von Aufgaben unterstützen können. Wichtig ist den Befragten dabei, dass die KI zusätzliche Informationen liefern und das Auswahlverfahren beschleunigen kann. Die finale Entscheidung solle dabei aber immer beim Menschen bleiben.

Sehr viel wird nicht nur von der Aufgabe der KI abhängen, sondern vom konkreten Produktdesign und somit für das Nutzererlebnis. Eine spielerische Note, wie es etwa der US Army bei der Gestaltung von Sergeant Star gelang, kann die Nutzerakzeptanz deutlich erhöhen. Erklärungen zur Funktionsweise und dem Zweck der KI können Transparenz schaffen und so das Vertrauen der Nutzer erhöhen. In diesem Zusammenhang ist auch die Angabe eines menschlichen Ansprechpartners für Rückfragen wirkungsvoll.

5 Fazit

KI, die Büchse der Pandora? Das ist eine Frage, die erst kommende Generationen beantworten können. Fest steht wie auch schon im antiken Mythos: Sobald einmal geöffnet, kann die Büchse nicht mehr geschlossen werden.

KI-Lösungen sind längst Teil der Realität im Recruiting und ihr Einsatz wird in den kommenden Jahren kontinuierlich zunehmen.

Einige Kritiker leiten aus der bloßen Existenz ethischer Bedenken gegen KI-Lösungen ab, dass diese zu viele Gefahren mit sich brächten. Dabei wird verkannt, dass die meisten KI-Befürworter genau diese Diskussionen begrüßen. Überhaupt erst aus einem regen Austausch können Lösungen entstehen, die dem Unternehmer nachhaltig Mehrwert liefern und gleichzeitig ethisch akzeptiert sind. Das gilt in besonderem Maß für den zukunfts kritischen Recruiting-Bereich.

Der richtig dosierte Einsatz von KI wird für jedes Unternehmen anders sein. Hierzu müssen aktuelle Prozesse für die Besetzung einer Stelle auf Schwächen und Potenziale untersucht werden. Je weniger Bewerber ein Unternehmen hat, desto eher wird es KI vorsichtig und ausschließlich unterstützend einsetzen, etwa um im Rahmen von Chatbot-Lösungen schneller auf Bewerberrückfragen reagieren zu können.

Je höher das Bewerbungsvolumen eines Unternehmens ist, desto eher wird es gewillt oder sogar gezwungen sein, einen Schritt weiter zu gehen und eine KI auch in späteren Stadien des Auswahlprozesses etwa zu Screeningzwecken einzusetzen.

Hier ist es wichtig, das richtige Gleichgewicht zu finden. Wer zu optimistisch voranstürmt, kann sich mit schwierigen rechtlichen und ethischen Fragen konfrontiert sehen. Unternehmen, die sich dieser Entwicklung aber ganz verschließen, werden langfristig in Schwierigkeiten kommen.

Am Ende muss KI im Recruitment Teil einer größeren Diskussion über KI in unserer Gesellschaft sein. An dieser Stelle sei die Bertelsmann Stiftung auf ihrem Projekt „Ethik der Algorithmen“ zitiert [14]: *„Nicht das technisch Mögliche, sondern das gesellschaftlich Sinnvolle muss Leitbild sein – damit maschinelle Entscheidungen den Menschen dienen.“*

Literatur

1. Dastin J (2018) Amazon scraps secret AI recruiting tool that showed bias against women, Reuters. <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight-idUSKCN1MK08G>. Zugegriffen: 09. Okt. 2020
2. Weitzel T et al (2019) Social recruiting and active sourcing. https://www.uni-bamberg.de/fileadmin/uni/fakultaeten/wiai_lehrstuehle/isdl/Studien_2019_01_Social_Recruiting_Web.pdf. Zugegriffen: 11. Okt. 2020
3. Mladina A (2019) Der passive Bewerbermarkt: So wichtig ist Direktansprache. <https://www.roberthalf.de/blog/passiver-bewerbermarkt-und-direktansprache>. Zugegriffen: 11. Okt. 2020
4. Hermeier B et al (Hrsg) (2019) Arbeitswelten der Zukunft: Wie die Digitalisierung unsere Arbeitsplätze und Arbeitsweisen verändert. Springer Fachmedien, Wiesbaden, S 249 ff
5. Maass D (2014) Free Sgt. Star: army ignores FOIA request for artificial intelligence records. <https://www.eff.org/de/deeplinks/2014/01/free-sgt-star-army-ignores-foia-request-artificial-intelligence-records>. Zugegriffen: 13. Okt. 2020
6. Maass D (2014) Answers and questions about military, law enforcement, and intelligence agency chatbots. <https://www.eff.org/de/deeplinks/2014/04/answers-questions-about-military-law-enforcement-and-intelligence-agency-chatbots>. Zugegriffen: 13. Okt. 2020
7. Verhoeven T (Hrsg) (2020) Digitalisierung im Recruiting: Wie sich Recruiting durch künstliche Intelligenz, Algorithmen und Bots verändert. Springer Fachmedien, Wiesbaden, S 108
8. Facebook Newsroom (2017) <https://about.fb.com/news/2017/11/messages-matter-exploring-the-evolution-of-conversation/>. Zugegriffen: 17. Okt. 2020
9. Beattie G, Johnson P (2011) Possible unconscious bias in recruitment and promotion and the need to promote equality. Perspective. Taylor & Francis, Abingdon, S 7–13
10. Precire Technologies GmbH (2019) <https://precire.com/blog/2019/10/22/sprachanalyse-mit-precire/>. Zugegriffen: 18. Okt. 2020
11. Bärschneider N (2019) <https://www.humanresourcesmanager.de/news/sprachanalysesoftware-das-recruitingtool-der-zukunft.html>. Zugegriffen: 18. Okt. 2020
12. Ethikbeirat HR Tech (2020), https://www.ethikbeirat-hrtech.de/wp-content/uploads/2020/03/Richtlinien_A1_final.pdf Zugegriffen: 18.10.2020
13. Lauret J (2019) <https://becominghuman.ai/amazons-sexist-ai-recruiting-tool-how-did-it-go-so-wrong-e3d14816d98e>. Zugegriffen: 09. Okt. 2020
14. Bertelsmann Stiftung <https://www.bertelsmann-stiftung.de/de/unsere-projekte/ethik-der-algorithmen/projektbeschreibung>. Zugegriffen: 24. Okt. 2020



Dr. Jakob Sidoruk ist seit 2016 technischer Direktor bei Jobtensor und für die Leitung des KI Teams zuständig. Er studierte Chemie mit Spezialisierung physikalische Chemie in Göttingen und promovierte über quantenmechanisches Schaltverhalten in SrTiO_3 Einkristallen. Sein Tätigkeitsschwerpunkt liegt in der Entwicklung neuer Machine Learning Algorithmen zum verbesserten semantischen Verständnis von Stellenanzeigen im Bereich Wissenschaft, Ingenieurwesen und IT.



Harald Ritter ist Mitgründer von Jobtensor. Er studierte Chemie mit Spezialisierung physikalische Chemie in Göttingen und widmete sich nach seinem Abschluss den Möglichkeiten des digitalen Wandels u. a. im Bereich Human Resources.

Sein Tätigkeitsschwerpunkt liegt in der Suchmaschinenoptimierung mithilfe von Big-Data-Methoden.



Künstliche Intelligenz und Führung: Automatisierung und die Veränderung von Managementaufgaben und -arbeitsweisen

Isabell Claus und Matthias Szupories

1 Künstliche und menschliche Intelligenz in Kombination

Führungskräfte konzentrieren sich sowohl in der Theorie als auch in der Praxis bislang im Wesentlichen auf das Management der menschlichen Intelligenz (MI). Sie versuchen Prozesse, innerbetriebliche Interdependenzen, Umweltbeziehungen und wirtschaftliche Wirkungsweisen zu abstrahieren, transparent zu machen und proaktiv zu beeinflussen. Das Ziel ist branchenübergreifend das Gleiche: Es gilt den Unternehmenserfolg positiv und proaktiv zu beeinflussen, seien es beispielsweise Maximierungsbestrebungen von Umsatz-, Margen- oder Marktanteilszielen.

Die Anforderung an die MI besteht nun darin, alle relevanten Prozesse im Unternehmen und deren Umweltbeziehungen mit Stakeholdern (unter anderem Kunden, Kapitalgeber, Aktionäre, Zulieferer, Öffentlichkeit) wie deren Interdependenzen und Wirkungsgrade gleichermaßen abstrahieren zu können. Hinzu kommt die Schwierigkeit, dass alle Unternehmen versuchen, durch strategische und operative Schachzüge entweder wirtschaftliche oder wettbewerbsrelevante Vorteile zu erlangen (Effizienz und Effektivität). Damit ist zwangsweise jedes Unternehmen in seiner jeweiligen Umwelt und mit seinen Stakeholdern in einem permanenten Veränderungsprozess. Es wird schnell deutlich, dass die Veränderungsgeschwindigkeit einerseits und die Datenflut

I. Claus (✉)
thinkers GmbH, Wien, Österreich
E-Mail: isabell.claus@thinkers.ai

M. Szupories
DEUTZ AG, Köln, Deutschland
E-Mail: matthias.szupories@deutz.com

© Der/die Autor(en), exklusiv lizenziert durch Springer-Verlag GmbH, DE, ein Teil von Springer Nature 2021

341

R. Altenburger und R. Schmidpeter (Hrsg.), *CSR und Künstliche Intelligenz*, Management-Reihe Corporate Social Responsibility,
https://doi.org/10.1007/978-3-662-63223-9_18

aus internen und externen Kommunikationskanälen, Managementsystemen und persönlichen Gesprächen andererseits die MI und Aufnahmemöglichkeit in Breite und Tiefe überfordert. Künstliche Intelligenz (KI) kann hier ansetzen, um Führungskräfte zu unterstützen. Sie soll möglichst einfach einsetzbare Bausteine bieten, die die Komplexität aller Veränderungsinformationen überschaubarer macht und auf ein für den Menschen handhabbares Maß reduziert.

So wird KI dafür genutzt: Im Mittelpunkt steht die Fähigkeit, Datenberge in kürzester Zeit auszuwerten und aufzubereiten. Eine intelligente Reduktion der großen Masse steht im Mittelpunkt. Auf dem Ergebnis bauen dann die Stärken der MI auf: Sie soll aus der klaren und laufend aktuellen Daten- und Analysebasis, die die KI erzeugt hat, standardisierte, wiederkehrende oder je nach Einsatzfeld auch Ad-hoc-Handlungsempfehlungen abstrahieren und forcieren. Im operativen Geschäft soll so der richtige Hebel gewählt werden, der zur Erreichung der Unternehmensziele dient.

In diesem Rahmen ersetzt also KI nicht die MI, sondern hilft ihr, der aktuell für das Gehirn bereits jetzt zu komplexen Umwelt und deren schnelle Weiterentwicklung besser zu folgen und schneller zu agieren und zu reagieren.

Andererseits bietet die MI erst die Basis für die KI: Denn KI ist nicht von sich aus intelligent. Wenn er falsch ausgewählt oder trainiert ist, wird ein Automatismus nicht viel verwertbares Material auswerten und präsentieren. Stattdessen müssen Prozesse (Analysen, Handlungsempfehlungen und Routinen) durch MI definiert werden, die für das Geschäftsfeld sinnvoll und erforderlich erscheinen. Die notwendige Datenqualität muss eruiert, erzeugt oder zugekauft und die laufende Arbeitsweise und Wirksamkeit überprüft und sichergestellt werden.

Kurzum: KI kann Datenmengen besser durchsuchen, verarbeiten und handhabbar machen sowie Denkroutinen vereinfachen und automatisieren. Der Entscheidungsprozess in der strategischen und operativen Unternehmensführung wird aber weiterhin durch Führungskräfte gewählt, durchgesetzt und gegebenenfalls adaptiert werden müssen. Folglich bereitet KI eine wesentlich bessere Analyse- und Empfehlungsbasis für die MI im Vergleich zur aktuellen Situation auf, in der Führungskräfte kaum auf diese Automatisierungsressource zugreifen. Um tatsächliche Wettbewerbsvorteile in einem Markt, einer Branche oder einem Umfeld zu erzielen, ist der Entscheidungsprozess von Individuen maschinell jedoch nicht ersetzbar.

2 Führung mit künstlicher Intelligenz: Warum kein Weg daran vorbeiführt

Die Anforderungen an Führungskräfte werden sich vor dem Hintergrund des Genannten in den nächsten Jahren immer stärker darauf fokussieren, ausgewählte wirtschaftliche Prozesse und Routinen zugweise mittels KI zu automatisieren. Folglich sind die aktuellen Denkprozesse im Management durch (nahezu) ausschließlich MI näher zu betrachten, zu zerlegen und zu abstrahieren, an welchen Stellen und in welchen

Bereichen künstliche Automatismen unterstützen und sogar positiv beeinflussen können. Die Übersetzung in maschinelle Systeme ist dann der zweite Schritt.

Zeit ist kein unerheblicher Faktor in diesem Zusammenhang. Wie erwähnt ist das unternehmerische Ziel im Regelfall die Erzielung von (zukünftiger) Wettbewerbsfähigkeit und Wettbewerbsvorteilen, um das Unternehmen zukunftsfähig zu machen und die Aktivitäten auszubauen. In diesem kompetitiven Rennen entscheidet also nicht zuletzt die Schnelligkeit der Marktbegleiter versus der eigenen. Es sollte also daraufhin gearbeitet werden, eine hohe Wirksamkeit und Verbesserung durch Automatisierung in der Praxis zu erreichen und darüber Erfolgspotenziale zu heben, bevor dies dem Wettbewerb gelingt. Auch in diesem Zusammenhang entscheiden am Ende des Tages auch zukünftig die Fähigkeiten der Führungskraft/-kräfte und des gesamten Teams – nicht allein eine eingesetzte KI – über den Erfolg.

Die Datenbasis, die Tiefe und Breite der Informationen, auf deren Basis Führungskräfte agieren und entscheiden, wird durch Automatisierung besser auf die einzelne Organisation und ihre Führungskraft zugeschnitten. Im Entscheidungsmoment soll sie eine möglichst ideale Informationsbasis für eine höhere Erfolgswahrscheinlichkeit bieten und nicht zuletzt mehr Vertrauen in Entscheidungen, beispielsweise große, strategische Budgetentscheidungen, hervorrufen. Das Erlangen dieser neuen, wesentlich umfassendere Markttransparenz – national, international oder global – ist ohne KI nicht erreichbar, denn personelle Ressourcen sind nicht in diesem Ausmaß leistbar. Der Einsatz von KI bietet also einerseits wesentliche Effektivitätskomponenten für das Unternehmensmanagement, aber auch vollkommen neuartige Effizienzkomponenten, die sich entweder eine Ressourcenersparnis oder einen Zeitvorsprung im Markt darstellen können.

Neben den Faktoren, schneller, weitreichender und situationsspezifischer Führen zu können, wird durch KI die Problemlösungskompetenz verbessert sowie das Erlernen aus bereits Erlebtem besser gespeichert. Automatismen in prosperierenden oder rezessiven Zeiten und Märkten wiederholen sich, KI kann also helfen, Fehlerhäufigkeiten zu reduzieren, oder anders ausgedrückt, ausreichend warnen, Fehler nicht immer zu wiederholen. Durch mehr Transparenz bei vorhandenen Daten und Informationen sollten Krisen und Frühindikatoren ebenso wie Marktchancen besser und früher erkannt werden. Hier entwickelt sich das Feld der KI sehr schnell weiter und liefert bereits Lösungsansätze in der Praxis.

Neben Automatisierungen von wiederkehrenden, verlässlichen bzw. absehbaren Prozessen braucht eine gute Unternehmensführung auch eine sukzessive Weiterentwicklung von in der Automatisierung berücksichtigten Handlungsspielräumen und neu aufkommenden Handlungsmöglichkeiten. Aktuell erfüllen Systeme und KI meist nur hochstandardisierte Aufgaben. Initiativen sind jedoch zahlreich, die Kreativität in den selbstlernenden Prozess einzubauen versuchen. Denn fortgeschrittene Unternehmen und Anbieter sind sich einig: Auf Dauer werden einfache Buchungsrhythmen und Fertigungsrouninen nicht den ausschlaggebenden Wettbewerbsvorteil liefern. Hier KI und MI zu verbinden, um maximale Datenbasis, Erfahrung und Routinen mit Inspiration und

Risikobereitschaft zu kombinieren, wird eine weitere wichtige Entwicklungsstufe von KI ausmachen.

Die Schlussfolgerung daraus ist also, dass sich die Aufgaben und Arbeitsweisen des Unternehmensmanagements auf einem klar erkennbaren Weg zu stärkerer Einbeziehung von Automatisierungsmöglichkeiten befinden, dies neue Managementvorteile bietet und die Wettbewerbslage Führungskräfte unter Umständen sogar zum Agieren in diesem Feld zwingt. Es führt daher kein Weg daran vorbei, sich als Führungskraft mit KI auseinanderzusetzen und seinen individuell richtigen Weg im Rahmen der neuen Möglichkeiten zu finden.

3 Der Idealzustand und die Geschwindigkeit der Weiterentwicklung

Was uns heute nach wie vor hindert, komplexe Denkaufgaben zu automatisieren, ist unser Nichtwissen über die Art und Weise, wie das Gehirn als Ganzes arbeitet um diese Arbeitsweise durch Technologie nachzuahmen. Zudem ist die vollkommene Informationstransparenz ein Ideal der Ökonomie, das wir wohl nie ganz erreichen werden. Risikofreie Entscheidungen sind damit in weiter Ferne oder unerreichbar. Der Kern des strategischen Wirkens von MI enthält also auch die Möglichkeit, scheitern zu können oder falsch zu liegen. Dennoch können wir Daten besser, schneller, gezielter auswerten und Handlungsoptionen digital aufzeigen. Wie viel dann für die Entscheidungsfindung und -umsetzung investiert wird, liegt in absehbarer Zeit aber weiterhin in den Händen der Führungskräfte und damit der MI.

Stellt man sich den Idealzustand vor, in dem wir wüssten, wie unser Gehirn als Ganzes arbeitet, bräuchten wir wahrscheinlich nicht so lange, bis wir Maschinen ähnliche Abläufe beibringen. De facto bleibt uns aber genau das verborgen. In unzähligen Studien und Untersuchungen werden einzelne Charakteristika, Fähigkeiten und Prozesse mithilfe verschiedener Ansätze, Methoden und in mehreren Disziplinen erforscht. So kommen wir Stück für Stück zu neuen Erkenntnissen. Gleichzeitig fehlt aber der gesamtheitliche Überblick über alles, was die Menschheit heute über das Gehirn bereits an Wissen generiert hat und wie diese Wissenspuzzlestücke zusammenpassen könnten. KI und im Speziellen eine ihrer besonderen Fähigkeiten bringen uns auch in dieser Problemstellung einen Schritt weiter, der uns unter Umständen beachtlich nach vorn katapultieren könnte: Die Verarbeitung und Auswertung massenhafter Daten mittels mathematischer und statistischer Methoden. Je weiter die massenhafte Datenverarbeitung zum Beispiel im Bereich der Erforschung des Gehirns mit darauf aufbauender MI verknüpft wird, desto höher ist die Wahrscheinlichkeit, zu durchblicken, was alles in unserem Kopf passiert und was Intelligenz tatsächlich ausmacht, um sie künstlich zu reproduzieren. Hier zeigt sich das Potenzial der Zusammenarbeit von MI und KI: Massiver Fortschritt.

Zum Status quo müssen wir jedoch mit dem Wissen leben, das wir haben, es weiterentwickeln und im geschäftlichen Umfeld bestmöglich in Erfolgsfaktoren verwandeln. Und in dieser Momentaufnahme ist der Drang, auch Aufgaben mit Intelligenz-anforderung zu automatisieren, bei Führungskräften unterschiedlich hoch.

Zu den Faktoren, die den Automatisierungswille und -fortschritt beeinflussen, zählen unter anderem

- der Wettbewerbsdruck;
- der vorherrschende Effizienzdruck;
- der Zugang zu Wissen über Lösungen, ihren Potenziale und Funktionsweisen;
- die vorhandenen Ressourcen für das Einkaufen und Experimentieren mit relativ jungen Technologien aber auch
- Berührungs- oder Veränderungsängste von Führungskräften oder MitarbeiterInnen sowie
- der Zeitdruck in unternehmerischen Entscheidungen und
- die Taktung an relevanten Geschehnissen.

Nicht zuletzt zählt der „tone from the top“ bzw. das „enablement“ der Belegschaft.

Sind diese Faktoren entsprechend hoch, ist zwar der am Anfang des Abschn. 2 beschriebene Idealzustand nicht erreichbar, aber es findet eine wesentliche Weiterentwicklung statt.

4 Führen bedeutet auch umsetzungsstarkes Agieren

Beschäftigt sich nun eine Führungskraft mit dem Einsatz von KI, ist diese Arbeit und ihr Fortschritt in drei grundsätzliche Schritte einteilbar, wobei sich diese Beschäftigungsprozesse laufend wiederholen:

1. Das Erkennen von (heutigen und zukünftigen) Herausforderungen, Effektivitäts- und Effizienzpotenzialen in Unternehmen und die Suche nach Lösungen für deren Systematisierung, Digitalisierung und Automatisierung durch KI.
2. Die Einführung einer zentralen KI-Lösung mit nachhaltiger Auswirkung auf die Arbeitsgestaltung der MitarbeiterInnen und den Ablauf von Geschäftsprozessen.
3. Die Etablierung und Weiterentwicklung der MitarbeiterInnen und der Organisation mit fortschreitender Nutzung von KI im Unternehmen.

Zusammenführend geht es im letzten Schritt um die breite Institutionalisierung und strategische Umstellung der Arbeitsweisen und Prozesse in der Gesamtorganisation unter Berücksichtigung des Umsetzungstempos und der Werte der Organisation und ihrer Stakeholder.

Wie können diese Schritte nun in der Praxis durch KI positiv beeinflusst werden?

4.1 Potenziale der künstlichen Intelligenz erkennen und passende Lösungen finden

Der Einsatz von KI unterscheidet sich hinsichtlich des Ziels nicht vom Einsatz von MI: Schlussendlich geht es um die Wettbewerbsfähigkeit und -vorteile. Analysen sollen durchgeführt und Stellhebel bzw. Handlungsoptionen aufgezeigt werden, damit unter Berücksichtigung unterschiedlicher Szenarien die jeweils beste Option für ein Team, eine Abteilung und schlussendlich das Gesamtunternehmen gewählt, umgesetzt und verfolgt wird.

Der Aufbau von Intelligenz geht also auf die Grundgene der betriebswirtschaftlichen Theorie seit den 1990er-Jahren zurück, indem das Bewusstsein und Bestreben reifte, dass Unternehmen nicht per Zufall erfolgreich sind, sondern ihren wirtschaftlichen Erfolg und ihre Abhängigkeit in ihrer Umwelt, also den ökologischen, gesellschaftlichen, ökonomischen Rahmenbedingungen, aktiv beeinflussen können.

KI soll also Teilziele und später ein möglichst vergleichbares Gesamtziel wie die mittels MI erzielten Ergebnisse erreichen, dies aber unter stringenter Berücksichtigung deutlich größerer Kombinationsmöglichkeiten, einer größeren Breite und Tiefe von Daten, mit nahezu unendlichen Wiederholungsroutinen und im Idealfall der Abdeckung wesentlicher Geschäftsprozesse in (nahezu) Echtzeit.

Dies kann KI aber nicht ohne MI als notwendige Basis: KI lernt von MI – im Regelfall laufend, nicht einmalig. Damit muss MI die Geschäftsprozesse und Systematiken eindeutig und bestmöglich beschreiben und erfolgsversprechende Anwendungen selektieren können. Erst wenn Geschäftsprozesse und Systematiken optimiert, standardisiert und systematisiert sind, können diese innerhalb von KI-Routinen belastbar ausgestaltet werden.

Die Grundlage für eine Führungskraft ist also nicht nur ein tiefes strategisches und operatives Wissen über die Systematik des eigenen Geschäftsfelds, sondern auch ein technisches Verständnis oder alternativ die Abstraktionsfähigkeit, Vorstellungskraft und Fantasie, sich Technologie zunutze machen zu können und sich dem Wissen und den Fähigkeiten von Technologieexperten bedienen, Aufgaben und Ziele ausreichend beschreiben und das Geschäftsfeld entsprechend skizzieren und systematisieren zu können, um Prozesse oder Analysen erfolgreich in intelligente Systeme umzusetzen. Erst dann kann KI diese Systematiken in Systeme, Tools, Programme, Routinen und Zeit mit enormen Vorteilen gegenüber MI umsetzen. Anders ausgedrückt: KI kann der Beschleuniger werden, den Kern strategischen Denkens und Handelns in die Praxis umzusetzen, unabhängig ob im lokalen oder globalen Kontext.

Besonders der globale Kontext gibt der KI aber noch einen zusätzlichen Schub. So werden in Asien, Amerika und Europa unterschiedliche Programme, Sprachen, Systeme und Inhalte entwickelt und zugelassen. Hier die Fülle an Daten abzugleichen, zuzuordnen und Trends zu identifizieren, überfordert das Individuum im Mengenaufwand, in der Informationssuche und Lösungsgeschwindigkeit. Hier kann KI enorme Zeit- und

Kostenvorteile schaffen, die im Kampf um Effizienz und Effektivität nicht substituierbar sind.

Wie jedoch ersichtlich wird, ist KI nicht immer eine fertige Software, die heruntergeladen, installiert und sofort nutzbar ist. Auch wenn Convenience eine zentrale Anforderung ist, bedarf es heute meist noch einer kontinuierlichen Beschäftigung mit KI-Anwendungen und -Potenzialen. Diesbezüglich unterscheidet sich der Grundsatz der Anforderung an die Führungskraft nicht wesentlich von der, die die Weiterentwicklung eines Teams betrifft: Potenziale weiterentwickeln und das Zusammenspiel von Menschen und Technologie orchestrieren und perfektionieren.

Wie in anderen Bereichen bietet die Vielzahl an im Markt verfügbaren KI-Lösungen dabei einerseits hervorragende Auswahl- und Vergleichsmöglichkeiten für den Technologieteil. Andererseits fordert sie von einer Führungskraft aber auch laufende Aufmerksamkeit und stetiges Lernen, um die richtige Auswahl für ein System und dessen Bausteine zu treffen. Nicht wesentlich unterschiedlich zur ständigen Weiterentwicklung des eigenen Teams, braucht es den Fokus auf die KI-Bedürfnisse und ihre Weiterentwicklungspotenziale zur vollen Entfaltung und dem größtmöglichen Return on Investment (ROI) für eine Organisation.

4.2 Erfolgsfaktoren für die Einführung von Künstliche-Intelligenz-Systemen

Ist die Auswahl getroffen, folgt im nächsten Schritt die Implementierung. Abgesehen von der technischen Umsetzung, bedeutet eine umfassende KI-Einführung das Potenzial – und auch das Ziel –, spürbare organisatorische Veränderungen herbeizuführen. Während dies für die Gesamtorganisation zukunftsweisend sein wird, kann es für einzelne MitarbeiterInnen oder ganze Teams starke Umwälzungen – nicht immer im positiven Sinn – bedeuten. Einbeziehung, Kommunikation, Weiterbildung und aktives Change Management aus der Feder der Führungskraft sind also notwendig, um eine KI-Einführung zum Erfolg zu bringen. Denn: Akzeptanz durch die MitarbeiterInnen ist ein wichtiger Erfolgsfaktor für eine KI-Einführung: Ebenso wie es zwischen MitarbeiterInnen zu Dissonanz kommen kann, die das Vorankommen des Teams hindert, kann auch eine Ablehnung oder Berührungsängste vor KI-Systemen Erfolg reduzieren oder im schlimmsten Fall gänzlich gefährden.

Nicht nur positive Resonanz seitens der MitarbeiterInnen ist zu beachten. Wichtig ist auch die eigene Einstellung der Führungskraft hinsichtlich des KI-Einbezugs. Sie bestimmt oftmals die Geschwindigkeit der Ergebniserzielung und die Unterstützung der MitarbeiterInnen: Authentischer Umgang und der Wille zur Förderung des Fortschritts durch die Führungskraft setzt die notwendigen Ressourcen und Energien frei, um KI-Anwendungen erfolgreich zu etablieren. Zusätzlich wird es immer eine negative Resonanz im Umgang mit KI geben, denn dort wo Informationssammelungs-, Analyse- und Entscheidungsherleitungen optimiert und automatisiert werden, bedarf es weniger

manueller Arbeit. Es geht also mit KI oftmals eine Automatisierung von betriebswirtschaftlichen Prozessen einher, die ähnlich wie bei der Automatisierung in der Produktion das Potenzial trägt, Arbeitsplätze einsparen zu können. Für die Führungskraft bedeutet das ein Spannungsfeld, einerseits Kosten für Automatisierung zu planen, sie unter Umständen gleichermaßen oder darüber hinaus durch Personalkosten einzusparen und dennoch den involvierten Mitarbeitern die Angst vor KI zu nehmen und das Erfolgspotenzial als Wachstumsfeld zu eröffnen.

Damit hat die Projektierung, Einführung und Umsetzung von KI eine ganz menschliche Herausforderung und bedarf empathischer, starker und angstbefreiter Neugierde und Führung der Mitarbeiter in eine spannende, schnelle und wissende Welt, unabhängig von einschneidenden Change-Management-Prozessen, die entweder das Arbeiten als solches oder gar den Einzelnen empfindlich treffen könnten.

4.3 Institutionalisierung und gesamtheitliche Umstellung der Organisation

KI löst den Einsatz von MI in absehbarer Zeit keineswegs ab. Vielmehr gilt es, die Arbeitsverteilung zwischen MI und KI regelmäßig zu hinterfragen, aufzuarbeiten, neue Systematiken und Kombinationen zu finden, um daraus Wettbewerbsvorteile zu generieren. Dieser Dauerlauf ist eine anspruchsvolle Anforderung an Führungskräfte.

KI-Anwendungen als reines Softwaretool zu verstehen, untergräbt oftmals wohl ihr Potenzial. Auch wenn der Intelligenzaspekt bisher in mathematischen Formeln und Methoden besteht, so können doch Teile, für die wir heute MI einsetzen, vor allem repetitive und zeitgleich nicht hochstandardisierte Aufgaben, automatisiert werden – ein Novum im Vergleich zu herkömmlicher Softwareanwendung. Das heißt auch, dass MI entweder auf den Arbeitsergebnissen von KI aufsetzt, Teile davon ersetzt wird oder durch KI gänzlich neue Möglichkeiten für die MI entstehen.

Die Anforderung an Führungskräfte besteht also darin, Geschäfts- und Arbeitsprozesse tatsächlich auf ein neues Niveau zu heben, statt marginal oder gar nicht anzupassen. Wenn also nur die Datenbreite, Tiefe und Zeitfaktor der Wissensbeschaffung optimiert wird, aber folgende Entscheidungs- und Umsetzungsprozesse nicht berührt werden, schöpft KI wenig ihres eigentlichen Potenzials aus bzw. erzielt wenig tatsächliche Weiterentwicklung der Organisation. Es bedarf also weiterhin des Wissensdursts und des Umsetzungswillens, mit dem vorhandenen Wissen auch nachfolgende Prozesse positiv zu beeinflussen, einzusparen oder weiterzuentwickeln.

5 Case Study – künstliche Intelligenz im Einsatz bei der laufenden Unternehmensumfeldanalyse

Im operativen Management lösen intelligente Dashboards zunehmend manuelle Reportings, Analysen und Bewertungen ab. Der Vorteil ist unter anderem, dass Daten um Umsatz, Marktanteil, Marktgröße, Produkt- und Kundenmix und Rendite mit allen Detailstammbäumen abgebildet, in Echtzeit und jederzeit aggregier- und skalierbar und diese zusätzlich mit Vorhersagen für Zukunftsentwicklungen versehen werden können. Vorbei sind idealerweise die Zeiten, in denen in PDF- oder Excel-Formate Umsätze ohne Details von zugrundeliegenden Kunden, Produkten oder Dienstleistungen angezeigt werden. Erst verschiedene Ebenen ermöglichen das vollständige Analysieren der Datenbasis, um dann erfolgsversprechende Interpretationen und Handlungen darzubieten und nicht im Dunklen zu stochern.

Wichtig ist hierbei, neben der klassischen Inhouse-Reporting-Sicht, dass auch externe Umfeldfaktoren erfolgsentscheidend sind. Denn kein Unternehmen agiert in einem Vakuum und keine Organisation agiert im geschlossenen Raum, sondern sieht sich einer Vielzahl weltweit agierender Wettbewerber, Substituten von neu eintretenden Marktbegleitern oder schlichtweg sich verändernden Kundenverhaltensweisen konfrontiert. Mangelnde Weitsicht, Datenbasis oder fehlender Reaktionsrahmen können hier verheerend sein.

Es ist entscheidend, sich den ändernden Kundenanforderungen und Lieferantenumwelten anzupassen, diese vorwegzunehmen oder gar positiv zu stimulieren. Ein ideales Feld für KI, Netzwerke zu bilden und die bislang heute eher singulär agierenden Systeme und Daten zu verbinden; über unternehmensinterne Systeme, branchenweiten Buchungsstandards bis hin zu sozialen Netzwerken und sämtlichen Webseiten weltweit.

Der Begriff „connect“ macht beispielsweise seit einigen Jahren bereits deutlich, wie sich Geschäftsfelder mit etwas Fantasie entwickeln lassen: Ob CarConnect, was Advanced Service indiziert, vor dem Platzen der Reifen frühzeitig warnt oder auch SOS-Routinen im Unfall abbildet; oder der Kühlschrank, der über fehlende Milch und Eier die Einkaufsliste steuert, die sonst Zeit, Aufwand und Muße gekostet hätte oder schlichtweg für den Anwender bei Vergessen Verzicht bewirkt hätte; und schlussendlich auch die Waschmaschine, die sich morgens beladen und bei der Anfahrt aus der Ferne aktivieren lässt. Diese Felder sind Beispiele für Routinen, dessen Automatisierung das tägliche Leben einfacher und angenehmer gestalten. Diese Beispiele können durch zahlreiche Routinen in Unternehmen ergänzt werden – unter anderem Recherchetätigkeiten, Abholservices oder sich wiederholende Kommunikationsmaßnahmen.

Man sieht anhand der Beispiele nicht nur, wie zahlreich und vielfältig Aufgaben mit Wiederholungscharakter und Zeitaufwand sind, sondern auch, wie zugeschnittene Datenbasen mit zielorientiertem Denken auch schnell zu neuen Services führen können, die merklich ein Produkt, Unternehmen und Erfolg beeinflussen.

Neben diesen Daten, die gegebenenfalls zu Features werden können, sind für Unternehmen beispielsweise auch volkswirtschaftliche oder gesellschaftliche Entwicklungen relevant. Es gibt unzählige informative Warenkörbe, Barometer und Indizes. Aber welche

davon sind relevant, um wirtschaftliche Entwicklungen zu antizipieren? Wie schaffe ich eine generelle Erkennung oder eine Früherkennung dieser relevanten Faktoren auf globaler Basis? Auch etablieren sich in der Ökonomie über die Zeit neue gesellschaftliche Faktoren oder Verhaltensweisen, die Nutzergruppen in ihrer Vielzahl durch Faktoren homogenisieren lassen, seien es Altersstrukturen, Verhaltensweisen Mann/Frau, Lebensphasen oder Gehaltsstufen.

Wie lassen sich derart komplexe, zahlreiche und vielfältige Umfeldfaktoren ermitteln und managen? Personelle Ressourcen sind in diesem Umfang nicht leistbar. Die herkömmlichen Ansätze, beispielsweise die der On- oder Offline-Zielgruppenbefragungen sind aufwendig und führen dennoch zu mäßig zufriedenstellenden Ergebnissen. Die Vielzahl an Informationen durch Auskunfteien, Regulierung oder Meldepflichten schafft eine sehr punktuelle und vereinzelte Transparenz, die nur wenn sie ausreichend gebündelt und in hoher Zahl wiederholt wird, Transparenz und Einblick in Konsumverhalten, Nutzerstrukturen und deren laufende Veränderungen bringt. Auch wenn hier sämtliche ethische Fragen des Datenschutzes und weitere Regularien berücksichtigt werden müssen, kann dieses Spektrum weitreichendere und vor allem wesentlich belastbarere Datenbasen liefern, als es Fragebögen und Einkaufsstraßenumfragen heute abbilden können.

Für Unternehmen und ihre Führungskräfte wird die Suche nach Wissen und Daten und die Erlangung von Erkenntnissen aus ihnen immer komplexer, je breiter das Portfolio, die Kundenkreise oder die geografische Ausbreitung ist. KI ist hingegen darauf ausgelegt, große Datenmassen zu verarbeiten und einzubeziehen, und so ist es für sie irrelevant, ob ein lokales, regionales oder internationales Unternehmensumfeld analysiert werden soll. Die Informationsfülle und die Schnelligkeit der Veränderungen sind eher ein Vor- als ein Nachteil, denn sie führen dazu, dass Systeme aus einer hohen Datenzahl noch mehr und immer präziser lernen.

Während heute noch Einzelerhebungen als Basis für statistische Trends dienen oder manuelle Webrecherchen zur Erfassung von Themengebieten zweckdienlich erscheinen, kann KI in vielen Fällen entscheidende und oftmals sogar öffentlich zugängliche Informationen hundertfach auswerten und aggregieren. Beispielhaft sei hier auf Ankündigungen, Pressemitteilungen oder anderen Beiträgen und Veröffentlichungen von Wettbewerbern oder (potenziellen) Kundenunternehmen hingewiesen. KI führt unter anderem dazu, dass Führungskräfte wesentlich schneller und besser durch ein Substitut eines Kunden oder ein Wettbewerberangebot informiert sind, als es sich durch normales Hörensagen übertragen würde. Heute nehmen hingegen in den überwiegenden Fällen weder Führungskräfte noch MitarbeiterInnen Notiz von vielen eigentlich relevanten Informationen und entscheiden Investitionen, Budgets und Strategien vor dem Hintergrund einer mangelnden Daten- und somit Wissensgrundlage. Die Erfolgswahrscheinlichkeit dieser Investitionen und Vorhaben ist zu diskutieren, enthält sie doch einen durchaus beachtlichen Anteil an Zufalls- und Unsicherheitskomponenten. KI kann hier also nicht nur schneller sein, sondern das Augenmerk deutlich erhöhen, um Fehlentscheidungen vorzubeugen oder zu vermeiden.

In diesem Anwendungsfall leisten die Fähigkeiten von KI einen signifikanten Wertbeitrag, der durch menschliche Arbeit nicht erreichbar wäre. KI durchforstet massen-

haft Daten, prüft sie auf Signifikanz für das Geschäftsfeld, die Aufgabenstellung oder die Arbeit des Teams und des Unternehmens, trennt relevantes von irrelevantem Datenmaterial, verarbeitet und bereitet relevantes Wissen für Führungskräfte und ihre Teams auf. Das Ergebnis ist ein neues Transparenzniveau hinsichtlich sämtlicher relevanter Ereignisse und Vorgänge im Umfeld des Unternehmens und damit eine spürbar bessere Datengrundlage für Entscheidungen und das laufende Unternehmensmanagement. Zudem ermöglicht es signifikante Zeitersparnis hinsichtlich repetitiver Aufgaben wie der Informationssuche. Studien haben gezeigt, dass Büroangestellte im Schnitt zwei Stunden täglich nach Informationen suchen (McKinsey Global Institute, 2012). Das bedeutet, dass ein Mitarbeiter einen kompletten Tag seiner Arbeitswoche mit dem Suchen verbringt. Diese immense Zeitinvestition ist an sich jedoch nicht wertschaffend. Erst gefundene relevante Information, die in weiterer Folge durch MI analysiert und zu einer Basis für Handlungen wird, ist wertschaffend für eine Organisation.

Optimalerweise übernimmt daher KI die repetitive Suche und liefert inhaltlich sehr gut vorqualifizierte Suchergebnisse. MitarbeiterInnen nutzen dann ihre Arbeitszeit, um die Informationen auszuwerten und entsprechend datenbasiert zu handeln. Diesen Ansatz verfolgt thinkers.ai für Unternehmen und öffentliche Institutionen hinsichtlich der kontinuierlichen Umfeldanalysen auf der Basis von Daten aus dem Web. Er ermöglicht eine neue Dimension des datenbasierten Unternehmensmanagements. Die aufwendige Arbeit des Suchens wird durch KI auf ein Minimum reduziert; MitarbeiterInnen arbeiten mit den Suchergebnissen und darauf aufbauenden Analysen und Unternehmen erzielen Wettbewerbsvorteile, indem sie schneller und aufgrund einer qualitativ besonders hochwertigen Datenbasis hinsichtlich ihrer Branche und sämtlichen geschäftsrelevanten Fragen entscheiden, investieren und planen können. KI löst hier ein branchenübergreifendes Problem: Die massive Flut an öffentlich zugänglichen Daten und Informationen im Web, die im Sekundentakt wächst und wo sich Neuigkeiten überschlagen, wird durch KI effizient gesammelt, gefiltert und für die MI bestmöglich aufbereitet.

Die Anforderungen an die Führungskraft liegen folglich immer entfernter vom laufenden Management repetitiver, nicht direkt wertschaffender Aufgaben eines Teams. Sie geht hin zu Aufgaben, die analytischer Stärke, Kompetenz und Neugier bedürfen. Zudem bestehen sukzessive höhere Anforderungen an die kognitiven Fähigkeiten für ein umfangreiches Verständnis für Unternehmenszusammenhänge und Systemumweltfaktoren. Diese müssen nicht nur bei der Führungskraft selbst vorhanden und gestärkt werden, sondern ebenso bei allen MitarbeiterInnen, die mit einem System wie thinkers.ai arbeiten sollen. So erfüllt ein derartiges System seinen Zweck, eine intelligente Wissensquelle und Basis für nachhaltig erfolgreiches und zeitgleich effizienzsteigerndes Managen zu sein. Es geht also folglich um die immer weiter fortschreitende Vernetzung von Unternehmung, Mensch und IT in der sich weiterentwickelnden Wissensgesellschaft bis hin zum Redesign von Produkten und Dienstleistungen (Connect-X) als Reaktion auf erkannte Trends.

Vor diesem Hintergrund ist ein Grundverständnis, von dem was KI und IT generell leisten können oder ein Abstraktionsvermögen dessen, sehr hilfreich. Systeme wie das hier vor-

gestellte sind jedoch keine IT-Systeme für Spezialisten: Sie sind für Anwender konzipiert und entsprechend ohne tiefgreifendes IT-Verständnis oder -Ausbildung nutzbar. Die Anforderung an eine Führungskraft ist es also explizit nicht, zukünftig nur mehr IT-Spezialisten einzustellen und aufzubauen. Vielmehr steht ein fachliches Verständnis des Geschäftsfelds und Umfelds eines Unternehmens im Mittelpunkt – die Fähigkeit, die KI unbedingt benötigt, um Ergebnisse zu erzielen, die in Wettbewerbsvorteile umgewandelt werden.

6 Fazit

KI eröffnet Führungskräften neue Möglichkeiten, stellt gleichzeitig aber auch Anforderungen an sie. Faktoren aus dem internen und externen Umfeld des Unternehmens bestimmen, wie schnell sich eine Organisation umstellen muss oder sollte, um zukunftsfähig zu bleiben oder Wettbewerbsvorteile auszubauen. Ein überlegtes und strukturiertes Vorgehen der Führungskraft mit dem Anspruch an eine nachhaltige Wirkung der gesetzten Automatisierungsschritte und ebenso der Beschäftigung mit den sozialen Faktoren hinsichtlich des Teams oder der Belegschaft wird empfohlen.

Literatur

McKinsey Global Institute (2012) The Social Economy – Unlocking Value and Productivity Through Social Technologies, S. 47

Dr. Isabell Claus ist Geschäftsführerin und Mitgründerin von thinkers.ai, Anbieter von künstlicher-Intelligenz(KI)-basierter Suchmaschinentechnologie für Unternehmen. Als Serial Entrepreneur war sie vorab bereits im Gründungsteam eines Cybersecurity-Unternehmens, das fünf Jahre in Folge zu den Top100 der am schnellsten wachsenden Unternehmen in der EMEA-Region gehörte. Im Jahr 2020 wurde sie in Österreich als „Unternehmerin des Jahres“ ausgezeichnet. Sie studierte Wirtschaftswissenschaften (Wirtschaft & Recht) und Internationale Betriebswirtschaft an der Wirtschaftsuniversität Wien, promovierte dort und absolvierte mehrere Auslandsaufenthalte an der Harvard University, London School of Economics, Singapore Management University und Dubai University College.

Dr. Matthias Szupories ist seit Jahren im Automotive für Marken wie Peugeot, Sixt, MAN, Volkswagen Financial Services und zuletzt bei der DEUTZ in Fach- und Führungspositionen. Aktuell trägt er als Bereichsleiter Zentralvertrieb und Marketing sowie in Personalunion als Regionalleiter der zweitgrößten Vertriebsregion Verantwortung, die Kundenzufriedenheit zu steigern, neue Geschäftsmodelle aufzubauen und darüber den Umsatz und EBIT-Anteil zu steigern. Zudem begleitet er mehrere Aufsichts- und Verwaltungsratspositionen. Als Verfechter der dualen Ausbildung hat er sein Diplom berufsbegleitend an der FHDW in Bergisch Gladbach absolviert und über Aufbaukurse später in Wien und Bratislava an der Paneuropäischen Universität im Bereich Industrieökonomie promoviert. Seit 2013 arbeitet er als Dozent an der FHDW und dem Automotive Center von Prof. Stefan Bratzel und als Gastdozent an weiteren Universitäten.

Künstliche Intelligenz und die Zukunft von Arbeit

Georg von Richthofen, Ali Aslan Gümüşay und Hendrik Send

1 Einleitung

Unternehmen setzen in vielfältiger Weise in immer mehr Bereichen Anwendungen der künstlichen Intelligenz (KI) ein. Eine Reihe von Ökonom*innen gehen davon aus, dass der Einsatz von KI-basierten Verfahren und Anwendungen, in Kombination mit zunehmenden Rechenleistungen und steigender Verfügbarkeit von Daten, die Arbeitswelt grundlegend verändern können (Acemoglu und Restrepo 2018; Brynjolfsson und McAfee 2014; Huang et al. 2019). Auch Organisationsforscher*innen beschäftigen sich zunehmend mit der Frage, wie der Einsatz von KI Organisationen und die dort verrichtete Arbeit verändern kann – bisher jedoch primär in Form von konzeptionellen Beiträgen (Bailey et al. 2019; Faraj et al. 2018; Raisch und Krakowski, 2020; von Krogh 2018). Es konkurrieren dabei Ansätze, die primär eine Aufwertung von Arbeit vermuten (Rai et al. 2019) und solche, die vor einem Wegfall von Arbeit oder Aufgaben warnen (Arntz et al. 2017). Allerdings fehlen mitunter qualitative, empirische Daten, um die Auswirkungen konkret zu erfassen und zu analysieren. Dementsprechend groß ist der Bedarf an Studien, die den Einsatz von KI in Organisationen empirisch untersuchen.

G. von Richthofen (✉) · A. A. Gümüşay · H. Send
Alexander von Humboldt Institut für Internet und Gesellschaft,
Hochschule für Technik und Wirtschaft (HTW) Berlin., Berlin, Deutschland
E-Mail: georg.v.richthofen@hiig.de

A. A. Gümüşay
E-Mail: ali.guemuesay@hiig.de

H. Send
E-Mail: send@hiig.de

KI ist zunächst ein Feld der Informatik, das sich mit der Entwicklung von Systemen beschäftigt, die Aufgaben ausführen, die gewöhnlich menschliche Intelligenz erfordern (Pesapane et al. 2018), d. h. Aufgaben wie Lernen, Planen und Problemlösen (De Bruyn et al. 2020). So beschäftigt sich das maschinelle Lernen, ein wesentlicher Bereich der KI-Forschung, mit Ansätzen, die es Computer ermöglichen, selbstständig von Daten zu lernen, ohne explizit dafür programmiert zu sein (Pesapane et al. 2018). In absehbarer Zeit verfügbare KI-Anwendungen sollten dabei präziser als schwache KI („weak AI“) bezeichnet werden, denn sie sind nur in der Lage, Entscheidungen für abgegrenzte, strukturierte Probleme zu treffen (Shrestha et al. 2019). Da die Bedeutung von KI weit über das Feld der Informatik hinausgeht, muss das Zusammenwirken von Technologie und menschlichem Verhalten stärker betrachtet werden.

Ziel dieses Kapitels ist es daher, anhand von konkreten Anwendungsfällen zu untersuchen, welche Anzeichen für Aufwertung oder Wegfall von Arbeit wir jetzt schon beim Einsatz von KI feststellen können. Dazu haben wir Interviews mit Beschäftigten aus 19 unterschiedlichen Organisationen geführt, die KI entweder als Anwender*innen nutzen oder KI-basierte Lösungen anbieten. Unsere Analyse der Interviews ergibt, dass der Einsatz von KI vier Typen von Auswirkungen auf die Arbeit haben kann. Zunächst kann der Einsatz von KI menschliche Arbeit ersetzen (Ersatz) oder Mitarbeiter*innen bei bestimmten Tätigkeiten unterstützen und sie dadurch entlasten (Entlastung). Darüber hinaus kann der Einsatz von KI den Handlungsspielraum von Menschen einschränken (Einschränkung). Zudem zeigen wir, dass der Einsatz von KI auch zu gänzlich neuen Formen von Arbeit führen kann, die jedoch direkt von Maschinen übernommen werden (Entstehung).

Das Kapitel ist wie folgt aufgebaut: Zunächst geben wir einen kurzen Überblick über die KI-Literatur aus der Organisations- und Managementforschung. Anschließend stellen wir unsere methodische Vorgehensweise und die Datengrundlage des Kapitels dar und präsentieren Vignetten von Unternehmen, um die unterschiedlichen Auswirkungen auf Arbeit zu veranschaulichen. Abschließend diskutieren wir die Implikationen unserer Ergebnisse für menschliche Arbeit, Organisationen und Gesellschaft.

2 Theoretischer Rahmen

2.1 Künstliche Intelligenz und Arbeit

Agrawal et al. (2018) sehen in KI eine Basistechnologie („general purpose technology“), die weitreichende Verwendung in praktisch allen Gesellschafts- und Wirtschaftsbereichen finden wird, wenn in der nächsten Zeit zunehmend komplementäre Innovationen ihren Einsatz unterstützen. Dabei haben in den letzten Jahren Menge, Qualität und Vielfalt an Daten, die Unternehmen zur Verfügung stehen, stark zugenommen. Gleichzeitig stiegen die Rechenleistungen und Speicherkapazitäten und damit die Möglichkeiten der Datenverarbeitung.

Dennoch ist der Einsatz von KI-Anwendungen aktuell auf konkrete Arbeitsaufgaben eingeschränkt. KI-Anwendungen sind häufig gut geeignet für die Verarbeitung von großen Datenmengen im Kontext sich wiederholender, klar abgegrenzter Tätigkeiten, also Situationen, in denen Entscheidungen auf kodifizierbaren, speicherbaren und breit verfügbaren Daten beruhen. Viele Probleme der realen Welt im Unternehmenskontext betreffen jedoch Situationen, in denen keine historischen Daten verfügbar sind, oder Intuition, Wahrnehmung und persönliche Erfahrung zentrale Rollen spielen (Metcalf et al. 2019). Für diesen Einsatz von KI bedarf es also einer Modularisierung von Arbeit und einer Distinktion zwischen Anteilen, die KI und Menschen übernehmen, sowie der Definition von Schnittstellen zwischen beiden Anteilen (Tschang und Mezquita 2020). Die Implikationen von KI für die menschliche Arbeit sind dabei vielschichtig und die Interaktion von Mensch und Maschine im Arbeitskontext bedarf weiterer umfangreicher Forschung (Kellogg et al. 2020).

2.2 Automatisierung vs. Erweiterung als paradoxe Beziehung

Organisationen können KI-basierte Anwendungen dazu nutzen, Prozesse und Arbeit zu automatisieren und/oder menschliche Arbeit zu erweitern. Automatisierung bedeutet, dass Maschinen menschliche Arbeit ersetzen, indem sie Aufgaben von diesen übernehmen. In dieser Perspektive sind KI-Anwendungen, wie zuvor andere Technologien, Auslöser einer neuen Automatisierungswelle (Jarrahi 2018). Während Wissensarbeiter*innen bislang als immun gegen Automatisierung galten, betrifft diese KI-basierte Automatisierung nun auch komplexere Aufgabenstellungen, die den Umgang mit Wissen, Informationen und Entscheidungen beinhalten (Davenport und Kirby 2016). Ein vielzitiert Bereich für den Wegfall menschlicher Arbeit sind KI-basierte Anwendungen im juristischen Bereich. So berichtet Donahue (2018) über eine Software beim Beratungsunternehmen JPMorgan, die 2017 in Kreditverträgen nach bekannten Risiken und Anomalien suchte, was zuvor jährlich 360.000 menschliche Arbeitsstunden in Anspruch nahm.

Eine Erweiterung (im Englischen als „augmentation“ bezeichnet) beinhaltet, dass Mensch und Maschine eng miteinander kooperieren, um eine Aufgabe auszuführen (Raisch und Krakowski 2020). Dabei soll der maschinelle Einsatz die menschlichen Fähigkeiten erweitern (Jarrahi 2018), statt sie zu ersetzen. Davenport und Kirby (2016) nennen als Beispiel für eine solche Erweiterung menschlicher Fähigkeiten die KI-basierte Astrophysiksoftware KIGEN, die die Verteilung von dunkler Materie im Weltall kartographieren kann. Die Software ermöglicht völlig neue Erkenntnisse basierend auf ihren Ergebnissen, würde aber Forscher nicht ersetzen, die die Ergebnisse der Kartographie erst interpretieren und verwenden müssen.

Raisch und Krakowski (2020) zeigen, dass einige Managementforscher*innen Wegfall und Erweiterung menschlicher Arbeit durch KI als eine Art Trade-off beschreiben, und argumentieren, dass die Trade-off-Perspektive vernachlässigt, dass Automatisierung

und Erweiterung in einer paradoxen Beziehung zueinander stehen. Paradoxien sind von beständigen Widersprüchen zwischen voneinander abhängigen Elementen gekennzeichnet (Gümüşay et al. 2020; Schad et al. 2016; Smith und Lewis 2011). Im Fall der Auswirkungen von KI auf die Arbeit mag es, wenn man sich auf eine bestimmte Aufgabe zu einem bestimmten Zeitpunkt fokussiert, zunächst so erscheinen, als müssten Manager*innen sich entscheiden, ob sie KI zum Wegfall oder zur Erweiterung menschlicher Arbeit nutzen wollen. Sobald man die räumliche oder zeitliche Skala jedoch erhöht, in dem man sich beispielsweise die Veränderung von Arbeit über einen längeren Zeitpunkt ansieht, wird, so Raisch und Krakowski (2020), jedoch sichtbar, dass ein Wegfall menschlicher Arbeitsprozesse nicht ohne die (periodische) Erweiterung menschlicher Arbeit möglich ist. Als Beispiel führen sie die Entwicklung einer KI-Anwendung an, die dabei hilft, Personal auszuwählen. So erfordert die Entwicklung der KI-Anwendung zunächst eine stärkere Involvierung von Personalexpert*innen, die eher technisch ausgerichtete Mitglieder des Entwicklungsteams dabei unterstützen, die für die KI-Anwendung relevanten Faktoren und Parameter zu identifizieren und diese entsprechend zu trainieren. Wenn die KI-Anwendung ausreichend trainiert ist, könnte es dann zeitweise zu einer Automatisierung der Erstauswahl von Bewerber*innen kommen. Spätestens zu dem Zeitpunkt, an dem sich die Kompetenzanforderungen an Jobprofile grundsätzlich ändern, müssten Personalexpert*innen jedoch wieder involviert werden.

3 Methodik

Unsere Studie basiert auf 19 Interviews von Oktober 2019 bis April 2020, die wir mit Hilfe von Mitarbeiter*innen mit Organisationen geführt haben, die KI-Anwendungen in ihren betrieblichen Abläufen einsetzen (KI-Anwender*innen) oder KI-Lösungen anbieten (KI-Anbieter*innen). Die Interviewteilnehmer*innen haben unterschiedliche Hintergründe, wobei die meisten Befragten der KI-Anwender*innen die KI-Einführung als Führungskraft begleitet haben. Wenn möglich wurden die Interviews aufgezeichnet und transkribiert. In Fällen, wo dies nicht möglich war, haben wir während des Gesprächs umfassend Notizen gemacht und diese anschließend in Gedächtnisprotokolle erweitert. Die Tab. 1 gibt eine Übersicht über die Organisationen, den Wirtschaftszweig (dem die Organisation zugeordnet werden kann), die Position der Interviewteilnehmenden sowie die Funktion der KI-Anwendung.

Die Datenanalyse beinhaltet eine ausführliche Analyse jedes einzelnen Anwendungsfalls hinsichtlich der Auswirkungen des KI-Einsatzes auf die Arbeit sowie einen systematischen Vergleich der Auswirkungen über die Fälle hinweg. Dazu haben sich die beteiligten Autoren mehrmals getroffen und die Kategorisierung der jeweiligen Auswirkungen und der jeweiligen Fälle diskutiert und abgestimmt. Im Ergebnisteil fokussieren wir uns auf vier Vignetten, die beispielhaft für die jeweiligen Typen von Auswirkungen auf die Arbeit stehen. Diese sind Ersatz, Einschränkung und Entlastung menschlicher Arbeit sowie Entstehung neuer, maschineller Arbeit.

Tab. 1 Übersicht der befragten Organisationen

Organisation	Anwender*in/ Anbieter*in	Wirtschaftszweig ^a	Position Interview- teilnehmer*in	KI-Anwendung
1	Anwender*in	Information und Kommunikation	Vizepräsident Data & Analytics	Unterstützung bei der Bildrecherche in der Produktion von Bildungs- medien
2	Anwender*in	Information und Kommunikation	Redaktionsleiter	Unterstützung bei dem Heraus- filtern von toxischen Online- Kommentaren
3	Anwender*in	Mischkonzern	Personalmanagerin	Unterstützung bei der Beantwortung von HR-Fragen im Personal- management
4	Anwender*in	Information und Kommunikation	Direktor des Kundendienstes	Unterstützung bei der Beantwortung von Kundenan- fragen
5	Anwender*in	Öffentliche Ver- waltung	Projektkoordinator	Unterstützung bei der Digitalisierung von historischen Bibliotheks- beständen
6	Anwender*in	Verarbeitendes Gewerbe	Entwickler	Unterstützung bei der Begutachtung von Ideen im Verbesserungs- management
7	Anwender*in	Information und Kommunikation	Produktmanager	Unterstützung bei Qualitätssicherung der Inhalte in einer Wissens- datenbank
8	Anwender*in	Öffentliche Ver- waltung	Leiter der Auto- matisierung	Unterstützung bei der Erschließung von wissen- schaftlichen Publikationen für einen Bibliotheks- katalog

(Fortsetzung)

Tab. 1 (Fortsetzung)

Organisation	Anwender*in/ Anbieter*in	Wirtschaftszweig ^a	Position Interview- teilnehmer*in	KI-Anwendung
9	Anwender*in	Information und Kommunikation	Redakteurin im Digital Resort	Unterstützung beim Heraus- filtern von toxischen Online- Kommentaren
10	Anwender*in	Finanz- und Ver- sicherungsdienst- leistungen	Partner	Unterstützung bei der Wirtschafts- prüfung
11	Anwender*in	Finanz- und Ver- sicherungsdienst- leistungen	Chefingenieur Strategie & Geschäfts-ent- wicklung	Unterstützung bei der Dokumenten- analyse in der Baufinanzierung
12	Anwender*in	Kunst, Unter- haltung und Erholung	Forschungsleiter	Unterstützung bei der Produktion von Exponaten
13	Anbieter*in	Information und Kommunikation	Geschäftsführer & Gründer	Unterstützung bei der redaktionellen Aufbereitung von Inhalten
14	Anbieter*in	Sonstige wirtschaftliche Dienstleistungen	Leiter der Marketingab- teilung	Unterstützung bei der Beantwortung von Kundenan- fragen
15	Anbieter*in	Sonstige wirtschaftliche Dienstleistungen	Geschäftsführer & Gründer	Unterstützung bei der Recherche und Aufbereitung von Informationen
16	Anbieter*in	Sonstige wirtschaftliche Dienstleistungen	Voice Architect	Unterstützung bei Sprach-Assistenz- systemen
17	Anbieter*in	Sonstige wirtschaftliche Dienstleistungen	Forschungs- direktor	Unterstützung bei der Diagnostik im Gesundheitswesen
18	Anbieter*in	Sonstige wirtschaftliche Dienstleistungen	Geschäftsführer & Mitgründer	Sprachkorrektur- dienst
19	Anbieter*in	Sonstige wirtschaftliche Dienstleistungen	Leiter der Marketingab- teilung	Unterstützung bei der Immobilien- verwaltung

^aDie Einordnung erfolgte nach der Klassifizierung der Wirtschaftszweige des statistischen Bundesamts: <https://www.destatis.de/DE/Methoden/Klassifikationen/Gueter-Wirtschaftsklassifikationen/klassifikation-wz-2008.html>

4 Ergebnisse

4.1 Ersatz menschlicher Arbeit

Der Ersatz menschlicher Arbeit durch den Einsatz von KI lässt sich anhand des KI-Einsatzes im Kundendienst bei Organisation 4 illustrieren. Sie setzt eine KI-Anwendung im Kundendienst ein, die einfache, sich oft wiederholende Kundenanfragen, die die Plattform per E-Mail erreichen, herausfiltert und automatisch beantwortet. Infolgedessen können sich die Mitarbeiter*innen, so der Leiter des Kundendiensts, auf komplexere Anfragen fokussieren. Auch wenn die Mitarbeiter*innen im Kundendienst durch den Einsatz der KI-Anwendung nicht überflüssig werden – da es immer noch ausreichend komplexe Kundenanfragen gibt, die die KI-Anwendung nicht bearbeiten kann – so kann man doch, bezogen auf die Beantwortung der häufig wiederholten, einfachen Kundenanfragen, von einem Ersatz menschlicher Arbeit sprechen, weil diese von der KI-Anwendung selbstständig bearbeitet werden.

4.2 Einschränkung menschlicher Arbeit

Eine weitere Auswirkung auf die Arbeit, die nach unserem Wissen in der Literatur so bisher noch keine Erwähnung gefunden hat, ist, dass der Einsatz von KI zu einer Einschränkung menschlicher Arbeit führen kann. Nehmen wir hierzu die Einführung eines KI-basierten Assistenzsystems im Personalwesen von Organisation 3 als Beispiel. Die Personalsachbearbeiter*innen des Konzerns schätzen das Assistenzsystem grundsätzlich, weil es ihnen hilft, Anfragen von Mitarbeiter*innen des Konzerns effizienter zu beantworten. Gleichzeitig schränkt die Nutzung des Assistenzsystems sie jedoch auch ein, weil sie den Anwender*innen ein beschränktes Set an Auswahlmöglichkeiten zur Verfügung stellt. Es ist durchaus denkbar, dass es in einigen Fällen Möglichkeiten zur Lösung des Problems eines Mitarbeitenden gegeben hätte, die nicht vom Assistenzsystem berücksichtigt werden. Eine Auswahl an Optionen ist somit nicht nur hilfreich, sondern auch einschränkend.

4.3 Entlastung menschlicher Arbeit

Die Entlastung menschlicher Arbeit durch KI lässt sich gut anhand des KI-Einsatzes im Ideenmanagement bei Organisation 6 veranschaulichen. Das Ideenmanagement ist eine Abteilung innerhalb des Personalbereichs, in der Verbesserungsideen der Mitarbeiter*innen zu betrieblichen Abläufen entgegengenommen und auf Basis definierter Regelungen begutachtet werden. Da jährlich mehr als 20.000 Ideen eingereicht werden, muss jede*r Mitarbeiter*in der Abteilung über 1000 Ideen pro Jahr bearbeiten. Die Bearbeitung einer Idee ist aufwendig und kompliziert. So müssen zur Bewertung zum

Beispiel geeignete Gutachter*innen identifiziert werden, die Fachexpert*innen auf ihrem Gebiet sind. Diese ausfindig zu machen, ist aufgrund der Größe des Unternehmens und der Vielfalt der Themen sehr zeitaufwendig. Seit 2017 unterstützt eine intern von einem Mitarbeiter der Strategie- und Innovationsabteilung des Personalbereichs entwickelte KI-Anwendung die Mitarbeiter*innen des Ideenmanagements bei der Identifizierung von Gutachter*innen. Wenn ein*e Mitarbeiter*in die KI-Anwendung nutzt, sucht diese nach ähnlichen Ideen in einer Datenbank, in der frühere Verbesserungsideen archiviert werden. Aus den Vorschlägen der KI-Anwendung gehen auch die mit den Ideen betrauten Gutachter*innen hervor. Ob die Mitarbeiter*innen des Ideenmanagements die von der KI-Anwendung vorgeschlagenen Gutachter*innen für die Bearbeitung neuer Verbesserungsideen letztlich heranziehen, entscheiden diese jedoch basierend auf ihrem Fachwissen und ihrer Erfahrung selbstständig. Insgesamt führt der Einsatz der KI-Anwendung also zu einer engen Kooperation zwischen Mitarbeiter*innen des Ideenmanagements und der eingesetzten KI-Anwendung und damit zu einer Entlastung der Mitarbeiter*innen.

4.4 Entstehung neuer, maschineller Arbeit

Eine weitere Auswirkung des KI-Einsatzes ist die Entstehung neuer Arbeitsaufgaben, die von der KI übernommen werden. Ein gutes Beispiel dafür ist Organisation 15, ein Start-up, das es Firmen ermöglicht, systematisch Informationen zu Marktgeschehen, politischen Entwicklungen und der Reputation des eigenen Unternehmens zu beobachten. Dazu analysiert die Anwendung kontinuierlich Daten aus Online-Quellen, wie z. B. sozialen Medien, Nachrichtenseiten und Blogs, ebenso wie Print, TV und Radio. Auch wenn es stets menschliche Medienbeobachter*innen gegeben hat, so war die Analyse und Auswertung oft eine Aufgabe, die mehrere Tage, Wochen oder gar Monate dauerte. Eine fast unmittelbare Auswertung einer Vielzahl von Online-Quellen wäre allein mit menschlicher Arbeit nicht möglich gewesen. Hier wird also von der KI Arbeit verrichtet, die sonst nicht ausgeübt worden wäre.

5 Implikationen

5.1 Künstliche Intelligenz und menschliche Arbeit

Es besteht die Möglichkeit, dass KI menschliche Arbeit quantitativ stärker ersetzen wird als vergangene Technologien (Acemoglu und Restrepo 2018). Mindestens so wichtig ist auch nach der Art und Qualität der Arbeit zu schauen (Wajcman 2019). Dabei müssen wir insbesondere versuchen, unbeabsichtigte Nebeneffekte von digitalen Technologien (Smith 1995) im Zusammenhang mit komplexer Wissensarbeit zu verstehen (Ogolla und Send 2020). Inwiefern der Einsatz von Technologien und insbesondere

Automatisierung menschliche Arbeit qualitativ verändert, ist in der Soziologie eine Debatte mit langer Tradition (Giddens et al. 2016). Die empirischen Erkenntnisse zu diesem Thema gehen dabei weit auseinander und reichen von einer Abnahme menschlicher Freiheit und Kontrolle, Entfremdung und dem Abbau von Fähigkeiten bis zu diametral entgegengesetzten Überlegungen, wie dass Automatisierung zu einem Anstieg an Freiheit und abnehmender Entfremdung führt (Giddens et al. 2016). Der Fokus dieses Kapitels liegt darauf, wie der Einsatz von KI vom Menschen ausgeführte Aufgaben verändert. Es bedarf weiterer Untersuchungen dessen, wie die beteiligten Mitarbeiter*innen diese Veränderungen erfahren.

Wir haben die Auswirkungen entlang von 4E klassifiziert: Ersatz, Einschränkung, Entlastung und Entstehung. Die Implikationen des Ersatzes menschlicher Arbeit werden in der Literatur bereits prominent diskutiert. Zu wenig Beachtung finden hingegen die von uns beschriebenen Szenarien der Einschränkung und der Entstehung. Die Übergänge zwischen den 4E sind sicherlich fließend und teilweise lassen sich Fälle mehreren Typen von Auswirkungen zuordnen. Auch kann eine KI-Anwendung für einige Mitarbeiter*innen Entlastung und für andere Einschränkung bedeuten. Es ist wichtig zu betonen, dass der Einsatz von KI Arbeit vielschichtig prägt. Kellogg et al. (2020) bieten hierfür einen umfassenden konzeptionellen Rahmen, den wir durch empirische Beispiele komplementieren. Auch der Hinweis darauf, dass eine Erweiterung von Arbeit durch KI nicht gleichzusetzen ist mit mehr Freiheit und Optionen, ist eine wichtige Erkenntnis, die so in der Literatur noch nicht aufgezeigt wurde. Damit bieten wir auch einen Beitrag zur Paradoxliteratur (Gümüşay et al. 2020; Schad et al. 2016; Smith und Lewis 2011), indem wir empirisch zeigen, dass eine Auswahl von Optionen durch eine KI einerseits den Prozess erleichtert, andererseits auch einschränkt. Unsere Vignette zur Einschränkung ist im Grunde kognitiver Art. Kognitiv bedeutet hier, dass sich Arbeiter*innen aufgrund der Arbeit von KI keine anderen Optionen vorstellen können, obgleich sie noch möglich wären. Mindestens zwei weitere potenzielle Paradoxien sind technischer bzw. normativer Natur. Technisch bedeutet, dass die KI dem Menschen Arbeit abnimmt und gleichzeitig einschränkt, indem nur eine gewisse Anzahl an Optionen überhaupt auswählbar ist. Normativ bedeutet, dass andere Optionen durchaus denkbar sind, es allerdings schwierig sein kann, Optionen zu wählen, die nicht von der KI vorgeschlagen worden sind. Wiederholtes Abweichen, insbesondere bei negativen Folgen, kann so in Organisationen zu besonderem Rechtfertigungsdruck führen.

Die 4E können als Analyseraster dienen, um Auswirkungen des Einsatzes von KI-Technologie besser zu beschreiben und einen aktiven Umgang mit ihrem Einsatz zu finden. Unsere Fallbeispiele deuten darauf hin, dass die Frage, ob eine Technologie entlastend, einschränkend oder ersetzend wirkt, weniger eine Frage der Technologie, als eine Frage der organisatorischen Einbettung ist. Da der einschränkende Einsatz von Technologie kritische Implikationen wie Autonomieverlust und damit sinkende Attraktivität von Arbeitsplätzen (Güntert 2015), den Abbau von Fähigkeiten durch Deskilling (Davenport und Kirby 2016) und eine nachfolgende Abhängigkeit von

IT-Systemen (Anderson et al. 2018) haben kann, sollte insbesondere der einschränkende Einsatz von KI bedacht und begründet gewählt werden.

5.2 Künstliche Intelligenz und organisationale Veränderungen

Während KI bisher vielfältig aber zugleich nur verstreut eingesetzt wird, hat die Technologie bereits eine sehr große Wirkungsmächtigkeit. Dies hat drei Gründe. Erstens wirft der Einsatz einer neuartigen Technologie viele grundsätzliche Fragen auf, die beantwortet werden müssen, unabhängig davon, ob eine Technologie umfassend oder nur teilweise eingesetzt wird. Zweitens gibt es große Erwartungshaltungen und Unsicherheiten, die mit KI verbunden sind, sodass teilweise weniger KI selbst, als vielmehr die Erwartung an KI Reaktionen hervorruft. Drittens hat der Einsatz von KI Auswirkungen auf die verschiedenen Schnittstellen, die mit der KI interagieren. Während KI also teils nur punktuell und modular eingesetzt wird, wirkt sie trotzdem direkt oder indirekt in weite Teile von Organisationen. Auswirkungen sowie Bedeutung von KI müssen daher organisational verankert werden.

5.3 Potenzielle gesellschaftliche Auswirkungen

Einige Forscher*innen gehen davon aus, dass die zunehmende Übernahme analytischer Aufgaben durch KI dazu führen könnte, dass Menschen mehr in Richtung von Aufgaben gravitieren, die Empathie und zwischenmenschliche Fähigkeiten benötigen, sodass wir zunehmend die Entstehung einer „feeling economy“ beobachten können und werden (Huang und Rust 2018; Huang et al. 2019). Unsere Ergebnisse deuten in eine ähnliche Richtung. So entlasten Chatbots in Bereichen wie Kundendienst oder auch Personalwesen die Mitarbeiter*innen von repetitiven und leicht zu beantwortenden Anfragen, sodass diese sich theoretisch verstärkt ihren Kund*innen widmen könnten – zumindest solange Beschäftigte im Zuge der teilweisen Automatisierung des Kundendienstes nicht abgebaut werden. Der Einsatz von KI kann daher ein hohes Maß an kreativem Potenzial ermöglichen, wenn er zu einer besonderen Arbeitsteilung führt, indem vergleichsweise banale Aufgaben von Technologien und anspruchsvollere Aufgaben durch Menschen ausgeübt werden. Wenn dieses weit verbreitet geschieht, kann das durchaus Auswirkungen auf das gesellschaftliche Zusammenleben haben: von der Stellung und dem Umfang von Arbeit bis hin zur grundsätzlichen Befähigung von Menschen. Mit anderen Worten kann anspruchsvollere Arbeit durchaus zu einer Art „upskilling“ führen.

6 Konklusion

Die Frage danach, wie die Zukunft der Arbeit aussehen könnte, beschäftigt Praktiker*innen (Manyika 2017), Politiker*innen (Bundesministerium für Arbeit und Soziales 2018; Bundesministerium für Bildung und Forschung 2016; Bundesministerium für Wirtschaft und Energie 2014) und Wissenschaftler*innen unterschiedlichster Disziplinen (Brynjolfsson und McAfee 2014; Howard 2019; Jarrahari 2018; Spencer 2018). Der zunehmende Einsatz von KI spielt in dieser Debatte eine zentrale Rolle. Einige Autor*innen argumentieren, dass erste Anzeichen dafür, wie die Zukunft der Arbeit aussehen könnte, bereits sichtbar sind (Kaplan 2020; Lobo 2019; von Richthofen 2020). Die Erkenntnisse dieses Kapitels decken sich mit dieser Einschätzung. KI übernimmt zurzeit sehr spezifische Arbeitspraktiken. Allerdings haben selbst diese begrenzt intelligenten KI-Anwendungen bereits weitreichende potenzielle Implikationen für Arbeit, Organisationen und Gesellschaft. Wir haben die Auswirkungen auf die Arbeit exemplarisch empirisch aufgezeigt und deren organisationale und gesellschaftliche Implikationen erläutert. Mit der steigenden Nutzung von KI erwarten wir entsprechend eine Zunahme dieser Auswirkungen. Daher ist es wichtig, empirische Daten zur Nutzung und Verbreitung von KI in Organisationen zu sammeln und auszuwerten – insbesondere, weil selbst eine modulare Nutzung von KI bereits Auswirkungen außerhalb dieses Moduls hat. Während KI häufig modular konzipiert wird, müssen die Implikationen umfassender betrachtet werden.

Danksagung Wir bedanken uns herzlich bei Shirley Ogolla und Vivien Hard für die umfassende Unterstützung bei der Datenerhebung.

Literatur

- Acemoglu D, Restrepo P (2018) Artificial intelligence, automation and work. National Bureau of Economic Research. <https://www.nber.org/papers/w24196>
- Agrawal A, Gans J, Goldfarb A (2018) The economics of artificial intelligence. McKinsey Quarterly
- Anderson J, Rainie L, Luchsinger A (2018) Artificial intelligence and the future of humans, Pew Research Center, December
- Arntz M, Gregory T, Zierahn U (2017) Revisiting the risk of automation. *Economics Letters* 159:157–160. <https://doi.org/10.1016/j.econlet.2017.07.001>
- Bailey D, Faraj S, Hinds P, von Krogh G, Leonardi P (2019) Special issue of organization science: emerging technologies and organizing. *Organ Sci* 30(3):642–646. <https://doi.org/10.1287/orsc.2019.1299>
- Brynjolfsson E, McAfee A (2014) The second machine age: work, progress, and prosperity in a time of brilliant technologies. WW Norton & Company, New York
- Bundesministerium für Arbeit und Soziales (2018) Digitale Transformation ist Herausforderung und Ermutigung [Pressemeldung]. <https://www.bmas.de/DE/Presse/Pressemitteilungen/2018/bundesarbeitsminister-eroeffnet-denkfabrik-digitale-arbeitsgesellschaft.html>

- Bundesministerium für Bildung und Forschung (2016) Zukunft der Arbeit: Innovationen für die Arbeit von morgen. https://www.bmbf.de/upload_filestore/pub/Zukunft_der_Arbeit.pdf
- Bundesministerium für Wirtschaft und Energie (2014) Zukunft der Arbeit in Industrie 4.0. https://www.bmwi.de/Redaktion/DE/Publikationen/Digitale-Welt/zukunft-der-arbeit-in-industrie-4-0.pdf?__blob=publicationFile&v=3
- Davenport TH, Kirby J (2016) Only humans need apply: winners and losers in the age of smart machines. Harper Business, New York
- De Bruyn A, Viswanathan V, Beh YS, Brock JK-U, von Wangenheim F (2020) Artificial intelligence and marketing: pitfalls and opportunities. *J Interact Mark*. <https://doi.org/10.1016/j.intmar.2020.04.007>
- Donahue L (2018) A primer on using artificial intelligence in the legal profession. *JOLT Digest*. <http://jolt.law.harvard.edu/digest/a-primer-on-using-artificial-intelligence-in-the-legal-profession>
- Faraj S, Pachidi S, Sayegh K (2018) Working and organizing in the age of the learning algorithm. *Inf Organ* 28(1):62–70. <https://doi.org/10.1016/j.infoandorg.2018.02.005>
- Giddens A, Duneier M, Appelbaum RP, Carr DS (2016) Introduction to sociology. W. W. Norton & Company, New York
- Gümüşay Ali Aslan, Smets Michael, Morris Timothy (2020) ‚God at work‘: engaging central and incompatible institutional logics through elastic hybridity. *Acad Manag J* 63(1):124–54
- Güntert ST (2015) The impact of work design, autonomy support, and strategy on employee outcomes: a differentiated perspective on self-determination at work. *Moti Emot* 39(1):74–87. <https://doi.org/10.1007/s11031-014-9412-7>
- Howard J (2019) Artificial intelligence: implications for the future of work. *Am J Ind Med* 62(11):917–926. <https://doi.org/10.1002/ajim.23037>
- Huang M-H, Rust R, Maksimovic V (2019) The feeling economy: managing in the next generation of artificial intelligence (AI). *Calif Manag Rev* 61(4):43–65. <https://doi.org/10.1177/0008125619863436>
- Huang M-H, Rust RT (2018) Artificial intelligence in service. *J Serv Res* 21(2):155–172. <https://doi.org/10.1177/1094670517752459>
- Jarrahi MH (2018) Artificial intelligence and the future of work: human-AI symbiosis in organizational decision making. *Bus Horiz* 61(4):577–586. <https://doi.org/10.1016/j.bushor.2018.03.007>
- Kaplan A (2020) Hochschulbildung in Zeiten der Künstlichen Intelligenz. In: Nachwei J, Sureth A (Hrsg) Zukunft der Arbeit – ein Panorama aus 100+ Feldern. HR Consulting Review. https://www.researchgate.net/profile/Jens-Nachtwei/publication/345670805_Sonderband_Zukunft_der_Arbeit/links/5faa6afda6fdcc06242522b3/Sonderband-Zukunft-der-Arbeit.pdf
- Kellogg, K. C., Valentine, M. A., & Christin, A. (2020). Algorithms at Work: The New Contested Terrain of Control. *Academy of Management Annals*, 14(1), 366–410. <https://doi.org/10.5465/annals.2018.0174>
- Lobo S (2019) Realitätsschock – Zehn Lehren aus der Gegenwart. Kiepenheuer & Witsch, Köln
- Manyika J (2017) Technology, jobs and the future of work. <https://dln.jaipuria.ac.in:8080/jspui/bitstream/123456789/1891/1/MGI-Future-of-Work-Briefing-note-May-2017.pdf>
- Metcalf L, Askay DA, Rosenberg LB (2019) Keeping humans in the loop: pooling knowledge through artificial swarm intelligence to improve business decision making. *Calif Manag Rev* 61(4):84–109. <https://doi.org/10.1177/0008125619862256>
- Ogolla S, Send H (2020) Konkurrent oder Komplementär? Herausforderungen und Potenziale beim Einsatz von Enterprise Social Software im Kontext betrieblicher Mitbestimmung. In: Bader V, Kaiser S (Hrsg) Arbeit in der Data Society – Herausforderungen, Chancen und Zukunftsvisionen für Mitbestimmung und Personalmanagement. Springer, Heidelberg

- Pesapane F, Codari M, Sardanelli F (2018) Artificial intelligence in medical imaging: threat or opportunity? Radiologists again at the forefront of innovation in medicine. *Eur Radiol Exp* 2(1):35. <https://doi.org/10.1186/s41747-018-0061-6>
- Rai A, Constantinides P, Sarker S (2019) Editor's comments: next-generation digital platforms: toward human–AI hybrids. *MIS Q* 43(1):iii–x
- Raisch S, Krakowski S (in press) Artificial intelligence and management: the automation-augmentation paradox. *Acad Manag Rev* <https://journals.aom.org/doi/abs/10.5465/2018.0072>
- Schad J, Lewis MW, Raisch S, Smith WK (2016) Paradox research in management science: looking back to move forward. *Acad Manag Ann* 10(1):5–64. <https://doi.org/10.5465/19416520.2016.1162422>
- Shrestha YR, Ben-Menahem SM, von Krogh G (2019) Organizational decision-making structures in the age of artificial intelligence. *Calif Manag Rev* 61(4):66–83. <https://doi.org/10.1177/0008125619862257>
- Smith P (1995) On the unintended consequences of publishing performance data in the public sector. *Int J Public Adm* 18(2–3):277–310. <https://doi.org/10.1080/01900699508525011>
- Smith Wendy K, Lewis Marianne W (2011) Toward a theory of paradox: a dynamic equilibrium model of organizing. *Acad Manag Rev* 36(2):381–403
- Spencer DA (2018) Fear and hope in an age of mass automation: debating the future of work. *New Technol Work Employ* 33(1):1–12. <https://doi.org/10.1111/ntwe.12105>
- Tschang, F. T., & Mezquita, E. A. (2020). Artificial Intelligence as Augmenting Automation: Implications for Employment. *Academy of Management Perspectives*, 0(ja), null. <https://doi.org/10.5465/amp.2019.0062>
- von Krogh G (2018) Artificial intelligence in organizations: new opportunities for phenomenon-based theorizing. *Acad Manag Discov* 4(4):404–409. <https://doi.org/10.5465/amd.2018.00>
- von Richthofen G (2020) Algorithmisches Management und seine Folgen: Arbeiten in der Sharing Economy. In: Nachwei J, Sureth A (Hrsg) *Zukunft der Arbeit – ein Panorama aus 100+ Feldern*. HR Consulting Review. https://www.researchgate.net/profile/Jens-Nachtwei/publication/345670805_Sonderband_Zukunft_der_Arbeit/links/5faa6afda6fdcc06242522b3/Sonderband-Zukunft-der-Arbeit.pdf
- Wajcman J (2019) Automatisierung: Ist es diesmal wirklich anders? In *Marx und die Roboter: Vernetzte Produktion, Künstliche Intelligenz und lebendige Arbeit*, Bd 1. Karl Dietz Berlin GmbH, Berlin

Dr. Georg von Richthofen ist Senior Researcher in der Innovation, Entrepreneurship & Gesellschaft Forschungsgruppe am Humboldt Institut für Internet und Gesellschaft (HIIG). Im Projekt „Künstliche Intelligenz & Wissensarbeit“ erforscht er den Einsatz von künstlicher Intelligenz in der Wissensarbeit. Seine weitere Forschung fokussiert sich auf die Sharing Economy und ist in der Konsum- und Marketingforschung angesiedelt.

Dr. Ali Aslan Gümüşay ist Forschungsgruppenleiter für Innovation, Entrepreneurship & Gesellschaft am Humboldt Institut für Internet und Gesellschaft und Habilitand an der Universität Hamburg. Seine Forschung besteht aus vier Bereichen: Werte, Sinn und Hybridität in Entrepreneurship; gesellschaftliche Herausforderungen, Innovation und neue Formen des Organisierens; gesellschaftliche Komplexität und Wissenschaft sowie Digitalisierung und die Zukunft der Arbeit/Führung. Er hat in Zeitschriften wie *Academy of Management Journal*, *Academy of Management Perspectives*, *Business & Society*, *Journal of Business Ethics*, *Organization Theory*, *Research in the Sociology of Organizations* und *Research Policy* publiziert.

Dr. Hendrik Send ist Professor für Betriebswirtschaft, insbesondere Marketing, an der Hochschule für Technik und Wirtschaft (HTW) Berlin. Am Humboldt Institut für Internet und Gesellschaft untersucht er als assoziierter Forscher die Auswirkungen künstlicher Intelligenz auf Wissensarbeit für das Bundesministerium für Arbeit. Seine Forschungsthemen sind digitale Innovation und Nutzerverhalten in der digitalen Welt. Zuvor war er Leiter der Forschung und Beratung am Institute of Electronic Business Berlin und promovierte an der Universität St. Gallen zum Thema Innovations-Communities und Ideengenerierung.

Open Access Dieses Kapitel wird unter der Creative Commons Namensnennung 4.0 International Lizenz (<http://creativecommons.org/licenses/by/4.0/deed.de>) veröffentlicht, welche die Nutzung, Vervielfältigung, Bearbeitung, Verbreitung und Wiedergabe in jeglichem Medium und Format erlaubt, sofern Sie den/die ursprünglichen Autor(en) und die Quelle ordnungsgemäß nennen, einen Link zur Creative Commons Lizenz beifügen und angeben, ob Änderungen vorgenommen wurden.

Die in diesem Kapitel enthaltenen Bilder und sonstiges Drittmaterial unterliegen ebenfalls der genannten Creative Commons Lizenz, sofern sich aus der Abbildungslegende nichts anderes ergibt. Sofern das betreffende Material nicht unter der genannten Creative Commons Lizenz steht und die betreffende Handlung nicht nach gesetzlichen Vorschriften erlaubt ist, ist für die oben aufgeführten Weiterverwendungen des Materials die Einwilligung des jeweiligen Rechteinhabers einzuholen.





Künstliche Intelligenz: Wegbegleiter für ein neues menschliches „Maß“? – Ein kurzer Ausblick

René Schmidpeter

1 Künstliche Intelligenz verändert unsere Gesellschaft und Wirtschaft

In den aktuellen Beiträgen zur künstlichen Intelligenz (KI) sieht man verschiedene Menschen- und Gesellschaftsbilder: von einer Totalüberwachung der Gesellschaft und Wirtschaft bis hin zur Weiterentwicklung des menschlichen Denkens in Form neuer Kreativität, unterstützt durch die Rechenkraft von Computern. Es stellt sich die berechnete Frage: Ist die KI eine Chance zur Befreiung des Menschen oder ein neuer goldener Käfig, der menschliches Handeln begrenzt bzw. sogar limitiert? Die heutigen Entscheidungen in der Frage wie wir das Verhältnis Mensch-Maschine ausgestalten, werden auch für unsere Kinder und Enkelkinder relevant sein. Umso wichtiger ist es, das Verhältnis Mensch-Maschine auch im erweiterten Dreieck Mensch-Maschine-Wirtschaft zu erörtern, denn es sind oft die wirtschaftlichen Anwendungsfelder, die die Weiterentwicklung von Technologien und deren Akzeptanz in der Gesellschaft beeinflussen.

Daher ist die Frage nach der gesellschaftlichen Verantwortung von Unternehmen im Anwendungsfeld KI mehr als berechnigt. Vor allem auch, weil die digitalen Technologien sich derzeit immer dynamischer entwickeln. So brauchte das Telefon noch rund 75 Jahre, um 100 Mio. Nutzer zu erreichen (Statista 2017). Das schaffen neue Systeme, wie z. B. digitale Kommunikationsdienste nunmehr in wenigen Monaten. Mittlerweile sind rund 60 % der österreichischen Internetnutzer in elektronischen Kommunikationsplattformen

R. Schmidpeter (✉)
Köln, Deutschland
E-Mail: schmidpeter@m3trix.de

aktiv (Statista 2020). Weltweit nutzen über 4 Milliarden Menschen Social Networks (We Are Social 2018). Experten des World Economic Forum prognostizieren, dass in den nächsten Jahren ein Großteil der Weltbevölkerung über ein Online-Profil verfügen werden (World Economic Forum 2018). Diese globale Verbreitung der digitalen Technologien ist die Basis einer globalen Wirtschaftstransformation, die auch bis in die geografisch entlegenen Weltregionen wirkt.

Auch im Gesundheitssystem sehen wir mehr und mehr digitale Anwendungen. Mittlerweile nutzen rund die Hälfte der Deutschen Gesundheits-Apps auf ihrem Smartphone (Bitkom 2017). Und der digitale Gesundheitsmarkt wird in Europa auf rund 250 Mrd. EUR und weltweit auf rund 1 Billionen EUR wachsen (Berger 2020). Aber auch die Schulen zeigen immer mehr Affinität zu digitalen Lehrinhalten und -methoden. So sind die LehrerInnen und SchülerInnen der Meinung, dass neue Medien die Attraktivität der Schulbildung erhöhen werden (Bertelsmann Stiftung 2017). Insbesondere getriggert durch die jüngsten Effekte der Coronapandemie sind im Bildungssystem weitere Dynamiken hin zu digitalen Lernmethoden und -plattformen zu erkennen. Und auch im privaten Bereich erfreuen sich digitale Assistenzroboter und Online-Systeme immer größerer Beliebtheit. Insbesondere im Banking zeigt sich der Wachstum an digitalen Anwendungen. In den Finanzmärkten buhlen mittlerweile mehr als 3000 verschiedene Kryptowährungen um die Gunst der Nutzer. Der Wert dieser Online-Währungen steigt dynamisch und ist mittlerweile bei über 200 Mrd. US\$ (Statista, coinmarketcap 2019). Zudem erledigen mittlerweile über 75 % der Bundesbürger ihre Bankgeschäfte online (CGI 2018).

Der neue Mobilfunkstandard 5G, der demnächst auf den Markt kommt, wird die digitalen Märkte weiter exponentiell vergrößern und die bestehenden digitalen und analogen Technologien immer mehr miteinander vernetzen. So entstehen ein engmaschiges Internet der Dinge, Virtuelle Realitäten und neue Mensch-Maschine-Schnittstellen, die unser Leben und unsere Wirtschaft grundlegend neu definieren werden. Diese neue Welt ermöglicht dann ganz neue Anwendungen und wird auch die klassischen Märkte grundlegend verändern. Smart Cars, Smart Energy, Smart Health, Smart Living etc. eröffnen neue unternehmerische Möglichkeiten und Märkte der Zukunft.

2 Kritische Diskussionen erfordern neue Perspektiven

Jedoch zeigen die zunehmend auch kritische Diskussionen zu den aktuellen Digitalzukunftsvisionen und ein erstarkender Widerstand der Öffentlichkeit, dass nicht immer alles nach Plan der ambitionierten Techniker und visionären Wirtschaftslenker läuft. Rund 70 % der Deutschen glauben, dass ihre Daten im Netz völlig unsicher seien (Statista, bitkom 2020). Dieses Misstrauen gegen neue Technologien zeigt, dass die sozialwissenschaftliche und wirtschaftswissenschaftliche Gestaltung der soziotechnologischen Prozesse aus neuen Perspektiven diskutiert werden muss. Denn nicht der technologische Fortschritt ist der limitierende Faktor, sondern das menschliche Maß, die

Akzeptanz in der Bevölkerung und die positiven Anwendungsfelder in der Wirtschaft. Unternehmen sind gefordert, die neuen Technologien in nachhaltige Geschäftsmodelle zu übersetzen, die positiven Impact für alle generieren und dabei den menschlichen Bedürfnissen folgen.

Den Grundoptimismus, dass uns Technologien helfen können, gesellschaftlichen und unternehmerischen Mehrwert zu generieren, gilt es dabei zu erhalten. Denn Computeralgorithmen können durchaus helfen, komplexe Herausforderungen besser und schneller zu lösen. Jedoch können sie menschliche Intelligenz nicht vollständig kopieren und vor allem können sie nicht die Vernunft (eines der wichtigsten menschlichen Alleinstellungsmerkmale) ersetzen. Computer werden daher dem Menschen dienen und die menschliche Würde und die Menschenrechte unter allen Umständen anerkennen müssen. Dies ist die Aufgabe von uns allen, darauf zu achten, dass die Menschenwürde unantastbar bleibt und Computer sich auch in Zukunft diesem Primat unterordnen.

Eine zentrale Frage dabei ist, wie viel Transparenz der einzelne Mensch über die Verarbeitung seiner persönlichen Daten hat. Insbesondere in Europa wollen Nutzer die Kontrolle über ihre Daten behalten, dieses Recht auf Selbstbestimmung ist ein hohes Gut und muss auch von Maschinen berücksichtigt werden. Nichtsdestotrotz steht es den Menschen frei, mit ihrer Vernunft zu entscheiden, welche Daten sinnvollerweise für neue Anwendungen verwendet werden können bzw. sollen. In der aktuellen Pandemiesituation stellt sich daher die Frage grundlegend neu: Wie viel Datenschutz ist richtig und sinnvoll im Kampf gegen die Ausbreitung des Virus? Hier gibt es durchaus unterschiedliche Antworten, wie auch die Beispiele aus asiatischen Demokratien sowie der chinesische Weg einer kollektiven Gesellschaft zeigen. Wichtig wird auch sein, die Technologien für die nachhaltige Entwicklung der globalen Weltbevölkerung sowie der regionalen Räume zu nutzen.

3 Chancen der künstlichen Intelligenz in einer nachhaltigen Transformation

Mittels neuer technischer Möglichkeiten können wir Menschen sehr viel besser als bisher die Auswirkungen unseres Handelns begreifen und so neue Lösungen im Sinn unserer menschlichen Bedürfnisse entwickeln. Hier liegen wohl die größten Chancen einer Versöhnung zwischen Mensch und Maschine, wenn es gelingt die menschlichen Bedürfnisse als Maß der weiteren Entwicklungen zu erhalten, solange der Mensch der bestimmende Faktor und Kreativdenker bleibt. Hierin könnte auch die deutsche Erfolgsgeschichte von Industrie 4.0 im Gegensatz zu einem Technotalitarismus liegen. In der vernünftigen Anwendung von KI liegt somit auch eine Chance, neue Arbeitsplätze für den Menschen zu schaffen. Durch den Einsatz von Robotern und KI kann der Produktionsstandort Europa wieder an Bedeutung gewinnen und neue Unternehmen entstehen. Und auch analoge Produkte, ein Markenkern des deutschen Handwerks, haben in einer nachhaltigen digitalen Welt eine neue Alleinstellung und neue

Chancen. Insbesondere traditionelles Handwerk kann daher auch von digitalen Technologien profitieren und seine analoge Exzellenz weiter ausbauen und am Markt anbieten.

Der Wunsch des Menschen nach auf Basis von menschlicher Kreativität und Ästhetik geschaffenen Produkten und Dienstleistungen wird in einer immer mehr digitalen Welt eher zu- als abnehmen. Voraussetzung dafür ist, den Grundwert des menschlichen Maß in unserer Gesellschaft zu erhalten. Unsere Leben werden dann gleichzeitig ausdrücklich physisch und zugleich digital vernetzt sein. Wir werden immer mehr smarte Geschäftsmodelle sehen, die die analogen menschlichen Bedürfnisse in Form von ganz neuen Produkten und Dienstleistungen digital vernetzen und diese in Echtzeit anbieten.

Der Erfolg der Etablierung von KI wird davon abhängen, ob es den Unternehmen gelingt, mit KI positiven Impact für alle Stakeholder zu genießen und gleichzeitig einen positiven Impact für den Planeten zu liefern. Die aktuelle Diskussion um die CSR wird daher durch KI weiter an Bedeutung gewinnen und zentral, wenn es um die nachhaltige Transformation unserer Wirtschaft geht.

4 Weiterentwicklung der Corporate Social Responsibility

Aus der derzeit in rasender Geschwindigkeit ablaufenden Transformation unserer Gesellschaft ergeben sich insbesondere für die Unternehmen weitreichende Herausforderungen in der Gestaltung ihrer Wertschöpfungsstrategien und -prozesse durch KI-gestützte Technologien. Die Digitalisierung und insbesondere der Einzug von KI und Big Data beschleunigen die längst notwendige Entwicklung neuer nachhaltiger Unternehmensansätze und regionaler Innovationen.

Derzeit werden ganze Branchen und Regionen gleichzeitig, sowohl vom verstärkten gesellschaftlichen Nachhaltigkeitsdiskurs als auch von disruptiven Innovationen insbesondere aus der IT-Branche, herausgefordert. Durch diese Effekte der Globalisierung und Digitalisierung, wird der externe Druck auf die grundlegende Veränderung der Geschäftsmodelle als Ganzes immer größer. Denkt man Nachhaltigkeit aus einer konsequent unternehmerischen Perspektive, muss diese weit über eine reine Vermeidungslogik hinausgehen. Denn insbesondere für Unternehmer ist es wichtig, die positiven Auswirkungen ihres Handelns zu managen bzw. zu steigern. Bei dieser progressiven Sichtweise geht es nicht mehr zentral darum, den Schaden unternehmerischen Handelns zu minimieren, sondern die Wertschöpfung des Unternehmens für die Gesellschaft insgesamt zu erhöhen.

Dabei steht nicht das moralische Motiv des altruistischen Gebens im Vordergrund, sondern die ökonomische und gesellschaftliche Sinnhaftigkeit. Es geht bei diesem „neuen“ CSR-Verständnis nicht um das Durchbrechen der Wettbewerbslogik – wie von Sozialromantikern oft gern dargestellt – sondern ganz im Gegenteil: sie weitet die Marktmöglichkeiten durch die immer neuen Möglichkeiten der Digitalisierung aus. Dies schafft sowohl Mehrwert für die Gesellschaft als auch neue Geschäftsmöglichkeiten.

Die Potenziale eines verantwortungsvollen Unternehmertums können im Wandel der Digitalisierung effizient und effektiv genutzt werden, um die drängenden gesellschaftlichen Herausforderungen unternehmerisch zu lösen. Davon profitieren sowohl unsere Gesellschaft als auch die Unternehmen. Neue Technologien sind damit eine große Chance, unternehmerische Verantwortung positiv neu zu denken! Dazu müssen wir aber die KI-Algorithmen entlang der neuen Wirtschaftslogik programmieren. Es gilt, das klassische Gegensatzdenken zwischen Profit und Nachhaltigkeit auch in der digitalen Welt zu überwinden und so eine „neue“ intelligente Beziehung zwischen Mensch, Natur und Technik zu definieren, die die zukünftigen Möglichkeiten aller systematisch vergrößert und nicht gegeneinander ausspielt.

Hierin liegt die größte Chance und Gefahr zugleich. Die entscheidende Frage ist: Können wir Synergien zwischen der digitalen Welt der Computer und der analogen Welt des Menschen so nutzen, um einen gemeinsamen „purpose“ zu definieren, der wechselseitig in beiden Welten positiven Impact generiert. Dazu ist insbesondere eine ethische und wirtschaftswissenschaftliche Neuorientierung in der aktuellen Technologiediskussion notwendig, die den Menschen als Maß der weiteren Entwicklung ausdrücklich definiert.

Es wird dann kein Unternehmen länger erfolgreich sein – welches alte Geschäftsmodelle mehr schlecht, als recht auf Nachhaltigkeit trimmt –, vielmehr braucht es dann ganz „neue“, von Grund auf nachhaltige Geschäftsmodelle! Denn um den gegenwärtigen gesellschaftlichen und ökologischen Herausforderungen erfolgreich zu begegnen, bedarf es vermehrter ökologischer und sozialer Innovationen. Unternehmerische Kreativität und nachhaltige Wertschöpfung sind die Leitplanken für den wirtschaftlichen Erfolg sowie die weitere Entwicklung von KI.

5 Visionäre Unternehmer setzen auf Künstliche-Intelligenz-Geschäftsmodelle mit positivem Impact

Visionäre Unternehmer und verantwortungsbewusste Wirtschaftslenker haben die Zeichen der Zeit erkannt und generieren neue KI-unterstützte Geschäftsmodelle, die Lösungen für drängende gesellschaftliche Probleme aufzeigen. Der Ansatz „unternehmerischer Wertschöpfung verbunden mit nachhaltiger KI“ läutet ein neues Managementparadigma ein, das nicht nur jedes Unternehmen als Einzelnes, sondern ganze Branchen, Regionen und Wirtschaftsbereiche betrifft.

Wir befinden uns in einer der größten wirtschaftlichen und gesellschaftlichen Transformationen seit der Industrialisierung. KI – richtig angewendet – kann hier große Unterstützung für die weitere Entwicklung der menschlichen Freiheit sein – wenn es gelingt, sie in den Dienst der menschlichen Vernunft und Kreativität zu stellen.

Wenn wir es schaffen, mithilfe der KI gesellschaftliche und ökologische Themen als unabdingbaren Teil des unternehmerischen Geschäftsmodells sowie der weiteren globalen Entwicklung zu begreifen, entstehen ganz neue Lösungen, die wir dringend

brauchen, um die gegenwärtigen Herausforderungen in Wirtschaft und Gesellschaft zu lösen. Verantwortung und Unternehmertum sind so gesehen, zwei Seiten einer Medaille.

Die Transformation unserer Geschäftsmodelle durch neue Technologien einschließlich KI, ist daher nicht nur ethisch geboten, sondern ökonomisch notwendig und am Ende auch ein weiteres Mittel zur Befriedigung der Bedürfnisse von über 10 Mrd. Menschen und der Wahrung der menschlichen Würde und individuellen Freiheit.

Weiterführende Literatur

- Berger R (2020) Future of health – report. <https://www.rolandberger.com/de/Publications/Future-of-Health-Der-Aufstieg-der-Gesundheitsplattformen.html>
- Bitkom (2017) Fast jeder zweite nutzt Gesundheits-Apps. <https://www.bitkom.org/Presse/Presse-information/Fast-jeder-Zweite-nutzt-Gesundheits-Apps.html>
- CGI (2018) Financial consumer survey – white paper. <https://www.de.cgi.com/de/white-paper/banking-and-capital-markets/cgi-2018-financial-consumer-survey>
- Statista (2017) Key issues for digital transformation in G20. <https://de.statista.com/info-grafik/7573/geschwindigkeit-mit-der-sich-technologien-verbreiten/>
- Statista (2020) Nutzung von sozialen Netzwerken in Österreich nach Altersgruppen 2020. <https://de.statista.com/statistik/daten/studie/298406/umfrage/nutzung-von-sozialen-netzwerken-in-oesterreich-nach-altersgruppen/>
- Statista, bitkom (2020) <https://de.statista.com/statistik/daten/studie/217842/umfrage/sicherheit-von-persoenlichen-daten-im-internet/>
- Statista, coinmarketcap (2019) Aufwärtstrend bei Kryptowährungen. <https://de.statista.com/info-grafik/12186/unterschiedliche-krypto-coins-und-marktkapitalisierung/>
- Bertelsmann Stiftung (2017) Monitor Digitale Bildung. https://www.bertelsmann-stiftung.de/fileadmin/files/BSt/Publikationen/GrauePublikationen/BSt_MDB3_Schulen_web.pdf
- We Are Social (2018) Global Digital Report. <https://wearesocial.com/de/blog/2018/01/global-digital-report-2018>
- World Economic Forum (2018) <https://reports.weforum.org/digital-transformation/wp-content/blogs.dir/94/mp/files/pages/files/dti-executive-summary-20180510.pdf>

Prof. Dr. René Schmidpeter steht als innovativer Vordenker für einen Paradigmenwechsel in der BWL und in der Nachhaltigkeitsdiskussion. Er ist ein internationaler anerkannter Experte für strategisches Management, Unternehmenstransformation und globale Nachhaltigkeitsentwicklungen. In den letzten fünf Jahren veröffentlichte er in seinen deutsch- und englischsprachigen Managementreihen mehr als 150 Publikationen zum Thema CSR, Sustainability, Governance und Ethik im Springer Verlag. Er ist Berater und Mitgestalter in zahlreichen nationalen und internationalen Nachhaltigkeitsinitiativen und Thinktanks (China, Australien, Großbritannien, Japan, Slowenien, USA) und Mitbegründer der M3TRIX GmbH in Köln. Weblink: www.m3trix.de